

BỘ GIÁO DỤC VÀ ĐÀO TẠO
ĐẠI HỌC CẦN THƠ

TRẦN NAM HÙNG

NHẬN DẠNG THỐNG KÊ
CHO HÀM MẬT ĐỘ XÁC SUẤT MẤT CÂN BẰNG
VÀ ỨNG DỤNG CHO DỮ LIỆU ẢNH

LUẬN VĂN TỐT NGHIỆP THẠC SĨ

NGÀNH: LÝ THUYẾT XÁC SUẤT VÀ THỐNG KÊ TOÁN HỌC
MÃ SỐ: 8 46 01 06

NĂM 2025

BỘ GIÁO DỤC VÀ ĐÀO TẠO
ĐẠI HỌC CẦN THƠ

TRẦN NAM HÙNG
MÃ SỐ HỌC VIÊN: M1823002

NHẬN DẠNG THỐNG KÊ
CHO HÀM MẬT ĐỘ XÁC SUẤT MẤT CÂN BẰNG
VÀ ỨNG DỤNG CHO DỮ LIỆU ẢNH

LUẬN VĂN TỐT NGHIỆP THẠC SĨ
NGÀNH: LÝ THUYẾT XÁC SUẤT VÀ THỐNG KÊ TOÁN HỌC
MÃ SỐ: 8 46 01 06

CÁN BỘ HƯỚNG DẪN
PGS. TS. VÕ VĂN TÀI

NĂM 2025

CHẤP THUẬN CỦA HỘI ĐỒNG

Luận văn này với tựa đề là “**Nhận dạng thông kê cho hàm mật độ xác suất mất cân bằng và ứng dụng cho dữ liệu ảnh**”, do học viên Trần Nam Hưng thực hiện theo sự hướng dẫn của PGs. TS. Võ Văn Tài. Luận văn đã báo cáo và được Hội đồng chấm luận văn thông qua ngày 26, tháng 10, năm 2025. Luận văn đã được chỉnh sửa theo góp ý và được Hội đồng chấm luận văn xem lại.


Thành viên đọc luận văn sau khi chỉnh sửa

(Ký tên)**


Lê Hoài Nhân


Chủ tịch hội đồng

(Ký tên)*


Lê Văn Lý


Thư ký

(Ký tên)


Lê Hoài Nhân

Người hướng dẫn

(Ký tên)**


Võ Văn Tài

** : Căn cứ và Quyết nghị của Hội đồng đánh giá luận văn, những thành viên có yêu cầu hoặc được ủy quyền xem lại luận văn sau khi chỉnh sửa thì có phần xác nhận gồm họ tên và chữ ký của thành viên đó.

* : Ghi đầy đủ học hàm, học vị và họ tên. Chữ ký chấp thuận của Hội đồng là chữ ký trực tiếp.

LỜI CẢM TẠ

Hoàn thành luận văn, em nhận ra hành trình này được viết nên không những bằng tri thức, mà còn là tấm lòng, sự kiên định và ân nghĩa của bao người.

Trên hành trình đó, em xin gửi lời tri ân đến thầy hướng dẫn luận văn **PGs. TS. Võ Văn Tài** đã tận tình giảng dạy và tạo điều kiện cho em trong suốt quá trình học tập và nghiên cứu. Em đã làm nên nhờ thầy, thầy truyền phương pháp, truyền lửa, truyền lí tưởng sống cho em.

Đồng thời, em xin gửi lời cảm ơn chân thành đến quý thầy cô *Khoa Khoa học Tự nhiên - Đại học Cần Thơ*, cô Phạm Bích Như, thầy Nguyễn Hữu Khánh, thầy Trần Văn Lý, thầy Lâm Hoàng Chương và cô Dương Thị Bé Ba; Quý thầy từ Thành phố Hồ Chí Minh, thầy Lê Sĩ Đồng, thầy Phạm Bích Huy và thầy Tô Anh Dũng đã dạy em những kiến thức nền tảng, đã không tiếc công chỉ dẫn, trao đổi, định hướng cho em. Em xin cảm ơn TS. Nguyễn Trang Thảo, người anh cả của nhóm nghiên cứu, NCS Thái Minh Trọng, cùng quý đồng nghiệp tại *Viện Khoa học Tính toán và Trí tuệ Nhân tạo - trường Đại học Văn Lang* đã giúp em có thêm nhiều góc nhìn sâu sắc trong nghiên cứu.

Tôi xin cảm ơn vì Luận văn tốt nghiệp này được tài trợ bởi **Chương trình học bổng đào tạo thạc sĩ, tiến sĩ trong nước của Quỹ Đổi mới sáng tạo Vingroup (VINIF)**, mã số VINIF.2024.ThS.56. Đây không chỉ là sự hỗ trợ vật chất, mà là niềm tin mà Quỹ đã đặt vào thế hệ trẻ trên con đường nghiên cứu khoa học.

Con của mẹ Uyên, cha Trung, của ngoại, nội đã lớn rồi. Con biết những năm tháng qua là những tháng năm sống động nhất cuộc đời vì con là con của mẹ, là con của cha, là của nhà mình. Cảm ơn cả nhà vì đã luôn ủng hộ việc học của con, cho con tự do phiêu lưu trên hành trình tri thức, cho con được phép viết tiếp giấc mơ dở dang của cha mẹ. Con cảm ơn mẹ đã nhớ con lúc con đi làm xa, con cảm ơn cha đã sửa xe cho con sẵn sàng. Khi con về, vẫn thơm mùi cơm của Ngoại và vang tiếng cười của em Thy. Đồng thời, em cũng xin cảm ơn tấm lòng thơm thảo của anh Nguyễn Quốc Anh, cảm ơn những đêm cùng thức, cùng dỗi theo cổ vũ em. Người tri kỷ giỏi giang là một món quà quý, cũng là người thầy mà mình phải luôn ghi ơn. Sau cùng, tôi xin cảm ơn bản thân tôi đã luôn cố gắng ngày đêm. Vì tôi biết hạt giống học hành tôi gieo bây giờ đã ra hoa kết trái.


Do khả năng có hạn trong khi nguồn tri thức là vô hạn, luận văn này chắc chắn không tránh khỏi thiếu sót. Em kính mong nhận được góp ý quý báu từ Hội đồng bảo vệ cùng độc giả trong tương lai để luận văn ngày càng được hoàn thiện. Một lần nữa, em

xin chân thành cảm ơn tất cả những người đã đi cùng em qua chặng đường này và kính chúc cho tất cả quý vị có sức khỏe, bình an và hạnh phúc.

Cần Thơ, ngày 20 tháng 10 năm 2025

Tác giả

(Ký, họ và tên)


Trần Nam Hùng

TÓM TẮT NỘI DUNG

Luận văn này xây dựng thuật toán phân tích chùm và phân loại cho PDF với dữ liệu mất cân bằng, đồng thời áp dụng các thuật toán này cho dữ liệu ảnh khi các đặc trưng của nó được trích xuất và đại diện bởi PDF. Về phân tích chùm, luận văn đề xuất thuật toán phân tích chùm mờ cải tiến (IFCF) giải quyết “hiệu ứng đồng nhất” qua việc cải tiến hàm mục tiêu. Luận văn cũng đã thiết lập và chứng minh IFCF hội tụ dựa trên định lý Zangwill với một số điều kiện ràng buộc về khoảng cách. Về phân loại, luận văn thiết lập mô hình Bayes-IFCF mở rộng của IFCF sang bài toán phân loại có giám sát. Phương pháp này sử dụng ma trận phân vùng mờ từ IFCF để xác định xác suất tiên nghiệm đồng cho các lớp. Kết quả được đưa ra dưới dạng ví dụ số, cho thấy IFCF đạt hiệu suất gần như hoàn hảo ($ARI = 1,0; NMI = 1,0$) trên dữ liệu ảnh kết cấu Brodatz và Landsat. Mô hình Bayes-IFCF cũng cho kết quả nhất quán và chính xác cao ($GM = 1,0; F_1 = 1,0$) trong bài toán phân loại màu sắc các loại đất.

Từ khóa: *Nhận dạng thống kê; Hàm mật độ xác suất; Phân loại có giám sát; Phân tích chùm không giám sát; Dữ liệu hình ảnh*

ABSTRACT

This thesis develops cluster analysis and classification algorithms tailored for PDF, specifically in the context of imbalanced data. It applies these algorithms to image data where the PDF represent various features. A key aspect of this work is the enhancement of the objective function to achieve a “uniform effect”. Additionally, the thesis establishes and proves that the Improved Fuzzy C-means Framework (IFCF) converges based on Zangwill’s theorem, subject to certain distance constraints. In terms of classification, the thesis presents an extended Bayes-IFCF model designed for the supervised classification problem. This method utilises a fuzzy partition matrix derived from IFCF to determine prior probabilities for the classes dynamically. Results are illustrated through a numerical example, demonstrating that IFCF achieves near-perfect performance ($ARI = 1,0; NMI = 1,0$) on Brodatz and Landsat texture image datasets. Furthermore, the Bayes-IFCF model yields consistent and highly accurate outcomes ($GM = 1,0; F_1 = 1,0, p < 0,01$) in classifying soil colour.

Keywords: *Statistical Recognition; Probability Density Functions; Supervised Classification; Unsupervised clustering; Images data*

LỜI CAM ĐOAN

Tôi tên là Trần Nam Hưng, là học viên cao học ngành Lý thuyết Xác suất và Thống kê Toán học khóa 2023–2025. Tôi xin cam đoan luận văn này là công trình nghiên cứu khoa học thực sự của bản thân tôi được sự hướng dẫn của PGs. TS. Võ Văn Tài.


Các thông tin được sử dụng tham khảo trong đề tài luận văn được thu thập từ các nguồn đáng tin cậy, đã được kiểm chứng, được công bố rộng rãi và được tôi trích dẫn nguồn gốc rõ ràng ở phần Danh mục Tài liệu tham khảo. Các kết quả nghiên cứu được trình bày trong luận văn/đề án này là do chính tôi thực hiện một cách nghiêm túc, trung thực và không trùng lặp với các đề tài khác cùng cấp đã được công bố trước đây. Tác giả đồng ý về việc Nhà trường có quyền công bố và phổ biến để phục vụ nhu cầu đào tạo, nghiên cứu khoa học (NCKH) và phục vụ cộng đồng.

Tôi xin lấy danh dự và uy tín của bản thân để đảm bảo cho lời cam đoan này.

Cần Thơ, ngày 9 tháng 11 năm 2025


Người hướng dẫn

(Ký tên)


Võ Văn Tài

Tác giả thực hiện

(Ký tên)


Trần Nam Hưng

LÝ LỊCH CÁ NHÂN

1 Lý lịch sơ lược

Họ và tên	Trần Nam Hưng	Giới tính	Nam
Ngày sinh	03/4/2001	Dân tộc	Kinh
Nơi sinh	phường Cái Khế, TP. Cần Thơ	Điện thoại	(+84) 765 143 365
Trình độ	Cử nhân Toán Ứng Dụng	Năm tốt nghiệp	2023
Email	hungm1823002@gstudent.ctu.edu.vn		
Email	namhung34.info@gmail.com (Cá nhân)		
Địa chỉ	Số 86/11B, đường Cách Mạng Tháng Tám, phường Bình Thủy, TP. Cần Thơ		

2 Quá trình Đào tạo

Trình độ	Thời gian	Địa chỉ
THPT	2016–2019	<i>Trường THPT Thực hành Sư phạm – Đại học Cần Thơ.</i> Hệ đào tạo: Chính quy.
Đại học	2019–2023	<i>Khoa Khoa học Tự nhiên – Đại học Cần Thơ.</i> Ngành học: Toán Ứng dụng; Hệ đào tạo: Chính quy. Trình độ ngoại ngữ: B2
Thạc sĩ	2023–2025	<i>Khoa Khoa học Tự nhiên – Đại học Cần Thơ.</i> Ngành học: Lý thuyết Xác suất và Thống kê Toán học; Hệ đào tạo: Chính quy. Trình độ ngoại ngữ: B2

3 Danh mục các công trình đã công bố

Bài báo khoa học hỗ trợ nội dung luận văn Thạc sĩ của tác giả

- (i) **T. N. Hưng**, C. N. Thơ và V. V. Tài, “*Cải tiến thuật toán tự cập nhật chùm cho các hàm mật độ xác suất*”, CTU J. Sci., vol 61, số p.h 4, tháng 8 2025,
- (ii) T. M. Lượng, N. K. Ngân, **T. N. Hưng**, N. H. Chi, N. N. Huỳnh và V. V. Tài, “*Thuật toán xây dựng chùm ảnh dựa trên các pixel màu được trích xuất*”, CTU J. Sci., vol 60, số p.h CĐ Khoa học tự nhiên, tr 98-107, tháng 8 2024.

- (iii) **Tran-Nam, H.** & Che-Ngoc, H., *A Black-winged Kite Improved Fuzzy Clustering handling Imbalanced Uncertain Data*. PLUS ONE (2025). (Revised).
- (iv) **Tran-Nam, H.** & Vo-Van, T., *Developing Bayesian classifier algorithm for images based on fuzzy relationship of extracted features*. Japanese Journal of Statistics and Data Science. (Revised).


Bài báo khoa học hỗ trợ liên quan của tác giả

- (i) **Tran-Nam, H.**, Nguyen-Trang, T. & Che-Ngoc, H. *A new possibilistic-based clustering method for probability density functions and its application to detecting abnormal elements*. Sci Rep 14, 17871 (2024). <https://doi.org/10.1038/s41598-024-68323-9>

Cần Thơ, ngày 20, tháng 10, năm 2025

Tác giả

(Ký, họ và tên)



Tran Nam Hing

MỤC LỤC

CHẤP THUẬN CỦA HỘI ĐỒNG	i
LỜI CẢM TẠ	ii
TÓM TẮT NỘI DUNG	iv
ABSTRACT	v
LỜI CAM ĐOAN	vi
LÝ LỊCH CÁ NHÂN	vii
DANH SÁCH BẢNG	xi
DANH SÁCH HÌNH VẼ	xii
DANH SÁCH KÝ HIỆU TOÁN HỌC	xiii
DANH SÁCH TỪ VIẾT TẮT	xiv
PHẦN MỞ ĐẦU	1
1 Lý do chọn đề tài	1
2 Mục đích nghiên cứu	2
3 Đối tượng và phạm vi nghiên cứu	2
4 Phương pháp nghiên cứu	2
5 Cấu trúc luận văn	3
PHẦN NỘI DUNG	3
1 MỘT SỐ VẤN ĐỀ LIÊN QUAN ĐẾN HÀM MẬT ĐỘ XÁC SUẤT	4
1.1 Hàm mật độ xác suất	4
1.1.1 Các định nghĩa và tính chất cơ bản	4
1.1.2 Một số hàm mật độ xác suất thông dụng	6
1.1.3 Một số hàm mật độ xác suất bổ sung	10
1.1.4 Ước lượng hàm mật độ xác suất	11
1.2 Độ đo đánh giá sự tương tự của các hàm mật độ xác suất	12
1.2.1 Sự tương tự của hai hàm mật độ xác suất	13
1.2.2 Sự tương tự của nhiều hơn hai hàm mật độ xác suất	18
1.3 Phương pháp số xấp xỉ tích phân	20

1.4	Phân tích chùm cho hàm mật độ xác suất	20
1.4.1	Phân tích chùm không mờ	20
1.4.2	Phân tích chùm mờ (FCF)	24
1.5	Phân loại cho hàm mật độ xác suất	27
1.5.1	Hồi quy logistics	27
1.5.2	Máy vector hỗ trợ	29
1.5.3	Phương pháp Naïve Bayes	30
2	NHẬN DẠNG THỐNG KÊ CHO HÀM MẬT ĐỘ XÁC SUẤT	
	VỚI DỮ LIỆU MẤT CÂN BẰNG	33
2.1	Giới thiệu dữ liệu hàm mật độ xác suất	33
2.2	Giới thiệu bài toán phân tích chùm cho dữ liệu mất cân bằng	34
2.2.1	Phương pháp phân tích chùm hàm mật độ xác suất	34
2.2.2	Thuật toán đề nghị	39
2.2.3	Sự hội tụ của thuật toán	42
2.2.4	Tham số đánh giá chất lượng	47
2.2.5	Ví dụ minh hoạ	50
2.3	Giới thiệu bài toán phân loại cho dữ liệu mất cân bằng	54
2.3.1	Phương pháp phân loại hàm mật độ xác suất	54
2.3.2	Thuật toán	56
2.3.3	Tham số đánh giá chất lượng	56
2.3.4	Ví dụ minh hoạ	59
3	ỨNG DỤNG CHO DỮ LIỆU HÌNH ẢNH	64
3.1	Trích xuất đặc trưng của hình ảnh thành hàm mật độ xác suất	64
3.1.1	Vấn đề trích xuất đặc trưng của hình ảnh	64
3.1.2	Ước lượng hàm mật độ xác suất đại diện cho hình ảnh	65
3.2	Ứng dụng của bài toán phân tích chùm	66
3.2.1	Dữ liệu	66
3.2.2	Phương pháp thực hiện	69
3.2.3	Kết quả thực hiện	69
3.3	Ứng dụng của bài toán phân loại	74
3.3.1	Dữ liệu	74
3.3.2	Phương pháp thực hiện	75
3.3.3	Kết quả thực hiện	75
	PHẦN KẾT LUẬN	77
	TÀI LIỆU THAM KHẢO	78
	PHỤ LỤC	84
	CHỈ MỤC	95

DANH SÁCH BẢNG

1.1	Một số hàm hạt nhân phổ biến dùng trong ước lượng mật độ hạt nhân các PDF	12
1.2	Bảng tổng kết các loại khoảng cách giữa hai PDF bất kỳ	14
1.3	Các kết quả khoảng cách giữa hai PDF-đều trong bốn tình huống vị trí đối với Ví dụ 1.1	17
1.4	Bảng tổng kết các loại liên kết Δ giữa hai chùm PDF $\mathcal{F}$ và $\mathcal{G}$	19
1.5	Các phép đo khoảng cách giữa liên kết hợp hai chùm PDF $(\mathcal{F} \cup \mathcal{G})$ và chùm PDF $\mathcal{H}$	19
1.6	Tổng kết các hệ số tương tự giữa các chùm PDF đối với dữ liệu $\mathcal{F}$. . .	19
1.7	So sánh độ phức tạp của ba thuật toán phân chùm	26
2.1	Tổng quan nghiên cứu phân tích chùm cho dữ liệu PDF giai đoạn từ năm 2019–2024	36
2.2	Tổng kết các công thức trọng tâm theo khoảng cách khác nhau đối với hàm mục tiêu (IFCF)	45
2.3	Các chỉ số đánh giá độ tương đồng giữa hai phân hoạch	49
2.4	Tổng quan phương pháp phân loại cho dữ liệu PDF trong giai đoạn 2019–2024	55
2.5	Mô tả các chỉ số đánh giá phân loại	58
2.6	Phân bố số lượng và tỷ lệ PDF trong tập huấn luyện và kiểm tra đối với Ví dụ 2.2.	60
3.1	Cấu hình thuật toán phân chùm cho phân tích so sánh	69
3.2	So sánh các thuật toán đề nghị và các thuật toán cơ sở đối với Ví dụ 3.2 . . .	71
3.3	Kết quả so sánh các mô hình Bayes với các tiên nghiệm cơ sở khác nhau đối với Ví dụ 3.3	75
3.4	Một số hàm cơ sở $\psi_m(x)$ phổ biến trong hồi quy logistic cho dữ liệu PDF . . .	84
3.5	Kết quả so sánh các khoảng cách theo chỉ số ARI đối với Ví dụ 2.1 . . .	93
3.6	Kết quả so sánh các khoảng cách theo chỉ số NMI đối với Ví dụ 2.1 . . .	94
3.7	Kết quả so sánh các khoảng cách theo chỉ số $Silhouette$ đối với Ví dụ 2.1 . . .	94
3.8	Kết quả so sánh các khoảng cách theo chỉ số Thời gian chạy đối với Ví dụ 2.1	94

DANH SÁCH HÌNH VẼ

1.1	Minh họa hai PDF đại diện trong một tập hợp các PDF $\mathcal{F}$.	11
1.2	So sánh các hàm hạt nhân và hệ số trơn trong ước lượng mật độ xác suất	13
1.3	Dãy khoảng cách $D(f_1; f_2)$ giữa hai PDF Gauss $\mathcal{N}(0; 1)$ và $\mathcal{N}(\mu; 1)$	15
1.4	Các trường hợp trong khoảng cách giữa hai PDF-đều $f_1(x)$ và $f_2(x)$ đối với Ví dụ 1.1.	16
1.5	Kết quả trọng tâm và ma trận phân vùng của thuật toán KCF đối với Ví dụ 1.4	23
1.6	Kết quả phân cấp thứ bậc tích tụ HCF đối với Ví dụ 1.5	23
1.7	Biểu đồ phân vùng mờ theo khoảng cách D_{1j} với các hệ số m khác nhau.	25
1.8	Hàm $\hat{\beta}(x)$ được ước lượng qua 10 hàm cơ sở Gauss.	28
2.1	Minh họa các dữ liệu PDF được thu thập trong thực tế từ các nghiên cứu trước đây	34
2.2	Quan hệ giữa tỷ lệ IR và quy mô chùm có số lượng chiếm ưu thế	38
2.3	Ảnh hưởng của dữ liệu PDF Gauss mất cân bằng lên thuật toán FCF ($m = 2; c = 2; D = \mathcal{L}_2^2$)	40
2.4	Ảnh hưởng của tham số mờ m trong IFCM qua tỷ lệ $IR = \{1; 5; 10; 20\}$	41
2.5	Minh họa các công thức trọng tâm theo khoảng cách đối với (IFCF)	45
2.6	Một số chỉ số đánh giá và số chùm tối ưu	48
2.7	Dữ liệu Gauss mô phỏng tại Ví dụ 2.1	50
2.8	Đánh giá thống kê các chỉ số cho Ví dụ 2.1	51
2.9	Kết quả tham số m qua các chỉ số đánh giá đối với Ví dụ 2.1	52
2.10	Đánh giá thống kê các chỉ số so sánh thuật toán cho Ví dụ 2.1	53
2.11	Minh họa dữ liệu Ví dụ 2.2	59
2.12	Quá trình biến đổi của các trọng tâm đối với Ví dụ 2.2	60
2.13	Kết quả ANOVA cho các chỉ số phân loại đối với Ví dụ 2.2	63
3.1	Minh họa quá trình chuyển đổi dữ liệu ảnh thành PDF dựa trên màu sắc.	66
3.2	Minh họa quá trình chuyển đổi dữ liệu ảnh thành PDF dựa trên khối màu.	67
3.3	Các hình ảnh được cắt từ tập dữ liệu Brodatz.	68
3.4	Hình ảnh thực tế và các PDF được trích xuất từ khối màu	69
3.5	Ma trận phân vùng của các phương pháp tại $IR = 80$	70
3.6	Khảo sát sự biến đổi của tham số đối với Ví dụ 3.1	72
3.7	Kết quả thuật toán đề nghị IFCF được áp dụng cho ảnh Landsat đối với Ví dụ 3.2	73
3.8	Dữ liệu phân loại màu sắc của các loại đất đối với Ví dụ 3.3	75
3.9	Minh họa sự cập nhật của ma trận phân vùng và khoảng cách đối với Ví dụ 1.6	92
3.10	Thay đổi của trọng tâm chùm FCF qua các vòng lặp	93

DANH SÁCH KÝ HIỆU TOÁN HỌC

Ký hiệu	Mô tả
$(\Omega; \mathcal{E}; \mathbb{P})$	Không gian xác suất
$X; Y; Z; S$	Biến ngẫu nhiên
Y	Tập nhãn của dữ liệu (đối với bài toán phân loại)
$D; U; U^\top$	Ma trận, ma trận chuyển vị
$\mathcal{F}; \mathcal{G}; \mathcal{H}; \mathcal{P}; \mathcal{Q}$	Tập hợp
$\#\mathcal{F}; \#c$	Lực lượng của tập hợp $\mathcal{F}$, số phần tử của chùm c
$\mathbb{R}; \mathbb{R}_{>0}; \mathbb{N}; \mathbb{N}_{>0}$	Số thực, số thực dương, số tự nhiên, số tự nhiên dương
$\mathbb{E}(\cdot)$	Kỳ vọng của biến ngẫu nhiên
$\text{Var}(\cdot)$	Phương sai của biến ngẫu nhiên
$\text{Trace}(\cdot)$	Vết của ma trận
$ \cdot $	Định thức của ma trận
$f \oplus g$	Toán tử tích chập giữa hai hàm mật độ xác suất f và g
$\mathbf{1}_{\{\cdot\}}$	Hàm logic (bằng 1 nếu thỏa điều kiện $\{\cdot\}$, ngược lại là 0)
$\text{sign}(\cdot)$	Hàm xét dấu (bằng +1 nếu thỏa điều kiện $(\cdot)$, ngược lại là -1)
$\ell(\cdot)$	Hàm mất mát
$\mathcal{L}(\cdot)$	Hàm L'Agrange
$\langle \cdot; \cdot \rangle$	Tích trong của hai ma trận

Các ký hiệu đã được thống nhất, các ký hiệu khác sẽ được làm rõ trong luận văn

DANH SÁCH TỪ VIẾT TẮT

Từ viết tắt	Nghĩa Tiếng Việt	Nghĩa Tiếng Anh
AI	Trí thông minh nhân tạo	A rtificial I ntelligence
CVI	Chỉ số đánh giá phân tích cụm	C lustering V alidation I ndices
KCF	Thuật toán k -means cho hàm mật độ xác suất	k -means for probability density F unction
FCF	Thuật toán phân cụm mờ cho hàm mật độ xác suất	F uzzy c -means for probability density F unction
HCF	Thuật toán phân cấp thứ bậc cho hàm mật độ xác suất	H ierarchical C lustering for probability density F unction
IFCF	Thuật toán phân cụm mờ cải tiến cho hàm mật độ xác suất	I mproved F uzzy c -means for probability density F unction
SUP	Thuật toán phân cụm tự cập nhật	S elf- U pdating P rocessing
SR	Nhận dạng thống kê	S tatistical R ecognition
PDF	Hàm mật độ xác suất	P robability D ensity F unction
XAI	Thông minh nhân tạo giải thích được	e X plainable A rtificial I ntelligence

PHẦN MỞ ĐẦU

1 Lý do chọn đề tài

Nghiên cứu – phát triển các nguyên tắc và ứng dụng hệ thống thông minh nhân tạo (AI) là yếu tố then chốt nhằm thúc đẩy tăng trưởng kinh tế bền vững ở các quốc gia [1, 6]. Với khả năng ứng dụng đa ngành – đa chiều, AI không chỉ cải thiện năng suất lao động mà còn mở ra nhiều cơ hội việc làm, góp phần xây dựng nền kinh tế số [43], nâng cao tiện ích, thu nhập và chất lượng cuộc sống [14]. Trong sự phát triển của AI dự đoán, nhận dạng thống kê được xem là một trong những kiến thức nền tảng.

Nhận dạng thống kê (SR) giải quyết hai bài toán chính bao gồm nhận dạng được giám sát và không được giám sát [11, 66]. Nhận dạng không được giám sát là việc chia dữ liệu thành các nhóm sao cho các phần tử trong cùng một nhóm đó có sự tương tự nhiều hơn so với các phần tử bên ngoài nhóm [9, 39]. Do đó, nó còn được gọi là bài toán phân tích chùm. Phân tích chùm là cơ sở của việc lưu trữ, trích xuất và xử lý dữ liệu lớn nên được rất nhiều nhà thống kê và công nghệ thông tin quan tâm. Nhận dạng được giám sát là việc xếp một phần tử vào một lớp trong các lớp đã biết một cách thích hợp [11, 81]. Do đó, nó còn được gọi là bài toán phân loại. Phân loại đã và đang được áp dụng trong nhiều lĩnh vực khác nhau. Chẳng hạn, trong y tế hoạt động chẩn đoán bệnh của các bác sĩ xem một người có bệnh hay không có bệnh B, loại nào trong bệnh B thực chất là thực hiện bài toán phân loại. Trong lĩnh vực xã hội và an ninh, việc nhận dạng khuôn mặt, chữ ký, dấu vân tay của một người cũng chính là thực hiện bài toán phân loại.

Dữ liệu cho bài toán SR có thể là dữ liệu rời rạc, dữ liệu khoảng và hàm mật độ xác suất (PDF). Bài toán SR cho dữ liệu rời rạc đã được nghiên cứu và là tiên phong [9, 13, 85]. Trong thực tế, chúng ta cũng lưu trữ nhiều dữ liệu khoảng như nhiệt độ, lượng mưa, giá chứng khoán nên nhận dạng cho kiểu dữ liệu khoảng đã được đề xuất và phát triển [40]. Khi dữ liệu lớn và phức tạp như hình ảnh, đối tượng hình ảnh có thể được xem là một PDF trong một số phương pháp biểu diễn [65], do đó nhận dạng thống kê cho các PDF được đề xuất.

Xét về số lượng phần tử trong các nhóm/lớp, dữ liệu có thể được gọi là mất cân bằng và không mất cân bằng. Khi số lượng phần tử của các nhóm/lớp không có sự chênh lệch nhiều thì nó được gọi là không mất cân bằng. Tuy nhiên, trong nhận dạng dữ liệu của thực tế, nhiều trường hợp chúng ta gặp phải dữ liệu mất cân bằng. Đó là kiểu dữ liệu

có một hoặc một số ít nhóm/lớp chứa số lượng phần tử quá nhỏ so với các nhóm còn lại [29]. Chẳng hạn, trong tầm soát ung thư, ca bị bệnh có thể ít hơn 1000 lần so với trường hợp không bị bệnh [61]. Trong trường hợp này, độ chính xác của các nhóm/lớp thiểu số là quan trọng hơn [29], bởi vì việc tầm soát sai người mắc ung thư là khỏe mạnh gây ra tổn thất tính mạng lớn hơn nhiều so với tầm soát sai người không mắc. Trong khi đó, mô hình nhận dạng phải đối mặt với chênh lệch lớn về số lượng mẫu, nó dễ dàng bị thiên lệch về nhóm/lớp đa số, dẫn đến hiệu quả thấp trong việc nhận dạng các mẫu thiểu số [46]. Tức là, các thuật toán nhận dạng truyền thống sẽ không phát huy hiệu quả.

Bài toán SR cho dữ liệu mất cân bằng với các phần tử rời rạc đã được quan tâm trong những năm gần đây. Tuy nhiên, với dữ liệu PDF hầu như chưa được xem xét. Từ sự phân tích trên, đề tài **“Nhận dạng thống kê cho hàm mật độ xác suất mất cân bằng và ứng dụng cho dữ liệu ảnh”** được chọn làm luận văn tốt nghiệp.

2 Mục đích nghiên cứu

- Xây dựng thuật toán phân loại và phân tích chùm cho dữ liệu PDF với dữ liệu mất cân bằng;
- Áp dụng hai thuật toán trên cho dữ liệu hình ảnh khi các đặc trưng của nó được trích xuất và đại diện bởi các PDF để nhận dạng.

3 Đối tượng và phạm vi nghiên cứu

3.1 Đối tượng nghiên cứu

- Thuật toán phân loại và phân tích chùm với dữ liệu mất cân bằng;
- Dữ liệu hình ảnh được trích xuất thành các đối tượng đại diện.

3.2 Phạm vi nghiên cứu

- Các thuật toán phân tích chùm và phân loại cho PDF;
- Dữ liệu hình ảnh được trích xuất thành PDF đại diện;
- Vấn đề tính toán của các phương pháp phân loại, phân tích chùm.

4 Phương pháp nghiên cứu

- *Nghiên cứu lý thuyết*: Phân tích – tổng kết, phân loại – hệ thống hóa kiến thức về lĩnh vực SR; So sánh đánh giá ưu điểm và nhược điểm của các thuật toán.
- *Thực nghiệm khoa học*: Thực hiện các ví dụ số minh họa lý thuyết trong môi trường mô phỏng nhằm đánh giá các mô hình SR qua nhiều tiêu chí cụ thể, từ đó xử lý so sánh kết quả bằng các phân tích thống kê.

5 Cấu trúc luận văn

Luận văn bao gồm phần mở đầu, phần nội dung và phần kết luận, trong đó phần nội dung gồm ba chương:

Chương 1. *Một số vấn đề liên quan đến hàm mật độ xác suất*

Chương 2. *Nhận dạng thống kê cho hàm mật độ xác suất với dữ liệu mất cân bằng*

Chương 3. *Ứng dụng cho dữ liệu hình ảnh*

CHƯƠNG 1

MỘT SỐ VẤN ĐỀ LIÊN QUAN ĐẾN HÀM MẬT ĐỘ XÁC SUẤT

Chương 1 trình bày cơ sở lý thuyết và những tổng kết về PDF được sử dụng cho hai chương tiếp theo. Cụ thể, các kiến thức chung về PDF và một số trường hợp PDF thông dụng được trình bày. Ngoài ra, ước lượng PDF và độ đo đánh giá sự tương tự của chúng được phân tích. Chương này cũng trình bày các thuật toán phân tích chùm và phân loại cơ bản cho dữ liệu không mất cân bằng làm nền tảng để nghiên cứu dữ liệu mất cân bằng. Trong mỗi vấn đề, luận văn có sự phân tích, tổng kết và nhận xét để làm rõ bản chất, đặc biệt là ý nghĩa ứng dụng của nó.

1.1 Hàm mật độ xác suất

1.1.1 Các định nghĩa và tính chất cơ bản

Các PDF là khách thể nghiên cứu của một số nhà thống kê hiện đại [10, 33, 76]. Nó là một phần của dữ liệu đặc trưng bao gồm hữu hạn các xác suất, khoảng và hàm mật độ xác suất [10]. Ở đây, luận văn chỉ hệ thống hóa những kiến thức có liên quan.

Định nghĩa 1.1 (Biến ngẫu nhiên). Một biến ngẫu nhiên X trong không gian xác suất $(\Omega; \mathcal{E}; \mathbb{P})$ là một hàm Borel đo được từ Ω đến $\mathbb{R}$, cụ thể $X : (\Omega; \mathcal{E}) \rightarrow (\mathbb{R}; \mathcal{B}(\mathbb{R}))$, trong đó, Ω là không gian mẫu, $\mathcal{E}$ là σ -đại số trên Ω và $\mathbb{P}$ là hàm xác suất.

Tương tự, ta mở rộng cho biến ngẫu nhiên d -chiều cho vector ngẫu nhiên $\mathbf{X} = (X_1; X_2; \dots; X_d)$ trong $\mathbb{R}^d$, với mỗi thành phần X_i là biến ngẫu nhiên trên $(\Omega; \mathcal{E}; \mathbb{P})$, nhận giá trị trong $\mathbb{R}$ với $i = 1, 2, \dots, d$.

Định nghĩa 1.2 (Biến ngẫu nhiên d -chiều). Biến ngẫu nhiên d -chiều là một hàm Borel đo được từ không gian xác suất đến không gian Euclide $\mathbb{R}^d$, tức là $\mathbf{X} : (\Omega; \mathcal{E}) \rightarrow (\mathbb{R}^d; \mathcal{B}(\mathbb{R}^d))$.

Định nghĩa 1.3 (Hàm phân phối). Hàm phân phối của biến ngẫu nhiên X là hàm $P := P_X : \mathbb{R} \rightarrow [0; 1]$ được định nghĩa bởi $P(x) = P\{\omega : X(\omega) \leq x\}$ với mọi $x \in \mathbb{R}$.

Tính chất 1.1. Phân phối P thỏa các tính chất sau:

(i) P không giảm, tức là nếu $s_1 \leq s_2$ thì $P(s_1) \leq P(s_2)$;

(ii) $\lim_{x \rightarrow \infty} P(x) = 1$ và $\lim_{x \rightarrow -\infty} P(x) = 0$;

(iii) P liên tục phải, tức là $\lim_{y \downarrow x} P(y) = P(x)$;

(iv) Nếu $P(x_-) = \lim_{y \uparrow x} P(y)$ thì $P(x_-) = \mathbb{P}(X < x)$;

(v) $\mathbb{P}(X = x) = P(x) - P(x_-)$.

Định nghĩa 1.4 (Hàm phân vị). Cho phân phối P trên $\mathbb{R}$, hàm phân vị $F^{-1} : [0; 1] \rightarrow \mathbb{R}$ được định nghĩa bởi $F^{-1}(s) = \inf\{x \in \mathbb{R} : P(x) \geq s\}$, với $s \in [0; 1]$.

Tính chất 1.2. Hàm phân vị F^{-1} thỏa các tính chất sau:

(i) F^{-1} không giảm, tức là nếu $s_1 \leq s_2$ thì $F^{-1}(s_1) \leq F^{-1}(s_2)$;

(ii) Nếu P liên tục và tăng nghiêm ngặt, $P(F^{-1}(s)) = s$ và $F^{-1}(P(x)) = x$;

(iii) Kỳ vọng và phương sai của biến ngẫu nhiên X được biểu diễn qua hàm phân vị F^{-1} lần lượt bằng công thức $\mathbb{E}(X) = \int_0^1 F^{-1}(s) ds$ và $\text{Var}(X) = \int_0^1 (F^{-1}(s) - \mathbb{E}(X))^2 ds$;

(iv) Nếu P đối xứng quanh kỳ vọng $\mathbb{E}(X)$, ta có quan hệ đối xứng $F^{-1}(1-s) = 2\mu - F^{-1}(s)$.

Định nghĩa 1.5 (Hàm mật độ xác suất). Giả sử P là một độ đo xác suất trên không gian đo được $(\mathbb{R}^d, \mathcal{B})$, liên tục tuyệt đối theo một độ đo λ hoặc độ đo Lebesgue hoặc độ đo đếm. Theo định lý Radon–Nikodym, tồn tại một hàm $f : \mathbb{R}^d \rightarrow [0, \infty)$ sao cho

$$\mathbb{P}(A) = \int_A f(x) d\lambda(x), \quad \forall A \in \mathcal{B}.$$

Hàm f được gọi là PDF của P theo λ , ký hiệu

$$f(x) = \frac{dP}{d\lambda}(x) = \begin{cases} f(x), & \text{nếu } \lambda \text{ là độ đo Lebesgue (phân phối liên tục),} \\ \mathbb{P}(X = x), & \text{nếu } \lambda \text{ là độ đo đếm (phân phối rời rạc).} \end{cases}$$

Tính chất 1.3. Một PDF có các tính chất như sau:

(i) Một PDF là hàm không âm, $f(x) \geq 0, \forall x \in \mathbb{R}^d$;

(ii) Tích phân của $f(x)$ trên toàn không gian bằng 1, tức là $\int_{\mathbb{R}^d} f(x) d\lambda(x) = 1$;

(iii) Với mọi tập Borel $A \subseteq \mathbb{R}^d$, xác suất để biến ngẫu nhiên X nhận giá trị trong A được cho bởi $\mathbb{P}(X \in A) = \int_A f(x) d\lambda(x)$;

(iv) Trong trường hợp λ là độ đo Lebesgue,

$$\mathbb{P}(a < X < b) = \mathbb{P}(a \leq X \leq b) = \int_a^b f(x) dx.$$

Nhận xét. Các hàm phân phối P và phân vị F^{-1} đều không bảo toàn trong không gian vector Hilbert. Đối với phân phối liên tục tuyệt đối, một PDF f có thể nhận các giá trị tùy ý trên $\mathbb{R}^d$, nhưng phải thỏa mãn các tính chất trong Tính chất 1.3. Một xác suất tại điểm $x = x_0$ không được khảo sát trong PDF liên tục, mà chỉ thông qua xác suất của các tập Borel thực như Tính chất 1.3(iii). Nói cách khác, $\mathbb{P}(X = x_0) = 0; \forall x_0 \in \mathbb{R}^d$, đối với mọi biến ngẫu nhiên liên tục. Tập hợp tất cả các hàm mật độ xác suất có thể được xem là một tập con lồi và đóng trong không gian Banach $\mathcal{L}^1(\Omega)$, được ký hiệu bởi $\mathcal{F}(\Omega) = \{f : \Omega \rightarrow \mathbb{R}_{\geq 0} \mid \int_{\Omega} f(x) d\lambda(x) = 1\}$.

Định nghĩa 1.6. Hai tham số kỳ vọng và phương sai của biến ngẫu nhiên X được định nghĩa bởi $\mathbb{E}(X) = \int_{\mathbb{R}^d} xf(x) dx < \infty$ và $\text{Var}(X) = \int_{\mathbb{R}^d} (x - \mathbb{E}(X))^2 f(x) dx$, với $x \in \mathbb{R}^d$.

Định nghĩa 1.7. Với các đối tượng PDF trong khoảng $I \neq \emptyset$, toán tử tổng và tích có hướng được thay thế bởi phép nhân điểm và lũy thừa. Tức là,

$$(f \oplus g)(x) = \frac{f(x)g(x)}{\int_I f(\xi)g(\xi) d\xi} \text{ và } (\alpha \odot f)(x) = \frac{f^\alpha(x)}{\int_I f^\alpha(\xi) d\xi} \text{ với } \alpha \in \mathbb{R}.$$

Định nghĩa 1.8 (Dữ liệu PDF 1-chiều). Dữ liệu PDF là một bộ đối tượng không chắc chắn o có dạng $(o_1; o_2; \dots; o_n)$ [25]. Mỗi đối tượng o_j chứa một cặp $(I_j; f_j)$ với mỗi $1 \leq j \leq n$, trong đó $I_j = [l_j; u_j]$ là khoảng xác định của o_j và $f : \mathbb{R} \rightarrow \mathbb{R}^+$ là PDF xếp các giá trị xác suất vào mỗi $x \in I_j$ sao cho

$$\int_{x \in I_j} f_j(x) dx = 1 \text{ và } \int_{x \in \mathbb{R} \setminus I_j} f_j(x) dx = 0.$$

Định nghĩa 1.9 (Dữ liệu PDF d -chiều). Dữ liệu PDF d -chiều là một bộ đối tượng không chắc chắn o có dạng $(o_1; o_2; \dots; o_n)$ [25]. Mỗi đối tượng o_j chứa một cặp $(R_j; f_j)$ với mỗi $1 \leq j \leq n$, trong đó $R_j = [l_1; u_1] \times \dots \times [l_d; u_d] \subseteq \mathbb{R}^d$ là vùng xác định d -chiều của o_j và $f : \mathbb{R}^d \rightarrow \mathbb{R}^{d+}$ là PDF xếp các giá trị xác suất vào mỗi $x \in R_j$ sao cho

$$\int_{x \in R_j} f_j(x) dx = 1 \text{ và } \int_{x \in \mathbb{R} \setminus R_j} f_j(x) dx = 0.$$

Để minh họa và mô phỏng, luận văn này làm việc trên dữ liệu các PDF định nghĩa trên toàn không gian mẫu $I = \mathbb{R}$ hoặc $R = \mathbb{R}^d$ và ký hiệu xuyên suốt là tập $\mathcal{F} = \{f_1(x); f_2(x), \dots; f_n(x)\}$. Để đơn giản hóa, luận văn này giả định các đối tượng PDF trong các ví dụ số là độc lập và cùng phân phối.

1.1.2 Một số hàm mật độ xác suất thông dụng

Các PDF cụ thể được nghiên cứu bởi các nhà khoa học thực nghiệm và thỏa mãn các Tính chất 1.3.

Định nghĩa 1.10 (PDF Gauss). Biến ngẫu nhiên liên tục X tuân theo PDF Gauss

(chuẩn) với hai tham số μ và σ^2 (trong đó $\mu \in \mathbb{R}$ và $\sigma \in \mathbb{R}_{>0}$) nếu nó có PDF là

$$\mathcal{N}(x; \mu; \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), x \in \mathbb{R}.$$

Định lý 1.1 (Kỳ vọng và phương sai). *Kỳ vọng và phương sai của biến ngẫu nhiên X có PDF Gauss lần lượt là $\mathbb{E}(X) = \mu$ và $\text{Var}(X) = \sigma^2$.*

Một PDF Gauss có dáng điệu hình cong đối xứng và miền xác định khắp không gian. Đặc trưng kỳ vọng chính là giá trị cực đại và xác định vị trí của nó trong không gian. Đặc trưng phương sai thể hiện độ phân tán hay độ cao của hàm. Giá trị của nó càng nhỏ thì PDF càng cao và hẹp. Thông thường, dữ liệu rời rạc thường được biến đổi thành dữ liệu PDF qua biểu diễn của PDF Gauss (khi ước lượng tham số) hoặc nhân-Gauss (khi ước lượng phi tham số). Hơn hết, định lý giới hạn trung tâm chứng minh tổng các biến ngẫu nhiên độc lập và có cùng phân phối xấp xỉ có phân phối Gauss. Ta cũng thành lập được công thức tính xác suất khi $X \sim \mathcal{N}(\mu; \sigma^2)$ là $\mathbb{P}(a < X < b) = \Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right)$, trong đó hàm Laplace $\Phi(x) = \int_0^x \frac{1}{\sqrt{2\pi}} \exp(-\xi^2/2) d\xi$.

Bổ đề 1.1 (Tổng hai PDF Gauss). *Cho hai biến ngẫu nhiên độc lập $X_1 \sim \mathcal{N}(\mu_1; \sigma_1^2)$ và $X_2 \sim \mathcal{N}(\mu_2; \sigma_2^2)$. Khi đó $S = X_1 \pm X_2$ cũng là biến ngẫu nhiên có PDF Gauss, cụ thể $S \sim \mathcal{N}(\mu_1 \pm \mu_2; \sigma_1^2 + \sigma_2^2)$.*

Bổ đề 1.2 (Tích phân của hai PDF Gauss). *Cho hai PDF Gauss gồm $\mathcal{N}(\mu_1; \sigma_1^2)$ và $\mathcal{N}(\mu_2; \sigma_2^2)$ với kỳ vọng $\mu_1, \mu_2 \in \mathbb{R}$ và phương sai $\sigma_1^2, \sigma_2^2 > 0$. Khi đó, tích giữa hai PDF được xác định bởi*

$$\int_{\mathbb{R}} \mathcal{N}(\mu_1; \sigma_1^2) \cdot \mathcal{N}(\mu_2; \sigma_2^2) dx = \frac{1}{\sqrt{2\pi(\sigma_1^2 + \sigma_2^2)}} \exp\left(-\frac{(\mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right).$$

Chứng minh. Ta tính tích phân của tích này bởi

$$\begin{aligned}
& \int_{-\infty}^{\infty} \mathcal{N}(x; \mu_1; \sigma_1^2) \cdot \mathcal{N}(x; \mu_2; \sigma_2^2) dx \\
&= \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{(x-\mu_1)^2}{2\sigma_1^2} - \frac{(x-\mu_2)^2}{2\sigma_2^2}\right) dx \\
&= \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{1}{2}\underbrace{\left(\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}\right)}_{:=1/\sigma^2} x^2 + \underbrace{\left(\frac{\mu_1}{\sigma_1^2} + \frac{\mu_2}{\sigma_2^2}\right)}_{:=\mu} x - \frac{\mu_1^2}{2\sigma_1^2} - \frac{\mu_2^2}{2\sigma_2^2}\right) dx \\
&= \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{1}{2}\sigma(x-\mu)^2 - \frac{(\mu_1-\mu_2)^2}{2(\sigma_1^2+\sigma_2^2)}\right) dx \\
&= \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{(\mu_1-\mu_2)^2}{2(\sigma_1^2+\sigma_2^2)}\right) \underbrace{\int_{-\infty}^{\infty} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right) dx}_{=\sqrt{2\pi}\sigma} \\
&= \frac{\sqrt{2\pi}\sigma^2}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{(\mu_1-\mu_2)^2}{2(\sigma_1^2+\sigma_2^2)}\right).
\end{aligned}$$

Từ đây, ta suy ra được điều phải chứng minh. ■

Định nghĩa 1.11 (PDF Gauss d -chiều). Một vector ngẫu nhiên liên tục d -chiều X tuân theo PDF Gauss (chuẩn) với hai tham số μ và Σ (trong đó $\mu \in \mathbb{R}^d$ là vectơ kỳ vọng và Σ là ma trận hiệp phương sai đối xứng xác định dương) nếu nó có PDF là

$$\mathcal{N}(x; \mu; \Sigma) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x-\mu)^\top \Sigma^{-1}(x-\mu)\right), x \in \mathbb{R}^d,$$

trong đó $|\Sigma|$ là định thức của ma trận hiệp phương sai.

Định lý 1.2 (Kỳ vọng và hiệp phương sai). Vector kỳ vọng và ma trận hiệp phương sai của vector ngẫu nhiên X có PDF Gauss lần lượt là $\mathbb{E}(X) = \mu$ và $\text{Cov}(X) = \Sigma$.

Bổ đề 1.3 (Tổng hai PDF Gauss d -chiều). Cho hai vector ngẫu nhiên độc lập $X_1 \sim \mathcal{N}(\mu_1; \Sigma_1)$ và $X_2 \sim \mathcal{N}(\mu_2; \Sigma_2)$. Khi đó $S = X_1 \pm X_2$ cũng là vector ngẫu nhiên có hàm mật độ Gauss, tức là $S \sim \mathcal{N}(\mu_1 \pm \mu_2; \Sigma_1 + \Sigma_2)$.

Bổ đề 1.4 (Tích phân của hai PDF Gauss d -chiều). Cho hai PDF Gauss d -chiều có dạng $\mathcal{N}(\mu_1; \Sigma_1)$ và $\mathcal{N}(\mu_2; \Sigma_2)$ với vector kỳ vọng $\mu_1, \mu_2 \in \mathbb{R}^d$ và ma trận hiệp phương sai Σ_1, Σ_2 xác định dương. Khi đó, tích phân giữa hai PDF này được xác định bởi

$$\begin{aligned}
\int_{\mathbb{R}^d} \mathcal{N}(\mu_1; \Sigma_1) \cdot \mathcal{N}(\mu_2; \Sigma_2) dx &= \frac{1}{(2\pi)^{d/2} |\Sigma_1 + \Sigma_2|^{1/2}} \\
&\quad \times \exp\left(-\frac{1}{2}(\mu_1 - \mu_2)^\top (\Sigma_1 + \Sigma_2)^{-1}(\mu_1 - \mu_2)\right).
\end{aligned}$$

Ngoài ra, các phát triển bất đối xứng của Gauss điển hình là hàm Gauss-lệch [5] với PDF của nó được định nghĩa như sau:

Định nghĩa 1.12 (PDF Gauss-lệch 1-chiều). Một biến ngẫu nhiên liên tục X tuân theo mật độ Gauss-lệch (chuẩn-lệch) [5] với ba tham số μ , σ^2 và α (trong đó $\mu, \alpha \in \mathbb{R}$ và $\sigma^2 \in \mathbb{R}_{>0}$) nếu nó có PDF là

$$\mathcal{S}\mathcal{N}(x; \mu; \sigma^2; \alpha) = \frac{2}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \Phi\left(\frac{\alpha(x-\mu)}{\sigma}\right); x \in \mathbb{R},$$

trong đó $\Phi(\cdot)$ là hàm phân phối tích lũy của phân phối chuẩn tắc, tức là

$$\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} \exp(-\xi^2/2) d\xi.$$

Các PDF Gauss-lệch nhận thêm một tham số thể hiện mức độ lệch α . Khi giá trị α càng lớn, độ lệch so với kỳ vọng μ càng lớn. Khi $\alpha = 0$, phân phối này trở về Gauss như Định nghĩa 1.10.

Định lý 1.3 (Kỳ vọng và phương sai). Kỳ vọng và phương sai của biến ngẫu nhiên X có PDF Gauss-lệch lần lượt là $\mathbb{E}(X) = \mu + \sigma\delta\sqrt{\frac{2}{\pi}}$ và $\text{Var}(X) = \sigma^2\left(1 - \frac{2\delta^2}{\pi}\right)$, với $\delta = \frac{\alpha}{\sqrt{1+\alpha^2}} \in (-1; 1)$.

Định nghĩa 1.13 (PDF-đều 1-chiều). Một biến ngẫu nhiên liên tục X tuân theo hàm mật độ xác suất đều trên đoạn $[l; u]$ với $l < u$ và $l, u \in \mathbb{R}$ nếu nó có PDF là

$$\mathcal{U}(x; l; u) = \begin{cases} \frac{1}{u-l}, & x \in [l; u], \\ 0, & x \notin [l; u]. \end{cases}$$

Định lý 1.4 (Kỳ vọng và phương sai). Kỳ vọng và phương sai của biến ngẫu nhiên X có PDF-đều lần lượt là $\mathbb{E}(X) = \frac{l+u}{2}$ và $\text{Var}(X) = \frac{(u-l)^2}{12}$.

Định nghĩa 1.14 (PDF-đều d -chiều). Vector ngẫu nhiên liên tục d -chiều $\mathbf{X}$ tuân theo PDF-đều d -chiều trên hình hộp $[l_1; u_1] \times \cdots \times [l_d; u_d]$ với $l_i < u_i$ và $l_i, u_i \in \mathbb{R}$ nếu nó có PDF là

$$\mathcal{U}(\mathbf{x}; \mathbf{l}; \mathbf{u}) = \begin{cases} \prod_{i=1}^d \frac{1}{u_i-l_i}, & \mathbf{x} \in [l_1; u_1] \times \cdots \times [l_d; u_d], \\ 0, & \text{ngược lại.} \end{cases}$$

Định lý 1.5 (Kỳ vọng và hiệp phương sai). Vector kỳ vọng và ma trận hiệp phương sai của vector ngẫu nhiên $\mathbf{X}$ có PDF-đều lần lượt là

$$\mathbb{E}(\mathbf{X}) = \frac{\mathbf{l} + \mathbf{u}}{2} \text{ và } \text{Cov}(\mathbf{X}) = \text{diag}\left(\frac{(u_1-l_1)^2}{12}; \dots; \frac{(u_d-l_d)^2}{12}\right).$$

1.1.3 Một số hàm mật độ xác suất bổ sung

Gần đây, các thuật toán phân tích chùm dựa vào trọng tâm đề xuất bổ sung PDF trọng tâm (hay PDF đại diện của chùm) [47, 71]. Nó có chức năng như trung bình có trọng số của tổng các PDF trong chùm.

Định nghĩa 1.15 (PDF đại diện chùm). Cho tập $\mathcal{F}$ gồm n -PDF với $n \geq 2$. Ta phân bổ $\mathcal{F}$ vào c -chùm, với $1 < c \leq n$. Khi đó, PDF đại diện của các chùm c_i là

$$\theta_i(x) = \frac{\sum_{j=1}^n \mu_{ij} \times f_j(x)}{\sum_{j=1}^n \mu_{ij}}, \quad (1.1)$$

trong đó μ_{ij} là trọng số phân bổ một PDF $f_j(x)$ bất kỳ vào chùm c_i theo [77], ta có $0 \leq \mu_{ij} \leq 1$.

Dựa vào định nghĩa trên, ta dễ dàng nhận được θ_i cũng là một PDF (theo Tính chất 1.3).

Tính chất 1.4. Hàm đại diện được tính theo (1.1) là một hàm mật độ xác suất.

Chứng minh. Các giá trị trọng số $0 \leq \mu_{ij} \leq 1$ nên các θ_i liên tục không âm và

$$\int_{\Omega} \theta_i(x) dx = \int_{\Omega} \frac{\sum_{j=1}^n \mu_{ij} \times f_j(x)}{\sum_{j=1}^n \mu_{ij}} dx = \frac{\sum_{j=1}^n \mu_{ij} \times \int_{\Omega} f_j(x) dx}{\sum_{j=1}^n \mu_{ij}} = 1.$$

Định lý 1.6. Kỳ vọng của biến ngẫu nhiên X có PDF đại diện $\theta_i(x)$ là

$$\mathbb{E}_{\theta_i}(X) = \frac{\sum_{j=1}^n \mu_{ij} \mathbb{E}_{f_j}(X)}{\sum_{j=1}^n \mu_{ij}}.$$

Chứng minh. Ta có

$$\mathbb{E}_{\theta_i}(X) = \int_{\mathbb{R}} x \theta_i(x) dx = \int_{\mathbb{R}} x \frac{\sum_{j=1}^n \mu_{ij} f_j(x)}{\sum_{j=1}^n \mu_{ij}} dx = \frac{1}{\sum_{j=1}^n \mu_{ij}} \sum_{j=1}^n \mu_{ij} \int_{\mathbb{R}} x f_j(x) dx.$$

Vì $\int_{\mathbb{R}} x f_j(x) dx = \mathbb{E}_{f_j}(X)$ nên ta suy ra điều phải chứng minh. ■

Ta cũng mở rộng được cho PDF đại diện chùm đến không gian d -chiều tương tự cho vector ngẫu nhiên $\mathbf{X}$ và nó cũng thỏa mãn các tính chất của một PDF. Mới đây, Thao Nguyen-Trang *et al.* [48, 63] đề xuất PDF đại diện Gauss như là một phiên bản Gauss hóa của hàm Fréchet [21].

Định nghĩa 1.16 (PDF đại diện Gauss). Một PDF đại diện Gauss có dạng phân phối


chuẩn sao cho tổng khoảng cách giữa chúng đến các PDF khác là nhỏ nhất [21], tức là

$$\theta_i(x) = \arg \min_{\mathcal{N}(\mu; \sigma)} \sum_{j=1}^n \mu_{ij} D(\mathcal{N}(\mu; \sigma); f_j(x)),$$

trong đó $D(\mathcal{N}(\mu; \sigma); f_j(x))$ là khoảng cách giữa một PDF Gauss đến tất cả các PDF $f_j(x)$ khác trong tập hợp hàm.

Nhận xét. Một PDF đại diện Gauss là hàm trung bình Fréchet nên có nghiệm duy nhất [21]. Khác với Công thức (1.1), PDF này chỉ cần tìm một hàm Gauss duy nhất mà không cần tổ hợp các f_j giúp tăng khả năng khái quát hóa. Ta cũng có phương sai Fréchet $\text{Var}_j(X) = \mathbb{E}(D^2(\mathcal{N}(\mu; \sigma); f_j(x)))$.

Hình 1.1 minh họa cụ thể hai cách biểu diễn PDF đại diện trong cùng một chùm hàm Gauss. Để thấy sự khác biệt, PDF đại diện tập trung vào phân bố trung bình của nó tại các chùm, còn PDF đại diện Gauss lựa chọn vị trí dựa vào khoảng cách các PDF với nhau. Tóm lại, PDF đại diện có chức năng là PDF kỳ vọng của các tổng thể khác nhau.



Hình 1.1: Minh họa hai PDF đại diện trong một tập hợp các PDF $\mathcal{F}$.

Chú thích: PDF thể hiện bằng đường thẳng in đậm là hàm PDF đại diện cho ba hàm PDF Gauss minh họa bằng nét đứt (a) dựa vào trọng số phân bố đều giữa ba hàm $\mu_{ij} = 1/3$ và (b) dựa vào vị trí tối ưu với khoảng cách $\mathcal{L}_2$.

1.1.4 Ước lượng hàm mật độ xác suất

Trong thực tế, ta cần phải ước lượng PDF dựa vào dữ liệu điểm vector, luận văn này sử dụng phương pháp ước lượng hàm hạt nhân để chuyển từ dữ liệu điểm vector sang dữ liệu PDF.

Định nghĩa 1.17 (Ước lượng PDF bằng phương pháp hàm hạt nhân). Giả sử ta có một tập dữ liệu rời rạc gồm n quan sát x_j , với $j = 1, 2, \dots, n$ trong không gian $\mathbb{R}^d$. Mỗi điểm $x_j = (x_{1j}; x_{2j}; \dots; x_{dj})^\top$. Khi đó, một PDF $\hat{f}(x)$ tại điểm $x = (x_1; x_2; \dots; x_d)^\top$

Bảng 1.1: Một số hàm hạt nhân phổ biến dùng trong ước lượng mật độ hạt nhân các PDF

Tên hàm	$\kappa(x)$	Miền xác định	Khả vi
Hình chữ nhật	$(1/2)\mathbf{1}_{\{ x \leq 1\}}$	$[-1; 1]$	
Tam giác	$(1 - x)\mathbf{1}_{\{ x \leq 1\}}$	$[-1; 1]$	$\mathcal{C}^0$
Epanechnikov	$(3/4)(1 - x^2)\mathbf{1}_{\{ x \leq 1\}}$	$[-1; 1]$	$\mathcal{C}^0$
Gauss	$\frac{1}{\sqrt{2\pi}} \exp(-x^2/2)$	$(-\infty, \infty)$	$\mathcal{C}^\infty$
Logistic	$\frac{\exp(-x)}{1+\exp(-x)^2}$	$(-\infty, \infty)$	$\mathcal{C}^\infty$

được ước lượng bằng phương pháp hạt nhân bởi công thức

$$\hat{f}(x) = \frac{1}{n \prod_{i=1}^d bw_i} \sum_{j=1}^n \prod_{i=1}^d \kappa_i \left(\frac{x_i - x_{ij}}{bw_i} \right),$$

trong đó κ_i là hàm hạt nhân theo chiều thứ i có tính chất $\kappa(x) \geq 0$ và $\int_{\mathbb{R}} \kappa(x) dx = 1$ và tham số $bw_i > 0$ là tham số trơn ứng với chiều đó.


Nhận xét. Khi tham số trơn bw nhỏ, các PDF ước lượng sẽ kém trơn và có thể dao động mạnh. Ngược lại, nếu bw lớn thì hàm trở nên trơn hơn nhưng có thể làm mất chi tiết quan trọng của phân phối gốc. Trong trường hợp đơn giản, có thể chọn cùng một hàm hạt nhân và cùng một tham số trơn cho tất cả các chiều, tức là $\kappa_i \equiv \kappa$ và $bw_i = bw$ với mọi $i = 1, 2, \dots, d$.

Một số công thức hàm hạt nhân phổ biến được liệt kê trong Bảng 1.1. Luận văn này khảo sát các PDF ước lượng từ hàm hạt nhân Gauss với tham số trơn cố định và được tính bởi công thức của Silverman cho bởi Công thức $bw = 1,06 \times \text{Var}(x_j) \times n^{-1/5}$.

Hình 1.2(a) so sánh các hàm hạt nhân khác nhau. Cùng tham số trơn $bw = 1$, hàm Gauss cho đường trơn, còn hàm logistic dao động yếu và hàm Epanechnikov nổi bật rõ đỉnh. Hình 1.2(b) giữ cố định nhân Gauss và thay bằng thông bao gồm $\{0,2; 0,5; 1,0\}$. Rõ ràng, bw nhỏ hơn làm đồ thị nhọn và chi tiết hơn và ngược lại.

1.2 Độ đo đánh giá sự tương tự của các hàm mật độ xác suất

Phần này giới thiệu một số độ đo đánh giá sự tương tự của các PDF nhằm xác định mức độ "gần nhau" của chúng, làm tiêu chuẩn trong xây dựng các thuật toán phân tích chùm và phân loại.



Hình 1.2: So sánh các hàm hạt nhân và hệ số trơn trong ước lượng mật độ xác suất

Chú thích: Vùng xám là PDF mô phỏng thực tế $X \sim 0,30\mathcal{N}(0,0;1,0) + 0,70\mathcal{N}(5,0;1,0)$, Đường đen là minh họa của (a) các hàm hạt nhân với tham số trơn $bw = 1,0$ bao gồm Gauss, logistics và Epanechnikov ảnh hưởng đến khả năng khớp với PDF thực tế và (b) tham số trơn với hàm hạt nhân Gauss, ảnh hưởng đến mức độ khớp. Nguồn: Minh họa của tác giả.

1.2.1 Sự tương tự của hai hàm mật độ xác suất

Định nghĩa 1.18 (Khoảng cách $\mathcal{L}_p$). Cho hai PDF f_1, f_2 trên $\mathbb{R}^d$. Khoảng cách $\mathcal{L}_p$ được định nghĩa là

$$\mathcal{L}_p(f_1; f_2) = \left(\int_{\mathbb{R}^d} |f_1(x) - f_2(x)|^p dx \right)^{1/p}, 1 \leq p < \infty.$$

Theo Định nghĩa 1.18, khoảng cách giữa hai PDF thỏa mãn các tiên đề của mê-tríc. Trong lý thuyết thống kê và thông tin, một mê-tríc được gọi là *khoảng cách* và nửa mê-tríc gọi là *phân kỳ*. Thực tế, ta thường sử dụng $p = 1$ hoặc $p = 2$ cho các tính toán. Ta cũng có mối quan hệ giữa hai PDF đối với một PDF trọng tâm bất kỳ trong khoảng cách mê-tríc.

Bổ đề 1.5 (Bất đẳng thức tam giác). Với mọi PDF $f_j, f_k \in c_i$ trong không gian khoảng cách mê-tríc và PDF trọng tâm chùm θ_i , ta có bất đẳng thức tam giác

$$D(f_j, f_k) \leq D(f_j, \theta_i) + D(f_k, \theta_i).$$

Tại Vo-Van (2019) [71] dựa trên khoảng cách $\mathcal{L}_p$ để giới thiệu độ rộng chùm.

$$CWD(f_1; f_2) = \int_{\Omega} \max\{f_1(x); f_2(x)\} dx - 1.$$

Định nghĩa 1.19 (f -phân kỳ). Hàm $D : P_1 \times P_2 \rightarrow \mathbb{R}$ được gọi là f -phân kỳ của hai

PDF $f_1 \in P_1$ và $f_2 \in P_2$ khi nó thỏa hệ số phân kỳ giữa hai PDF [3]

$$D(P_1; P_2) = h \left(\mathbb{E}_1 \left(g \left(\frac{f_2}{f_1} \right) \right) \right),$$

trong đó hàm g là một hàm liên tục lồi trên $\mathbb{R}_{>0}$, h là hàm tăng trên $\mathbb{R}$ và $\mathbb{E}_1$ là kỳ vọng của phân phối P_1 .

Bảng 1.2 làm rõ các công thức khoảng cách và độ đo tương tự giữa hai PDF theo tiếp cận xác suất.

Bảng 1.2: Bảng tổng kết các loại khoảng cách giữa hai PDF bất kỳ

Khoảng cách	$D(f_1(x), f_2(x))$	$g(u)$	$h(u)$	Miền giá trị
$\mathcal{L}_1$	$\int_{\Omega} f_1(x) - f_2(x) dx$	$ 1 - u $	u	$[0; 2]$
Chernoff	$-\log \left(\int_{\Omega} f_1(x)^s f_2(x)^{1-s} dx \right)$	u^{1-s}	$-\log(-u)$	$[0; +\infty)$
Matusita	$\left(\int_{\Omega} f_1^{1/r}(x) - f_2^{1/r}(x) ^r dx \right)^{1/r}$	$ 1 - u^{1/r} ^r$	$u^{1/r}$	$[0; \sqrt{2}]$
bình phương Hellinger	$\int_{\Omega} \left(\sqrt{f_1(x)} - \sqrt{f_2(x)} \right)^2 dx$	$(\sqrt{u} - 1)^2$	u	$[0; 2]$
thông tin Kullback	$\int_{\Omega} f_1(x) \log \frac{f_1(x)}{f_2(x)} dx$	$-\log(u)$	u	$[0; +\infty)$
Jensen-Shannon	$\frac{1}{2} \left(D_{KL}(f_1; \frac{f_1+f_2}{2}) + D_{KL}(f_2; \frac{f_1+f_2}{2}) \right)$	$u \log \left(\frac{2u}{1+u} \right) + \log \left(\frac{2}{1+u} \right)$	$\frac{1}{2}u$	$[0; +\infty)$
Bayes Error	$1 - \int_{\Omega} \min\{\pi f_1(x); \pi(1 - f_2(x))\} dx$	$-\min\{u; 1 - u\}$	$u + 1$	$[0; 1]$


Chú thích: trong khoảng cách Chernoff, $0 \leq r \leq 1$ và trong khoảng cách Matusita, $r \geq 2$.

Nhìn vào Bảng 1.2, có thể thấy khoảng cách Chernoff là một tổng quát hóa của khoảng cách Bhattacharyya khi chọn $s = 1/2$. Tương tự khoảng cách Matusita là tổng quát hóa của khoảng cách bình phương Hellinger khi $r = 2$. Trong họ $\mathcal{L}_p$, chỉ có khoảng cách $\mathcal{L}_1$ là một f -phân kỳ và là khoảng cách Matusita với $r = 1$. Đáng chú ý, khoảng cách Matusita cũng thỏa mãn tính chất mê-tríc.

Hình 1.3 ghi nhận các giá trị khoảng cách giữa hai PDF $f_1 \sim \mathcal{N}(0; 1)$ và $f_2 \sim \mathcal{N}(\mu; 1)$, với μ trượt từ -10 đến 20 . Ta thấy khi hàm f_2 cách nhau quá xa hàm f_1 , tức là $|\mu_2| \gg 0$, tất cả loại khoảng cách hai PDF đều bão hòa và không đo được sự khác biệt. Lúc này hai PDF xét về mặt không gian thì rất xa nhau, nhưng khoảng cách không thể có giá trị lớn hơn nữa vì nó đã đạt đến ngưỡng lớn nhất. Đây là hạn chế không giữ được vị trí hình học đối với các khoảng cách hai PDF.

Do đó, luận văn này giới thiệu khoảng cách Wasserstein (hay còn gọi là khoảng cách Kantorovich–Rubinstein), là một mê-tríc hỗ trợ tốt cho tính toán khoảng cách các PDF không chồng lấp [70] thỏa Định nghĩa 1.18 và bất đẳng thức tam giác của Bổ đề 1.5. Khoảng cách này được phát triển trong bài toán vận chuyển tối ưu, nhưng chưa được nghiên cứu trong lĩnh vực SR cho PDF.

Định nghĩa 1.20 (Khoảng cách p -Wasserstein). Khoảng cách p -Wasserstein ($p \geq$



Hình 1.3: Dãy khoảng cách $D(f_1; f_2)$ giữa hai PDF Gauss $\mathcal{N}(0; 1)$ và $\mathcal{N}(\mu; 1)$

Chú thích: Khảo sát (a) các khoảng cách có miền xác định bị chặn trên và (b) ngược lại. Nguồn: Minh họa của tác giả.

1) giữa hai độ đo xác suất μ và ν trong không gian $\mathbb{R}^d$ được định nghĩa là

$$W_p(\mu; \nu) = \inf_{\substack{X \sim \mu \\ Y \sim \nu}} (\mathbb{E} \|X - Y\|^p)^{1/p} = \left(\inf_{\gamma \in \Gamma(\mu, \nu)} \int_{M \times M} d(x; y)^p d\gamma(x, y) \right)^{1/p},$$

Khoảng cách p -Wasserstein đo mức chênh lệch tối ưu giữa hai PDF, xét trên tất cả các cặp PDF có thể ghép cặp. Tức là nó tính đến công sức để di chuyển và tái sắp xếp khối lượng từ hàm này sang hàm kia. Ở đây, luận văn này sử dụng $p = 2$ để tính toán đo độ khác biệt. Trong thực tế, ta tính toán cụ thể khoảng cách này bằng cách biểu diễn nó qua hàm phân vị được thể hiện bởi Định lý 1.7.

Định lý 1.7. *Khoảng cách p -Wasserstein giữa hai độ đo xác suất μ và ν có thể được biểu diễn dưới dạng phân vị trong trường hợp 1-chiều bởi định nghĩa*

$$W_p^p(\mu; \nu) = \int_0^1 |F_\mu^{-1}(s) - F_\nu^{-1}(s)|^p ds,$$

trong đó F_μ^{-1} và F_ν^{-1} lần lượt là hàm phân vị của μ và ν (Xem Định nghĩa 1.4).

Định lý 1.8 (Khoảng cách 2-Wasserstein giữa hai PDF-Gauss 1-chiều). *Giả sử hai PDF $f_1(x) \sim \mathcal{N}(\mu_1; \sigma_1^2)$ và $f_2(x) \sim \mathcal{N}(\mu_2; \sigma_2^2)$ trong $\mathbb{R}^d$. Khi đó, khoảng cách 2-Wasserstein giữa chúng là $W_2^2(f_1, f_2) = (\mu_1 - \mu_2)^2 + (\sigma_1 - \sigma_2)^2$.*

Chứng minh. Dựa vào Định lý 1.7, ta xét hàm phân vị Gauss $F_i^{-1}(u) = \mu_i + \sigma_i \Phi^{-1}(u)$, với

$\Phi^{-1}(u)$ là phân vị chuẩn $\mathcal{N}(0,0;1,0)$. Khi đó,

$$\begin{aligned}
W_2^2(f_1; f_2) &= \int_0^1 (\mu_1 + \sigma_1 \Phi^{-1}(u) - \mu_2 - \sigma_2 \Phi^{-1}(u))^2 du \\
&= \int_0^1 ((\mu_1 - \mu_2) + (\sigma_1 - \sigma_2) \Phi^{-1}(u))^2 du \\
&= \int_0^1 [(\mu_1 - \mu_2)^2 + 2(\mu_1 - \mu_2)(\sigma_1 - \sigma_2) \Phi^{-1}(u) + (\sigma_1 - \sigma_2)^2 (\Phi^{-1}(u))^2] du \\
&= (\mu_1 - \mu_2)^2 \underbrace{\int_0^1 du}_{=1} + 2(\mu_1 - \mu_2)(\sigma_1 - \sigma_2) \underbrace{\int_0^1 \Phi^{-1}(u) du}_{=0} + (\sigma_1 - \sigma_2)^2 \underbrace{\int_0^1 (\Phi^{-1}(u))^2 du}_{=1}.
\end{aligned}$$

Từ đây ta suy ra được điều phải chứng minh. ■


Tương tự ta cũng suy ra được Định lý khoảng cách cho hai PDF Gauss d -chiều như sau:

Định lý 1.9 (Khoảng cách 2-Wasserstein giữa hai PDF Gauss d -chiều). *Giả sử hai PDF Gauss $f_1(x) \sim \mathcal{N}(\mu_1; \Sigma_1)$ và $f_2(x) \sim \mathcal{N}(\mu_2; \Sigma_2)$ trong $\mathbb{R}^d$. Khi đó, khoảng cách 2-Wasserstein giữa chúng là*

$$W_2^2(f_1; f_2) = \|\mu_1 - \mu_2\|_2^2 + \text{Tr} \left(\Sigma_1 + \Sigma_2 - 2(\Sigma_1^{1/2} \Sigma_2 \Sigma_1^{1/2})^{1/2} \right).$$

Định lý 1.10 (Khoảng cách 2-Wasserstein giữa hai PDF-đều 1-chiều). *Giả sử hai PDF-đều $f_1(x) \sim \mathcal{U}[a_1; b_1]$ và $f_2(x) \sim \mathcal{U}[a_2; b_2]$ trong $\mathbb{R}$. Khi đó, ta có khoảng cách 2-Wasserstein giữa chúng là $W_2^2(f_1; f_2) = (\mu_1 - \mu_2)^2 + \frac{1}{12}(l_1 - l_2)^2$, trong đó $m_i = \frac{a_i + b_i}{2}$ là trung điểm và $l_i = b_i - a_i$ là độ dài của khoảng $[a_i; b_i]$.*

Ví dụ 1.1 (So sánh các loại khoảng cách hàm mật độ xác suất). Xét hai PDF-đều $f_1(x)$ và $f_2(x)$ tại các vị trí khác nhau trên trục $x \in \mathbb{R}$.



Hình 1.4: Các trường hợp trong khoảng cách giữa hai PDF-đều $f_1(x)$ và $f_2(x)$ đối với Ví dụ 1.1.

Chú thích: Bốn trường hợp PDF-đều với (a) hai hàm rời nhau, cùng chiều rộng; (b) hai hàm rời nhau, khác chiều rộng; (c) hai hàm rời nhau, cách xa nhau; và (d) hai hàm chồng lấp. Ở đây, ô vuông trắng $\square$ biểu thị PDF $f_1(x)$ và ô vuông xám $\blacksquare$ biểu thị PDF $f_2(x)$. Nguồn: Minh họa của tác giả.

Hình 1.4 mô tả khoảng cách giữa hai PDF-đều này tại các vị trí có thể có trong bốn trường hợp. Ta có Bảng 1.3 tổng hợp kết quả các phép đo khoảng cách bốn tình huống như sau:

Bảng 1.3: Các kết quả khoảng cách giữa hai PDF-đều trong bốn tình huống vị trí đối với Ví dụ 1.1

Họ khoảng cách	$D(f_1; f_2)$	Trường hợp			
		(a)	(b)	(c)	(d)
Họ $\mathcal{L}_p$	$\mathcal{L}_1$	2,0	2,0	2,0	1,0
	$\mathcal{L}_2$	1,4	1,2	1,4	0,7
	D_O (Overlap)	1,0	1,0	1,0	0,5
	CWD	1,0	1,0	1,0	0,5
Họ f -phân kỳ	D_{BC} (Bhattacharyya)	∞	∞	∞	0,7
	D_H^2 (Hellinger)	1,0	1,0	1,0	0,7
	D_M (Matusita)	1,4	1,4	1,4	1,0
	D_{KL} (Kullback–Leibler)	27,6	27,3	27,6	13,5
	D_{JS} (Jensen–Shannon)	27,6	26,9	27,6	13,5
Họ Optimal	W_2^2 (2-Wasserstein)	3,0	3,5	6,0	1,0

Nguồn: Tác giả tính toán.

Trước hết, trong các trường hợp (a), (b) và (c), mặc dù $f_1(x)$ và $f_2(x)$ nằm xa dần, nhưng các giá trị khoảng cách $\mathcal{L}_1$ và $\mathcal{L}_2$ hầu như không đổi (đều bằng 2,0 hoặc 1,4). Khoảng cách này nhận biết được khác biệt hình dáng và phân bố, nhưng không nhận biết tốt yếu tố vị trí trong không gian. Hệ số Bhattacharyya và khoảng cách Hellinger chỉ có ý nghĩa trong trường hợp (d), khi có phần chồng lấp giữa hai PDF. Điều này cho thấy chúng nhạy với mức độ chồng lấp, nhưng không phân biệt được hai PDF có vị trí tách biệt nhau.

Ngược lại, khoảng cách Wasserstein nhạy cảm với vị trí hình học, hình dáng và phân bố. Khi so sánh (a) và (c), ta thấy khoảng cách này tăng rất lớn. Điều này cho thấy có hiệu quả khi so sánh vị trí. Xét tình huống (a) và (b), khi thay đổi hình dáng PDF, khoảng cách này cũng có sự khác biệt. Đáng chú ý, khoảng cách $\mathcal{L}_2$ và W_2^2 là trái ngược nhau. Khi thay đổi hình dáng đồ thị, khoảng cách $\mathcal{L}_2$ giảm nhưng D_W lại tăng lên. Cuối cùng, trường hợp (d) cho thấy khoảng cách cũng có ý nghĩa khi chồng lấp.

Định nghĩa 1.21 (Affinity). Hàm $\rho : f \rightarrow [0; 1]$ được gọi là affinity của hai PDF $f_1(x)$ và $f_2(x)$ nếu nó thỏa mãn ba điều kiện

1. $0 \leq \rho(f_1; f_2) \leq 1$;
2. $\rho(f_1; f_2) = 1$ nếu và chỉ nếu $f_1 \equiv f_2$; và
3. mỗi dãy hàm $\{f_n\}$ thì $\rho(f_n; f_0) \rightarrow 1$.

Nhận xét. Affinity đo lường sự giống nhau giữa hai PDF theo vị trí. Vì vậy, ta cũng có tương quan giữa Affinity và Khoảng cách giữa hai PDF $f_1(x)$ và $f_2(x)$ là $D(f_1; f_2) = 1 - \rho(f_1; f_2)$.

Ví dụ 1.2. Affinity cơ bản cho hệ số tương tự giữa PDF $f_1(x)$ và $f_2(x)$ là Affinity Bhattacharyya với $\rho_{BC}(f_1; f_2) = \int_{\Omega} \sqrt{f_1(x)f_2(x)} dx$.

Định nghĩa 1.22 (Hàm hạt nhân của khoảng cách). Hàm $K : \mathcal{F} \times \mathcal{F} \rightarrow [0; 1]$ với tập $\mathcal{F}$ được gọi là hạt nhân (hạch) giữa hai PDF $f_1(x)$ và $f_2(x)$ nếu nó thỏa mãn

1. $0 \leq K(f_1; f_2) \leq 1$;
2. $K(f_1; f_2) = K(f_2; f_1)$ với mọi $f_1, f_2 \in \mathcal{F}$;
3. với mọi tập hữu hạn $\{f_1; \dots; f_n\} \subset \mathcal{F}$ và các hệ số $\alpha_1; \dots; \alpha_n \in \mathbb{R}$, hàm hạt nhân là xác định dương, tức là $\sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j K(f_i; f_j) \geq 0$.

Ví dụ 1.3. Ba hạt nhân cơ bản cho khoảng cách giữa $f_1(x)$ và $f_2(x)$ là

1. Hạt nhân chuẩn, $K_G(f_1; f_2) = \exp\left(-\frac{\mathcal{L}_p^2(f_1; f_2)}{\beta\sigma^2}\right)$; $\beta \in \mathbb{R}_{>0}$,
2. Hạt nhân tuyến tính, $K_L(f_1; f_2) = \int_{\Omega} f_1(x)f_2(x) dx$,
3. Hạt nhân Bhattacharyya, $K_{BC}(f_1; f_2) = \int_{\Omega} \sqrt{f_1(x)f_2(x)} dx$,
4. Hạt nhân χ^2 , $K_{\chi^2}(f_1; f_2) = \int_{\Omega} \frac{2f_1(x)f_2(x)}{f_1(x) + f_2(x)} dx$.

Hàm hạt nhân $K(\cdot; \cdot)$ càng gần giá trị 1,0 thì hai PDF càng giống nhau và ngược lại. Ở đây, việc chuyển đổi từ hàm hạt nhân thành khoảng cách được cho bởi công thức $D = 1 - K_G$ đối với các hạt nhân chuẩn hóa $[0; 1]$, hoặc $D = 2(1 - K_H)$ đối với hạt nhân Bhattacharyya.

Định nghĩa 1.23 (Ma trận khoảng cách từng đôi). Cho tập PDF gồm n đối tượng, $\mathcal{F} = \{f_1; f_2; \dots; f_n\}$, ma trận khoảng cách $D \in \mathbb{R}^{n \times n}$ là một ma trận đối xứng và có $\text{Trace}(D) = 0$, được định nghĩa bởi $D_{ij} = D(f_i; f_j)$ với mọi $i; j = 1, 2, \dots, n$.

1.2.2 Sự tương tự của nhiều hơn hai hàm mật độ xác suất

a. Liên kết chùm hàm mật độ xác suất

Giả sử hai chùm PDF không rỗng $\mathcal{F}$ và $\mathcal{G}$ chứa hữu hạn phần tử và $D(f; g)$ là khoảng cách giữa hai PDF, sao cho $f \in \mathcal{F}$ và $g \in \mathcal{G}$. Khoảng cách giữa hai chùm PDF là một ánh xạ $\delta : \mathcal{P}(X) \times \mathcal{P}(X) \times \mathcal{M}(X) \rightarrow \mathbb{R}_+$, trong đó $\mathcal{P}(X)$ là tập lũy thừa của X . Ta còn gọi chùm PDF là liên kết và ký hiệu là Δ . Bảng 1.4 tổng kết các loại liên kết Δ .

Bảng 1.4: Bảng tổng kết các loại liên kết Δ giữa hai chùm PDF $\mathcal{F}$ và $\mathcal{G}$

Liên kết	Ký hiệu	Δ
Liên kết đơn ¹ (SLINK)[20]	$\Delta_{\min}$	$\min_{f \in \mathcal{F}, g \in \mathcal{G}} D(f; g)$
Liên kết đủ ² (CLINK)[59]	$\Delta_{\max}$	$\max_{f \in \mathcal{F}, g \in \mathcal{G}} D(f; g)$
Liên kết tâm (UPGMC)	Δ_{centroid}	$D(\theta_{\mathcal{F}}; \theta_{\mathcal{G}})$
Liên kết trung bình (UPGMA)	Δ_{avg}	$\frac{1}{\#\mathcal{F}\#\mathcal{G}} \sum_{f \in \mathcal{F}, g \in \mathcal{G}} D(f; g)$
Liên kết Ward [78]	Δ_{Ward}	$\frac{\#\mathcal{F} \cdot \#\mathcal{G}}{\#\mathcal{F} + \#\mathcal{G}} D^2(\theta_{\mathcal{F}}; \theta_{\mathcal{G}})$

Chú thích: ¹: tổng khoảng cách nhỏ nhất; ²: tổng khoảng cách lớn nhất. Nguồn: Tác giả tổng hợp.

Khi cần tính khoảng cách từ hợp hai chùm PDF $\mathcal{F} \cup \mathcal{G}$ đến một chùm PDF $\mathcal{H}$, ta cũng có thể sử dụng công thức biến đổi theo Bảng 1.5. Ví dụ 3.4 cung cấp hướng dẫn tính toán các liên kết Δ được trình bày ở Phụ lục B, tr. 86.

Bảng 1.5: Các phép đo khoảng cách giữa liên kết hợp hai chùm PDF ($\mathcal{F} \cup \mathcal{G}$) và chùm PDF $\mathcal{H}$

Ký hiệu	Công thức
$\Delta_{\min}(\mathcal{F} \cup \mathcal{G}; \mathcal{H})$	$\min \{D_{f \in \mathcal{F}; h \in \mathcal{H}}(f; h); D_{g \in \mathcal{G}; h \in \mathcal{H}}(g; h)\}$
$\Delta_{\max}(\mathcal{F} \cup \mathcal{G}; \mathcal{H})$	$\max \{D_{f \in \mathcal{F}; h \in \mathcal{H}}(f; h); D_{g \in \mathcal{G}; h \in \mathcal{H}}(g; h)\}$
$\Delta_{\text{avg}}(\mathcal{F} \cup \mathcal{G}; \mathcal{H})$	$\frac{1}{\#(\mathcal{F} \cup \mathcal{G}) \cdot \#\mathcal{H}} \sum_{f \in \mathcal{F} \cup \mathcal{G}} \sum_{h \in \mathcal{H}} D(f; h)$
$\Delta_{\text{centroid}}(\mathcal{F} \cup \mathcal{G}; \mathcal{H})$	$D(\theta_{\mathcal{F} \cup \mathcal{G}}; \theta_{\mathcal{H}})$
$\Delta_{\text{Ward}}(\mathcal{F} \cup \mathcal{G}; \mathcal{H})$	$\frac{\#(\mathcal{F} \cup \mathcal{G}) \cdot \#\mathcal{H}}{(\#(\mathcal{F} \cup \mathcal{G}) + \#\mathcal{H})} D^2(\theta_{\mathcal{F} \cup \mathcal{G}}; \theta_{\mathcal{H}})$

Nguồn: Tác giả tổng hợp.

b. Tương tự chùm hàm mật độ xác suất

Nếu xem chùm PDF là tổng thể chứa các PDF, ta có thể đánh giá mức độ ổn định (giống nhau) của tổng thể này qua các hệ số tương tự chùm được giới thiệu ở Bảng 1.6.

Bảng 1.6: Tổng kết các hệ số tương tự giữa các chùm PDF đối với dữ liệu $\mathcal{F}$

Tương tự	$\Delta(\mathcal{F})$
Affinity của Matusita [41]	$\int_{\Omega} \left(\prod_{j=1}^n f_j(x) \right)^{1/n} dx$
Affinity của Toussaint [67]	$\int_{\Omega} \left(\prod_{j=1}^n f_j(x) \right)^{\alpha_j} dx$
Độ rộng chùm [76]	$\int_{\Omega} f_{\max}(x) dx - 1$
Hệ số tương tự chùm [75]	$\frac{1}{n-1} \left(1 - \frac{1}{n} \int_{\Omega} f_{\max}(x) dx \right)$

Chú thích: trong Affinity của Matusita và Toussaint, hệ số $\alpha_1 + \alpha_2 + \dots + \alpha_n = 1$ và trong độ rộng chùm, hệ số $f_{\max}(x) = \max_x \{f_1(x); f_2(x); \dots; f_n(x)\}$. Nguồn: Tác giả tổng hợp.

Bảng 1.6 cho thấy Affinity của Toussaint suy biến thành Affinity của Matusita khi

$\alpha_1 = \alpha_2 = \dots = \alpha_n = \frac{1}{n}$. Khi Affinity của Matusita có $n = 2$ thì nó trở thành hệ số Bhattacharyya. Cuối cùng, hệ số tương tự chòm chuẩn hóa tuyến tính độ rộng chòm.

1.3 Phương pháp số xấp xỉ tích phân

Các tích phân trong lĩnh vực phân tích PDF cần xấp xỉ bằng phương pháp số. Luận văn này, chọn sử dụng phương pháp hình thang nhằm cải thiện độ chính xác so với tổng Riemann nhưng cũng không tốn quá nhiều tài nguyên như Monte Carlo hay Simpson. Một tích phân trên miền $\Omega \subset \mathbb{R}^d$ được xấp xỉ bằng công thức tổng quát $\int_{\Omega} f(x) dx = \lim_{h \rightarrow 0} \sum_i h^d w_i f(x_i)$. Khi đó, giả sử hàm $f : [a; b] \rightarrow \mathbb{R}$, ta chia đoạn $[a; b]$ thành n phần bằng nhau với độ chia $h = (b - a)/n$, phương pháp hình thang một chiều xấp xỉ tích phân với mọi $x_i = a + ih$ và $i = 0, 1, \dots, n$, tức là

$$\int_a^b f(x) dx \approx \frac{h}{2} \left(f(x_0) + 2 \sum_{i=1}^{n-1} f(x_i) + f(x_n) \right).$$

1.4 Phân tích chòm cho hàm mật độ xác suất

1.4.1 Phân tích chòm không mờ

Phân tích chòm không mờ (hay phân chòm cứng) yêu cầu một phần tử chỉ thuộc duy nhất một chòm cố định. Tiểu mục này trình bày hai khía cạnh chính của phân tích chòm bao gồm phân tích chòm phân vùng (dựa trên trọng tâm) và phân cấp thứ bậc.

a. Phân tích chòm k -means (KCF)

Phân tích chòm phân vùng giả sử $\mathcal{S}$ là tập các vector d -chiều x_j , trong đó $j = 1, 2, \dots, n$. Mỗi đối tượng o_j liên hệ với các PDF $f_j(x)$. Tập $\mathcal{F}$ gồm họ n -PDF trên Ω . Bài toán phân tích chòm phân bổ PDF thứ j vào chòm thứ i trong c -chòm cho trước với $i = 1, 2, \dots, c$ và $c \in \mathbb{N}$, thỏa mãn ba ràng buộc

1. Hợp tất cả các chòm $\bigcup_i c_i$ bằng $\mathcal{F}$;
2. Giao của mỗi chòm là rỗng, tức là $c_i \cap c_j = \emptyset$, với mỗi $i \neq j$;
3. Lực lượng của mỗi chòm là khác rỗng, tức là $|c_i| \neq \emptyset$.

Phép gán này được mô tả bằng một ánh xạ nhiều-đến-một, hay còn gọi là bộ mã hóa $c_i = c(f_j)$, trong đó một PDF f_j được gán vào chòm thứ c_i là duy nhất. Cụ thể, ràng buộc 1 đảm bảo tất cả các PDF phải được phân tách thành các chòm, trong đó mỗi chòm phải chứa ít nhất một đối tượng PDF (ràng buộc 3) và không có đối tượng nào được xếp vào hai chòm riêng biệt (ràng buộc 2).

Phân tích chòm KCF là bài toán tối thiểu đơn mục tiêu cho tổng các bình phương

khoảng cách trong chùm các PDF. [39, 65, 76], tức là

$$\text{Minimise : } J(U; \Theta | \mathcal{F}; c) = \sum_{i=1}^c \sum_{f_j(x) \in c_i} \mu_{ij} D^2(\theta_i; f_j), \quad (\text{KCF})$$

trong đó hàm $\theta_i(x)$ là PDF trọng tâm của chùm thứ c_i . Ký hiệu $D^2(\theta_i; f_j)$ là khoảng cách giữa PDF trọng tâm $\theta(x)$ đến các đối tượng $f_j(x)$ còn lại trong dữ liệu. Ta cũng có μ_{ij} là biến tiềm ẩn thể hiện mức độ thành viên của PDF $f_j(x)$ thỏa $\mu_{ij} = 1_{\{j \in c_i\}}$. Tức là $\mu_{ij} = 1$ nếu PDF f_j thuộc chùm c_i và $\mu_{ij} = 0$ nếu ngược lại.

Chứng minh. Điều kiện $\sum_i \mu_{ij} = 1$ đảm bảo rằng mỗi hàm f_j được gán vào đúng một chùm duy nhất. Mà tập tất cả các ma trận U là hữu hạn và việc cố định U biến hàm mục tiêu KCF trở thành hàm tuyến tính theo U . Đặc biệt, với θ_i cố định, giá trị J được tối thiểu khi gán f_j vào chùm c_i sao cho $D^2(f_j; \theta_i)$ nhỏ nhất, tức là $\mu_{ij} = 1_{\{i = \arg \min_s D^2(f_j; \theta_s)\}}$. ■

Bổ đề 1.6 (Thành lập hàm mật độ xác suất đại diện). *Giả sử tập $\mathcal{F}$ -PDF được phân thành c -chùm qua các mức độ thành viên μ_{ij} với bình phương khoảng cách $D^2(\theta_i; f_j)$. Khi đó, PDF đại diện $\theta_i^*(x)$ tối ưu trên mỗi chùm c_i được cho bởi công thức*

$$\theta_i^*(x) = \frac{\sum_{f_j \in c_i} \mu_{ij} f_j(x)}{\sum_{f_j \in c_i} \mu_{ij}}.$$

Chứng minh. Từ hàm mục tiêu KCF, ta cố định μ_{ij} và đối thứ tự tổng và tích phân của hàm mục tiêu J , ta có $J(\mathcal{F}; c) = \int_{\Omega} \sum_{i=1}^c \sum_{j=1}^n \mu_{ij} (\theta_i(x) - f_j(x))^2 dx$. Lấy đạo hàm của J theo $\theta_i(x)$ ta có $\frac{\partial}{\partial \theta_i(x)} J = 2 \sum_{j=1}^n \mu_{ij} (\theta_i(x) - f_j(x))$. Cho đạo hàm bằng 0 ta suy ra được điều phải chứng minh. ■

Tóm lại, PDF đại diện tối ưu để cực tiểu hàm mục tiêu là PDF trọng tâm (1.1) của các PDF trong các chùm. Hơn nữa, vì mỗi PDF trọng tâm (1.1) được đại diện trừu tượng bằng trung bình có trọng số của từng chùm, nên kết quả trọng tâm này có thể không đồng nhất với bất kỳ đối tượng nào trong chùm PDF. Thay vào đó, nó có thể nằm bất kỳ trong không gian, đóng vai trò như một đối tượng tham chiếu để các PDF khác so sánh [79].

Một PDF mới $h(x)$ được gán vào chùm c_i nếu $k = \arg \min_i D^2(h; \theta_i)$. Hơn nữa, vì ma trận phân vùng $\mu_{ij} = 1_{\{j \in c_i\}}$ nên ta có thể rút gọn PDF đại diện (1.1) thành trung bình Fréchet với khoảng cách $\mathcal{L}_2$, tức là

$$\theta_i(x) = \frac{1}{\#c_i} \sum_{f_j(x) \in c_i} f_j(x). \quad (1.2)$$

Bổ đề 1.7 (Sự hội tụ của thuật toán KCF). *Sau mỗi bước lặp của thuật toán KCF, hàm mục tiêu $J^{(t)}$ luôn giảm tại hữu hạn bước lặp t .*

Chứng minh. Gọi $\mathcal{Z}^{(t)} = \{c_1^{(t)}; \dots; c_i^{(t)}\}$ là phân hoạch tại bước t , với PDF trọng tâm $\theta_i^{(t)}(x)$ và hàm mục tiêu $J^{(t)}$. Khi trọng tâm $\theta_i^{(t)}$ cố định, mỗi hàm f_j được gán vào chùm gần nhất. Khi đó,

$$\sum_{i=1}^k \sum_{f \in c_i^{(t+1)}} D^2(f; \theta_i^{(t)}) \leq J^{(t)}. \quad (1.3)$$

Còn khi chùm $c_i^{(t+1)}$ cố định, PDF trọng tâm $\theta_i^{(t+1)}$ được cập nhật sao cho

$$\sum_{f \in c_i^{(t+1)}} D^2(f; \theta_i^{(t+1)}) \leq \sum_{f \in c_i^{(t+1)}} D^2(f; \theta_i^{(t)}) \quad (1.4)$$

Cộng (1.3) và (1.4) ta được giá trị

$$J^{(t+1)} = \sum_{i=1}^k \sum_{f \in c_i^{(t+1)}} D^2(f; \theta_i^{(t+1)}) \leq J^{(t)}.$$

Hơn nữa, ta có chặn dưới

$$J^{(t)} - J^{(t+1)} \geq \sum_{i=1}^k |c_i^{(t+1)}| \cdot D^2(\theta_i^{(t)}; \theta_i^{(t+1)}).$$

Suy ra, thuật toán hội tụ đơn điệu và dừng sau hữu hạn bước do số phân hoạch hữu hạn. ■

Ví dụ 1.4 (Phân tích chùm cứng hàm Gauss 1-chiều). Cho bảy PDF Gauss 1-chiều $\mathcal{F}$ cho bởi Tai Vo-Van & Pham-Gia, T., (2010) [76] có phương sai đồng nhất $\sigma_i^2 = 1$, với $i = 1; 2; \dots; 7$ và các trung bình lần lượt là $\mu_i = \{0, 3; 4, 0; 9, 1; 1, 0; 5, 5; 8, 0; 4, 8\}$. Phân tích chùm KCF với $c = 3$ và khoảng cách xét là $\mathcal{L}_2$.


Ta có kết quả sau khi thực hiện các vòng lặp được giải chi tiết ở Phụ lục (tr. 86). Hình 1.5(a) cho thấy kết quả PDF trọng tâm của ba chùm. Các khoảng cách khác cũng được khảo sát, tuy nhiên kết quả đều giống nhau.

b. Phân tích chùm thứ bậc (HCF)

Phân cấp thứ bậc giả định họ $\mathcal{F}^{(t=0)} = \{\{f_1\}, \{f_2\}, \dots, \{f_n\}\}$ trong [35]. Thuật toán này không yêu cầu tiên nghiệm số chùm c , mà xây dựng một cây phân cấp qua việc hợp nhất lần lượt các chùm gần nhất theo một liên kết cho trước. Tại mỗi bước $t = 1 \div (n - 1)$, ta chọn hai chùm $c_i, c_j \in \mathcal{F}^{(t-1)}$ sao cho vị trí

$$(c_i; c_j) = \arg \min_{c_u; c_v \in \mathcal{F}^{(t-1)}} \Delta(c_u; c_v),$$

trong đó $\Delta(c_u; c_v)$ là liên kết giữa hai chùm (Tiểu mục 1.2.2). Thuật toán 3 (Phụ lục C, tr. 84) mô tả rõ quy trình thực hiện của phương pháp phân cấp này.



Hình 1.5: Kết quả trọng tâm và ma trận phân vùng của thuật toán KCF đối với Ví dụ 1.4


Chú thích: Hình (a) PDF trọng tâm chùm bằng nét liền và dữ liệu PDF nét đứt ở các chùm và (b) ma trận phân vùng cứng của KCF. Nguồn: Minh họa của tác giả.

Định lý 1.11 (Hội tụ của thuật toán HCF). Giải thuật HCF luôn hội tụ sau $(n - 1)$ -bước hợp nhất và tạo thành một cây nhị phân có n nút lá và $n - 1$ nút trong.

Chứng minh. Mỗi lần hợp nhất, một cặp c_i và c_j được thay thế bằng chùm $c_i \cup c_j$ và giữ nguyên các chùm còn lại. Ta có $\forall c \in C_t, \exists c' \in C_{t+1}$ sao cho $c \subseteq c'$, tức là C_{t+1} phân rã nhỏ hơn C_t . ■

Ví dụ 1.5 (Phân cấp thứ bậc hàm Gauss 1-chiều). Ta sử dụng lại dãy các PDF trong Ví dụ 1.4. Phân cấp thứ bậc với khoảng cách $D(f_1; f_2) = \mathcal{L}_2$ và liên kết $\Delta_{\max}(\mathcal{F}_1; \mathcal{F}_2)$ là liên kết đủ.

Ta có kết quả phân cấp thứ bậc tích tụ bởi Hình 1.6 và bài giải chi tiết được phân tích trong Phụ lục B (tr. 86). Quá trình phân cấp được thực hiện với hai phương pháp liên kết đủ và liên kết Ward. Nhìn Hình 1.6, ta thấy phương pháp liên kết đủ có xu hướng tạo ra các chùm nhỏ, chặt chẽ và nhạy cảm với nhiễu ở biên. Ngược lại, liên kết Ward cho kết quả các chùm có tính đồng nhất cao hơn về phân bố, làm cây phân cấp cân đối.



Hình 1.6: Kết quả phân cấp thứ bậc tích tụ HCF đối với Ví dụ 1.5

Chú thích: Cây phân cấp ở phía trên thể hiện cách sắp xếp và nhóm các PDF dựa trên liên kết, phần dưới thể hiện ma trận khoảng cách tương ứng của PDF đó. Nguồn: Minh họa của tác giả.

1.4.2 Phân tích chùm mờ (FCF)

Phân tích chùm mờ (FCF) được xây dựng lần đầu tiên cho dữ liệu PDF bởi Thao Nguyen-Trang & Tai Vo-Van [47] với sự phát triển từ phương pháp cho phần tử rời rạc do Bezdek (1984), [9] và từ ý tưởng của Dunn (1973), [16]. Khác biệt giữa nó với phân chùm cứng là sự chấp nhận thuộc nhiều chùm của một phần tử với một mức độ phân vùng mềm hơn. Điều này hữu ích khi ranh giới giữa các hàm là không chắc chắn.

Giả sử $\mathcal{F}$ -PDF chưa được gán nhãn, mục tiêu của bài toán là tối thiểu hóa tổng trọng số các giá trị hàm thành viên μ có trọng số và bình phương khoảng cách $D(\theta_i; f_j)$.

$$\text{Minimise : } J(U; \Theta | \mathcal{F}; c; m) = \sum_{i=1}^c \sum_{j=1}^n \mu_{ij}^m D^2(\theta_i; f_j), \quad (\text{FCF})$$

$$\text{s.t : } \sum_{i=1}^c \mu_{ij} = 1, \quad \forall j \in \{1, 2, \dots, n\}, \quad (\text{C1})$$

$$\mu_{ij} \in [0; 1], \quad \forall i \in \{1, 2, \dots, c\}, \forall j \in \{1, 2, \dots, n\}, \quad (\text{C2})$$

$$\sum_{j=1}^n \mu_{ij} > 0, \quad \forall i \in \{1, 2, \dots, c\}. \quad (\text{C3})$$

Thuật toán phân tích chùm mờ cho phần tử rời rạc đã được chứng minh là tối ưu toàn cục bởi [7, 8, 26] qua định lý Zangwill [84]. Đặc biệt, [24] mới đây chứng minh sự hội tụ toàn cục qua thuật toán độ dốc. Do đó, luận văn này chỉ giới thiệu Định lý 1.12 trình bày sự thành lập của ma trận phân vùng và PDF đại diện từ hàm mục tiêu J .

Định lý 1.12. Cho $\mathcal{F}$ -PDF chứa $n > c$ các PDF và $m > 1$. Xét $D_{ij}^2 = D^2(\theta_i; f_j)$ với $1 \leq j \leq n$ và $1 \leq i \leq c$. Với mỗi j , xác định các tập $I_j = \{i | D_{ij}^2 = 0; 1 \leq i \leq c\}$ và tập $I_j^c = \{1, 2, \dots, c\} \setminus I_j$. Khi đó hàm mục tiêu (FCF) có thể đạt cực tiểu toàn cục khi và chỉ khi


$$\theta_i^*(x) = \frac{\sum_{j=1}^n (\mu_{ij}^*)^m f_j(x)}{\sum_{j=1}^n (\mu_{ij}^*)^m} \text{ và} \quad (1.5)$$

$$\begin{cases} \mu_{ij}^* = \frac{(D_{ij}^2)^{1/(m-1)}}{\sum_{s=1}^n (D_{sj}^2)^{1/(m-1)}}, & \text{nếu } I_j \neq \emptyset, \\ \mu_{ij}^* = 0, \sum_{i \in I_j^c} \mu_{ij}^* = 1, \forall i \in I_j^c, & \text{nếu } I_j = \emptyset. \end{cases} \quad (1.6)$$

Nhận xét. Ở đây, tham số m thể hiện mức độ mờ của ma trận phân vùng U . Khi $m \rightarrow 1$, ma trận phân vùng kết quả sẽ tiến về ma trận phân vùng không mờ ($\mu_{ij} = 1_{\{j \in c_i\}}$). Khi $m \rightarrow \infty$, các giá trị μ_{ij} sẽ trở nên bằng nhau ($= 1/c$) làm mất khả năng gán một PDF vào các chùm.

Để minh họa ảnh hưởng của tham số m , ta giả định hai chùm PDF với $D_{2j}^2 = 2 - D_{1j}^2$ và xét giá trị μ_{1j} theo khoảng cách này chạy từ $0 \div 2$. Hình 1.7 trực quan hóa cách m điều chỉnh mức độ cho các giá trị phân vùng μ_{ij} . Khi $m \rightarrow 1$, đường phân vùng trở nên

gãy; khi m tăng, đường cong trở nên phẳng và đều ở $y = 1/2$. Nhiều nghiên cứu tổng quát hóa tham số m đã được đặt ra sau khi thuật toán này công bố. Tuy nhiên, cho đến nay các nhà phân tích vẫn chọn tiêu biểu $m = 2$ vì tính dễ giải thích [7, 9].



Hình 1.7: Biểu đồ phân vùng mờ theo khoảng cách D_{1j} với các hệ số m khác nhau.

Chú thích: Giá trị μ_{1j} tại trục tung biểu diễn mức độ phân vùng tại cụm thứ 1 theo khoảng cách $D_{1j}^2 = \mathcal{L}_1^2(f_1; f_j)$ với các giá trị $m = \{1,1; 1,5; 2,0; 3,0; 5,0; 10,0\}$. Nét đậm hơn thể hiện $m = 2$. Nguồn: Minh họa của tác giả.

Thuật toán phân cụm mờ FCF được thực hiện qua hai bước cập nhật PDF trọng tâm và cập nhật ma trận phân vùng [9, 47] (Thuật toán 5). Kết thúc thuật toán, ta nhận được ma trận phân vùng U và các PDF trọng tâm Θ , trong đó tiêu chuẩn dừng cho FCF là chuẩn của hàm mục tiêu tại hai vòng lặp liên tiếp phải thấp hơn ngưỡng dương ε cho trước, tức là $\|J_{FCF}^{(t)} - J_{FCF}^{(t-1)}\| < \varepsilon$. Cuối cùng, ta có thể giải mờ theo quy tắc $c_i = \arg \max_j \mu_{ij}$. Tức là một PDF $f_j(x)$ sẽ được xếp vào cụm c_i khi và chỉ khi nó có mức độ phân vùng tại cụm đó là cao nhất.

Ví dụ 1.6 (Phân cụm mờ hàm Gauss 1-chiều). Ta sử dụng lại dữ liệu PDF trong Ví dụ 1.4. Phân tích $\mathcal{F}$ thành ba cụm, biết $m = 2$, tiêu chuẩn dừng $\varepsilon = 10^{-3}$ và khoảng cách là $\mathcal{L}_2^2$. Ta có kết quả sau khi thực hiện các vòng lặp được giải chi tiết ở Phụ lục (tr. 86).

Nhận xét. Dựa vào mức độ phân vùng μ_{ij} , ta nhận thấy được mức độ tin cậy để một PDF $f_j(x)$ xếp vào cụm c_i . Nếu phân vùng μ_{ij} tại cụm c_i này lớn, ta có thể chắc chắn vào kết quả phân bố. Ngược lại, nếu giá trị này không cao, ta biết được PDF này có khả năng thuộc vào một cụm khác, hoặc một cụm mới.

So sánh về mặt phức tạp thời gian và phức tạp dung lượng, Bảng 1.7 cho thấy phương pháp KCF đơn giản hơn và ít tốn tài nguyên tính toán hơn so với FCF và thuật toán HCF.

Bảng 1.7: So sánh độ phức tạp của ba thuật toán phân cụm

Thuật toán	Phức tạp thời gian	Phức tạp không gian
Phân cụm KCF	$\mathcal{O}(ncdt)$	$\mathcal{O}(n + cd)$
Phân cấp HCF	$\mathcal{O}(n^2 \log n)$	$\mathcal{O}(n^2)$
Phân cụm FCF	$\mathcal{O}(ncdt)$	$\mathcal{O}(nc)$

Chú thích: n là số lượng đối tượng trong dữ liệu PDF, c là số lượng cụm, d là số chiều dữ liệu, i là tổng số vòng lặp.

► **Chú ý.** Phân tích cụm phân vùng dựa vào trọng tâm rất đơn giản, đặc biệt trong quá trình lặp lại việc cập nhật ma trận phân vùng và trọng tâm cụm. Thuật toán KCF và FCF có độ phức tạp thời gian tương đối thấp là $\mathcal{O}(ncdi)$ và độ phức tạp không gian là $\mathcal{O}(nc)$ hoặc $\mathcal{O}(n + cd)$. Hơn nữa, sử dụng phân tích cụm có lại tiềm năng lớn trong việc khám phá các cấu trúc ẩn và những mối quan hệ có ý nghĩa giữa các mẫu dữ liệu, từ đó hỗ trợ các phân tích chuyên sâu.

Tuy nhiên, nó cũng có một số khuyết điểm bao gồm tính không xác định của các siêu tham số, chất lượng dữ liệu đầu vào và khả năng giải thích của mô hình. Đầu tiên, họ thuật toán này không cung cấp c cụm tối ưu. Đôi khi, ta không có tri thức về số lượng c , dẫn đến khó khăn khi phân cụm các mẫu có số chiều lớn [58] và nguy cơ quá khớp. Theo Goutte *et al.*, “*khi số lượng cụm không phản ánh trong dữ liệu, kết quả cuối cùng cơ bản là vô nghĩa*” [23]. Ngoài ra, do giả định tối ưu lỗi, thuật toán dựa trên trọng tâm thường hoạt động hiệu quả nhất với hình dạng gần cầu và có thể gặp thách thức khi áp dụng cho dữ liệu chứa nhiễu, ngoại lệ, có chồng lấp giữa các cụm hoặc có sự chênh lệch lớn về kích thước và mật độ. Cuối cùng, PDF trọng tâm cụm ban đầu cũng ảnh hưởng đến kết quả tối ưu dù đã có nhiều khuyến nghị như k -means++. Ngược lại, phân tích cụm thứ bậc không đòi hỏi tiên nghiệm về số cụm, nhưng chi phí tính toán cao, đặc biệt với dữ liệu lớn khi cần tính toàn bộ ma trận khoảng cách.

Tóm lại, các thuật toán phân tích cụm mang lại tiềm năng lớn trong việc khám phá các cấu trúc ẩn và những mối quan hệ có ý nghĩa giữa các mẫu dữ liệu, từ đó hỗ trợ các phân tích chuyên sâu và mở ra nhiều ứng dụng tiềm năng [47, 65]. Mặc dù kết quả của các thuật toán phân tích cụm có thể chịu ảnh hưởng bởi dữ liệu đầu vào, thể loại tự nhiên và lựa chọn thuật toán, chúng vẫn đóng vai trò là công cụ mạnh mẽ giúp người dùng nhận diện và diễn giải các mẫu tốt hơn. Qua đó, *các loại tự nhiên có là những gì thuật toán phân cụm phần nào hướng đến trong điều kiện lý tưởng không* là một chủ đề nghiên cứu đầy hứa hẹn, tiếp tục được quan tâm và mở rộng trong cộng đồng khoa học thống kê [36, 44, 79, 80].

1.5 Phân loại cho hàm mật độ xác suất

Ở dữ liệu rời rạc, bốn thuật toán phân loại kinh điển dựa vào thống kê là Naïve Bayes, Cây quyết định, hồi quy Logistics, phân biệt Fisher [19] và Perceptron [56] đã được áp dụng phát triển cho đến hiện nay. Trong khi đó, các phát triển phân loại đối tượng PDF chỉ dựa trên phương pháp Naïve Bayes. Luận văn này tập trung nghiên cứu phương pháp hồi quy logistics, máy vector hỗ trợ và đặc biệt là phương pháp Naïve Bayes [31, 74].

1.5.1 Hồi quy logistics

Phương pháp này được tổng quát hóa cho dữ liệu hàm bởi các nghiên cứu của Akturk et al. [2]. Luận văn này cụ thể hóa cho đối tượng PDF. Mô hình hồi quy logistic cho dữ liệu PDF có dạng

$$\pi_j = \mathbb{P}(Y_j = 1 | f(x) = f_j(x)) = \frac{\exp\{\beta_0 + \int_{\Omega} f(x)\beta(x) dx\}}{1 + \exp\{\beta_0 + \int_{\Omega} f(x)\beta(x) dx\}}, \quad (1.7)$$

trong đó $\beta_0 \in \mathbb{R}$ là hằng số chặn và $\beta(x) \in \mathcal{L}_2[\Omega]$ là hàm hệ số cần ước lượng. Để giải phương trình (1.7), biến đổi logit được sử dụng

$$\ell_j = \log\left(\frac{\pi_j}{1 - \pi_j}\right) = \beta_0 + \int_{\Omega} f(x)\beta(x) dx.$$

Mục tiêu tiếp theo là ước lượng β_0 và hàm $\beta(x)$. Do $\beta(x)$ là vô hạn chiều, ta chiếu hàm này vào một tập hàm cơ sở chọn trước để ước lượng, cụ thể là hàm Gauss, wavelet, chuỗi Fourier, đa thức Bernstein và Legendre, hoặc B-spline (Xem thêm Bảng 3.4 tại Phụ lục C, tr. 84). Khi đó,

$$\ell_j = \beta_0 + \sum_{m=1}^M \theta_m \underbrace{\int_{\Omega} \psi_m(x) f_j(x) dx}_{=: \Phi = \phi_{j,m}},$$

trong đó $\phi_{j,m}$ là mô-men của hàm $f_j(x)$ trên hàm cơ sở $\psi_m(x)$.

Bài toán ước lượng $\beta(x)$ chuyển thành cực đại hóa log-likelihood của hồi quy logistics như sau:

$$\ell(\beta_0; \beta(x)) = \max_{\substack{\beta_0 \in \mathbb{R}; \\ \beta(x) \in \mathbb{R}^M}} \left\{ \underbrace{\sum_{j=1}^n [y_j \log \pi_j + (1 - y_j) \log(1 - \pi_j)]}_{\text{Logistics}} - \underbrace{\lambda_1 \sum_{m=1}^M |\beta_m(x)|}_{\text{Lasso}} - \underbrace{\frac{\lambda_2}{2} \sum_{m=1}^M \beta_m(x)^2}_{\text{Ridge}} \right\}, \quad (1.8)$$


trong đó $\pi_j = \mathbb{P}(Y_j = 1 | f(x))$ và ℓ là hàm mất mát.

Định lý 1.13. *Hàm mất mát ℓ là một hàm lồi theo cả β_0 và $\beta(x)$. Nếu $\lambda_2 > 0$ thì hàm này lồi nghiêm ngặt. Vì vậy, nghiệm tối ưu toàn cục luôn tồn tại duy nhất.*

Từ Định lý 1.13, ta tính được Gradient theo hệ số $\beta(x)$ với $\hat{y}_j = \pi_j$ là xác suất dự đoán, có dạng $\nabla_{\beta} \ell = \Phi^T(y - \hat{y}) - \lambda_1 \text{sign}(\beta(x)) - \lambda_2 \beta$, mà qua đó ta có nhiều phương pháp tối ưu như tối ưu độ dốc như ADAM, hay các quasi-Newton khác như L-BFG-S.

Ví dụ 1.7 (Phân loại hàm mật độ xác suất bằng hồi quy logistic). Xét hai lớp PDF Gauss $\mathcal{F}$ và $\mathcal{G}$ với các trung tâm lần lượt là $\mu_{\mathcal{F}} = \{1,0; 1,5; 2,0; 2,5; 6,0\}$, và $\mu_{\mathcal{G}} = \{4,5; 7,5; 8,5; 8,0; 9,0\}$, trong đó phương sai lần lượt là $\sigma_{\mathcal{F}}^2 = 0,40$ và $\sigma_{\mathcal{G}}^2 = 0,90$. Bài toán đặt ra là phân loại một PDF Gauss mới $h(x) = \mathcal{N}(3,0; 0,90)$ vào một trong hai lớp $\mathcal{F}$ hoặc $\mathcal{G}$.

Sử dụng $M = 10$ hàm cơ sở Gauss, ta ước lượng được hàm hệ số $\hat{\beta}(x)$, phản ánh đóng góp của từng miền x đối với phân loại. Hàm $\hat{\beta}(x)$ được tái tạo và minh họa ở Hình 1.8.



Hình 1.8: Hàm $\hat{\beta}(x)$ được ước lượng qua 10 hàm cơ sở Gauss.

Nguồn: Minh họa của tác giả.

Tiếp theo, để phân loại h , ta cũng chiếu lên không gian cơ sở. Hàm h được chiếu lên 10 hàm cơ sở Gauss để tạo thành vector đặc trưng được đưa vào mô hình logistic đã huấn luyện. Cuối cùng, mô hình logistic dự đoán xác suất h thuộc lớp $\mathcal{F}$ là 43%. Do đó, ta phân loại $h(x)$ vào lớp $\mathcal{F}$.

Nhận xét. Hàm hệ số $\hat{\beta}(x)$ đóng vai trò như một công cụ giải thích quan trọng, cho phép đánh giá mức độ đóng góp của từng miền $x \in \Omega$ đối với quá trình phân loại nhị phân. Đáng chú ý, $\hat{\beta}(x)$ cung cấp một dạng giải thích bằng tính năng, giúp ta hiểu thêm nguồn gốc của từng đóng góp riêng lẻ đến xác suất phân loại.

Hình 1.8 cho thấy $\hat{\beta}(x)$ dao động quanh trục 0 với cả miền dương và âm, phản ánh rằng các vùng khác nhau của x có ảnh hưởng trái ngược đến xác suất dự đoán. Những vùng mà $\hat{\beta}(x) > 0$ sẽ tăng xác suất dự đoán lớp 1 và ngược lại. Cụ thể, các hệ số ψ_5 và ψ_8 có giá trị dương thể hiện tác động tăng xác suất dự đoán, trong khi ψ_3 và ψ_6 mang giá trị âm, góp phần làm giảm xác suất của lớp $\mathcal{F}$.

Việc áp dụng các kỹ thuật chuẩn hoá Ridge làm giảm hệ số một cách đồng đều, còn Lasso tạo ra sự chọn lọc hàm cơ sở ψ_m quan trọng.

1.5.2 Máy vector hỗ trợ

Cho tập huấn luyện gồm các PDF và nhãn của từng hàm $\mathcal{D} = \{(f_j; y_j)\}$ với $j = 1, 2, \dots, n$, trong đó $f_j \in \mathcal{F}$ và $y_j \in \{-1; 1\}$. Bài toán máy vector hỗ trợ lề mềm được xây dựng từ nguyên lý cực tiểu hoá độ lớn vector trọng số w và cho phép sai số điều chỉnh được bởi các biến ξ_j , tức là

$$\begin{aligned} \text{Minimise : } & \frac{1}{2} \|w\|_{\mathcal{H}}^2 + C \sum_{j=1}^n \xi_j, \\ \text{S.t. : } & y_j (\langle w; \Phi(f_j) \rangle + b) \geq 1 - \xi_j, \\ & \xi_j \geq 0, \quad j = 1, 2, \dots, n. \end{aligned}$$

Hàm L'Agrange tương ứng được cho bởi

$$\mathcal{L}(w; b; \xi; \alpha; \mu) = \frac{1}{2} \|w\|^2 + C \sum_{j=1}^n \xi_j - \sum_{j=1}^n \alpha_j [y_j (\langle w; \Phi(f_j) \rangle + b) - (1 - \xi_j)] - \sum_{j=1}^n \mu_j \xi_j.$$

Lấy đạo hàm theo w và đặt $\nabla_w \mathcal{L} = 0$. Ta có $w = \sum_{j=1}^n \alpha_j y_j \Phi(f_j)$. Thay vào hàm

L'Agrange, ta được bài toán đối ngẫu của SVM được định nghĩa bởi

$$\text{Maximise : } \sum_{j=1}^n \alpha_j - \frac{1}{2} \sum_{j=1}^n \sum_{k=1}^n \alpha_j \alpha_k y_j y_k \underbrace{\langle \Phi(f_j); \Phi(f_k) \rangle}_{K(f_j; f_k)}, \quad (\text{SVM})$$

$$\text{S.t. : } 0 \leq \alpha_j \leq C, \quad \sum_{j=1}^n \alpha_j y_j = 0. \quad (1.9)$$

Định lý 1.14. SVM là bài toán tối ưu lồi nghiêm ngặt trên đa diện lồi compact, do đó tồn tại duy nhất nghiệm vector $\alpha^* \in \mathbb{R}^n$.

Chứng minh. Ma trận Gram $G_{jk} = y_j y_k K(f_j; f_k)$ là xác định dương do K là kernel thỏa mãn điều kiện Mercer. hàm mục tiêu là hiệu của một hàm tuyến tính và một dạng toàn phương xác định dương nên lồi nghiêm ngặt. Nhờ đó, tồn tại nghiệm cực đại duy nhất theo định lý Weierstrass.

Khi đó, hàm phân lớp tương ứng đối với PDF mới h là

$$\hat{y}(h) = \text{sign}(g(h)) = \text{sign} \left(\sum_{j=1}^n \alpha_j^* y_j K(f_j; h) + b^* \right).$$

1.5.3 Phương pháp Naïve Bayes

a. Thuật toán phân lớp

Phương pháp Naïve Bayes đã được nhiều nhà thống kê quan tâm cho dữ liệu PDF bởi [55]. Cho tập huấn luyện gồm các PDF và nhãn của từng hàm $\mathcal{D} = \{(f_j; y_j)\}$ với $j = 1, 2, \dots, n$, trong đó $f_j \in \mathcal{F}$ và $y_j \in \{-1; 1\}$. Xác suất hậu nghiệm Bayes để xếp $h(x)$ vào lớp $Y = k$ được viết dưới dạng

$$\mathbb{P}(Y = k | h) = \frac{\mathbb{P}(Y = k) f(h | Y = k)}{\sum_{j \in \{0; 1\}} \mathbb{P}(Y = j) f(h | Y = j)}.$$

Khi đó, ta ước lượng mật độ có điều kiện $f(h | Y = k)$ bằng kỳ vọng của hàm hạt nhân giữa đối tượng mới h và các PDF huấn luyện f_i trong lớp $Y = k$. Tức là,

$$f(h | Y = k) = \frac{1}{n_k b w_k} \sum_{i=1}^{N_k} \mathbb{E}_{X \sim h, Y \sim f_i} \left(\kappa \left(\frac{X - Y}{b w_k} \right) \right), \quad (1.10)$$

trong đó n_k là số mẫu huấn luyện thuộc lớp $Y = k$, f_i là các PDF huấn luyện trong lớp đó, và $b w_k$ là tham số trơn. Dưới dạng tích phân, công thức (1.10) tương đương với

$$f(h | Y = k) = \frac{1}{n_k} \sum_{i=1}^{n_k} \iint \frac{1}{b w_k} \kappa \left(\frac{x - y}{b w_k} \right) h(x) f_i(y) dx dy.$$

Giả sử không có thông tin tiên nghiệm, ta lấy tiên nghiệm đều $\mathbb{P}(Y = 1) = \mathbb{P}(Y = 0) = 1/2$. Khi đó, ta có quy tắc phân loại cho PDF mới $h(x)$ là phân loại vào lớp $Y = 1$ nếu $f(h|Y = 1) > f(h|Y = 0)$ và ngược lại. Tương tự, đối với phân loại nhiều hơn hai lớp, PDF mới h sẽ được phân loại vào lớp k nào có hậu nghiệm lớn nhất, tức là

$$\hat{y} = \arg \max_{k \in \{1, \dots, K\}} \mathbb{P}(Y = k | h).$$

Bổ đề 1.8 (Hàm mật độ xác suất Gauss có điều kiện). Xét công thức ước lượng mật độ có điều kiện $f(h|Y = k)$. Nếu chọn hạt nhân Gauss $\kappa(u) = \mathcal{N}(u; 0; 1)$, thì ta có

$$f(h|Y = k) = \frac{1}{n_k} \sum_{i=1}^{n_k} \mathcal{N}(\mu_h - \mu_i; 0; \sigma_h^2 + \sigma_i^2 + bw_k^2),$$

trong đó $\mathcal{N}(\cdot; 0; \tau^2)$ là mật độ Gauss với trung bình 0 và phương sai τ^2 .

Chứng minh. Ta có $\kappa\left(\frac{x-y}{bw_k}\right) = \mathcal{N}(x-y; 0; bw_k^2)$. Ngoài ra, viết lại tích phân đôi theo biến $z = x - y$, ta có

$$\iint \mathcal{N}(z; 0; bw_k^2) h(y+z) f_i(y) dz dy.$$

Đặt $X \sim \mathcal{N}(\mu_h; \sigma_h^2)$ và $Y \sim \mathcal{N}(\mu_i; \sigma_i^2)$ độc lập. Khi đó biến ngẫu nhiên $Z = X - Y$ cũng tuân theo phân phối chuẩn (Bổ đề 1.1), tức là $Z \sim \mathcal{N}(\mu_h - \mu_i; \sigma_h^2 + \sigma_i^2)$. Do đó, giá trị $f(h|Y = k)$ có thể viết thành kỳ vọng

$$f(h|Y = k) = \int \mathcal{N}(z; 0; bw_k^2) \mathcal{N}(z; \mu_h - \mu_i; \sigma_h^2 + \sigma_i^2) dz.$$

Áp dụng Bổ đề 1.2 về tích phân của tích hai mật độ chuẩn với $a = bw_k^2$, $b = \sigma_h^2 + \sigma_i^2$ và $m = \mu_h - \mu_i$, ta thu được điều phải chứng minh. ■

Ví dụ 1.8 (Phân loại hàm mật độ xác suất bằng phương pháp Naïve Bayes). Trở lại giả thuyết của Ví dụ 1.7, ta cần phân loại PDF Gauss mới $h(x) = \mathcal{N}(3; 0; 0,90)$ vào một trong hai lớp.

Bài giải. Giả sử không có thông tin tiên nghiệm, $\mathbb{P}(Y=1) = \mathbb{P}(Y=0) = 0,50$. Theo Bổ đề 1.8 ta có

$$f(h|Y = k) = \frac{1}{n_k} \sum_{i=1}^{n_k} \frac{1}{\sqrt{2\pi(\sigma_h^2 + \sigma_i^2 + bw_k^2)}} \exp\left(-\frac{(\mu_h - \mu_i)^2}{2(\sigma_h^2 + \sigma_i^2 + bw_k^2)}\right).$$

Dùng quy tắc Silverman cho từng lớp, ta có $h_{\mathcal{F}} = 1,06 \sqrt{0,40} (n_{\mathcal{F}})^{-1/5} = 0,49$ và $h_{\mathcal{G}} = 1,06 \sqrt{0,90} (n_{\mathcal{G}})^{-1/5} = 0,73$. Khi đó, ta tính được $f(h|\mathcal{F})$ qua các kỳ vọng $\mu_{\mathcal{F}}$, ta có kết quả $f(h|\mathcal{F}) = 0,16$. Tương tự, ta cũng tính được $f(h|\mathcal{G})$ qua với các kỳ vọng $\mu_{\mathcal{G}}$, kết quả là $f(h|\mathcal{G}) = 0,03$.

Cuối cùng, xác suất hậu nghiệm của hai lớp được tính bởi công thức

$$\mathbb{P}(\mathcal{F} | h) = \frac{0,50 f(h | \mathcal{F})}{0,50 f(h | \mathcal{F}) + 0,50 f(h | \mathcal{G})} = \frac{0,50 \cdot 0,16}{0,50 \cdot 0,16 + 0,50 \cdot 0,03} = 0,83,$$

và $\mathbb{P}(\mathcal{G} | h) = 1,0 - 0,83 = 0,17$. Vì $\mathbb{P}(\mathcal{F} | h) > \mathbb{P}(\mathcal{G} | h)$ nên $h(x)$ được phân loại vào lớp $\mathcal{F}$ với xác suất hậu nghiệm xấp xỉ 83%.

b. Xác định tiên nghiệm

Trong phân lớp Bayes, xác suất tiên nghiệm $\mathbb{P}(Y = k)$ thường được ước lượng dựa vào kiến thức chuyên gia hoặc thông tin trong lịch sử nghiên cứu tương tự. Trong trường hợp không có thông tin tiên nghiệm, ta giả định các lớp có tiên nghiệm như nhau, tức là $\mathbb{P}(Y = k) = 1/k$. Trong nhiều tình huống, xác suất tiên nghiệm còn có thể ước lượng từ tần suất xuất hiện của các lớp trong tập dữ liệu huấn luyện. Khi đó, $\mathbb{P}(Y = k) = n_k/n$, trong đó n_k là số lượng mẫu thuộc lớp k và n là tổng số mẫu. Tuy nhiên, phương pháp này có thể gặp vấn đề khi dữ liệu ít. Phương pháp Laplace được sử dụng để điều chỉnh, $\mathbb{P}(Y = k) = (n_k + \alpha)/(n + \alpha k)$ với $\alpha > 0$. Với tiên nghiệm Laplace, ta chọn $\alpha = 1$ và với Jeffreys, ta chọn $\alpha = 1/2$.

CHƯƠNG 2

NHẬN DẠNG THỐNG KÊ CHO HÀM MẬT ĐỘ XÁC SUẤT VỚI DỮ LIỆU MẤT CÂN BẰNG


Chương 2 tập trung vào giới thiệu thuật toán SR cho dữ liệu PDF hiệu quả với tình trạng mất cân bằng. Cụ thể, với bài toán phân tích chùm, nghiên cứu tổng quan các nghiên cứu trước đó để làm cơ sở đề xuất thuật toán phân tích chùm mở cải tiến (IFCF). Về phân loại, chương này cũng tổng quan các phương pháp hiện có và giới thiệu việc ứng dụng nguyên tắc phân loại Bayes-IFCF cho dữ liệu mất cân bằng. Các thuật toán đề nghị được ứng dụng trên ví dụ số và so sánh với các thuật toán khác thông qua các tham số đánh giá.

2.1 Giới thiệu dữ liệu hàm mật độ xác suất

Các PDF được xem là dạng dữ liệu đặc trưng với cấu trúc phức tạp. Nó cho phép khám phá quy luật phân bố tại nhiều tổng thể khác nhau hoặc được xem như đối tượng không chắc chắn khi quyết định chưa chính xác hoặc có lỗi. Nhìn chung, có hai dạng dữ liệu PDF bao gồm PDF rời rạc và liên tục. Để xuyên suốt trong quá trình thực hiện các thuật toán đề nghị, Chương 2 sử dụng dữ liệu hàm liên tục là ánh xạ đo được $\mathcal{F} : (\Omega; \mathcal{S}; P) \rightarrow (\mathcal{D}; \mathcal{B}_D)$ với $(\Omega; \mathcal{S}; P)$ là không gian xác suất và σ -đại số Borel $\mathcal{B}_D$ trên $(\mathcal{D}; d)$. Một tập đối tượng PDF quan sát là $f_j \sim \mathcal{F}$ với $j = 1, 2, \dots, n$ (Theo Định nghĩa 1.8 và 1.9).

Dữ liệu hàm mật độ liên tục ngày càng được quan tâm trong nhiều lĩnh vực ứng dụng thực tế, đặc biệt là khi cần mô tả và phân tích các đại lượng có tính ngẫu nhiên biến thiên liên tục theo không gian và thời gian. Trong dữ liệu 1-chiều, nghiên cứu về cá hồi vây vàng (*Yellowfin tuna*) của Minami [42] thể hiện phân bố chiều dài cá theo từng ô tọa độ tại Thái Bình Dương. Bên cạnh đó, các phân phối liên quan đến tỷ giá theo ngày, khí hậu ở các trạm theo năm, mật độ tuổi giữa hai giới ở các tỉnh thành, hay chỉ số sức khỏe theo độ tuổi [10, 33, 52] cũng là những ví dụ tiêu biểu cho dạng 1-chiều. Đặc biệt, dữ liệu PDF còn có thể được xây dựng từ hình ảnh thông qua việc trích xuất thông tin màu sắc [65, 74], mở ra hướng nghiên cứu mới trong phân tích thị giác và SR. Trong khi đó, dữ liệu 2-chiều thường xuất hiện trong các nghiên cứu về mối tương quan, chẳng hạn như phân tích điểm số sinh viên giữa các khoa hoặc viện tại Đại học Cần Thơ [71]. Ngoài ra, dữ liệu này còn có thể được xem là sự mở rộng tự nhiên của các vector rời rạc đa chiều [31, 62]. Hình 2.1 minh họa dữ liệu PDF gồm (a), (b) và (d) là liên tục và (c)

rời rạc; đồng thời, (a), (b) và (c) là 1-chiều và (d) là 2-chiều trong thực tế.



Hình 2.1: Minh họa các dữ liệu PDF được thu thập trong thực tế từ các nghiên cứu trước đây

Chú thích: (a) Dữ liệu Tuna_Fork_Length của Minami [42] biểu diễn phân bố chiều dài thân cá ở các vùng biển khác nhau, (b) Dữ liệu BOLD của Petersen [52] là chuỗi tín hiệu fMRI được biểu diễn bởi PDF, (c) Dữ liệu Blood_dataset của Irpino [33] gồm các PDF thực nghiệm của ba chỉ số sức khỏe và (d) Dữ liệu CTU của Thao Nguyen-Trang [47] là dữ liệu PDF 2-chiều của GPA và rèn luyện của các Khoa/Viện Đại học Cần Thơ. Nguồn: Tác giả tổng hợp.

Tuy nhiên, quá trình thu thập và xử lý loại dữ liệu này thường đòi hỏi nhiều thời gian, đồng thời gặp khó khăn trong việc lưu trữ và biểu diễn trong không gian vô hạn chiều. Do đó, trong những năm gần đây, nhiều phương pháp tiếp cận mới từ bài toán SR đã được phát triển nhằm đáp ứng nhu cầu phân tích và khai thác dữ liệu dạng PDF. Các hướng tiếp cận này bao gồm hai nhóm chính: phân tích cụm và phân loại cho dữ liệu PDF.

2.2 Giới thiệu bài toán phân tích cụm cho dữ liệu mất cân bằng

2.2.1 Phương pháp phân tích cụm hàm mật độ xác suất

Phân tích cụm đóng vai trò quan trọng trong lĩnh vực SR, đặc biệt khi mục tiêu là khám phá cấu trúc tiềm ẩn trong dữ liệu mà không cần thông tin gán nhãn trước. Nói cách khác, đây là một trong những nhánh chính của nhận dạng không được giám sát [15, 34, 57]. Nó tập trung vào việc phát hiện các nhóm tự nhiên trong tập dữ liệu thông

qua độ tương tự giữa các mẫu đầu vào [11, 81].

Ví dụ, trong y học, phương pháp này được sử dụng để khoanh vùng khối u trong hình ảnh MRI; hoặc trong khoa học xã hội, nó hỗ trợ tổng hợp và nhóm các ý kiến, quan điểm theo từng chủ đề khác nhau trong các báo cáo định tính. Như vậy, đầu ra của phân tích chùm chính là các nhãn được gán cho dữ liệu ban đầu, thể hiện mối quan hệ giữa các phần tử trong không gian đặc trưng.

Trong lĩnh vực này, đã có nhiều công trình nghiên cứu chuyên sâu liên quan. Bài toán phân tích chùm PDF lần đầu tiên được giới thiệu vào những năm 2010 [71, 72], mở ra hướng tiếp cận mới cho việc xử lý dữ liệu phức tạp. Hơn nữa, song song với sự phát triển của các phần tử rời rạc và công cụ mô hình hóa thống kê, bài toán phân tích chùm PDF đã không ngừng được hoàn thiện và mở rộng phạm vi ứng dụng trong thực tế. Tổng quan tiến trình phát triển của các phương pháp này trong giai đoạn năm năm được trình bày trong Bảng 2.1, qua đó thể hiện xu hướng tiến hóa từ các phương pháp truyền thống sang các kỹ thuật thích nghi và lai ghép hiện đại.

Nhìn chung, các nghiên cứu từ các tác giả trong nước cho thấy xu hướng phát triển mạnh mẽ cả về chiều sâu lý thuyết lẫn chiều rộng ứng dụng. Cụ thể, các hàm mục tiêu truyền thống như SSE và VCC đã dần được mở rộng và tinh chỉnh thành những biến thể phức tạp hơn, chẳng hạn như CSB và FSF, cho phép đánh giá chất lượng kết quả phân tích chùm một cách đa chiều và sâu sắc hơn. Đáng chú ý, nghiên cứu của Thao Nguyen-Trang đã sử dụng FSF [48] hoặc CSB [63] làm hàm mục tiêu phân chùm, qua đó thể hiện nỗ lực đào sâu vào nội hàm và bản chất tối ưu của thuật toán. Hơn nữa, giai đoạn năm 2019 đánh dấu bước chuyển quan trọng khi các mô hình phân chùm bắt đầu mở rộng từ dạng cứng [54] sang các phương pháp tổng quát hơn như mờ [53], khả dĩ [30] và bán giám sát [65] sử dụng một phần dữ liệu có nhãn để cải thiện độ chính xác của quá trình phân chùm. Sự xuất hiện của hướng tiếp cận này cho thấy bước tiến rõ rệt trong việc kết hợp các phương pháp khác nhau.

Ở các công bố quốc tế, hai công trình tiêu biểu thể hiện hai hướng tiếp cận khác nhau trong nghiên cứu phân tích chùm. Cụ thể, Chen & Hung (2020) [12] tập trung vào việc sử dụng tiêu chuẩn thông tin để tự động phát hiện cấu trúc chùm và xác định số chùm tối ưu, hướng đến việc giảm sự phụ thuộc vào tham số người dùng. Ngược lại, Tavakkol & Son (2021) [62] lại khai thác không gian hạt nhân nhằm xử lý hiệu quả các chùm có hình dạng bất quy tắc và ranh giới phức tạp. Mặc dù các mục tiêu khác nhau, điểm chung giữa chúng là sự mở rộng nền tảng của phân chùm truyền thống sang các dạng dữ liệu có cấu trúc cao hơn. Về mặt ứng dụng, thuật toán entropy-jackknife là phương pháp phân chùm cứng phù hợp cho dữ liệu hình ảnh, trong khi mô hình của Tavakkol & Son lại thích hợp hơn cho dữ liệu PDF đa chiều và liên tục.

Tuy vậy, vấn đề mất cân bằng chùm vẫn chưa có một hướng tiếp cận chuyên biệt.

Bảng 2.1: Tổng quan nghiên cứu phân tích cụm cho dữ liệu PDF giai đoạn từ năm 2019–2024

Năm	Tác giả	Mô tả phương pháp	Khoảng cách	Phân cụm tự động
2019	Tai Vo-Van [71]	Phân cụm FCF, $m = 2$, tìm số cụm bằng SUP	Độ rộng cụm	×
2019	Dinh Pham-Toan <i>et al.</i> [54]	Phân cụm k -medoids, tối thiểu SSE bằng nhị phân aeDE, số cụm cho trước	$\mathcal{L}_2$	×
2020	Dinh Pham-Toan & Tai Vo-Van [53]	Phân cụm FCF, tối thiểu VCC bằng nhị phân GA, $m = 2$, tìm số cụm bằng SUP	$\mathcal{L}_1$	×
2023	Thao Nguyen-Trang, Tai Vo-Van & Ha Che-Ngoc [64]	Phân cụm tự cập nhật cải tiến, tự động dựa trên SUP	Hạt nhân Gauss $\mathcal{L}_1$	×
2023	Thao Nguyen-Trang <i>et al.</i> [63]	Phân cụm cứng, tối thiểu CSB bằng DE, PDF đại diện Gauss	$\mathcal{L}_2$	✓
2023	Thao Nguyen-Trang, Trung Nguyen-Thoi, & Tai Vo-Van [48]	Phân cụm FCF, tối thiểu FSF bằng DE, PDF đại diện Gauss, $m = 1$	$\mathcal{L}_1$	✓
2024	Hung Tran-Nam, Thao Nguyen-Trang & Ha Che-Ngoc [30]	Phân cụm khả dĩ, tối thiểu SSE, chọn ngưỡng bất thường bằng α -cut, $m = 2$, số cụm cho trước	$\mathcal{L}_2$	×
2024	Thao Nguyen-Trang, Yen Nguyen-Hoang & Tai Vo-Van [65]	Phân cụm KCF, tối thiểu SSE, bán giám sát bằng số lượng % nhãn cho trước, số cụm cho trước	$\mathcal{L}_1$	×
2020	Jen-Hao Chen & Wen-Liang Hung [12]	Phân cụm cứng bằng jackknife Shannon entropy, điều chỉnh ngưỡng bằng tối đại VCC	hạt nhân Gauss $\mathcal{L}_1$	✓
2021	Tavakkol, Behnam & Son, Youngdoo [62]	Phân cụm mờ hạt nhân k -medoids cho dữ liệu PDF 2-chiều, $m = 2$, số cụm cho trước	hạt nhân Gauss $\mathcal{L}_1$	×
2024	Okano Ryo & Imaizumi Masaaki [50]	Phân cụm cứng cho dữ liệu PDF	W_2^2	×


Chú thích: Đối với hàm mục tiêu, SSE: sai số của bình phương tối thiểu; VCC: tiêu chuẩn tỷ lệ phương sai (chỉ số Calinski–Harabasz); CSB: hợp của độ đo tương đồng và cân bằng; FSF: tỷ lệ giữa SSE và sự phân biệt giữa các cụm. Đối với phương pháp tối ưu, DE: tiến hóa vi phân; aeDE: tiến hóa vi phân ưu tú thích nghi; GA: giải thuật di truyền. Ở cột cuối, dấu ✓ có nghĩa là tự động toàn bộ thuật toán.

Tỷ lệ mất cân bằng (IR) được định nghĩa là tỷ số giữa số phần tử lớn nhất và số phần tử nhỏ nhất giữa các chùm hay lớp, $IR = \frac{\max_i \#c_i}{\min_j \#c_j}$, trong đó $\#c_i$ là số lượng phần tử trong chùm/lớp i . Khi $IR = 1$, các chùm/lớp có quy mô cân bằng hoàn toàn. Giá trị IR càng lớn thì sự chênh lệch kích thước giữa chùm/lớp lớn nhất và nhỏ nhất càng rõ rệt. Trong kinh tế, các giá trị IR từ trên 10 là đã có tác động tiêu cực đến các thuật toán cả thống kê và học máy/học sâu. Do đó, việc phát triển các thuật toán phân tích chùm có khả năng chống chịu với mất cân bằng là một khoảng trống nghiên cứu quan trọng.

Phân tích chùm cho dữ liệu mất cân bằng là chủ đề phát triển để giải quyết nhu cầu thực tế. Bài toán khoanh vùng hình ảnh hòn đảo giữa đại dương được ghi nhận là có sự mất cân bằng, hay phân đoạn chuỗi tín hiệu hiếm như động đất cũng có tính chất mất cân bằng hơn tín hiệu nền yên tĩnh. Nói cách khác, dữ liệu lúc này có sự chênh lệch lớn giữa các loại trong tự nhiên và tồn tại hai tình trạng: Kích thước chùm và số lượng phần tử trong chùm mất cân bằng. Cụ thể, mất cân bằng về kích thước chùm xảy ra khi các chùm có mức độ phân tán khác biệt đáng kể về đường kính hoặc mật độ, trong khi mất cân bằng về số lượng biểu hiện qua sự chênh lệch lớn trong tổng số mẫu giữa các chùm. Khi đó, các thuật toán phân tích chùm truyền thống dễ gặp khó khăn trong việc duy trì ranh giới rõ ràng giữa các nhóm.

Trong lĩnh vực phân tích chùm dữ liệu rời rạc, thuật toán phân tích chùm mất cân bằng đã được giải quyết rất tốt qua các thuật toán csiFCM (2002) [49], siiFCM (2014) [37], iFCM (2016) [38], EM-IFCM (2024) [83] và EKM (2024) [27]. Các thuật toán này giải quyết chủ yếu hai vấn đề bao gồm mở rộng kích thước chùm và dịch chuyển trọng tâm. Hơn nữa, khi có sự khác biệt lớn về số lượng phần tử hoặc kích thước chùm không đồng đều, các thuật toán phân chùm phân vùng có xu hướng nuốt các chùm nhỏ và chia cho lớp lớn hơn như Yue Pu, Wenbin Yao, & Xiaoyong Li (2024) đề cập [83]. Hiệu ứng này được gọi là "hiệu ứng xi phong" có xu hướng kéo (hút) các phần tử biên của lớp nhỏ về lớp lớn và trọng tâm của lớp nhỏ cũng dịch chuyển về phía lớp lớn. Hai hiệu ứng trên cũng là điểm yếu lớn của phân tích chùm truyền thống.

Giả sử hai chùm có số lượng phần tử $\#c_1$ lớn và $\#c_2$ nhỏ sao cho $\#c_1 = IR \cdot \#c_2$ với $IR \in \mathbb{N}_{>0}$. Khi IR tăng, hàm tỷ số giữa $\#c_1$ và tổng số phần tử trong dữ liệu được biểu diễn bởi $k(x) = 1 - \frac{1}{x+1}$. Trong Hình 2.2, hàm $k(x)$ là một đường cong tăng đơn điệu, trong khi đạo hàm của nó giảm dần. Nghĩa là việc chỉ số hóa kích thước chùm thông qua trọng số lớp dần trở nên bão hòa.



Hình 2.2: Quan hệ giữa tỷ lệ IR và quy mô chùm có số lượng chiếm ưu thế

Tuy nhiên, các thuật toán KCF và FCF giả định rằng các chùm có kích thước tương đương nhau [4], điều này dẫn đến các quyết định phân chùm sai lệch khi dữ liệu thực tế có sự mất cân bằng đáng kể. Theo Xiong (2006) [82], thuật toán KCF có xu hướng ưu tiên chia dữ liệu thành các lớp có kích thước tương đối đồng đều, ngay cả khi bản chất phân bố thực tế không như vậy, dẫn đến kết quả bị lệch, chùm nhỏ dễ bị hút vào chùm lớn. Hiện tượng này được gọi là “hiệu ứng đồng nhất”, xuất phát trực tiếp từ đặc tính của hàm mục tiêu. Tương tự như trong trường hợp của KCF, FCF cũng chịu ảnh hưởng của này. Để chứng minh, ta xét hai PDF trọng tâm θ_1 và θ_2 trong bài toán hai chùm được tính theo (1.5), với mức độ phân vùng giản hóa thành $\mu_{ij} = u$ nếu $f_j \in c_i$ và $(1 - u)$ cho các trường hợp còn lại, ta có

$$\theta_1(x) = \frac{u^m \sum_{f_j \in c_1} f_j(x) + (1-u)^m \sum_{f_j(x) \in c_2} f_j(x)}{\#c_1 u^m + \#c_2 (1-u)^m},$$

$$\theta_2(x) = \frac{(1-u)^m \sum_{f_j(x) \in c_1} f_j(x) + u^m \sum_{f_j \in c_2} f_j}{\#c_1 (1-u)^m + \#c_2 u^m}.$$

Khi chùm đa số c_1 tăng số lượng, khoảng cách $\mathcal{L}_2(\theta_1; \theta_2)$ này giảm dần. Cụ thể, giả sử $\hat{\theta}_i(x) = (1/\#c_i) \sum_{f_j \in c_i} f_j(x)$ là các trọng tâm thực tế tính theo (1.2), ta có

$$\lim_{\#c_1 \rightarrow \infty} \mathcal{L}_2^2(\theta_1; \theta_2) = \lim_{\#c_1 \rightarrow \infty} \int \left(\frac{u^m \#c_1 \hat{\theta}_1(x) + (1-u)^m \#c_2 \hat{\theta}_2(x)}{\#c_1 u^m + \#c_2 (1-u)^m} - \frac{(1-u)^m \#c_1 \hat{\theta}_1(x) + u^m \#c_2 \hat{\theta}_2(x)}{\#c_1 (1-u)^m + \#c_2 u^m} \right)^2 dx$$

$$\stackrel{p=\#c_1/\#c_2}{=} \lim_{p \rightarrow \infty} \left(\frac{p(u^{2m} - (1-u)^{2m})}{(pu^m + (1-u)^m)(p(1-u)^m + u^m)} \right)^2 \mathcal{L}_2^2(\hat{\theta}_1; \hat{\theta}_2).$$

Ta biết trong tỷ lệ trên, p có bậc của tử nhỏ hơn bậc của mẫu, nên giới hạn của nó là 0, từ đó ta có $\lim_{\#c_1 \rightarrow \infty} \mathcal{L}_2^2(\theta_1; \theta_2) = 0$. Điều này chứng minh rằng FCF và KCF có xu hướng làm cho các trọng tâm chùm cuối cùng Θ dịch chuyển gần nhau hơn so với các trọng tâm thực tế $\hat{\Theta}$. Kết quả là, các chỉ số đánh giá phân chùm truyền thống sẽ ưu tiên gộp chùm thiếu số và chùm lân cận thành một chùm duy nhất.

Hình 2.3 minh họa ảnh hưởng đồng thời của IR và mức nhiễu dữ liệu lên kết quả xác định trọng tâm trong thuật toán FCF. Cụ thể, các dòng từ 1 ÷ 4 thể hiện sự gia tăng dần của IR , cho thấy FCF có xu hướng tạo ra các phân vùng đồng đều hơn về số lượng PDF trong mỗi chùm. Đây chính là biểu hiện rõ của “hiệu ứng đồng nhất”. Ngược lại, các cột trong hình mô tả mức độ nhiễu khác nhau của dữ liệu, FCF cho thấy các PDF biên của chùm nhỏ hơn bị kéo lệch về phía chùm lớn khi phân bố dữ liệu trở nên rối loạn. Trong phạm vi của luận văn này, “hiệu ứng đồng nhất” được xem là vấn đề trung tâm và được đề cập, phân tích cũng như giải quyết lần đầu tiên đối với đối tượng là các PDF, trong khi “hiệu ứng xi-phông” được bỏ qua do mức độ ưu tiên thấp hơn trong bối cảnh nghiên cứu hiện tại.

2.2.2 Thuật toán đề nghị


Cho tập $\mathcal{F}$ -PDF, trong đó mỗi f_j là một đối tượng trong tập $\mathcal{F}$ với $j = 1, 2, \dots, n$. Cho trước c là số chùm với $i = 1; \dots; c$. Gọi $U = [\mu_{ij}] \in \mathbb{R}^{n \times c}$ là ma trận phân vùng và $\Theta = \{\theta_1; \dots; \theta_c\}$ là các trọng tâm chùm. Giả sử tham số mờ $m > 1$. hàm mục tiêu của IFCE là tổng của hai phần bao gồm trọng số $1/\omega_i$ giảm “hiệu ứng đồng nhất”.

$$\text{Minimise : } J(U; \Theta | \mathcal{F}; c; m) = \sum_{j=1}^n \sum_{i=1}^c \frac{1}{\omega_i} \mu_{ij}^m D^2(f_j; \theta_i), \quad (\text{IFCF})$$


$$\text{s.t : } \sum_{i=1}^c \mu_{ij} = 1, \quad \forall j = 1, 2, \dots, n, \quad (\text{C1})$$

trong đó $\omega_i^{(t)} = \frac{1}{n} \sum_{j=1}^n \mu_{ij}^{(t-1)}$ là tỷ lệ kích thước mờ của chùm thứ i với $i = 1, 2, \dots, c$, thỏa mãn $\sum_{i=1}^c \omega_i = 1$ với $\mu_{ij}^{(t-1)}$ là ma trận phân vùng tại vòng lặp thứ $(t-1)$.

Nhận xét. Khi mức độ mất cân bằng tăng, phần đóng góp của chùm lớn vào hàm mục tiêu sẽ dần lấn át ảnh hưởng của các chùm nhỏ hơn. Để khắc phục, thành phần của hàm mục tiêu IFCE được hiệu chỉnh bằng cách chia cho hệ số $\frac{1}{\omega_i}$, với $\omega_i \in (0; 1]$, nhằm giảm tỷ lệ đóng góp tương ứng theo kích thước của từng chùm. Khi đó, các chùm lớn phải chịu tổn thất cao hơn trong quá trình tối ưu hóa, nhằm hạn chế chi phối tổng thể mà không làm sai lệch trọng tâm và tính ổn định. Khi tất cả các $\omega_i = 1$, công thức IFCE sẽ trở về dạng gốc của FCF đề cập ở Tiểu mục 1.4.2.



Hình 2.3: Ảnh hưởng của dữ liệu PDF Gauss mất cân bằng lên thuật toán FCF ($m = 2; c = 2; D = \mathcal{L}_2^2$)



Hình 2.4: Ảnh hưởng của tham số mờ m trong IFCM qua tỷ lệ $IR = \{1; 5; 10; 20\}$

Nguồn: Minh họa của tác giả.

Để mô tả các đường cong mức độ phân vùng μ_1 trong trường hợp phân tích chùm nhị phân, luận văn này mô phỏng trực quan thuật toán IFCF trong môi trường khoảng cách chuẩn hóa $D^2 \in [0; 1]$, với chùm 1 tại gốc và chùm 2 tại $D^2 = 1$ đồng thời với các tham số mờ m khác nhau. Hình 2.4 biểu diễn kết quả cho chùm thứ 1.

Hình 2.4 minh họa kết quả của IFCF trong các môi trường có mức độ mất cân bằng khác nhau $IR = \{1; 5; 10; 20\}$, cùng với các trọng số tương ứng ω_i giữa hai chùm. Có thể thấy rằng khi $IR = 1$, các đường cong phân hoạch μ_1 đối xứng quanh khoảng cách D^2 , phản ánh trạng thái cân bằng hoàn toàn giữa hai chùm. Tuy nhiên, khi IR tăng dần, chùm lớn bắt đầu chiếm ưu thế rõ rệt và các đường cong phân hoạch bị lệch về phía chùm đó, cho thấy ảnh hưởng mạnh của hiện tượng mất cân bằng lên ranh giới phân tách. Bên cạnh đó, sự thay đổi của tham số mờ m trong khoảng $1,1 \div 10,0$ cũng minh họa vai trò quan trọng của nó trong việc điều chỉnh độ mờ của phân vùng: các giá trị m thấp làm cho ranh giới giữa các chùm trở nên sắc nét hơn, trong khi các giá trị cao lại tạo nên vùng chuyển tiếp mềm và mượt hơn. Tóm lại, Thuật toán 1 trình bày chi tiết quy trình thực hiện phương pháp IFCF, qua đó cho thấy cơ chế thích ứng của mô hình trước các mức mất cân bằng khác nhau trong dữ liệu.

Algorithm 1: Giải thuật phân tích chùm mờ cải tiến (IFCF)

```

1: procedure IFCF( $c; \varepsilon$ ) ▷ Cho trước số chùm  $c$ 
2:    $t \leftarrow 0$ 
3:   Khởi tạo  $\mu^{(t)}$  và  $\Theta^{(t)}$  ngẫu nhiên và  $\omega_i^{(t)} = 0$ 
4:   while  $\|\mu^{(t+1)} - \mu^{(t)}\| < \varepsilon$  do
5:      $t \leftarrow t + 1$ 
6:     Cập nhật  $\Theta^{(t+1)}$  bằng Công thức (2.7)
7:     Cập nhật  $\mu^{(t+1)}$  bằng Công thức (2.2) và (C1)
8:     Tính  $\omega_i^{(t+1)} \leftarrow \frac{1}{n} \sum_{j=1}^n \mu_{ij}^{(t+1)}$ ,  $1 \leq i \leq c$ 
9:   end while
10:  return  $\mu$ ,  $\Theta$  và  $\omega$ . ▷ Ma trận phân vùng, PDF đại diện, trọng số chùm
11: end procedure

```

2.2.3 Sự hội tụ của thuật toán

Trong phần này, một dãy $(\mu^{(t)}; \Theta^{(t)})$ khởi tạo được thành lập. Mục tiêu là chứng minh dãy này có hội tụ hay không [7, 83]. Xét hai ánh xạ $F : \mathbb{R}^{cd} \rightarrow U; F(\Theta) = \mu$ và $G : U \rightarrow \mathbb{R}^{cd}; G(\mu) = \Theta$, trong đó $\Theta = (\theta_1; \theta_2; \dots; \theta_c)$ và các PDF trọng tâm θ_i tính bởi công thức (1.5).

Ta định nghĩa toán tử $T_{IFCF} : \mathbb{R}^{cd} \times U \rightarrow \mathbb{R}^{cd} \times U; T_{IFCF} = T_2 \circ T_1$, trong đó ánh xạ $T_1 : \mathbb{R}^{cd} \times U \rightarrow \mathbb{R}^{cd}; T_1(\mu; \Theta) = G(\mu)$ và $T_2 : \mathbb{R}^{cd} \rightarrow \mathbb{R}^{cd} \times U; T_2(\Theta) = (F(\Theta), \Theta)$. Khi đó, ta có $T_{IFCF} = (T_2 \circ T_1)(F \circ G(\mu); G(\mu))$. Tức là

$$T_{IFCF} : \mathbb{R}^{cd} \times U \rightarrow \mathbb{R}^{cd} \times U; T_{IFCF} = T_2 \circ T_1. \quad (2.1)$$

Bổ đề 2.1 (Cập nhật ma trận phân vùng U). Với Θ cố định, bài toán tối ưu hoá J_{IFCF} theo U có nghiệm cực tiểu duy nhất $U^* = F(\Theta)$ dưới các ràng buộc phân hoạch mờ (C1). Cụ thể,

$$\mu_{ij} = \frac{\left(\frac{\omega_i}{D^2(\theta_i; f_j)}\right)^{\frac{1}{m-1}}}{\sum_{s=1}^c \left(\frac{\omega_s}{D^2(\theta_s; f_j)}\right)^{\frac{1}{m-1}}}, \quad (2.2)$$

trong đó $1 \leq i \leq c$ và $1 \leq j \leq n$ và trọng số kích thước $\omega_i = \frac{1}{n} \sum_{j=1}^n \mu_{ij}^{(t-1)}$ với $\omega_i > 0$ và $\sum_i \omega_i = 1$. Ngoài ra, nếu tồn tại i_0 sao cho $D^2(\theta_{i_0}; f_j) = 0$ thì nghiệm tối ưu cho cột j là $\mu_{i_0,j} = 1$ và $\mu_{s,j} = 0$ với mọi $s \neq i_0$. Nếu có nhiều chỉ số đạt 0 thì mọi phân phối trên tập đó đều tối ưu.

Chứng minh. Do ràng buộc phân hoạch mờ là độc lập theo từng mẫu j và mục tiêu (IFCF) là tổng theo j , nên bài toán tối ưu hoá theo U tách thành n bài toán độc lập. Cố định một $j \in \{1, 2, \dots, n\}$ và đặt hằng số $\delta_{ij} := \frac{1}{\omega_i} D^2(\theta_i; f_j)$. Khi đó, mục tiêu của bài toán con theo cột j là

$$\min_{\mu_{.j} \in \mathbb{R}_{>0}^c} \phi_j(\mu_{.j}) : \sum_{i=1}^c \delta_{ij} \mu_{ij}^m; \quad \text{s.t.} \quad \sum_{i=1}^c \mu_{ij} = 1, \mu_{ij} \geq 0. \quad (2.3)$$

Với $m > 1$, ta nhận được hàm $t \mapsto t^m$ lồi nghiêm ngặt trên $\mathbb{R}_{>0}$. Khi đó, hàm mục tiêu ϕ_j là tổng các hàm lồi nghiêm ngặt theo từng biến. Miền khả thi là một đơn hình đóng và bị chặn, do đó nghiệm tối ưu tồn tại duy nhất. Hơn nữa, ma trận Hessian là xác định dương, với các phần tử trong ma trận

$$\begin{cases} \frac{\partial^2 \phi_j}{\partial \mu_{ij}^2} = m(m-1)(\delta_{ij})\mu_{ij}^{m-2} > 0, & \text{khi } s = i \\ \frac{\partial^2 \phi_j}{\partial \mu_{ij} \partial \mu_{sj}} = 0, & \text{khi } s \neq i. \end{cases}$$

Lập hàm Lagrangian với nhân tử $\lambda_j \in \mathbb{R}$ cho ràng buộc tổng bằng 1 và $\alpha_{ij} \geq 0$ cho các ràng buộc không âm, ta có

$$\mathcal{L}(\mu_j, \lambda_j, \alpha_j) = J_{IFCF} - \lambda_j \left(\sum_{i=1}^c \mu_{ij} - 1 \right) - \sum_{i=1}^c \alpha_{ij} \mu_{ij}. \quad (2.4)$$

Điều kiện dừng bậc nhất là đạo hàm riêng của (2.4) theo μ_{ij} bằng 0, tức là

$$\frac{\partial}{\partial \mu_{ij}} \mathcal{L} = m \delta_{ij} \mu_{ij}^{m-1} - \lambda_j - \alpha_{ij} = 0, \quad (2.5)$$

cùng với các điều kiện $\sum_{i=1}^c \mu_{ij} = 1$, $\mu_{ij} \geq 0$, $\alpha_{ij} \geq 0$, và $\alpha_{ij} \mu_{ij} = 0 \forall i$. Giả sử $\delta_{ij} > 0$ với mọi i , nếu $\mu_{ij} > 0$ thì $\alpha_{ij} = 0$. Khi đó (2.5) cho kết quả

$$\mu_{ij} = \left(\frac{\lambda_j}{m} \right)^{\frac{1}{m-1}} (\delta_{ij})^{-\frac{1}{m-1}}. \quad (2.6)$$

Áp dụng ràng buộc chuẩn hoá $\sum_{i=1}^c \mu_{ij} = 1$ vào (2.6), ta có

$$1 = \sum_{i=1}^c \left(\frac{\lambda_j}{m} \right)^{\frac{1}{m-1}} (\delta_{ij})^{-\frac{1}{m-1}} = \left(\frac{\lambda_j}{m} \right)^{\frac{1}{m-1}} \sum_{i=1}^c (\delta_{ij})^{-\frac{1}{m-1}},$$

suy ra

$$\left(\frac{\lambda_j}{m} \right)^{\frac{1}{m-1}} = \frac{1}{\sum_{s=1}^c (\delta_{sj})^{-\frac{1}{m-1}}}.$$

Thế ngược lại vào (2.6), ta thu được (2.2).

Ngược lại, tồn tại i_0 sao cho $D^2(\theta_{i_0}; f_j) = 0$ thì $\delta_{i_0j} = 0$. Tuy nhiên, với mọi $s \neq i_0$, ta có $\delta_{sj} > 0$, nên để tối thiểu hoá tổng $\sum_s c_{sj} \mu_{sj}^m$ dưới ràng buộc tổng bằng 1, nghiệm tối ưu là $\mu_{i_0j} = 1$ và $\mu_{sj} = 0$ với $s \neq i_0$. Từ đây ta suy ra được điều phải chứng minh. ■

Bổ đề 2.2 (Cập nhật trọng tâm Θ với $\mathcal{L}_2^2$). Với U cố định, bài toán tối thiểu hoá J_{IFCF} theo Θ là phân tích được theo từng θ_i với $i = 1, 2, \dots, c$ và lời nghiệm ngặt. Tồn tại duy nhất nghiệm cực tiểu $\Theta^* = G(U)$ khi khoảng cách $D^2 = \mathcal{L}_2^2$,

$$\theta_i(x) = \frac{\sum_{j=1}^n (\mu_{ij})^m f_j(x)}{\sum_{j=1}^n (\mu_{ij})^m}. \quad (2.7)$$

Chứng minh. Giữ U cố định và lấy đạo hàm của hàm mục tiêu (IFCF) cho $\psi_i = \sum_{i=1}^c \psi_i(\theta_i)$ với các $\psi_i(\theta_i) = \psi_i(\theta_i) = \sum_{j=1}^n \frac{1}{\omega_i} (\mu_{ij})^m \mathcal{L}_2^2(\theta_i, f_j)$ theo θ_i , ta có

$$\nabla_{\theta_i} \psi_i(\theta_i) = \frac{1}{\omega_i} \sum_{j=1}^n (\mu_{ij})^m (\mu_{ij})^m \nabla_{\theta_i} \mathcal{L}_2^2(\theta_i; f_j). \quad (2.8)$$

Cho $\nabla_{\theta_i} \psi_i(\theta_i) = 0$, ta được công thức cập nhật (2.7) đối với riêng trường hợp $\mathcal{L}_2^2(\theta_i; f_j)$. Hơn

nữa, với khoảng cách $\mathcal{L}_2$, ma trận Hess theo θ_i là $\nabla_{\theta_i}^2 \psi_i(\theta_i) = \frac{2}{\omega_i} \left(\sum_{j=1}^n (\mu_{ij})^m \right) \mathbf{I}_d$, xác định dương vì $\sum_j (\mu_{ij})^m > 0$ và $\omega_i > 0$. Do đó ψ_i lồi nghiêm ngặt và nghiệm bậc nhất (2.8) là duy nhất, suy ra nghiệm toàn cục duy nhất $\Theta^* = G(U)$. ■

Tuy nhiên, $\nabla_{\theta_i}^2 \psi_i(\theta_i)$ chỉ lồi nghiêm ngặt trong một số khoảng cách như $\mathcal{L}_2$, D_H^2 , hoặc W_2^2 , trong khi với các khoảng cách khác như D_{BC} , D_{KL} , hoặc D_{JS} có thể không có duy nhất nghiệm toàn cục. Bổ đề 2.3 chứng minh công thức thành lập trọng tâm đối với khoảng cách D_H^2 .

Bổ đề 2.3 (Cập nhật trọng tâm Θ với D_H^2). Với U cố định, bài toán tối thiểu hoá hàm mục tiêu (IFCF) theo Θ có thể tách được theo từng θ_i và là lồi nghiêm ngặt trong biến $\sqrt{\theta_i}$. Tồn tại duy nhất nghiệm cực tiểu $\Theta^* = G(U)$ khi khoảng cách $D^2 = D_H^2$, trong đó

$$\theta_i(x) = \frac{\left(\sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(x)} \right)^2}{\int_{\Omega} \left(\sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(\xi)} \right)^2 d\xi}. \quad (2.9)$$

Chứng minh. Giữ U cố định, xét $\psi_i(\theta_i) = \sum_{j=1}^n \frac{1}{\omega_i} (\mu_{ij})^m D_H^2(\theta_i, f_j)$. Ta có khoảng cách bình phương Hellinger là $D_H^2(\theta_i, f_j) = 1 - \int \sqrt{\theta_i(x) f_j(x)} dx$. Do đó

$$\psi_i(\theta_i) = \frac{1}{\omega_i} \sum_{j=1}^n (\mu_{ij})^m \left(1 - \int_{\Omega} \sqrt{\theta_i(x) f_j(x)} dx \right).$$

Vì $\theta_i(x) \geq 0$, nên ψ_i trở thành một hàm lồi theo $\theta_i^{1/2}(x)$. Vì vậy,

$$\frac{\partial \psi_i}{\partial \theta_i^{1/2}(x)} = -\frac{1}{\omega_i} \sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(x)} + \frac{1}{\omega_i} \left(\sum_{j=1}^n (\mu_{ij})^m \right) \theta_i^{1/2}(x).$$

Cho $\frac{\partial \psi_i}{\partial \theta_i^{1/2}(x)} = 0$, ta có công thức (2.9). Ta cũng có ma trận Hess xác định dương, nên nghiệm (2.9) là nghiệm toàn cục duy nhất. ■

Ta cũng chứng minh được công thức đóng tại Bổ đề 2.3 cũng là một PDF (Tính chất 1.3).

Chứng minh. Từ kết quả công thức (2.9), ta có


$$\int_{\Omega} \theta_i(x) dx = \int_{\Omega} \frac{\left(\sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(x)} \right)^2}{\int_{\Omega} \left(\sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(\xi)} \right)^2 d\xi} dx = \frac{\int_{\Omega} \left(\sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(x)} \right)^2 dx}{\int_{\Omega} \left(\sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(\xi)} \right)^2 d\xi} = 1.$$

Tổng thể, Bảng 2.2 và Hình 2.5 thể hiện sự khác biệt các khoảng cách $\mathcal{L}_2$, D_H^2 và W_2^2 trong xác định trọng tâm chùm gồm ba đối tượng PDF, cho thấy hình dạng, vị trí và

phân tán của nó.

Bảng 2.2: Tổng kết các công thức trọng tâm theo khoảng cách khác nhau đối với hàm mục tiêu (IFCF)

Công thức khoảng cách	Trọng tâm θ
$\mathcal{L}^2(f; \theta) = \int (f(x) - \theta(x))^2 dx$	$\theta(x) = \frac{\sum_j u_{ij}^m f_j(x)}{\sum_j u_{ij}^m}$
$D_H^2(f; \theta) = \frac{1}{2} \int (\sqrt{f(x)} - \sqrt{\theta(x)})^2 dx$	$\theta(x) = \frac{\left(\sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(x)} \right)^2}{\int_{\Omega} \left(\sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(\xi)} \right)^2 d\xi}$
$W_2^2(f; \theta) = \int_0^1 (F^{-1}(p) - G^{-1}(p))^2 dp,$	$\theta(x) = \frac{d}{dx} Q_{\theta}^{-1}; Q_{\theta}(p) = \frac{\sum_j u_{ij}^m Q_{f_j}(p)}{\sum_j u_{ij}^m}$



Hình 2.5: Minh họa các công thức trọng tâm theo khoảng cách đối với hàm mục tiêu (IFCF)

Chú thích: Trọng tâm (nét liền) của ba PDF (nét đứt) qua các loại khoảng cách (a) $\mathcal{L}_2$, (b) Hellinger và (c) 2-Wasserstein. Nguồn: Minh họa của tác giả.

Tuy nhiên, hai Bổ đề 2.1 và 2.2 chỉ là điều kiện cần để $(\mu^*; \Theta^*)$ là một cực tiểu toàn cục của hàm mục tiêu (IFCF). Từ đây, bài toán cần giải quyết câu hỏi liệu dãy $\{T_{IFCF}^{(t)}(\mu^{(0)})\}$ có hội tụ về μ^* hay không. Điều kiện đủ cho định lý Zangwill là tính compact của một tập con $U \times \mathbb{R}^{cd}$ chứa tất cả các dãy sinh bởi T_{IFCF} .

Ba Định lý 2.1, 2.2 và 2.3 là một phần của chứng minh (IFCF) bằng định lý Zangwill, chứng minh trực tiếp cho kết quả của Định lý 2.4.

Định lý 2.1 (Ràng buộc compact). Cho $[\text{conv}(\mathcal{F})]^c$ là tích Descartes bậc c của bao lồi $\mathcal{F}$ và $(\mu^{(0)}; \Theta^{(0)})$ là điểm bắt đầu của phép lặp với J_{IFCF} với $\mu^{(0)} \in U$ và $\Theta^{(0)} = G(\mu^{(0)})$. Khi đó $T_{IFCF}^{(0)}(\mu^{(0)}; \Theta^{(0)}) \in U \times [\text{conv}(\mathcal{F})]^c$, và $U \times [\text{conv}(\mathcal{F})]^c$ là tập compact trong $U \times \mathbb{R}^{cd}$.

Chứng minh. Giả sử $\mu^{(0)} \in U$, khi đó $\Theta^{(0)} = G(\mu^{(0)})$ được tính theo (2.7). Khi đó $\theta_i^{(0)} = \frac{\sum_{j=1}^n (\mu_{ij}^{(0)})^m f_j}{\sum_{j=1}^n (\mu_{ij}^{(0)})^m}$. Đặt $\rho_{ij} = \frac{(\mu_{ij}^{(0)})^m}{\sum_{l=1}^n (\mu_{il}^{(0)})^m}$ với $1 \leq j \leq n$. Theo các ràng buộc (C1), ta có $0 < \rho_{ij} < 1$ với mọi i, j . Vậy $\forall i$, ta có thể viết lại $\theta_i^{(0)} = \sum_{j=1}^n \rho_{ij} f_j$ với $\sum_{j=1}^n \rho_{ij} = 1$.

Tóm lại với mọi i , ta có $\theta_i^{(0)} \in \text{conv}(\mathcal{F})$ và do đó $\Theta^{(0)} \in [\text{conv}(\mathcal{F})]^c$. Tiếp tục đệ quy $\mu^{(1)} = F(\mu^{(0)}) \in U$ và $\Theta^{(1)} = G(\mu^{(1)}) \in [\text{conv}(\mathcal{F})]^c$ theo lập luận tương tự. Khi đó, mọi dãy lặp của (IFCF) đều thuộc $U \times [\text{conv}(\mathcal{F})]^c$ với mọi $t \geq 1$. Nếu có thể khởi tạo $\Theta^{(0)} \in \mathbb{R}^{cd} \setminus [\text{conv}(\mathcal{F})]^c$, nhưng khi đó $\mu^{(0)} = F(\Theta^{(0)}) \in U$ và từ $t \geq 1$ thì $\Theta^{(t)} = G(\mu^{(t)}) \in [\text{conv}(\mathcal{F})]^c$. Rõ ràng, $U \times [\text{conv}(\mathcal{F})]^c$ là một tập com-pắc trong $\mathcal{F}$ và dãy lặp hội tụ hữu hạn. ■

Định lý 2.2. Xét $S_{IFCF} = \{(\mu^*; \Theta^*) : J_{IFCF}(\mu^*; \Theta^*) < J_{IFCF}(\mu; \Theta)\}$ với mọi $(\mu; \Theta) \in B^0((\mu^*; \Theta^*); r)$ là tập nghiệm. Khi đó, (IFCF) là hàm giảm của $\{T_{IFCF}; S_{IFCF}\}$.

Chứng minh. Đầu tiên, vì các ánh xạ $\{y \mapsto D_y^2\}$, $\{y \mapsto 1 - y\}$ và $\{y \mapsto y^m\}$ đều liên tục và J_{IFCF} là tổng các tích của các hàm này. Do đó, hàm mục tiêu (IFCF) liên tục trên $U \times \mathbb{R}^{cd}$. Tiếp theo, giả sử $(\mu; \Theta) \notin S_{IFCF}$. Từ (2.1) suy ra

$$\begin{aligned} J_{IFCF}(T_{IFCF}(\mu; \Theta)) &= J_{IFCF}(T_2 \circ T_1(\mu; \Theta)) \\ &= J_{IFCF}(F \circ G(\mu); G(\mu)) \quad \text{theo Định nghĩa 2.1} \\ &< J_{IFCF}(\mu; G(\mu)) \quad \text{theo Bổ đề 2.1} \\ &< J_{IFCF}(\mu; \Theta) \quad \text{theo Bổ đề 2.2} \end{aligned}$$

Do đó, nếu $(\mu; \Theta) \notin S_{IFCF}$ thì $J_{IFCF}(T_{IFCF}(\mu; \Theta)) < J_{IFCF}(\mu; \Theta)$. Nói cách khác, J_{IFCF} là hàm giảm đối với cặp $(T_{IFCF}; S_{IFCF})$ theo định lý Zangwill.

Định lý 2.3 (Ràng buộc liên tục). T_{IFCF} liên tục trên $U \times \mathbb{R}^{cd}$.

Chứng minh. Vì $T_{IFCF} = T_2 \circ T_1$ là hợp của các hàm liên tục nên cũng liên tục. Ta chỉ cần chỉ ra T_1 và T_2 đều liên tục. Với $T_1(\mu, \Theta) = G(\mu)$, T_1 liên tục nếu G liên tục. Để chứng minh G liên tục trong cd biến μ , ta có G là một trường vector, với ánh xạ $G : \mathbb{R}^{cd} \rightarrow \mathbb{R}^{cd}$. Vì $\{\mu \mapsto \mu^m\}$ là liên tục, $\{\mu^m \mapsto \mu^m/\omega_i\}$ là liên tục. Do đó, G_i là thương của hai hàm liên tục nên liên tục với mọi i . Do đó, G và T_1 liên tục trên toàn bộ tập xác định.

Tương tự, vì $T_2(\Theta) = (F(\Theta); \Theta)$, nên chỉ cần chứng minh F liên tục trên $\{\theta_i\}$. Cũng có F là một trường vector $F : \mathbb{R}^{cd} \rightarrow \mathbb{R}^{cd}$. Vì $\{\theta_i \mapsto D^2(\theta_i; f_j)\}$ liên tục với mọi i và $\{D^2(\theta_i; f_j) \mapsto D(\theta_i; f_j)^{-2/(m-1)}\}$ liên tục. Mà F_{ij} là thương của hai hàm liên tục (với giả thuyết $D^2 > 0$). Do đó, F và T_2 liên tục trên toàn bộ tập xác định. Cuối cùng, toán tử $T_{IFCF} = T_2 \circ T_1$ là liên tục trên $U \times \mathbb{R}^{cd}$. ■

Định lý 2.4 (Định lý hội tụ cho J_{IFCF}). Xét tập $\mathcal{F}$ -PDF $\mathcal{F} = \{f_1; f_2; \dots; f_n\}$, cho hàm mục tiêu $J_{IFCF}(U; \Theta)$ có dạng (IFCF), trong đó ma trận phân vùng U thỏa mãn (C1) và các trọng tâm chùm $\Theta = \{\theta_1; \theta_2; \dots; \theta_c\}$. Nếu $T_{IFCF} : \mathbb{R}^{cd} \times U \rightarrow \mathbb{R}^{cd} \times U$ là một toán tử lặp Picard của J_{IFCF} và với mọi t sao cho $D^2(\theta_i^{(t)}; f_j) > 0$, thì với mọi $(\mu^{(0)}; \Theta^{(0)}) \in U \times [\text{conv}(\mathcal{F})]^c$, hoặc

1. Dãy $\{(J_{IFCF})^{(t)}(\mu^{(0)}; \Theta^{(0)})\}$ dừng tại giá trị cực tiểu địa phương $(\mu_{ij}^*; \Theta^*)$ của J_{IFCF} ; hoặc
2. Dãy $\{(J_{IFCF})^{(t)}(\mu^{(0)}; \Theta^{(0)})\}$ chứa một dãy con sao cho $\{(J_{IFCF})^{(t_k)}(\mu^{(0)}; \Theta^{(0)})\} \rightarrow (\mu^*; \Theta^*)$ là giá trị cực tiểu địa phương của J_{IFCF} khi $t_k \rightarrow \infty$.

Chứng minh. Do hàm mục tiêu J_{IFCF} liên tục trên $U \times \mathbb{R}^{cd}$, Định lý 2.2 chỉ ra rằng J_{IFCF} là một hàm Zangwill giảm cho tập nghiệm $\{T_{IFCF}; S_{IFCF}\}$ trong đó S_{IFCF} là tập các cực tiểu nghiệm ngặt của J_{IFCF} . Định lý 2.3 khẳng định T_{IFCF} liên tục trên $U \times [\text{conv}(\mathcal{F})]^c$ và theo Định lý 2.1, toán tử dãy lặp J_{IFCF} luôn nằm trong một tập con compact của miền xác định. Kết quả này suy ra trực tiếp từ định lý Zangwill. ■

Nhận xét. Định lý này đánh giá sự hội tụ theo từng vòng lặp với một số điều kiện ràng buộc về khoảng cách là một mê-tríc. Điều này dẫn đến một số khó khăn khi đánh giá trên các khoảng cách là f -phân kỳ.

2.2.4 Tham số đánh giá chất lượng

Đánh giá phân tích chùm đóng vai trò quan trọng trong việc đánh giá sự chính xác và phản ánh đúng cấu trúc thực tế của dữ liệu. Các chỉ số đánh giá hiệu suất chùm (CVI) được sử dụng nhằm đo lường mối quan hệ giữa các đặc trưng của các chùm đã hình thành, bao gồm tính kết nối, tính gắn kết, tính đối xứng và tính tách biệt [32].

Thông thường, việc đánh giá kết quả phân tích chùm được chia thành hai trường hợp (a) đánh giá bên ngoài và (b) đánh giá bên trong. Đối với (a), tiêu chí đánh giá bên ngoài được áp dụng khi có thông tin về nhãn thực tế, cho phép so sánh trực tiếp giữa kết quả phân chùm và dữ liệu gốc để đo độ chính xác trong các thí nghiệm mô phỏng. Ngược lại, đối với (b), các tình huống thực tế khi nhãn không được biết trước, việc đánh giá phải dựa trên tiêu chí nội bộ. Đánh giá nội bộ vì thế phản ánh năng lực tự tổ chức của thuật toán, mà không cần đến thông tin gán nhãn sẵn có.

a. Đánh giá bên trong

- (i) Chỉ số *Silhouette* $S = \text{mean}(s(f_j))$ đo mức độ phù hợp của một PDF f_j với chùm mà nó được gán nhãn so với chùm gần nhất khác, trong đó

$$s(f_j) = \frac{b(f_j) - a(f_j)}{\max\{a(f_j); b(f_j)\}},$$

với $a(f_j) = \frac{1}{\#c_i - 1} \sum_{\substack{f \in c_i \\ f \neq f_j}} D(f_j; f)$ là khoảng cách trung bình giữa f_j và tất cả các PDF khác trong chùm c_i chứa nó và $b(f_j) = \min_{j \neq i} \frac{1}{\#c_j} \sum_{f \in c_j} D(f_j; f)$ là khoảng cách trung bình giữa f_j và các PDF trong chùm gần nhất c_j với $j \neq i$.

- (ii) Chỉ số *Dunn* đánh giá mức độ tách biệt giữa các chùm, được định nghĩa bởi

$$Dunn = \frac{\min_{i \neq j} \Delta_{\min}(c_i; c_j)}{\max_m \Delta(c_m)},$$

trong đó $\Delta_{\min}(c_i; c_j) = \min_{\substack{f \in c_i \\ g \in c_j}} D(f; g)$ là liên kết nhỏ nhất giữa hai chùm c_i và c_j và $\Delta(c_m) = \max_{f, g \in c_m} D(f; g)$ là đường kính lớn nhất của chùm c_m .


(iii) Chỉ số Davies–Bouldin đo mức độ tương đồng giữa các cụm, được định nghĩa bởi

$$DBI = \frac{1}{c} \sum_{i=1}^c \max_{j \neq i} \left\{ \frac{S_i + S_j}{D(\theta_i; \theta_j)} \right\},$$

trong đó $S_i = \frac{1}{\#c_i} \sum_{f \in c_i} D(f; \theta_i)$ là độ phân tán trung bình của cụm c_i với θ_i là trọng tâm của cụm c_i , $D(\theta_i, \theta_j)$ là khoảng cách giữa hai trọng tâm θ_i và θ_j và c là tổng số cụm.

Nhận xét. Chỉ số Silhouette và Dunn có giá trị càng lớn, kết quả phân tích cụm càng tốt. Ngược lại, chỉ số DBI càng nhỏ càng tốt, do giá trị thấp biểu thị sự phân tách tốt và giảm mức độ chồng lấn giữa các cụm.

Ta cũng có thể khảo sát và chọn số cụm tối ưu qua các CVI này. Để minh họa, Hình 2.6 cho giá trị các chỉ số CVI với số cụm $c = 2 \div 7$ đối với dữ liệu ở Ví dụ 1.5. Kết quả cho thấy chỉ số Silhouette đạt cực đại tại $c = 3$, chỉ số Dunn cao nhất tại $c = 6$ và DBI giảm dần. Như vậy, cả ba chỉ số đều gợi ý rằng mô hình phân cụm có hiệu quả cao nhất khi số cụm $c = 3$, thể hiện sự tách biệt giữa các cụm PDF.



Hình 2.6: Một số chỉ số đánh giá và số cụm tối ưu được đề xuất từ phương pháp khuỷu tay với dữ liệu PDF ở Ví dụ 1.5

Chú thích: Hình ở trên thể hiện chỉ số Silhouette và Dunn vì chúng càng lớn càng tốt. Ngược lại, chỉ số DBI càng nhỏ càng tốt. Điểm khuỷu tay là điểm mà ở đó độ dốc giữa hai dãy cụm bất kỳ đạt cực đại. Ở đây, ta thấy chỉ số Silhouette và DBI đều đề xuất k-cụm tối ưu là $k = 3$. Trong khi đó, chỉ số Dunn cho kết quả $k = 6$. Nguồn: Minh họa của tác giả.

Bên cạnh đó, hệ số tương tự chùm được trình bày trong Bảng 1.6 cũng được xem là một chỉ số đánh giá bên ngoài, giúp định lượng mức độ tương tự giữa hai chùm PDF [75]. Thông qua việc kết hợp các chỉ số này, có thể đánh giá toàn diện hơn về tính ổn định và độ chính xác của kết quả phân tích chùm. Trong phạm vi luận văn này, các thuật toán được thống nhất sử dụng khoảng cách $\mathcal{L}_2$ để đảm bảo tính nhất quán trong so sánh và đánh giá.

Nhận xét. Các chỉ số đánh giá nội chùm phụ thuộc vào khoảng cách và liên kết chùm (Chương 1), dẫn đến một số sai lệch khi ta thiết kế thuật toán phân chùm theo các loại khoảng cách khác nhau. Tức là, cùng một cấu trúc dữ liệu nhưng với các loại khoảng cách khác nhau, giá trị của các chỉ số đánh giá nội chùm có thể thay đổi đáng kể.

b. Đánh giá bên ngoài

Đánh giá bên ngoài được sử dụng khi có nhãn thực tế $\mathcal{P} = \{\mathcal{F}_1; \mathcal{F}_2; \dots; \mathcal{F}_R\}$ của tập PDF $\mathcal{F} = \{f_1; f_2; \dots; f_n\}$ và kết quả phân chùm $\mathcal{G} = \{\mathcal{G}_1; \mathcal{G}_2; \dots; \mathcal{G}_K\}$. Xét các cặp $(f_i; f_j)$, ta có các trường hợp

$$\begin{aligned} a &= \#\{(f_i; f_j) \mid f_i, f_j \in \mathcal{F}_r \cap \mathcal{G}_k\}; \\ b &= \#\{(f_i; f_j) \mid f_i, f_j \in \mathcal{F}_r; f_i \in \mathcal{G}_k; f_j \in \mathcal{G}_l; k \neq l\}; \\ c &= \#\{(f_i; f_j) \mid f_i, f_j \in \mathcal{G}_k; f_i \in \mathcal{F}_r; f_j \in \mathcal{F}_s; r \neq s\}; \\ d &= \#\{(f_i; f_j) \mid f_i \in \mathcal{F}_r \cap \mathcal{G}_k; f_j \in \mathcal{F}_s \cap \mathcal{G}_l; r \neq s; k \neq l\}. \end{aligned}$$

Bảng 2.3: Các chỉ số đánh giá độ tương đồng giữa hai phân hoạch

Chỉ số	Công thức	Ý nghĩa
Rand Index (RI)	$RI = \frac{a + d}{a + b + c + d}$	Đo mức độ tương đồng/chính xác của $\mathcal{P}$ theo $\mathcal{G}$
Adjusted Rand Index (ARI)	$ARI = \frac{RI - \mathbb{E}(RI)}{\max(RI) - \mathbb{E}(RI)}$	Loại bỏ trùng khớp ngẫu nhiên; giá trị tối đa là 1.
Fowlkes–Mallows Index (FMI)	$FMI = \sqrt{\frac{a}{a+b} \cdot \frac{a}{a+c}}$	Đo lường cặp đúng/sai dựa trên precision và recall.
Jaccard Index (J)	$J = \frac{a}{a+b+c}$	Tỷ lệ cặp cùng chùm trên tổng số cặp liên quan.
Normalized Mutual Information (NMI)	$NMI = \frac{2I(\mathcal{P}, \mathcal{G})}{H(\mathcal{P}) + H(\mathcal{G})}$	Đo mức độ phụ thuộc thông tin giữa hai phân hoạch.

Trong đó, $p_i = \#\mathcal{F}_i/n$, $p_j = \#\mathcal{G}_j/n$, $p_{ij} = \#(\mathcal{F}_i \cap \mathcal{G}_j)/n$, ta có, $I(\mathcal{P}, \mathcal{G}) = \sum_{i,j} p_{ij} \log \frac{p_{ij}}{p_i p_j}$, với $H(\mathcal{P}) = -\sum_i p_i \log p_i$ và $H(\mathcal{G}) = -\sum_j p_j \log p_j$. Nguồn: Tác giả tổng hợp.

Nhận xét. Các chỉ số đánh giá bên ngoài phụ thuộc vào cách giải mờ trong phân tích chùm mờ. Khi kết quả phân tích chùm nằm ở mức độ không chắc chắn cao, chỉ số có thể đánh giá là nhầm lẫn.

Trong thực tế, ta nên sử dụng một cách có ý nghĩa song song cả hai loại chỉ số bên trong và bên ngoài. Luận văn sử dụng thống nhất *ARI* và *NMI* đối với đánh giá bên ngoài và *Silhouette* và *Dunn* đối với đánh giá bên trong. Ngoài ra, chúng còn được đánh giá qua số lần lặp lại trong phân tích cụm phân vùng và thời gian chạy kể từ khi khởi đầu thuật toán.

2.2.5 Ví dụ minh họa


Để khảo sát hành vi của thuật toán đề nghị IFCF trong các bài toán phân tích cụm, trước tiên, luận văn này tạo dữ liệu tổng hợp qua Ví dụ 2.1.

a. Dữ liệu mô phỏng

Ví dụ 2.1 (Phân tích hai cụm hàm Gauss mất cân bằng). Giả sử dữ liệu được tạo theo công thức tổng quát về kỳ vọng và độ lệch chuẩn của mỗi cụm, cụ thể như sau:

Chùm 1 : $f(x|\mu; \sigma^2) \sim \mathcal{N}(\mu_1; \sigma_1^2)$; với $\mu_1 \sim \mathcal{N}(-5, 0; 1, 0)$; $\sigma_1 = 2, 0$,

Chùm 2 : $f(x|\mu; \sigma^2) \sim \mathcal{N}(\mu_2; \sigma_2^2)$; với $\mu_2 \sim \mathcal{N}(5, 0; 1, 0)$; $\sigma_2 = 4, 0$.



Hình 2.7: Dữ liệu Gauss mô phỏng tại Ví dụ 2.1

Luận văn mô phỏng dữ liệu PDF Gauss trên tập số thực với hai cụm được giả định trước. Vai trò của dữ liệu nhân tạo là đánh giá độ ổn định của thuật toán IFCF trong các kịch bản mất cân bằng nghiêm trọng khi *IR* thay đổi từ 10 đến 50. Tỷ lệ *IR* càng lớn thì sự chênh lệch giữa cụm 1 và 2 càng cao. Hình 2.7 thể hiện rõ tác động của *IR* lên phân bố dữ liệu. Khi *IR* tăng từ 10, 30 và 50, cụm lớn hơn trở nên dày đặc hơn, trong khi cụm nhỏ chứa chỉ 10 PDF thì giữ nguyên kích thước.


Để bảo đảm tính công bằng, trong ví dụ này luận văn khảo sát các thuật toán với số cụm cố định $c = 2$, tham số mờ $m = 2, 0$, sai số hội tụ $\epsilon = 10^{-12}$, số vòng lặp tối đa $T_{\max} = 200$ và phương pháp khởi tạo được cố định là *k-means++*. Luận văn này đánh giá tác động lặp lại ngẫu nhiên thuật toán IFCF với 30 lần thử nghiệm ngẫu nhiên.

b. Kết quả các loại khoảng cách

Các thuật toán phân cụm được triển khai với nhiều loại khoảng cách khác nhau, bao gồm $\mathcal{L}_2$, D_H^2 , D_{BC} , D_{JS} và W_2^2 , như được trình bày trong Bảng 1.2. Kết quả chi tiết được trình bày trong Hình 2.8 thể hiện giá trị trung vị của các chỉ số đánh giá phân cụm qua kiểm định Friedman.

Rõ ràng, khi IR tăng từ $10 \div 50$, hầu hết các chỉ số đánh giá như ARI , NMI , $Dunn$ và $Silhouette$ đều giảm đáng kể. Ở mức $IR = 10$, các phương pháp đạt giá trị rất cao, với $ARI = 0,93$ và $NMI = 0,86$, phản ánh khả năng tách cụm tốt và ổn định. Tuy nhiên, khi $IR \geq 30$, các chỉ số này nhanh chóng suy giảm gần về 0,00, cho thấy mô hình bắt đầu suy yếu. Đồng thời, thời gian tính toán và số vòng lặp hội tụ tăng lên rõ rệt theo IR , thể hiện rằng bài toán trở nên phức tạp hơn khi mức mất cân bằng dữ liệu tăng cao. Ngoài ra, các khoảng cách $\mathcal{L}_2$, D_{BC} , D_H^2 và D_{JS} cho kết quả gần tương đương nhau ở các mức IR thấp. Tuy nhiên, khi IR tăng, D_H^2 và D_{JS} cho thấy tính ổn định cao hơn, duy trì giá trị ARI và NMI cao hơn so với $\mathcal{L}_2$ và đặc biệt là W_2^2 . Ngược lại, khoảng cách W_2^2 thể hiện hiệu năng yếu hơn cả về chỉ số nội bộ lẫn chỉ số bên ngoài, đồng thời đòi hỏi chi phí tính toán cao hơn đáng kể.

Phân tích thống kê bằng phép kiểm định Friedman với mức ý nghĩa $\alpha = 0.05$, ta có kết quả $\chi^2 = 14 \div 15$, $p < 0,02$. Điều này cho thấy sự khác biệt giữa các loại khoảng cách là có ý nghĩa thống kê, khẳng định rằng lựa chọn độ đo thích hợp có ảnh hưởng trực tiếp đến chất lượng phân tích cụm.



Hình 2.8: Đánh giá thống kê các chỉ số cho Ví dụ 2.1

Chú thích: (a) ARI , (b) NMI , (c) $Silhouette$ và (d) thời gian tính toán. Giá trị p được ước tính từ kiểm định phi tham số Friedman cho giả thiết thống kê là các loại khoảng cách này có phương sai như nhau. Nguồn: Minh họa của tác giả.

Ở các chỉ số ARI (Hình 2.8(a)) và NMI (Hình 2.8(b)), các khoảng cách D_{JS} , D_{BC} và $\mathcal{L}_2$ có thứ hạng cao trong kiểm định hậu nghiệm Nemenyi (tham khảo thêm Phụ lục B, tr. 86), thể hiện tính chính xác ổn định. Ngược lại, W_2^2 liên tục đạt thứ hạng thấp nhất. Với chỉ số $Silhouette$, khoảng cách D_{JS} tiếp tục thể hiện hiệu năng vượt trội (Hình 2.8(c)),


trong khi D_H^2 và D_{BC} đạt cân bằng giữa độ chính xác và độ bền vững. Về chi phí tính toán, D_{JS} và W_2^2 là hai phương pháp tốn kém nhất do liên quan đến các phép lô-ga-rít hoặc tích phân trên hàm phân phối tích lũy, trong khi D_{BC} và $\mathcal{L}_2$ có tốc độ xử lý nhanh hơn đáng kể. Nếu cần cân bằng giữa độ chính xác và thời gian, hai khoảng cách D_H^2 và D_{BC} là lựa chọn hợp lý.

Kết quả phân tích thống kê thứ hạng các độ đo khoảng cách cho thấy sự khác biệt rõ rệt về hiệu năng chùm (p -value < 0,02). Cụ thể, ở các chỉ số ARI (Hình 2.8(a)) và NMI (Hình 2.8(b)), các khoảng cách D_{JS} , D_{BC} và $\mathcal{L}_2$ đều đạt thứ hạng cao trong kiểm định hậu nghiệm Nemenyi (tham khảo thêm Phụ lục B, tr. 86), chứng minh tính ổn định và độ chính xác cao. Trong khi đó, khoảng cách W_2^2 xếp hạng thấp nhất, cho thấy độ nhạy cao nhưng thiếu ổn định trong môi trường mất cân bằng mạnh. Tiếp theo, với chỉ số $Silhouette$, khoảng cách D_{JS} tiếp tục thể hiện hiệu năng nổi bật (Hình 2.8(c)), trong khi D_H^2 và D_{BC} duy trì mức cân bằng tốt. Xu hướng này cho thấy rằng các độ đo dựa trên phân kỳ thông tin có ưu thế.

Về mặt chi phí tính toán, các độ đo D_{JS} và W_2^2 là hai phương pháp tốn kém nhất, chủ yếu do yêu cầu các phép tính lô-ga-rít hoặc tích phân trên hàm phân phối tích lũy. Ngược lại, D_{BC} và $\mathcal{L}_2$ có tốc độ xử lý nhanh hơn qua cấu trúc tính toán đơn giản hơn. Tóm lại, trong các tình huống cần cân bằng giữa độ chính xác và thời gian thực thi, hai khoảng cách D_H^2 và D_{BC} được xem là lựa chọn hợp lý nhất.

c. Kết quả các tham số mờ

Hình 2.9 minh họa mối quan hệ giữa tham số m và hai chỉ số đánh giá ARI và $Silhouette$, được phân tích tại các tỷ lệ IR khác nhau. Kết quả cho thấy khi m tăng, hiệu năng của mô hình giảm mạnh theo cả hai chỉ số.



Hình 2.9: Kết quả tham số m qua các chỉ số đánh giá đối với Ví dụ 2.1


Nguồn: Minh họa của tác giả.

Cụ thể, khi m vượt quá 4,0, giá trị ARI giảm nhanh về gần 0,00. Điều này cho thấy tham số mờ quá cao ($m > 3,0$) làm ranh giới giữa các chùm trở nên mờ nhạt. Bên cạnh

đó, chỉ số *Silhouette* cũng thể hiện xu hướng suy giảm tương tự. Hiện tượng này cho thấy rằng việc lựa chọn tham số mờ m đóng vai trò quyết định trong việc duy trì độ chính xác và tính ổn định kết quả. Thông thường, các giá trị m nằm trong khoảng $1,5 \div 3,0$ được xem là tối ưu.

d. Kết quả các loại phân tích chùm

Kết quả so sánh giữa thuật toán đề nghị IFCF và phương pháp FCF truyền thống được trình bày trong Hình 2.10. Dễ nhận thấy rằng trung vị của các chỉ số *ARI*, *NMI* và *Silhouette* trong FCF giảm nhanh khi tỷ lệ *IR* tăng, cho thấy thuật toán truyền thống không còn duy trì được ranh giới chùm ổn định khi dữ liệu bị lệch mạnh về kích thước chùm. Mặc dù FCF có tốc độ tính toán nhanh hơn (Hình 2.10(d)), nhưng độ ổn định giữa các lần lặp không cao ($p < 0,05$, kiểm định Wilcoxon). So sánh với IFCF, kết quả thống kê cho thấy sự khác biệt có ý nghĩa ở tất cả các chỉ số được xem xét (Hình 2.10(a)-(d)), phản ánh ưu thế rõ rệt của thuật toán đề nghị IFCF.



Hình 2.10: Đánh giá thống kê các chỉ số so sánh thuật toán cho Ví dụ 2.1

Chú thích: (a) *ARI*, (b) *NMI*, (c) *Silhouette* và (d) thời gian tính toán. Màu xám đậm là thuật toán đề nghị IFCF và màu xám nhạt là FCF truyền thống. Nguồn: Minh họa của tác giả.

Ngược lại, thuật toán IFCF duy trì độ ổn định ngay cả khi $IR > 30$, với các giá trị trung vị của *ARI* và *NMI* luôn cao hơn đáng kể so với FCF, đồng thời độ biến thiên nhỏ hơn, chứng tỏ khả năng hội tụ ổn định. Kết quả kiểm định Wilcoxon ($p < 0,01$) khẳng định rằng IFCF không chỉ cho kết quả chính xác mà còn có tốc độ tính toán cạnh tranh. Tổng thể, điều này cho thấy IFCF đạt được sự cân bằng hiệu quả giữa độ chính xác, độ bền vững và chi phí tính toán.

► **Chú ý.** Thuật toán IFCF cải tiến hàm mục tiêu giúp trung hòa đóng góp của các chùm lớn hơn, từ đó giảm "hiệu ứng đồng nhất". Tuy nhiên, trong quá trình lặp, giả sử hai trọng tâm Θ được xác định, khi đó với bất kỳ PDF j thuộc chùm c_1 , các mức độ phân vùng được cập nhật theo Công thức (2.2) và điều kiện $\sum_{j=1}^c u_{ij} = 1$, có thể được viết lại

thành

$$\frac{1}{1 + \left(\frac{\omega_2}{\omega_1}\right)^{\frac{1}{m-1}} \left(\frac{\mathcal{L}_2^2(\theta_1; f_j)}{\mathcal{L}_2^2(\theta_2; f_j)}\right)^{\frac{1}{m-1}}} + \frac{1}{\left(\frac{\omega_1}{\omega_2}\right)^{\frac{1}{m-1}} \left(\frac{\mathcal{L}_2^2(\theta_2; f_j)}{\mathcal{L}_2^2(\theta_1; f_j)}\right)^{\frac{1}{m-1}} + 1} = 1.$$

Khi $\omega_1 \rightarrow \infty$, ta có $\lim_{\omega_1 \rightarrow \infty} \mu_{i1} = 1$ và $\lim_{\omega_1 \rightarrow \infty} \mu_{i2} = 0$. Điều này cho thấy khi tỷ lệ IR tăng đến vô cùng, mức độ phân vùng mờ cho chùm lớn sẽ tiến về 1 và chùm nhỏ sẽ tiến về 0. Hiện tượng này được gọi là phân cực trong các mức độ phân vùng. Ta vẫn chưa có cơ chế phát triển nào cho hiện tượng này mặc dù đã có cải tiến.

2.3 Giới thiệu bài toán phân loại cho dữ liệu mất cân bằng

2.3.1 Phương pháp phân loại hàm mật độ xác suất

Phương pháp phân loại là một nhánh của nhận dạng có giám sát, phát triển với mục tiêu thành lập quy tắc quy nạp có chức năng phân tách được các lớp quan tâm với sai lầm thực nghiệm tối thiểu. Ta giả sử tồn tại một không gian đầu vào $\mathcal{F}$ và tập nhãn rời rạc $Y = \{1, 2, \dots, C\}$. Cặp dữ liệu $(f; y)$ là biến ngẫu nhiên có PDF chung $P_{\mathcal{F}; Y}$ trên $\mathcal{F} \times Y$. Mục tiêu của bài toán là tìm một ánh xạ phân loại $h: \mathcal{F} \rightarrow Y$ thuộc không gian giả thuyết $\mathcal{H}$ sao cho tối thiểu hóa giá trị kỳ vọng của hàm mất mát $\ell: Y \times Y \rightarrow \mathbb{R}_{\geq 0}$, tức là $h^* = \arg \min_{h \in \mathcal{H}} \mathbb{E}(f; y) \sim P_{\mathcal{F}; Y} [\ell(h(f), y)]$. Tuy nhiên, do PDF thực $P_{\mathcal{F}; Y}$ là chưa biết, ta cần tiếp cận qua một tập huấn luyện $\mathcal{D}_n = \{(f_1; y_1); (f_2; y_2); \dots; (f_n; y_n)\} \subset \mathcal{F} \times Y$. Vì vậy, ta giải bài toán $\hat{h}_n = \arg \min_{h \in \mathcal{H}} \frac{1}{n} \sum_{j=1}^n \ell(h(f_j), y_j)$.

Trong thực tế, các quy luật đánh giá có bệnh B hay không dựa vào những dữ liệu cho trước chính là thực hiện bài toán phân loại. Hay phân biệt được hữu hạn các biểu cảm khuôn mặt dựa vào hình ảnh cũng phải thực hiện bài toán phân loại. Đầu ra của mô hình phân loại là ước tính hoặc dự đoán hữu hạn các nhãn cho trước (không đo được) với dữ liệu mới chưa được mô hình hóa [18].

Phương pháp phân loại cho PDF là một bài toán mới mẻ nên còn nhiều thách thức lớn cả bề sâu và bề rộng. Nhìn chung, hai phương pháp chính để phân loại là từ hai góc nhìn bao gồm ánh xạ PDF thành vector hữu hạn chiều thông qua các đặc trưng thống kê, hay xử lý trực tiếp trong không gian hàm. Cả hai hướng này đều có ưu và nhược điểm riêng, trong đó cách tiếp cận theo không gian hàm cho phép bảo toàn thông tin xác suất tốt hơn nhưng đòi hỏi chi phí tính toán lớn hơn. Bảng 2.4 mô tả quá trình phát triển của lĩnh vực này.

Bảng 2.4: Tổng quan phương pháp phân loại cho dữ liệu PDF trong giai đoạn 2019-2024

Năm	Tác giả	Mô tả phương pháp
2023	Tai Vo-Van, Hieu Nguyen Thi Kim & Dinh Pham-Toan [60]	Phát triển phương pháp phân loại Bayes cải tiến cho bài toán đa lớp
2023	Pavlů <i>et al.</i> [51]	Nhúng hàm mật độ vào không gian Bayes, triển khai logistic PDF
2024	Thu-Anh Nguyen-Tran, An Thien Ngoc Nguyen & Dinh Pham-Toan[68]	Phát triển phương pháp phân loại Bayes cải tiến tích hợp vào học sâu
2025	Tai Vo-Van & Dinh Pham-Toan [74]	Học đa lớp cho dữ liệu PDF bằng phương pháp Bayes cải tiến
2025	Tai Vo-Van [72]	Cải thiện độ chính xác trong phân loại dữ liệu hình ảnh đa kênh màu bằng Bayes cải tiến
2025	Tai Vo-Van [73]	Phát triển phương pháp phân loại Bayes cải tiến bằng khoảng cách tương tự chùm

Nguồn: Tác giả tổng hợp.

Trong bối cảnh này, các nghiên cứu trong nước đã có nhiều đóng góp nổi bật. Chuỗi công trình gần đây tập trung cải tiến mô hình Bayes truyền thống để thích ứng với dữ liệu dạng PDF, mở rộng từ bài toán hai lớp sang đa lớp và từ dữ liệu đơn kênh sang hình ảnh đa kênh màu. Các thuật toán Bayes cải tiến chứng minh được tính ổn định và khả năng tổng quát hóa tốt. Đặc biệt, giai đoạn 2023–2025 đánh dấu bước trưởng thành quan trọng của hướng nghiên cứu này.

Khi tồn tại *IR* trong dữ liệu, các thuật toán phân loại truyền thống có xu hướng nghiêng về phía lớp chiếm đa số, bởi vì việc giảm sai số tổng thể thường đạt được bằng cách hy sinh khả năng nhận diện lớp hiếm. Hệ quả là, trong các bài toán có tính rủi ro cao như phát hiện gian lận, chẩn đoán y khoa hay cảnh báo thiên tai, việc bỏ sót một vài trường hợp hiếm có thể dẫn đến hậu quả nghiêm trọng hơn nhiều so với việc dự đoán nhầm một trường hợp phổ biến. Do đó, vấn đề mất cân bằng trong phân loại không chỉ là một khía cạnh kỹ thuật, mà còn là yếu tố quyết định độ tin cậy của mô hình trong các ứng dụng thực tế.

Theo thời gian, các hướng tiếp cận chính đã được hình thành bao gồm kỹ thuật cân bằng dữ liệu hay cải tiến thuật toán. Nhóm phương pháp tiền xử lý dữ liệu tập trung tái cân bằng tập huấn luyện thông qua kỹ thuật sinh mẫu giảm đa số, sinh mẫu tăng lớp thiểu số, hoặc sinh mẫu tổng hợp SMOTE. Ngoài ra, việc cải tiến thuật toán phân biệt có thể được xây dựng qua việc tinh chỉnh trực tiếp hàm mất mát hoặc cơ chế học, hoặc học đa mô hình để đạt hiệu năng ổn định hơn. Tuy nhiên, trong các bài toán phức tạp như phân loại PDF, hiện tượng mất cân bằng không chỉ xuất hiện ở mức số lượng mẫu mà còn ở cấp độ phân bố xác suất. Điều này khiến việc đo khoảng cách và xác định ranh giới quyết định trở nên khó khăn hơn đáng kể. Vì vậy, nghiên cứu các phương pháp phân loại hiệu

quả trong điều kiện mất cân bằng không chỉ là sự mở rộng tự nhiên của các kỹ thuật cổ điển, mà đã trở thành một hướng nghiên cứu độc lập, đòi hỏi cơ sở lý thuyết và phương pháp luận mới.

2.3.2 Thuật toán

Trong các phương pháp thống kê, Bayesian truyền thống là một phương pháp phân loại điển hình dựa trên biến rời rạc và các phiên bản cải tiến của nó đã được đề xuất cho biến liên tục [73, 74]. Khi đối tượng cần phân loại là một PDF, việc tính toán trở nên cực kỳ phức tạp. Do đó, cải tiến của Pham-Gia et al., (2008) được đưa ra để làm việc với PDF liên tục, nhưng việc xác định tiên nghiệm và ước lượng PDF vẫn là điểm yếu chính. Luận văn này thiết lập mô hình phân lớp Bayes-IFCF gồm hai giai đoạn bao gồm xác định xác suất tiên nghiệm, sau đó thiết lập nguyên tắc phân loại dựa vào Bayes. Việc kết hợp cả hai thuật toán phân tích chùm mờ IFCF và Bayes có thể giải quyết được bài toán phân loại mất cân bằng.

Cho dữ liệu huấn luyện gồm N -PDF có các đối tượng f_j và dữ liệu kiểm tra gồm n -PDF mới cần phân loại. Giả sử c lớp c_i , trong đó lớp c_i chứa n_j đối tượng PDF. Xác suất tiên nghiệm q_{ij} (hay u_i) được xác định thông qua mối quan hệ mờ giữa đối tượng PDF cần phân loại $h(x)$ và các lớp trong tập huấn luyện, sử dụng kỹ thuật phân tích chùm mờ IFCF (Thuật toán 1). Tiên nghiệm IFCF là phương pháp tiên nghiệm động giống với Bayes-FCM [60, 72] nhưng dành cho dữ liệu được xác định là có mất cân bằng cao hơn.

Phân loại một PDF mới $h(x)$ vào lớp c_i bằng quy tắc Bayes nếu nó có xác suất hậu nghiệm đối với lớp đó là cao nhất, tức là

$$c_i = \arg \max_i \left\{ \frac{U_{ij}^{(test)} \exp \left(-D_{ij}^{(test)} / \tau \right)}{\sum_s U_{sj}^{(test)} \exp \left(-D_{sj}^{(test)} / \tau \right)} \right\},$$

trong đó khoảng cách D được chuẩn hóa với $\tau = \frac{1}{n_{test}} \sum_i D_{ij}$. Nguyên tắc này chỉ định rằng một PDF được gán vào một lớp cụ thể nếu nó đồng thời sở hữu giá trị cao nhất đối với xác suất tiên nghiệm và độ đo tương đồng đối với lớp đó. Mã giả của thuật toán đề nghị được trình bày trong Thuật toán 2.

2.3.3 Tham số đánh giá chất lượng

Đối với thuật toán phân loại, ta đánh giá kết quả dự đoán thông qua độ chính xác của mô hình trên tập dữ liệu chưa được huấn luyện. Kết quả phân loại thường được tóm tắt trong ma trận nhầm lẫn, thể hiện số lượng dự đoán đúng và sai của mô hình. Giả sử ta có một bài toán phân loại nhị phân với hai lớp { Dương tính; Âm tính }. Ma trận nhầm lẫn có dạng

Algorithm 2: Giải thuật phân loại Bayes-IFCF

- 1: **procedure** BAYES-IFCF($\mathcal{D}_{\text{train}}; \mathcal{D}_{\text{test}}; c; \varepsilon; m; \mathcal{L}_2$)
- 2: $t \leftarrow 0$
- 3: Khởi tạo ngẫu nhiên ma trận phân vùng $\mu^{(0)}$ và tập PDF trọng tâm $\Theta^{(0)} = \{\theta_i^{(0)}\}_{i=1}^c$
- 4: **while** $\|\mu^{(t+1)} - \mu^{(t)}\| > \varepsilon$ **do** ▷ Giai đoạn 1
- 5: $t \leftarrow t + 1$
- 6: Cập nhật trọng tâm

$$\theta_i^{(t)}(x) = \frac{\sum_{j=1}^{n_{\text{train}}} \left(\mu_{ij}^{(t-1)}\right)^m f_j^{(\text{train})}(x)}{\sum_{j=1}^{n_{\text{train}}} \left(\mu_{ij}^{(t-1)}\right)^m}, 1 \leq i \leq c.$$

- 7: Tính khoảng cách $D_{ij} = \mathcal{L}_2(\theta_i^{(t)}(x), f_j^{(\text{train})}(x))$
- 8: Cập nhật mức độ phân vùng

$$\mu_{ij}^{(t)} = \frac{1}{\sum_{s=1}^c \left(\frac{\omega_i^{(t-1)}}{D_{ij}^2 / D_{sj}^2} \right)^{\frac{1}{m-1}}}.$$

- 9: Cập nhật trọng số kích thước lớp

$$\omega_i^{(t)} = \frac{1}{n_{\text{train}}} \sum_{j=1}^{n_{\text{train}}} \mu_{ij}^{(t)}.$$

- 10: **end while**
- 11: Lưu $\Theta^* \leftarrow \{\theta_i^{(t)}\}, \mu^* = \{\mu_{ij}^{(t)}\}$.

- 12: **for** $j = 1$ **to** n **do** ▷ Giai đoạn 2
- 13: Tính khoảng cách $D_{ij}^{(\text{test})} = \mathcal{L}_2(\theta_i^*(x), f_j^{(\text{test})}(x))$
- 14: Gán nhãn phân loại Bayes cho $f_j^{(\text{test})}$

$$c_j^* = \arg \max_i \left\{ \frac{\mu_{ij} \exp(-D_{ij}^{(\text{test})} / \tau)}{\sum_s \mu_{sj} \exp(-D_{sj}^{(\text{test})} / \tau)} \right\}.$$

- 15: **end for**
 - 16: **return** c_j^* với $j = 1, 2, \dots, n_{\text{test}}$ ▷ Nhãn của các PDF kiểm tra
 - 17: **end procedure**
-

	Dự đoán dương tính	Dự đoán âm tính
Thực tế dương tính	Dương tính thật ($\#TP$)	Âm tính giả ($\#FN$)
Thực tế âm tính	Dương tính giả ($\#FP$)	Âm tính thật ($\#TN$)

Ví dụ khi ta phân loại các ca có bệnh B hoặc không có bệnh B, $\#TP$ thể hiện số lượng dự đoán đúng kết luận có bệnh B; $\#FP$ là số dự đoán đúng không bệnh. Ngược lại $\#FN$ là số dự đoán kết luận không bệnh, nhưng thực tế là có; và $\#FP$ là số dự đoán kết luận có bệnh B, nhưng thực tế là không. Từ ma trận nhầm lẫn, ta định nghĩa các chỉ số phổ biến khác. Các chỉ số trong Bảng 2.5 cung cấp cơ sở định lượng cho việc đánh giá hiệu năng mô hình,

Bảng 2.5: Mô tả các chỉ số đánh giá phân loại

Chỉ số	Công thức	Ý nghĩa	Phạm vi
Độ chính xác (ACC)	$\frac{\#TP + \#TN}{\#TP + \#TN + \#FP + \#FN}$	Tỷ lệ dự đoán đúng trên tổng số mẫu	[0; 1]
Độ nhạy (PRE)	$\frac{\#TP}{\#TP + \#FP}$	Tỷ lệ mẫu được dự đoán dương tính thật	[0; 1]
Độ chuyên, TPR (REC)	$\frac{\#TP}{\#TP + \#FN}$	Tỷ lệ nhận diện đúng dương tính	[0; 1]
F1-score	$\frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$	Trung bình điều hoà giữa Precision và Recall	[0; 1]
FPR	$\frac{\#FP}{\#FP + \#TN}$	Tỷ lệ dự đoán sai âm tính thành dương tính	[0; 1]
AUC-ROC	$\int_0^1 \text{TPR}(\text{FPR}) d\text{FPR}$	Diện tích dưới đường cong ROC	[0; 1]
AUC-PR	$\int_0^1 \text{Precision}(\text{Recall}) d\text{Recall}$	Diện tích dưới đường cong Precision-Recall	[0; 1]

Chú thích: Trong đó, các chỉ số cơ bản Precision = $\frac{\#TP}{\#TP + \#FP}$ và Recall = $\frac{\#TP}{\#TP + \#FN}$. Nguồn: Tác giả tổng hợp.

Nhận xét. Độ chính xác (Accuracy) tuy trực quan và dễ diễn giải nhưng chỉ đưa ra tỷ lệ tổng quát các dự đoán đúng, bỏ qua cấu trúc mất cân bằng giữa các lớp và không phản ánh mức độ rủi ro gắn với từng lỗi. Trong các bài toán mà sai lầm ở một lớp có hậu quả lớn, F_1 -score và AUC-ROC được ưu tiên vì chúng thể hiện sự cân bằng giữa Precision và Recall, cũng như khả năng phân biệt mô hình qua toàn bộ miền ngưỡng. Đặc biệt với dữ liệu mất cân bằng, hai chỉ số AUC-PR và F_1 -score thường cho hiệu quả tốt hơn Accuracy hoặc AUC-ROC [22].

► **Chú ý.** Các chỉ số đánh giá định lượng hình thức, nhưng không phải chất lượng và tính tin cậy. Ma trận nhầm lẫn cung cấp thông tin về số lượng dự đoán đúng/sai tại một ngưỡng, nhưng không đánh giá tính hợp lý của bằng chứng nó nhận biết. Ian van der Linde (2025) nhấn mạnh “một mô hình có thể dự đoán đúng và có bằng chứng nhưng dựa trên đặc trưng hoặc bằng chứng không liên quan sẽ dẫn đến kết quả dù đúng nhưng

không thể coi là quy luật tổng quát” [69].

Do vậy, để đánh giá mô hình một cách đầy đủ và tin cậy, cần kết hợp nhiều thước đo. Quan trọng hơn, việc tối ưu hiệu năng đi kèm với chú trọng giải thích lý do dự đoán [17, 28], thông qua giải thích-AI (XAI), tương tác người dùng và tiêu chuẩn đánh giá phù hợp, sẽ nâng cao độ tin cậy và giá trị ứng dụng thực tiễn của mô hình.


2.3.4 Ví dụ minh họa

a. Dữ liệu mô phỏng

Ví dụ 2.2 (Hàm Gauss-lệch, ba lớp). Giả sử dữ liệu PDF Gauss-lệch được lấy từ nguồn <http://azzalini.stat.unipd.it/SN/>. Một PDF Gauss-lệch được định nghĩa như sau:

$$f(x|\xi;\sigma;\lambda) = \frac{2}{\lambda} \phi\left(\frac{x-\xi}{\sigma}\right) \Phi\left(\lambda \frac{x-\xi}{\sigma}\right),$$

trong khung nghiên cứu này, tham số vị trí ξ_i được lấy mẫu ngẫu nhiên từ các PDF Gauss gồm $\mathcal{N}(0;0.2)$, $\mathcal{N}(2;0.2)$ và $\mathcal{N}(-2;0.2)$ tương ứng cho chùm, 1, 2 và 3. Các tham số độ lệch-Gauss được đặt là $\sigma_i = [0; 10; -10]$, trong khi các tham số lệch được xác định là $\lambda_i = [1; 2; 2]$, nhằm tạo ra sự bất đối xứng giữa các lớp. Các PDF của ba lớp này được minh họa trong Hình 2.11(a), với tỷ lệ $IR = 1 : 20 : 20$ tương ứng cho ba lớp, với lớp nhỏ nhất (lớp 1) có 10 PDF.



Hình 2.11: Minh họa dữ liệu Ví dụ 2.2

Chú thích: (a) Toàn bộ dữ liệu PDF, và (b) Các PDF kiểm tra được lấy ngẫu nhiên trong dữ liệu. Nguồn: Minh họa của tác giả.

b. Các bước thực hiện

Luận văn thực hiện các bước trong Thuật toán 2 một cách tuần tự. Thuật toán gồm hai phần bao gồm tìm xác suất tiên nghiệm và phân lớp Bayes. Thuật toán tìm xác suất tiên nghiệm là IFCF (Thuật toán 1) với khoảng cách tiêu chuẩn $\mathcal{L}_2^2$ và các tham số liên

quan bao gồm $m = 2,0$, $c = 3$ và khởi tạo bằng k -means++. Sau đó, phân lớp Bayes xác định các lớp mà tập kiểm tra thuộc về.

Bước 1. Tiền xử lý. Trong bước này, luận văn chia dữ liệu thành hai tập hợp các PDF huấn luyện và kiểm tra. Tập huấn luyện có chức năng đào tạo các PDF để xác định tiên nghiệm cho tập kiểm tra. Tập kiểm tra được chia ngẫu nhiên như sau: Chọn cố định số lượng phần tử trong tập kiểm tra là $n_1 = 2; n_2 = 10; n_3 = 8$. Mỗi PDF kiểm tra $f_j^{(test)}$ với $j = 1; 2; \dots; 20$ được gán vào tập kiểm tra là tổ hợp $C_n^{n_i}$ với $i = 1; 2; 3$ để mỗi lớp đều có PDF kiểm tra. Tập huấn luyện là phần còn lại sau khi đã chọn ngẫu nhiên kiểm tra. Hình 2.11 thể hiện các PDF kiểm tra chọn ngẫu nhiên từ dữ liệu. Ta có số lượng tập huấn luyện và kiểm tra như sau:


Bảng 2.6: Phân bố số lượng và tỷ lệ PDF trong tập huấn luyện và kiểm tra đối với Ví dụ 2.2.

Tập dữ liệu	Lớp 1	Lớp 2	Lớp 3	Tổng cộng
Huấn luyện	8 (2,1%)	190 (48,7%)	192 (49,2%)	390
Kiểm tra	2 (10,0%)	10 (50,0%)	8 (40,0%)	20
Tổng cộng	10 (2,5%)	200 (50,0%)	200 (47,5%)	410

Nguồn: Tác giả tính toán.

Bước 2. Xác định tiên nghiệm. Bước này đánh giá tiên nghiệm dựa vào phân tích chùm PDF IFCF trên tập huấn luyện.

Bước 2.1. Khởi tạo tập hợp ba PDF trọng tâm $\Theta^{(t=0)}$ bằng k -means++. Ta có Hình 2.12(a) thể hiện ba PDF trọng tâm khởi tạo cho ba lớp lần lượt là $\Theta = \{f_{98}; f_6; f_{226}\}$. Khi không có thông tin gì về kích thước lớp, ta khởi tạo $\omega_i = 1/c = 1/3$ cho cả ba lớp. Tại bước lặp thứ nhất $t = 1$, ta cập nhật các giá trị của U và Θ .



Hình 2.12: Quá trình biến đổi của các trọng tâm đối với Ví dụ 2.2

Chú thích: (a) Khởi tạo từ k -means++, (b) Vòng lặp thứ nhất $t = 1$, (c) Vòng lặp thứ hai $t = 2$, (d) Vòng lặp cuối cùng. Nguồn: Minh họa của tác giả.

Bước 2.2. Ta tiến hành tính khoảng cách $\mathcal{L}_2(\theta_i; f_j)$ giữa các PDF trọng tâm khởi

tạo với tất cả các PDF còn lại. Ở đây, luận văn trình bày cụ thể cột đầu tiên như sau:

$$D_{11} = \mathcal{L}_2^2(f_{98}; f_1) = 0,49, D_{21} = \mathcal{L}_2^2(f_6; f_1) = 0,037, D_{31} = \mathcal{L}_2^2(f_{226}; f_1) = 0,52.$$

Tổng hợp lại, ta có ma trận khoảng cách $D = D^2(\theta_i; f_j) = \mathcal{L}_2^2$.

$$D^{(t=1)} = \begin{bmatrix} 0,49 & 0,49 & 0,50 & \cdots & 0,53 & 0,53 \\ 0,04 & 0,04 & 0,01 & \cdots & 0,51 & 0,49 \\ 0,52 & 0,52 & 0,52 & \cdots & 0,00 & 0,04 \end{bmatrix}_{3 \times 390}.$$

Bước 2.3. Cập nhật ma trận $U^{(t=1)}$ theo Công thức (2.2) theo ma trận khoảng cách D vừa tính và cả ba $\omega_i = 1/3$ với $i = 1 \div 3$. Ở đây, luận văn trình bày cụ thể cột đầu tiên như sau:

$$\begin{bmatrix} \mu_{11} \\ \mu_{12} \\ \mu_{13} \end{bmatrix} = \begin{bmatrix} \frac{1}{1 + \left(\frac{f_{c2}}{f_{c1}} \frac{D_{11}}{D_{21}}\right)^{\frac{1}{m-1}} + \left(\frac{f_{c3}}{f_{c1}} \frac{D_{11}}{D_{31}}\right)^{\frac{1}{m-1}}} \\ \frac{1}{\left(\frac{f_{c2}}{f_{c1}} \frac{D_{12}}{D_{22}}\right)^{\frac{1}{m-1}} + 1 + \left(\frac{f_{c3}}{f_{c1}} \frac{D_{12}}{D_{32}}\right)^{\frac{1}{m-1}}} \\ \frac{1}{\left(\frac{f_{c2}}{f_{c1}} \frac{D_{13}}{D_{23}}\right)^{\frac{1}{m-1}} + \left(\frac{f_{c3}}{f_{c1}} \frac{D_{13}}{D_{33}}\right)^{\frac{1}{m-1}} + 1} \end{bmatrix} = \begin{bmatrix} 0,07 \\ 0,87 \\ 0,06 \end{bmatrix}.$$

Tổng hợp các tính toán trên, ta có ma trận phân vùng tại vòng lặp $t = 1$ như sau:

$$U^{(t=1)} = \begin{bmatrix} 0,07 & 0,06 & 0,02 & \cdots & 0,01 & 0,07 \\ 0,87 & 0,88 & 0,95 & \cdots & 0,01 & 0,07 \\ 0,06 & 0,06 & 0,02 & \cdots & 0,99 & 0,86 \end{bmatrix}_{3 \times 390}.$$

Bước 2.4. Cập nhật trọng tâm chòm bằng Công thức 2.7. Hình 2.12(b) cho ta cụ thể trọng tâm sau khi cập nhật ở bước $t = 1$.

Bước 2.5. Cập nhật lại kích thước chòm $\omega_i^{(t=1)}$, $i = 1 \div 3$ bằng Công thức trung bình U . Ta có, $\omega_1 = 0,49$; $\omega_2 = 0,05$; $\omega_3 = 0,46$.

Ta tính tiêu chí dừng giữa $U^{(t=1)}$ và $U^{(t=0)}$ được tính bởi công thức

$$\|U^{(t=1)} - U^{(t=0)}\| = 1,3 < \varepsilon.$$

Ta quyết định tiếp tục vòng lặp thứ 2, $t = 2$. Tương tự ta cũng cập nhật được ma trận

khoảng cách D , ma trận phân vùng U , kích thước chùm ω_i và trọng tâm Θ_i . Ta có,

$$D^{(t=2)} = \begin{bmatrix} 0,47 & 0,47 & 0,49 & \cdots & 0,52 & 0,52 \\ 0,02 & 0,02 & 0,01 & \cdots & 0,41 & 0,39 \\ 0,51 & 0,51 & 0,50 & \cdots & 0,01 & 0,01 \end{bmatrix}, U^{(t=2)} = \begin{bmatrix} 0,24 & 0,24 & 0,14 & \cdots & 0,01 & 0,02 \\ 0,55 & 0,56 & 0,74 & \cdots & 0,00 & 0,00 \\ 0,21 & 0,21 & 0,13 & \cdots & 0,99 & 0,98 \end{bmatrix}.$$

Sau 21 vòng lặp ta dừng thuật toán do thỏa mãn điều kiện dừng. Kết quả nhận được là trọng tâm $\Theta^{(t=21)}$ và ma trận phân vùng $U^{(t=21)}$ cuối cùng.

Bước 3. Phân lớp Bayes. Một phần tử mới được xếp lớp bất kỳ nếu hậu nghiệm của nó là lớn nhất. Vì vậy, ta tính hậu nghiệm từ kết quả ở **Bước 2.** cho tập kiểm tra. Ở mỗi PDF trọng tâm θ_i ở bước 2, ta tính khoảng cách giữa nó đến từng phần tử của $f_j^{(test)}$, $j = 1 \div 20$. Ta có,

$$D^{(test)} = \begin{bmatrix} 0,50 & 0,49 & 0,00 & \cdots & 0,49 & 0,00 \\ 0,00 & 0,01 & 0,50 & \cdots & 0,01 & 0,50 \\ 0,49 & 0,49 & 0,52 & \cdots & 0,49 & 0,52 \end{bmatrix}_{3 \times 20}$$

và

$$U^{(test)} = \begin{bmatrix} 0,13 & 0,24 & 0,10 & \cdots & 0,24 & 0,10 \\ 0,75 & 0,52 & 0,00 & \cdots & 0,52 & 0,00 \\ 0,13 & 0,24 & 0,00 & \cdots & 0,24 & 0,00 \end{bmatrix}_{3 \times 20}.$$

Vì vậy, ta có thể tính được xác suất hậu nghiệm của các PDF kiểm tra với $\tau = \text{mean}(D_{ij})$ là

$$\mathbb{P}(c = c_i; f = f_j^{(test)}) = \frac{\mu_{ij} \exp(-D_{ij}/\tau)}{\sum_s \mu_{sj} \exp(-D_{sj}/\tau)} = \begin{bmatrix} 0,06 & 0,13 & 0,10 & \cdots & 0,13 & 0,10 \\ 0,89 & 0,74 & 0,00 & \cdots & 0,74 & 0,00 \\ 0,06 & 0,13 & 0,00 & \cdots & 0,13 & 0,00 \end{bmatrix}_{3 \times 20}.$$

Từ đây ta biết được các PDF được xếp vào lớp c_i là $\hat{y}_j = \{2; 2; \underbrace{1; 1; \dots; 1}_{10 \text{ lần}}; \underbrace{3; \dots; 3}_{8 \text{ lần}}\}$.


Tuy nhiên, mỗi lớp trên dựa vào sự ngẫu nhiên của khởi tạo nên chưa phải là lớp thật sự. Do đó, ta biến đổi qua ánh xạ hoán vị tối ưu giữa nhãn lớp dự đoán và nhãn thực tế, tức là

$$\pi = \arg \max_{\pi \in S_c} \frac{1}{n_{test}} \sum_{j=1}^{n_{test}} \mathbf{1}_{\{\pi(\hat{y}_j)=y_j\}},$$

trong đó S_c là hoán vị của c . Từ đây ta tính được các chỉ số đánh giá phân lớp bao gồm $ACC = 1,0$, $AUC-ROC = 1,0$.

c. Kết quả số

Luận văn lặp lại thuật toán phân loại Bayes-IFCF cho 30 lần ngẫu nhiên ở bước chọn dữ liệu PDF kiểm tra. Các chỉ số đánh giá được ghi nhận bao gồm $AUC-ROC$, F_1 -score và đánh giá thuật toán đề nghị Bayes-IFCF so với những thuật toán đã có bao gồm Bayes-U (phân bố đều giữa ba lớp), Bayes-L (phương pháp Laplace- $\alpha = 1$), Bayes-J (phương pháp Jeffreys- $\alpha = \frac{1}{2}$), Bayes-FCM (phân tích chùm mờ).



Hình 2.13: Kết quả ANOVA cho các chỉ số phân loại đối với Ví dụ 2.2

Chú thích: (a) Độ chính xác ACC, (b) Độ chính xác cân bằng GM và (c) Chỉ số F_1 -score. Nguồn: Minh họa của tác giả.

Kết quả so sánh bằng kiểm định Friedman–Nemenyi (Hình 2.13) cho thấy sự khác biệt rõ rệt giữa các phương pháp phân loại. Trong cả ba chỉ số đánh giá, xác suất phân loại dựa vào tiên nghiệm đều và dựa vào phương pháp phân tích chùm IFCF đạt hạng trung bình thấp nhất ($1,5 \div 1,6$), cho thấy hiệu năng ổn định và vượt trội. Ngược lại, phương pháp Laplace và Jeffreys có hạng trung bình cao hơn đạt 4,1, phản ánh kết quả kém hơn đáng kể theo cả độ chính xác, độ chính xác cân bằng và chỉ số F_1 . Phương pháp FCF nằm ở mức trung bình với hạng trung bình là 3,6, chỉ cải thiện nhẹ so với hai biến thể tiên nghiệm không đều.

► **Chú ý.** Mô hình Bayes-IFCF được thiết lập để giải quyết vấn đề phân loại trong điều kiện mất cân bằng dữ liệu nghiêm trọng. Phương pháp này đạt được sự vượt trội bằng cách sử dụng kết quả từ thuật toán phân chùm IFCF, được chứng minh là hiệu quả hơn hẳn so với các giả định tiên nghiệm tĩnh truyền thống như phân bố đều (Bayes-U), Laplace (Bayes-L), hay Jeffreys (Bayes-J).

Tuy nhiên, cách hình thành mô hình Bayes-IFCF vẫn bộc lộ một hạn chế đáng chú ý. Cụ thể, việc kết hợp trực tiếp mức độ phân vùng với hàm khoảng cách giúp tăng khả năng nhận dạng trong thực nghiệm, song lại khiến diễn giả xác suất hậu nghiệm trở nên không rõ ràng. Khi hệ số thành viên được dùng như xác suất tiên nghiệm và được nhân tiếp với biến đổi của khoảng cách, nó không còn phản ánh niềm tin về lớp một cách thuần túy, mà trở thành một đại lượng mang tính kinh nghiệm. Dẫu vậy, trong các tình huống mất cân bằng nghiêm trọng, cách tiếp cận này vẫn cho thấy hiệu quả thực tiễn.

CHƯƠNG 3

ỨNG DỤNG CHO DỮ LIỆU HÌNH ẢNH

Chương này tập trung vào việc áp dụng các thuật toán đã đề xuất trong Chương 2 để nhận dạng dữ liệu hình ảnh mất cân bằng. Đầu tiên, các đặc trưng của hình ảnh sẽ được trích xuất, sau đó các đặc trưng này sẽ được ước lượng thành PDF đại diện. Thực hiện trên dữ liệu hình ảnh kết cấu Brodatz và dữ liệu hình ảnh Landsat-8 (Đảo Yam) cho thấy thuật toán phân tích chùm mờ đề nghị IFCF đã cho kết quả thuận lợi hơn các thuật toán gần đây. Bên cạnh đó, chương này cũng áp dụng phương pháp Bayes-IFCF đề nghị để phân loại màu sắc của bốn loại đất trong điều kiện tỷ lệ IR cao. Kết quả phân loại cũng cho thấy sự hiệu quả của thuật toán đề nghị so với các thuật toán khác qua các tham số thống kê đánh giá.

3.1 Trích xuất đặc trưng của hình ảnh thành hàm mật độ xác suất

Xử lý hình ảnh là cầu nối giữa toán học rời rạc, xác suất thống kê và trí tuệ nhân tạo, đóng vai trò nền tảng trong các lĩnh vực như thị giác máy tính, chẩn đoán y học hình ảnh và hệ thống tự động nhận dạng. Hình ảnh số được cấu thành từ các điểm ảnh, điểm ảnh lưu trữ thông tin về cường độ sáng hoặc vector màu. Kích thước hình ảnh thường được biểu diễn bởi số hàng và số cột của điểm ảnh, ví dụ $M \times N$ cho hình ảnh hai chiều, hoặc $M \times N \times 3$ cho ảnh màu RGB. Một điểm ảnh tại vị trí (i, j) có thể được biểu diễn bằng giá trị $I(i, j)$ trong miền cường độ $[0; 255]$ (với hình ảnh 8-bit), hoặc được chuẩn hóa về miền $[0; 1]$ trong các xử lý số.

3.1.1 Vấn đề trích xuất đặc trưng của hình ảnh

Trong xử lý hình ảnh, đặc trưng là những thông tin tóm tắt để mô hình SR phân biệt giữa các lớp hoặc đối tượng. Có thể phân chia đặc trưng thành hai loại bao gồm thủ công dùng cho thống kê và học máy được dùng cho máy học/học sâu [45]. Trong thống kê cổ điển, đặc trưng thường được tính toán trực tiếp từ phân bố cường độ hoặc phân bố điểm ảnh, sau đó đưa vào mô hình. Loris Nanni (2017) [45] cho rằng “Việc thiết kế các tính năng thủ công thường liên quan đến việc cân bằng giữa độ chính xác và hiệu quả tính toán”.

Ở đây, hình ảnh là biểu diễn số hóa của thông tin thị giác, được cấu thành từ các điểm ảnh (pixel) theo ma trận hai chiều, trong đó mỗi điểm lưu giá trị cường độ hoặc màu sắc. Trong xử lý ảnh, hình ảnh được xem là một dạng tín hiệu hai chiều có thể phân

tích, biến đổi và trích xuất thông tin. Quá trình trích xuất hình ảnh được ứng dụng rộng rãi trong các lĩnh vực như SR, phân loại hình ảnh, phát hiện vật thể, thị giác máy tính, chẩn đoán hình ảnh y tế, viễn thám và trong các mô hình học sâu nhằm tự động học biểu diễn từ dữ liệu hình ảnh thô.

3.1.2 Ước lượng hàm mật độ xác suất đại diện cho hình ảnh

Ước lượng PDF là bài toán phái sinh khi dữ liệu cần được chuyển thành dữ liệu PDF. Thông thường một đối tượng vector được chuyển đổi thành PDF Gauss đa chiều như [55] với kỳ vọng là trung bình mẫu và độ lệch chuẩn chứa mức độ không chắc chắn thường là $\pm 5\%$.

Khi chuyển dữ liệu hình ảnh sang dạng PDF, ý tưởng chính là xem hình ảnh hoặc một phần của hình ảnh như một biểu diễn phân bố xác suất. Cách tiếp cận này cho phép thay thế tập hợp rời rạc các điểm ảnh bằng một hàm liên tục. Các phương pháp ước lượng phổ biến thường dựa trên hình ảnh toàn cục hoặc trên các khối cục bộ. Trong phần này, hai hướng tiếp cận chính được trình bày và phân tích.

a. Ước lượng dựa trên màu sắc

Xét một hình ảnh $I \in \mathbb{R}^{M \times N \times C}$ với mỗi điểm ảnh được ký hiệu bởi chỉ số đếm $p \in \{1, 2, \dots, MN\}$ và có thể được ánh xạ thành vector đặc trưng $f_I \in \mathbb{R}^d$ trong không gian cường độ xám hoặc trong không gian màu RGB. Để tiến hành ước lượng, trước tiên toàn bộ hình ảnh được duỗi thẳng thành vector một chiều


$$x = \text{vec}(I) = (I_{11}; I_{12}; \dots; I_{1N}; I_{21}; \dots; I_{MN})^T \in \mathbb{R}^{MN}.$$

Quá trình duỗi thẳng giúp chuyển đổi hình ảnh ma trận hai chiều thành dữ liệu vector một chiều. Tập hợp $\{x_p\}_{p=1}^{MN}$ được coi như một mẫu độc lập từ phân bố xác suất cường độ. Trên cơ sở đó, áp dụng phương pháp ước lượng mật độ hạt nhân với hạt nhân Gauss và quy tắc chọn băng thông của Silverman. Công thức cụ thể của PDF ước lượng được viết là

$$\hat{f}(u) = \frac{1}{MNh} \sum_{p=1}^{MN} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(u - x_p)^2}{2h^2}\right),$$

trong đó $h = 0.9\hat{\sigma}(MN)^{-1/5}$ với $\hat{\sigma}$ là độ lệch chuẩn của tập cường độ toàn cục.

Cách tiếp cận này sử dụng trực tiếp toàn bộ điểm ảnh, do đó phản ánh đặc tính màu sắc toàn cục của hình ảnh. Hình 3.1 thể hiện quá trình biến đổi hình ảnh thành PDF với hình ảnh gốc có kích thước 32×32 với phân bố không đồng đều có hai chấm ở hai phía. Một PDF hạt nhân cho thấy phân bố cường độ xám của hình ảnh tập trung trong một khoảng giá trị hẹp phản ánh mức sáng tối của hình ảnh.



Hình 3.1: Minh họa quá trình chuyển đổi dữ liệu hình ảnh thành PDF dựa trên màu sắc.
Nguồn: Minh họa của tác giả.

b. Ước lượng dựa vào khối màu


Một hướng tiếp cận khác là phân chia hình ảnh thành các khối nhỏ có kích thước $s \times s$ và không chồng lấp từ phải sang trái và từ trên xuống dưới. Mỗi ma trận vuông P_k được ánh xạ thành vector $z_k = \text{vec}(P_k) \in \mathbb{R}^{s^2}$. Trong từng khối, tập hợp $\{z_{k,p}\}$ được coi là mẫu cục bộ. Với mỗi khối, tiến hành ước lượng mật độ bằng công thức hạt nhân Gauss, bằng thông vẫn được lựa chọn theo quy tắc Silverman. Các PDF cục bộ $\hat{f}_k(u)$ là kết quả sau khi ước lượng cho từng khối. Hình 3.2 thể hiện bốn khối màu của hình ảnh mô phỏng (của Hình 3.1) đánh theo thứ tự 1 ÷ 4 theo thứ tự từ trái sang phải, từ trên xuống dưới.

Cách tiếp cận này duy trì thông tin màu sắc cho từng khối hình ảnh, phù hợp cho bài toán phân tích chùm vì sự phân biệt của nó trong các vùng màu sắc khác nhau. Khối đầu chứa vùng sáng, khối cuối chứa vùng tối, hai khối còn lại nằm trên các vùng trung gian có mức xám thay đổi dần. Một PDF của khối đầu có phân bố tập trung ở cường độ cao, thể hiện sự hiện diện của vùng sáng. Ngược lại, khối cuối có phân bố nghiêng về cường độ thấp phản ánh sự tồn tại của một vùng tối.

3.2 Ứng dụng của bài toán phân tích chùm

3.2.1 Dữ liệu


Ví dụ 3.1. Luận văn mô phỏng một tập dữ liệu hình ảnh mất cân bằng và định nghĩa trước hai chùm là sự khác biệt màu sắc của hai hình ảnh kết cấu. Hai hình ảnh gốc (kích thước 200×200 pixel với 256 mức xám) có cường độ nền khác nhau, $D83$ và $D102$. Những ảnh này được lấy từ cơ sở dữ liệu Kết cấu Brodatz tại https://multibandtexture.recherche.usherbrooke.ca/original_brodatz.html. Nhờ tính đồng nhất, giàu chi tiết và dễ thao tác, bộ ảnh này nhanh chóng trở thành một trong những tập dữ liệu sớm nhất và phổ biến nhất trong nghiên cứu thị giác máy tính, đặc biệt trong các bài toán phân tích chùm, phân loại và nhận dạng kết cấu hình ảnh. Các hình ảnh được cắt ngẫu nhiên và phân bố đều với kích thước 64×64 . Sau đó, các hình ảnh được ghép lại thành một tập dữ liệu mất cân bằng với IR dao động từ 10 đến 70.



Hình 3.2: Minh họa quá trình chuyển đổi dữ liệu ảnh thành PDF dựa trên khối màu.

Minh họa quá trình chuyển đổi dữ liệu hình ảnh thành PDF dựa trên khối màu.

Nguồn: Minh họa của tác giả.




Hình 3.3: Các hình ảnh được cắt từ tập dữ liệu Brodatz.

Chú thích (a) Hình ảnh D83 và (b) Hình ảnh D102; (c) PDF trích xuất 1 : 10 cho cả hai hình ảnh, (d) PDF trích xuất 1 : 50 cho cả hai hình ảnh và (e) PDF trích xuất 1 : 100 cho cả hai hình ảnh. Nguồn: Minh họa của tác giả.

Hình 3.3(a) và (b) minh họa một hình ảnh đã cắt và các PDF được trích xuất của nó. Khi xem xét Hình 3.3(c), (d) và (e), chúng tôi nhận thấy thiếu sự khác biệt rõ ràng và nguy cơ mất cân bằng đáng kể trong tập dữ liệu. Chúng tôi nhận thức và chia nội dung của tập dữ liệu hình ảnh thành hai cụm do tính chất tiên nghiệm của nó (D83 và D102). Thách thức hiện tại là phân tích hình ảnh thành các cụm tương ứng một cách nhanh chóng.

Ví dụ 3.2. Hình ảnh Landsat-8 (512×256 pixel) bao phủ Đảo Yam cho thấy nguồn mất cân bằng ở cấp độ biển và đảo từ <https://oceancolor.gsfc.nasa.gov/>. Các bãi san hô nông, bãi cát nhỏ và các mảng thảm thực vật trên đảo bị áp đảo rất nhiều bởi các pixel ở vùng nước sâu. Độ lệch nghiêm trọng này đòi hỏi một thuật toán phân cụm mất cân bằng.

Để phân đoạn hình ảnh này theo màu, trước tiên hình ảnh được chuyển đổi sang thang độ xám và quét cửa sổ trượt các mảng ($p \times p$) không chồng lấn từ trái sang phải, từ trên xuống dưới. Mỗi mảng giờ được làm phẳng thành một vector ($p \times p$)-pixel, PDF cường độ của nó được ước tính thông qua PDF hạt nhân (Chương 1, minh họa ở Hình 3.2) và khối lập phương ($\text{patch} \times h \times \text{pdf}$) kết quả trên 3-D được lưu trữ để phân cụm các mảng. Ở đây, kích thước khối màu được đặt cố định là 4×4 .



Hình 3.4: Hình ảnh thực tế và các PDF được trích xuất từ khối màu

Chú thích: (a) Hình ảnh Landsat đã chuyển về ảnh xám và (b) Mật độ của các khối màu (4×4). Nguồn: Minh họa của tác giả.

3.2.2 Phương pháp thực hiện

Để so sánh giữa các thuật toán đề nghị và các phương pháp truyền thống khác, luận văn giới thiệu các thuật toán cơ sở bao gồm KCF [65], FCF theo CWD [71], FCM theo $\mathcal{L}_1$ [47] chuyên dùng để phân cụm các PDF. Bảng 3.1 mô tả các tham số và cơ sở của phương pháp đề nghị.

Bảng 3.1: Cấu hình thuật toán phân cụm cho phân tích so sánh

Phương pháp	Mô tả	Tham số đầu vào
FCF- $\mathcal{L}_1$ [47]	dựa trên c -means mờ truyền thống với $\mathcal{L}_1$ giữa hai PDF	$maxIter = 500; m = 2; \varepsilon = 1 \times 10^{-6}$
FCF-CWD [71]	dựa trên c -means mờ truyền thống c -means với khoảng cách độ rộng cụm giữa hai PDF	$maxIter = 500; m = 2; \varepsilon = 1 \times 10^{-6}$
KCF [65]	dựa trên k -means truyền thống với khoảng cách $\mathcal{L}_1$ giữa hai PDF	$maxIter = 500$
IFCF (Đề nghị)	dựa trên c -means mờ cải tiến cho PDF mất cân bằng	$maxIter = 500; m = 2; \varepsilon = 1 \times 10^{-6}$


Nguồn: Tác giả tổng hợp.

3.2.3 Kết quả thực hiện

a. Ví dụ 3.1

Theo kết quả phân vùng, các bản đồ của Hình 3.5(a)–Hình 3.5(d) hiển thị thành viên trên mỗi mẫu của từng thuật toán cụm (ngoại trừ FCF- $\mathcal{L}_1$) với $IR = 80$.

Có thể thấy rõ sự khác biệt đáng kể giữa các kỹ thuật trong khả năng duy trì ranh giới phân cụm khi dữ liệu bị lệch mạnh. Cụ thể, IFCF thể hiện cấu trúc phân cụm ổn định, hai cụm được tách biệt rõ ràng, hầu như không xuất hiện hiện tượng nhiễu hoặc lẫn mẫu giữa các vùng. Ngược lại, Self-Updating cho thấy sự phân cụm cứng nhưng lại tự động xem xét trong ba cụm chứ không phải hai như cần thiết. Thuật toán FCD-CWD



Hình 3.5: Ma trận phân vùng của các phương pháp tại $IR = 80$

Nguồn: Minh họa của tác giả.


và KCF đều thể hiện sự dao động mạnh và phân vùng ngẫu nhiên do các dải phân chùm xen kẽ dày đặc phản ánh hiện tượng sụp đổ phân chùm ngẫu nhiên, đặc trưng khi IR cao.

Hơn nữa, để đánh giá tính xác thực của phân vùng, Bảng 3.2 cho thấy IFCF đạt kết quả tốt, có khả năng chống nhiễu cao và duy trì hiệu suất tính toán ổn định. Một mặt, FCF-CWD và FCF- $\mathcal{L}_1$ cho kết quả gần như giống hệt nhau về mặt thống kê trên mọi phép đo, cho thấy việc hiệu chỉnh khoảng cách không mang lại lợi ích đáng kể trong các môi trường dữ liệu mất cân bằng. Ngoài ra, KCF thể hiện sự suy giảm chất lượng rõ rệt tại $IR \geq 80$, khi ARI giảm mạnh từ 1,0 xuống 0,02 và chỉ số $Dunn$ giảm xuống 0,00. Điều này phản ánh sự tồn tại của một ngưỡng nhiễu tối hạn, vượt qua ngưỡng này các phương pháp trọng tâm cổ điển sẽ mất đi cấu trúc chùm. Bên cạnh đó, SUP đạt được giá trị $Silhouette$ bằng 1,0 nhưng đồng thời tạo ra các giá trị $Dunn$ dao động mạnh, từ 6112 tại $IR = 20$ xuống 141 tại $IR = 80$, cho thấy tính đồng nhất nội bộ của chùm là tốt. Tuy nhiên, phương pháp này chỉ ổn định trong khoảng 4 ÷ 5 lần lặp, trong khi thời gian chạy tăng tuyến tính (lớn hơn 49s tại $IR = 100$), thể hiện sự không tương xứng giữa số lần lặp và hiệu quả tính toán thực tế. Mặt khác, IFCF là phương pháp đầu tiên được chứng minh là hoạt động đồng thời trên cả năm tiêu chí $ARI = NMI = 1,0$, chỉ số $Dunn$ khoảng 6,0, chỉ số $Silhouette$ khoảng 0,99, thời gian chạy nhỏ hơn 0,11 giây và hội tụ trong 5 ÷ 10 lần lặp trên các thiết lập cho trước. Qua đó, kết quả này góp phần khẳng định khả năng chống mất cân bằng của thuật toán đề nghị.

Bảng 3.2: So sánh các thuật toán đề nghị và các thuật toán cơ sở đối với Ví dụ 3.2

Chỉ số	IR	FCF-CWD	FCM- $\mathcal{L}_1$	KCF	IFCF
<i>ARI</i>	20	0,12±0,19	0,12±0,19	1,0±0,00	1,0±0,00
	50	0,01±0,00	0,01±0,00	1,0±0,00	1,0±0,00
	80	0,00±0,00	0,00±0,00	0,02±0,00	1,0±0,00
	100	0,00±0,00	0,00±0,00	0,02±0,00	1,0±0,00
<i>NMI</i>	20	0,14±0,12	0,14±0,12	1,0±0,00	1,0±0,00
	50	0,04±0,00	0,04±0,00	1,0±0,00	1,0±0,00
	80	0,03±0,00	0,03±0,00	0,04±0,00	1,0±0,00
	100	0,02±0,00	0,02±0,00	0,03±0,00	1,0±0,00
<i>Dunn</i>	20	0,00±0,00	0,00±0,00	6,3±0,00	6,3±0,00
	50	0,00±0,00	0,00±0,00	7,7±0,00	7,7±0,00
	80	0,00±0,00	0,00±0,00	0,00±0,00	6,7±0,00
	100	0,00±0,00	0,00±0,00	0,00±0,00	5,8±0,00
<i>Silhouette</i>	20	0,41±0,29	0,41±0,28	0,99±0,00	0,99±0,00
	50	0,19±0,01	0,19±0,01	0,99±0,00	0,99±0,00
	80	0,23±0,00	0,23±0,00	0,34±0,00	0,99±0,00
	100	0,25±0,00	0,25±0,00	0,36±0,00	0,99±0,00
Thời gian chạy	20	0,01±0,01	0,01±0,01	0,01±0,00	0,02±0,00
	50	0,03±0,01	0,02±0,01	0,04±0,02	0,04±0,02
	80	0,03±0,01	0,02±0,01	0,06±0,02	0,07±0,00
	100	0,04±0,02	0,03±0,02	0,07±0,03	0,11±0,02
Số vòng lặp	20	8,0±5,0	8,0±5,0	3,5±1,0	5,0±1,0
	50	9,5±7,0	9,5±7,0	12,0±5,0	7,0±1,0
	80	7,0±3,0	7,0±3,0	14,0±4,0	9,0±1,0
	100	7,0±3,0	7,0±3,0	11,0±3,0	10,0±1,0

Nguồn: Tác giả tính toán.



Hình 3.6: Khảo sát sự biến đổi của tham số đối với Ví dụ 3.1

Nguồn: Minh họa của tác giả.




Các đường cong trong Hình 3.6 có cùng trục hoành là tham số mờ trong tập $m \in \{1,1; 1,5; 2,0; 2,5; 5,0; 10,0\}$ và trục tung là *ARI* và *Silhouette*. Trong các Hình 3.6, chỉ có đường cong $IR = 20$ cho kết quả *ARI* cao, trong khi các đường cong từ hơn 50 đều bị giảm về 0,00 ngay từ giá trị m thấp.

Nhìn chung, kết quả thực nghiệm cho thấy hiệu suất phân cụm phụ thuộc rõ rệt vào tham số mờ m khi IR thay đổi. Trong thuật toán đề xuất, phân cụm chất lượng cao được duy trì đối với các giá trị m nhỏ, bất kể IR . Khi m tăng, sự suy giảm hiệu suất xảy ra đột ngột hơn đối với các giá trị IR cao hơn; tuy nhiên, thuật toán đề nghị IFCF cho thấy sự suy giảm chậm hơn đáng kể so với kết quả của FCF thông thường được báo cáo trong các nghiên cứu trước đó [47]. Cụ thể, đối với $IR = 20$ hoặc 50, cả *ARI* và *Silhouette* vẫn gần tối ưu cho đến khi $m = 5$, sau đó điểm số giảm mạnh. Trong khi đó, đối với $IR > 80$ cao hơn, phân cụm mờ thông thường, như được ghi nhận trong các công trình trước đây [64, 65], có xu hướng mất khả năng phân tách cụm ở mức $m = 2$ nhỏ hơn nhiều, thường dẫn đến các phép gán gần như ngẫu nhiên. Ngược lại, thuật toán đề nghị IFCF làm chậm quá trình suy giảm này, duy trì chất lượng phân cụm ổn định hơn trên phạm vi giá trị m rộng hơn.

Kết quả này chứng minh IFCF là phương pháp hiệu quả để phân tích và nhóm các đối tượng dựa trên đặc trưng màu sắc hoặc kết cấu, ngay cả khi các đối tượng cần nhận dạng chỉ chiếm một phần rất nhỏ trong tổng thể dữ liệu.

b. Ví dụ 3.2

Hình 3.7 cho thấy kết quả của thuật toán đề nghị IFCF với số cụm c tăng dần từ $2 \div 10$ được áp dụng để phân đoạn ảnh Landsat của đảo Yam và vùng biển xung quanh, cho thấy mức độ chi tiết của việc tách lớp phủ đất tăng lên theo số cụm c .

(a) $c = 2$ (b) $c = 3$ (c) $c = 4$ (d) $c = 5$ (e) $c = 6$ (f) $c = 7$ (g) $c = 8$ (h) $c = 9$ (i) $c = 10$

Hình 3.7: Kết quả thuật toán đề nghị IFCF được áp dụng cho ảnh Landsat đối với Ví dụ 3.2

Nguồn: Minh họa của tác giả.

Kết quả là, trên $c = 2 \div 10$, quá trình phân đoạn IFCF diễn ra đơn điệu và không tạo ra các hiện tượng nhiễu hạt muối tiêu. Ở $c = 2$, thuật toán phân tách cảnh thành vùng nước sâu và các vùng ven biển xung quanh. Khi chùm c tăng dần về phía 3, độ tương phản quang phổ giữa các rạn san hô và hòn đảo trở nên rõ ràng hơn, qua đó cho thấy các đường viền hiển thị sắc nét hơn. Tiếp đến, trong khoảng $c = 4 \div 6$, hòn đảo trở nên nổi bật hơn, thể hiện rõ các khu vực cát nhẹ, thảm thực vật và các vùng biển khác nhau. Đồng thời, một lớp mới được hình thành để làm nổi bật sự khác biệt trong nước biển. Hơn nữa, ở các lớp vi mô $c = 7 \div 9$, các đặc điểm như bãi cát mỏng, chiếm chưa đến 0,5% tổng số pixel, vẫn được nhóm lại, cho thấy khả năng của thuật toán trong việc bảo tồn các dấu hiệu cường độ sáng nhỏ. Cuối cùng, ở $c = 10$, không có chùm nào bị phá vỡ, thể hiện tính nhất quán không gian nội tại của thuật toán. Tóm lại, số chùm trung bình c từ $4 \div 6$ được xem là phù hợp nhất để cân bằng giữa khả năng phân biệt lớp phủ và khả năng khái quát hóa đối với Ví dụ 3.2. Ngược lại, các giá trị c cao hơn thích hợp hơn cho các nghiên cứu vi mô, nơi cần điều tra sâu và phân tích chi tiết hơn.


Hình ảnh Landsat-8 của Đảo Yam được sử dụng có các điểm ảnh vùng nước sâu áp đảo rất nhiều các điểm thuộc các bãi san hô nông, bãi cát nhỏ và thảm thực vật trên đảo. Điều này tạo ra một nguồn mất cân bằng tự nhiên. Nhiệm vụ phân tích chùm trong Ví dụ này có thể dĩ nhiên được phân đoạn thủ công do không có nhiều trở ngại. Nhưng để máy tính hiểu được sắc độ màu của hình ảnh, ta có thể dùng IFCF theo khối màu.

3.3 Ứng dụng của bài toán phân loại

3.3.1 Dữ liệu

Ví dụ 3.3 (Phân loại màu sắc của các loại đất). Bốn loại đất được lựa chọn để xây dựng tập dữ liệu bao gồm Alluvial Soil, Black Soil, Cinder Soil và Red Soil. Ban đầu, mỗi loại đất chỉ có một hình ảnh gốc, được chuẩn hoá về thang cường độ xám $[0; 1]$. Sau đó, hình ảnh này được sử dụng để sinh thêm các mẫu hình nhân tạo nhằm mô phỏng sự biến thiên tự nhiên của bề mặt vật lý.

Cụ thể, hình ảnh gốc của mỗi lớp được xoay ngẫu nhiên trong khoảng $[-10^\circ; 10^\circ]$ và đồng thời được cắt ngẫu nhiên một vùng con có tỉ lệ từ $80\% \div 100\%$ so với kích thước ban đầu. Nhờ quá trình biến đổi này, tập dữ liệu thu được vừa đa dạng hơn về đặc trưng hình ảnh, vừa phản ánh tốt hơn sự khác biệt thực tế giữa các loại đất. Kết quả là, một tập dữ liệu mất cân bằng được tạo ra theo tỉ lệ 1 : 10 : 10 : 20 tương ứng với bốn lớp, với số mẫu mỗi lớp Alluvial Soil, Black Soil, Cinder Soil và Red Soil lần lượt là $[10; 100; 100; 200]$.



Hình 3.8: Dữ liệu phân loại màu sắc của các loại đất đối với Ví dụ 3.3

Nguồn: Minh họa của tác giả.

3.3.2 Phương pháp thực hiện

Tập hợp các PDF $f_j(x)$ được nội suy trên lưới đều $\Omega = [0; 1]$ gồm 256 điểm. Kết quả cuối cùng là một tập dữ liệu gồm $N = 410$ PDF với miền xác định của mỗi hàm là $[0; 256]$. Hình 3.8(b) minh họa ngẫu nhiên 10 PDF chia theo từng lớp đất. Sau đó, luận văn đánh giá việc phân loại bốn hình ảnh mới ngẫu nhiên trong bốn lớp (mỗi lớp lấy ngẫu nhiên một hình ảnh kiểm tra). Các chỉ số phân loại sau đó được thống kê sau 30 lần chọn mẫu ngẫu nhiên có hoàn lại, bao gồm độ chính xác ACC , độ chính xác cân bằng GM và chỉ số F_1 -score

3.3.3 Kết quả thực hiện

Kết quả trong Bảng 3.3 cho thấy sự khác biệt rõ rệt giữa các phương pháp phân loại PDF.

Bảng 3.3: Kết quả so sánh các mô hình Bayes với các tiên nghiệm cơ sở khác nhau đối với Ví dụ 3.3

Phương pháp	ACC	GM	F_1 -score	Thời gian (s)
Bayes-IFCF	$1,0 \pm 0,00$	$1,0 \pm 0,00$	$1,0 \pm 0,00$	0,04
Bayes-FCF	$0,84 \pm 0,12$	$0,37 \pm 0,49$	$0,79 \pm 0,16$	0,14
Bayes-U	$0,75 \pm 0,00$	$0,00 \pm 0,00$	$0,67 \pm 0,00$	0,00
Bayes-L	$0,50 \pm 0,00$	$0,00 \pm 0,00$	$0,38 \pm 0,00$	0,00
Bayes-J	$0,50 \pm 0,00$	$0,00 \pm 0,00$	$0,38 \pm 0,00$	0,00

Nguồn: Tác giả tính toán.

Ba phương pháp Bayes sử dụng các tiên nghiệm khác nhau, bao gồm phân bố đều, Laplace và Jeffreys, đều cho hiệu năng thấp hơn đáng kể. Cụ thể, mô hình Bayes-Uniform

chỉ đạt ACC là 0,75 và chỉ số F_1 là 0,67, trong khi Bayes-Laplace và Bayes-Jeffreys đều dừng ở mức $ACC = 0,50$ và $F_1\text{-score} = 0,38$. Điều này cho thấy rằng, trong bối cảnh dữ liệu có sự mất cân bằng nghiêm trọng, việc giả định tiên nghiệm đều hoặc hiệu chỉnh đơn giản bằng α là không đủ để khắc phục sai lệch xác suất giữa các lớp. Ngược lại, mô hình Bayes-IFCF đã đạt hiệu quả cao nhất về độ chính xác, cân bằng phân loại và tính ổn định toàn cục. Điều này chứng minh mô hình này có khả năng nhận dạng chính xác toàn bộ các lớp mà không xảy ra hiện tượng mất cân bằng hay suy giảm nhạy cảm giữa các lớp nhỏ và lớp lớn. Hơn nữa, thời gian huấn luyện của tất cả các phương pháp đều nhỏ hơn 0,20 s, cho thấy tính khả thi cao khi áp dụng trong thực nghiệm thực tế.

► **Chú ý.** Qua các Ví dụ số cho bài toán SR, ta có thể thấy, việc phân đoạn hay phân loại dữ liệu hình ảnh có thể dựa trên màu sắc đặc trưng của các đối tượng. Sử dụng dữ liệu PDF để biểu diễn hình ảnh mang lại nhiều lợi thế đáng chú ý tính rõ ràng và trực quan qua phân tích chùm. Hơn nữa, nó có tính ổn định khi hình ảnh bị xoay. Phương pháp ước lượng PDF dựa trên màu sắc phản ánh rõ đặc tính sáng/tối toàn cục của hình ảnh. Tuy nhiên, việc trích xuất này cần một số tiên giả định về việc màu sắc phải cố định và hạn chế sai lệch. Vì sử dụng các thang màu RGB hoặc xám làm cho bài toán phân loại phải là phân loại màu sắc mà không phải hình dạng hay kết cấu. Ví dụ, việc trích xuất các loại củ quả như ớt chuông, củ cải, táo, các loại này có nhiều màu sắc (như táo đỏ, táo xanh) nên không thể dùng trích xuất loại này. Hơn nữa, các sai lệch về độ sáng của hình ảnh cũng ảnh hưởng đến kết quả trích xuất. Phương pháp dựa trên màu sắc (hoặc khối màu) không duy trì được thông tin hình học. Tức là, ta không thể sử dụng thuật toán để đánh giá nội dung hình ảnh như nhận dạng khuôn mặt, đánh dấu các vị trí chứa các bất thường của hình ảnh X-quang.

PHẦN KẾT LUẬN

1. Kết luận

Nhận dạng thông kê cho PDF là một chủ đề hấp dẫn, chưa có nhiều nghiên cứu nên còn nhiều khả năng phát triển cả lý thuyết và ứng dụng. Ứng dụng của nó cho dữ liệu hình ảnh hứa hẹn nhiều tiềm năng trong nâng cao hiệu quả. Luận văn này đã thực hiện được những vấn đề sau cho dữ liệu PDF:

- (i) *Về phân tích chùm*: Luận văn đã đề xuất 1 thuật toán phân tích chùm mờ cải tiến (IFCF) cho dữ liệu bị mất cân bằng. Thuật toán đề nghị đã được xem xét sự hội tụ, vấn đề tính toán và những khía cạnh liên quan đến áp dụng thực tế. Thuật toán phân tích chùm đề nghị được xem có tính tổng quát hơn so với các thuật toán hiện có.
- (ii) *Về phân loại*: Luận văn đã thiết lập 1 thuật toán phân loại dựa trên việc cải tiến vấn đề xác định xác suất tiên nghiệm dựa vào thuật toán phân tích chùm mờ của (i) và nguyên tắc tính chỉ số hậu nghiệm mới. Cách tiếp cận tiên nghiệm động mới này được chứng minh hiệu quả hơn so với các giả định tiên nghiệm tĩnh truyền thống như tiên nghiệm đều, Laplace hay Jeffreys.
- (iii) *Về các áp dụng số*: Luận văn đã xây dựng phương pháp trích xuất đặc trưng của hình ảnh thành PDF đại diện để áp dụng được các thuật toán đề nghị trong (i) và (ii). Nghiên cứu cũng đã giải quyết được vấn đề tính toán của các thuật toán, thông qua các chương trình trên ngôn ngữ lập trình Python để có thể áp dụng hiệu quả cho tập hình ảnh thực. Kết quả thực nghiệm trên những tập dữ liệu cụ thể cho thấy các thuật toán đề nghị nhận được kết quả ổn định, hiệu quả hơn các thuật toán phổ biến cùng nhóm, căn cứ vào các tham số thống kê đánh giá.

2. Định hướng nghiên cứu

- *Về mặt lý thuyết*, các hướng phát triển tiếp theo được định hình nhằm mở rộng và hoàn thiện khung phương pháp luận cho bài toán SR với đối tượng PDF.

- (i) Phát triển các mô hình SR kết hợp để đồng thời giải quyết hai hiệu ứng “đồng nhất” và “xi phong”. Thuật toán đề nghị IFCF trong luận văn đã góp phần giảm thiểu “hiệu ứng đồng nhất”. Tuy nhiên, các thuật toán phân chùm vẫn phải đối mặt với “hiệu ứng xi phong”, trong đó các phần tử biên của lớp nhỏ có xu hướng bị kéo lệch

về chùm lớn hơn.

(ii) Thiết lập các điều kiện và chứng minh tính hội tụ nghiêm ngặt khi sử dụng các f -phân kỳ. Hiện nay, cơ sở toán học cho việc phân tích chùm với các phân kỳ này vẫn còn là một khoảng trống kiến thức cần được nghiên cứu và hoàn thiện trong tương lai.

(iii) Thiết kế và triển khai các phiên bản học không giám sát trực tuyến nhằm cập nhật trọng tâm và ma trận phân vùng dựa trên các lô dữ liệu nhỏ hoặc từng PDF khi chúng đến liên tục. Nhờ vậy, có thể giảm đáng kể yêu cầu về bộ nhớ và thời gian tính toán, đồng thời nâng cao khả năng xử lý trong môi trường dữ liệu động.

• *Trên phương diện ứng dụng*, các hướng mở rộng được định hướng nhằm tăng tính thực tiễn và khả năng triển khai của mô hình trong các lĩnh vực khác nhau.

(i) Phát triển các kỹ thuật trích xuất đặc trưng tiên tiến hơn để biểu diễn các đặc tính hình ảnh phức tạp như kết cấu và hình dạng thành các PDF. Đồng thời, nên mở rộng việc trích xuất đặc trưng mật độ để xử lý dữ liệu hình ảnh đa kênh màu.

(ii) Xây dựng cơ chế xác định siêu tham số tối ưu cho các thuật toán phân chùm PDF. Song song đó, phát triển các công cụ giải thích-AI chuyên biệt cho các mô hình SR cho PDF nhằm tăng tính minh bạch và khả năng diễn giải, giúp người dùng hiểu rõ lý do mô hình phân loại một mẫu vào lớp thiếu số.

(iii) Mở rộng việc áp dụng SR cho dữ liệu PDF đa chiều vốn xuất hiện ngày càng nhiều trong các nghiên cứu về mối tương quan phức tạp giữa các biến.

TÀI LIỆU THAM KHẢO

- [1] Act, A. I. (2023). Artificial intelligence act. *Euroopan Unioni. Luettavissa:* <https://artificialintelligen>.
- [2] Akturk, B., Beyaztas, U., Shang, H. L., and Mandal, A. (2024). Robust functional logistic regression. *Advances in Data Analysis and Classification*, pages 1–25.
- [3] Ali, S. M. and Silvey, S. D. (1966). A general class of coefficients of divergence of one distribution from another. *Journal of the Royal Statistical Society: Series B (Methodological)*, 28(1):131–142.
- [4] Askari, S. (2021). Fuzzy c-means clustering algorithm for data with unequal cluster sizes and contaminated with noise and outliers: Review and development. *Expert Systems with Applications*, 165:113856.
- [5] Azzalini, A. (1985). A class of distributions which includes the normal ones. *Scandinavian Journal of Statistics*, pages 171–178.
- [6] Belhadi, A., Mani, V., Kamble, S. S., Khan, S. A. R., and Verma, S. (2024). Artificial intelligence-driven innovation for enhancing supply chain resilience and performance under the effect of supply chain dynamism: an empirical investigation. *Annals of Operations Research*, 333(2):627–652.
- [7] Bezdek, J. C. (1980). A convergence theorem for the fuzzy isodata clustering algorithms. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, (1):1–8.
- [8] Bezdek, J. C. (2013). *Pattern recognition with fuzzy objective function algorithms*. Springer Science & Business Media.
- [9] Bezdek, J. C., Ehrlich, R., and Full, W. (1984). Fcm: The fuzzy c-means clustering algorithm. *Computers and Geosciences*, 10(2-3):191–203.
- [10] Billard, L. and Diday, E. (2012). *Symbolic data analysis: Conceptual statistics and data mining*. John Wiley & Sons.
- [11] Bishop, C. M. and Bishop, H. (2024). *Deep Learning: Foundations and Concepts*. Springer.
- [12] Chen, J.-H. and Hung, W.-L. (2021). A jackknife entropy-based clustering algorithm for probability density functions. *Journal of Statistical Computation and Simulation*, 91(5):861–875.
- [13] Cortes, C. (1995). Support-vector networks. *Machine Learning*.
- [14] Dey, P. K., Chowdhury, S., Abadie, A., Vann Yaroson, E., and Sarkar, S. (2024). Artificial intelligence-driven supply chain resilience in vietnamese manufacturing small-and medium-sized enterprises. *International Journal of Production Research*, 62(15):5417–5456.
- [15] Dinh, T., Wong, H., Fournier-Viger, P., Lisik, D., Ha, M.-Q., Dam, H.-C., and Huynh, V.-N. (2025). Categorical data clustering: 25 years beyond k-modes. *Expert Systems with Applications*, 272:126608.

- [16] Dunn, J. C. (1973). A fuzzy relative of the isodata process and its use in detecting compact well-separated clusters.
- [17] Erasmus, A., Brunet, T. D., and Fisher, E. (2021). What is interpretability? *Philosophy and Technology*, 34(4):833–862.
- [18] Fillmore-Patrick, S. (2025). The logit model measurement problem. *Philosophy of Science*, 92(2):285–303.
- [19] Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7(2):179–188.
- [20] Florek, K., Łukaszewicz, J., Perkal, J., Steinhaus, H., and Zubrzycki, S. (1951). Sur la liaison et la division des points d’un ensemble fini. In *Colloquium mathematicum*, volume 2, pages 282–285.
- [21] Fréchet, M. (1948). Les éléments aléatoires de nature quelconque dans un espace distancié. In *Annales de l’institut Henri Poincaré*, volume 10, pages 215–310.
- [22] Ghanem, M., Ghaith, A. K., El-Hajj, V. G., Bhandarkar, A., De Giorgio, A., Elmi-Terander, A., and Bydon, M. (2023). Limitations in evaluating machine learning models for imbalanced binary outcome classification in spine surgery: a systematic review. *Brain Sciences*, 13(12):1723.
- [23] Goutte, C., Toft, P., Rostrup, E., Nielsen, F. Å., and Hansen, L. K. (1999). On clustering fmri time series. *NeuroImage*, 9(3):298–310.
- [24] Groll, L. and Jakel, J. (2005). A new convergence proof of fuzzy *c*-means. *IEEE Transactions on Fuzzy Systems*, 13(5):717–720.
- [25] Gullo, F., Ponti, G., Tagarelli, A., and Greco, S. (2008). A hierarchical algorithm for clustering uncertain data via an information-theoretic approach. In *2008 Eighth IEEE International Conference on Data Mining*, pages 821–826. IEEE.
- [26] Hathaway, R. J. and Bezdek, J. C. (1988). Recent convergence results for the fuzzy *c*-means clustering algorithms. *Journal of Classification*, 5(2):237–247.
- [27] He, Y. (2024). Imbalanced data clustering using equilibrium k-means. *arXiv preprint arXiv:2402.14490*.
- [28] Herm, L.-V., Heinrich, K., Wanner, J., and Janiesch, C. (2023). Stop ordering machine learning algorithms by their explainability! a user-centered investigation of performance and explainability. *International Journal of Information Management*, 69:102538.
- [29] Hu, X., Chen, H., Zhang, J., Chen, H., Liu, S., Li, X., Wang, Y., and Xue, X. (2024). Gato-cobo: Cost-sensitive graph neural network for telecom fraud detection. *IEEE Transactions on Big Data*.
- [30] Hung Tran-Nam, T. N.-T. and Che-Ngoc, H. (2024). A new possibilistic-based clustering method for probability density functions and its application to detecting abnormal elements. *Scientific Reports*, 14(1):17871.
- [31] Huynh-Van, H., Le-Hoang, T., and Vo-Van, T. (2024). Classifying for images based on the extracted probability density function and the quasi bayesian method. *Computational Statistics*, 39(5):2677–2701.
- [32] Ikotun, A. M., Habyarimana, F., and Ezugwu, A. E. (2025). Cluster validity indices for automatic clustering: A comprehensive review. *Heliyon*.

- [33] Irpino, A. and Verde, R. (2015). Basic statistics for distributional symbolic variables: a new metric-based approach. *Advances in Data Analysis and Classification*, 9(2):143–175.
- [34] Jain, A. K. (2010). Data clustering: 50 years beyond k -means. *Pattern Recognition Letters*, 31(8):651–666.
- [35] Johnson, S. C. (1967). Hierarchical clustering schemes. *Psychometrika*, 32(3):241–254.
- [36] Leonelli, S. (2019). *Data-centric biology: A philosophical study*. University of Chicago Press.
- [37] Lin, P.-L., Huang, P.-W., Kuo, C.-H., and Lai, Y. (2014). A size-insensitive integrity-based fuzzy c-means method for data clustering. *Pattern Recognition*, 47(5):2042–2056.
- [38] Liu, Y., Hou, T., Kang, B., and Liu, F. (2016). Unsupervised binning of metagenomic assembled contigs using improved fuzzy c-means method. *IEEE/ACM transactions on computational biology and bioinformatics*, 14(6):1459–1467.
- [39] Macqueen, J. (1967). Some methods for classification and analysis of multivariate observations. In *Proceedings of 5-th Berkeley Symposium on Mathematical Statistics and Probability/University of California Press*.
- [40] Maia, A. L. S. and de Carvalho, F. d. A. (2011). Holt’s exponential smoothing and neural network models for forecasting interval-valued time series. *International Journal of Forecasting*, 27(3):740–759.
- [41] Matusita, K. (1967). On the notion of affinity of several distributions and some of its applications. *Annals of the institute of Statistical Mathematics*, 19:181–192.
- [42] Minami, M. and Lennert-Cody, C. E. (2024). Regression tree and clustering for distributions, and homogeneous structure of population characteristics. *Journal of Agricultural, Biological and Environmental Statistics*, pages 1–20.
- [43] Mollema, T. (2024a). “ai colonialism” is a conceptual metaphor. Master’s thesis.
- [44] Mollema, W. J. T. (2024b). Responding to the watson-sterkenburg debate on clustering algorithms and natural kinds.
- [45] Nanni, L., Ghidoni, S., and Brahnam, S. (2017). Handcrafted vs. non-handcrafted features for computer vision classification. *Pattern recognition*, 71:158–172.
- [46] Nguyen, G. H., Bouzerdoum, A., and Phung, S. L. (2009). Learning pattern classification tasks with imbalanced data sets. *Pattern Recognition*, 10(2009):1322–1328.
- [47] Nguyen-Trang, T. and Vo-Van, T. (2017). Fuzzy clustering of probability density functions. *Journal of Applied Statistics*, 44(4):583–601.
- [48] Nguyen-Trang, Thao, T. N.-T. and Vo-Van, T. (2023). Globally automatic fuzzy clustering for probability density functions and its application for image data. *Applied Intelligence*, 53(15):18381–18397.
- [49] Noordam, J., Van Den Broek, W., and Buydens, L. (2002). Multivariate image segmentation with cluster size insensitive fuzzy c-means. *Chemometrics and Intelligent Laboratory Systems*, 64(1):65–78.
- [50] Okano, R. and Imaizumi, M. (2024). Wasserstein k -centres clustering for distributional data. *arXiv e-prints*, pages arXiv–2407.
- [51] Pavlů, I., Menafoglio, A., Bongiorno, E., and Hron, K. (2023). Classification of probability density functions in the framework of bayes spaces: methods and applications. *SORT: Statistics and Operations Research Transactions*, 47(2):295–322.

- [52] Petersen, A. and Müller, H.-G. (2016). Functional data analysis for density functions by transformation to a hilbert space. *The Annals of Statistics*, pages 183–218.
- [53] Pham-Toan, D. and Vo-Van, T. (2022). Automatic fuzzy clustering for probability density functions using the genetic algorithm. *Neural Computing and Applications*, 34(17):14609–14625.
- [54] Pham-Toan, D., Vo-Van, T., Pham-Chau, A., Nguyen-Trang, T., and Ho-Kieu, D. (2019). A new binary adaptive elitist differential evolution based automatic k -medoids clustering for probability density functions. *Mathematical Problems in Engineering*, 2019(1):6380568.
- [55] Ren, J., Lee, S. D., Chen, X., Kao, B., Cheng, R., and Cheung, D. (2009). Naive bayes classification of uncertain data. In *2009 Ninth IEEE international conference on data mining*, pages 944–949. IEEE.
- [56] Rosenblatt, F. (1961). Principles of neurodynamics: Perceptrons and the theory of brain mechanisms.
- [57] Saxena, A., Prasad, M., Gupta, A., Bharill, N., Patel, O. P., Tiwari, A., Er, M. J., Ding, W., and Lin, C.-T. (2017). A review of clustering techniques and developments. *Neurocomputing*, 267:664–681.
- [58] Schubert, E. (2023). Stop using the elbow criterion for k-means and how to choose the number of clusters instead. *ACM SIGKDD Explorations Newsletter*, 25(1):36–42.
- [59] Sorensen, T. (1948). A method of establishing groups of equal amplitude in plant sociology based on similarity of species content and its application to analyses of the vegetation on danish commons. *Biologiske Skrifter*, 5:1–34.
- [60] Tai Vo-Van, H. N.-T.-K. and Pham-Toan, D. (2023). Multi-class classification using a new bayesian method. *Model Assisted Statistics and Applications*, 18(3):257–266.
- [61] Tang, Y., Zhang, Y.-Q., Chawla, N. V., and Krasser, S. (2008). Svms modeling for highly imbalanced classification. *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)*, 39(1):281–288.
- [62] Tavakkol, B. and Son, Y. (2021). Fuzzy kernel k -medoids clustering algorithm for uncertain data objects. *Pattern Analysis and Applications*, 24(3):1287–1302.
- [63] Thao Nguyen-Trang, Trung Nguyen-Thoi, K.-N. N.-T. and Vo-Van, T. (2023). Balance-driven automatic clustering for probability density functions using metaheuristic optimization. *International Journal of Machine Learning and Cybernetics*, 14(4):1063–1078.
- [64] Thao Nguyen-Trang, T. V.-V. and Che-Ngoc, H. (2024). An efficient automatic clustering algorithm for probability density functions and its applications in surface material classification. *Statistica Neerlandica*, 78(1):244–260.
- [65] Thao Nguyen-Trang, Y. N.-H. and Vo-Van, T. (2024). A new semi-supervised clustering algorithm for probability density functions and applications. *Neural Computing and Applications*, 36(11):5965–5980.
- [66] Theodoridis, S. and Koutroumbas, K. (2006). *Pattern recognition*. Elsevier.
- [67] Toussaint, G. T. (1972). Some inequalities between distance measures for feature evaluation. *IEEE Transactions on Computers*, 21(04):409–410.
- [68] Tran, T. A. N., Nguyen, A. T. N., and PhamToan, D. (2025). A novel supervised learning model for mri image using fuzzy clustering and naïve bayes algorithms. *Model Assisted Statistics and Applications*, page 15741699251334321.

- [69] van der Linde, I. (2025). Why the confusion matrix fails as a model of knowledge. *AI and SOCIETY*, pages 1–2.
- [70] Villani, C. (2008). *Optimal transport: old and new*, volume 338. Springer.
- [71] Vo-Van, T. (2019). Cluster width of probability density functions. *Intelligent Data Analysis*, 23(2):385–405.
- [72] Vo-Van, T. (2025a). Classifying for images based on the extracted color scales and representative probability density functions. *Expert Systems with Applications*, page 128456.
- [73] Vo-Van, T. (2025b). Developing an image classification algorithm based on the novel measure combined with quasi-bayesian method for representing probability density function. *Annals of Operations Research*, pages 1–26.
- [74] Vo-Van, T. and Dinh, P. (2024). A supervised learning algorithm based on the quasi-bayesian method for the probability density functions and application for medical data. *Knowledge-Based Systems*, 299:112003.
- [75] Vo-Van, T. and Nguyen-Trang, T. (2018). Similar coefficient for cluster of probability density functions. *Communications in Statistics-Theory and Methods*, 47(8):1792–1811.
- [76] Vo-Van, T. and Pham-Gia, T. (2010). Clustering probability distributions. *Journal of Applied Statistics*, 37(11):1891–1910.
- [77] Wald, A. (1950). Statistical decision functions. In *Breakthroughs in Statistics: Foundations and Basic Theory*, pages 342–357. Springer.
- [78] Ward Jr, J. H. (1963). Hierarchical grouping to optimize an objective function. *Journal of the American statistical association*, 58(301):236–244.
- [79] Watson, D. S. (2023a). On the philosophy of unsupervised learning. *Philosophy and Technology*, 36(2):28.
- [80] Watson, D. S. (2023b). Reply to tom sterkenburg’s commentary. *Philosophy and Technology*, 36(4):69.
- [81] Webb, A. R. (2003). *Statistical pattern recognition*. John Wiley & Sons.
- [82] Xiong, H., Wu, J., and Chen, J. (2006). K-means clustering versus validation measures: a data distribution perspective. In *Proceedings of the 12th ACM SIGKDD international conference on Knowledge discovery and data mining*, pages 779–784.
- [83] Yu, H., Li, H., Xu, X., Gao, Q., and Lan, R. (2024). Suppressed possibilistic fuzzy c-means clustering based on shadow sets for noisy data with imbalanced sizes. *Applied Soft Computing*, 167:112263.
- [84] Zangwill, W. I. (1969). *Nonlinear programming: a unified approach*.
- [85] Zha, D., Bhat, Z. P., Lai, K.-H., Yang, F., Jiang, Z., Zhong, S., and Hu, X. (2025). Data-centric artificial intelligence: A survey. *ACM Computing Surveys*, 57(5):1–42.

PHỤ LỤC A LÝ THUYẾT BỔ SUNG VÀ MÃ NGUỒN

Phần này cung cấp lý thuyết và các thuật toán của luận văn.

Bảng 3.4: Một số hàm cơ sở $\psi_m(x)$ phổ biến trong hồi quy logistic cho dữ liệu PDF

Hàm cơ sở	Công thức $\psi_m(x)$	Miền xác định
Gaussian (RBF)	$\psi_m(x) = \exp\left(-\frac{(x-\mu_m)^2}{2\sigma_m^2}\right)$	$x \in \mathbb{R}$
Hàm sóng con (Wavelet)	$\psi_m(x) = 2^{jm/2} \psi(2^j m x - k_m)$	$x \in \mathbb{R}$
Chuỗi Fourier	$\psi_m^{(\cos)}(x) = \cos\left(\frac{2\pi m x}{T}\right), \quad \psi_m^{(\sin)}(x) = \sin\left(\frac{2\pi m x}{T}\right)$	$x \in [0; T]$
Đa thức Bernstein	$\psi_m(x) = \binom{n}{m} x^m (1-x)^{n-m}$	$x \in [0; 1]$
Đa thức Legendre	$\psi_m(x) = \frac{1}{2^m m!} \frac{d^m}{dx^m} [(x^2 - 1)^m]$	$x \in [-1; 1]$
B-spline	$\psi_m(x) = \frac{x-t_m}{t_{m+k}-t_m} \psi_{m,k-1}(x) + \frac{t_{m+k+1}-x}{t_{m+k+1}-t_{m+1}} \psi_{m+1,k-1}(x),$ với $\psi_{m,0}(x) = \mathbf{1}_{[t_m, t_{m+1})}(x)$	$x \in \mathbb{R}$

Algorithm 3: Giải thuật phân cụm thứ bậc tích tụ (HCF)

```

1: procedure HCF( $\mathcal{F}; \Delta$ ) ▷ Cho trước liên kết
2:    $t \leftarrow 0$ 
3:   Khởi tạo:  $\mathcal{F}^{(t=0)} = \{\{f_1\}; \{f_2\}; \dots; \{f_n\}\}$ 
4:   while  $n - t > 1$  do
5:     Chọn hai  $c_i; c_j \in \mathcal{F}^{(t=0)}$  sao cho thỏa tại vị trí  $(c_i; c_j) = \arg \min_{c_u; c_v \in \mathcal{F}^{(t=0)}} \Delta(c_u; c_v)$ .
6:     Gộp  $c \leftarrow c_i \cup c_j$ 
7:     Cập nhật  $\mathcal{F}^{t+1} \leftarrow (\mathcal{F}^{(t)} \setminus \{c_i; c_j\}) \cup \{c\}$ 
8:      $t \leftarrow t + 1$ 
9:   end while
10:  return Cây phân cấp
11: end procedure

```

Algorithm 4: Giải thuật phân tích chùm (KCF)

```
1: procedure KCF( $c; \varepsilon$ ) ▷ Cho trước số chùm  $c$ 
2:    $t \leftarrow 0$ 
3:   Khởi tạo  $\mu^{(t)}$  và  $\Theta^{(t)}$  ngẫu nhiên
4:   while  $\|J^{(t+1)} - J^{(t)}\| < \varepsilon$  do
5:      $t \leftarrow t + 1$ 
6:     Cập nhật  $\mu^{(t+1)}$  bằng Công thức  $\mu_{ij} = \mathbf{1}_{\{j \in c_i\}}$ 
7:     Cập nhật  $\Theta^{(t+1)}$  bằng Công thức (1.2)
8:   end while
9:   return  $\mu$  và  $\Theta$ . ▷ Ma trận phân vùng và PDF đại diện
10: end procedure
```

Algorithm 5: Giải thuật phân tích chùm mờ (FCF)

```
1: procedure FCF( $c; \varepsilon$ ) ▷ Cho trước số chùm  $c$ 
2:    $t \leftarrow 0$ 
3:   Khởi tạo  $\mu^{(t)}$  và  $\Theta^{(t)}$  ngẫu nhiên
4:   while  $\|\mu^{(t+1)} - \mu^{(t)}\| < \varepsilon$  do
5:      $t \leftarrow t + 1$ 
6:     Cập nhật  $\Theta^{(t+1)}$  bằng Công thức (1.5)
7:     Cập nhật  $\mu^{(t+1)}$  bằng Công thức (1.6)
8:   end while
9:   return  $\mu$  và  $\Theta$ . ▷ Ma trận phân vùng và PDF đại diện
10: end procedure
```

Về tài nguyên tính toán, luận văn này chạy trên hệ điều hành Ubuntu 24.04.2 LTS, nhân Linux 6.11.0-19-generic, 11th Gen Intel® Core™ i5-11400H×12, bộ nhớ 16.0 GiB.

Việc thực thi mã nguồn được sử dụng trong môi trường ảo của Anaconda tên là ‘proclustEnv’. Các mã Python được sử dụng trong luận văn này được lưu trữ tại <https://github.com/hungtrannam/probclust>. Các thư viện trên được lưu trong tệp requirements.yml và có thể được cài đặt tự động bằng lệnh

```
conda install environment.yml
```

Đây là danh sách các thư viện Python cần thiết để thực thi toàn bộ mã nguồn trong luận văn.

```
numpy matplotlib pandas tqdm seaborn optuna argparse
torch torchvision torchmetrics scikit-learn einops optunahub cmaes
gpustat statsmodels gputil shap ipykernel opencv-python
scikit-image pyvis scikit-posthocs forestplot
```

PHỤ LỤC B KẾT QUẢ

Ví dụ 3.4 (Liên kết các chùm hàm mật độ xác suất). Giả sử ta có ba chùm PDF Gauss $\mathcal{F}; \mathcal{G}$ và $\mathcal{H}$. Tính các liên kết $\Delta(\mathcal{F}; \mathcal{G})$ và $\Delta(\mathcal{F} \cup \mathcal{G}; \mathcal{H})$ biết khoảng cách giữa hai PDF là $\mathcal{L}_2$ và các chùm

$$\begin{aligned}\mathcal{F} &= \{f_1 = \mathcal{N}(0,30;1); f_2 = \mathcal{N}(1,0;1,0)\}, \\ \mathcal{G} &= \{g_1 = \mathcal{N}(4,0;1,0); g_2 = \mathcal{N}(5,5;1,0); g_3 = \mathcal{N}(4,8;1,0)\}, \\ \mathcal{H} &= \{h_1 = \mathcal{N}(9,1;1,0); h_2 = \mathcal{N}(8,0;1,0)\}.\end{aligned}$$

Bài giải 3.4. Vì các phương sai của PDF Gauss đều bằng 1. Nên ta có thể tính $\mathcal{L}_2$ bằng công thức tổng quát $\mathcal{L}_2(u; v) = \left(2 - 2 \exp\left(-\frac{(\mu_u - \mu_v)^2}{4\sigma^2}\right)\right)^{1/2}$. Sau khi tính toán, ta nhận được ma trận khoảng cách từng đôi một.

	$\{f_1 \quad f_2\}$	$\{g_1 \quad g_2 \quad g_3\}$	$\{h_1 \quad h_2\}$
f_1			
f_2	0,26		
g_1	0,74	0,71	
g_2	0,75	0,75	0,49
g_3	0,75	0,74	0,29
h_1	0,75	0,75	0,75
h_2	0,75	0,75	0,74

Từ đây, ta có thể dễ dàng tính được các liên kết $\Delta(\mathcal{F}; \mathcal{G})$ thông qua ma trận này. Ta có,

$$\begin{aligned}\Delta_{\min}(\mathcal{F}; \mathcal{G}) &= \min \{ \mathcal{L}_2(f_1; g_1); \mathcal{L}_2(f_1; g_2); \mathcal{L}_2(f_1; g_3); \mathcal{L}_2(f_2; g_1); \mathcal{L}_2(f_2; g_2); \mathcal{L}_2(f_2; g_3) \} \\ &= \min \{ 0,74; 0,75; 0,75; 0,71; 0,75; 0,74 \} = 0,71,\end{aligned}$$

$$\begin{aligned}\Delta_{\max}(\mathcal{F}; \mathcal{G}) &= \max \{ \mathcal{L}_2(f_1; g_1); \mathcal{L}_2(f_1; g_2); \mathcal{L}_2(f_1; g_3); \mathcal{L}_2(f_2; g_1); \mathcal{L}_2(f_2; g_2); \mathcal{L}_2(f_2; g_3) \} \\ &= \max \{ 0,74; 0,75; 0,75; 0,71; 0,75; 0,74 \} = 0,75,\end{aligned}$$

$$\Delta_{\text{avg}}(\mathcal{F}; \mathcal{G}) = \frac{1}{6} \sum_{\substack{f \in \mathcal{F} \\ g \in \mathcal{G}}} \mathcal{L}_2(f; g) = 0,17(0,74 + 0,75 + 0,75 + 0,71 + 0,75 + 0,74) = 0,74,$$

$$\Delta_{\text{centroid}}(\mathcal{F}; \mathcal{G}) = \mathcal{L}_2(\theta_{\mathcal{F}}; \theta_{\mathcal{G}}) = \left(2 - 2 \exp\left(-\frac{(0,65 - 4,8)^2}{4}\right)\right)^{1/2} = 1,4,$$

$$\text{với } \theta_{\mathcal{F}} = (0,30 + 1,0)/2 = 0,65; \quad \theta_{\mathcal{G}} = (4,0 + 5,5 + 4,8)/3 = 4,8,$$

$$\Delta_{\text{Ward}}(\mathcal{F}; \mathcal{G}) = \frac{\#\mathcal{F} \cdot \#\mathcal{G}}{\#\mathcal{F} + \#\mathcal{G}} \cdot \mathcal{L}_2^2(\theta_{\mathcal{F}}; \theta_{\mathcal{G}}) = \frac{2 \cdot 3}{2 + 3} \cdot (1,4)^2 = 2,4.$$

Tương tự, ta cũng có kết quả cho $\Delta(\mathcal{F} \cup \mathcal{G}; \mathcal{H})$ là

$$\begin{aligned}\Delta_{\min}(\mathcal{F} \cup \mathcal{G}; \mathcal{H}) &= 0,67; & \Delta_{\max}(\mathcal{F} \cup \mathcal{G}; \mathcal{H}) &= 0,75; \\ \Delta_{\text{avg}}(\mathcal{F} \cup \mathcal{G}; \mathcal{H}) &= 0,74; & \Delta_{\text{centroid}}(\mathcal{F} \cup \mathcal{G}; \mathcal{H}) &= 1,4; & \Delta_{\text{Ward}}(\mathcal{F} \cup \mathcal{G}; \mathcal{H}) &= 2,9.\end{aligned}$$

Bài giải Ví dụ 1.5. Đầu tiên, ta xem thứ tự của μ_i chính là thứ tự của dữ liệu PDF f_i , tính toán các khoảng cách từng đôi PDF bất kỳ bằng khoảng cách $\mathcal{L}_2(f_i; f_j)$ với $i, j = 1; 2; \dots; 7$, ta nhận được ma trận khoảng cách

	f_1	f_2	f_3	f_4	f_5	f_6	f_7
$D^{(t=0)} =$	f_1						
	f_2	0,74					
	f_3	0,75	0,75				
	f_4	0,26	0,71	0,75			
	f_5	0,75	0,49	0,74	0,75		
	f_6	0,75	0,74	0,38	0,75	0,67	
	f_7	0,75	0,29	0,75	0,74	0,26	0,72

Ta thấy khoảng cách $D(f_1; f_4) = D(f_5; f_7) = 0,26$ là khoảng cách nhỏ nhất nên ta chọn một trong hai. Trường hợp này, ta chọn PDF f_1 và f_4 xếp vào một cụm $\{f_1; f_4\}$. Tiến hành tính toán liên kết đủ giữa cụm $\{f_1; f_4\}$ với các PDF khác. Ta có

$$\begin{aligned}\Delta(\{f_1; f_4\}; f_2) &= \max\{D(f_1; f_2); D(f_4; f_2)\} = \max\{0,74; 0,71\} = 0,74, \\ \Delta(\{f_1; f_4\}; f_3) &= \max\{D(f_1; f_3); D(f_4; f_3)\} = \max\{0,75; 0,75\} = 0,75, \\ \Delta(\{f_1; f_4\}; f_5) &= \max\{D(f_1; f_5); D(f_4; f_5)\} = \max\{0,75; 0,75\} = 0,75, \\ \Delta(\{f_1; f_4\}; f_6) &= \max\{D(f_1; f_6); D(f_4; f_6)\} = \max\{0,75; 0,75\} = 0,75, \\ \Delta(\{f_1; f_4\}; f_7) &= \max\{D(f_1; f_7); D(f_4; f_7)\} = \max\{0,75; 0,74\} = 0,75.\end{aligned}$$

Ta xóa dòng/cột f_1 và f_4 và thay bằng một dòng/cột mới là $\{f_1; f_4\}$, ta được ma trận khoảng cách mới

	$\{f_1; f_4\}$	f_2	f_3	f_5	f_6	f_7
$D^{(t=1)} =$	$\{f_1; f_4\}$					
	f_2	0,74				
	f_3	0,75	0,75			
	f_5	0,75	0,49	0,74		
	f_6	0,75	0,74	0,38	0,67	
	f_7	0,75	0,29	0,75	0,26	0,72

Tiếp theo, ta thấy $D(f_5; f_7) = 0,26$ là cách nhỏ nhất nên ta xếp hai PDF này thành một

chùm mới $\{f_5; f_7\}$. Tiến hành tính toán liên kết đủ giữa chùm $\{f_5; f_7\}$ với các PDF khác. Ta có

$$\begin{aligned}\Delta(\{f_5; f_7\}; \{f_1; f_4\}) &= \max\{D(f_5; f_1); D(f_5; f_4); D(f_7; f_1); D(f_7; f_4)\} = 0,75, \\ \Delta(\{f_5; f_7\}; f_2) &= \max\{D(f_5; f_2); D(f_7; f_2)\} = 0,49, \\ \Delta(\{f_5; f_7\}; f_3) &= \max\{D(f_5; f_3); D(f_7; f_3)\} = 0,75, \\ \Delta(\{f_5; f_7\}; f_6) &= \max\{D(f_5; f_6); D(f_7; f_6)\} = 0,72.\end{aligned}$$

Ta xóa dòng/cột f_5 và f_7 và thay bằng một dòng/cột mới là $\{f_5; f_7\}$, ta được ma trận khoảng cách mới

	$\{f_1; f_4\}$	f_2	f_3	$\{f_5; f_7\}$	f_6
$D^{(t=2)} =$	$\{f_1; f_4\}$				
	f_2	0,75			
	f_3	0,75	0,75		
	$\{f_5; f_7\}$	0,75	0,49	0,75	
	f_6	0,75	0,74	0,38	0,72

Tiếp theo, ta thấy $D(f_3; f_6) = 0,38$ là cách nhỏ nhất nên ta xếp hai PDF này thành một chùm mới $\{f_3; f_6\}$. Tiến hành tính toán liên kết đủ giữa chùm $\{f_3; f_6\}$ với các PDF khác. Ta có

$$\begin{aligned}\Delta(\{f_3; f_6\}; \{f_1; f_4\}) &= \max\{D(f_3; f_1); D(f_3; f_4); D(f_6; f_1); D(f_6; f_4)\} = 0,75, \\ \Delta(\{f_3; f_6\}; \{f_5; f_7\}) &= \max\{D(f_3; f_5); D(f_3; f_7); D(f_6; f_5); D(f_6; f_7)\} = 0,75, \\ \Delta(\{f_3; f_6\}; f_2) &= \max\{D(f_3; f_2); D(f_6; f_2)\} = 0,75,\end{aligned}$$

Ta xóa dòng/cột f_3 và f_6 và thay bằng một dòng/cột mới là $\{f_3; f_6\}$, ta được ma trận khoảng cách mới

	$\{f_1; f_4\}$	f_2	$\{f_5; f_7\}$	$\{f_3; f_6\}$
$D^{(t=3)} =$	$\{f_1; f_4\}$			
	f_2	0,75		
	$\{f_5; f_7\}$	0,75	0,49	
	$\{f_3; f_6\}$	0,75	0,75	0,75

Tiếp theo, ta thấy $D(\{f_5; f_7\}; f_2) = 0,49$ là cách nhỏ nhất nên ta xếp PDF f_2 này vào chùm $\{f_5; f_7\}$. Tiến hành tính toán liên kết đủ giữa chùm $\{f_2; f_5; f_7\}$ với các PDF khác. Ta có

$$\begin{aligned}\Delta(\{f_2; f_5; f_7\}; \{f_1; f_4\}) &= \max\{D(f_2; \{f_1; f_4\}); D(f_5; \{f_1; f_4\}); D(f_7; \{f_1; f_4\})\} = 0,75, \\ \Delta(\{f_2; f_5; f_7\}; \{f_3; f_6\}) &= \max\{D(f_2; \{f_3; f_6\}); D(f_5; \{f_3; f_6\}); D(f_7; \{f_3; f_6\})\} = 0,75.\end{aligned}$$

Ta xóa dòng/cột f_2 và $\{f_5; f_7\}$ và thay bằng một dòng/cột mới là $\{f_2; f_5; f_7\}$, ta được ma

trận khoảng cách mới

		$\{f_1; f_4\}$	$\{f_2; f_5; f_7\}$	$\{f_3; f_6\}$
$D^{(t=4)} =$	$\{f_1; f_4\}$			
	$\{f_2; f_5; f_7\}$	0,75		
	$\{f_3; f_6\}$	0,75	0,75	

Cuối cùng, ta chọn xếp chòm $\{f_2; f_5; f_7\}$ vào chòm $\{f_3; f_6\}$ dựa vào khoảng cách chính xác nhỏ nhất (4 chữ số thập phân). Vậy ta có chòm $\{f_2; f_5; f_3; f_6\}$. Ta xếp chòm còn lại vào chòm mới này, thuật toán kết thúc.

```
In [4]: import sys
import os

project_root = os.path.abspath("..")
if project_root not in sys.path:
    sys.path.insert(0, project_root)
```

```
In [5]: import numpy as np
from data.data_loader import generateGauss
from utils.integral import grid
from Models.clustering import HCF
```

```
In [ ]: bandwidth = 0.01
grid_x    = grid(bandwidth, start=-5, end=15)
mu        = np.array([0.3, 4.0, 9.1, 1.0, 5.5, 8.0, 4.8])
sig       = np.array([1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0])
F_data    = generateGauss(mu, sig, grid_x)
```

```
In [7]: cluster=HCF.Model(
    grid_x=grid_x,
    max_depth=7,
    distance_metric='L1',
    linkage='complete',
    bandwidth=bandwidth
)
cluster.fit(F_data)
cluster.print_tree()
```

```
├─ root (7 samples): [0, 1, 2, 3, 4, 5, 6]
│   ├── root0 (2 samples): [0, 3]
│   │   ├── root00 (1 samples): [0]
│   │   └── root01 (1 samples): [3]
│   ├── root1 (5 samples): [1, 4, 6, 2, 5]
│   │   ├── root10 (3 samples): [1, 4, 6]
│   │   │   ├── root100 (1 samples): [1]
│   │   │   ├── root101 (2 samples): [4, 6]
│   │   │   │   ├── root1010 (1 samples): [4]
│   │   │   │   └── root1011 (1 samples): [6]
│   │   └── root11 (2 samples): [2, 5]
│   │       ├── root110 (1 samples): [2]
│   │       └── root111 (1 samples): [5]
```

Bài giải Ví dụ 1.6. Cho $c = 3$, $\varepsilon = 10^{-3}$, Các trọng tâm khởi tạo ngẫu nhiên bởi $\theta_1(x) \sim \mathcal{N}(0; 1)$, $\theta_2(x) \sim \mathcal{N}(2; 1)$, $\theta_3(x) \sim \mathcal{N}(5; 1)$. Ta cũng khởi tạo các phần tử trong ma trận $\mathbf{U}$ tuân theo phân bố Dirichlet. Ma trận khoảng cách $\mathbf{D}$ trong đó hàng i là θ_i , cột j là f_j , các khoảng cách được tính bởi $\mathcal{L}_2$ dựa vào trọng tâm và phân vùng.

Khoảng cách $\mathbf{D}^{(t=0)}$ với $\mathcal{L}_2 = \|\mathcal{N}(\mu; 1) - \mathcal{N}(\nu; 1)\|_2 = \left[\frac{1}{\sqrt{\pi}} \left(1 - e^{-(\mu-\nu)^2/4} \right) \right]^{1/2}$, ta có

$$D_{11} = \left[\frac{1}{\sqrt{\pi}} \left(1 - e^{-(0,30)^2/4} \right) \right]^{1/2} = 0,11,$$

$$D_{21} = \left[\frac{1}{\sqrt{\pi}} \left(1 - e^{-(1,7)^2/4} \right) \right]^{1/2} = 0,54,$$

$$D_{31} = \left[\frac{1}{\sqrt{\pi}} \left(1 - e^{-(4,7)^2/4} \right) \right]^{1/2} = 0,75.$$

Tóm lại, ta thu được ma trận khoảng cách $\mathbf{D}$ tại Hình 3.9(b). Hơn nữa, Ma trận phân vùng $\mathbf{U}^{(1)}$ với $m = 2$ cũng được tính toán như sau: Vì không có $D_{ij} = 0$ nên dùng công thức cập nhật từ (1.6), ta có $u_{ij}^{(1)} = \left(\sum_{k=1}^3 \left(\frac{D_{ij}}{D_{kj}} \right)^2 \right)^{-1}$; $\forall j$. Suy ra ta thu được ma trận phân vùng $\mathbf{U}$ (tại Hình 3.9(a)) từ cách tính cho cột $j = 1$ như sau:

$$u_{11} = \left[1 + \left(\frac{0,11}{0,54} \right)^2 + \left(\frac{0,11}{0,75} \right)^2 \right]^{-1} = 0,94,$$

$$u_{21} = \left[\left(\frac{0,54}{0,11} \right)^2 + 1 + \left(\frac{0,54}{0,75} \right)^2 \right]^{-1} = 0,04,$$


$$u_{31} = \left[\left(\frac{0,75}{0,11} \right)^2 + \left(\frac{0,75}{0,54} \right)^2 + 1 \right]^{-1} = 0,02.$$

Gom toàn bộ cột, ta nhận được ma trận phân vùng sau vòng lặp đầu tiên là $\mathbf{U}$. Với chuẩn $\mathcal{L}_2$ trên hàm, theo (1.6). Để tính toán tiêu chuẩn dừng, ta tính theo công thức


$$\left\| \boldsymbol{\mu}^{(t+1)} - \boldsymbol{\mu}^{(t)} \right\| = 0,96.$$

Vì chuẩn này chưa nhỏ hơn tiêu chuẩn dừng, ta tiếp tục lặp lại quá trình trên. Sau $t = 9$ vòng lặp, thuật toán FCF dừng với chuẩn là $6,1 \times 10^{-4}$.

Ta có quá trình biến đổi ở mỗi vòng lặp đối với các trọng tâm ở Hình 3.10. Khác với các điểm rời rạc, trọng tâm FCM chỉ tịnh tiến trong không gian tọa độ, các PDF trọng tâm trong FCF vừa biến dạng hình dạng vừa dịch chuyển vị trí.



Hình 3.9: Minh họa sự cập nhật của ma trận phân vùng và khoảng cách đối với Ví dụ 1.6



Hình 3.10: Thay đổi của trọng tâm chùm FCF qua các vòng lặp

Bảng 3.5: Kết quả so sánh các khoảng cách theo chỉ số ARI đối với Ví dụ 2.1

Khoảng cách	meanrank	median	mad	ci_lower	ci_upper	effect_size	magnitude	effect_size_above	magnitude above
D_H^2	4,0	-0,00	0,02	-0,02	0,9	0,00	negligible	0,00	negligible
$\mathcal{L}_2$	3,9	-0,01	0,01	-0,02	0,9	0,43	small	0,43	small
D_{JS}	3,8	-0,00	0,01	-0,01	0,9	0,01	negligible	-0,56	medium
W_2^2	2,1	0,88	0,12	0,45	1,0	-7,1	large	-7,1	large
D_{BC}	1,2	0,88	0,00	0,88	1,0	-46,7	large	-0,01	negligible

Bảng 3.6: Kết quả so sánh các khoảng cách theo chỉ số *NMI* đối với Ví dụ 2.1

Khoảng cách	meanrank	median	mad	ci_lower	ci_upper	effect_size	magnitude	effect_size_above	magnitude above
D_H^2	4,2	0,03	0,00	0,03	0,9	0,00	negligible	0,00	negligible
$\mathcal{L}_2$	3,9	0,05	0,02	0,03	0,9	-0,91	large	-0,91	large
D_{JS}	3,6	0,05	0,03	0,03	0,9	-0,85	large	0,01	negligible
W_2^2	2,1	0,80	0,18	0,36	1,0	-4,2	large	-4,0	large
D_{BC}	1,2	0,80	0,01	0,79	1,0	-72,8	large	-0,02	negligible

Bảng 3.7: Kết quả so sánh các khoảng cách theo chỉ số *Silhouette* đối với Ví dụ 2.1

Khoảng cách	meanrank	mean	std	ci_lower	ci_upper	effect_size	magnitude	effect_size_above	magnitude above
D_H^2	4,2	0,50	0,03	0,47	0,66	0,00	negligible	0,00	negligible
D_{JS}	4,0	0,50	0,03	0,47	0,66	0,00	negligible	0,00	negligible
$\mathcal{L}_2$	3,5	0,48	0,01	0,43	0,66	0,41	small	0,41	small
W_2^2	2,1	0,62	0,02	0,59	0,66	-3,22	large	-5,01	large
D_{BC}	1,2	0,62	0,01	0,61	0,67	-3,92	large	0,00	negligible

Bảng 3.8: Kết quả so sánh các khoảng cách theo chỉ số Thời gian chạy đối với Ví dụ 2.1

Khoảng cách	meanrank	mean	std	ci_lower	ci_upper	effect_size	magnitude	effect_size_above	magnitude above
D_{BC}	4,6	0,07	0,06	-0,06	0,20	0,00	negligible	0,00	negligible
$\mathcal{L}_2$	3,6	0,12	0,08	-0,05	0,28	-0,65	medium	-0,65	medium
W_2^2	3,6	0,09	0,05	-0,02	0,20	-0,39	small	0,36	small
D_H	2,2	0,37	0,33	-0,32	1,1	-1,24	large	-1,16	large
D_{JS}	1,0	1,2	1,1	-1,0	3,5	-1,5	large	-1,1	large

CHỈ MỤC

- k -means++, 26, 50, 60
- Affinity Bhattacharyya, 18
- bộ mã hóa (encoding), 20
- cây quyết định (decision tree method), 27
- dữ liệu đặc trưng (symbolic data), 4, 33
- giải thích-AI (XAI), 59, 78
- hiệu suất phân cụm (Cluster Validity Indices), 47
- hiệu ứng xi-phông (siphon effect), 77
- hiệu ứng đồng nhất (uniform effect), 39
- hàm cơ sở (basis functions), 27
- hàm hệ số $\beta(x)$ (β -functional coefficient), 27
- hàm Laplace (Laplace function), 7
- hàm mất mát (loss function), 28, 54
- hàm mục tiêu (Objective function), 21, 22, 24, 25, 30, 35, 36, 38, 39, 42–47, 53
- hàm phân vị (quantile function), 5
- hạt nhân χ^2 (Chi-squared kernel), 18
- hạt nhân Bhattacharyya, 18
- hạt nhân chuẩn (Gaussian kernel), 18
- hạt nhân tuyến tính (Linear kernel), 18
- hằng số chặn (intercept), 27
- học không giám sát trực tuyến (Online unsupervised learning), 78
- hồi quy Logistics (Logistics regression method), 27
- khoảng cách Wasserstein (Wasserstein distance), 14
- không gian vector Hilbert (Hilbert vector space), 6
- kiểm định Friedman (Friedman test), 51
- liên kết (linkage), 18, 19, 22, 23, 47, 49, 84, 86–88
- lô dữ liệu nhỏ (mini-batch), 78
- ma trận nhầm lẫn (confusion matrix), 56
- máy vector hỗ trợ (support vector machine), 27
- môi trường ảo (virtual environment), 85
- mức độ phân vùng (membership partition), 24, 25, 38, 41, 53, 54, 57, 63
- nhận dạng không được giám sát (unsupervised recognition), 1, 34
- nhận dạng được giám sát (supervised recognition), 1, 54
- phân biệt Fisher (Fisher discrimination), 27
- phép nhân điểm (point-wise product), 6
- phương pháp hình thang (trapezoidal method), 20
- phương pháp Laplace (Laplace smoothing), 32
- phương pháp Naïve Bayes (Naïve Bayes method), 31
- phương pháp Naïve Bayes (Naïve Bayes method), 27, 30
- quá khớp (overfitting), 26
- siêu tham số (hyper-parametre), 26
- thông minh nhân tạo (AI), 1
- thị giác máy tính (computer vision), 65
- tỷ lệ mất cân bằng (Imbalance Ratio), 37
- vận chuyển tối ưu (optimal transport), 14
- ánh xạ nhiều-đến-một (many-to-one map), 20
- điểm ngoại lệ (outliers), 26
- đặc trưng hình dạng (shape feature), 78
- đặc trưng kết cấu (texture feature), 78
- độ dốc (gradient method), 24

Số: 643/XNTLDL.2025

Cần Thơ, ngày 09 tháng 10 năm 2025

**XÁC NHẬN KẾT QUẢ KIỂM TRA TRÙNG LẬP DỮ LIỆU
CỦA LUẬN VĂN/ĐỀ ÁN TỐT NGHIỆP THẠC SĨ, LUẬN ÁN TIẾN SĨ**

1. Thông tin luận văn/đề án tốt nghiệp thạc sĩ, luận án tiến sĩ

Tên luận văn/đề án tốt nghiệp thạc sĩ, luận án tiến sĩ (LVLA): Nhận dạng thông kê cho hàm mật độ xác suất mất cân bằng và ứng dụng cho dữ liệu ảnh

Tổng số trang (nội dung chính): 72

Ngày kiểm tra: 16:45 08/10/2025

Họ và tên học viên: Trần Nam Hưng

MSHV: M1823002

Ngành: Lý thuyết xác suất và thống kê toán học

Khóa: 30

Chương trình đào tạo: Thạc sĩ ☒

Tiến sĩ ☐

Đơn vị đào tạo (khoa/trường chuyên ngành): Khoa Khoa học Tự nhiên

2. Kết quả kiểm tra

2.1. Tên hệ thống kiểm tra trùng lặp

- KiemTraTaiLieu (tiếng Việt) ☒

- iThenticate (tiếng Anh) ☐

2.2. Kết quả kiểm tra trùng lặp

Tỷ lệ trùng lặp trước khi loại bỏ nguồn	Tỷ lệ trùng lặp sau khi loại bỏ nguồn (*)
2%	1%

(*) Kể cả danh mục trích dẫn do học viên và giảng viên hướng dẫn đề nghị loại bỏ nguồn (nếu có).

3. Kết luận

LVLA có tỷ lệ trùng lặp so với Quy định Liên chính học thuật của Trường	QR code kết quả lượt kiểm tra cuối
☒ Phù hợp ☐ Chưa phù hợp	

Lưu ý: Kết quả trùng lặp phụ thuộc vào dữ liệu hệ thống tại thời điểm kiểm tra.

Người kiểm tra
(Ký và ghi rõ họ tên)

Giám đốc
(Ký và ghi rõ họ tên và đóng dấu)

Trần Minh Thư

Trần Thanh Điện

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM
Độc lập - Tự do - Hạnh phúc

QUYẾT NGHỊ CỦA HỘI ĐỒNG CHẤM LUẬN VĂN THẠC SĨ
(Ghi ngắn gọn các vấn đề chính của luận văn)

Họ và tên học viên: **Trần Nam Hưng** Mã số học viên: M1823002

Ngành: Toán giải tích

Mã ngành: 8460102

Khóa: 2023-2025

Tên luận văn thạc sĩ: Nhận dạng thống kê cho hàm mật độ xác suất mất cân bằng và ứng dụng cho dữ liệu ảnh

Người hướng dẫn: PGS.TS. Võ Văn Tài, Trường Đại học Cần Thơ.

Xác nhận kết quả kiểm tra trùng lặp dữ liệu luận văn thạc sĩ của Nhà Xuất bản:

.2...% trước khi loại bỏ nguồn.

.1...% sau khi loại bỏ nguồn.

Địa điểm bảo vệ: Khoa Khoa học Tự nhiên

Hình thức bảo vệ luận văn: Trực tiếp.

Số lượng thành viên Hội đồng tham dự: 5/5.

1. Ý nghĩa về lý luận, thực tiễn của luận văn:

2. Mức độ đáp ứng yêu cầu của luận văn (chọn 1 trong 3):

- Luận văn đạt: không cần chỉnh sửa

☐

- Luận văn đạt: cần chỉnh sửa theo kết luận của Hội đồng

☒

- Luận văn không đạt

☐

3. Yêu cầu kiểm tra trùng lặp dữ liệu luận văn thạc sĩ sau chỉnh sửa (chọn 1 trong 2):

- Không cần kiểm tra lại trước khi nộp luận văn hoàn chỉnh

☒

- Cần kiểm tra lại trước khi nộp luận văn hoàn chỉnh

☐

4. Kết luận của Hội đồng về việc công nhận trình độ và cấp bằng thạc sĩ cho học viên cao học: Trần Nam Hưng

- Các nội dung chính cần chỉnh sửa (*theo Biên bản Hội đồng chấm luận văn thạc sĩ*).

- Hội đồng thống nhất Ủy quyền cho thư ký kiểm tra và ký xác nhận vào Trang chấp thuận của Hội đồng và Bản giải trình chỉnh sửa của học viên (*nếu có*).

- Đề nghị Nhà trường xem xét công nhận trình độ và cấp bằng thạc sĩ cho học viên Trần Nam Hưng nếu học viên đã hoàn thành việc chỉnh sửa các nội dung mà Hội đồng thông qua theo Quyết nghị này.

- Thư ký đã đọc lại nội dung Quyết nghị này cho tất cả thành viên Hội đồng và nhất trí biểu quyết thông qua Quyết nghị với kết quả 5/5 thành viên đồng ý.
- Chủ tịch Hội đồng tuyên bố kết thúc buổi chăm bảo vệ luận văn thạc sĩ lúc .14... giờ.40 phút cùng ngày.

Cần Thơ, ngày 26 tháng 10 năm 2025

Chủ tịch Hội đồng

Thư ký Hội đồng



TS. Trần Văn Lý




TS. Lê Hoài Nhân

XÁC NHẬN CỦA TRƯỜNG ĐẠI HỌC CẦN THƠ

TL. HIỆU TRƯỞNG

TRƯỞNG KHOA KHOA HỌC TỰ NHIÊN



Ngô Thanh Phong

BẢN GIẢI TRÌNH CHỈNH SỬA LUẬN VĂN THẠC SĨ

(Thông qua Hội đồng bảo vệ luận văn thạc sĩ ngày 26/10/2025)

Họ và tên học viên: **TRẦN NAM HƯNG** Mã số học viên: **M1823002**
Ngành: **Lý thuyết Xác suất và Thống kê Toán học** Mã ngành: **8 46 01 06**
Tên đề tài luận văn Thạc sĩ: **Nhận dạng thống kê cho hàm mật độ xác suất mất cân bằng và ứng dụng cho dữ liệu ảnh**
Người hướng dẫn: **PGs. TS. Võ Văn Tài, Khoa Khoa học Tự nhiên, Đại học Cần Thơ.**

Luận văn đã chỉnh sửa theo ý kiến đóng góp của Hội đồng như sau:

TT	Nội dung góp ý, đề nghị	Nội dung đã chỉnh sửa
1	Bỏ các dẫn nguồn hình ảnh và bảng học viên là tác giả	Các dẫn nguồn ảnh và bảng học viên thực hiện đã được loại bỏ trong luận văn
2	Chỉnh sửa lỗi đánh máy	Các lỗi đánh máy đã được kiểm tra cẩn thận và chỉnh sửa
3	Thống nhất các ký hiệu	Các kí hiệu đã được rà soát để thống nhất cho toàn luận văn
4	Kết cấu Brodatz là gì, học viên hãy mô tả chi tiết dữ liệu và phương pháp giải quyết	Hình ảnh kết cấu Brodatz là bộ hình ảnh các kết cấu vật liệu khác nhau được thu thập bởi Trygve Randen và được lưu trữ tại đường dẫn https://www.uv.uio.no/~tranden/ . Các nghiên cứu trước đây sử dụng bộ hình ảnh kết cấu để nhận dạng và phân loại kết cấu, phân đoạn hình ảnh, và thiết kế ngân hàng bộ lọc. Đến năm 2017, nhóm tác giả Thao Nguyen-Trang sử dụng với mục tiêu phân tích chùm các hình ảnh qua việc cắt ngẫu nhiên và thêm nhiễu Gaussian. Luận văn đã được bổ sung một đoạn giới thiệu cụ thể ở trang 66.
5	Tóm tắt nội dung cần ngắn gọn hơn	Tóm tắt nội dung được lược bỏ từ dòng 1–13, trang iv.

6 Định nghĩa độ nhạy và độ chính xác

Trong bài toán phân loại mất cân bằng, các thước đo truyền thống như độ chính xác tổng thể thường gây sai lệch vì mô hình có thể dự đoán lớp đa số gần như mọi lúc mà vẫn đạt giá trị cao. Do đó, hai chỉ số quan trọng và ổn định hơn cần được sử dụng là *độ nhạy* (sensitivity hoặc recall) và *độ chính xác* (precision). Giả sử bài toán nhị phân có lớp dương là lớp quan tâm, ta ký hiệu số lượng dự đoán đúng dương là TP, dự đoán sai dương là FP và bỏ sót dương là FN. Độ nhạy đo lường khả năng của mô hình trong việc phát hiện đúng các mẫu thuộc lớp dương, được định nghĩa bởi

$$\text{Sensitivity} = \text{Recall} = \frac{TP}{TP + FN}.$$

Chỉ số này đặc biệt quan trọng khi chi phí bỏ sót mẫu dương là lớn, ví dụ trong phát hiện gian lận hoặc chẩn đoán bệnh hiểm. Giá trị độ nhạy cao cho thấy mô hình nhận diện được phần lớn các trường hợp cần quan tâm. Độ chính xác phản ánh mức độ tin cậy của các dự đoán dương, được cho bởi


$$\text{Precision} = \frac{TP}{TP + FP},$$

trong bối cảnh mất cân bằng, độ chính xác giúp đánh giá xem mô hình có tạo ra quá nhiều cảnh báo giả hay không. Khi kết hợp với độ nhạy, hai chỉ số này cung cấp cái nhìn toàn diện hơn về hiệu quả của mô hình trên lớp thiểu số.

Cần Thơ, ngày 9 tháng 11 năm 2025


Người hướng dẫn

(Ký tên)


Lê Văn Tài


Chủ tịch Hội đồng

(Ký tên)


Lê Văn Lý


Tác giả thực hiện


(Ký tên)


Trần Nam Hùng

Thư ký

(Ký tên)


Lê Hoài Nhân



DOI:10.22144/ctujos.2025.111

CẢI TIẾN THUẬT TOÁN TỰ CẬP NHẬT CHÙM CHO CÁC HÀM MẬT ĐỘ XÁC SUẤT

Trần Nam Hưng, Châu Ngọc Thơ và Võ Văn Tài*

Khoa Khoa học Tự nhiên, Đại học Cần Thơ, Việt Nam

*Tác giả liên hệ (Corresponding author): vvtai@ctu.edu.vn

Thông tin chung (Article Information)

Nhận bài (Received): 06/01/2025

Sửa bài (Revised): 29/01/2025

Duyệt đăng (Accepted): 11/05/2025

Title: Improving the cluster self-update algorithm for probability density functions

Author: Tran Nam Hung, Chau Ngoc Tho and Vo Van Tai*

Affiliation(s): College of Natural Science, Can Tho University, Viet Nam

TÓM TẮT

Nghiên cứu được thực hiện nhằm cải tiến thuật toán tự cập nhật chùm cho các hàm mật độ xác suất (PDF) khi tham số trong thuật toán được chọn thích ứng với từng tập dữ liệu thay vì là một hằng số như các thuật toán trước đó. Thuật toán đề nghị được trình bày chi tiết các bước thực hiện và ví dụ số minh họa. Thuật toán đề nghị cũng được áp dụng cho dữ liệu ảnh khi các pixel của chúng được trích xuất và biểu diễn thành các PDF đại diện. Áp dụng cho dữ liệu số và dữ liệu ảnh, thuật toán đề nghị đã cho kết quả tốt và thuận lợi hơn một số thuật toán được công bố gần đây.

Từ khóa: Dữ liệu ảnh, hàm mật độ xác suất, phân tích chùm, tự cập nhật chùm

ABSTRACT

This research improves the cluster self-update algorithm for probability density functions (PDFs) when the parameter is selected based on each dataset rather than being constant, as in previous algorithms. The proposed algorithm is presented in detail with step-by-step procedures and numerical examples. It is also applied to image data, where the pixels are extracted and represented as representative PDFs. Applying numerical examples and images demonstrates that the proposed algorithm obtains good results and outperforms some recently published algorithms.

Keywords: Image data, probability density function, cluster analysis, cluster self-update

1. GIỚI THIỆU

Phân tích chùm là công cụ học không được giám sát, với mục tiêu khai phá và phân bố dữ liệu phi cấu trúc thành các chùm, sao cho những đối tượng trong cùng chùm có được sự tương đồng theo những đặc tính chung nào đó. Trong xử lý dữ liệu lớn, phân tích chùm được xem là nền tảng không thể thiếu nên nó đã và đang nhận được rất nhiều sự quan tâm của các nhà nghiên cứu (Hung et al., 2015; Chen et al., 2020; Le et al., 2023).

Phân tích chùm có thể thực hiện cho dữ liệu điểm, dữ liệu khoảng và dữ liệu hàm mật độ xác suất (PDF). Phân tích chùm cho dữ liệu điểm được đề nghị từ rất sớm, được phát triển rất mạnh cả lý thuyết và ứng dụng (Vo & Nguyen, 2018; Hung et al., 2021; Vo et al., 2023). Trong thực tế, chúng ta cũng lưu trữ nhiều dữ liệu khoảng như giá thấp nhất và cao nhất của cổ phiếu, vàng, đô la. Các dữ liệu thời tiết như nhiệt độ, lượng mưa, độ ẩm,... cũng thường được ghi nhận dưới dạng khoảng. Do đó, việc phân tích chùm cho dữ liệu khoảng đã được đề nghị (Le et al., 2023). Khi dữ liệu lớn, mỗi đối tượng cần

được xem là một phân phối hay dữ liệu phức tạp như hình ảnh có thể được đại diện bởi một phân phối thì phân tích chùm cho các PDF đã được đề nghị (Chen & Hung, 2015; Chen et al., 2020). So với dữ liệu số và dữ liệu khoảng, phân tích chùm cho các PDF được đánh giá phức tạp hơn, đặc biệt là ứng dụng. Sự phức tạp thể hiện trong độ đo đánh giá sự tương tự của các PDF và trong các tính toán. Việc phân tích chùm cho các PDF được nghiên cứu này quan tâm.

Có nhiều thuật toán phân tích chùm khác nhau đã được đề nghị như: thuật toán thứ bậc, không thứ bậc, cực đại hoá kỳ vọng. Khi xây dựng thuật toán phân tích chùm, việc xác định số chùm thích hợp và những phần tử cụ thể trong mỗi chùm là hai vấn đề quan trọng cần phải được giải quyết. Khi hai vấn đề này được thực hiện trong cùng một thuật toán thì nó được gọi là thuật toán tự cập nhật chùm (cluster self-update algorithm, CSU). CSU lần đầu tiên được giới thiệu bởi Chen and Shiu (2007), với ý tưởng đơn giản là các đối tượng thuộc cùng một chùm qua thuật toán hội tụ đến cùng một phần tử. Trong CSU, sự hội tụ của thuật toán cũng như kết quả phân tích chùm phụ thuộc vào một hằng số mà nó được chọn cố định cho tất cả dữ liệu. Sau năm 2015, CSU được phát triển nhanh với nhiều cải tiến mới về vấn đề bán kính lân cận. Chen and Hung (2015) đã phát triển bán kính lân cận bởi giá trị trung bình các khoảng cách. Sự thay đổi này được áp dụng vào dữ liệu hàm mờ và dạng cầu (Hung & Yang, 2015). Việc sử dụng bán kính lân cận bởi trung bình khoảng cách thích ứng được với những tập dữ liệu có nhiều đặc tính khác nhau của thực tế, tuy nhiên nhiều trường hợp vẫn không cho kết quả phân tích chùm thích hợp. Để cải tiến nhược điểm này của chính mình, Shiu and Chen (2016) đã đề nghị mô hình tĩnh và động qua mỗi lần lặp. Sự cải tiến này đã tạo ra sự thích ứng hơn với dữ liệu của thuật toán nên nhận được những kết quả tốt cho nhiều tập dữ liệu. Tuy nhiên, các tham số trong thuật toán của Chen and Chiu (2016) thực chất vẫn là hằng số. Người sử dụng khi thực hiện vẫn phải cài đặt trước ba tham số như bán kính lân cận, tham số hội tụ và hàm hạt nhân.

Về tham số hội tụ trong CSU, một số công bố quan trọng sau đã được quan tâm. Trong Chen and Shiu (2007), tham số này được sử dụng cố định là 1. Với Chen and Shiu (2016), nó được thành lập dựa trên bán kính và số vòng lặp. Một đề nghị đáng chú ý của Chen and Hung (2015) là chọn tham số hội tụ bằng phương sai của từng đôi khoảng cách. Thuật toán cải tiến này cũng được áp dụng cho dữ liệu khoảng bởi Hung et al. (2016), nghiên cứu của Le et al. (2023) cho rằng, việc chọn tham số bằng trung

binh và phương sai chưa giải quyết được vấn đề phát hiện nhiễu nên đã lần lượt thay bằng trung vị và khoảng tứ phân vị. Pham and Vo (2023) tập trung sử dụng tự cập nhật cho mờ hóa dữ liệu chuỗi thời gian với sự thay đổi tham số cho từng trường hợp cụ thể. Tất cả các nghiên cứu trên đều khẳng định rằng việc tham số trong thuật toán CSU quyết định số chùm thích hợp cũng như những phần tử trong mỗi chùm, nhưng việc xác định tối ưu cho nó vẫn là bài toán chưa có lời giải cuối cùng.

Thuật toán CSU được nghiên cứu với những đóng góp chính sau:

(i) Tổng quát hoá việc chọn tham số trong thuật toán CSU, phù hợp với từng tập dữ liệu để tối ưu kết quả xây dựng chùm.

(ii) Ứng dụng cho dữ liệu ảnh khi đặc trưng pixel của chúng được trích xuất để chứng minh sự hiệu quả của thuật toán đề nghị.

2. CÁC VẤN ĐỀ LIÊN QUAN

2.1. Hàm mật độ xác suất trọng tâm

Trong các thuật toán xây dựng chùm cho dữ liệu PDF, việc xác định hàm trọng tâm của các chùm là vấn đề quan trọng. Trong nghiên cứu này, hàm trọng tâm được đề nghị thông qua các định nghĩa sau.

Định nghĩa 1. (Hàm hạt nhân) Hàm ϕ được gọi là hàm hạt nhân khi và chỉ khi nó thoả các điều kiện sau:

- (i) $0 \leq \phi(u, v) \leq 1$; $\phi(u, v) = 1$ khi $u = v$,
- (ii) $\phi(u, v)$ chỉ phụ thuộc vào khoảng cách $d(u, v)$ giữa hai phần tử.
- (iii) $\phi(u, v)$ là hàm nghịch biến theo khoảng cách của $d(u, v)$.

Định nghĩa 2. (Hàm mật độ xác suất trọng tâm) Cho m chùm $\{C_1, C_2, \dots, C_m\}$ của n -PDF $\{f_1, f_2, \dots, f_n\}$, ($m \leq n$). Khi đó, hàm

$$\theta_i = \sum_{i < j} \left(\frac{\phi(f_i, f_j)}{\sum_{i < j} \phi(f_i, f_j)} \times f_j \right), i = 1, 2, \dots, m$$

được gọi là hàm trọng tâm của chùm C_i .

Ta có 2 nhận xét sau:

- Vì hàm $\phi(\cdot)$ không âm và có giá trị trong đoạn $[0; 1]$, nên hàm trọng tâm θ_i cũng không âm.

- Mặt khác ta có

$\sum_{i < j} \frac{\phi(f_i, f_j)}{\sum_{i < j} \phi(f_i, f_j)} = 1, \int f_j(x) dx = 1$ (vì $f(x)$ là một PDF).

Do đó

$$\begin{aligned}\int \theta_i(x) dx &= \int \sum_{i < j} \left(\frac{\phi(f_i, f_j)}{\sum_{i < j} \phi(f_i, f_j)} \times f_j(x) \right) dx \\ &= \left(\sum_{i < j} \frac{\phi(f_i, f_j)}{\sum_{i < j} \phi(f_i, f_j)} \right) \int f_j(x) dx = 1.\end{aligned}$$

Từ hai nhận xét trên, ta kết luận được hàm trọng tâm của một chùm cũng là một PDF.

2.2. Khoảng cách của hai hàm mật độ xác suất

Định nghĩa 3. (Khoảng cách L_1) Cho hai PDF $f_1(x)$ và $f_2(x)$, $x \in \mathbb{R}$. Khi đó, khoảng cách L_1 giữa $f_1(x)$ và $f_2(x)$ được định nghĩa là:

$$\|f_1, f_2\|_1 = \int |f_1(x) - f_2(x)| dx.$$

Từ định nghĩa trên, ta có $0 \leq \|f_1, f_2\|_1 \leq 2$. Khi hai PDF càng xa nhau thì khoảng cách này càng lớn và ngược lại. Nếu hai PDF trùng nhau thì khoảng cách bằng 1 và nếu hai PDF rời nhau hoàn toàn thì khoảng cách này bằng 2.

2.3. Trích xuất ảnh thành hàm mật độ xác suất đại diện

Để nhận dạng ảnh, trước hết chúng ta phải trích xuất đặc trưng của nó. Các đặc trưng của ảnh có thể được sử dụng là hình dạng, màu sắc và kết cấu. Trong nghiên cứu này, đặc trưng màu sắc được sử dụng thông qua các điểm pixel của ảnh.


Sau khi các đặc trưng được trích xuất, chúng ta phải biểu diễn chúng thành một đối tượng nào đó để nhận dạng. Thông thường đối tượng đại diện cho ảnh là ma trận, các điểm và các khoảng. Đối tượng đại diện cho ảnh là PDF được sử dụng với các bước thực hiện cụ thể sau:

Bước 1. Chuyển đổi hình ảnh màu bất kỳ về dạng ảnh màu xám.

Bước 2. Chuyển ma trận điểm ảnh thành một véc tơ cột bằng cách duỗi thẳng tất cả giá trị pixel.

Bước 3. Ước lượng PDF cho mỗi ảnh dựa vào kết quả của Bước 2.

Như vậy, việc nhận dạng hay phân biệt các hình ảnh với nhau dựa vào sự khác biệt màu sắc thông qua các PDF đại diện. Kết quả thể hiện ở Hình 1 minh họa các bước trích xuất đặc trưng pixel của mỗi ảnh thành một PDF.



Hình 1. Minh họa các bước trích xuất mỗi hình ảnh thành PDF

Có nhiều phương pháp tham số và phi tham số để ước lượng PDF. Trong nghiên cứu này, phương pháp hàm hạt nhân, một phương pháp phi tham số được sử dụng phổ biến hiện nay được sử dụng. Với dữ liệu là các điểm $\{x_1, x_2, \dots, x_N\}$, PDF ước lượng theo phương pháp hàm hạt nhân có dạng:

$$\hat{f}(x) = \frac{1}{N} \frac{1}{h} \sum_{i=1}^N K\left(\frac{x - x_i}{h}\right), \quad (1)$$

trong đó,

- x_i là dữ liệu thứ i với $i = 1, 2, \dots, N$,
- h là tham số trơn,
- $K(\cdot)$ là hàm hạt nhân thỏa mãn hai điều kiện

$$K(\cdot) \geq 0 \text{ và } \int K(x) dx = 1.$$

Khi có một tập dữ liệu cụ thể, kết quả ước lượng PDF từ tập dữ liệu này phụ thuộc vào việc chọn tham số trơn và hàm hạt nhân. Mặc dù có nhiều nghiên cứu quan tâm đến hai vấn đề này nhưng vẫn chưa có một phương pháp nào được xem hiệu quả cho tất cả số liệu. Trong nghiên cứu này, hàm hạt nhân được chọn có dạng chuẩn $K(x) = \frac{1}{\sqrt{2\pi}} \exp(-x^2/2)$ và tham số trơn được chọn theo đề nghị của Bowman and Azzalini (1997). Cụ thể, $h = (4/3)^{1/5} \cdot \sigma \cdot N^{1/5}$, với N và σ lần lượt là số phần tử và độ lệch chuẩn của tập dữ liệu.

2.4. Tiêu chuẩn đánh giá chất lượng của thuật toán phân tích chùm

Khi chùm được xây dựng, để đánh giá hiệu quả của các thuật toán phân tích chùm với nhau, có thể căn cứ vào nhiều tham số thống kê. Trong nghiên cứu này, tham số ARI và G-mean được sử dụng.

(i) Chỉ số ARI (*Adjusted Rand Index*) đo mức độ tương đồng giữa kết quả phân chùm của thuật toán và thực tế. Chỉ số này được cho bởi công thức sau:

$$\begin{aligned}ARI &= \frac{\sum_{ij} \binom{n_{ij}}{2} - \left[\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2} / \binom{n}{2} \right]}{\frac{1}{2} \left[\sum_i \binom{a_i}{2} + \sum_j \binom{b_j}{2} \right] - \left[\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2} / \binom{n}{2} \right]}\end{aligned}$$

trong đó,

- n_{ij} : Số phần tử chung giữa chùm thực tế thứ i và chùm của thứ j của thuật toán,
- $a_i = \sum_j n_{ij}$: Tổng số phần tử trong chùm thực tế thứ i ,
- $=$: Tổng số phần tử trong chùm thứ j của thuật toán,
- n : Tổng số phần tử trong tập dữ liệu.
- $:$: Số tổ hợp chập hai của n , biểu thị tổng số cặp mẫu.

ARI có giá trị trong đoạn $[-1; 1]$, với ARI càng lớn thì kết quả phân tích chùm càng tốt và ngược lại. Khi kết quả phân tích chùm hoàn toàn khớp với thực tế thì giá trị của ARI là 1 và ngược lại, khi kết quả phân tích chùm hoàn toàn khác thực tế thì ARI nhận giá trị là -1 . Giá trị ARI bằng 0 khi các đối tượng được phân bổ ngẫu nhiên vào các chùm.

(ii) Độ nhạy (*Sensitivity*) có công thức là $\frac{TP}{TP+FN}$ và độ chuyên (*Specificity*) có công thức là $\frac{TN}{TN+FP}$, trong đó TP là số cặp điểm được phân chùm đúng vào cùng một chùm, FN là số cặp điểm thuộc cùng chùm nhưng bị phân chùm sai, TN là số cặp điểm thuộc các chùm khác nhau và được phân chùm đúng, FP là số cặp điểm thuộc các chùm khác nhau nhưng bị phân chùm sai.

(iii) Chỉ số trung bình nhân (*G-mean*) là căn bậc hai của tích độ nhạy và độ chuyên. Cụ thể:

$$G\text{-means} = \sqrt{Sensitivity \times Specificity}.$$

Ta có $G\text{-means}$ có giá trị $[0; 1]$. $G\text{-means}$ có giá trị càng lớn thì kết quả phân tích chùm càng tốt và ngược lại. Khi $G\text{-means}$ bằng 1 thì kết quả phân tích chùm là hoàn hảo.

3. THUẬT TOÁN PHÂN TÍCH CHÙM ĐỀ NGHỊ

Cho tập n PDF: $F = \{f_1, f_2, \dots, f_n\}$ trong không gian d -chiều. Gọi ϵ là một số dương nhỏ tùy ý và $T \in N^*$ là số lần lặp tối đa của thuật toán. Thuật toán CSU cải tiến cho F gồm bốn bước sau:

Bước 1. Tại vòng lặp $t = 0$, ta gán dãy trọng tâm khởi tạo chính là các PDF ban đầu. Tức là

$$\theta^{(0)} = \{\theta_1^{(0)}, \theta_2^{(0)}, \dots, \theta_n^{(0)}\} \equiv \{f_1^{(0)}, f_2^{(0)}, \dots, f_n^{(0)}\}.$$

Bước 2. Lấy ngẫu nhiên không lặp theo phân phối đều một tập hợp con S của F có lực lượng $\lfloor n/2 \rfloor$.

Bước 3. Tại vòng lặp $t + 1$, nâng cấp trọng tâm $\theta^{(t+1)}$ theo công thức sau:

$$\theta_i^{(t+1)} = \sum_{\theta_j^{(t)} \in S} \left(\frac{\phi(\theta_i^{(t)}, \theta_j^{(t)})}{\sum_{\theta_k^{(t)} \in S} \phi(\theta_i^{(t)}, \theta_k^{(t)})} \times \theta_j^{(t)} \right) \quad (2)$$

với $i, j = 1, 2, \dots, n$, $i \leq j$ và $\phi(\theta_i^{(t)}, \theta_j^{(t)})$ là hàm hạt nhân chặt cụt được xác định bởi

$$\phi(\theta_i^{(t)}, \theta_j^{(t)}) = \begin{cases} \exp(L_1(\theta_i^{(t)}, \theta_j^{(t)})/\lambda) & (a), \\ 0 & (b) \end{cases}$$

với điều kiện của (a) là $L_1(\theta_i^{(t)}, \theta_j^{(t)}) \leq \mu_d \alpha_{ij}(t)$, và điều kiện của (b) là $L_1(\theta_i^{(t)}, \theta_j^{(t)}) > \mu_d \alpha_{ij}(t)$.

Trong hàm hạt nhân chặt cụt, ta có

- $L_1(\theta_i^{(t)}, \theta_j^{(t)})$ là khoảng cách từng đôi giữa hai PDF trọng tâm bất kỳ ở vòng lặp t ,

- $\mu_d = \frac{1}{\binom{n}{2}} \sum_{i < j} L_1(\theta_i^{(t)}, \theta_j^{(t)})$ là trung bình của từng đôi các khoảng cách L_1 ,

- $\alpha_{ij}(t + 1) = \frac{\alpha_{ij}(t)}{1 + \alpha_{ij}(t) \phi(\theta_i^{(t)}, \theta_j^{(t)})}$, $\alpha_{ij}(0) = 1$ là tốc độ học,

- $\lambda = \frac{\sigma_d}{1+t}$ là tốc độ hội tụ, trong đó tham số $\sigma_d = \sqrt{\frac{1}{\binom{n}{2}} \sum_{i < j} (L_1(\theta_i^{(t)}, \theta_j^{(t)}) - \mu_d)^2}$ là phương sai của từng đôi các khoảng cách.

Bước 4. Lặp lại Bước 2 và Bước 3 t lần hoặc điều kiện sau được thỏa:

$$\|\theta^{(t)} - \theta^{(t-1)}\| = \max\{L_1(\theta_i^{(t)}, \theta_j^{(t)})\} < \epsilon, \quad (3)$$

trong đó ϵ là một số dương nhỏ tùy ý. Trong các ví dụ số và ứng dụng của nghiên cứu này, $\epsilon = 10^{-6}$ được chọn.

Khi thuật toán đề nghị kết thúc, nếu $\theta^{(t)}$ có bao nhiêu phần tử thì chúng ta chia tập dữ liệu ban đầu F thành bấy nhiêu chùm. Những phần tử cùng hội tụ về chung một PDF đại diện thì được xếp chung một chùm.

Nhận xét. Ta có một số nhận xét sau về thuật toán đề nghị.

(i) Ở Bước 2, các tập hợp con được chọn chỉ chiếm 50% dữ liệu ban đầu và không ảnh hưởng đến kết quả của thuật toán nhưng lại làm giảm đáng kể

sự lặp lại của thuật toán và tăng khả năng tìm kiếm các đối tượng mới một cách ngẫu nhiên.

(ii) Điều kiện (a) và (b) là một sự cải tiến quan trọng trong thuật toán đề nghị so với các thuật toán trước đó. Bán kính của lân cận $r(t) = \mu_d \alpha_{ij}(t)$ thay đổi qua từng vòng lặp t bởi tốc độ học $\alpha_{ij}(t)$ và co giãn độ lớn với khoảng cách trung bình μ_d thay vì cố định như các thuật toán trước đó. Các lân cận cũng có sự tự cập nhật dựa trên ý tưởng của Self-Organizing Map về lượng tử hóa véc tơ mạng nơ-ron. Khi khoảng cách L_1 của hai PDF bất kỳ lớn hơn bán kính lân cận, trọng tâm đó không được xem xét và gán trọng số là 0. Ngược lại, khi khoảng này nằm trong bán kính cho phép, ta xem xét trọng số và di chuyển trọng tâm.

(iii) Việc chọn $\lambda = \frac{\sigma_d}{1+t}$ cũng là một đóng góp của nghiên cứu này. Thay vì λ là một hằng số cố định (tĩnh), λ trong thuật toán đề nghị được xem là động. Giá trị của nó phụ thuộc vào phương sai của từng đôi khoảng cách (σ_d) và giảm liên tục từ σ_d về 0. Khi vòng lặp t càng lớn, tốc độ hội tụ λ càng nhỏ, làm cho trọng số ϕ càng cao. Từ đó, hàm ϕ giúp các trọng tâm di chuyển chậm hơn. Điều này cho phép thuật toán đề nghị có kết quả hợp lý hơn khi các phần tử có nhiều sự chồng lấp.

4. VÍ DỤ SỐ

4.1. Ví dụ 1

Gọi F là tập gồm 20 PDF có phân phối chuẩn 2 chiều với các véc tơ trung bình được sinh ngẫu nhiên theo phân phối chuẩn và hiệp phương sai theo phân phối đều. Chi tiết dữ liệu mô phỏng xem xét gồm bốn chùm, mỗi chùm gồm 5 PDF lần lượt có véc tơ trung bình như sau:

Chùm 1: $\mu_1 \sim N((-1, -1)^T; 0,05I_2)$,

Chùm 2: $\mu_2 \sim N((1, 1)^T; 0,05I_2)$,


Chùm 3: $\mu_3 \sim N((1, -1)^T; 0,05I_2)$,

Chùm 4: $\mu_4 \sim N((-1, 1)^T; 0,05I_2)$,

trong đó: I_2 là ma trận đơn vị cấp 2. Ma trận hiệp phương sai của các phân phối được xác định như sau:

$$\Sigma = \begin{pmatrix} 0,5 & u/2 \\ u/2 & 0,5 \end{pmatrix}, u \sim U[0, 1].$$

Hình 2a thể hiện đồ thị bề mặt 3D của 20 PDF và Hình 2b là đường đồng mức của chúng.



Hình 2. (a) Đồ thị bề mặt của 20 PDF có phân phối chuẩn hai chiều; và (b) Đường đồng mức của các PDF


Hình 2 cho thấy các PDF ở ví dụ này có tỷ lệ chồng lấp khá cao giữa các nhóm nên có thể là một thách thức cho bài toán phân tích chùm.

Ta lần lượt thực hiện các bước trong thuật toán đề nghị với kết quả thực hiện như sau:

Bước 1. Xây dựng PDF trọng tâm ban đầu trùng với toàn bộ PDF đã cho. Cụ thể, ta có

$$\theta^{(0)} = \{\theta_1^{(0)}, \theta_2^{(0)}, \dots, \theta_{20}^{(0)}\} \equiv \{f_1, f_2, \dots, f_{20}\}.$$

Tính từng đôi các khoảng cách $L_1(\theta_i^{(0)}, \theta_j^{(0)})$ giữa hai trọng tâm bất kỳ, ta nhận được kết quả được thể hiện ở Hình 3.



Hình 3. Ma trận khoảng cách các trọng tâm

Tính khoảng cách trung bình và phương sai của các khoảng cách, ta nhận được kết quả:


$$\mu_d = 1,50 \text{ và } \sigma_d = 0,54.$$

Bước 2. Chia $\lfloor n/2 \rfloor = 10$ PDF một cách ngẫu nhiên theo phân phối đều, tức là ta chọn các PDF trong tập S để khảo sát trọng số, trong đó,

$$S = \{1; 3; 4; 7; 8; 9; 14; 18; 19; 20\}.$$


Bước 3. Vì tại vòng lặp đầu tiên $t = 0$, $\alpha_{ij}(0) = 1$, bán kính lân cận lúc này là $\mu_d = 1,50$ nên tốc độ hội tụ λ có giá trị bằng $\sigma_d = 0,54$. Khi đó, ma trận

ϕ giữa hai trọng tâm thuộc tập hợp S được tính với kết quả thể hiện trong Hình 4.



Hình 4. Ma trận hàm hạt nhân ϕ

Bước 3. Tiến hành nâng cấp các trọng tâm theo công thức (2) ta nhận được sự biến đổi của trọng tâm $\theta_i^{(1)}, i = 1; 2; 3; 4$, trong đó đồ thị đường đồng mức của chúng được thể hiện bởi Hình 5.




Hình 5. Đường đồng mức của các trọng tâm tại vòng lặp thứ nhất ($t = 1$)

Bước 4. Tính điều kiện dừng theo công thức (3), ta có

$$\epsilon = \|\theta^{(1)} - \theta^{(0)}\| = \max |\theta_{ij}^{(1)} - \theta_{ij}^{(0)}| = 0,08.$$

Vì điều kiện dừng chưa thỏa mãn ($\epsilon > 10^{-6}$), nên ta tiếp tục lặp lại Bước 2 và Bước 3 với sự cập nhật của các trọng tâm $\theta_i^{(1)}, i = 1; 2; 3; 4$. Sau 13 vòng lặp, thuật toán hội tụ. Quá trình dừng ứng với giá trị của ϵ qua 13 vòng lặp được mô tả trong Hình 6.




Hình 6. Quá trình dừng của thuật toán đề nghị qua 13 vòng lặp

Chi tiết PDF trọng tâm của một số vòng lặp có các đường đồng mức được trình bày trong Hình 7.

Kết quả thể hiện ở Hình 7 cho thấy rằng sau mỗi vòng lặp, các trọng tâm hội tụ về bốn cụm. Tại vòng lặp thứ 13, chúng ta có bốn trọng tâm một cách rõ ràng. Do đó, ta có bốn cụm. Vì các PDF chung một nhóm ban đầu đều hội tụ về cùng một PDF trọng tâm nên chúng ta cũng có các cụm với các PDF đúng như ban đầu.

Để đánh giá hiệu quả của thuật toán đề nghị so với các thuật toán khác, các chỉ số ARI và $G-Mean$ được xem xét. Thuật toán đề nghị được so sánh với các thuật toán được công bố trong những năm gần đây như thuật toán của Chen and Hung (2015), Hung et al. (2021) và Le et al. (2023). Mỗi thuật toán được thực hiện 30 lần lặp lại và đánh giá kết quả trên trung vị của các hệ số đánh giá. Cụ thể sự khác biệt của các trung vị được kiểm tra dựa vào phương pháp Kruskal-Wallis với mức ý nghĩa 0,05. Kết quả so sánh của các thuật toán cho tập dữ liệu này được trình bày trong Bảng 1.

Bảng 1 cho thấy mức độ hiệu quả của các thuật toán phân tích cụm được xem xét. Về chỉ số ARI , các thuật toán được so sánh đều ở mức rất thấp (0,00 - 0,30), trong khi thuật toán đề nghị đã cho kết quả vượt trội, đạt mức tối ưu ($ARI = 1$). Kết quả kiểm định Kruskal-Wallis chứng minh sự khác biệt trung vị của thuật toán đề nghị với các thuật toán khác với mức ý nghĩa $p < 0,05$. Chúng ta cũng có những nhận xét tương tự về sự vượt trội của thuật toán đề nghị so với các thuật toán khác khi căn cứ vào tham số $G-means$.




Hình 7. Đường đồng mức của các PDF trọng tâm tại một số vòng lặp

Bảng 1. Kết quả phân tích cụm của các thuật toán tự cập nhật cho 20 PDF

Thuật toán	ARI	G-means
Chen and Hung (2015)	0,30	0,71
Hung et al. (2021)	0,30	0,71
Le et al. (2023)	0,85	0,91
Thuật toán đề nghị	1,00	1,00
Kruskal-Wallis	< 0,05	< 0,05

Đường đồng mức các PDF trọng tâm ở vòng lặp cuối cùng cho các thuật toán được so sánh được vẽ, ta nhận được Hình 8.




Hình 8. Trọng tâm ở vòng lặp cuối cùng của các thuật toán

Kết quả được thể hiện ở Hình 8 thể hiện sự khác biệt về mặt trọng tâm của các thuật toán được xem xét và thuật toán đề nghị. Rõ ràng, các thuật toán được so sánh hầu như có xu hướng co lại và cho số lượng chùm thấp. Cụ thể, thuật toán của Chen and Hung (2015) và Hung et al. (2021) cho kết quả hai chùm, trong khi thuật toán của Shiu and Chen (2016) và Le et al. (2023) chỉ cho một chùm duy nhất. Như vậy so với thực tế, các thuật toán được so sánh đã xác định sai số chùm, trong khi thuật toán đề nghị đã thể hiện sự hợp lý trong xác định số chùm với tập dữ liệu này. Hơn nữa, các tham số đánh giá đã cho thấy ưu điểm của nó so với các thuật toán mạnh đã được đề nghị trước đó. Sự khác biệt lớn nhất của thuật toán đề nghị với các thuật toán còn lại

là sự thích ứng trong môi trường các phân tử gần nhau, ít có sự khác nhau về mặt khoảng cách và có sự chồng lấp cao.

4.2. Ứng dụng cho dữ liệu ảnh

Phần này áp dụng thuật toán đề nghị để phân tích chùm cho hình ảnh ba loại trái cây. Các ảnh này được trích từ tập dữ liệu có tên *Natural Color Dataset for Colorization Task* và được tải miễn phí từ website: <https://www.kaggle.com/datasets/tyrionlannisterlzy/natural-color-dataset-for-colorization-task>. Cụ thể, tập dữ liệu được xem xét gồm có 45 ảnh với 15 ảnh quả chuối, 25 ảnh quả lựu và 5 ảnh quả cà tím. Hình 9 minh họa một hình ảnh cho mỗi nhóm.




Hình 9. Ba mẫu hình ảnh của tập dữ liệu ảnh được xem xét

Đầu tiên, chúng ta trích xuất đặc trưng của mỗi ảnh và biểu diễn chúng thành PDF như đã đề nghị. Các PDF nhận được đại diện cho 45 hình ảnh được trình bày ở Hình 9.


Tiếp tục thực hiện từng bước trong thuật toán đề nghị, sau 30 vòng lặp, thuật toán dừng, khi đó ta có được Hình 10.

Hình 10 cho thấy, 45 PDF ban đầu đã hội tụ về ba PDF trọng tâm. Như vậy, thuật toán đề nghị đã cho kết quả ba chùm. Đây là một kết quả phân tích chùm đúng so với thực tế.



Hình 10. Dữ liệu 45 hàm mật độ xác suất được trích xuất từ dữ liệu hình ảnh

Thuật toán đề nghị cũng được so sánh với các thuật toán khác qua các tham số ARI và *G-means* với 30 lần lặp lại. Kết quả so sánh của các thuật toán được trình bày trong Bảng 2.



Hình 11. Các PDF trọng tâm của vòng lặp cuối cùng

Bảng 2. Kết quả phân tích cụm của các thuật toán cho tập dữ liệu ảnh

Thuật toán	ARI	G-means
Chen & Hung (2015)	0,85	0,93
Hung et al. (2021)	-0,02	0,18
Lethikim et al. (2023)	0,82	0,89
Thuật toán đề nghị	0,90	0,95
Kruskal-Wallis	< 0,05***	< 0,05***

Bảng 2 một lần nữa cho thấy thuật toán đề nghị có hiệu quả cao và vượt trội một cách có ý nghĩa so với các thuật toán được so sánh với tập dữ liệu hình ảnh này.

TÀI LIỆU THAM KHẢO (REFERENCES)

- Bowman, A. W., & Azzalini, A. (1997). *Applied smoothing techniques for data analysis: the kernel approach with S-Plus illustrations*. <https://global.oup.com/academic/> Oxford University Press
- Chen, T. L., & Shiu, S. Y. (2007). A new clustering algorithm based on self-updating process. *Proceeding about A statistical Computing, Salt Lake City, Utah 2034*, 1-5. <https://api.semanticscholar.org/CorpusID:18819116>
- Chen, J. H., Chang, Y. C., & Hung, W. L. (2020). A self-organizing clustering algorithm for functional data. *Communications in Statistics-Simulation & Computation*, 49(5), 1237–1263. <https://doi.org/10.1080/03610918.2018.1494280>
- Chen, J. H., & Hung, W. L. (2015). An automatic clustering algorithm for probability density functions. *Journal of statistical computation & simulation*, 85(15), 3047–3063. <https://doi.org/10.1111/stan.12315>
- Chen, T. L., & Shiu, S. Y. (2016). A new clustering algorithm based on self-updating process. In *proceedings Statistical Computing, Salt Lake City, Utah, 2034*, 2038. <https://api.semanticscholar.org/CorpusID:18819116>
- Hung, W. L., Chang-Chien, S. J., & Yang, M. S. (2015). An intuitive clustering algorithm for spherical data with application to extrasolar planets. *Journal of Applied Statistics*, 42(10), 2220–2232. <https://doi.org/10.1080/02664763.2015.1023271>
- Hung, W. L., & Yang, J. H. (2015). Automatic clustering algorithm for fuzzy data. *Journal of Applied Statistics*, 42(7), 1503–1518. <https://doi.org/10.1080/02664763.2014.1001326>
- Hung, W. L., Yang, J. H., & Shen, K. F. (2016). Self-updating clustering algorithm for interval-valued data. In *2016 IEEE International Conference on Fuzzy Systems (FUZZ-IEEE)*, 1494–1500. <https://doi.org/10.1109/FUZZ-IEEE.2016.7737867>
- Hung, W. L., Yang, J. H., Song, I. W., & Chang, Y. C. (2021). A modified self-updating clustering algorithm for application to dengue gene expression data. *Communications in Statistics-Simulation & Computation*, 50(2), 483–500. <https://doi.org/10.1080/03610912018.1563149>


5. KẾT LUẬN

Thuật toán tự cập nhật cụm cho các PDF được cải tiến trong nghiên cứu. Thuật toán đề nghị tập trung việc xác định tham số thích hợp mà các thuật toán trước đó chưa có sự giải quyết triệt để. Với các chọn tham số động, phụ thuộc vào sự biến động mức độ tương tự của các phần tử thông qua độ lệch chuẩn từng đôi khoảng cách giữa các trọng tâm, thuật toán đề nghị có thể thích ứng với nhiều tập dữ liệu khác nhau. Kết quả kiểm tra thuật toán đề nghị qua dữ liệu mô phỏng và dữ liệu ảnh đã cho thấy sự hợp lý của thuật toán. Kết quả so sánh trên các tập dữ liệu này thông qua các tham số đánh giá cũng cho thấy thuật toán đề nghị có ưu điểm vượt trội so với nhiều thuật toán mạnh được công bố trước đó. Trong thời gian tới, thuật toán đề nghị được kiểm tra trên những tập dữ liệu có tính đặc thù như chuỗi thời gian để áp dụng trong xây dựng mô hình dự báo.

LỜI CẢM ƠN

Công trình này được tài trợ bởi Chương trình học bổng đào tạo thạc sĩ, tiến sĩ trong nước của Quỹ Đổi mới sáng tạo Vingroup (VINIF), mã số VINIF.2024.ThS.56.

- Le, K. T. N., Le, H. T., & Vo, V. T. (2023). Automatic clustering algorithm for interval data based on overlap distance. *Communications in Statistics-Simulation & Computation*, 52(5), 2194–2209.
<https://doi.org/10.1080/03610918.2021.1900248>
- Pham, D. T., & Vo, T. V. (2024). Improving fuzzy clustering model for probability density functions using the two-objective genetic algorithm. *Multimedia Tools & Applications* 83, 45291–45314.
<https://doi.org/10.1007/s11042-023-17217-5>.
- Shiu, S. Y., & Chen, T. L. (2016). On the strengths of the self-updating process clustering algorithm. *Journal of Statistical Computation & Simulation*, 86(5), 1010–1031.
<https://doi.org/10.1080/00949655.2015.1049605>
- Vo, T. V., & Nguyen, T. T. (2018). Similar coefficient of cluster for discrete elements. *Sankhya B, The Indian Journal of Statistics*, 80(1), 19 - 36.
<https://doi.org/10.1007/s13571-018-0159-0>
- Vo, T. V., Nguyen, Y. H., Dang, S. (2023). An automatic fuzzy clustering algorithm for discrete elements. *Journal of the Operations Research Society of China*, 11, 309-325.
<https://doi.org/10.1007/s40305-021-00388-z>



DOI:10.22144/ctujos.2024.320

THUẬT TOÁN XÂY DỰNG CHÙM ẢNH DỰA TRÊN CÁC PIXEL MÀU ĐƯỢC TRÍCH XUẤT

Trương Minh Lượng, Nguyễn Kim Ngân, Trần Nam Hưng, Nguyễn Hồng Chi, Phan Như Huỳnh và Võ Văn Tài*

Khoa Khoa học Tự nhiên, Trường Đại học Cần Thơ

*Tác giả liên hệ (Corresponding author): vvtai@ctu.edu.vn

Thông tin chung (Article Information)

Nhận bài (Received): 03/04/2024

Sửa bài (Revised): 31/05/2024

Duyệt đăng (Accepted): 03/07/2024

Title: The clustering algorithm for images based on extracted color pixels

Author(s): Truong Minh Luong, Nguyen Kim Ngan, Tran Nam Hung, Nguyen Hong Chi, Phan Nhu Huynh and Vo Van Tai*

Affiliation(s): Can Tho University

TÓM TẮT

Trong nhiều lĩnh vực, việc phân chia hình ảnh thành các cụm có thể giúp chúng ta phân loại, nhận dạng các đối tượng trong ảnh cũng như phát hiện được những yếu tố bất thường. Nghiên cứu này đề xuất một thuật toán phân tích cụm cho ảnh dựa vào hàm mật độ xác suất (PDF) được ước lượng từ đặc trưng trích xuất. Đầu tiên, ta đưa một ảnh bất kỳ về 4 màu cơ bản (đỏ, xanh lục, xanh lam, xám) để trích xuất đặc trưng pixel tại mỗi điểm ảnh. Tiếp theo, các PDF đại diện cho đặc trưng trích xuất sẽ được ước lượng để đại diện cho ảnh trong nhận dạng. Cuối cùng, một thuật toán phân tích cụm mờ cho các PDF được đề xuất. Thuật toán đề nghị được trình bày từng bước và được áp dụng trên những tập ảnh cụ thể. Các kết quả số cho thấy thuật toán đề nghị hiệu quả và ổn định, có thể ứng dụng cho nhiều lĩnh vực khác nhau của thực tế.

Từ khoá: Hàm mật độ xác suất, khoảng cách, phân tích cụm, trích xuất ảnh

ABSTRACT

In many fields, dividing images into clusters can help us classify, identify objects in the images, and detect anomalies. This study proposes a clustering analysis algorithm for images based on the probability density function (PDF) estimated from extracted features. First, any image is converted into four basic colors (red, green, blue, and gray) to extract pixel features at each point. Next, the PDFs representing the extracted features will be estimated to represent the image in recognition. Finally, a fuzzy clustering algorithm for the PDFs is proposed. The algorithm is presented step by step and applied to specific image sets. Numerical results showed that the proposed algorithm is effective and stable, applicable to various fields of reality.

Keywords: Clustering, distance, extracting images, probability density function

1. GIỚI THIỆU

Phân tích cụm là quá trình phân chia dữ liệu thành các nhóm, gọi là "cụm" dựa trên các đặc

điểm của dữ liệu. Khi đó, những phần tử trong cùng một cụm có sự tương tự nhiều hơn so với những phần tử thuộc các cụm khác (Strehl & Ghosh, 2002; Chen et al. 2018). Trong thời đại bùng nổ

thông tin hiện nay, mỗi ngày chúng ta đều phải lưu trữ và trích xuất một số lượng dữ liệu khổng lồ, do đó phân tích chùm cần phải được thực hiện. Cũng chính vì thế mà phân tích chùm trở thành một hướng phát triển quan trọng của thống kê và khoa học dữ liệu ngày nay (Wu et al., 2013, Nguyen-Trang et al., 2023a).

Đối tượng phân tích chùm có thể được chia thành hai nhóm: dữ liệu số và dữ liệu ảnh. Phân tích chùm cho dữ liệu số đã được đề xuất đầu tiên và được áp dụng rộng rãi ngày nay (Hung & Yang, 2015; Rao & Liu, 2020; Vo-Van & Nguyen-Trang, 2023b). Với sự phát triển mạnh mẽ của các thiết bị ghi hình, dữ liệu ảnh ngày càng trở nên phổ biến. Ảnh đã trở thành dữ liệu đầu vào không thể thiếu cho nhiều cải tiến công nghệ, đặc biệt liên quan đến trí tuệ nhân tạo và tự động hoá. Theo đó, việc phân chia ảnh thành các chùm có ý nghĩa thực tiễn trong nhiều lĩnh vực khác nhau. Trong lĩnh vực y học, phân chia chùm ảnh đóng vai trò quan trọng trong việc phát hiện các bất thường trong hình ảnh được chụp từ các thiết bị y tế như máy siêu âm, máy MRI và CT scanner. Bên cạnh đó, trong các ứng dụng về quản lý và an ninh, việc phân chùm hình ảnh có thể giúp phát hiện và nhận dạng đối tượng hoặc hoạt động đáng chú ý từ các hình ảnh giám sát. Ngoài ra, việc phân chia ảnh từ vệ tinh có thể được sử dụng để theo dõi, quản lý tài nguyên tự nhiên như rừng và đất, nhằm đánh giá sự thay đổi của rừng, phân biệt giữa các loại đất, hay theo dõi mức độ ô nhiễm môi trường, phân tích mật độ dân số, kết cấu đô thị, và các yếu tố khác.

So với dữ liệu số, phân tích chùm cho ảnh có sự phức tạp hơn khá nhiều. Trích xuất ảnh là bước đầu tiên để thực hiện quá trình phân tích chùm. Thông thường, ảnh sẽ được trích xuất thông qua màu sắc, kết cấu và hình dạng (Nguyen-Trang et al., 2023b). Chúng ta không thể khẳng định sử dụng đặc trưng nào để trích xuất ảnh là tốt nhất cho tất cả trường hợp bởi vì nó phụ thuộc vào tập ảnh và mục đích nhận dạng. Khi đặc trưng của ảnh được trích xuất, chúng phải được biểu diễn thành một đối tượng nào đó để nhận diện. Trong đa số các nghiên cứu, đối tượng nhận diện ảnh là ma trận đặc trưng (Izakian et al., 2016; Qi et al., 2016; Rao & Liu, 2020). Nhận dạng ảnh từ ma trận đặc trưng làm cho bài toán phân tích chùm tốn nhiều thời gian để thực hiện và không hiệu quả cho nhiều trường hợp (Xu et al., 2015, Wang et al., 2020). Nhận dạng ảnh từ các vector hoặc khoảng nhiều chiều từ đặc trưng được trích xuất là một sự cải tiến đáng kể so với ma trận số. Những thuật toán phân tích chùm theo hướng này đã cải tiến được tốc độ tính toán và hiệu quả trong một

số trường hợp. Tuy nhiên kết quả không hữu ích cho mọi trường hợp (Montanari & Calò, 2013; Zhu et al., 2021). Nhận dạng ảnh từ hàm mật độ xác suất (PDF) đại diện cho đặc trưng được trích xuất là một sự đột phá, mang đến nhiều lợi ích cho bài toán phân tích chùm. Do đó, hướng nghiên cứu này được sự quan tâm của nhiều nhà thống kê trong thời gian gần đây (Hung & Yang, 2015; Chen and Hung, 2021; Nguyen-Trang et al., 2023b).

Phương pháp phân tích chùm dựa trên hàm mật độ xác suất là một trong những cách tiếp cận để phân chia ảnh thành các nhóm có ý nghĩa. Bằng cách xác định các điểm dữ liệu có mật độ cao trong không gian đặc trưng của ảnh, chúng ta có thể nhận ra các vùng có sự tương đồng và phân chia chúng thành các nhóm riêng biệt. Trong quá trình này, hàm mật độ xác suất được sử dụng để đo lường mức độ "tập trung" của các điểm dữ liệu trong không gian. Các vùng có mật độ cao hơn được coi là các vùng quan trọng và có thể tương ứng với các đối tượng hoặc cấu trúc quan trọng trong ảnh. Bằng cách phân chia ảnh dựa trên các điểm dữ liệu có mật độ cao, chúng ta có thể xác định các vùng có ý nghĩa trong ảnh và nhóm chúng lại với nhau (Vo-Van & Nguyen-Trang, 2018).

Tuy nhiên, tất cả các nghiên cứu về phân tích chùm ảnh dựa trên PDF đại diện đã liệt kê ở trên đều chỉ dựa vào một PDF mà thông thường là PDF đại diện cho màu xám. Việc chỉ dựa vào một màu để trích xuất đặc trưng có thể không phân biệt được sự khác biệt của các ảnh. Chúng ta biết rằng một màu nào đó trong thực tế là sự kết hợp chủ yếu của 3 màu cơ bản RGB (đỏ: Red (R), xanh lục: Green (G), xanh da trời: Blue (B)). Do đó, nếu trích xuất đặc trưng của ảnh cùng lúc từ các màu này có thể cải thiện quá trình nhận dạng, từ đó nâng cao hiệu quả trong xây dựng chùm. Nghiên cứu này khảo sát hiệu quả của thuật toán phân tích chùm ảnh dựa trên đặc trưng được trích xuất từ những không gian màu khác nhau và biểu diễn các đặc trưng này thành các PDF đại diện.

2. CÁC VẤN ĐỀ LIÊN QUAN ĐẾN THUẬT TOÁN ĐỀ NGHỊ

2.1. Ước lượng hàm mật độ xác suất

Có nhiều phương pháp để ước lượng PDF từ dữ liệu rời rạc, bao gồm phương pháp tham số và phi tham số. Trong hai phương pháp trên, phi tham số được xem có nhiều ưu điểm hơn vì không đòi hỏi điều kiện của dữ liệu (Bowman & Azzalini, 1997). Trong các phương pháp phi tham số, hàm hạt nhân được xem là một phương pháp hiệu quả, được sử

dùng phổ biến nhất hiện nay (Nguyen-Trang et al., 2023a). Phương pháp này rất linh hoạt và mạnh mẽ trong việc xử lý dữ liệu không đồng nhất và phức tạp. Về cơ bản, phương pháp này hoạt động bằng cách tạo ra hàm hạt nhân cho từng biến, sau đó kết hợp nhiều hàm hạt nhân để ước lượng PDF cho toàn bộ tập dữ liệu nhiều chiều. Giả sử ta có dữ liệu rời rạc d -chiều, khi đó PDF được ước lượng theo phương pháp hàm hạt nhân có dạng:

$$f(x) = \frac{1}{N} \cdot \frac{1}{h_1 h_2 \dots h_d} \sum_{i=1}^N \prod_{j=1}^d K_j \left(\frac{x_j - x_{ij}}{h_j} \right),$$

trong đó

N là số phần tử của dữ liệu,

d là số chiều,

h_j là tham số trơn của biến thứ j ,

x_j là biến thứ $j, j = 1, 2, \dots, d$,

x_{ij} là dữ liệu thứ i của biến thứ $j, i = 1, 2, \dots, N$,

$K_j(\cdot)$ là hàm hạt nhân của biến thứ j . Hàm hạt nhân phải thỏa mãn hai điều kiện $K_j(x) \geq 0$ và $\int K_j(x) dx = 1$.

Một số hàm hạt nhân phổ biến bao gồm hàm tam giác, chữ nhật, Epanechnikov, song lượng và chuẩn tắc. Hiện tại, chưa có hàm hạt nhân nào được xem là tối ưu cho tất cả các loại dữ liệu. Hầu hết các nghiên cứu hiện tại sử dụng hàm hạt nhân dạng chuẩn:

$$K(x) = \frac{1}{\sqrt{2\pi}} \exp \left(-\frac{x^2}{2} \right).$$

Ngoài ra, việc chọn tham số trơn h cũng là một vấn đề trong quá trình ước lượng PDF. Khi tham số trơn h nhỏ thì PDF ước lượng sẽ kém trơn. Ngược lại, khi h càng lớn thì tính trơn của PDF sẽ tăng lên, nhưng sẽ kém chính xác trong ước lượng. Các nhà toán học khẳng định việc chọn tham số trơn quan trọng hơn việc chọn hàm hạt nhân. Nghiên cứu này sử dụng hàm hạt nhân dạng chuẩn và tham số trơn theo Bowman & Azzalini (1997). Cụ thể tham số trơn của biến thứ j được tính như sau:

$$h_j = \left(\frac{4}{N(d+2)} \right)^{\frac{1}{d+4}} \times \sigma_j,$$

trong đó N là số phần tử của dữ liệu, d là số chiều và σ_j là độ lệch chuẩn của biến thứ j .

2.2. Hàm mật độ xác suất đại diện chòm

Cho $\mathcal{F} = \{f_1(x), f_2(x), \dots, f_n(x)\}$ là tập hợp các PDF với $n \geq 2$. Các PDF cần được xếp vào k chòm $\mathcal{C} = \{C_1, C_2, \dots, C_k\}, k \geq 2$. Hàm đại diện của mỗi chòm được xác định bởi công thức:

$$f_{v_i} = \frac{1}{\sum_{j=1}^n (\mu_{ij})^2} \times \sum_{j=1}^n (\mu_{ij})^2 f_j, i = 1, 2, \dots, k,$$

trong đó μ_{ij} là xác suất để hàm mật độ f_j xếp vào chòm C_i . Khi đó, ta nhận thấy hàm đại diện của nhóm f_{v_i} không âm và $\int_{\mathbb{R}^d} f_{v_i}(x) dx = 1$. Do đó, hàm đại diện của một nhóm cũng là một PDF.

2.3. Độ đo đánh giá sự tương tự của hai hàm mật độ xác suất

Trong không gian xác suất $(\Omega, \mathcal{F}, \mathbb{P})$, với Ω là không gian mẫu, họ $\mathcal{F}$ các tập con đo được của σ -đại số trong Ω và hàm xác suất $\mathbb{P}: \mathcal{F} \rightarrow [0; 1]$ gồm hai PDF f và g . Khi đó, ta có các khoảng cách sau:

Khoảng cách $\mathcal{L}^1$:

$$\begin{aligned} \|f, g\|_1 &= \int_{\mathbb{R}^n} f_{\max}(x) dx - \int_{\mathbb{R}^n} f_{\min}(x) dx \\ &= 2 \left(\int_{\mathbb{R}^n} f_{\max}(x) dx - 1 \right). \end{aligned}$$

Khoảng cách Divergence:

$$\mathcal{D}_{DVG}(f \parallel g) = 2 \int_{-\infty}^{+\infty} \frac{(f(x) - g(x))^2}{(f(x) + g(x))^2} dx.$$

Khoảng cách Kullback-Leibler:

$$\mathcal{D}_{KL}(f \parallel g) = \int_{-\infty}^{+\infty} f(x) \cdot \ln \left(\frac{f(x)}{g(x)} \right) dx.$$

Khoảng cách Jensen-Shannon:

$$\mathcal{D}_{JS}(f \parallel g) = \frac{1}{2} \mathcal{D}_{KL}(f \parallel h) + \frac{1}{2} \mathcal{D}_{KL}(g \parallel h),$$

trong đó $h = \frac{1}{2}(f + g)$.

Khoảng cách Bhattacharyya:

$$\mathcal{D}_B(f, g) = \int_{\mathbb{R}^n} [f(x)g(x)]^{\frac{1}{2}} dx.$$

Các khoảng cách trên được sử dụng để đánh giá sự tương tự của hai PDF. Khi khoảng cách càng nhỏ thì sự tương tự của chúng càng lớn và ngược lại, khoảng cách càng lớn thì sự tương tự của chúng càng nhỏ. Có nhiều nghiên cứu việc chọn khoảng cách tối ưu cho bài toán nhận dạng thống kê. Tuy nhiên, chưa có khoảng cách nào được xem là tốt nhất

cho mọi trường hợp. Nghiên cứu này sử dụng khoảng cách $\mathcal{L}^1$ để xây dựng thuật toán phân loại.


2.4. Vấn đề trích xuất hình ảnh

Trong lĩnh vực thị giác máy tính, có ba yếu tố chính để phân biệt và nhận dạng một hình ảnh. Chúng là màu sắc, kết cấu và hình dạng. Trong số đó, trích xuất đặc trưng màu sắc của hình ảnh được xem là phổ biến, thu hút nhiều sự quan tâm từ cộng đồng nghiên cứu (Nguyen-Trang et al., 2023b).

Về màu sắc, chúng ta có nhiều thang đo khác nhau, trong đó RGB (R: red; G: Green; B: Blue) được xem là phổ biến nhất hiện nay. Mỗi màu có giá trị trong khoảng $[0; 255]$ và một màu thực tế mà chúng ta quan sát được là sự kết hợp của ba màu trên. Như vậy thực tế chúng ta có $256 \times 256 \times 256 = 16777216$ màu khác nhau. Ảnh xám (Gr) cũng là một sự kết hợp của ba ảnh màu RGB.

Điểm ảnh là đơn vị cơ bản của một hình ảnh số. Mỗi điểm ảnh đại diện cho một điểm cụ thể trên bề mặt hình ảnh và chứa thông tin về màu sắc và độ sáng tại điểm đó. Trong hình ảnh số, điểm ảnh thường được biểu diễn bằng các pixel. Mỗi pixel có thể chứa thông tin về màu sắc theo các kênh màu (ảnh màu) hoặc độ sáng (ảnh trắng đen). Một ảnh có pixel càng lớn thì chất lượng ảnh càng tốt.

Trong nghiên cứu này, đặc trưng pixel được sử dụng để nhận dạng cho ảnh và PDF ước lượng từ pixel trích xuất được sử dụng làm phần tử đại diện. Cụ thể, thuật toán trích xuất đặc trưng của ảnh được đề nghị như sau:



Hình 1. Minh họa các bước trích xuất một hình ảnh thành PDF

Thuật toán 1:

Bước 1. Chuyển mỗi ảnh về ảnh R, G, B và Gr.

Bước 2. Trích xuất pixel cho mỗi ảnh từ Bước 1 để có ma trận điểm ảnh cho mỗi trường hợp.

Bước 3. Chuyển ma trận điểm ảnh của mỗi trường hợp thành vector cột.

Bước 4. Ước lượng PDF cho mỗi trường hợp bằng phương pháp hàm hạt nhân.

Như vậy sau thuật toán này, mỗi ảnh có thể được nhận diện bởi 4 PDF. Hình 1 minh họa cho các bước của Thuật toán 1 đề nghị.

2.5. Tiêu chuẩn đánh giá chất lượng của một thuật toán phân tích chùm

Khi có nhiều phương pháp phân tích chùm trên cùng một tập dữ liệu, chúng ta cần phải có sự lựa chọn. Trong nghiên cứu này, chỉ số hạng điều chỉnh (ARI : Adjusted Rand Index) được sử dụng. Đây là tiêu chuẩn được xem phổ biến nhất hiện nay được sử dụng trong đánh giá chất lượng của thuật toán xây dựng chùm (Rand, 1971).

Gọi P là kết quả phân vùng thực tế dựa trên các nhãn đã có sẵn, và Q là kết quả phân vùng của thuật toán, chỉ số ARI được tính bởi công thức:

$$ARI = \frac{a - (a+c)(a+b)/(a+b+c+d)}{((a+c) + (a+b))/2 - (a+c)(a+b)/(a+b+c+d)}$$

Trong công thức trên, a là số các cặp phần tử được xếp vào cùng một chùm ở cả P và Q , b là số các cặp phần tử thuộc cùng một chùm trong P nhưng thuộc vào hai chùm khác nhau trong Q , c là số các cặp phần tử thuộc hai chùm khác nhau trong P nhưng thuộc vào cùng một chùm trong Q , và d là số các cặp phần tử thuộc vào hai chùm khác nhau trong cả P lẫn Q .

Chỉ số ARI có giá trị thuộc $[0,1]$. Nếu giá trị của nó càng lớn thì thuật toán phân tích chùm càng tốt. Nếu giá trị $ARI = 1$ thì kết quả xây chùm là tối ưu.

3. THUẬT TOÁN ĐỀ NGHỊ

Cho N ảnh $\{I_1, I_2, \dots, I_N\}$, khi đó thuật toán phân tích chùm mờ cho các ảnh gồm các bước sau:

Thuật toán 2:

Bước 1. Áp dụng Thuật toán 1, tìm 4 PDF $\{g_{1i}, g_{2i}, g_{3i}, g_{4i}\}$ đại diện cho đặc trưng được trích xuất của ảnh $I_i, i = 1, 2, \dots, N$.

Bước 2. Đặt $f_i = g_{1i} + g_{2i} + g_{3i} + g_{4i}, i = 1, 2, \dots, N$. Khởi tạo các phần tử đại diện của chùm tại vòng lặp $t = 0$.

$$\{f_1, f_2, \dots, f_N\} \equiv \{f_1^{(0)}, f_2^{(0)}, \dots, f_N^{(0)}\} = f^{(0)}.$$

Bước 3. Cập nhật các PDF đại diện theo công thức sau:

$$f_i^{(t+1)} = \frac{\sum_{j=1}^N K_{\lambda}(f_i^{(t)}, f_j^{(t)}) f_j^{(t)}}{\sum_{j=1}^N K_{\lambda}(f_i^{(t)}, f_j^{(t)})}, 1 \leq i \leq N, \quad (1)$$

trong đó

$$K_\lambda(f_i^{(t)}, f_j^{(t)}) = \begin{cases} \exp\left(-\frac{\|f_i^{(t)}, f_j^{(t)}\|_1}{\lambda}\right) & \text{nếu } \|f_i^{(t)}, f_j^{(t)}\|_1 \leq w_s, \\ 0 & \text{nếu } \|f_i^{(t)}, f_j^{(t)}\|_1 > w_s, \end{cases} \quad (2)$$

với $\lambda = \frac{w_s}{5}$, $w_s = \frac{2}{N(N-1)} \sum_{i < j} \|f_i^{(t)}, f_j^{(t)}\|_1$.

Bước 4. Lặp lại Bước 3 cho đến khi

$$\max_i \|f_i^{(t+1)}, f_i^{(t)}\|_1 < \varepsilon.$$

Sau mỗi vòng lặp, các PDF $f_i^{(t+1)}$ sẽ tự cập nhật gần về các PDF đại diện của nó theo công thức (1). Khi Bước 4 dừng, nếu ta có bao nhiêu PDF đại diện thì tập ảnh đã cho sẽ được chia thành bấy nhiêu chùm.

Bước 5. Giả sử sau Bước 4 ta có được k chùm, khi mà trận phân vùng ban đầu $U^{(0)} = [\mu_{ij}^{(0)}]_{k \times N}$ được thiết lập, trong đó các phần tử của ma trận này được tính theo công thức:

$$\mu_{ij}^{(0)} = \begin{cases} 1 & \text{nếu } f_j \in C_i, \\ 0 & \text{nếu } f_j \notin C_i, \end{cases} \quad 1 \leq i \leq k, 1 \leq j \leq N.$$

Bước 6. Tìm phần tử đại diện f_{v_i} của chùm và tính độ rộng chùm giữa mỗi hàm f_{v_i} và các hàm mật độ f_j , trong đó

$$f_{v_i} = \frac{\sum_{j=1}^N (\mu_{ij}^{(0)})^2 f_j}{\sum_{j=1}^N (\mu_{ij}^{(0)})^2}, \quad 1 \leq i \leq k.$$

Bước 7. Cập nhật ma trận phân vùng mờ $U^{(1)}$ theo công thức:

$$u_{ij}^{(1)} = \begin{cases} \frac{1}{\sum_{m=1}^k (\|f_j, f_{v_i}\|_1 / \|f_j, f_{v_m}\|_1)^2} & \text{nếu } \|f_j, f_{v_i}\|_1 > 0, \\ 0 & \text{ngược lại,} \end{cases}$$

trong đó $1 \leq i \leq k, 1 \leq j \leq N$.

Bước 8. Tính giá trị $\|U^{(1)} - U^{(0)}\| = \max_{i,j} \{|\mu_{ij}^{(1)} - \mu_{ij}^{(0)}|\}$. Lặp lại Bước 7 t lần cho đến khi điều kiện dừng sau được thỏa mãn:


$$\|U^{(t+1)} - U^{(t)}\| < \varepsilon.$$

Khi thuật toán kết thúc ta nhận được ma trận $U^{(t)} = [\mu_{ij}^{(t)}]_{k \times N}$ chính là xác suất để xếp ảnh thứ j vào chùm thứ $i, j = 1, 2, \dots, N; i = 1, 2, \dots, k$.

Trong Bước 4 và Bước 8, ε đo sự khác biệt giá trị của hai vòng lặp một cách có ý nghĩa. Nghiên cứu này chọn $\varepsilon = 0,0001$ trong ví dụ số và các áp dụng.

4. VÍ DỤ MINH HỌA


Phần này sử dụng 3 ảnh trùng roi xanh (C_1), 2 ảnh trùng giày (C_2) và 2 ảnh kí sinh trùng sốt rét (C_3) để minh họa các bước của Thuật toán 2. Những loại trùng này đều có vai trò quan trọng trong hệ sinh thái và sức khỏe con người, từ việc là nguồn thức ăn cho các sinh vật khác đến gây bệnh và tác động đến sự phát triển của các quần thể sinh vật. Ảnh mẫu của ba nhóm sinh vật trên được thể hiện ở Hình 2.



Hình 2. Hình ảnh minh họa ba nhóm sinh vật kí sinh trùng sốt rét, trùng giày và trùng roi xanh

Các bước của thuật toán được thực hiện như sau:

Bước 1: Đưa mỗi ảnh về bốn màu cơ bản (xem Hình 3).



Hình 3. Đưa ảnh C1 về bốn màu cơ bản


Trích xuất đặc trưng từng màu và ước lượng các PDF $g_{1i}, g_{2i}, g_{3i}, g_{4i}, 1 \leq i \leq 7$ tương ứng với bốn màu cho mỗi hình ảnh. Trong đó $\{g_{1i}, g_{2i}, g_{3i}, g_{4i}, i = 1, 2, 3\}$ là các PDF đại diện cho C_1 , $\{g_{1i}, g_{2i}, g_{3i}, g_{4i}, i = 4, 5\}$ là các PDF đại diện cho C_2 , $\{g_{1i}, g_{2i}, g_{3i}, g_{4i}, i = 6, 7\}$ là các PDF đại diện cho C_3 . Hình 4 thể hiện 7 PDF được trích xuất từ mỗi màu.

Bước 2: Khởi tạo các phần tử đại diện của chùm tại vòng lặp $t = 0$ bằng cách lấy tổng bốn PDF tương ứng với bốn màu.


$$f_j^{(0)} \equiv g_{1j} + g_{2j} + g_{3j} + g_{4j}, 1 \leq j \leq N.$$

$$\{f_1, f_2, \dots, f_N\} \equiv \{f_1^{(0)}, f_2^{(0)}, \dots, f_N^{(0)}\} = f^{(0)}.$$

Đồ thị các PDF cho bởi Hình 5.




Hình 4. PDF tương ứng với bốn màu



Hình 5. Các PDF tại vòng lặp $t = 0$

Bước 3: Cập nhật các PDF đại diện, kết quả thực hiện của bước này được mô tả trong Hình 6.



Hình 6. Sự hội tụ của 7 PDF vào 3 PDF đại diện

Bước 4: Sau 11 vòng lặp, Bước 3 dừng. Kết quả mô tả các PDF trong 11 vòng lặp của thuật toán được biểu diễn trong Hình 6. Trong vòng lặp cuối cùng, 7 PDF (các đường màu xanh) hội tụ vào 3 PDF đại diện (các đường màu đỏ). Do đó, 7 PDF được chia thành 3 chùm:

$$C_1 = \{f_1, f_2, f_3\}, C_2 = \{f_4, f_5\}, C_3 = \{f_6, f_7\}.$$

Kết quả phân tích chùm này đúng như dữ liệu gốc ban đầu.


Bước 5: Từ kết quả của Bước 4, thuật toán thiết lập ma trận phân vùng ban đầu như sau:

$$U^{(0)} = [\mu_{ij}^{(0)}] = \begin{bmatrix} 1 & 1 & \dots & 0 \\ 0 & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix}.$$

Bước 6, 7, 8: Tìm phần tử đại diện của chùm và cập nhật ma trận phân vùng mờ đến khi thỏa mãn điều kiện dừng. Khi đó ta sẽ có xác suất thuộc mỗi chùm của 7 PDF được trình bày chi tiết trong Bảng 1 và minh họa bởi Hình 7.

Bảng 1. Mối quan hệ mờ giữa 7 PDF và 3 chùm

f	C_1	C_2	C_3
f_1	0,9630	0,0133	0,0237
f_2	0,8982	0,0432	0,0586
f_3	0,9494	0,0206	0,0300
f_4	0,0287	0,9288	0,0425
f_5	0,0239	0,9440	0,0321
f_6	0,0930	0,0832	0,8238
f_7	0,0838	0,0832	0,8331



Hình 7. Xác suất thuộc vào 3 chùm của 7 PDF

Chỉ số đánh giá chất lượng của kết quả phân tích chùm đối với 4 màu Gr, R, G, B là $ARI = 1$.

Thực hiện phân tích chùm tương tự cho 2 màu và 3 màu, ta có Bảng 2.

Bảng 2 cho thấy việc sử dụng các đặc trưng từ các thang màu (Gr, R), (Gr, G), (R, G) và (Gr, R, G) không cho kết quả phân tích chùm tốt, tất cả các trường hợp còn lại đều cho kết quả tối ưu với ARI đều bằng 1.

Bảng 2. Bảng tổng hợp chỉ số ARI trong phân tích chùm cho 7 ảnh

Màu	ARI
Gr	1,0
R	1,0
G	1,0
B	1,0
Gr, R	0,4425
Gr, G	0,4425
Gr, B	1,0
R, G	0,4425
R, B	1,0
G, B	1,0
Gr, R, G	0,4425
Gr, R, B	1,0
Gr, G, B	1,0
R, G, B	1,0
Gr, R, G, B	1,0

5. ỨNG DỤNG

5.1. Áp dụng cho dữ liệu ảnh hạt cà phê


Để minh họa cho thuật toán đề nghị, ta thực hiện phân tích chùm cho hai loại hạt cà phê Arabica và Robusta. Trên thế giới cũng như tại Việt Nam, Arabica và Robusta là hai trong các loại hạt cà phê được trồng phổ biến nhất. Hai loại hạt cà phê này cũng khó phân biệt bằng mắt thường đối với những người không phải chuyên gia. Thuật toán được thực hiện trên tập dữ liệu *Robusta or Arabica* gồm 112 ảnh với 82 ảnh hạt cà phê Arabica và 30 hạt ảnh cà phê Robusta được lấy miễn phí từ website universe.roboflow.com. Mẫu ảnh của hai nhóm được cho bởi Hình 8.



(a) Cà phê Arabica (b) Cà phê Robusta


Hình 8. Hình ảnh minh họa hai loại hạt cà phê

Trích xuất mỗi ảnh thành 4 PDF dựa trên 4 không gian màu cơ bản và phương pháp ước lượng hàm hạt nhân, ta có Hình 9.




Hình 9. PDF cho toàn bộ dữ liệu ảnh RGBGr

Sử dụng hàm đại diện từ 4 PDF cho mỗi ảnh và tìm hàm đại diện cho hai nhóm, ta nhận được Hình 10.



Hình 10. Minh họa hai PDF đại diện

Sau 6 vòng lặp, thuật toán dừng, khi đó ta có hai chùm như tập dữ liệu ảnh gốc ban đầu và xác suất thuộc vào hai chùm của các ảnh được cho bởi Hình 11.



Hình 11. Xác suất thuộc vào hai chùm của 112 ảnh hạt cà phê

Hình 11 một lần nữa cho thấy khả năng phân tích chùm hợp lý của các ảnh khi xác suất thuộc vào chùm đúng của các ảnh đều cao.

Thực hiện phân tích chùm cho trường hợp trích xuất đặc trưng từ 1 màu, 2 màu, 3 màu và 4 màu và

tính chỉ số ARI cho các trường hợp, ta nhận được Bảng 3.

Bảng 3. Chỉ số ARI trong các trường hợp cho tập dữ liệu ảnh cà phê

Màu	ARI
Gr	0,9625
R	0,9625
G	1,0
B	1,0
Gr, R	0,9625
Gr, G	1,0
Gr, B	1,0
R, G	0,9625
R, B	1,0
G, B	1,0
Gr, R, G	0,9625
Gr, R, B	1,0
Gr, G, B	1,0
R, G, B	1,0
Gr, R, G, B	1,0

Từ Bảng 3, ta thấy kết quả phân loại dữ liệu ảnh cà phê của các phương pháp đều rất tốt vì giá trị ARI của nó bằng 0,9625 hoặc bằng 1, trong đó trường hợp sử dụng bốn màu Gr, R, G, B vẫn cho kết quả ổn định tối ưu với giá trị $ARI = 1$.

5.2. Áp dụng cho tập ảnh bệnh đậu mùa khỉ, thủy đậu và sởi

Bộ dữ liệu được trích lọc gồm 60 hình ảnh thuộc các nhóm bệnh về da gồm 30 ảnh đậu mùa khỉ (C_1), 20 ảnh thủy đậu (C_2) và 10 ảnh bệnh Sởi (C_3) từ các tập dữ liệu *Monkeypox*, *Chickenpox*, *Measles* được lấy miễn phí từ website universe.roboflow.com. Tất cả các hình ảnh đều có kích thước 128×128 pixels và ở định dạng kiểu file jpg. Ảnh mẫu của ba nhóm bệnh được thể hiện ở Hình 12.




Hình 12. Hình ảnh minh họa ba loại bệnh đậu mùa khỉ, thủy đậu và bệnh sởi


Sau 8 vòng lặp, thuật toán dừng. Khi đó ta có kết quả phân tích chùm giống như dữ liệu gốc ban đầu và xác suất thuộc vào chùm của mỗi ảnh được cho bởi Hình 14.

Ba loại bệnh Đậu mùa khỉ, Thủy đậu, Sởi đều là các bệnh truyền nhiễm phổ biến gây ra bởi các loại virus khác nhau. Các nhóm bệnh này có thể gây ra các triệu chứng đa dạng, bao gồm sự xuất hiện của mụn đỏ trên. Chúng có thể xuất hiện ở nhiều phần khác nhau của cơ thể và thường đi kèm với các triệu chứng khác như sốt, đau đầu và mệt mỏi. Về mặt hình ảnh biểu hiện bên ngoài, người dân cũng có thể nhầm lẫn 3 bệnh này nên cũng cần thực hiện bài toán phân tích chùm.


Tiến hành trích xuất tập ảnh thành các PDF đối với ảnh G, R, B và Gr, ta có Hình 13.




(a) PDF được trích xuất và đại diện của 3 nhóm từ ảnh R



(b) PDF được trích xuất và đại diện của 3 nhóm từ ảnh G




(c) PDF được trích xuất và đại diện của 3 nhóm từ ảnh B



(d) PDF được trích xuất và đại diện của 3 nhóm từ ảnh Gr

Hình 13. PDF đại diện cho các ảnh và đại diện của mỗi chùm được trích xuất từ các màu RGBGr



Hình 14. Xác suất thuộc vào 3 chùm của 60 ảnh

Hình 14 cũng cho thấy kết quả phân tích chùm khá tốt khi xác suất của ảnh thuộc vào chùm đúng đều cao.

Tính chỉ số *ARI* của các kết quả phân tích chùm trong các trường hợp khác nhau của không gian màu, ta nhận được Bảng 4.

Bảng 4 cho thấy khi sử dụng đặc trưng trích xuất từ một màu Gr, R, hoặc 2 màu (Gr, G), (Gr, B), (R, G), (G, B), hoặc 3 màu (Gr, R, G), (Gr, G, B), hoặc cả 4 màu sẽ cho kết quả phân tích chùm tối ưu vì chỉ số *ARI* có giá trị bằng 1.

Từ ví dụ minh họa và hai ứng dụng trên, chúng ta cũng thấy rằng việc sử dụng 1 màu, hoặc 2 màu hoặc 3 màu chúng ta cũng có thể nhận được kết quả phân tích chùm tốt, nhưng không ổn định. Việc sử dụng cùng lúc đặc trưng trích xuất từ 4 màu có thể mang lại kết quả phân tích chùm ổn định hơn.

TÀI LIỆU THAM KHẢO

- Bowman, A. W., & Azzalini, A. (1997). *Applied smoothing techniques for data analysis: The kernel approach with S-plus illustrations* (Vol. 18). Oxford, England: OUP.
- Chen, J., Chang, Y., & Hung, W. (2018). A robust automatic clustering algorithm for probability density functions with application to categorizing color images. *Communications in Statistics-Simulation and Computation*, 47(7), 2152–2168.
- Chen, J. H., & Hung, W. L. (2021). A jackknife entropy-based clustering algorithm for probability density functions. *Journal of Statistical Computation and Simulation*, 91(5), 861–875.
- Hung, W. L., & Yang, J. H. (2015). Automatic clustering algorithm for fuzzy data. *Journal of Applied Statistics*, 42(7), 1503–1518.

Bảng 4. Bảng tổng hợp chỉ số *ARI* trong phân tích của 60 ảnh

Màu	ARI
Gr	1,0
R	1,0
G	0,6748
B	0,6748
Gr, R	0,3792
Gr, G	1,0
Gr, B	1,0
R, G	1,0
R, B	0,4479
G, B	1,0
Gr, R, G	1,0
Gr, R, B	0,3792
Gr, G, B	1,0
R, G, B	0,4479
Gr, R, G, B	1,0

6. KẾT LUẬN

Nghiên cứu này đã đề xuất phương pháp trích xuất đặc trưng pixel màu sắc của ảnh thành các PDF để đại diện. Các PDF này sau đó được sử dụng để xây dựng thuật toán phân tích chùm cho dữ liệu ảnh. Ví dụ số và ứng dụng cho thấy thuật toán phân tích chùm đề nghị ổn định và hiệu quả, có tiềm năng trong các áp dụng thực tế.

Trong thời gian tới, nghiên cứu sẽ kiểm tra thêm sự hiệu quả của thuật toán trên những tập dữ liệu lớn của thực tế trong những lĩnh vực khác nhau để cải tiến các tham số của mô hình đề nghị. Nghiên cứu cũng sẽ mở rộng việc trích xuất các đặc trưng khác của ảnh để nhận dạng, từ đó cải thiện thuật toán phân tích chùm.

- Izakian, Z., Mesgari, M. S., & Abraham, A. (2016). Automated clustering of trajectory data using a particle swarm optimization. *Computers, Environment and Urban Systems*, 55, 55–65.
- Montanari, A., & Calò, D. G. (2013). Model-based clustering of probability density functions. *Advances in Data Analysis and Classification*, 7(3), 301–319.
- Nguyen-Trang, T., Nguyen-Thoi, T., Nguyen-Thi, K. N., & Vo-Van, T. (2023). Balance-driven automatic clustering for probability density functions using metaheuristic optimization. *International Journal of Machine Learning and Cybernetics*, 14(4), 1063–1078.
- Nguyen-Trang, T., Nguyen-Thoi, T., & Vo-Van, T. (2023). Globally automatic fuzzy clustering for probability density functions and its application

- for image data. *Applied Intelligence*, 53, 18381–18397.
- Qi, X., Li, C. G., Zhao, G., Hong, X., & Pietikäinen, M. (2016). Dynamic texture and scene classification by transferring deep image features. *Neurocomputing*, 171, 1230–1241.
- Rand, W. M. (1971). Objective criteria for the evaluation of clustering methods. *Journal of the American Statistical Association*, 66(336), 846–850.
- Rao, C., & Liu, Y. (2020). Three-dimensional convolutional neural network (3D-CNN) for heterogeneous material homogenization. *Computational Materials Science*, 184, 109850.
- Strehl, A., & Ghosh, J. (2002). Cluster ensembles—A knowledge reuse framework for combining multiple partitions. *Journal of Machine Learning Research*, 3(Dec), 583–617.
- Vo-Van, T., & Nguyen-Trang, T. (2018). Similar coefficient for cluster of probability density functions. *Communications in Statistics-Theory and Methods*, 47(8), 1792–1811.
- Vo-Van, T., & Nguyen-Trang, T. (2018). Similar coefficient of cluster for discrete elements. *Sankhya B*, 80(1), 19–36.
- Wang, X., Zhao, Y., & Pourpanah, F. (2020). Recent advances in deep learning. *International Journal of Machine Learning and Cybernetics*, 11, 747–750.
- Wu, X., Zhu, X., Wu, G. Q., & Ding, W. (2013). Data mining with big data. *IEEE Transactions on Knowledge and Data Engineering*, 26(1), 97–107.
- Xu, L., Hu, Q., Hung, E., Chen, B., Tan, X., & Liao, C. (2015). Large margin clustering on uncertain data by considering probability distribution similarity. *Neurocomputing*, 158, 81–89.
- Zhu, Y., Deng, Q., Huang, D., Jing, B., & Zhang, B. (2021). Clustering based on Kolmogorov–Smirnov statistic with application to bank card transaction data. *Journal of the Royal Statistical Society Series C: Applied Statistics*, 70(3), 558–578.