

BỘ GIÁO DỤC VÀ ĐÀO TẠO
ĐẠI HỌC CẦN THƠ

TRẦN NAM HÙNG

NHẬN DẠNG THỐNG KÊ
CHO HÀM MẬT ĐỘ XÁC SUẤT MẤT CÂN BẰNG
VÀ ỨNG DỤNG CHO DỮ LIỆU ẢNH

LUẬN VĂN TỐT NGHIỆP THẠC SĨ

NGÀNH: LÝ THUYẾT XÁC SUẤT VÀ THỐNG KÊ TOÁN HỌC
MÃ SỐ: 8 46 01 06

NĂM 2025

BỘ GIÁO DỤC VÀ ĐÀO TẠO
ĐẠI HỌC CẦN THƠ

TRẦN NAM HÙNG
MÃ SỐ HỌC VIÊN: M1823002

NHẬN DẠNG THỐNG KÊ
CHO HÀM MẬT ĐỘ XÁC SUẤT MẤT CÂN BẰNG
VÀ ỨNG DỤNG CHO DỮ LIỆU ẢNH

LUẬN VĂN TỐT NGHIỆP THẠC SĨ
NGÀNH LÝ THUYẾT XÁC SUẤT VÀ THỐNG KÊ TOÁN HỌC
MÃ SỐ: 8 46 01 06

CÁN BỘ HƯỚNG DẪN
PGS. TS. VÕ VĂN TÀI

NĂM 2025

CHẤP THUẬN CỦA HỘI ĐỒNG

Luận văn này với tựa đề là “**Nhận dạng thống kê cho hàm mật độ xác suất mất cân bằng và ứng dụng cho dữ liệu ảnh**”, do học viên Trần Nam Hưng thực hiện theo sự hướng dẫn của PGs. TS. Võ Văn Tài. Luận văn đã báo cáo và được Hội đồng chấm luận văn thông qua ngày , tháng , năm . Luận văn đã được chỉnh sửa theo góp ý và được Hội đồng chấm luận văn xem lại.

Thư ký
(Ký tên)*

Ủy viên
(Ký tên)

Phản biện 1
(Ký tên)*

Phản biện 2
(Ký tên)

Người hướng dẫn
(Ký tên)*

Chủ tịch hội đồng
(Ký tên)

*: Ghi đầy đủ học hàm, học vị và họ tên

LỜI CẢM TẠ

Hoàn thành luận văn, em nhận ra hành trình này được viết bên không những bằng tri thức, mà còn là tấm lòng, sự kiên định, và ân nghĩa của bao người theo bước đi của thời gian.

Với sự trân trọng và lòng biết ơn vô cùng, em xin gửi lời cảm ơn chân thành đến thầy hướng dẫn luận văn **PGs. TS. Võ Văn Tài** đã tận tình giảng dạy và tạo điều kiện cho em trong suốt quá trình học tập và nghiên cứu. Em đã làm nên nhờ thầy, thầy truyền phương pháp, truyền lửa, truyền lí tưởng sống cho em. E

Đồng thời, em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến quý quý thầy cô *Khoa Khoa học Tự nhiên - Đại học Cần Thơ*, cô Phạm Bích Như, thầy Nguyễn Hữu Khánh, thầy Trần Văn Lý, và thầy Lâm Hoàng Chương; Quý thầy từ Thành phố Hồ Chí Minh, thầy Lê Sĩ Đồng, thầy Phạm Bích Huy đã dạy em những kiến thức nền tảng, đã không tiếc công chỉ dẫn, trao đổi, định hướng cho em. Em xin cảm ơn TS. Nguyễn Trang Thảo, người anh cả của nhóm nghiên cứu, ThS Thái Minh Trọng, cùng quý đồng nghiệp tại *Viện Khoa học Tính toán và Trí tuệ Nhân tạo - trường Đại học Văn Lang* đã không tiếc công chỉ dẫn, trao đổi, phản biện giúp em có thêm nhiều góc nhìn mới mẻ.

Tôi xin cảm ơn vì Luận văn tốt nghiệp này được tài trợ bởi **Chương trình học bổng đào tạo thạc sĩ, tiến sĩ trong nước của Quỹ Đổi mới sáng tạo Vingroup (VINIF)**, mã số VINIF.2024.ThS.56. Đây không chỉ là sự hỗ trợ vật chất, mà là niềm tin mà Quỹ đã đặt vào thế hệ trẻ trên con đường nghiên cứu khoa học.

Con của mẹ Uyên, cha Trung, của ngoại, nội đã lớn rồi. Con biết những năm tháng qua là những tháng năm sống động nhất cuộc đời vì con là con vẫn là của mẹ, là con của cha, là của nhà mình. Cảm ơn cả nhà vì đã luôn ủng hộ việc học của con và cho con tự do phiêu lưu trên hành trình tri thức. Con cảm ơn mẹ đã nhớ con lúc con đi làm xa, con cảm ơn cha đã âm thầm sửa xe trước ngày con đi. Khi con về, vẫn thơm mùi cơm của Ngoại, và vang tiếng cười của em Thy. Tôi xin cảm ơn tấm lòng thơm thảo của anh Nguyễn Quốc Anh, cảm ơn những đêm cùng thức, cùng dỗi theo cổ vũ em. Người tri kỷ giỏi giang là một món quà quý, cũng là người thầy mà mình phải luôn ghi ơn. Sau cùng, tôi xin cảm ơn bản thân tôi đã luôn cố gắng ngày đêm. Vì tôi biết hạt giống học hành tôi gieo bây giờ đã ra hoa kết trái.

Do khả năng có hạn trong khi nguồn tri thức là vô hạn, luận văn này chắc chắn không tránh khỏi thiếu sót. Em kính mong nhận được góp ý quý báu từ Hội đồng bảo vệ cùng độc giả trong tương lai để luận văn này ngày càng được hoàn thiện. Một lần nữa, em xin chân thành cảm ơn tất cả những người đã đi cùng em qua chặng đường này, và chúc cho tất cả quý vị có sức khỏe, bình an và hạnh phúc.

Cần Thơ, ngày tháng năm

Tác giả

(Ký, họ và tên)

TÓM TẮT NỘI DUNG

Nhận dạng thống kê cho hàm mật độ xác suất là một chủ đề mới và là kiến thức nền tảng nhằm phát triển các hệ thống AI dự đoán hiện nay. Dữ liệu cho nhận dạng thống kê có thể là dữ liệu rời rạc, dữ liệu khoảng, hoặc hàm mật độ xác suất. Trong thực tế, nhiều trường hợp gặp phải dữ liệu mất cân bằng. Khi đó, các mô hình nhận dạng truyền thống dễ dàng bị thiên lệch về lớp đa số, dẫn đến hiệu quả thấp trong việc nhận dạng các lớp thiểu số quan trọng. Luận văn này xây dựng thuật toán phân tích chùm và phân loại cho hàm mật độ xác suất với dữ liệu mất cân bằng, đồng thời, áp dụng các thuật toán này cho dữ liệu hình ảnh khi các đặc trưng đại diện bởi hàm mật độ xác suất. Về phân tích chùm, luận văn đề xuất thuật toán Phân tích chùm mờ cải tiến (IFCF) giải quyết “hiệu ứng đồng nhất” qua việc cải tiến hàm mục tiêu. Luận văn cũng đã thiết lập và chứng minh IFCF hội tụ dựa trên định lý Zangwill, với một số điều kiện ràng buộc về khoảng cách. Về phân loại, luận văn thiết lập mô hình Bayes-IFCF mở rộng của IFCF sang bài toán phân loại có giám sát. Phương pháp này sử dụng ma trận phân vùng mờ từ IFCF để xác định xác suất tiên nghiệm động cho các lớp. Kết quả được đưa ra dưới dạng Ví dụ số, cho thấy IFCF đạt hiệu suất gần như hoàn hảo ($ARI = 1,00; NMI = 1,00$) trên dữ liệu ảnh kết cấu Brodatz và Landsat. Mô hình Bayes-IFCF cũng cho kết quả nhất quán và chính xác cao ($ACC = 1,00; GM = 1,00; F_1 = 1,00$) trong bài toán phân loại màu sắc các loại đất.

Keywords: Statistical Recognition; Probability Density Functions; Supervised Classification; Unsupervised clustering; Images data.

ABSTRACT

Statistical recognition of probability density functions is an emerging field that serves as foundational knowledge for the development of contemporary predictive AI systems. The data utilised in statistical recognition can take the form of discrete values, intervals, or probability density functions. In practice, many situations involve imbalanced data, which can cause traditional recognition models to become biased toward the majority class, ultimately resulting in suboptimal performance in recognising significant minority classes. This thesis develops cluster analysis and classification algorithms tailored for probability density functions, specifically in the context of imbalanced data. It applies these algorithms to image data where the probability density functions represent various features. A key aspect of this work is the enhancement of the objective function to achieve a “uniform effect”. Additionally, the thesis establishes and proves that the Improved Fuzzy C-means Framework (IFCF) converges based on Zangwill’s theorem, subject to certain distance constraints. In terms of classification, the thesis presents an extended Bayes-IFCF model designed for the supervised classification problem. This method utilises a fuzzy partition matrix derived from IFCF to determine prior probabilities for the classes dynamically. Results are illustrated through a numerical example, demonstrating that IFCF achieves near-perfect performance ($ARI = 1,00$; $NMI = 1,00$) on Brodatz and Landsat texture image datasets. Furthermore, the Bayes-IFCF model yields consistent and highly accurate outcomes ($ACC = 1,00$; $GM = 1,00$; $F_1 = 1,00$) in classifying soil colour.

Keywords: Statistical Recognition; Probability Density Functions; Supervised Classification; Unsupervised clustering; Images data

LỜI CAM ĐOAN

Tôi tên là Trần Nam Hưng, là học viên cao học ngành Lý thuyết Xác suất và Thống kê Toán học khóa 2023–2025. Tôi xin cam đoan luận văn này là công trình nghiên cứu khoa học thực sự của bản thân tôi được sự hướng dẫn của PGS. TS. Võ Văn Tài.

Các thông tin được sử dụng tham khảo trong đề tài luận văn được thu thập từ các nguồn đáng tin cậy, đã được kiểm chứng, được công bố rộng rãi và được tôi trích dẫn nguồn gốc rõ ràng ở phần Danh mục Tài liệu tham khảo. Các kết quả nghiên cứu được trình bày trong luận văn/đề án này là do chính tôi thực hiện một cách nghiêm túc, trung thực và không trùng lặp với các đề tài khác cùng cấp đã được công bố trước đây. Tác giả đồng ý về việc Nhà trường có quyền công bố và phổ biến để phục vụ nhu cầu đào tạo, nghiên cứu khoa học (NCKH) và phục vụ cộng đồng.

Tôi xin lấy danh dự và uy tín của bản thân để đảm bảo cho lời cam đoan này.

Cần Thơ, ngày tháng năm

Người hướng dẫn
(Ký tên)

Tác giả thực hiện
(Ký tên)

LÝ LỊCH CÁ NHÂN

1 Lý lịch sơ lược

Họ và tên	Trần Nam Hưng	Giới tính	Nam
Ngày sinh	03/4/2001	Dân tộc	Kinh
Nơi sinh	phường Cái Khế, TP. Cần Thơ	Điện thoại	(+84) 765 143 365
Trình độ	Cử nhân Toán Ứng Dụng	Năm tốt nghiệp	2023
Email	hungm1823002@gstudent.ctu.edu.vn		
Email	namhung34.info@gmail.com (Cá nhân)		
Địa chỉ	Số 86/11B, đường Cách Mạng Tháng Tám, phường Bình Thủy, TP. Cần Thơ		

2 Quá trình Đào tạo

Trình độ	Thời gian	Địa chỉ
THPT	2016–2019	<i>Trường THPT Thực hành Sư phạm – Đại học Cần Thơ.</i> Hệ đào tạo: Chính quy.
Đại học	2019–2023	<i>Khoa Khoa học Tự nhiên – Đại học Cần Thơ.</i> Ngành học: Toán Ứng Dụng; Hệ đào tạo: Chính quy. Trình độ ngoại ngữ: B2
Thạc sĩ	2023–2025	<i>Khoa Khoa học Tự nhiên – Đại học Cần Thơ.</i> Ngành học: Lý thuyết Xác suất và Thống kê Toán học; Hệ đào tạo: Chính quy. Trình độ ngoại ngữ: B2

3 Danh mục các công trình đã công bố

Bài báo khoa học hỗ trợ nội dung luận văn Thạc sĩ của tác giả

- **T. N. Hưng**, C. N. Thơ, và V. V. Tài, “*Cải tiến thuật toán tự cập nhật chùm cho các hàm mật độ xác suất*”, CTU J. Sci., vol 61, số p.h 4, tháng 8 2025,
- T. M. Lượng, N. K. Ngân, **T. N. Hưng**, N. H. Chi, N. N. Huỳnh, và V. V. Tài, “*Thuật toán xây dựng chùm ảnh dựa trên các pixel màu được trích xuất*”, CTU J. Sci., vol 60, số p.h CD Khoa học tự nhiên, tr 98-107, tháng 8 2024.

Bài báo khoa học hỗ trợ liên quan của tác giả

- **Tran-Nam, H.** & Che-Ngoc, H., *A Black-winged Kite Improved Fuzzy Clustering handling Imbalanced Uncertain Data*. IEEE Access (2025). (Revised).
- **Tran-Nam, H.**, Nguyen-Trang, T. & Che-Ngoc, H. *A new possibilistic-based clustering method for probability density functions and its application to detecting abnormal elements*. Sci Rep 14, 17871 (2024). <https://doi.org/10.1038/s41598-024-68323-9>

Cần Thơ, ngày tháng năm

Tác giả

(Ký, họ và tên)

MỤC LỤC

CHẤP THUẬN CỦA HỘI ĐỒNG	i
LỜI CẢM TẠ	ii
TÓM TẮT NỘI DUNG	iv
ABSTRACT	v
LỜI CAM ĐOAN	vi
LÝ LỊCH CÁ NHÂN	vii
DANH SÁCH BẢNG	xi
DANH SÁCH HÌNH VẼ	xiii
DANH SÁCH KÝ HIỆU TOÁN HỌC	xiv
DANH SÁCH TỪ VIẾT TẮT	xv
PHẦN MỞ ĐẦU	1
1 Lý do chọn đề tài	1
2 Mục đích nghiên cứu	2
3 Đối tượng và phạm vi nghiên cứu	2
4 Phương pháp nghiên cứu	2
5 Cấu trúc luận văn	3
PHẦN NỘI DUNG	3
1 KIẾN THỨC CHUẨN BỊ	4
1.1 Hàm mật độ xác suất	4
1.2 Một số hàm mật độ thông dụng	6
1.3 Một số hàm mật độ bổ sung	9
1.4 Ước lượng hàm mật độ xác suất	10
1.5 Độ đo đánh giá sự tương tự của các hàm mật độ xác suất	12
1.5.1 Sự tương tự của hai hàm mật độ xác suất	12
1.5.2 Sự tương tự của nhiều hơn hai hàm mật độ xác suất	17
1.6 Phương pháp số xấp xỉ tích phân	18

1.7	Phân tích chùm cho hàm mật độ xác suất	19
1.7.1	Phân tích chùm không mờ	19
1.7.2	Phân tích chùm mờ (FCF)	22
1.8	Phân loại cho hàm mật độ xác suất	24
1.8.1	Hồi quy logistics	24
1.8.2	Máy véc-tơ hỗ trợ	26
1.8.3	Phương pháp naive Bayes	27
	Tổng kết chương 1	29
2	NHẬN DẠNG THỐNG KÊ CHO HÀM MẬT ĐỘ XÁC SUẤT	
	VỚI DỮ LIỆU MẮT CÂN BẰNG	30
2.1	Giới thiệu dữ liệu hàm mật độ	30
2.2	Giới thiệu bài toán phân tích chùm cho dữ liệu mắt cân bằng	31
2.2.1	Phương pháp phân tích chùm hàm mật độ xác suất	31
2.2.2	Thuật toán	37
2.2.3	Sự hội tụ của thuật toán	37
2.2.4	Tham số đánh giá chất lượng	43
2.2.5	Ví dụ minh hoạ	46
2.3	Giới thiệu bài toán phân loại cho dữ liệu mắt cân bằng	50
2.3.1	Phương pháp phân loại hàm mật độ xác suất	50
2.3.2	Thuật toán	52
2.3.3	Tham số đánh giá chất lượng	53
2.3.4	Ví dụ minh hoạ	54
	Tổng kết chương 2	59
3	ỨNG DỤNG CHO DỮ LIỆU HÌNH ẢNH	60
3.1	Trích xuất đặc trưng của hình ảnh thành hàm mật độ xác suất	60
3.1.1	Vấn đề trích xuất đặc trưng của hình ảnh	60
3.1.2	Ước lượng hàm mật độ xác suất đại diện cho hình ảnh	60
3.2	Ứng dụng của bài toán phân tích chùm	63
3.2.1	Dữ liệu	63
3.2.2	Phương pháp thực hiện	64
3.2.3	Kết quả thực hiện	64
3.3	Ứng dụng của bài toán phân loại	68
3.3.1	Dữ liệu	68
3.3.2	Phương pháp thực hiện	69
3.3.3	Kết quả thực hiện	69
	Tổng kết chương 3	70
	PHẦN KẾT LUẬN	71
	TÀI LIỆU THAM KHẢO	72
	PHỤ LỤC	79
	CHỈ MỤC	93

DANH SÁCH BẢNG

1.1	Một số hàm hạt nhân phổ biến dùng trong ước lượng mật độ hạt nhân . .	11
1.2	Bảng tổng kết các loại khoảng cách và các chỉ số khác giữa hai hàm mật độ xác suất	13
1.3	Các kết quả khoảng cách giữa hai hàm mật độ đều trong bốn tình huống vị trí đối với Ví dụ 1.1	16
1.4	Bảng tổng kết các loại liên kết Δ giữa hai chùm hàm mật độ xác suất $\mathcal{F}$ và $\mathcal{G}$	17
1.5	Các phép đo khoảng cách giữa liên kết chùm $(\mathcal{F} \cup \mathcal{G})$ và chùm hàm $\mathcal{H}$	18
1.6	Tổng kết các tương tự giữa các chùm hàm mật độ xác suất	18
1.7	So sánh độ phức tạp của ba thuật toán phân chùm	24
2.1	Tổng quan giai đoạn 5 năm (2019–2024) nghiên cứu phân tích chùm cho hàm mật độ xác suất	32
2.2	Các công thức trọng tâm tương ứng với các loại khoảng cách	40
2.3	Các chỉ số đánh giá độ tương đồng giữa hai phân hoạch	45
2.4	So sánh hiệu suất phân chùm của IFCF qua các loại khoảng cách và các tỷ lệ IR đối với Ví dụ 2.1	47
2.5	Tổng quan phương pháp phân loại cho hàm mật độ xác suất	51
2.6	Mô tả các chỉ số đánh giá phân loại	54
2.7	Phân bố số lượng và tỷ lệ hàm mật độ trong tập huấn luyện và kiểm tra đối với Ví dụ 2.2.	56
3.1	Cấu hình thuật toán phân chùm cho phân tích so sánh	64
3.2	So sánh các thuật toán đề xuất và các thuật toán cơ sở đối với Ví dụ 3.2 .	66
3.3	Kết quả so sánh các mô hình Bayes với các tiên nghiệm khác nhau đối với Ví dụ 3.3	69
3.4	Một số hàm cơ sở $\psi_m(x)$ phổ biến trong hồi quy logistic cho dữ liệu hàm mật độ	79
3.5	Kết quả so sánh các khoảng cách theo chỉ số ARI đối với Ví dụ 2.1 . . .	89
3.6	Kết quả so sánh các khoảng cách theo chỉ số đối với NMI Ví dụ 2.1 . .	89
3.7	Kết quả so sánh các khoảng cách theo chỉ số $Silhouette$ đối với Ví dụ 2.1	90
3.8	Kết quả so sánh các khoảng cách theo chỉ số Thời gian chạy đối với Ví dụ 2.1	90

DANH SÁCH HÌNH VẼ

1.1	Minh họa hai hàm mật độ xác suất đại diện một chùm hàm mật độ $\mathcal{F}$.	10
1.2	So sánh các hàm hạt nhân và hệ số trơn trong ước lượng mật độ xác suất	12
1.3	Dãy khoảng cách $D(f_1; f_2)$ giữa hai hàm mật độ Gauss $\mathcal{N}(0; 1)$ và $\mathcal{N}(\mu; 1)$	14
1.4	Các trường hợp trong khoảng cách giữa hai hàm mật độ đều $f_1(x)$ và $f_2(x)$ đối với Ví dụ 1.1.	15
1.5	Kết quả phân chùm KCF đối với Ví dụ 1.4	21
1.6	Kết quả phân cấp thứ bậc tích tụ HCF đối với Ví dụ 1.5	22
1.7	Biểu đồ phân vùng mờ theo khoảng cách D_{1j} với các hệ số m khác nhau.	23
1.8	Hàm $\hat{\beta}(x)$ được ước lượng qua 10 hàm cơ sở Gauss.	26
2.1	Quan hệ giữa tỷ lệ mất cân bằng và quy mô chùm có số lượng chiếm ưu thế	34
2.2	Ảnh hưởng của dữ liệu hàm mật độ Gauss mất cân bằng lên FCF ($m = 2; c = 3; D = \mathcal{L}_2$)	36
2.3	Minh họa các công thức trọng tâm theo khoảng cách	40
2.4	Ảnh hưởng của tham số mờ m trong EM-IFCM qua IR	42
2.5	Một số chỉ số đánh giá và số chùm tối ưu	45
2.6	Dữ liệu tại Ví dụ 2.1	46
2.7	Đánh giá thống kê các chỉ số cho Ví dụ 2.1	48
2.8	Kết quả tham số m qua các chỉ số đánh giá đối với Ví dụ 2.1	49
2.9	Đánh giá thống kê các chỉ số so sánh thuật toán cho Ví dụ 2.1	50
2.10	Minh họa dữ liệu Ví dụ 2.2	55
2.11	Quá trình biến đổi của các trọng tâm đối với Ví dụ 2.2	56
2.12	Kết quả ANOVA cho các chỉ số phân loại đối với Ví dụ 2.2	59
3.1	Minh họa quá trình chuyển đổi dữ liệu ảnh thành hàm mật độ dựa trên màu sắc.	61
3.2	Minh họa quá trình chuyển đổi dữ liệu ảnh thành hàm mật độ dựa trên khối màu.	62
3.3	Các hình ảnh được cắt từ tập dữ liệu Brodatz.	63
3.4	Hình ảnh thực tế và các hàm mật độ xác suất trích xuất từ khối màu	64
3.5	Ma trận phân vùng của các phương pháp tại $IR = 80$	65
3.6	Khảo sát sự biến đổi của tham số đối với Ví dụ 3.1	66
3.7	Phương pháp IFCF được đề xuất áp dụng cho ảnh Landsat	67
3.8	Dữ liệu phân loại màu sắc của các loại đất đối với Ví dụ 3.3	69
3.9	Khởi tạo ngẫu nhiên của FCF	87
3.10	Vòng lặp $t = 1$ của FCF	88

3.11	Vòng lặp $t = 9$ của FCF	88
3.12	Thay đổi của trọng tâm chùm FCF qua các vòng lặp	89

DANH SÁCH KÝ HIỆU TOÁN HỌC

Ký hiệu	Mô tả
$X; Y; Z; S$	Biến ngẫu nhiên
Y	Tập nhãn của dữ liệu (đối với bài toán phân loại)
$D; U; U^\top$	Ma trận, ma trận chuyển vị
$\mathcal{F}; \mathcal{G}; \mathcal{H}; \mathcal{P}; \mathcal{Q}$	Tập hợp
$\#\mathcal{F}, \#c$	Lực lượng của tập hợp $\mathcal{F}$, số phần tử của chùm c
$\mathbb{R}; \mathbb{R}_{>0}; \mathbb{N}; \mathbb{N}_{>0}$	Số thực, số thực dương, số tự nhiên, số tự nhiên dương
$\mathbb{E}(\cdot)$	Kỳ vọng của biến ngẫu nhiên
$\text{Var}(\cdot)$	Phương sai của biến ngẫu nhiên
$\text{Trace}(\cdot)$	Vết của ma trận
$ \cdot $	Định thức của ma trận
$f \oplus g$	Toán tử tích chập giữa hai hàm mật độ f và g
$\mathbf{1}_{\{\cdot\}}$	Hàm logic (bằng 1 nếu thỏa điều kiện $\{\cdot\}$, ngược lại là 0)
$\text{sign}(\cdot)$	Hàm xét dấu (bằng +1 nếu thỏa điều kiện $(\cdot)$, ngược lại là -1)
$\ell(\cdot)$	Hàm mất mát
$\mathcal{L}(\cdot)$	Hàm L'Arange
$\langle \cdot; \cdot \rangle$	Tích trong của hai ma trận

Các ký hiệu đã được thống nhất, các ký hiệu khác sẽ được làm rõ trong luận văn

DANH SÁCH TỪ VIẾT TẮT

Từ viết tắt	Nghĩa Tiếng Việt	Nghĩa Tiếng Anh
AI	Trí thông minh nhân tạo	Artificial Intelligence
CVI	Chỉ số đánh giá phân tích cụm	Clustering Validation Indices
KCF	Thuật toán k -means cho hàm mật độ xác suất	k -means for probability density Function
FCF	Thuật toán phân cụm mờ cho hàm mật độ xác suất	Fuzzy c -means for probability density Function
HCF	Thuật toán phân cấp thứ bậc cho hàm mật độ xác suất	Hierarchical Clustering for probability density Function
IFCF	Thuật toán phân cụm mờ cải tiến cho hàm mật độ xác suất	Improved Fuzzy c -means for probability density Function
SUP	Thuật toán phân cụm tự cập nhật	Self-Updating Processing
XAI	Thông minh nhân tạo giải thích được	eXplainable Artificial Intelligence

PHẦN MỞ ĐẦU

1 Lý do chọn đề tài

Nghiên cứu – phát triển các nguyên tắc và ứng dụng hệ thống thông minh nhân tạo (AI) là yếu tố then chốt nhằm thúc đẩy tăng trưởng kinh tế bền vững ở các quốc gia [1, 2]. Với khả năng ứng dụng đa ngành – đa chiều, AI không chỉ cải thiện năng suất lao động mà còn mở ra nhiều cơ hội việc làm, góp phần xây dựng nền kinh tế số [3], nâng cao tiện ích, thu nhập, và chất lượng cuộc sống [4]. Trong sự phát triển của AI dự đoán, nhận dạng thống kê được xem là một trong những kiến thức nền tảng.

Nhận dạng thống kê giải quyết hai bài toán chính bao gồm nhận dạng được giám sát và không được giám sát [5, 6]. Nhận dạng không được giám sát là việc chia dữ liệu thành các nhóm sao cho các phần tử trong cùng một nhóm đó có sự tương tự nhiều hơn so với các phần tử bên ngoài nhóm [7, 8]. Do đó, nó còn được gọi là bài toán phân tích chùm. Phân tích chùm là cơ sở của việc lưu trữ, trích xuất và xử lý dữ liệu lớn nên được rất nhiều nhà thống kê và công nghệ thông tin quan tâm. Nhận dạng được giám sát là việc xếp một phần tử vào một lớp trong các lớp đã biết một cách thích hợp [5, 9]. Do đó, nó còn được gọi là bài toán phân loại. Phân loại đã và đang được áp dụng trong nhiều lĩnh vực khác nhau. Chẳng hạn, trong y tế hoạt động chẩn đoán bệnh của các bác sĩ xem một người có bệnh hay không có bệnh B, loại nào trong bệnh B thực chất là thực hiện bài toán phân loại. Trong lĩnh vực xã hội và an ninh, việc nhận dạng khuôn mặt, chữ ký, dấu vân tay của một người cũng chính là thực hiện bài toán phân loại.

Dữ liệu cho nhận dạng thống kê có thể là dữ liệu rời rạc, dữ liệu khoảng và hàm mật độ xác suất. Nhận dạng thống kê cho dữ liệu rời rạc đã được xem xét đầu tiên đã và đang được nghiên cứu tiên phong [7, 10, 11]. Trong thực tế, chúng ta cũng lưu trữ nhiều dữ liệu khoảng như nhiệt độ, lượng mưa, giá chứng khoán nên nhận dạng cho kiểu dữ liệu khoảng đã được đề xuất và phát triển [12]. Khi dữ liệu lớn và phức tạp như hình ảnh, đối tượng hình ảnh có thể được xem là một hàm mật độ xác suất trong một số phương pháp biểu diễn [13], do đó nhận dạng thống kê cho hàm mật độ xác suất được đề xuất.

Xét về số lượng phần tử trong các nhóm/lớp, dữ liệu có thể được gọi là mất cân bằng và không mất cân bằng. Khi số lượng phần tử của các nhóm/lớp không có sự chênh lệch nhiều thì nó được gọi là không mất cân bằng. Tuy nhiên, trong nhận dạng dữ liệu

của thực tế, nhiều trường hợp chúng ta gặp phải dữ liệu mất cân bằng. Đó là kiểu dữ liệu có một hoặc một số ít nhóm/lớp chứa số lượng phần tử quá nhỏ so với các nhóm còn lại [14]. Chẳng hạn, trong tầm soát ung thư, ca bị bệnh có thể ít hơn 1000 lần so với trường hợp không bị bệnh [16]. Trong trường hợp này, độ chính xác của các nhóm/lớp thiểu số là quan trọng hơn [14], bởi vì việc tầm soát sai người mắc ung thư là khỏe mạnh gây ra tổn thất tính mạng lớn hơn nhiều so với tầm soát sai người không mắc. Trong khi đó, mô hình nhận dạng phải đối mặt với chênh lệch lớn về số lượng mẫu, nó dễ dàng bị thiên lệch về nhóm/lớp đa số, dẫn đến hiệu quả thấp trong việc nhận dạng các mẫu thiểu số [15]. Tức là, các thuật toán nhận dạng truyền thống sẽ không phát huy hiệu quả.

Nhận dạng thống kê cho dữ liệu mất cân bằng với các phần tử rời rạc đã được quan tâm trong những năm gần đây. Tuy nhiên với dữ liệu hàm mật độ xác suất hầu như chưa được xem xét. Từ sự phân tích trên, đề tài **“Nhận dạng thống kê cho hàm mật độ xác suất mất cân bằng và ứng dụng cho dữ liệu hình ảnh”** được chọn làm luận văn tốt nghiệp.

2 Mục đích nghiên cứu

- Xây dựng thuật toán phân loại và phân tích chùm cho hàm mật độ xác suất với dữ liệu mất cân bằng;
- Áp dụng hai thuật toán trên cho dữ liệu hình ảnh khi các đặc trưng của nó được trích xuất và đại diện bởi hàm mật độ xác suất để nhận dạng.

3 Đối tượng và phạm vi nghiên cứu

3.1 Đối tượng nghiên cứu

- Thuật toán phân loại và phân tích chùm với dữ liệu mất cân bằng;
- Dữ liệu hình ảnh được trích xuất thành các đối tượng đại diện.

3.2 Phạm vi nghiên cứu

- Các thuật toán phân tích chùm và phân loại cho hàm mật độ xác suất;
- Dữ liệu hình ảnh được trích xuất thành hàm mật độ xác suất đại diện;
- Vấn đề tính toán của các phương pháp phân loại, phân tích chùm.

4 Phương pháp nghiên cứu

- *Nghiên cứu lý thuyết*: Phân tích – tổng kết, phân loại – hệ thống hóa kiến thức về lĩnh vực nhận dạng thống kê; So sánh đánh giá ưu điểm và nhược điểm của các thuật toán.

- *Thực nghiệm khoa học*: Thực hiện các ví dụ số minh họa lý thuyết trong môi trường mô phỏng nhằm đánh giá các mô hình nhận dạng qua nhiều tiêu chí cụ thể, từ đó xử lý so sánh kết quả bằng các phân tích thống kê.

5 Cấu trúc luận văn

Luận văn bao gồm phần mở đầu, phần nội dung và phần kết luận, trong đó phần nội dung gồm ba chương:

Chương 1. *Kiến thức chuẩn bị*

Chương 2. *Nhận dạng thống kê cho hàm mật độ xác suất với dữ liệu mất cân bằng*

Chương 3. *Ứng dụng cho dữ liệu hình ảnh*

CHƯƠNG 1

KIẾN THỨC CHUẨN BỊ

1.1 Hàm mật độ xác suất

Hàm mật độ xác suất là khách thể nghiên cứu của một số nhà thống kê hiện đại [17–19]. Nó là một phần của dữ liệu đặc trưng bao gồm hữu hạn các xác suất, khoảng và hàm mật độ [18]. Ở đây, luận văn chỉ hệ thống hóa những kiến thức có liên quan.

Định nghĩa 1.1 (Biến ngẫu nhiên). Một biến ngẫu nhiên X trong không gian xác suất $(\Omega; \mathcal{E}; \mathbb{P})$ là một hàm Borel đo được từ Ω đến $\mathbb{R}$, tức là $X : (\Omega; \mathcal{E}) \rightarrow (\mathbb{R}; \mathcal{B}(\mathbb{R}))$.

Tương tự, ta mở rộng biến ngẫu nhiên d -chiều cho véc-tơ $\mathbf{X} = (X_1; X_2; \dots; X_d)$ trong $\mathbb{R}^d$, với mỗi thành phần $X_i; (i = 1; 2; \dots; d)$ là biến ngẫu nhiên trên $(\Omega, \mathcal{E}, \mathbb{P})$, nhận giá trị trong $\mathbb{R}$.

Định nghĩa 1.2 (Biến ngẫu nhiên d -chiều). Biến ngẫu nhiên d -chiều là một hàm Borel đo được từ không gian xác suất đến không gian Euclid $\mathbb{R}^d$, tức là $\mathbf{X} : (\Omega; \mathcal{E}) \rightarrow (\mathbb{R}^d; \mathcal{B}(\mathbb{R}^d))$.

Định nghĩa 1.3 (Hàm phân phối). Hàm phân phối của biến ngẫu nhiên X là hàm $P := P_X : \mathbb{R} \rightarrow [0; 1]$ được định nghĩa bởi $P(x) = P\{\omega : X(\omega) \leq x\}; \forall x \in \mathbb{R}$.

Tính chất 1.1. Phân phối P thỏa các tính chất sau

1. P không giảm, tức là nếu $s_1 \leq s_2$ thì $P(s_1) \leq P(s_2)$;
2. $\lim_{x \rightarrow \infty} P(x) = 1$ và $\lim_{x \rightarrow -\infty} P(x) = 0$;
3. P liên tục phải, tức là $\lim_{x \downarrow y} P(y) = P(x)$;
4. Nếu $P(x_-) = \lim_{y \uparrow x} P(y)$ thì $P(x_-) = \mathbb{P}(X < x)$;
5. $\mathbb{P}(X = x) = P(x) - P(x_-)$.

Định nghĩa 1.4 (Hàm phân vị). Cho phân phối P trên $\mathbb{R}$, hàm phân vị $F^{-1} : [0; 1] \rightarrow \mathbb{R}$ được định nghĩa bởi $F^{-1}(s) = \inf\{x \in \mathbb{R} : P(x) \geq s\}$, với $s \in [0; 1]$.

Tính chất 1.2. Hàm phân vị F^{-1} thỏa các tính chất sau

1. F^{-1} không giảm, tức là nếu $s_1 \leq s_2$ thì $F^{-1}(s_1) \leq F^{-1}(s_2)$;
2. Nếu P liên tục, $P(F^{-1}(s)) = s$ và $F^{-1}(P(x)) = x$;
3. Kỳ vọng và phương sai được biểu diễn qua F^{-1} dưới công thức $\mathbb{E}(X) = \int_0^1 F^{-1}(s) ds$

$$\text{và } \text{Var}(X) = \mathbb{E}^2(X - \mathbb{E}(X));$$

4. Nếu P đối xứng quanh μ , ta có quan hệ đối xứng $F^{-1}(1-s) = 2\mu - F^{-1}(s)$.

Định nghĩa 1.5 (Hàm mật độ xác suất). Họ các hàm phân phối $P : \mathbb{R}^d \rightarrow [0; \infty]$ là liên tục tuyệt đối trong $(\Omega; \mathcal{B})$ -đo được với μ hoặc là độ đo Lebesgue hoặc độ đo đếm. Khi này, hàm mật độ trong không gian thực được định nghĩa là

$$\forall x; f(x) = \frac{dP}{d\mu}(x) = \begin{cases} f(s), & \text{nếu } \mu \text{ là độ đo Lebesgue,} \\ \mathbb{P}(X = x) = p(x), & \text{nếu } \mu \text{ là độ đo đếm.} \end{cases}$$

Tính chất 1.3. Hàm mật độ thỏa mãn các tính chất sau

1. Hàm mật độ xác suất liên tục $f(x)$ là hàm không âm, $f(x) \geq 0; \forall x \in \Omega$;
2. Tích phân $f(x)$ trên toàn miền Ω bằng 1;
3. Xác suất trên tập con Borel $A \subseteq \Omega$ được tính bằng tích phân $\mathbb{P}(X \in A) = \int_A f(x) dx$;
4. Công thức xác suất trong tập Borel thực

$$\mathbb{P}(a < x < b) = \mathbb{P}(a < x \leq b) = \mathbb{P}(a \leq x < b) = \mathbb{P}(a \leq x \leq b) = \int_a^b f(x) dx.$$

Nhận xét. Các hàm phân phối P , và phân vị F^{-1} đều không bảo toàn trong không gian véc-tơ Hilbert. Các giá trị của mật độ xác suất liên tục thì có thể tùy ý, nhưng phải thỏa mãn Tính chất 1.3. Một xác suất tại điểm $x = x_0$ không được khảo sát trong hàm mật độ liên tục tuyệt đối mà ở một tập Borel thực như Tính chất 1.3.(3). Tức là xác suất tại điểm bất kì luôn bằng 0 đối với biến ngẫu nhiên X liên tục. Ta có thể tổng quát hóa tập các hàm mật độ thành không gian con lồi của $\mathcal{L}^1(\Omega)$ và đóng trong tô-pô chuẩn $\mathcal{F}(\Omega) = \{f : \Omega \rightarrow \mathbb{R}^+ | \int_{\Omega} f(x) d\mu(x) = 1\} \cdot V$

Định nghĩa 1.6. Hai tham số kỳ vọng và phương sai của biến ngẫu nhiên X được định nghĩa bởi $\mathbb{E}(X) = \int_{\Omega} x f(x) dx < \infty$; và $\text{Var}(X) = \int_{\Omega} (x - \mathbb{E}(X))^2 f(x) dx$.

Định nghĩa 1.7. Với các đối tượng hàm mật độ trong khoảng $I \neq 0$, toán tử tổng và tích có hướng được thay thế bởi phép nhân điểm và lũy thừa. Tức là,

$$(f \oplus g)(x) = \frac{f(x)g(x)}{\int_I f(\xi)g(\xi) d\xi}, \text{ và } (\alpha \odot f)(x) = \frac{f^\alpha(x)}{\int_I f^\alpha(\xi) d\xi}, \text{ với } \alpha \in \mathbb{R}.$$

Định nghĩa 1.8 (Dữ liệu hàm mật độ 1-chiều). Dữ liệu hàm mật độ là một bộ đối tượng không chắc chắn o có dạng $(o_1; o_2; \dots; o_n)$ [20]. Mỗi đối tượng o_j chứa một cặp $(I_j; f_j)$ với mỗi $1 \leq j \leq n$, trong đó $I_j = [l_j; u_j]$ là khoảng xác định của o_j , và $f : \mathbb{R} \rightarrow \mathbb{R}^+$

là hàm mật độ xác suất xếp các giá trị xác suất vào mỗi $x \in I_j$ sao cho

$$\int_{x \in I_j} f_j(x) dx = 1, \text{ và } \int_{x \in \mathbb{R} \setminus I_j} f_j(x) dx = 0.$$

Định nghĩa 1.9 (Dữ liệu hàm mật độ d -chiều). Dữ liệu hàm mật độ d -chiều là một bộ đối tượng không chắc chắn $\mathbf{o}$ có dạng $(\mathbf{o}_1; \mathbf{o}_2; \dots; \mathbf{o}_n)$ [20]. Mỗi đối tượng $\mathbf{o}_j$ chứa một cặp $(\mathbf{R}_j; f_j)$ với mỗi $1 \leq j \leq n$, trong đó $\mathbf{R}_j = [l_1; u_1] \times \dots \times [l_d; u_d] \subseteq \mathbb{R}^d$ là vùng xác định d -chiều của $\mathbf{o}_j$, và $f : \mathbb{R}^d \rightarrow \mathbb{R}^{d+}$ là hàm mật độ xác suất xếp các giá trị xác suất vào mỗi $x \in \mathbf{R}_j$ sao cho

$$\int_{x \in \mathbf{R}_j} f_j(x) dx = 1, \text{ và } \int_{x \in \mathbb{R} \setminus \mathbf{R}_j} f_j(x) dx = 0.$$

Để minh họa và mô phỏng, luận văn này làm việc trên dữ liệu các hàm mật độ định nghĩa trên toàn không gian mẫu $I = \mathbb{R}$ hoặc $\mathbf{R} = \mathbb{R}^d$, và ký hiệu xuyên suốt là $\mathcal{F} = \{f_1(x); \dots; f_n(x)\}$. Để đơn giản hóa, luận văn này giả định các đối tượng hàm mật độ là độc lập.

1.2 Một số hàm mật độ thông dụng

Hàm mật độ xác suất cụ thể được nghiên cứu bởi các nhà khoa học thực nghiệm và thỏa mãn các Tính chất 1.3.

Định nghĩa 1.10 (Hàm mật độ Gauss). Biến ngẫu nhiên liên tục X tuân theo mật độ Gauss (chuẩn) với hai tham số μ và σ^2 (trong đó $\mu \in \mathbb{R}$, và $\sigma^2 \in \mathbb{R}_{>0}$) nếu nó có hàm mật độ xác suất là

$$\mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), x \in \mathbb{R}.$$

Định lý 1.1 (Kỳ vọng và phương sai). Kỳ vọng và phương sai của biến ngẫu nhiên X có hàm mật độ xác suất Gauss lần lượt là $\mathbb{E}(X) = \mu$, và $\text{Var}(X) = \sigma^2$.

Hàm mật độ Gauss có dáng điệu hình cong đối xứng và miền xác định khắp không gian. Đặc trưng kỳ vọng chính là giá trị cực đại và xác định vị trí của hàm mật độ. Đặc trưng phương sai thể hiện độ phân tán hay độ cao của hàm. Giá trị của nó càng nhỏ thì hàm mật độ càng cao và hẹp. Thông thường, dữ liệu rời rạc thường được biến đổi thành dữ liệu hàm mật độ qua biểu diễn của hàm mật độ Gauss (khi ước lượng tham số) hoặc nhân-Gauss (khi ước lượng phi tham số). Hơn hết, định lý giới hạn trung tâm chứng minh tổng các biến ngẫu nhiên độc lập có phân phối xấp xỉ Gauss. Ta cũng thành lập được công thức tính xác suất khi $X \sim \mathcal{N}(\mu; \sigma^2)$ là $\mathbb{P}(a < X < b) = \Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right)$.

Bổ đề 1.1 (Tổng hai hàm mật độ Gauss). Cho hai biến ngẫu nhiên độc lập $X_1 \sim$

$\mathcal{N}(\mu_1; \sigma_1^2)$ và $X_2 \sim \mathcal{N}(\mu_2; \sigma_2^2)$. Khi đó $S = X_1 \pm X_2$ cũng là biến ngẫu nhiên có hàm mật độ Gauss, tức là $S \sim \mathcal{N}(\mu_1 \pm \mu_2; \sigma_1^2 + \sigma_2^2)$.

Bổ đề 1.2 (Tích phân của hai hàm mật độ Gauss). Cho hai hàm mật độ Gauss $\mathcal{N}(\mu_1; \sigma_1^2)$ và $\mathcal{N}(\mu_2; \sigma_2^2)$ với kỳ vọng $\mu_1, \mu_2 \in \mathbb{R}$, và phương sai $\sigma_1^2, \sigma_2^2 > 0$. Khi đó, tích phân giữa hai hàm mật độ được xác định bởi

$$\int_{\Omega} \mathcal{N}(\mu_1; \sigma_1^2) \cdot \mathcal{N}(\mu_2; \sigma_2^2) dx = \frac{1}{\sqrt{2\pi(\sigma_1^2 + \sigma_2^2)}} \exp\left(-\frac{(\mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right).$$

Chứng minh. Xét tích phân

$$\begin{aligned} & \int_{-\infty}^{\infty} \mathcal{N}(x; \mu_1; \sigma_1^2) \cdot \mathcal{N}(x; \mu_2; \sigma_2^2) dx \\ &= \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{(x-\mu_1)^2}{2\sigma_1^2} - \frac{(x-\mu_2)^2}{2\sigma_2^2}\right) dx \\ &= \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{1}{2}\underbrace{\left(\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}\right)}_{:=1/\sigma^2} x^2 + \underbrace{\left(\frac{\mu_1}{\sigma_1^2} + \frac{\mu_2}{\sigma_2^2}\right)}_{:=\mu} x - \frac{\mu_1^2}{2\sigma_1^2} - \frac{\mu_2^2}{2\sigma_2^2}\right) dx \\ &= \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{1}{2}\sigma(x-\mu)^2 - \frac{(\mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right) dx \\ &= \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{(\mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right) \underbrace{\int_{-\infty}^{\infty} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right) dx}_{=\sqrt{2\pi}\sigma} \\ &= \frac{\sqrt{2\pi}\sigma^2}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{(\mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right). \end{aligned}$$

Từ đây, ta suy ra được điều phải chứng minh. ■

Định nghĩa 1.11 (Hàm mật độ Gauss d -chiều). Biến ngẫu nhiên liên tục d -chiều X tuân theo mật độ Gauss (chuẩn) với hai tham số μ và Σ (trong đó $\mu \in \mathbb{R}^d$ và Σ thuộc đa tập của ma trận đối xứng xác định dương) nếu nó có hàm mật độ xác suất là

$$\mathcal{N}(x; \mu; \Sigma) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1} (x - \mu)\right), x \in \mathbb{R}^d,$$

trong đó, $|\Sigma|$ là định thức của ma trận hiệp phương sai.

Định lý 1.2 (Kỳ vọng và hiệp phương sai). Véc-tơ kỳ vọng và ma trận hiệp phương sai của biến ngẫu nhiên X có hàm mật độ xác suất Gauss lần lượt là $\mathbb{E}(X) = \mu$, và $\text{Cov}(X) = \Sigma$.

Bổ đề 1.3 (Tổng hai hàm mật độ Gauss d -chiều). Cho hai biến ngẫu nhiên độc lập $X_1 \sim \mathcal{N}(\mu_1; \Sigma_1)$ và $X_2 \sim \mathcal{N}(\mu_2; \Sigma_2)$. Khi đó $S = X_1 \pm X_2$ cũng là biến ngẫu nhiên có hàm mật độ Gauss, tức là $S \sim \mathcal{N}(\mu_1 \pm \mu_2; \Sigma_1 + \Sigma_2)$.

Bổ đề 1.4 (Tích phân của hai hàm mật độ Gauss d -chiều). Cho hai hàm mật độ Gauss d -chiều $\mathcal{N}(\mu_1; \Sigma_1)$ và $\mathcal{N}(\mu_2; \Sigma_2)$ với véc-tơ kỳ vọng $\mu_1, \mu_2 \in \mathbb{R}^d$, và ma trận hiệp phương sai Σ_1, Σ_2 xác định dương. Khi đó, tích phân giữa hai hàm mật độ được xác định bởi

$$\int_{\Omega} \mathcal{N}(\mu_1; \Sigma_1) \cdot \mathcal{N}(\mu_2; \Sigma_2) dx = \frac{1}{(2\pi)^{d/2} |\Sigma_1 + \Sigma_2|^{1/2}} \times \exp \left(-\frac{1}{2} (\mu_1 - \mu_2)^T (\Sigma_1 + \Sigma_2)^{-1} (\mu_1 - \mu_2) \right).$$

Ngoài ra, các phát triển bất đối xứng của Gauss điển hình là hàm Gauss-lệch [21]. với hàm mật độ của nó được định nghĩa như sau.

Định nghĩa 1.12 (Hàm mật độ Gauss-lệch). Biến ngẫu nhiên liên tục X tuân theo mật độ Gauss-lệch (chuẩn-lệch) [21] với ba tham số μ , σ^2 , và α (trong đó $\mu, \alpha \in \mathbb{R}$, và $\sigma^2 \in \mathbb{R}_{>0}$) nếu nó có hàm mật độ xác suất là

$$\mathcal{S}\mathcal{N}(x; \mu, \sigma^2, \alpha) = \frac{2}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{(x-\mu)^2}{2\sigma^2} \right) \int_{-\infty}^{\alpha(x-\mu)/\sigma} \frac{1}{\sqrt{2\pi}} \exp \left(-\frac{t^2}{2} \right) dt, x \in \mathbb{R}.$$

Hàm mật độ Gauss-lệch nhận thêm một tham số thể hiện mức độ lệch α . Khi giá trị α càng lớn, độ lệch so với kỳ vọng μ càng lớn. Khi $\alpha = 0$, phân phối này trở về Gauss như Định nghĩa 1.10.

Định lý 1.3 (Kỳ vọng và phương sai). Kỳ vọng và phương sai của biến ngẫu nhiên X có hàm mật độ xác suất Gauss-lệch lần lượt là $\mathbb{E}(X) = \mu + \sigma\delta\sqrt{\frac{2}{\pi}}$, và $\text{Var}(X) = \sigma^2 \left(1 - \frac{2\delta^2}{\pi} \right)$, với $\delta = \frac{\alpha}{\sqrt{1+\alpha^2}}$ nằm trong khoảng $(-1; 1)$.

Định nghĩa 1.13 (Hàm mật độ đều). Biến ngẫu nhiên liên tục X tuân theo phân phối đều trên đoạn $[l; u]$ (với $l < u$, và $l, u \in \mathbb{R}$) nếu nó có hàm mật độ xác suất là

$$\mathcal{U}(x; l, u) = \begin{cases} \frac{1}{u-l}, & x \in [l; u], \\ 0, & x \notin [l; u]. \end{cases}$$

Định lý 1.4 (Kỳ vọng và phương sai). Kỳ vọng và phương sai của biến ngẫu nhiên X có hàm mật độ xác suất đều lần lượt là $\mathbb{E}(X) = \frac{l+u}{2}$, và $\text{Var}(X) = \frac{(u-l)^2}{12}$.

Định nghĩa 1.14 (Hàm mật độ đều d -chiều). Biến ngẫu nhiên liên tục d -chiều X tuân theo phân phối đều trên hình hộp $[l_1; u_1] \times \cdots \times [l_d; u_d]$ (với $l_i < u_i$, và $l_i, u_i \in \mathbb{R}$) nếu nó có hàm mật độ xác suất là

$$\mathcal{U}(x; l, u) = \begin{cases} \prod_{i=1}^d \frac{1}{u_i-l_i}, & x \in [l_1; u_1] \times \cdots \times [l_d; u_d], \\ 0, & \text{ngược lại.} \end{cases}$$

Định lý 1.5 (Kỳ vọng và hiệp phương sai). Véc-tơ kỳ vọng và ma trận hiệp phương sai của biến ngẫu nhiên X có hàm mật độ xác suất đều lần lượt là $\mathbb{E}(X) = \frac{l+u}{2}$, và $\text{Cov}(X) = \text{diag}\left(\frac{(u_1-l_1)^2}{12}, \dots, \frac{(u_d-l_d)^2}{12}\right)$.

1.3 Một số hàm mật độ bổ sung

Gần đây, các thuật toán phân tích chùm dựa vào trọng tâm đề xuất bổ sung hàm mật độ xác suất trọng tâm (hay hàm mật độ đại diện của chùm) [22, 23]. Nó có chức năng như trung bình có trọng số của tổng các hàm mật độ trong chùm.

Định nghĩa 1.15 (Hàm mật độ đại diện chùm). Cho tập $\mathcal{F}$ gồm n -hàm mật độ xác suất với $n \geq 2$. Ta phân bổ $\mathcal{F}$ vào c -chùm, với $1 < c \leq n$. Khi này, hàm mật độ đại diện của các chùm c_i là

$$\theta_i(x) = \frac{\sum_{j=1}^n \mu_{ij} \times f_j(x)}{\sum_{j=1}^n \mu_{ij}}, \quad (1.1)$$

trong đó, μ_{ij} là trọng số phân bổ hàm mật độ $f_j(x)$ bất kỳ vào chùm c_i [24].

Dựa vào định nghĩa trên, ta dễ dàng nhận được θ_i cũng là một hàm mật độ (Tính chất 1.3).

Chứng minh. Các giá trị trọng số $0 \leq \mu_{ij} \leq 1$ nên các θ_i liên tục không âm, và

$$\int_{\Omega} \theta_i(x) dx = \int_{\Omega} \frac{\sum_{j=1}^n \mu_{ij} \times f_j(x)}{\sum_{j=1}^n \mu_{ij}} dx = \frac{\sum_{j=1}^n \mu_{ij} \times \int_{\Omega} f_j(x) dx}{\sum_{j=1}^n \mu_{ij}} = 1.$$

Định lý 1.6. Kỳ vọng của biến ngẫu nhiên X có hàm mật độ xác suất đại diện $\theta_i(x)$ là

$$\mathbb{E}_{\theta_i}(X) = \frac{\sum_{j=1}^n \mu_{ij} \mathbb{E}_{f_j}(X)}{\sum_{j=1}^n \mu_{ij}}.$$

Chứng minh. Ta có

$$\mathbb{E}_{\theta_i}(X) = \int_{\Omega} x \theta_i(x) dx = \int_{\Omega} x \frac{\sum_{j=1}^n \mu_{ij} f_j(x)}{\sum_{j=1}^n \mu_{ij}} dx = \frac{1}{\sum_{j=1}^n \mu_{ij}} \sum_{j=1}^n \mu_{ij} \underbrace{\int_{\Omega} x f_j(x) dx}_{=\mathbb{E}_{f_j}(X)}.$$

Từ đây, ta suy ra điều phải chứng minh. ■

Ta cũng mở rộng được cho hàm mật độ đại diện chùm đến không gian d -chiều tương tự cho véc-tơ ngẫu nhiên X , và nó cũng thỏa mãn các tính chất của một hàm mật độ xác suất. Mới đây, Thao Nguyen-Trang *et al.* [25, 26] đề xuất hàm mật độ đại diện Gauss như là một phiên bản Gauss hóa của hàm Fréchet [27].

Định nghĩa 1.16 (Hàm mật độ đại diện Gauss). Hàm mật độ đại diện Gauss có dạng phân phối chuẩn sao cho tổng khoảng cách giữa chúng đến các hàm mật độ khác là nhỏ


nhất [27], tức là

$$\theta_i(x) = \arg \min_{\mathcal{N}(\mu; \sigma)} \sum_{j=1}^n \mu_{ij} D(\mathcal{N}(\mu; \sigma); f_j(x)).$$

trong đó, $D(\mathcal{N}(\mu; \sigma); f_j(x))$ là khoảng cách giữa hai hàm mật độ Gauss đến tất cả các hàm mật độ $f_j(x)$ trong tổng thể.

Nhận xét. Hàm mật độ đại diện Gauss là hàm trung bình Fréchet nên có nghiệm duy nhất [27]. Khác với Công thức (1.1), hàm mật độ này chỉ cần tìm một hàm Gauss duy nhất mà không cần tổ hợp các f_j giúp tăng khả năng khái quát hóa. Ta cũng có phương sai Fréchet $\text{Var}_j(X) = \mathbb{E}(D^2(\mathcal{N}(\mu; \sigma); f_j(x)))$.

Hình 1.1 minh họa cụ thể hai cách biểu diễn hàm mật độ đại diện trong cùng một chùm hàm Gauss. Để thấy sự khác biệt, hàm mật độ đại diện tập trung vào phân bố trung bình của nó tại các chùm, còn hàm mật độ đại diện Gauss lựa chọn vị trí dựa vào khoảng cách các hàm mật độ với nhau. Tóm lại, hàm đại diện có chức năng là hàm mật độ kỳ vọng của các tổng thể khác nhau.



Hình 1.1. Minh họa hai hàm mật độ xác suất đại diện một chùm hàm mật độ $\mathcal{F}$.

Chú thích: Hàm mật độ đại diện thể hiện bằng đường thẳng in đậm cho ba hàm Gauss minh họa bằng nét đứt (a) dựa vào trọng số phân bố đều giữa ba hàm $\mu_{ij} = 1/3$, và (b) dựa vào vị trí tối ưu với khoảng cách $\mathcal{L}_2$. Nguồn: Minh họa của tác giả.

1.4 Ước lượng hàm mật độ xác suất

Trong thực tế, ta cần phải ước lượng hàm mật độ xác suất dựa vào dữ liệu rời rạc, luận văn này sử dụng phương pháp ước lượng hàm hạt nhân để chuyển từ bài toán rời rạc sang hàm mật độ xác suất.

Định nghĩa 1.17 (Ước lượng hàm mật độ bằng phương pháp hàm hạt nhân). Giả sử ta có một tập dữ liệu rời rạc gồm n quan sát x_j , với $j = 1; \dots; n$ trong không gian $\mathbb{R}^d$. Mỗi điểm $x_j = (x_{1j}; x_{2j}; \dots; x_{dj})^\top$. Khi đó, hàm mật độ xác suất $\hat{f}(x)$ tại điểm

$\mathbf{x} = (x_1; x_2; \dots; x_d)^\top$ được ước lượng bằng phương pháp hạt nhân bởi công thức

$$\hat{f}(\mathbf{x}) = \frac{1}{n \prod_{i=1}^d bw_i} \sum_{j=1}^n \prod_{i=1}^d \kappa_i \left(\frac{x_i - x_{ij}}{bw_i} \right),$$

trong đó κ_i là hàm hạt nhân theo chiều thứ i có tính chất $\kappa(\cdot) \geq 0$ và $\int \kappa(z) dz = 1$, và tham số $bw_i > 0$ là tham số trơn ứng với chiều đó.


Nhận xét. Khi tham số trơn bw nhỏ, hàm mật độ ước lượng sẽ kém trơn và có thể dao động mạnh. Ngược lại, nếu bw lớn thì hàm trở nên trơn hơn nhưng có thể làm mất chi tiết quan trọng của phân phối gốc. Trong trường hợp đơn giản, có thể chọn cùng một hàm hạt nhân và cùng một tham số trơn cho tất cả các chiều, tức là $\kappa_i \equiv \kappa$ và $bw_i = bw$ với mọi $i = 1, \dots, d$.

Một số công thức hàm hạt nhân phổ biến được liệt kê trong Bảng 1.1. Luận văn này khảo sát hàm mật độ ước lượng từ hàm hạt nhân Gauss với tham số trơn cố định và được tính bởi công thức của Silverman cho bởi Công thức $bw = 1.06 \times \text{Var}(x_j) \times n^{-1/5}$.

Bảng 1.1. Một số hàm hạt nhân phổ biến dùng trong ước lượng mật độ hạt nhân

Tên hàm	$\kappa(z)$	Miền xác định	Khả vi
Hình chữ nhật	$(1/2)\mathbf{1}_{\{ z \leq 1\}}$	$[-1; 1]$	
Tam giác	$(1 - z)\mathbf{1}_{\{ z \leq 1\}}$	$[-1; 1]$	$\mathcal{C}^0$
Epanechnikov	$(3/4)(1 - z^2)\mathbf{1}_{\{ z \leq 1\}}$	$[-1; 1]$	$\mathcal{C}^0$
Gauss	$\frac{1}{\sqrt{2\pi}} \exp(-z^2/2)$	$(-\infty, \infty)$	$\mathcal{C}^\infty$
Logistic	$\frac{\exp(-z)}{1 + \exp(-z)^2}$	$(-\infty, \infty)$	$\mathcal{C}^\infty$

Hình 1.2(a) so sánh các hàm hạt nhân khác nhau. Cùng tham số trơn $bw = 1$, hàm Gauss cho đường trơn, còn hàm logistic dao động yếu, và hàm Epanechnikov nổi bật rõ đỉnh. Hình 1.2(b) giữ cố định nhân Gauss và thay bằng thông. Rõ ràng, bw nhỏ hơn làm đồ thị nhọn và chi tiết hơn, và ngược lại.



Hình 1.2. So sánh các hàm hạt nhân và hệ số trơn trong ước lượng mật độ xác suất

Chú thích: Vùng xám là phân phối thực tế $X \sim 0,3\mathcal{N}(0;1) + 0,7\mathcal{N}(5;1)$, Đường đen là minh họa của (a) các hàm hạt nhân với tham số trơn $bw = 1$, ảnh hưởng đến khả năng khớp với hàm mật độ thực tế, và (b) tham số trơn với hàm hạt nhân Gauss, ảnh hưởng đến mức độ khớp. Nguồn: Minh họa của tác giả.

1.5 Độ đo đánh giá sự tương tự của các hàm mật độ xác suất

Khoảng cách là độ đo xa-gần các vật thể. Ở đây, khái niệm *khoảng cách* bao hàm cả độ đo phân biệt.

1.5.1 Sự tương tự của hai hàm mật độ xác suất

Định nghĩa 1.18 (Khoảng cách $\mathcal{L}_p$). Cho hai hàm mật độ xác suất f_1, f_2 trên $\mathbb{R}^d$. Khoảng cách $\mathcal{L}_p$ được định nghĩa là

$$\mathcal{L}_p(f, g) = \left(\int_{\mathbb{R}^d} |f_1(x) - f_2(x)|^p dx \right)^{1/p}, 1 \leq p < \infty.$$

Theo Định nghĩa 1.18, khoảng cách giữa hai hàm mật độ thỏa mãn các tiên đề của mê-tríc. Trong lý thuyết thống kê và thông tin, một mê-tríc được gọi là *khoảng cách* và nửa mê-tríc gọi là *phân kỳ*. Thực tế, ta thường sử dụng $p = 1$ hoặc $p = 2$ cho các tính toán. Ta cũng có mối quan hệ giữa hai hàm mật độ đối mỗi trọng tâm bất kỳ trong mê-tríc.

Bổ đề 1.5 (Bất đẳng thức tam giác). Với mọi $f_j, f_k \in c_i$ trong không gian khoảng cách mê-tríc, và trọng tâm chùm θ_i , ta có bất đẳng thức tam giác $D(f_j, f_k) \leq D(f_j, \theta_i) + D(f_k, \theta_i)$.

Tại Vo-Van (2019) [23] dựa trên khoảng cách $\mathcal{L}_p$ để giới thiệu độ rộng chùm.

$$CWD(f_1; f_2) = \int_{\Omega} \max\{f_1(x); f_2(x)\} dx - 1$$

Định nghĩa 1.19 (f -phân kỳ). Hàm $D : P_1 \times P_2 \rightarrow \mathbb{R}$ được gọi là f -phân kỳ của hai

hàm mật độ $f_1 \in P_1$ và $f_2 \in P_2$ khi nó thỏa hệ số phân kỳ giữa hai xác suất [28]

$$D(P_1; P_2) = h \left(\mathbb{E}_1 \left(g \left(\frac{f_2}{f_1} \right) \right) \right),$$

trong đó g là một hàm liên tục lồi trên $\mathbb{R}_{>0}$, h là hàm tăng trên $\mathbb{R}$, và $\mathbb{E}_1$ là kỳ vọng của P_1 .

Bảng 1.2 làm rõ các công thức khoảng cách và độ đo tương tự giữa hai hàm mật độ xác suất theo tiếp cận xác suất.

Bảng 1.2. Bảng tổng kết các loại khoảng cách và các chỉ số khác giữa hai hàm mật độ xác suất

Khoảng cách	$D(f_1(x), f_2(x))$	$g(u)$	$h(u)$	Miền giá trị
$\mathcal{L}_1$	$\int_{\Omega} f_1(x) - f_2(x) dx$	$ 1 - u $	u	$[0; 2]$
Chernoff	$-\log \left(\int_{\Omega} f_1(x)^s f_2(x)^{1-s} dx \right)$	$-u^{1-s}$	$-\log(-u)$	$[0; +\infty)$
Matusita	$\left(\int_{\Omega} f_1^{1/r}(x) - f_2^{1/r}(x) ^r dx \right)^{1/r}$	$ 1 - u^{1/r} ^r$	$u^{1/r}$	$[0; \sqrt{2}]$
bình phương Hellinger	$\int_{\Omega} \left(\sqrt{f_1(x)} - \sqrt{f_2(x)} \right)^2 dx$	$(\sqrt{u} - 1)^2$	u	$[0; 2]$
thông tin Kullback	$\int_{\Omega} f_1(x) \log \frac{f_1(x)}{f_2(x)} dx$	$-\log(u)$	u	$[0; +\infty)$
Jensen-Shannon	$\frac{1}{2} (D_{KL}(f_1; f_2) + D_{KL}(f_2; f_1))$	$-(u+1) \log(\frac{u+1}{2}) + u \log(u)$	$\frac{1}{2}u$	$[0; +\infty)$
Bayes Error	$1 - \int_{\Omega} \min\{\pi f_1(x); \pi(1 - f_2(x))\} dx$	$-\min\{u; 1 - u\}$	$u + 1$	$[0; 1]$


Trong khoảng cách Chernoff, $0 \leq r \leq 1$, và trong khoảng cách Matusita, $r \geq 2$. Nguồn: Tác giả tổng hợp

Nhìn vào Bảng 1.2, có thể thấy khoảng cách Chernoff là một tổng quát hóa của khoảng cách Bhattacharyya khi chọn $s = 1/2$. Tương tự khoảng cách Matusita là tổng quát hóa của bình phương Hellinger khi $r = 2$. Trong $\mathcal{L}_p$, chỉ có $\mathcal{L}_1$ là một f -phân kỳ và là Matusita với $r = 1$. Đáng chú ý, Matusita cũng thỏa mãn tính chất mê-tríc.

Hình 1.3 ghi nhận các giá trị khoảng cách giữa hàm mật độ $f_1 \sim \mathcal{N}(0; 1)$ và $f_2 \sim \mathcal{N}(\mu; 1)$, với μ trượt từ -10 đến 20 . Ta thấy khi hai hàm mật độ f_2 cách nhau quá xa hàm f_1 , tức là $|\mu_2| \gg 0$, tất cả loại khoảng cách hàm mật độ đều bão hòa và không đo được sự khác biệt. Lúc này hai hàm mật độ về mặt không gian rất xa nhau, nhưng khoảng cách không thể đo xa hơn nữa vì nó đã đạt đến ngưỡng lớn nhất. Đây là hạn chế không giữ được vị trí hình học đối với các khoảng cách hàm mật độ.

Do đó, luận văn này giới thiệu khoảng cách Wasserstein (hay Kantorovich–Rubinstein), là một mê-tríc hỗ trợ tốt cho tính toán khoảng cách các hàm mật độ không chồng lấp [29] thỏa Định nghĩa 1.18 và bất đẳng thức tam giác của Bổ đề 1.5. Khoảng cách này được phát triển trong bài toán vận chuyển tối ưu, nhưng chưa được nghiên cứu trong lĩnh vực nhận dạng hàm mật độ.

Định nghĩa 1.20 (Khoảng cách p -Wasserstein). Khoảng cách p -Wasserstein ($p \geq$



Chú thích: Khảo sát (a) các khoảng cách có miền xác định bị chặn trên, và (b) ngược lại. Nguồn: Minh họa của tác giả

Hình 1.3. Dãy khoảng cách $D(f_1; f_2)$ giữa hai hàm mật độ Gauss $\mathcal{N}(0; 1)$ và $\mathcal{N}(\mu; 1)$

1) giữa hai độ đo xác suất μ và ν trong không gian $\mathbb{R}^d$ được định nghĩa là

$$W_p(\mu; \nu) = \inf_{\substack{X \sim \mu \\ Y \sim \nu}} (\mathbb{E} \|X - Y\|^p)^{1/p} = \left(\inf_{\gamma \in \Gamma(\mu, \nu)} \int_{M \times M} d(x; y)^p d\gamma(x, y) \right)^{1/p},$$

Khoảng cách p -Wasserstein đo mức chênh lệch tối ưu giữa hai phân phối xác suất, xét trên tất cả các phép ghép cặp khả dĩ. Tức là nó tính đến công sức để di chuyển và tái sắp xếp khối lượng từ hàm này sang hàm kia. Ở đây, luận văn này sử dụng $p = 2$ để tính toán đo độ khác biệt giữa hai mật độ xác suất liên tục. Trong thực tế, ta tính toán cụ thể khoảng cách này bằng cách biểu diễn nó qua hàm phân vị. Ta có Định lý 1.7.

Định lý 1.7. *Khoảng cách p -Wasserstein giữa hai độ đo xác suất μ và ν có thể được biểu diễn dưới dạng phân vị trong trường hợp 1-chiều bởi định nghĩa*

$$W_p^p(\mu; \nu) = \int_0^1 |F_\mu^{-1}(s) - F_\nu^{-1}(s)|^p ds,$$

trong đó F_μ^{-1} và F_ν^{-1} lần lượt là hàm phân vị của μ và ν (Xem Định nghĩa 1.4).

Định lý 1.8 (Khoảng cách 2-Wasserstein giữa hai hàm mật độ Gauss 1-chiều). *Giả sử hai hàm mật độ $f_1(x) \sim \mathcal{N}(\mu_1; \sigma_1^2)$ và $f_2(x) \sim \mathcal{N}(\mu_2; \sigma_2^2)$ là hai phân bố Gauss 1-chiều. Khi đó, khoảng cách 2-Wasserstein giữa chúng là $W_2^2(f_1, f_2) = (\mu_1 - \mu_2)^2 + (\sigma_1 - \sigma_2)^2$.*

Chứng minh. Dựa vào Định lý 1.7, ta xét hàm phân vị Gauss $F_i^{-1}(u) = \mu_i + \sigma_i \Phi^{-1}(u)$, với

$\Phi^{-1}(u)$ là phân vị chuẩn $\mathcal{N}(0, 1)$. Khi đó,

$$\begin{aligned}
W_2^2(f_1; f_2) &= \int_0^1 (\mu_1 + \sigma_1 \Phi^{-1}(u) - \mu_2 - \sigma_2 \Phi^{-1}(u))^2 du \\
&= \int_0^1 ((\mu_1 - \mu_2) + (\sigma_1 - \sigma_2) \Phi^{-1}(u))^2 du \\
&= \int_0^1 [(\mu_1 - \mu_2)^2 + 2(\mu_1 - \mu_2)(\sigma_1 - \sigma_2) \Phi^{-1}(u) + (\sigma_1 - \sigma_2)^2 (\Phi^{-1}(u))^2] du \\
&= (\mu_1 - \mu_2)^2 \underbrace{\int_0^1 du}_{=1} + 2(\mu_1 - \mu_2)(\sigma_1 - \sigma_2) \underbrace{\int_0^1 \Phi^{-1}(u) du}_{=0} + (\sigma_1 - \sigma_2)^2 \underbrace{\int_0^1 (\Phi^{-1}(u))^2 du}_{=1}.
\end{aligned}$$

Từ đây ta suy ra được điều phải chứng minh. ■


Tương tự ta cũng suy ra được Định lý khoảng cách cho hai hàm mật độ Gauss d -chiều như sau.

Định lý 1.9 (Khoảng cách 2-Wasserstein giữa hai hàm mật độ Gauss d -chiều). *Giả sử hai hàm mật độ $f_1(x) \sim \mathcal{N}(\mu_1; \Sigma_1)$ và $f_2(x) \sim \mathcal{N}(\mu_2; \Sigma_2)$ là hai phân bố Gauss trong $\mathbb{R}^d$. Khi đó, khoảng cách 2-Wasserstein giữa chúng là*

$$W_2^2(f_1; f_2) = \|\mu_1 - \mu_2\|_2^2 + \text{Tr} \left(\Sigma_1 + \Sigma_2 - 2(\Sigma_1^{1/2} \Sigma_2 \Sigma_1^{1/2})^{1/2} \right).$$

Định lý 1.10 (Khoảng cách 2-Wasserstein giữa hai phân phối đều 1-chiều). *Giả sử hai hàm mật độ $f_1(x) \sim \mathcal{U}[a_1; b_1]$ và $f_2(x) \sim \mathcal{U}[a_2; b_2]$ là hai phân phối đều một chiều. Khi đó, khoảng cách 2-Wasserstein giữa chúng là $W_2^2(f_1; f_2) = (\mu_1 - \mu_2)^2 + \frac{1}{12}(l_1 - l_2)^2$, trong đó $m_i = \frac{a_i + b_i}{2}$ là trung điểm, và $l_i = b_i - a_i$ là độ dài của khoảng $[a_i; b_i]$.*

Ví dụ 1.1 (So sánh các loại khoảng cách hàm mật độ). Xét hai hàm mật độ xác suất đều $f_1(x)$ và $f_2(x)$ tại các vị trí khác nhau trên trục $x \in \mathbb{R}$.



Hình 1.4. Các trường hợp trong khoảng cách giữa hai hàm mật độ đều $f_1(x)$ và $f_2(x)$ đối với Ví dụ 1.1. *Chú thích: Bốn trường hợp mật độ đều với (a) hai hàm rời nhau, cùng chiều rộng; (b) hai hàm rời nhau, khác chiều rộng; (c) hai hàm rời nhau, cách xa nhau; và (d) hai hàm chồng lấp. Ở đây, ô vuông trắng $\square$ biểu thị hàm mật độ $f_1(x)$, và ô vuông xám $\blacksquare$ biểu thị hàm mật độ $f_2(x)$. Nguồn: Minh họa của tác giả.*

Hình 1.4 mô tả khoảng cách giữa hai hàm mật độ này tại các vị trí có thể có. Ta có

Bảng 1.3 tổng hợp kết quả các phép đo khoảng cách bốn tình huống như sau.

Bảng 1.3. Các kết quả khoảng cách giữa hai hàm mật độ đều trong bốn tình huống vị trí đối với Ví dụ 1.1

Họ khoảng cách	$D(f_1; f_2)$	Trường hợp			
		(a)	(b)	(c)	(d)
Họ $\mathcal{L}_p$	$\mathcal{L}_1$	2,0	2,0	2,0	1,0
	$\mathcal{L}_2$	1,4	1,2	1,4	0,7
	D_O (Overlap)	1,0	1,0	1,0	0,5
	CWD	1,0	1,0	1,0	0,5
Họ f -phân kỳ	D_{BC} (Bhattacharyya)	∞	∞	∞	0,7
	D_H^2 (Hellinger)	1,0	1,0	1,0	0,7
	D_M (Matusita)	1,4	1,4	1,4	1,0
	D_{KL} (Kullback–Leibler)	27,6	27,3	27,6	13,5
	D_{JS} (Jensen–Shannon)	27,6	26,9	27,6	13,5
Họ Optimal	W_2^2 (2-Wasserstein)	3,0	3,5	6,0	1,0

Trước hết, trong các trường hợp (a), (b), và (c), mặc dù $f_1(x)$ và $f_2(x)$ nằm xa dần, nhưng các giá trị khoảng cách $\mathcal{L}_1$ và $\mathcal{L}_2$ hầu như không đổi (đều bằng 2,0 hoặc 1,4). Khoảng cách này nhận biết được khác biệt hình dáng và phân bố, nhưng không nhận biết tốt yếu tố vị trí trong không gian. Hệ số Bhattacharyya và khoảng cách Hellinger chỉ có ý nghĩa trong trường hợp (d), khi có phần chồng lấp giữa $f_1(x)$ và $f_2(x)$. Điều này cho thấy chúng nhạy với mức độ chồng lấp, nhưng không phân biệt được hai hàm có vị trí tách biệt nhau.

Ngược lại, khoảng cách Wasserstein nhạy cảm với vị trí hình học, hình dáng và phân bố. Khi so sánh (a) và (c), ta thấy khoảng cách này tăng rất lớn. Điều này cho thấy có hiệu quả khi so sánh vị trí. Xét tình huống (a) và (b), khi thay đổi hình dáng hàm mật độ, khoảng cách này cũng có sự khác biệt. Đáng chú ý, khoảng cách $\mathcal{L}_2$ và W_2^2 là trái ngược nhau. Khi thay đổi hình dáng đồ thị, khoảng cách $\mathcal{L}_2$ giảm nhưng D_W lại tăng lên. Cuối cùng, trường hợp (d) cho thấy khoảng cách cũng có ý nghĩa khi chồng lấp.

Định nghĩa 1.21 (Affinity). Hàm $\rho : f \rightarrow [0; 1]$ được gọi là affinity của hai hàm mật độ $f_1(x)$ và $f_2(x)$ nếu nó thỏa mãn ba điều kiện

1. $0 \leq \rho(f_1; f_2) \leq 1$;
2. $\rho(f_1; f_2) = 1$ nếu và chỉ nếu $f_1 \equiv f_2$; và
3. mỗi dãy hàm $\{f_n\}$ thì $\rho(f_n; f_0) \rightarrow 1$.

Nhận xét. Affinity đo lường sự giống nhau giữa hai hàm mật độ theo vị trí. Vì vậy, ta có tương quan giữa Affinity và Khoảng cách giữa hai hàm mật độ xác suất $f_1(x)$ và $f_2(x)$ là $D(f_1; f_2) = 1 - \rho(f_1; f_2)$.

Ví dụ 1.2. Affinity cơ bản cho tương tự hai hàm mật độ $f_1(x)$ và $f_2(x)$ là Affinity Bhattacharyya với $\rho_{BC}(f_1; f_2) = \int_{\Omega} \sqrt{f_1(x)f_2(x)} dx$.

Định nghĩa 1.22 (Hàm hạt nhân của khoảng cách). Hàm $K : \mathcal{F} \times \mathcal{F} \rightarrow [0; 1]$ với tập $\mathcal{F}$ được gọi là hạt nhân (hạch) giữa hai hàm mật độ $f_1(x)$ và $f_2(x)$ nếu nó thỏa mãn

1. $0 \leq K(f_1; f_2) \leq 1$;
2. $K(f_1; f_2) = K(f_2, f_1)$ với mọi $f_1, f_2 \in \mathcal{F}$;
3. với mọi tập hữu hạn $\{f_1; \dots; f_n\} \subset \mathcal{F}$, và các hệ số $\alpha_1; \dots; \alpha_n \in \mathbb{R}$, hàm hạt nhân là xác định dương, tức là $\sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j K(f_i; f_j) \geq 0$.

Ví dụ 1.3. Ba hạt nhân cơ bản cho khoảng cách hai hàm mật độ $f_1(x)$ và $f_2(x)$ là

1. Hạt nhân chuẩn, $K_G(f_1; f_2) = \exp(-\frac{\mathcal{L}_p^2(f_1; f_2)}{\beta \sigma^2})$; $\beta \in \mathbb{R}_{>0}$,
2. Hạt nhân tuyến tính, $K_L(f_1; f_2) = \int_{\Omega} f_1(x) f_2(x) dx$,
3. Hạt nhân Bhattacharyya, $K_{BC}(f_1; f_2) = \int_{\Omega} \sqrt{f_1(x) f_2(x)} dx$,
4. Hạt nhân χ^2 , $K_{\chi^2}(f_1; f_2) = \int_{\Omega} \frac{2f_1(x)f_2(x)}{f_1(x)+f_2(x)} dx$.

Hàm hạt nhân $K(\cdot; \cdot)$ càng gần giá trị 1,0 thì hai hàm mật độ càng giống nhau, và ngược lại. Ở đây, việc chuyển đổi từ hàm hạt nhân thành khoảng cách được cho bởi công thức $D = 1 - K_G$ đối với các hạt nhân chuẩn hóa $[0; 1]$, hoặc $D = 2(1 - K_H)$ đối với hạt nhân Bhattacharyya.

Định nghĩa 1.23 (Ma trận khoảng cách từng đôi). Cho tập n hàm mật độ $\{f_1; f_2; \dots; f_n\}$, ma trận khoảng cách $D \in \mathbb{R}^{n \times n}$ là một ma trận đối xứng và có $\text{Trace}(D) = 0$, được định nghĩa bởi $D_{ij} = D(f_i; f_j)$, với mọi $i; j = 1; \dots; n$.

1.5.2 Sự tương tự của nhiều hơn hai hàm mật độ xác suất

a. Liên kết chùm hàm mật độ

Giả sử hai chùm hàm mật độ không rỗng $\mathcal{F}$ và $\mathcal{G}$ chứa hữu hạn phần tử, và $D(f; g)$ là khoảng cách giữa hai hàm mật độ, sao cho $f \in \mathcal{F}$ và $g \in \mathcal{G}$. Khoảng cách giữa hai chùm hàm mật độ là một ánh xạ $\delta : \mathcal{P}(X) \times \mathcal{P}(X) \times \mathcal{M}(X) \rightarrow \mathbb{R}_+$, trong đó, $\mathcal{P}(X)$ là tập lũy thừa của X . Ta còn gọi chùm hàm mật độ là *liên kết*, và ký hiệu là Δ . Bảng 1.4 tổng kết các loại liên kết Δ .

Bảng 1.4. Bảng tổng kết các loại liên kết Δ giữa hai chùm hàm mật độ xác suất $\mathcal{F}$ và $\mathcal{G}$

Liên kết	Ký hiệu	Δ
Liên kết đơn ¹ (SLINK)[30]	$\Delta_{\min}$	$\min_{f \in \mathcal{F}, g \in \mathcal{G}} D(f; g)$
Liên kết đủ ² (CLINK)[31]	$\Delta_{\max}$	$\max_{f \in \mathcal{F}, g \in \mathcal{G}} D(f; g)$
Liên kết tâm (UPGMC)	Δ_{centroid}	$D(\theta_{\mathcal{F}}; \theta_{\mathcal{G}})$
Liên kết trung bình (UPGMA)	Δ_{avg}	$\frac{1}{\#\mathcal{F} \cdot \#\mathcal{G}} \sum_{f \in \mathcal{F}, g \in \mathcal{G}} D(f; g)$
Liên kết Ward [32]	Δ_{Ward}	$\frac{\#\mathcal{F} \cdot \#\mathcal{G}}{\#\mathcal{F} + \#\mathcal{G}} D^2(\theta_{\mathcal{F}}, \theta_{\mathcal{G}})$

Chú thích: ¹: tổng khoảng cách nhỏ nhất; ²: tổng khoảng cách lớn nhất. *Nguồn:* Tác giả tổng hợp

Khi cần tính khoảng cách từ hợp hai chùm hàm $\mathcal{F} \cup \mathcal{G}$ đến một chùm hàm $\mathcal{H}$, ta cũng có thể sử dụng công thức biến đổi theo Bảng 1.5. Ví dụ 3.4 cung cấp hướng dẫn tính toán các liên kết Δ được trình bày ở Phụ lục B, tr. 81.

Bảng 1.5. Các phép đo khoảng cách giữa liên kết chùm ($\mathcal{F} \cup \mathcal{G}$) và chùm hàm $\mathcal{H}$

Ký hiệu	Công thức
$\Delta_{\min}(\mathcal{F} \cup \mathcal{G}; \mathcal{H})$	$\min \{D_{f \in \mathcal{F}; h \in \mathcal{H}}(f; h); D_{g \in \mathcal{G}; h \in \mathcal{H}}(g; h)\}$
$\Delta_{\max}(\mathcal{F} \cup \mathcal{G}; \mathcal{H})$	$\max \{D_{f \in \mathcal{F}; h \in \mathcal{H}}(f; h); D_{g \in \mathcal{G}; h \in \mathcal{H}}(g; h)\}$
$\Delta_{\text{avg}}(\mathcal{F} \cup \mathcal{G}; \mathcal{H})$	$\frac{1}{\#(\mathcal{F} \cup \mathcal{G}) \cdot \#\mathcal{H}} \sum_{f \in \mathcal{F} \cup \mathcal{G}} \sum_{h \in \mathcal{H}} D(f; h)$
$\Delta_{\text{centroid}}(\mathcal{F} \cup \mathcal{G}; \mathcal{H})$	$D(\theta_{\mathcal{F} \cup \mathcal{G}}; \theta_{\mathcal{H}})$
$\Delta_{\text{Ward}}(\mathcal{F} \cup \mathcal{G}; \mathcal{H})$	$\frac{\#(\mathcal{F} \cup \mathcal{G}) \cdot \#\mathcal{H}}{(\#(\mathcal{F} \cup \mathcal{G}) \cup \#\mathcal{H})} D^2(\theta_{\mathcal{F} \cup \mathcal{G}}; \theta_{\mathcal{H}})$

b. Tương tự chùm hàm mật độ

Nếu xem chùm hàm mật độ là tổng thể chứa các hàm mật độ, ta có thể đánh giá mức độ ổn định (giống nhau) của tổng thể này qua các hệ số tương tự chùm được giới thiệu ở Bảng 1.6.

Bảng 1.6. Tổng kết các tương tự giữa các chùm hàm mật độ xác suất

Tương tự	$\Delta(\mathcal{F})$
Affinity của Matusita [33]	$\int_{\Omega} \left(\prod_{j=1}^n f_j(x) \right)^{1/n} dx$
Affinity của Toussaint [34]	$\int_{\Omega} \left(\prod_{j=1}^n f_j(x) \right)^{\alpha_j} dx$
Độ rộng chùm [17]	$\int_{\Omega} f_{\max}(x) dx - 1$
Hệ số tương tự chùm [35]	$\frac{k}{k-1} \left(1 - \frac{1}{k} \int_{\Omega} f_{\max}(x) dx \right)$

Bảng 1.6 cho thấy Affinity của Toussaint suy biến thành Affinity của Matusita khi $\alpha_1 = \alpha_2 = \dots = \alpha_n = \frac{1}{n}$. Khi Affinity của Matusita có $n = 2$ thì nó trở thành hệ số Bhattacharyya. Cuối cùng, hệ số tương tự chùm chuẩn hóa tuyến tính độ rộng chùm.

1.6 Phương pháp số xấp xỉ tích phân

Các tích phân trong lĩnh vực hàm mật độ cần xấp xỉ bằng phương pháp số. Luận văn này, chọn sử dụng phương pháp hình thang nhằm cải thiện độ chính xác so với tổng Riemann nhưng cũng không tốn quá nhiều tài nguyên như Monte Carlo hay Simpsons. Một tích phân trên miền $\Omega \subset \mathbb{R}^d$ được xấp xỉ bằng công thức tổng quát $\int_{\Omega} f(x) dx = \lim_{h \rightarrow 0} \sum_i h^d w_i f(x_i)$. Khi này, giả sử hàm $f : [a; b] \rightarrow \mathbb{R}$, ta chia đoạn $[a; b]$ thành n phần bằng nhau với độ chia $h = (b - a)/n$, phương pháp hình thang một chiều xấp xỉ tích phân với mọi $x_i = a + ih$, và $i = 0; \dots; n$,

$$\int_a^b f(x) dx \approx \frac{h}{2} \left(f(x_0) + 2 \sum_{i=1}^{n-1} f(x_i) + f(x_n) \right)$$

1.7 Phân tích chùm cho hàm mật độ xác suất

1.7.1 Phân tích chùm không mờ

Phân tích chùm không mờ (hay phân chùm cứng) yêu cầu một phần tử chỉ thuộc duy nhất một chùm cố định. Tiểu mục này trình bày hai khía cạnh chính của phân tích chùm bao gồm phân tích chùm phân vùng (dựa trên trọng tâm) và phân cấp thứ bậc.

a. Phân tích chùm k -means (KCF)

Phân tích chùm phân vùng giả sử $\mathcal{S}$ là tập các véc-tơ d -chiều x_j , trong đó $j = 1; 2; \dots; n$. Mỗi đối tượng o_j liên hệ với hàm mật độ xác suất $f_j(x)$. Tập $\mathcal{F}$ gồm họ n -hàm mật độ trên Ω . Bài toán phân tích chùm phân bổ j -hàm mật độ vào c -chùm ($c \in \mathbb{N}$), với $i = 1; 2; \dots; c$ thỏa mãn ba ràng buộc

1. Hợp tất cả các chùm $\bigcup_i c_i$ bằng $\mathcal{F}$;
2. Giao của mỗi chùm là rỗng, tức là $c_i \cap c_j = \emptyset$, với mỗi $i \neq j$;
3. Lực lượng của mỗi chùm là khác rỗng, tức là $|c_i| \neq \emptyset$.

Phép gán này được mô tả bằng một ánh xạ nhiều-đến-một, hay còn gọi là bộ mã hóa $c_i = c(f_j)$, trong đó một hàm mật độ f_j được gán vào chùm thứ c_i là duy nhất. Cụ thể, ràng buộc 1 đảm bảo tất cả các đối tượng phải được phân tách thành các chùm, trong đó, mỗi chùm phải chứa ít nhất một đối tượng hàm mật độ (ràng buộc 3), và không có đối tượng nào được xếp vào hai chùm riêng biệt (ràng buộc 2).

Phân tích chùm KCF là bài toán tối thiểu đơn mục tiêu cho tổng các bình phương khoảng cách trong chùm các hàm mật độ [8, 13, 17], tức là

$$\text{Minimise : } J(U; \Theta | \mathcal{F}; c) = \sum_{i=1}^c \sum_{f_j(x) \in c_i} \mu_{ij} D^2(\theta_i; f_j), \quad (\text{KCF})$$

trong đó, hàm $\theta_i(x)$ là hàm mật độ trọng tâm của chùm thứ c_i . Ký hiệu $D^2(\theta_i; f_j)$ là khoảng cách giữa hàm mật độ trọng tâm $\theta(x)$ đến các đối tượng $f_j(x)$ còn lại trong dữ liệu. Ta cũng có μ_{ij} là biến tiềm ẩn thể hiện mức độ thành viên của hàm mật độ $f_j(x)$ thỏa $\mu_{ij} = 1_{\{j \in c_i\}}$. Tức là $\mu_{ij} = 1$ nếu hàm mật độ f_j thuộc chùm c_i , và $\mu_{ij} = 0$ nếu ngược lại.

Chứng minh. Điều kiện $\sum_i \mu_{ij} = 1$ đảm bảo rằng mỗi hàm f_j được gán vào đúng một chùm duy nhất. Mà tập tất cả các ma trận U là hữu hạn, và việc cố định U biến hàm mục tiêu KCF trở thành hàm tuyến tính theo U . Đặc biệt, với θ_i cố định, giá trị J được tối thiểu khi gán f_j vào chùm c_i sao cho $D^2(f_j; \theta_i)$ nhỏ nhất, tức là $\mu_{ij} = 1_{\{i = \arg \min_s D^2(f_j, \theta_s)\}}$. ■

Bổ đề 1.6 (Thành lập hàm mật độ đại diện). Giả sử tập $\mathcal{F}$ -hàm mật độ được phân thành c -chùm qua các mức độ thành viên μ_{ij} với bình phương khoảng cách $D^2(\theta_i; f_j)$.

Khi đó, hàm mật độ đại diện $\theta_i^*(x)$ tối ưu trên mỗi chùm c_i được cho bởi công thức

$$\theta_i^*(x) = \frac{\sum_{f_j \in c_i} \mu_{ij} f_j(x)}{\sum_{f_j \in c_i} \mu_{ij}}.$$

Chứng minh. Từ hàm mục tiêu KCF, ta cố định μ_{ij} , và đối thứ tự tổng và tích phân của hàm mục tiêu J , ta có $J(\mathcal{F}, c) = \int_{\Omega} \sum_{i=1}^c \sum_{j=1}^n \mu_{ij} (\theta_i(x) - f_j(x))^2 dx$. Lấy đạo hàm của J theo $\theta_i(x)$ ta có $\frac{\partial}{\partial \theta_i(x)} J = 2 \sum_{j=1}^n \mu_{ij} (\theta_i(x) - f_j(x))$. Cho đạo hàm bằng 0 ta suy ra được điều phải chứng minh. ■

Tóm lại, mật độ đại diện tối ưu để cực tiểu hàm mục tiêu là hàm mật độ trọng tâm (1.1) các hàm mật độ trong các chùm. Hơn nữa, vì mỗi hàm mật độ trọng tâm (1.1) được đại diện trừu tượng bằng trung bình có trọng số của từng chùm, nên kết quả trọng tâm này có thể không đồng nhất với bất kỳ đối tượng nào trong mẫu. Thay vào đó, mật độ trọng tâm này nằm bất kỳ trong không gian, đóng vai trò như một đối tượng tham chiếu để các hàm mật độ khác so sánh [36].

Một hàm mật độ mới $h(x)$ được gán vào chùm c_k nếu $k = \arg \min_i D^2(h; \theta_i)$. Hơn nữa, vì ma trận phân vùng $\mu_{ij} = 1_{\{j \in c_i\}}$ nên ta có thể rút gọn hàm mật độ đại diện (1.1) thành trung bình Fréchet với khoảng cách $\mathcal{L}_2$, tức là


$$\theta_i(x) = \frac{1}{\#c_i} \sum_{f_j(x) \in c_i} f_j(x). \quad (1.2)$$

Bổ đề 1.7 (Sự hội tụ của thuật toán KCF). Sau mỗi bước lặp của thuật toán KCF, hàm mục tiêu $J^{(t)}$ luôn giảm tại hữu hạn bước lặp t .

Chứng minh. Gọi $\mathcal{Z}^{(t)} = \{c_1^{(t)}; \dots; c_k^{(t)}\}$ là phân hoạch tại bước t , với hàm trọng tâm $\theta_i^{(t)}(x)$ và hàm mục tiêu $J^{(t)}$. Khi trọng tâm $\theta_i^{(t)}$ cố định, mỗi hàm f được gán vào chùm gần nhất. Khi đó, $\sum_{i=1}^k \sum_{f \in c_i^{(t+1)}} D^2(f; \theta_i^{(t)}) \leq J^{(t)}$ (1). Còn khi chùm $c_i^{(t+1)}$ cố định, hàm trọng tâm $\theta_i^{(t+1)}$ được cập nhật sao cho $\sum_{f \in c_i^{(t+1)}} D^2(f; \theta_i^{(t+1)}) \leq \sum_{f \in c_i^{(t+1)}} D^2(f; \theta_i^{(t)})$ (2). Cộng (1) và (2) ta được giá trị $J^{(t+1)} = \sum_{i=1}^k \sum_{f \in c_i^{(t+1)}} D^2(f; \theta_i^{(t+1)}) \leq J^{(t)}$. Hơn nữa, ta có chặn dưới $J^{(t)} - J^{(t+1)} \geq \sum_{i=1}^k |c_i^{(t+1)}| \cdot D^2(\theta_i^{(t)}; \theta_i^{(t+1)})$. Suy ra, thuật toán hội tụ đơn điệu và dừng sau hữu hạn bước do số phân hoạch hữu hạn. ■

Ví dụ 1.4 (Phân tích chùm cứng hàm Gauss 1-chiều). Cho bảy hàm mật độ chuẩn một chiều $\mathcal{F}$ cho bởi Vo-Van, Tai and Pham-Gia, T., [17] có phương sai đồng nhất $\sigma_i^2 = 1; i = 1; \dots; 7$ và các trung bình lần lượt là $\mu_i = \{0, 3; 4, 0; 9, 1; 1, 0; 5, 5; 8, 0; 4, 8\}$. Phân tích chùm KCF với $c = 3$ và khoảng cách xét là $\mathcal{L}_2$.

Ta có kết quả sau khi thực hiện các vòng lặp được giải chi tiết ở Phụ lục (tr. 81). Hình 1.5(a) cho thấy kết quả trọng tâm của ba chùm đối với khoảng cách $\mathcal{L}_2$. Các khoảng cách khác cũng được khảo sát, tuy nhiên kết quả đều giống nhau cho trọng tâm.



Hình 1.5. Kết quả phân cụm KCF đối với Ví dụ 1.4

(a) Trọng tâm, và (b) ma trận phân vùng cứng của KCF. Nguồn: Minh họa của tác giả.

b. Phân tích cụm thứ bậc (HCF)


Phân cấp thứ bậc giả định tập $\mathcal{F}^{(t=0)} = \{\{f_1\}; \{f_2\}; \dots; \{f_n\}\}$ trong [37] không yêu cầu tiên nghiệm số cụm c , mà xây dựng một cây phân cấp bằng cách hợp nhất lần lượt các cụm gần nhất theo một liên kết cho trước. Tại mỗi bước $t = 1; 2; \dots; n-1$, ta chọn hai cụm $c_i; c_j \in \mathcal{F}^{(t-1)}$ sao cho vị trí $(c_i; c_j) = \arg \min_{c_u; c_v \in \mathcal{F}^{(t-1)}} \Delta(c_u; c_v)$, trong đó, $\Delta(c_u; c_v)$ là liên kết giữa hai cụm hàm mật độ. Thuật toán 2 (Phụ lục C, tr. 79) mô tả rõ quy trình thực hiện của phương pháp phân cấp này.

Định lý 1.11 (Hội tụ của thuật toán HCF). *Giải thuật HCF luôn hội tụ sau $n-1$ bước hợp nhất và tạo thành một cây nhị phân có n nút lá và $n-1$ nút trong.*

Chứng minh. Mỗi lần hợp nhất, một cặp c_i, c_j được thay thế bằng cụm $c_i \cup c_j$, và giữ nguyên các cụm còn lại. Ta có $\forall c \in C_t, \exists c' \in C_{t+1}$ sao cho $c \subseteq c'$, tức là C_{t+1} phân rã nhỏ hơn C_t . ■

Ví dụ 1.5 (Phân cấp thứ bậc hàm Gauss 1-chiều). Ta sử dụng lại dãy hàm mật độ trong Ví dụ 1.4. Phân cấp thứ bậc với khoảng cách $D(f_1; f_2) = \mathcal{L}_2$ và liên kết $\Delta_{\max}(\mathcal{F}_1; \mathcal{F}_2)$ là liên kết đủ.

Ta có kết quả phân cấp thứ bậc tích tụ bởi Hình 1.6 và bài giải chi tiết được phân tích trong Phụ lục B (tr. 81). Quá trình phân cấp được thực hiện với hai phương pháp liên kết đủ liên kết Ward. Nhìn Hình 1.6, ta thấy phương pháp liên kết đủ có xu hướng tạo ra các cụm nhỏ, chặt chẽ, và nhạy cảm với nhiễu ở biên. Ngược lại, liên kết Ward cho kết quả các cụm có tính đồng nhất cao hơn về phân bố, làm cây phân cấp cân đối.



Hình 1.6. Kết quả phân cấp thứ bậc tích tụ HCF đối với Ví dụ 1.5

Chú thích: Cây phân cấp ở phía trên thể hiện cách sắp xếp và nhóm các hàm mật độ dựa trên liên kết, phần dưới thể hiện ma trận khoảng cách tương ứng với từng hàm mật độ đó. Nguồn: Minh họa của tác giả

1.7.2 Phân tích chùm mờ (FCF)

Phân tích chùm mờ được xây dựng lần đầu tiên cho hàm mật độ bởi Thao Nguyen-Trang and Tai Vo-Van [22] với sự phát triển từ phần tử rời rạc do [38]. Khác biệt giữa nó với phân chùm cứng là sự chấp nhận thuộc nhiều chùm của một phần tử với một *mức độ phân vùng* mềm hơn. Điều này hữu ích khi ranh giới giữa các hàm là không chắc chắn.

Giả sử $\mathcal{F}$ chưa được gán nhãn, mục tiêu của bài toán là tối thiểu hóa tổng trọng số các giá trị hàm thành viên với siêu tham số m và khoảng cách.

$$\text{Minimise : } J(U; \Theta | \mathcal{F}; c; m) = \sum_{i=1}^c \sum_{j=1}^n \mu_{ij}^m D^2(\theta_i; f_j), \quad (\text{FCF})$$

$$\text{s.t : } \sum_{i=1}^c \mu_{ij} = 1, \quad \forall j \in 1, \dots, n, \quad (\text{C1})$$

$$\mu_{ij} \in [0; 1], \quad \forall i \in 1, \dots, c, \forall j \in 1, \dots, n, \quad (\text{C2})$$

$$\sum_{j=1}^n \mu_{ij} > 0, \quad \forall i \in 1, \dots, c. \quad (\text{C3})$$

Thuật toán phân tích chùm mờ cho phần tử rời rạc đã được chứng minh là tối ưu toàn cục bởi [39–41] qua định lý Zangwill [42]. Đặc biệt, [43] mới đây chứng minh sự hội tụ toàn cục qua thuật toán độ dốc. Do đó, luận văn này chỉ giới thiệu Định lý 1.12 trình bày sự thành lập của ma trận phân vùng và hàm mật độ đại diện từ hàm mục tiêu J cho dữ liệu hàm mật độ xác suất.

Định lý 1.12. Cho $\mathcal{F}$ chứa $n > c$ hàm mật độ xác suất và $m > 1$. Xét $D_{ij} = D(\theta_i; f_j)$ với $1 \leq j \leq n; 1 \leq i \leq c$. Với mỗi j , xác định các tập $I_j = \{i | D_{ij} = 0, 1 \leq i \leq c\}$ và tập

$I_j^c = \{1; \dots; c\} \setminus I_j$. Khi đó J có thể đạt cực tiểu toàn cục khi và chỉ khi


$$\theta_i^*(x) = \frac{\sum_{j=1}^n (\mu_{ij}^*)^m f_j(x)}{\sum_{j=1}^n (\mu_{ij}^*)^m}; \text{ và} \quad (1.3)$$

$$\mu_{ij}^* = \frac{(D_{ij}^*)^{-1/(m-1)}}{\sum_{l=1}^n (D_{lj}^*)^{-1/(m-1)}}; \text{ nếu } I_j \neq \emptyset; \text{ và}, \quad (1.4)$$

$$\mu_{ij}^* = 0; \forall i \in I_j^c \text{ và } \sum_{i \in I_j^c} \mu_{ij}^* = 1; \text{ nếu } I_j \neq \emptyset, \quad (1.5)$$

Nhận xét. Ở đây, tham số m thể hiện mức độ mờ của ma trận phân vùng μ_{ij} . Khi $m \rightarrow 1$, ma trận phân vùng kết quả sẽ tiến về ma trận phân vùng không mờ ($\mu_{ij} = 1_{\{j \in c_i\}}$). Khi $m \rightarrow \infty$, các giá trị μ_{ij} sẽ trở nên bằng nhau ($= 1/c$) làm mất khả năng gán các hàm mật độ xác suất vào các chùm.

Để minh họa ảnh hưởng của tham số m , ta giả định hai chùm với $D_{2j} = 2 - D_{1j}$, và xét giá trị μ_{1j} theo khoảng cách này chạy từ 0 đến 2. Hình 1.7 trực quan hóa cách m điều chỉnh mức độ. Khi $m \rightarrow 1$, đường phân vùng trở nên gãy; khi m tăng, đường cong trở nên phẳng và đều ở $y = 1/2$. Nhiều nghiên cứu tổng quát hóa tham số m đã được đặt ra sau khi thuật toán này công bố. Tuy nhiên, cho đến nay các nhà phân tích vẫn chọn tiêu biểu $m = 2$ vì tính dễ giải thích [7, 40].



Hình 1.7. Biểu đồ phân vùng mờ theo khoảng cách D_{1j} với các hệ số m khác nhau.

Chú thích: Giá trị μ_{1j} tại trục tung biểu diễn mức độ phân vùng tại chùm 1 theo khoảng cách $D_{1j} = \mathcal{L}_1(f_1; f_j)$ với các giá trị $m = 1,1; 1,5; 2,0; 3,0; 5,0; 10,0$. Nguồn: Minh họa của tác giả.

Thuật toán phân chùm mờ FCF được thực hiện qua hai bước cập nhật trọng tâm và cập nhật ma trận phân vùng [7, 22] (Thuật toán 4). Kết thúc thuật toán ta nhận được ma trận phân vùng U_f và các trọng tâm chùm Θ . Trong đó, tiêu chuẩn dừng cho FCF là chênh lệch tuyệt đối tối đa giữa các phần tử của ma trận phân vùng $\mu^{(t)}$ và $\mu^{(t-1)}$ liên tiếp phải thấp hơn ngưỡng dương ε cho trước. Cuối cùng, ta có thể giải mờ theo quy tắc $c_i = \arg \max_i \mu_{ij}$. Tức là một hàm mật độ $f_j(x)$ được xếp vào chùm c_i khi và chỉ khi nó có mức độ phân vùng tại chùm đó là cao nhất.

Ví dụ 1.6 (Phân chùm mờ hàm Gauss 1-chiều). Ta sử dụng lại dãy hàm mật độ trong Ví dụ 1.4. Phân tích $\mathcal{F}$ thành ba chùm, biết $m = 2$, tiêu chuẩn dừng $\varepsilon = 10^{-3}$, và khoảng cách là $\mathcal{L}_2$. Ta có kết quả sau khi thực hiện các vòng lặp được giải chi tiết ở Phụ lục (tr. 81).

Nhận xét. Dựa vào mức độ phân vùng μ_{ij} , ta nhận thấy được mức độ tin cậy một hàm mật độ $f_j(x)$ xếp vào chùm c_i . Nếu phân vùng μ_{ij} tại chùm c_i này lớn, ta có thể chắc chắn vào kết quả phân bổ, ngược lại, nếu giá trị này không cao, ta biết được hàm mật độ này có khả năng thuộc vào một chùm khác hoặc một chùm mới thay vì thuộc vào chùm c_i .

So sánh về mặt phức tạp thời gian và phức tạp dung lượng, Bảng 1.7 cho thấy phương pháp k -mean đơn giản hơn và ít tốn tài nguyên tính toán hơn so với Fuzzy c -mean và thuật toán thứ bậc.

Bảng 1.7. So sánh độ phức tạp của ba thuật toán phân chùm

Thuật toán	Phức tạp thời gian	Phức tạp không gian
Phân chùm KCF	$\mathcal{O}(ncdi)$	$\mathcal{O}(n + cd)$
Phân cấp HCF	$\mathcal{O}(n^2 \log n)$	$\mathcal{O}(n^2)$
Phân chùm FCF	$\mathcal{O}(ncdi)$	$\mathcal{O}(nc)$

Chú thích: n là # đối tượng trong dữ liệu, c là # chùm, d là # chiều dữ liệu, i là # vòng lặp.

1.8 Phân loại cho hàm mật độ xác suất

Ở dữ liệu rời rạc, bốn thuật toán phân loại kinh điển dựa vào thống kê là Naive Bayes, Cây quyết định, hồi quy Logistics, phân biệt Fisher [44] và Perceptron [45] đã được áp dụng phát triển cho đến hiện nay. Trong khi đó, các phát triển phân loại hàm mật độ chỉ dựa trên phương pháp Bayesv. Luận văn này tập trung nghiên cứu phương pháp hồi quy logistics, máy véc-tơ hỗ trợ, và đặc biệt là phương pháp Bayes cho dữ liệu hàm mật độ [46, 47].

1.8.1 Hồi quy logistics

Phương pháp này được tổng quát hóa cho dữ liệu hàm bởi các nghiên cứu của Akturk et al. [48]. Luận văn này cụ thể hóa cho hàm mật độ xác suất. Mô hình hồi quy logistic cho dữ liệu hàm mật độ có dạng

$$\pi_j = \mathbb{P}(Y_j = 1 | f(x) = f_j(x)) = \frac{\exp\{\beta_0 + \int_{\Omega} f(x)\beta(x) dx\}}{1 + \exp\{\beta_0 + \int_{\Omega} f(x)\beta(x) dx\}}, \quad (1.6)$$

trong đó $\beta_0 \in \mathbb{R}$ là hằng số chặn, và $\beta(x) \in \mathcal{L}_2[\Omega]$ là hàm hệ số cần ước lượng. Để giải phương trình (1.6), biến đổi logit được sử dụng

$$\ell_j = \log \left(\frac{\pi_j}{1 - \pi_j} \right) = \beta_0 + \int_{\Omega} f(x) \beta(x) dx.$$

Mục tiêu tiếp theo là ước lượng β_0 và hàm $\beta(x)$. Do $\beta(x)$ là vô hạn chiều, ta chiếu hàm này vào một tập hàm cơ sở chọn trước để ước lượng, cụ thể là hàm Gauss, wavelet, chuỗi Fourier, đa thức Bernstein và Legendre, hoặc B-spline (Xem thêm Bảng 3.4 tại Phụ lục C, tr. 79). Khi đó,

$$\ell_j = \beta_0 + \sum_{m=1}^M \theta_m \underbrace{\int_{\Omega} \psi_m(x) f_j(x) dx}_{=: \Phi = \phi_{j,m}},$$

trong đó $\phi_{j,m}$ là mô-men của hàm mật độ $f_j(x)$ trên hàm cơ sở $\psi_m(x)$.

Bài toán ước lượng $\beta(x)$ chuyển thành cực đại hóa log-likelihood của hồi quy logistics

$$\ell(\beta_0; \beta(x)) = \max_{\substack{\beta_0 \in \mathbb{R}, \\ \beta(x) \in \mathbb{R}^M}} \left\{ \underbrace{\sum_{j=1}^n [y_j \log \pi_j + (1 - y_j) \log(1 - \pi_j)]}_{\text{Logistics}} - \underbrace{\lambda_1 \sum_{m=1}^M |\beta_m(x)|}_{\text{Lasso}} - \underbrace{\frac{\lambda_2}{2} \sum_{m=1}^M \beta_m(x)^2}_{\text{Ridge}} \right\},$$


trong đó, $\pi_j = \mathbb{P}(Y_j = 1 | f(x))$ và ℓ là hàm mất mát.

Định lý 1.13. *Hàm mất mát ℓ là một hàm lồi theo cả β_0 và $\beta(x)$. Nếu $\lambda_2 > 0$ thì hàm này lồi nghiêm ngặt. Vì vậy, nghiệm tối ưu toàn cục luôn tồn tại duy nhất.*

Từ Định lý 1.13, ta tính được Gradient theo hệ số $\beta(x)$ với $\hat{y}_j = \pi_j$ là xác suất dự đoán, có dạng $\nabla_{\beta} \ell = \Phi^T(y - \hat{y}) - \lambda_1 \text{sign}(\beta(x)) - \lambda_2 \beta$, mà qua đó ta có nhiều phương pháp tối ưu như tối ưu độ dốc như ADAM, hay các quasi-Newton khác như L-BFG-S.

Ví dụ 1.7 (Phân loại hàm mật độ bằng hồi quy logistic). Xét hai lớp hàm mật độ Gauss $\mathcal{F}$ và $\mathcal{G}$ với các trung tâm lần lượt là $\mu_{\mathcal{F}} = \{1, 0; 1, 5; 2, 0; 2, 5; 6, 0\}$, và $\mu_{\mathcal{G}} = \{4, 5; 7, 5; 8, 5; 8, 0; 9, 0\}$, trong đó phương sai lần lượt là $\sigma_{\mathcal{F}}^2 = 0, 4$ và $\sigma_{\mathcal{G}}^2 = 0, 9$. Bài toán đặt ra là phân loại một hàm mật độ Gauss mới $h(x) = \mathcal{N}(3, 0; 0, 9)$ vào một trong hai lớp $\mathcal{F}$ hoặc $\mathcal{G}$.

Sử dụng $M = 10$ hàm cơ sở Gauss, ta ước lượng được hàm hệ số $\hat{\beta}(x)$, phản ánh đóng góp của từng miền x đối với phân loại. Hàm $\hat{\beta}(x)$ được tái tạo và minh họa ở Hình 1.8.



Hình 1.8. Hàm $\hat{\beta}(x)$ được ước lượng qua 10 hàm cơ sở Gauss.

Tiếp theo, để phân loại h , ta cũng chiếu lên không gian cơ sở. Hàm h được chiếu lên 10 hàm cơ sở Gauss để tạo thành véc-tơ đặc trưng được đưa vào mô hình logistic đã huấn luyện. Cuối cùng, mô hình logistic dự đoán xác suất h thuộc lớp $\mathcal{F}$ là 43,26%. Do đó, ta phân loại $h(x)$ vào lớp $\mathcal{F}$.

Nhận xét. Hàm hệ số $\hat{\beta}(x)$ đóng vai trò như một công cụ giải thích quan trọng, cho phép đánh giá mức độ đóng góp của từng miền $x \in \Omega$ đối với quá trình phân loại nhị phân. Đáng chú ý, $\hat{\beta}(x)$ cung cấp một dạng giải thích bằng tính năng, giúp ta hiểu thêm nguồn gốc của từng đóng góp riêng lẻ đến xác suất phân loại.

Hình 1.8 cho thấy $\hat{\beta}(x)$ dao động quanh trục 0 với cả miền dương và âm, phản ánh rằng các vùng khác nhau của x có ảnh hưởng trái ngược đến xác suất dự đoán. Những vùng mà $\hat{\beta}(x) > 0$ sẽ tăng xác suất dự đoán lớp 1, và ngược lại. Cụ thể, các hệ số ψ_5 và ψ_8 có giá trị dương thể hiện tác động tăng xác suất dự đoán, trong khi ψ_3 và ψ_6 mang giá trị âm, góp phần làm giảm xác suất của lớp $\mathcal{F}$. Việc áp dụng các kỹ thuật chuẩn hoá Ridge làm giảm hệ số một cách đồng đều, còn Lasso tạo ra sự chọn lọc hàm cơ sở ψ_m quan trọng.

1.8.2 Máy véc-tơ hỗ trợ

Cho tập huấn luyện $\mathcal{D} = \{(f_j, y_j)\}_{j=1}^n; f_j \in \mathcal{F}, y_j \in \{-1, 1\}$. Bài toán máy véc-tơ hỗ trợ lờ mềm được xây dựng từ nguyên lý cực tiểu hoá độ lớn véc-tơ trọng số w và cho

phép sai số điều chỉnh được bởi các biến ξ_j , tức là

$$\begin{aligned} \text{Maximise : } & \frac{1}{2} \|w\|_{\mathcal{H}}^2 + C \sum_{j=1}^n \xi_j, \\ \text{S.t. : } & y_j (\langle w, \Phi(f_j) \rangle + b) \geq 1 - \xi_j, \\ & \xi_j \geq 0, \quad j = 1, \dots, n. \end{aligned}$$

Hàm L'Agrange tương ứng được cho bởi

$$\mathcal{L}(w, b, \xi, \alpha, \mu) = \frac{1}{2} \|w\|^2 + C \sum_{j=1}^n \xi_j - \sum_{j=1}^n \alpha_j [y_j (\langle w, \Phi(f_j) \rangle + b) - (1 - \xi_j)] - \sum_{j=1}^n \mu_j \xi_j.$$

Lấy đạo hàm theo w và đặt $\nabla_w \mathcal{L} = 0$. ta có $w = \sum_{j=1}^n \alpha_j y_j \Phi(f_j)$. Thay vào hàm L'Agrange, ta được bài toán đối ngẫu của SVM được định nghĩa bởi

$$\begin{aligned} \text{Maximise : } & \sum_{j=1}^n \alpha_j - \frac{1}{2} \sum_{j=1}^n \sum_{k=1}^n \alpha_j \alpha_k y_j y_k \underbrace{\langle \Phi(f_j), \Phi(f_k) \rangle}_{K(f_j, f_k)}, \quad (\text{SVM}) \\ \text{S.t. : } & 0 \leq \alpha_j \leq C, \quad \sum_{j=1}^n \alpha_j y_j = 0. \quad (1.7) \end{aligned}$$

Định lý 1.14. SVM là bài toán tối ưu lồi nghiêm ngặt trên đa diện lồi compact, do đó tồn tại duy nhất nghiệm véc-tơ $\alpha^* \in \mathbb{R}^n$.

Chứng minh. Ma trận Gram $G_{jk} = y_j y_k K(f_j, f_k)$ là xác định dương do K là kernel thỏa mãn điều kiện Mercer. Hàm mục tiêu là hiệu của một hàm tuyến tính và một dạng toàn phương xác định dương nên lồi nghiêm ngặt. Nhờ đó, tồn tại nghiệm cực đại duy nhất theo định lý Weierstrass.

Khi đó, hàm phân lớp tương ứng đối với hàm mật độ mới h là

$$\hat{y}(h) = \text{sign}(g(h)) = \text{sign} \left(\sum_{j=1}^n \alpha_j^* y_j K(f_j, h) + b^* \right).$$

1.8.3 Phương pháp naive Bayes

a Thuật toán phân lớp

Phương pháp naive Bayes đã được nhiều nhà thống kê quan tâm cho dữ liệu hàm mật độ xác suất bởi [49]. Cho tập huấn luyện $\mathcal{D} = \left\{ (f_j; y_j)_{j=1}^n ; f_j \in \mathcal{F}, y_j \in \{0; 1\} \right\}$. Xác suất hậu nghiệm Bayes để xếp $h(x)$ vào lớp $Y = k$ được viết dưới dạng

$$\mathbb{P}(Y = k | h) = \frac{\mathbb{P}(Y = k) f(h | Y = k)}{\sum_{j \in \{0, 1\}} \mathbb{P}(Y = j) f(h | Y = j)}. \quad (1.8)$$

Khi này, ta ước lượng mật độ có điều kiện $f(h|Y = k)$ bằng kỳ vọng của hàm hạt nhân giữa đối tượng mới h và các hàm mật độ huấn luyện f_i trong lớp $Y = k$. Tức là,

$$f(h|Y = k) = \frac{1}{n_k b w_k} \sum_{i=1}^{n_k} \mathbb{E}_{X \sim h, Y \sim f_i} \left(\kappa \left(\frac{X - Y}{b w_k} \right) \right), \quad (1.9)$$

trong đó n_k là số mẫu huấn luyện thuộc lớp $Y = k$, f_i là các hàm mật độ huấn luyện trong lớp đó, và $b w_k$ là tham số trơn. Dưới dạng tích phân, công thức (1.9) tương đương với

$$f(h|Y = k) = \frac{1}{n_k} \sum_{i=1}^{n_k} \iint \frac{1}{b w_k} \kappa \left(\frac{x - y}{b w_k} \right) h(x) f_i(y) dx dy.$$

Giả sử không có thông tin tiên nghiệm, ta lấy tiên nghiệm đều $\mathbb{P}(Y = 1) = \mathbb{P}(Y = 0) = 1/2$. Khi này ta có quy tắc phân loại hàm mật độ $h(x)$ phân loại vào lớp $Y = 1$ nếu $f(h|Y = 1) > f(h|Y = 0)$ và ngược lại. Tương tự, đối với phân loại nhiều hơn hai lớp, hàm mật độ h sẽ được phân loại vào lớp k nào có hậu nghiệm lớn nhất, tức là

$$\hat{y} = \arg \max_{k \in \{1; \dots; K\}} \mathbb{P}(Y = k|h).$$

Bổ đề 1.8 (Hàm mật độ Gauss có điều kiện). Xét công thức ước lượng mật độ có điều kiện $f(h|Y = k)$. Nếu chọn hạt nhân Gauss $\kappa(u) = \mathcal{N}(u; 0, 1)$, thì ta có

$$f(h|Y = k) = \frac{1}{n_k} \sum_{i=1}^{n_k} \mathcal{N}(\mu_h - \mu_i; 0, \sigma_h^2 + \sigma_i^2 + b w_k^2),$$

trong đó $\mathcal{N}(\cdot; 0, \tau^2)$ là mật độ Gauss với trung bình 0 và phương sai τ^2 .

Chứng minh. Ta có $\kappa \left(\frac{x-y}{b w_k} \right) = \mathcal{N}(x-y; 0, b w_k^2)$. Ngoài ra, viết lại tích phân đôi theo biến $z = x - y$, ta có

$$\iint \mathcal{N}(z; 0, b w_k^2) h(y+z) f_i(y) dz dy.$$

Đặt $X \sim \mathcal{N}(\mu_h, \sigma_h^2)$ và $Y \sim \mathcal{N}(\mu_i, \sigma_i^2)$ độc lập. Khi đó biến ngẫu nhiên $Z = X - Y$ cũng tuân theo phân phối chuẩn (Bổ đề 1.1), tức là $Z \sim \mathcal{N}(\mu_h - \mu_i, \sigma_h^2 + \sigma_i^2)$. Do đó, giá trị $f(h|Y = k)$ có thể viết thành kỳ vọng

$$f(h|Y = k) = \int \mathcal{N}(z; 0, b w_k^2) \mathcal{N}(z; \mu_h - \mu_i, \sigma_h^2 + \sigma_i^2) dz.$$

Áp dụng Bổ đề 1.2 về tích phân của tích hai mật độ chuẩn với $a = b w_k^2$, $b = \sigma_h^2 + \sigma_i^2$, $m = \mu_h - \mu_i$ ta thu được điều phải chứng minh. ■

Ví dụ 1.8 (Phân loại hàm mật độ bằng phương pháp naive Bayes). Trở lại giả thuyết của Ví dụ 1.7, ta cần phân loại hàm mật độ Gauss mới $h(x) = \mathcal{N}(3; 0, 0.9)$ vào một trong hai lớp.

Bài giải. Giả sử không có thông tin tiên nghiệm, $\mathbb{P}(Y=1) = \mathbb{P}(Y=0) = 0,5$. Theo Bổ đề 1.8 ta có

$$f(h|Y=k) = \frac{1}{n_k} \sum_{i=1}^{n_k} \frac{1}{\sqrt{2\pi(\sigma_h^2 + \sigma_i^2 + bw_k^2)}} \exp\left(-\frac{(\mu_h - \mu_i)^2}{2(\sigma_h^2 + \sigma_i^2 + bw_k^2)}\right).$$

Dùng quy tắc Silverman cho từng lớp, ta có

$$h_{\mathcal{F}} = 1,06 \sqrt{0,4} (n_{\mathcal{F}})^{-1/5} = 0,486, \text{ và } h_{\mathcal{G}} = 1,06 \sqrt{0,9} (n_{\mathcal{G}})^{-1/5} = 0,729,$$

Khi này, ta tính được $f(h|\mathcal{F})$ qua các kỳ vọng $\mu_{\mathcal{F}}$, ta có kết quả $f(h|\mathcal{F}) = 0,158$. Tương tự, ta cũng tính được $f(h|\mathcal{G})$ qua với các kỳ vọng $\mu_{\mathcal{G}}$, kết quả là $f(h|\mathcal{G}) = 0,033$.

Cuối cùng, xác suất hậu nghiệm của hai lớp được tính bởi công thức

$$\mathbb{P}(\mathcal{F}|h) = \frac{0,5 f(h|\mathcal{F})}{0,5 f(h|\mathcal{F}) + 0,5 f(h|\mathcal{G})} = \frac{0,5 \cdot 0,158}{0,5 \cdot 0,158 + 0,5 \cdot 0,033} = 0,826,$$

và $\mathbb{P}(\mathcal{G}|h) = 1 - 0,826 = 0,174$. Vì $\mathbb{P}(\mathcal{F}|h) > \mathbb{P}(\mathcal{G}|h)$ nên $h(x)$ được phân loại vào lớp $\mathcal{F}$ với xác suất hậu nghiệm xấp xỉ 82,6%.

b *Xác định tiên nghiệm*

Trong phân lớp Bayes, xác suất tiên nghiệm $\mathbb{P}(Y=k)$ thường được ước lượng dựa vào kiến thức chuyên gia hoặc thông tin trong lịch sử nghiên cứu tương tự. Trong trường hợp không có thông tin tiên nghiệm nào, ta có thể giả định mọi lớp đều có xác suất bằng nhau, tức là $\mathbb{P}(Y=k) = 1/k$. Trong nhiều tình huống, xác suất tiên nghiệm còn có thể ước lượng từ tần suất xuất hiện của các lớp trong tập dữ liệu huấn luyện. Khi đó, $\mathbb{P}(Y=k) = n_k/n$ trong đó n_k là số lượng mẫu thuộc lớp k và n là tổng số mẫu. Tuy nhiên, phương pháp này có thể gặp vấn đề khi dữ liệu ít hoặc có xác suất bằng 0 cho một số lớp, phương pháp Laplace được sử dụng để điều chỉnh, $\mathbb{P}(Y=k) = (n_k + \alpha)/(n + \alpha k)$, với $\alpha > 0$. Với tiên nghiệm Laplace ta chọn $\alpha = 1$, và với Jeffreys, ta chọn $\alpha = 1/2$.

Tổng kết Chương 1

Chương 1 trình bày cơ sở lý thuyết của hàm mật độ xác suất, các phép đo khoảng cách và phương pháp phân tích chùm/phân loại. Những kiến thức này đóng vai trò nền tảng cho các chương tiếp theo.

CHƯƠNG 2

NHẬN DẠNG THỐNG KÊ CHO HÀM MẬT ĐỘ XÁC SUẤT VỚI DỮ LIỆU MẤT CÂN BẰNG

2.1 Giới thiệu dữ liệu hàm mật độ

Hàm mật độ xác suất được xem là dạng dữ liệu đặc trưng với cấu trúc phức tạp hơn. Nó cho phép khám phá quy luật phân bố tại nhiều tổng thể khác nhau hoặc được xem như đối tượng không chắc chắn khi quyết định chưa chính xác hoặc có lỗi. Nhìn chung, có hai dạng dữ liệu hàm mật độ bao gồm hàm mật độ rời rạc và liên tục. Để xuyên suốt trong quá trình thực hiện các thuật toán đề xuất, Chương 2 sử dụng dữ liệu hàm liên tục là ánh xạ đo được $\mathcal{F} : (\Omega, \mathcal{S}, P) \rightarrow (\mathcal{D}, \mathcal{B}_D)$ với $(\Omega, \mathcal{S}, P)$ là không gian xác suất và sigma-đại số Borel $\mathcal{B}_D$ trên $(\mathcal{D}, d)$. Một tập đối tượng hàm mật độ quan sát là $f_j \sim \mathcal{F}$ với $j = 1, \dots, n$ (Theo Định nghĩa 1.8 và 1.9).

Dữ liệu hàm mật độ liên tục ngày càng được quan tâm trong nhiều lĩnh vực ứng dụng thực tế, đặc biệt là khi cần mô tả và phân tích các đại lượng có tính ngẫu nhiên biến thiên liên tục theo không gian và thời gian. Trong dữ liệu 1-chiều, nghiên cứu về cá hồi vây vàng (*Yellowfin tuna*) của Minami [50] thể hiện phân bố chiều dài cá theo từng ô tọa độ tại Thái Bình Dương. Bên cạnh đó, các phân phối liên quan đến tỷ giá theo ngày, khí hậu ở các trạm theo năm, mật độ tuổi giữa hai giới ở các tỉnh thành, hay chỉ số sức khỏe theo độ tuổi [18, 19] cũng là những ví dụ tiêu biểu cho dạng 1-chiều. Đặc biệt, dữ liệu hàm mật độ còn có thể được xây dựng từ hình ảnh thông qua việc trích xuất thông tin màu sắc [13, 47], mở ra hướng nghiên cứu mới trong phân tích thị giác và nhận dạng mẫu. Trong khi đó, dữ liệu 2-chiều thường xuất hiện trong các nghiên cứu về mối tương quan, chẳng hạn như phân tích điểm số sinh viên giữa các khoa hoặc viện tại Đại học Cần Thơ [23]. Ngoài ra, dữ liệu này còn có thể được xem là sự mở rộng tự nhiên của các véc-tơ rời rạc đa chiều [46, 51].

Tuy nhiên, quá trình thu thập và xử lý loại dữ liệu này thường đòi hỏi nhiều thời gian, đồng thời gặp khó khăn trong việc lưu trữ và biểu diễn trong không gian vô hạn chiều. Do đó, trong những năm gần đây, nhiều phương pháp tiếp cận mới từ nhận dạng thống kê đã được phát triển nhằm đáp ứng nhu cầu phân tích và khai thác dữ liệu dạng hàm mật độ. Các hướng tiếp cận này bao gồm hai nhóm chính: phân tích chùm và phân loại hàm mật độ xác suất.

2.2 Giới thiệu bài toán phân tích chùm cho dữ liệu mất cân bằng

2.2.1 Phương pháp phân tích chùm hàm mật độ xác suất

Phân tích chùm đóng vai trò quan trọng trong lĩnh vực nhận dạng mẫu, đặc biệt khi mục tiêu là khám phá cấu trúc tiềm ẩn trong dữ liệu mà không cần thông tin gán nhãn trước. Nói cách khác, đây là một trong những nhánh chính của nhận dạng không được giám sát [52–54]. Nó tập trung vào việc phát hiện các nhóm tự nhiên trong tập dữ liệu thông qua độ tương tự giữa các mẫu đầu vào [5, 9].

Ví dụ, trong y học, phương pháp này được sử dụng để khoanh vùng khối u trong hình ảnh MRI; hoặc trong khoa học xã hội, nó hỗ trợ tổng hợp và nhóm các ý kiến, quan điểm theo từng chủ đề khác nhau trong các báo cáo định tính. Như vậy, đầu ra của phân tích chùm chính là các nhãn được gán cho dữ liệu ban đầu, thể hiện mối quan hệ giữa các phần tử trong không gian đặc trưng.

Về mặt lịch sử, đã có nhiều công trình nghiên cứu chuyên sâu liên quan đến bài toán phân tích chùm. Bài toán này lần đầu tiên được giới thiệu vào những năm 2010 [23, 55], mở ra hướng tiếp cận mới cho việc xử lý dữ liệu phức tạp. Hơn nữa, song song với sự phát triển của các phần tử rời rạc và công cụ mô hình hóa thống kê, bài toán phân tích chùm hàm mật độ đã không ngừng được hoàn thiện và mở rộng phạm vi ứng dụng trong thực tế.

Tổng quan tiến trình phát triển của các phương pháp phân tích chùm hàm mật độ trong giai đoạn 5 năm gần đây (2019–2024) được trình bày trong Bảng 2.1, qua đó thể hiện xu hướng tiến hóa từ các phương pháp truyền thống sang các kỹ thuật thích nghi và lai ghép hiện đại.

Nhìn chung, các nghiên cứu từ các tác giả trong nước cho thấy xu hướng phát triển mạnh mẽ cả về chiều sâu lý thuyết lẫn chiều rộng ứng dụng. Cụ thể, các hàm mục tiêu truyền thống như SSE và VCC đã dần được mở rộng và tinh chỉnh thành những biến thể phức tạp hơn, chẳng hạn như CSB và FSF, cho phép đánh giá chất lượng kết quả phân tích chùm một cách đa chiều và sâu sắc hơn. Đáng chú ý, nghiên cứu của Thao Nguyen-Trang đã sử dụng FSF [25] hoặc CSB [26] làm hàm mục tiêu phân chùm, qua đó thể hiện nỗ lực đào sâu vào nội hàm và bản chất tối ưu của thuật toán. Hơn nữa, giai đoạn năm 2019 đánh dấu bước chuyển quan trọng khi các mô hình phân chùm bắt đầu mở rộng từ dạng cứng [56] sang các phương pháp tổng quát hơn như mờ [57], khả dĩ [59] và bán giám sát [13]. Cụ thể, các công trình trong năm 2019 chủ yếu tập trung vào mô hình phân chùm cứng, tiêu biểu là k -medoids và KCF. Tuy nhiên, từ sau năm 2019, các hướng nghiên cứu đã chuyển dần sang mô hình phân chùm mờ, điển hình trong các công trình của Tai Vo-Van [23, 57], trong đó tác giả đã áp dụng FCF với $m = 2$. Đặc biệt, đến cuối năm 2024, nhóm tác giả Thao Nguyen-Trang [13] đã giới thiệu một mô hình

Bảng 2.1. Tổng quan giai đoạn 5 năm (2019–2024) nghiên cứu phân tích cụm cho hàm mật độ xác suất

Năm	Tác giả	Mô tả phương pháp	Khoảng cách	Phân cụm tự động
2019	Tai Vo-Van [23]	Phân cụm FCF, $m = 2$, tìm số cụm bằng SUP	Độ rộng cụm	×
2019	Dinh Pham-Toan <i>et al.</i> [56]	Phân cụm k -medoids, tối thiểu SSE bằng nhị phân aeDE, số cụm cho trước	$\mathcal{L}_2$	×
2020	Dinh Pham-Toan & Tai Vo-Van [57]	Phân cụm FCF, tối thiểu VCC bằng nhị phân GA, $m = 2$, tìm số cụm bằng SUP	$\mathcal{L}_1$	×
2023	Thao Nguyen-Trang, Tai Vo-Van & Ha Che-Ngoc [58]	Phân cụm tự cập nhật cải tiến, tự động dựa trên SUP	Hạt nhân Gauss $\mathcal{L}_1$	×
2023	Thao Nguyen-Trang <i>et al.</i> [26]	Phân cụm cứng, tối thiểu CSB bằng DE, hàm đại diện Gauss	$\mathcal{L}_2$	✓
2023	Thao Nguyen-Trang, Trung Nguyen-Thoi, & Tai Vo-Van [25]	Phân cụm FCF, tối thiểu FSF bằng DE, hàm đại diện Gauss, $m = 1$	$\mathcal{L}_1$	✓
2024	Hung Tran-Nam, Thao Nguyen-Trang & Ha Che-Ngoc [59]	Phân cụm khả dĩ, tối thiểu SSE, chọn ngưỡng bắt thường bằng α -cut, $m = 2$, số cụm cho trước	$\mathcal{L}_2$	×
2024	Thao Nguyen-Trang, Yen Nguyen-Hoang & Tai Vo-Van [13]	Phân cụm KCF, tối thiểu SSE, bán giám sát bằng số lượng % nhãn cho trước, số cụm cho trước	$\mathcal{L}_1$	×
2020	Jen-Hao Chen & Wen-Liang Hung [60]	Phân cụm cứng bằng jackknife Shannon entropy, điều chỉnh ngưỡng bằng tối đại VCC	hạt nhân Gauss $\mathcal{L}_1$	✓
2021	Tavakkol, Behnam & Son, Youngdoo [51]	Phân cụm mờ hạt nhân k -medoids cho dữ liệu hàm mật độ 2-chiều, $m = 2$, số cụm cho trước	hạt nhân Gauss $\mathcal{L}_1$	×
2024	Okano Ryo & Imaizumi Masaaki [61]	Phân cụm cứng cho dữ liệu hàm mật độ	W_2	×

Chú thích: Đối với hàm mục tiêu, SSE: sai số của bình phương tối thiểu; VCC: tiêu chuẩn tỷ lệ phương sai (chỉ số Calinski–Harabasz); CSB: hợp của độ đo tương đồng và cân bằng; FSF: tỷ lệ giữa SSE và sự phân biệt giữa các cụm. Đối với phương pháp tối ưu, DE: tiến hóa vi phân; aeDE: tiến hóa vi phân ưu tú thích nghi; GA: giải thuật di truyền. Ở cột cuối, dấu ✓ có nghĩa là tự động toàn bộ thuật toán.

phân chùm bán giám sát, sử dụng một phần dữ liệu có nhãn để cải thiện độ chính xác của quá trình phân chùm. Sự xuất hiện của hướng tiếp cận này cho thấy bước tiến rõ rệt trong việc kết hợp giữa học có giám sát và không giám sát.

Ở bình diện quốc tế, hai công trình tiêu biểu thể hiện hai hướng tiếp cận khác nhau trong nghiên cứu phân tích chùm. Cụ thể, Chen & Hung (2020) [60] tập trung vào việc sử dụng tiêu chuẩn thông tin để tự động phát hiện cấu trúc chùm và xác định số chùm tối ưu, hướng đến việc giảm sự phụ thuộc vào tham số người dùng. Ngược lại, Tavakkol & Son (2021) [51] lại khai thác không gian hạt nhân nhằm xử lý hiệu quả các chùm có hình dạng bất quy tắc và ranh giới phức tạp. Mặc dù các mục tiêu khác nhau, điểm chung giữa chúng là sự mở rộng nền tảng của phân chùm truyền thống sang các dạng dữ liệu có cấu trúc cao hơn. Về mặt ứng dụng, thuật toán entropy-jackknife là phương pháp phân chùm cứng phù hợp cho dữ liệu hình ảnh, trong khi mô hình của Tavakkol & Son lại thích hợp hơn cho dữ liệu hàm mật độ đa chiều và liên tục.


Tuy vậy, vấn đề mất cân bằng chùm vẫn chưa có một hướng tiếp cận chuyên biệt. Tỷ lệ mất cân bằng (IR) được định nghĩa là tỷ số giữa số phần tử lớn nhất và số phần tử nhỏ nhất giữa các chùm hay lớp, $IR = \frac{\max_i \#c_i}{\min_j \#c_j}$, trong đó $\#c_i$ là số lượng phần tử trong chùm/lớp i . Khi $IR = 1$, các chùm/lớp có quy mô cân bằng hoàn toàn. Giá trị IR càng lớn thì mức độ mất cân bằng càng cao, nghĩa là sự chênh lệch kích thước giữa chùm/lớp lớn nhất và nhỏ nhất càng rõ rệt. Trong kinh tế, các giá trị IR từ trên 10 là đã có tác động tiêu cực đến các thuật toán cả thống kê và học máy/học sâu. Để giải quyết bài toán này, đa số nghiên cứu phân tích chùm tập trung vào việc cải thiện hàm mục tiêu hay cơ chế tối ưu hóa, nhưng đều giả định các chùm/lớp có quy mô tương đối đồng đều như phân tích chùm KCF hay FCF. Khi tỷ lệ mất cân bằng tăng cao, kết quả phân tích thường bị lệch, chùm nhỏ dễ bị hút vào chùm lớn, hoặc phân loại phần tử mới không đúng và lớp thiếu số. Do đó, việc phát triển các thuật toán phân tích chùm và phân loại có khả năng chống chịu với mất cân bằng là một khoảng trống nghiên cứu quan trọng.

Phân tích chùm cho dữ liệu mất cân bằng là chủ đề phát triển để giải quyết nhu cầu thực tế. Bài toán khoanh vùng hình ảnh hòn đảo giữa đại dương được ghi nhận là có sự mất cân bằng, hay phân đoạn chuỗi tín hiệu hiếm như động đất cũng có tính chất mất cân bằng hơn tín hiệu nền yên tĩnh. Nói cách khác, dữ liệu lúc này có sự chênh lệch lớn giữa các loại trong tự nhiên và tồn tại hai tình trạng: Kích thước chùm và số lượng phần tử trong chùm mất cân bằng. Cụ thể, mất cân bằng về kích thước chùm xảy ra khi các chùm có mức độ phân tán khác biệt đáng kể về đường kính hoặc mật độ, trong khi mất cân bằng về số lượng biểu hiện qua sự chênh lệch lớn trong tổng số mẫu giữa các chùm. Khi đó, các thuật toán phân tích chùm truyền thống dễ gặp khó khăn trong việc duy trì ranh giới rõ ràng giữa các nhóm.

Trong lĩnh vực phân tích chùm, để giải quyết vấn đề mất cân bằng tự nhiên, đa số

phương pháp tập trung cải thiện thuật toán, trong khi các phương pháp tăng cường mẫu ít được áp dụng do khó xác định chùm tiềm ẩn. Ở dữ liệu rời rạc, thuật toán phân tích chùm mất cân bằng đã được giải quyết rất tốt qua các thuật toán csiFCM (2002) [62], siiFCM (2014) [63], iFCM (2016) [64], EM-IFCM (2024) [65], và EKM (2024) [66]. Các thuật toán này giải quyết chủ yếu hai vấn đề bao gồm mở rộng kích thước chùm và dịch chuyển trọng tâm. Hơn nữa, khi có sự khác biệt lớn về số lượng phần tử hoặc kích thước chùm không đồng đều, các thuật toán phân chùm phân vùng có xu hướng nuốt các chùm nhỏ và chia cho lớp lớn hơn như Yue Pu, Wenbin Yao, & Xiaoyong Li (2024) đề cập [65]. Hiệu ứng này được gọi là "hiệu ứng xi phong" có xu hướng kéo (hút) các phần tử biên của lớp nhỏ về lớp lớn, và trọng tâm của lớp nhỏ cũng dịch chuyển về phía lớp lớn. Hai hiệu ứng trên cũng là điểm yếu lớn của phân tích chùm truyền thống.

Giả sử hai chùm có số lượng phần tử $\#c_1$ lớn và $\#c_2$ nhỏ sao cho $\#c_1 = IR \cdot \#c_2$ với $IR \in \mathbb{N}_{>0}$. Khi IR tăng, hàm tỷ số giữa $\#c_1$ và tổng số phần tử trong dữ liệu được biểu diễn bởi $k(x) = 1 - 1/(x + 1)$. Trong Hình 2.1, hàm $k(x)$ là một đường cong tăng đơn điệu, trong khi đạo hàm của nó giảm dần khi IR tăng. Nghĩa là việc chỉ số hóa kích thước chùm thông qua trọng số lớp dần trở nên bão hòa. Do đó, cần thiết phải xây dựng thêm các cơ chế trung hòa nhằm giảm ảnh hưởng của các phần tử thuộc lớp lớn trong hàm mục tiêu, từ đó đảm bảo sự công bằng giữa các chùm trong quá trình phân tích.



Hình 2.1. Quan hệ giữa tỷ lệ mất cân bằng và quy mô chùm có số lượng chiếm ưu thế

Tuy nhiên, các thuật toán KCF và FCF đều giả định rằng các chùm có kích thước tương đương nhau [67], điều này dẫn đến các quyết định phân chùm sai lệch khi dữ liệu thực tế có sự mất cân bằng đáng kể. Theo Xiong (2006) [68], thuật toán k -means có xu hướng ưu tiên chia dữ liệu thành các lớp có kích thước tương đối đồng đều, ngay cả khi bản chất phân bố thực tế không như vậy. Hiện tượng này được gọi là “hiệu ứng đồng nhất”, xuất phát trực tiếp từ đặc tính của hàm mục tiêu. Tương tự, trong trường hợp của KCF, hàm mục tiêu của thuật toán FCF cũng được xây dựng dựa trên cùng nguyên tắc tối thiểu hóa sai số bình phương có trọng số, nên cũng chịu ảnh hưởng của “hiệu ứng

đồng nhất”. Cụ thể, khi hai hàm mật độ trọng tâm θ_1 và θ_2 được tính theo (1.3), với mức độ phân vùng đơn giản hóa thành $\mu_{ij} = u$ nếu $f_j \in c_i$ và $(1 - u)$ cho các trường hợp còn lại, ta có

$$\theta_1(x) = \frac{u^m \sum_{f_j \in c_1} f_j(x) + (1-u)^m \sum_{f_j(x) \in c_2} f_j(x)}{\#c_1 u^m + \#c_2 (1-u)^m},$$


$$\theta_2(x) = \frac{(1-u)^m \sum_{f_j(x) \in c_1} f_j(x) + u^m \sum_{f_j \in c_2} f_j}{\#c_1 (1-u)^m + \#c_2 u^m}.$$

Khi chùm đa số c_1 tăng số lượng, giới hạn của khoảng cách $\mathcal{L}_2$ giữa hai trọng tâm này là $\lim_{\#c_1 \rightarrow \infty} \mathcal{L}_2^2(\theta_1, \theta_2) = 0$. Cụ thể, giả sử $\hat{\theta}_i(x) = (1/\#c_i) \sum_{f_j \in c_i} f_j(x)$ là các trọng tâm thực tế tính theo (1.2), ta có

$$\begin{aligned} \lim_{\#c_1 \rightarrow \infty} \mathcal{L}_2^2(\theta_1, \theta_2) &= \lim_{\#c_1 \rightarrow \infty} \int \left(\frac{u^m \#c_1 \hat{\theta}_1(x) + (1-u)^m \#c_2 \hat{\theta}_2(x)}{\#c_1 u^m + \#c_2 (1-u)^m} - \frac{(1-u)^m \#c_1 \hat{\theta}_1(x) + u^m \#c_2 \hat{\theta}_2(x)}{\#c_1 (1-u)^m + \#c_2 u^m} \right)^2 dx \\ &\stackrel{p = \frac{\#c_1}{\#c_2}}{=} \lim_{p \rightarrow \infty} \left(\frac{p(u^{2m} - (1-u)^{2m})}{(pu^m + (1-u)^m)(p(1-u)^m + u^m)} \right)^2 \int (\hat{\theta}_1(x) - \hat{\theta}_2(x))^2 dx \end{aligned}$$

Ta biết trong tỷ lệ trên, p có bậc của tử nhỏ hơn bậc của mẫu, nên dẫn đến giới hạn khoảng cách giữa hai trọng tâm khi số lượng phần tử chùm lớn tăng lên là $\lim_{\#c_1 \rightarrow \infty} \mathcal{L}_2^2(\theta_1, \theta_2) = 0$. Điều này chứng minh rằng FCF (và KCF) đều có xu hướng làm cho các trọng tâm chùm cuối cùng dịch chuyển gần nhau hơn so với các trọng tâm thực tế. Kết quả là, các chỉ số đánh giá phân chùm truyền thống sẽ ưu tiên gộp chùm thiếu số và chùm lân cận thành một chùm duy nhất, còn làm giảm khả năng nhận dạng các chùm nhỏ trong điều kiện mất cân bằng nghiêm trọng

Hình 2.2 minh họa ảnh hưởng đồng thời của IR và mức nhiễu dữ liệu lên kết quả xác định trọng tâm trong thuật toán FCF. Cụ thể, các dòng từ 1 ÷ 4 thể hiện sự gia tăng dần của IR , cho thấy FCF có xu hướng tạo ra các phân vùng đồng đều hơn về số lượng hàm mật độ trong mỗi chùm. Đây chính là biểu hiện rõ của “hiệu ứng đồng nhất”. Ngược lại, các cột trong hình mô tả mức độ nhiễu khác nhau của dữ liệu, FCF cho thấy các hàm mật độ biên của chùm nhỏ hơn bị kéo lệch về phía chùm lớn khi phân bố dữ liệu trở nên rối loạn. Trong phạm vi của luận văn này, “hiệu ứng đồng nhất” được xem là vấn đề trung tâm và được đề cập, phân tích cũng như giải quyết lần đầu tiên đối với đối tượng là các hàm mật độ xác suất, trong khi “hiệu ứng xi-phông” được bỏ qua do mức độ ưu tiên thấp hơn trong bối cảnh nghiên cứu hiện tại.



Hình 2.2. Ảnh hưởng của dữ liệu hàm mật độ Gauss mất cân bằng lên FCF ($m = 2; c = 3; D = \mathcal{L}_2$)

2.2.2 Thuật toán

Cho tập các hàm mật độ xác suất $\mathcal{F}$, trong đó mỗi f_j là một hàm mật độ xác suất ($j = 1; \dots; n$). Cho trước c là số chòm ($i = 1; \dots; c$). Gọi $U = [\mu_{ij}] \in \mathbb{R}^{n \times c}$ là ma trận phân vùng, và $\Theta = \{\theta_1, \dots, \theta_c\}$ là các trọng tâm chòm. Giả sử tham số mờ $m > 1$. Hàm mục tiêu của IFCF là tổng của hai phần bao gồm trọng số $1/\omega_i$ giảm “hiệu ứng đồng nhất”.

$$\text{Minimise : } J(U; \Theta | \mathcal{F}; c; m; \delta') = \sum_{j=1}^n \sum_{i=1}^c \frac{1}{\omega_i} \mu_{ij}^m D^2(f_j; \theta_i), \quad (\text{IFCF})$$

$$\text{s.t : } \sum_{i=1}^c \mu_{ij} = 1, \quad \forall j \in 1, \dots, n, \quad (\text{C1})$$

trong đó $\omega_i^{(t)} = \frac{1}{n} \sum_{j=1}^n \mu_{ij}^{(t-1)}$ là tỷ lệ kích thước mờ của chòm thứ i , với $1; \dots; c$, thỏa mãn $\sum_{i=1}^c \omega_i = 1$ với $\mu_{ij}^{(t-1)}$ là ma trận phân vùng tại vòng lặp thứ $(t-1)$. Khi $\omega_i = 1$ thì thuật toán trở thành FCF.

Nhận xét. Khi mức độ mất cân bằng tăng, phần đóng góp của chòm lớn vào hàm mục tiêu sẽ dần lấn át ảnh hưởng của các chòm nhỏ hơn. Để khắc phục, thành phần của hàm mục tiêu IFCF được hiệu chỉnh bằng cách chia cho hệ số $\frac{1}{\omega_i}$, với $\omega_i \in (0; 1]$, nhằm giảm tỷ lệ đóng góp tương ứng theo kích thước của từng chòm. Khi đó, các chòm lớn phải chịu tổn thất cao hơn trong quá trình tối ưu hóa, nhằm hạn chế chi phối tổng thể mà không làm sai lệch trọng tâm và tính ổn định. Đặc biệt, khi tất cả các $\omega_i = 1$, công thức IFCF sẽ trở về dạng gốc của FCF.

2.2.3 Sự hội tụ của thuật toán

Trong phần này, một dãy $(\mu^{(t)}; \Theta^{(t)})$ khởi tạo được thành lập. Mục tiêu là chứng minh dãy này có hội tụ hay không [40, 65]. Cho $F : \mathbb{R}^{cd} \rightarrow U_f; F(\Theta) = \mu$; và $G : U_f \rightarrow \mathbb{R}^{cd}; G(\mu) = \Theta$, trong đó, $\Theta = (\theta_1; \theta_2; \dots; \theta_c)$ và các hàm mật độ trọng tâm θ_i tính bởi công thức (1.3). Ta định nghĩa toán tử $T_{IFCF} : \mathbb{R}^{cd} \times U_f \rightarrow \mathbb{R}^{cd} \times U_f; T_{IFCF} = T_2 \circ T_1$, trong đó ánh xạ $T_1 : \mathbb{R}^{cd} \times U_f \rightarrow \mathbb{R}^{cd}; T_1(\mu; \Theta) = G(\mu)$, và $T_2 : \mathbb{R}^{cd} \rightarrow \mathbb{R}^{cd} \times U_f; T_2(\Theta) = (F(\Theta), \Theta)$. Khi này, ta có $T_{IFCF} = (T_2 \circ T_1)(F \circ G(\mu); G(\mu))$. Tức là

$$T_{IFCF} : \mathbb{R}^{cd} \times U_f \rightarrow \mathbb{R}^{cd} \times U_f; T_{IFCF} = T_2 \circ T_1, \quad (2.1)$$

Bổ đề 2.1 (Cập nhật ma trận phân vùng U). Với Θ cố định, bài toán tối ưu hoá J_{IFCF} theo $U = [\mu_{ij}]$ có nghiệm cực tiểu duy nhất $U^* = F(\Theta)$ dưới các ràng buộc phân

hoạch mờ (C1). Cụ thể,

$$\mu_{ij} = \frac{\left[\frac{\omega_i}{D^2(\theta_i, f_j)} \right]^{\frac{1}{m-1}}}{\sum_{s=1}^c \left[\frac{\omega_s}{D^2(\theta_s, f_j)} \right]^{\frac{1}{m-1}}}; 1 \leq i \leq c, 1 \leq j \leq n, \quad (2.2)$$

trong đó $\omega_i = \frac{1}{n} \sum_{j=1}^n \mu_{ij}^{(t-1)}$ là trọng số kích thước chùm với $\omega_i > 0$, $i = 1, \dots, c$ và $\sum_i \omega_i = 1$. Ngoài ra, nếu tồn tại i_0 sao cho $D^2(\theta_{i_0}, f_j) = 0$ thì nghiệm tối ưu cho cột j là $\mu_{i_0j} = 1$ và $\mu_{sj} = 0$ với mọi $s \neq i_0$; nếu có nhiều chỉ số đạt 0 thì mọi phân phối trên tập đó đều tối ưu.

Chứng minh. Do ràng buộc phân hoạch mờ là độc lập theo từng mẫu j , và mục tiêu (IFCF) là tổng theo j , bài toán tối ưu hoá theo U tách thành n bài toán độc lập. Cố định một $j \in \{1, \dots, n\}$, đặt hằng số $\delta_{ij} := D^2(\theta_i, f_j)/\omega_i$. Khi này, mục tiêu của bài toán con theo cột j là

$$\min_{\mu_j \in \mathbb{R}_{>0}^c} \phi_j(\mu_j) : \sum_{i=1}^c \delta_{ij} \mu_{ij}^m \quad \text{s.t.} \quad \sum_{i=1}^c \mu_{ij} = 1, \mu_{ij} \geq 0. \quad (2.3)$$

Với $m > 1$, ta nhận được hàm $t \mapsto t^m$ lồi nghiêm ngặt trên $\mathbb{R}_{>0}$. Khi đó, hàm mục tiêu ϕ_j là tổng các hàm lồi nghiêm ngặt theo từng biến. Miền khả thi là một đơn hình đóng và bị chặn, do đó nghiệm tối ưu tồn tại duy nhất. Hơn nữa, ma trận Hessian là xác định dương, với các phần tử trong ma trận

$$\frac{\partial^2 \phi_j}{\partial \mu_{ij}^2} = m(m-1)(\delta_{ij})\mu_{ij}^{m-2} > 0, \frac{\partial^2 \phi_j}{\partial \mu_{ij} \partial \mu_{sj}} = 0 \quad (s \neq i),$$

Lập Lagrangian với nhân tử $\lambda_j \in \mathbb{R}$ cho ràng buộc tổng bằng 1 và $\alpha_{ij} \geq 0$ cho các ràng buộc không âm, ta có

$$\mathcal{L}(\mu_j, \lambda_j, \alpha_j) = J_{IFCF} - \lambda_j \left(\sum_{i=1}^c \mu_{ij} - 1 \right) - \sum_{i=1}^c \alpha_{ij} \mu_{ij}. \quad (2.4)$$

Điều kiện dừng bậc nhất là đạo hàm riêng của (2.4) theo μ_{ij} bằng 0.

$$\frac{\partial}{\partial \mu_{ij}} \mathcal{L} = m \delta_{ij} \mu_{ij}^{m-1} - \lambda_j - \alpha_{ij} = 0, \quad (2.5)$$

cùng với các điều kiện $\sum_{i=1}^c \mu_{ij} = 1$, $\mu_{ij} \geq 0$, $\alpha_{ij} \geq 0$, và $\alpha_{ij} \mu_{ij} = 0$, $\forall i$. Giả sử $\delta_{ij} > 0$ với mọi i , nếu $\mu_{ij} > 0$ thì $\alpha_{ij} = 0$. Khi đó (2.5) cho kết quả

$$\mu_{ij} = \left(\frac{\lambda_j}{m} \right)^{\frac{1}{m-1}} (\delta_{ij})^{-\frac{1}{m-1}}. \quad (2.6)$$

Áp dụng ràng buộc chuẩn hoá $\sum_{i=1}^c \mu_{ij} = 1$ vào (2.6), ta có

$$1 = \sum_{i=1}^c \left(\frac{\lambda_j}{m} \right)^{\frac{1}{m-1}} (\delta_{ij})^{-\frac{1}{m-1}} = \left(\frac{\lambda_j}{m} \right)^{\frac{1}{m-1}} \sum_{i=1}^c (\delta_{ij})^{-\frac{1}{m-1}},$$

suy ra

$$\left(\frac{\lambda_j}{m} \right)^{\frac{1}{m-1}} = \frac{1}{\sum_{s=1}^c (\delta_{sj})^{-\frac{1}{m-1}}}.$$

Thế ngược lại vào (2.6), ta thu được (2.2).

Ngược lại, tồn tại i_0 sao cho $D^2(\theta_{i_0}, f_j) = 0$ thì $\delta_{i_0j} = 0$. Tuy nhiên, với mọi $s \neq i_0$, $\delta_{sj} > 0$, nên để tối thiểu hoá tổng $\sum_s c_{sj} \mu_{sj}^m$ dưới ràng buộc tổng bằng 1, nghiệm tối ưu là $\mu_{i_0j} = 1$ và $\mu_{sj} = 0$ với $s \neq i_0$. Từ đây, ta được điều phải chứng minh. ■

Bổ đề 2.2 (Cập nhật trọng tâm Θ với $\mathcal{L}_2^2$). Với U cố định, bài toán tối thiểu hoá J_{IFCF} theo $\Theta = \{\theta_i\}_{i=1}^c$ là phân tích được theo từng θ_i và lồi nghiêm ngặt. Tồn tại duy nhất nghiệm cực tiểu $\Theta^* = G(U)$ khi khoảng cách $D^2 = \mathcal{L}_2^2$,

$$\theta_i = \frac{\sum_{j=1}^n (\mu_{ij})^m f_j}{\sum_{j=1}^n (\mu_{ij})^m}; 1 \leq i \leq c, \quad (2.7)$$

Chứng minh. Giữ U cố định, lấy đạo hàm $\psi_i = \sum_{i=1}^c \psi_i(\theta_i)$, với các $\psi_i(\theta_i) = \sum_{j=1}^n \frac{1}{\omega_i} (\mu_{ij})^m D^2(\theta_i, f_j)$. theo θ_i đối với hàm mục tiêu (IFCF) ta có

$$\nabla_{\theta_i} \psi_i(\theta_i) = \frac{1}{\omega_i} \sum_{j=1}^n (\mu_{ij})^m (\mu_{ij})^m \nabla_{\theta_i} \mathcal{L}_2^2(\theta_i, f_j) \quad (2.8)$$

Cho $\nabla_{\theta_i} \psi_i(\theta_i) = 0$, ta được công thức cập nhật (2.7) đối với riêng trường hợp $\mathcal{L}_2^2(\theta_i, f_j)$. Hơn nữa, với khoảng cách $\mathcal{L}_2$, ma trận Hess theo θ_i là $\nabla_{\theta_i}^2 \psi_i(\theta_i) = \frac{2}{\omega_i} \left(\sum_{j=1}^n (\mu_{ij})^m \right) \mathbf{I}_d$, xác định dương vì $\sum_j (\mu_{ij})^m > 0$ và $\omega_i > 0$. Do đó ψ_i lồi nghiêm ngặt và nghiệm bậc nhất (2.8) là duy nhất, suy ra nghiệm toàn cục duy nhất $\Theta^* = G(U)$. Tuy nhiên, $\nabla_{\theta_i}^2 \psi_i(\theta_i)$ chỉ lồi nghiêm ngặt trong một số khoảng cách như $\mathcal{L}_2, D_H^2, D_{KL}$ hoặc W_2 , trong khi với các khoảng cách khác bao gồm $\mathcal{L}_2, D_B$ hoặc D_M có thể không duy nhất nghiệm toàn cục. ■

Bổ đề 2.3 (Cập nhật trọng tâm Θ với D_H^2). Với U cố định, bài toán tối thiểu hoá J_{IFCF} theo $\Theta = \{\theta_i\}_{i=1}^c$ có thể tách được theo từng θ_i và là lồi nghiêm ngặt trong biến $\sqrt{\theta_i}$. Tồn tại duy nhất nghiệm cực tiểu $\Theta^* = G(U)$ khi khoảng cách $D^2 = D_H^2$, trong đó

$$\theta_i(x) = \frac{\left(\sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(x)} \right)^2}{\int_{\Omega} \left(\sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(y)} \right)^2 dy}, \quad 1 \leq i \leq c. \quad (2.9)$$

Chứng minh. Giữ U cố định, xét $\psi_i(\theta_i) = \sum_{j=1}^n \frac{1}{\omega_i} (\mu_{ij})^m D_H^2(\theta_i, f_j)$. Ta có khoảng cách bình

phương Hellinger là $D_H^2(\theta_i, f_j) = 1 - \int \sqrt{\theta_i(x) f_j(x)} dx$. Do đó

$$\psi_i(\theta_i) = \frac{1}{\omega_i} \sum_{j=1}^n (\mu_{ij})^m \left(1 - \int_{\Omega} \sqrt{\theta_i(x) f_j(x)} dx \right).$$

Vì $\theta(x) \leq 0$, ψ_i trở thành một hàm lồi theo $\theta_i^{1/2}(x)$. Vì vậy,

$$\frac{\partial \psi_i}{\partial \theta_i^{1/2}(x)} = -\frac{1}{\omega_i} \sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(x)} + \frac{1}{\omega_i} \left(\sum_{j=1}^n (\mu_{ij})^m \right) \theta_i^{1/2}(x).$$

Cho $\frac{\partial \psi_i}{\partial \theta_i^{1/2}(x)} = 0$, ta có công thức (2.9). Ta cũng có ma trận Hess lúc này là xác định dương, nghiệm (2.9) là nghiệm toàn cục duy nhất. ■

Ta cũng chứng minh được công thức đóng tại Bổ đề 2.3 cũng là một hàm mật độ xác suất.


Chứng minh. Từ kết quả công thức (2.9), ta có

$$\int_{\Omega} \theta_i(x) dx = \int_{\Omega} \frac{\left(\sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(x)} \right)^2}{\int_{\Omega} \left(\sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(y)} \right)^2 dy} dx = \frac{\int_{\Omega} \left(\sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(x)} \right)^2 dx}{\int_{\Omega} \left(\sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(y)} \right)^2 dy} = 1. \quad \blacksquare$$

Bảng 2.2 trình bày các công thức cập nhật trọng tâm θ của chùm theo những khoảng cách khác nhau.

Bảng 2.2. Các công thức trọng tâm tương ứng với các loại khoảng cách

Công thức khoảng cách	Trọng tâm θ
$\mathcal{L}^2(f, \theta) = \int (f(x) - \theta(x))^2 dx$	$\theta(x) = \frac{\sum_j u_{ij}^m f_j(x)}{\sum_j u_{ij}^m}$
$D_H^2(f, \theta) = \frac{1}{2} \int (\sqrt{f(x)} - \sqrt{\theta(x)})^2 dx$	$\theta(x) = \left(\frac{\sum_j u_{ij}^m \sqrt{f_j(x)}}{\sum_j u_{ij}^m} \right)^2$
$W_2^2(f, \theta) = \int_0^1 (F^{-1}(p) - G^{-1}(p))^2 dp$	$\theta(x) = \frac{d}{dx} Q_{\theta}^{-1}, Q_{\theta}(p) = \frac{\sum_j u_{ij}^m Q_{f_j}(p)}{\sum_j u_{ij}^m}$



Hình 2.3. Minh họa các công thức trọng tâm theo khoảng cách

Chú thích từng loại khoảng cách (a) $\mathcal{L}_2$, (b) Hellinger và (c) Wasserstein-2.

Tuy nhiên, hai bổ đề 2.1 và 2.2 chỉ là điều kiện cần để $(\mu^*; \Theta^*)$ là một cực tiểu toàn cục của hàm mục tiêu J_{IFCF} . Từ đây, câu hỏi tiếp theo là liệu dãy $\{T_{IFCF}^{(t)}(\mu^{(0)})\}$ có hội tụ về μ^* hay không. Điều kiện đủ cho định lý Zangwill là tính com-pắc của một tập con $U_f \times \mathbb{R}^{cd}$ chứa tất cả các dãy sinh bởi T_{IFCF} .

Ba định lý này là một phần của chứng minh (IFCF) bằng định lý Zangwill, chứng minh trực tiếp cho kết quả của Định lý 2.4.

Định lý 2.1 (Ràng buộc com-pắc). Cho $[\text{conv}(\mathcal{F})]^c$ là tích Descartes bậc c của bao lồi $\mathcal{F}$, và $(\mu^{(0)}; \Theta^{(0)})$ là điểm bắt đầu của phép lặp với J_{IFCF} , với $\mu^{(0)} \in U_f$ và $\Theta^{(0)} = G(\mu^{(0)})$. Khi đó $T_{IFCF}^{(0)}(\mu^{(0)}; \Theta^{(0)}) \in U_f \times [\text{conv}(\mathcal{F})]^c$, và $U_f \times [\text{conv}(\mathcal{F})]^c$ là tập com-pắc trong $U_f \times \mathbb{R}^{cd}$.

Chứng minh. Giả sử $\mu^{(0)} \in U_f$, khi đó $\Theta^{(0)} = G(\mu^{(0)})$ được tính theo (2.7). Khi đó $\theta_i^{(0)} = \frac{\sum_{j=1}^n (\mu_{ij}^{(0)})^m f_j}{\sum_{j=1}^n (\mu_{ij}^{(0)})^m}$. Đặt $\rho_{ij} = \frac{(\mu_{ij}^{(0)})^m}{\sum_{j=1}^n (\mu_{ij}^{(0)})^m}$, $1 \leq j \leq n$. Theo các ràng buộc (C1), ta có $0 < \rho_{ij} < 1$, $\forall i, j$. Vậy $\forall i$, ta viết lại $\theta_i^{(0)} = \sum_{j=1}^n \rho_{ij} f_j$, với $\sum_{j=1}^n \rho_{ij} = 1$.

Tóm lại $\forall i$, $\theta_i^{(0)} \in \text{conv}(\mathcal{F})$, và do đó $\Theta^{(0)} \in [\text{conv}(\mathcal{F})]^c$. Tiếp tục đệ quy $\mu^{(1)} = F(\mu^{(0)}) \in U_f$, và $\Theta^{(1)} = G(\mu^{(1)}) \in [\text{conv}(\mathcal{F})]^c$ theo lập luận tương tự. Do đó, mọi dãy lặp của J_{IFCF} đều thuộc về $U_f \times [\text{conv}(\mathcal{F})]^c$ với mọi $t \geq 1$. Mặc dù có thể khởi tạo $\Theta^{(0)} \in \mathbb{R}^{cd} \setminus [\text{conv}(\mathcal{F})]^c$, nhưng khi đó $\mu^{(0)} = F(\Theta^{(0)}) \in U_f$, và từ $t \geq 1$ thì $\Theta^{(t)} = G(\mu^{(t)}) \in [\text{conv}(\mathcal{F})]^c$. Rõ ràng, $U_f \times [\text{conv}(\mathcal{F})]^c$ là một tập com-pắc trong $\mathcal{F}$ và dãy lặp hội tụ hữu hạn. ■

Định lý 2.2. Xét $S_{IFCF} = \{(\mu^*, \Theta^*) : J_{IFCF}(\mu^*, \Theta^*) < J_{IFCF}(\mu, \Theta); \forall (\mu, \Theta) \in B^0((\mu^*, \Theta^*), r)\}$ là tập nghiệm. Khi đó, J_{IFCF} là hàm giảm của $\{T_{IFCF}; S_{IFCF}\}$.

Chứng minh. Đầu tiên, vì các ánh xạ $\{y \mapsto D_y^2\}$, $\{y \mapsto 1 - y\}$, và $\{y \mapsto y^m\}$ đều liên tục, và J_{IFCF} là tổng các tích của các hàm này. Do đó, J_{IFCF} liên tục trên $U \times \mathbb{R}^{cd}$. Tiếp theo, giả sử $(\mu; \Theta) \notin S_{IFCF}$. Từ (2.1) suy ra

$$\begin{aligned} J_{IFCF}(T_{IFCF}(\mu, \Theta)) &= J_{IFCF}(T_2 \circ T_1(\mu; \Theta)) \\ &= J_{IFCF}(F \circ G(\mu), G(\mu)) \quad \text{theo Định nghĩa 2.1} \\ &< J_{IFCF}(\mu; G(\mu)) \quad \text{theo Bổ đề 2.1} \\ &< J_{IFCF}(\mu; \Theta) \quad \text{theo Bổ đề 2.2} \end{aligned}$$

Do đó, nếu $(\mu, \Theta) \notin S_{IFCF}$ thì $J_{IFCF}(T_{IFCF}(\mu, \Theta)) < J_{IFCF}(\mu, \Theta)$. Nói cách khác, J_{IFCF} là hàm giảm đối với cặp (T_{IFCF}, S_{IFCF}) theo nghĩa của định lý Zangwill.

Định lý 2.3 (Ràng buộc liên tục). T_{IFCF} liên tục trên $U_f \times \mathbb{R}^{cd}$.

Chứng minh. Vì $T_{IFCF} = T_2 \circ T_1$ là hợp của các hàm liên tục nên cũng liên tục. Ta chỉ cần chỉ ra T_1 và T_2 đều liên tục. Với $T_1(\mu, \Theta) = G(\mu)$, T_1 liên tục nếu G liên tục. Để chứng minh G liên tục trong cd biến μ , ta có G là một trường véc-tơ, với ánh xạ $G : \mathbb{R}^{cd} \rightarrow \mathbb{R}^{cd}$. Vì $\{\mu \mapsto \mu^m\}$ là liên tục, $\{\mu^m \mapsto \mu^m f_j\}$ là liên tục. Do đó, G_i là thương của hai hàm liên tục nên liên tục với mọi i . Do đó, G và T_1 liên tục trên toàn bộ tập xác định.

Tương tự, vì $T_2(\Theta) = (F(\Theta); \Theta)$, nên chỉ cần chứng minh F liên tục trên $\{\theta_i\}$. Cũng có F

là một trường véc-tơ $F : \mathbb{R}^{cd} \rightarrow \mathbb{R}^{cd}$. Vì $\{\theta_i \mapsto D^2(\theta_i; f_j)\}$ liên tục với mọi i , và $\{D^2(\theta_i; f_j) \mapsto D(\theta_i; f_j)^{-2/(m-1)}\}$ liên tục. Mà F_{ij} là thương của hai hàm liên tục (với giả thuyết $D^2 > 0$). Do đó, F và T_2 liên tục trên toàn bộ tập xác định. Cuối cùng, toán tử $T_{IFCF} = T_2 \circ T_1$ là liên tục trên $U_f \times \mathbb{R}^{cd}$. ■


Định lý 2.4 (Định lý hội tụ cho J_{IFCF}). Xét tập $\mathcal{F} = \{f_1; f_2; \dots; f_n\} \subset \mathbb{R}^d$, cho hàm mục tiêu $J_{IFCF}(U; \Theta)$ có dạng (IFCF), trong đó U thỏa mãn (C1) và $\Theta = \{\theta_1; \theta_2; \dots; \theta_c\}$. Nếu $T_{IFCF} : \mathbb{R}^{cd} \times U_f \rightarrow \mathbb{R}^{cd} \times U_f$ là một toán tử lặp Picard của J_{IFCF} , và với mọi t sao cho $D^2(\theta_i^{(t)}; f_j) > 0$, thì với mọi $(\mu^{(0)}; \Theta^{(0)}) \in U_f \times [\text{conv}(\mathcal{F})]^c$, hoặc

1. Dãy $\{(J_{IFCF})^{(t)}(\mu^{(0)}, \Theta^{(0)})\}$ dừng tại giá trị cực tiểu địa phương (μ_{ij}^*, Θ^*) của J_{IFCF} ; hoặc
2. Dãy $\{(J_{IFCF})^{(t)}(\mu^{(0)}, \Theta^{(0)})\}$ chứa một dãy con sao cho $\{(J_{IFCF})^{(t_k)}(\mu^{(0)}; \Theta^{(0)})\} \rightarrow (\mu^*, \Theta^*)$ là giá trị cực tiểu địa phương của J_{IFCF} khi $t_k \rightarrow \infty$.

Chứng minh. Do hàm mục tiêu J_{IFCF} liên tục trên $U_f \times \mathbb{R}^{cd}$, Định lý 2.2 chỉ ra rằng J_{IFCF} là một hàm Zangwill giảm cho tập nghiệm $\{T_{IFCF}; S_{IFCF}\}$ trong đó S_{IFCF} là tập các cực tiểu nghiệm ngặt của J_{IFCF} . Định lý 2.3 khẳng định T_{IFCF} liên tục trên $U_f \times [\text{conv}(\mathcal{F})]^c$, và theo Định lý 2.1, toán tử dãy lặp J_{IFCF} luôn nằm trong một tập con compact của miền xác định. Kết quả này suy ra trực tiếp từ định lý Zangwill. ■

Nhận xét. Định lý này đánh giá sự hội tụ theo từng vòng lặp với một số điều kiện ràng buộc về khoảng cách là một mê-tríc. Điều này dẫn đến một số khó khăn khi đánh giá trên các khoảng cách là f -phân kỳ.

Để mô tả các đường cong mức độ phân vùng μ_1 trong trường hợp phân tích chùm nhị phân, luận văn này mô phỏng trực quan thuật toán IFCF trong môi trường khoảng cách chuẩn hóa $D^2 \in [0; 1]$, với chùm 1 tại gốc và chùm 2 tại $D^2 = 1$ đồng thời với các tham số mờ m khác nhau.



Hình 2.4. Ảnh hưởng của tham số mờ m trong EM-IFCM qua IR

Hình 2.4 minh họa hành vi của IFCF trong môi trường ứng với các mức mất cân bằng khác nhau $IR = \{1; 5; 10; 20\}$, với trọng số tương ứng ω_i ở hai chùm. Ta thấy rằng với $IR = 1$, các đường cong phân hoạch μ_1 đối xứng quanh khoảng cách D^2 . Khi IR tăng

lên, chùm lớn chiếm ưu thế và các đường cong lệch rõ rệt về phía chùm lớn. Ngoài ra, sự thay đổi của tham số mờ m từ 1, 1 ÷ 10, 0 cho thấy vai trò của nó trong việc kiểm soát độ mờ. Rõ ràng, các giá trị thấp hơn làm sắc nét ranh giới, trong khi các giá trị cao hơn tạo ra sự chuyển tiếp mềm hơn. Tóm lại, Thuật toán 5 mô tả cách thực hiện thuật toán IFCF.

Hình 2.4 minh họa hành vi của IFCF trong các môi trường có mức độ mất cân bằng khác nhau $IR = 1; 5; 10; 20$, cùng với các trọng số tương ứng ω_i giữa hai chùm. Có thể thấy rằng khi $IR = 1$, các đường cong phân hoạch μ_1 đối xứng quanh khoảng cách D^2 , phản ánh trạng thái cân bằng hoàn toàn giữa hai chùm.

Tuy nhiên, khi IR tăng dần, chùm lớn bắt đầu chiếm ưu thế rõ rệt và các đường cong phân hoạch bị lệch về phía chùm đó, cho thấy ảnh hưởng mạnh của hiện tượng mất cân bằng lên ranh giới phân tách. Bên cạnh đó, sự thay đổi của tham số mờ m trong khoảng 1, 1 ÷ 10, 0 cũng minh họa vai trò quan trọng của nó trong việc điều chỉnh độ mờ của phân vùng: các giá trị m thấp làm cho ranh giới giữa các chùm trở nên sắc nét hơn, trong khi các giá trị cao lại tạo nên vùng chuyển tiếp mềm và mượt hơn. Tóm lại, Thuật toán 5 trình bày chi tiết quy trình thực hiện phương pháp IFCF, qua đó cho thấy cơ chế thích ứng của mô hình trước các mức mất cân bằng khác nhau trong dữ liệu.

2.2.4 Tham số đánh giá chất lượng

Đánh giá phân tích chùm đóng vai trò quan trọng trong việc đánh giá sự chính xác và phản ánh đúng cấu trúc thực tế của dữ liệu. Các chỉ số đánh giá hiệu suất chùm (CVI) được sử dụng nhằm đo lường mối quan hệ giữa các đặc trưng của các chùm đã hình thành, bao gồm tính kết nối, tính gắn kết, tính đối xứng và tính tách biệt [69].

Thông thường, việc đánh giá kết quả phân tích chùm được chia thành hai trường hợp: đánh giá bên ngoài và đánh giá bên trong. Trong đó, tiêu chí đánh giá bên ngoài được áp dụng khi có thông tin về nhãn thực tế, cho phép so sánh trực tiếp giữa kết quả phân chùm và dữ liệu gốc để đo độ chính xác, ví dụ trong các thí nghiệm mô phỏng hoặc dữ liệu có giám sát. Ngược lại, trong các tình huống thực tế khi nhãn không được biết trước, việc đánh giá phải dựa trên tiêu chí nội bộ. Đánh giá nội bộ vì thế phản ánh năng lực tự tổ chức của thuật toán, mà không cần đến thông tin gán nhãn sẵn có.

a. Đánh giá bên trong

Chỉ số Silhouette Chỉ số Silhouette $S = \text{mean}(s(f_j))$ đo mức độ phù hợp của một hàm mật độ f_j với chùm mà nó được gán nhãn, so với chùm gần nhất khác, trong đó $s(f_j) = \frac{b(f_j) - a(f_j)}{\max\{a(f_j), b(f_j)\}}$, với $a(f_j) = \frac{1}{\#c_k - 1} \sum_{f \in c_k, f \neq f_j} D(f_j, f)$ là khoảng cách trung bình giữa f_j và tất cả các hàm mật độ khác trong chùm c_k chứa nó, và $b(f_j) = \min_{l \neq k} \frac{1}{\#c_l} \sum_{f \in c_l} D(f_j, f)$ là khoảng cách trung bình giữa f_j và các hàm mật độ trong chùm gần nhất c_l với $l \neq k$.

Chỉ số Dunn Chỉ số Dunn đánh giá mức độ tách biệt giữa các chùm, được định nghĩa bởi $D = \frac{\min_{k \neq l} \Delta_{\min}(c_k, c_l)}{\max_m \Delta(c_m)}$, trong đó, $\Delta_{\min}(c_k, c_l) = \min_{\substack{f \in c_k \\ g \in c_l}} D(f, g)$ là liên kết nhỏ nhất giữa hai chùm c_k và c_l , và $\Delta(c_m) = \max_{f, g \in c_m} D(f, g)$ là đường kính lớn nhất của chùm c_m .

Chỉ số Davies–Bouldin Chỉ số Davies–Bouldin đo mức độ tương đồng giữa các chùm, được định nghĩa bởi $DI = \frac{1}{K} \sum_{k=1}^K \max_{l \neq k} \left\{ \frac{S_k + S_l}{D(\theta_k, \theta_l)} \right\}$, trong đó, $S_k = \frac{1}{|c_k|} \sum_{f \in c_k} D(f, \theta_k)$ là độ phân tán trung bình của chùm c_k , θ_k là trọng tâm của chùm c_k , $D(\theta_k, \theta_l)$ là khoảng cách giữa hai trọng tâm θ_k và θ_l và k là số chùm.


Chỉ số *Silhouette* và *Dunn* có giá trị càng nhỏ, kết quả phân tích chùm càng tốt. Ngược lại, chỉ số *Davies – Bouldin* càng nhỏ càng tốt, do giá trị thấp biểu thị sự phân tách tốt và giảm mức độ chồng lấn giữa các chùm. Bên cạnh đó, hệ số tương tự chùm được trình bày trong Bảng 1.6 cũng được xem là một chỉ số đánh giá bên ngoài, giúp định lượng mức độ tương tự giữa hai chùm hàm mật độ [35]. Thông qua việc kết hợp các chỉ số này, có thể đánh giá toàn diện hơn về tính ổn định và độ chính xác của kết quả phân tích chùm. Trong phạm vi luận văn này, các thuật toán được thống nhất sử dụng khoảng cách $\mathcal{L}_2$ để đảm bảo tính nhất quán trong so sánh và đánh giá.

Nhận xét. Các chỉ số đánh giá nội chùm phụ thuộc vào khoảng cách và liên kết chùm (Chương 1), dẫn đến một số sai lệch khi ta thiết kế thuật toán phân chùm theo các loại khoảng cách khác nhau. Tức là, cùng một cấu trúc dữ liệu nhưng với các loại khoảng cách khác nhau, giá trị của các chỉ số đánh giá nội chùm có thể thay đổi đáng kể.

b. Đánh giá bên ngoài

Đánh giá bên ngoài được sử dụng khi có nhãn thực tế $\mathcal{P} = \{\mathcal{F}_1; \dots; \mathcal{F}_R\}$ của tập hàm mật độ $\mathcal{F} = \{f_1; \dots; f_n\}$ và kết quả phân chùm $\mathcal{G} = \{\mathcal{G}_1; \dots; \mathcal{G}_K\}$. Xét các cặp $(f_i; f_j)$, ta có các trường hợp

$$\begin{aligned} a &= \#\{(f_i; f_j) \mid f_i, f_j \in \mathcal{F}_r \cap \mathcal{G}_k\}, \\ b &= \#\{(f_i; f_j) \mid f_i, f_j \in \mathcal{F}_r; f_i \in \mathcal{G}_k; f_j \in \mathcal{G}_l; k \neq l\}; \\ c &= \#\{(f_i; f_j) \mid f_i, f_j \in \mathcal{G}_k; f_i \in \mathcal{F}_r; f_j \in \mathcal{F}_s; r \neq s\}; \\ d &= \#\{(f_i; f_j) \mid f_i \in \mathcal{F}_r \cap \mathcal{G}_k; f_j \in \mathcal{F}_s \cap \mathcal{G}_l; r \neq s; k \neq l\}. \end{aligned}$$



Hình 2.5. Một số chỉ số đánh giá và số cụm tối ưu được đề xuất từ phương pháp khuỷu tay với dữ liệu hàm mật độ ở Ví dụ 1.5.

Chú thích: Hình ở trên thể hiện chỉ số Silhouette và Dunn vì chúng càng lớn càng tốt. Ngược lại, chỉ số DBI càng nhỏ càng tốt. Điểm khuỷu tay là điểm mà ở đó độ dốc giữa hai dãy cụm bất kỳ đạt cực đại. Ở đây, ta thấy chỉ số Silhouette và DBI đều đề xuất k -cụm tối ưu là $k = 3$. Trong khi đó, chỉ số Dunn cho kết quả $k = 6$.

Bảng 2.3. Các chỉ số đánh giá độ tương đồng giữa hai phân hoạch

Chỉ số	Công thức	Ý nghĩa
Rand Index (RI)	$RI = \frac{a + d}{a + b + c + d}$	Đo mức độ tương đồng/chính xác của $\mathcal{P}$ theo $\mathcal{G}$
Adjusted Rand Index (ARI)	$ARI = \frac{RI - \mathbb{E}(RI)}{\max(RI) - \mathbb{E}(RI)}$	Loại bỏ trùng khớp ngẫu nhiên; giá trị tối đa là 1.
Fowlkes–Mallows Index (FMI)	$FMI = \sqrt{\frac{a}{a+b} \cdot \frac{a}{a+c}}$	Đo lường cặp đúng/sai dựa trên precision và recall.
Jaccard Index (J)	$J = \frac{a}{a + b + c}$	Tỷ lệ cặp cùng cụm trên tổng số cặp liên quan.
Normalized Mutual Infomation (NMI)	$NMI = \frac{2I(\mathcal{P}, \mathcal{G})}{H(\mathcal{P}) + H(\mathcal{G})}$	Đo mức độ phụ thuộc thông tin giữa hai phân hoạch.

Trong đó, $p_i = \frac{\#\mathcal{F}_i}{n}$, $p_j = \frac{\#\mathcal{G}_j}{n}$, $p_{ij} = \frac{\#(\mathcal{F}_i \cap \mathcal{G}_j)}{n}$, ta có, $I(\mathcal{P}, \mathcal{Q}) = \sum_{i,j} p_{ij} \log \frac{p_{ij}}{p_i p_j}$, với $H(\mathcal{P}) = -\sum_i p_i \log p_i$; $H(\mathcal{Q}) = -\sum_j p_j \log p_j$.

Nhận xét. Các chỉ số đánh giá bên ngoài phụ thuộc vào cách giải mờ trong phân tích cụm mờ. Khi kết quả phân tích cụm nằm ở mức độ không chắc chắn cao, chỉ số có thể đánh giá là nhầm lẫn. Vì vậy, ta nên sử dụng một cách có ý nghĩa song song cả hai loại chỉ số bên trong và bên ngoài.

Trong các ví dụ số liên quan đến phân tích cụm, luận văn sử dụng thống nhất ARI , NMI đối với đánh giá bên ngoài, và $Silhouette$ và $Dunn$ đối với đánh giá bên trong. Ngoài ra, chúng còn được đánh giá qua số lần lặp lại trong phân tích cụm phân vùng và thời gian chạy kể từ khi khởi đầu thuật toán.

2.2.5 Ví dụ minh họa


Để khảo sát hành vi của thuật toán được đề xuất trong các bài toán chuẩn, trước tiên luận văn này tạo dữ liệu tổng hợp qua hai ví dụ Gauss hai chùm và Gauss lệch ba chùm.

a. Dữ liệu mô phỏng

Ví dụ 2.1 (Phân tích hai chùm hàm Gauss mất cân bằng). Giả sử dữ liệu được tạo theo công thức tổng quát về kỳ vọng và độ lệch chuẩn của mỗi chùm, cụ thể như sau.

Chùm 1 : $f(x|\mu; \sigma^2) \sim \mathcal{N}(\mu_1; \sigma_1^2)$; với $\mu_1 \sim \mathcal{N}(-5, 0; 1, 0)$; $\sigma_1 = 2, 0$,

Chùm 2 : $f(x|\mu; \sigma^2) \sim \mathcal{N}(\mu_2; \sigma_2^2)$; với $\mu_2 \sim \mathcal{N}(5, 0; 1, 0)$; $\sigma_2 = 4, 0$.



Hình 2.6. Dữ liệu tại Ví dụ 2.1

Luận văn mô phỏng dữ liệu hàm mật độ Gauss trên tập số thực với hai chùm được giả định trước. Vai trò chính của dữ liệu nhân tạo này là đánh giá độ ổn định của thuật toán trong các kịch bản mất cân bằng nghiêm trọng khi IR thay đổi từ 10 đến 50. IR càng lớn thì sự chênh lệch giữa chùm 1 và 2 càng cao. Hình 2.6 thể hiện rõ tác động của IR lên phân bố dữ liệu. Khi IR tăng (1 : 10, 1 : 30, và 1 : 50), chùm lớn hơn trở nên dày đặc hơn, trong khi chùm nhỏ giữ nguyên kích thước.

Để bảo đảm tính công bằng, số chùm $c = 2$ trong ví dụ này, tham số mờ $m = 2, 0$, sai số hội tụ $\varepsilon = 10^{-12}$, số vòng lặp tối đa $T_{\max} = 200$ và phương pháp khởi tạo được cố định là k -mean++. Luận văn này đánh giá tác động lặp lại ngẫu nhiên thuật toán IFCCF với 30 lần thử nghiệm ngẫu nhiên.

b. Kết quả các loại khoảng cách

Các thuật toán phân chùm được triển khai với nhiều loại khoảng cách khác nhau, bao gồm $\mathcal{L}_2$, D_H , D_{BC} , D_{JS} và W_2 , như được trình bày trong Bảng 1.2. Kết quả chi tiết được trình bày trong Bảng 2.4 thể hiện giá trị trung bình của các chỉ số đánh giá phân chùm tại các mức mất cân bằng khác nhau ($IR = 10 \div 50$).


Rõ ràng, khi IR tăng từ 10 ÷ 50, hầu hết các chỉ số đánh giá như ARI , NMI , $Dunn$

Bảng 2.4. So sánh hiệu suất phân cụm của IFCF qua các loại khoảng cách và các tỷ lệ IR đối với Ví dụ 2.1

Chỉ số đánh giá	IR	$\mathcal{L}_2$	D_{BC}	D_H	D_{JS}	W_2
<i>ARI</i>	10	$0,93\pm 0,00$	$1,00\pm 0,00$	$0,93\pm 0,00$	$0,93\pm 0,00$	$0,93\pm 0,00$
	20	$-0,01\pm 0,00$	$1,00\pm 0,00$	$0,94\pm 0,00$	$0,94\pm 0,00$	$1,00\pm 0,00$
	30	$-0,00\pm 0,00$	$0,88\pm 0,00$	$-0,00\pm 0,00$	$-0,00\pm 0,00$	$0,73\pm 0,00$
	40	$-0,02\pm 0,00$	$0,88\pm 0,00$	$-0,02\pm 0,00$	$-0,01\pm 0,00$	$0,88\pm 0,00$
	50	$-0,01\pm 0,00$	$0,88\pm 0,00$	$-0,01\pm 0,00$	$-0,01\pm 0,00$	$0,45\pm 0,00$
<i>NMI</i>	10	$0,86\pm 0,00$	$1,00\pm 0,00$	$0,86\pm 0,00$	$0,86\pm 0,00$	$0,86\pm 0,00$
	20	$0,07\pm 0,00$	$1,00\pm 0,00$	$0,88\pm 0,00$	$0,88\pm 0,00$	$1,00\pm 0,00$
	30	$0,05\pm 0,00$	$0,79\pm 0,00$	$0,03\pm 0,00$	$0,05\pm 0,00$	$0,62\pm 0,00$
	40	$0,03\pm 0,00$	$0,80\pm 0,00$	$0,03\pm 0,00$	$0,03\pm 0,00$	$0,80\pm 0,00$
	50	$0,03\pm 0,00$	$0,80\pm 0,00$	$0,03\pm 0,00$	$0,03\pm 0,00$	$0,36\pm 0,00$
<i>Dunn</i>	10	$0,24\pm 0,00$	$0,94\pm 0,00$	$0,24\pm 0,00$	$0,24\pm 0,00$	$0,24\pm 0,00$
	20	$0,00\pm 0,00$	$0,90\pm 0,00$	$0,08\pm 0,00$	$0,08\pm 0,00$	$0,90\pm 0,00$
	30	$0,01\pm 0,00$	$0,18\pm 0,00$	$0,01\pm 0,00$	$0,01\pm 0,00$	$0,07\pm 0,00$
	40	$0,00\pm 0,00$	$0,31\pm 0,00$	$0,00\pm 0,00$	$0,00\pm 0,00$	$0,31\pm 0,00$
	50	$0,00\pm 0,00$	$0,09\pm 0,00$	$0,00\pm 0,00$	$0,00\pm 0,00$	$0,09\pm 0,00$
<i>Silhouette</i>	10	$0,66\pm 0,00$	$0,67\pm 0,00$	$0,66\pm 0,00$	$0,66\pm 0,00$	$0,66\pm 0,00$
	20	$0,43\pm 0,00$	$0,62\pm 0,00$	$0,61\pm 0,00$	$0,61\pm 0,00$	$0,62\pm 0,00$
	30	$0,50\pm 0,00$	$0,61\pm 0,00$	$0,50\pm 0,00$	$0,50\pm 0,00$	$0,60\pm 0,00$
	40	$0,47\pm 0,00$	$0,62\pm 0,00$	$0,47\pm 0,00$	$0,47\pm 0,00$	$0,62\pm 0,00$
	50	$0,48\pm 0,00$	$0,61\pm 0,00$	$0,48\pm 0,00$	$0,48\pm 0,00$	$0,59\pm 0,00$
Thời gian chạy	10	$0,01\pm 0,00$	$0,01\pm 0,00$	$0,02\pm 0,00$	$0,10\pm 0,02$	$0,03\pm 0,00$
	20	$0,11\pm 0,02$	$0,03\pm 0,00$	$0,13\pm 0,01$	$0,58\pm 0,05$	$0,06\pm 0,00$
	30	$0,08\pm 0,01$	$0,06\pm 0,01$	$0,28\pm 0,03$	$0,83\pm 0,04$	$0,13\pm 0,00$
	40	$0,16\pm 0,02$	$0,06\pm 0,00$	$0,56\pm 0,02$	$2,00\pm 0,05$	$0,08\pm 0,00$
	50	$0,22\pm 0,03$	$0,18\pm 0,01$	$0,84\pm 0,04$	$2,71\pm 0,11$	$0,16\pm 0,00$
Số vòng lặp	10	$17,00\pm 0,00$	$12,00\pm 0,00$	$14,00\pm 0,00$	$14,00\pm 0,00$	$12,00\pm 0,00$
	20	$107,00\pm 0,00$	$13,00\pm 0,00$	$36,00\pm 0,00$	$46,00\pm 0,00$	$19,00\pm 0,00$
	30	$53,00\pm 4,00$	$23,00\pm 4,00$	$60,00\pm 5,00$	$46,00\pm 2,00$	$30,00\pm 0,00$
	40	$85,00\pm 9,00$	$18,00\pm 0,00$	$97,00\pm 4,00$	$84,00\pm 2,00$	$15,00\pm 0,00$
	50	$101,00\pm 12,00$	$41,00\pm 0,00$	$123,00\pm 5,00$	$93,00\pm 3,00$	$26,00\pm 0,00$

và *Silhouette* đều giảm đáng kể. Ở mức $IR = 10$, các phương pháp đạt giá trị rất cao, với $ARI = 0,93$ và $NMI = 0,86$, phản ánh khả năng tách chùm tốt và ổn định. Tuy nhiên, khi $IR \geq 30$, các chỉ số này nhanh chóng suy giảm gần về 0,00, cho thấy mô hình bắt đầu suy yếu. Đồng thời, thời gian tính toán và số vòng lặp hội tụ tăng lên rõ rệt theo IR , thể hiện rằng bài toán trở nên phức tạp hơn khi mức mất cân bằng dữ liệu tăng cao. Ngoài ra, các khoảng cách $\mathcal{L}_2$, D_{BC} , D_H và D_{JS} cho kết quả gần tương đương nhau ở các mức IR thấp. Tuy nhiên, khi IR tăng, D_H và D_{JS} cho thấy tính ổn định cao hơn, duy trì giá trị ARI và NMI cao hơn so với $\mathcal{L}_2$ và đặc biệt là W_2 . Ngược lại, khoảng cách W_2 thể hiện hiệu năng yếu hơn cả về chỉ số nội bộ lẫn chỉ số bên ngoài, đồng thời đòi hỏi chi phí tính toán cao hơn đáng kể.

Phân tích thống kê sâu hơn bằng phép kiểm định Friedman ($\chi^2 = 14 \div 15$, $p < 0,02$) cho thấy sự khác biệt giữa các loại khoảng cách là có ý nghĩa thống kê. Kết quả này khẳng định rằng lựa chọn độ đo thích hợp có ảnh hưởng trực tiếp đến chất lượng phân tích chùm.



Chú thích: (a) ARI , (b) NMI , (c) *Silhouette*, và (d) thời gian tính toán

Hình 2.7. Đánh giá thống kê các chỉ số cho Ví dụ 2.1

Ở các chỉ số ARI (Hình 2.7(a)) và NMI (Hình 2.7(b)), các khoảng cách D_{JS} , D_{BC} và $\mathcal{L}_2$ có thứ hạng cao trong kiểm định hậu nghiệm Nemenyi (tham khảo thêm Phụ lục B, tr. 81), thể hiện tính chính xác ổn định. Ngược lại, W_2 liên tục đạt thứ hạng thấp nhất. Với chỉ số *Silhouette*, khoảng cách D_{JS} tiếp tục thể hiện hiệu năng vượt trội (Hình 2.7(c)), trong khi D_H và D_{BC} đạt cân bằng giữa độ chính xác và độ bền vững. Về chi phí tính toán, D_{JS} và W_2 là hai phương pháp tốn kém nhất do liên quan đến các phép lô-ga-rít hoặc tích phân trên hàm phân phối tích lũy, trong khi D_{BC} và $\mathcal{L}_2$ có tốc độ xử lý nhanh hơn đáng kể. Nếu cần cân bằng giữa độ chính xác và thời gian, hai khoảng cách D_H và D_{BC} là lựa chọn hợp lý.


Kết quả phân tích thống kê thứ hạng các độ đo khoảng cách cho thấy sự khác biệt rõ rệt về hiệu năng chùm ($p\text{-value} < 0,02$). Cụ thể, ở các chỉ số ARI (Hình 2.7(a)) và

NMI (Hình 2.7(b)), các khoảng cách D_{JS} , D_{BC} và $\mathcal{L}_2$ đều đạt thứ hạng cao trong kiểm định hậu nghiệm Nemenyi (tham khảo thêm Phụ lục B, tr. 81), chứng minh tính ổn định và độ chính xác cao. Trong khi đó, khoảng cách W_2 xếp hạng thấp nhất, cho thấy độ nhạy cao nhưng thiếu ổn định trong môi trường mất cân bằng mạnh. Tiếp theo, với chỉ số *Silhouette*, khoảng cách D_{JS} tiếp tục thể hiện hiệu năng nổi bật (Hình 2.7(c)), trong khi D_H và D_{BC} duy trì mức cân bằng tốt. Xu hướng này cho thấy rằng các độ đo dựa trên phân kỳ thông tin có ưu thế.

Về mặt chi phí tính toán, các độ đo D_{JS} và W_2 là hai phương pháp tốn kém nhất, chủ yếu do yêu cầu các phép tính lô-ga-rít hoặc tích phân trên hàm phân phối tích lũy. Ngược lại, D_{BC} và $\mathcal{L}_2$ có tốc độ xử lý nhanh hơn qua cấu trúc tính toán đơn giản hơn. Tóm lại, trong các tình huống cần cân bằng giữa độ chính xác và thời gian thực thi, hai khoảng cách D_H và D_{BC} được xem là lựa chọn hợp lý nhất.

c. Kết quả các tham số mờ

Hình 2.8 minh họa mối quan hệ giữa tham số m và hai chỉ số đánh giá ARI và *Silhouette*, được phân tích tại các tỷ lệ IR khác nhau. Kết quả cho thấy khi m tăng, hiệu năng của mô hình giảm mạnh theo cả hai chỉ số.




Hình 2.8. Kết quả tham số m qua các chỉ số đánh giá đối với Ví dụ 2.1

Cụ thể, khi m vượt quá 4,0, giá trị ARI giảm nhanh về gần 0,00. Điều này cho thấy tham số mờ quá cao ($m > 3,0$) làm ranh giới giữa các cụm trở nên mờ nhạt. Bên cạnh đó, chỉ số *Silhouette* cũng thể hiện xu hướng suy giảm tương tự. Hiện tượng này cho thấy rằng việc lựa chọn tham số mờ m đóng vai trò quyết định trong việc duy trì độ chính xác và tính ổn định kết quả. Thông thường, các giá trị m nằm trong khoảng $1,5 \div 3,0$ được xem là tối ưu.

d. Kết quả các loại phân tích cụm

Kết quả so sánh giữa thuật toán đề xuất IFCE và phương pháp FCF truyền thống được trình bày trong Hình 2.9. Để nhận thấy rằng trung vị của các chỉ số ARI , NMI và

Silhouette trong FCF giảm nhanh khi tỷ lệ mất cân bằng IR tăng, cho thấy thuật toán truyền thống không còn duy trì được ranh giới chùm ổn định khi dữ liệu bị lệch mạnh về kích thước chùm. Mặc dù FCF có tốc độ tính toán nhanh hơn (Hình 2.9(d)), nhưng độ ổn định giữa các lần lặp không cao ($p < 0,05$, kiểm định Wilcoxon). So sánh với IFCE, kết quả thống kê cho thấy sự khác biệt có ý nghĩa ở tất cả các chỉ số được xem xét (Hình 2.9(a)÷(d)), phản ánh ưu thế rõ rệt của phương pháp đề xuất.



Hình 2.9. Đánh giá thống kê các chỉ số so sánh thuật toán cho Ví dụ 2.1

Chú thích: (a) ARI, (b) NMI, (c) *Silhouette*, và (d) thời gian tính toán. Màu xám đậm là thuật toán IFCE đề xuất, và màu xám nhạt là FCF truyền thống.

Ngược lại, thuật toán IFCE duy trì độ ổn định ngay cả khi $IR > 30$, với các giá trị trung vị của ARI và NMI luôn cao hơn đáng kể so với FCF, đồng thời độ biến thiên nhỏ hơn, chứng tỏ khả năng hội tụ ổn định. Kết quả kiểm định Wilcoxon ($p < 0,01$) khẳng định rằng IFCE không chỉ cho kết quả chính xác mà còn có tốc độ tính toán cạnh tranh. Tổng thể, điều này cho thấy IFCE đạt được sự cân bằng hiệu quả giữa độ chính xác, độ bền vững và chi phí tính toán.

2.3 Giới thiệu bài toán phân loại cho dữ liệu mất cân bằng

2.3.1 Phương pháp phân loại hàm mật độ xác suất

Phương pháp phân loại là một nhánh của nhận dạng có giám sát, phát triển với mục tiêu thành lập quy tắc quy nạp có chức năng phân tách được các lớp quan tâm với sai lầm thực nghiệm tối thiểu. Ta giả sử tồn tại một không gian đầu vào $\mathcal{F}$ và tập nhãn rời rạc $Y = \{1, 2, \dots, C\}$. Cặp dữ liệu (f, y) là biến ngẫu nhiên có phân phối chung $P_{\mathcal{F}, Y}$ trên $\mathcal{F} \times Y$. Mục tiêu của bài toán là tìm một ánh xạ phân loại $h : \mathcal{F} \rightarrow Y$ thuộc không gian giả thuyết $\mathcal{H}$ sao cho tối thiểu hóa giá trị kỳ vọng của hàm mất mát $\ell : Y \times Y \rightarrow \mathbb{R}_{\geq 0}$, tức là $h^* = \arg \min_{h \in \mathcal{H}} \mathbb{E}(f, y) \sim P_{\mathcal{F}, Y} [\ell(h(f), y)]$. Tuy nhiên, do phân phối thực $P_{\mathcal{F}, Y}$ là chưa biết, ta cần tiếp cận qua một tập huấn luyện $\mathcal{D}_n = \{(f_1, y_1), \dots, (f_n, y_n)\} \subset \mathcal{F} \times Y$. Vì vậy, ta giải bài toán $\hat{h}_n = \arg \min_{h \in \mathcal{H}} \frac{1}{n} \sum_{j=1}^n \ell(h(f_j), y_j)$. Trong thực tế, các quy

luật đánh giá có bệnh B hay không dựa vào những dữ liệu cho trước chính là thực hiện bài toán phân loại. Hay phân biệt được hữu hạn các biểu cảm khuôn mặt dựa vào hình ảnh cũng phải thực hiện bài toán phân loại. Đầu ra của mô hình phân loại là ước tính hoặc dự đoán hữu hạn các nhãn cho trước (không đo được) với dữ liệu mới chưa được mô hình hóa [70].

Phương pháp phân loại cho hàm mật độ xác suất là một bài toán mới mẻ nên còn nhiều thách thức lớn cả bề sâu và bề rộng. Nhìn chung, hai phương pháp chính để phân loại là từ hai góc nhìn bao gồm ánh xạ hàm mật độ thành véc-tơ hữu hạn chiều thông qua các đặc trưng thống kê, hay xử lý trực tiếp trong không gian hàm. Cả hai hướng này đều có ưu và nhược điểm riêng, trong đó cách tiếp cận theo không gian hàm cho phép bảo toàn thông tin xác suất tốt hơn nhưng đòi hỏi chi phí tính toán lớn hơn. Bảng 2.5 mô tả quá trình phát triển của lĩnh vực này.

Bảng 2.5. Tổng quan phương pháp phân loại cho hàm mật độ xác suất

Năm	Tác giả	Mô tả phương pháp
2023	Tai Vo-Van, Hieu Nguyen Thi Kim & Dinh Pham-Toan [71]	Phát triển phương pháp phân loại Bayes cải tiến cho bài toán đa lớp
2023	Pavlu <i>et al.</i> [72]	Nhúng hàm mật độ vào không gian Bayes, triển khai logistic hàm mật độ
2024	Thu-Anh Nguyen-Tran, An Thien Ngoc Nguyen & Dinh Pham-Toan[73]	Phát triển phương pháp phân loại Bayes cải tiến tích hợp vào học sâu
2025	Tai Vo-Van & Dinh Pham-Toan [47]	Học đa lớp cho dữ liệu hàm mật độ bằng phương pháp Bayes cải tiến
2025	Tai Vo-Van [55]	Cải thiện độ chính xác trong phân loại dữ liệu hình ảnh đa kênh màu bằng Bayes cải tiến
2025	Tai Vo-Van [74]	Phát triển phương pháp phân loại Bayes cải tiến bằng khoảng cách tương tự chùm

Trong bối cảnh này, các nghiên cứu trong nước đã có nhiều đóng góp nổi bật. Chuỗi công trình gần đây tập trung cải tiến mô hình Bayes truyền thống để thích ứng với dữ liệu dạng hàm mật độ, mở rộng từ bài toán hai lớp sang đa lớp, và từ dữ liệu đơn kênh sang hình ảnh đa kênh màu. Các thuật toán Bayes cải tiến chứng minh được tính ổn định và khả năng tổng quát hóa tốt. Đặc biệt, giai đoạn 2023–2025 đánh dấu bước trưởng thành quan trọng của hướng nghiên cứu này.

Khi tồn tại IR trong dữ liệu, các thuật toán phân loại truyền thống có xu hướng nghiêng về phía lớp chiếm đa số, bởi vì việc giảm sai số tổng thể thường đạt được bằng cách hy sinh khả năng nhận diện lớp hiếm. Hệ quả là, trong các bài toán có tính rủi ro cao như phát hiện gian lận, chẩn đoán y khoa hay cảnh báo thiên tai, việc bỏ sót một vài trường hợp hiếm có thể dẫn đến hậu quả nghiêm trọng hơn nhiều so với việc dự đoán nhầm một trường hợp phổ biến. Do đó, vấn đề mất cân bằng trong phân loại không chỉ là một khía cạnh kỹ thuật, mà còn là yếu tố quyết định độ tin cậy của mô hình trong các ứng dụng thực tế.

Theo thời gian, các hướng tiếp cận chính đã được hình thành bao gồm kỹ thuật cân bằng dữ liệu hay cải tiến thuật toán. Nhóm phương pháp tiền xử lý dữ liệu tập trung tái cân bằng tập huấn luyện thông qua kỹ thuật sinh mẫu giảm đa số, sinh mẫu tăng lớp thiểu số, hoặc sinh mẫu tổng hợp SMOTE. Ngoài ra, việc cải tiến thuật toán phân biệt có thể được xây dựng qua việc tinh chỉnh trực tiếp hàm mất mát hoặc cơ chế học, hoặc học đa mô hình để đạt hiệu năng ổn định hơn. Tuy nhiên, trong các bài toán phức tạp như phân loại hàm mật độ xác suất, hiện tượng mất cân bằng không chỉ xuất hiện ở mức số lượng mẫu mà còn ở cấp độ phân bố xác suất. Điều này khiến việc đo khoảng cách và xác định ranh giới quyết định trở nên khó khăn hơn đáng kể. Vì vậy, nghiên cứu các phương pháp phân loại hiệu quả trong điều kiện mất cân bằng cho hàm mật độ xác suất không chỉ là sự mở rộng tự nhiên của các kỹ thuật cổ điển, mà đã trở thành một hướng nghiên cứu độc lập, đòi hỏi cơ sở lý thuyết và phương pháp luận mới.

2.3.2 Thuật toán

Trong các phương pháp thống kê, Bayesian truyền thống là một phương pháp phân loại điển hình dựa trên biến rời rạc, và các phiên bản cải tiến của nó đã được đề xuất cho biến liên tục [47, 74]. Khi đối tượng cần phân loại là một hàm mật độ, việc tính toán trở nên cực kỳ phức tạp. Do đó, cải tiến của Pham-Gia et al., (2008) được đưa ra để làm việc với hàm mật độ liên tục, nhưng việc xác định tiên nghiệm và ước lượng hàm mật độ vẫn là điểm yếu chính. Luận văn này thiết lập mô hình phân lớp Bayes-IFCF gồm hai giai đoạn bao gồm xác định xác suất tiên nghiệm, sau đó thiết lập nguyên tắc phân loại dựa vào Bayes. Việc kết hợp cả hai thuật toán phân tích chùm mờ IFCF và Bayes có thể giải quyết được bài toán phân loại mất cân bằng.

Cho dữ liệu huấn luyện gồm N hàm mật độ xác suất f_j và n hàm mật độ mới cần phân loại. Giả sử c lớp c_i , trong đó lớp c_i chứa n_j đối tượng hàm mật độ. Xác suất tiên nghiệm q_{ij} (hay u_i) được xác định thông qua mối quan hệ mờ giữa hàm mật độ xác suất cần phân loại $h(x)$ và các lớp trong tập huấn luyện, sử dụng kỹ thuật phân tích chùm mờ IFCF (Thuật toán 5). Tiên nghiệm IFCF là phương pháp tiên nghiệm động giống với Bayes-FCM [55, 71] nhưng dành cho dữ liệu được xác định là có mất cân bằng cao hơn.

Phân loại một hàm mật độ mới $h(x)$ vào lớp c_i bằng quy tắc Bayes nếu nó có xác suất hậu nghiệm đối với lớp đó là cao nhất, tức là

$$c_i = \arg \max_i \left\{ \frac{U_{ij}^{(test)} \exp(-D_{ij}^{(test)} / \tau)}{\sum_s U_{sj}^{(test)} \exp(-D_{sj}^{(test)} / \tau)} \right\},$$

trong đó, khoảng cách D được chuẩn hóa với $\tau = \frac{1}{n_{test}} \sum_i D_{ij}$. Nguyên tắc này chỉ định rằng một hàm mật độ được gán vào một lớp cụ thể nếu nó đồng thời sở hữu giá trị cao

nhất đối với xác suất tiên nghiệm và độ đo tương đồng đối với lớp đó (Thuật toán 1).

Algorithm 1: Giải thuật phân loại Bayes-IFCF

- 1: **procedure** BAYES-IFCF($\mathcal{D}_{\text{train}}, \mathcal{D}_{\text{test}}, c, \varepsilon, m, \mathcal{L}_2$)
- 2: $t \leftarrow 0$
- 3: Khởi tạo ngẫu nhiên ma trận phân vùng $\mu^{(0)}$ và tập hàm mật độ trung tâm $\Theta^{(0)} = \{\theta_i^{(0)}\}_{i=1}^c$
- 4: **while** $\|\mu^{(t+1)} - \mu^{(t)}\| > \varepsilon$ ▷ Giai đoạn 1
- 5: $t \leftarrow t + 1$
- 6: Cập nhật trọng tâm

$$\theta_i^{(t)}(x) = \frac{\sum_{j=1}^{n_{\text{train}}} (\mu_{ij}^{(t-1)})^m f_j^{\text{train}}(x)}{\sum_{j=1}^{n_{\text{train}}} (\mu_{ij}^{(t-1)})^m}, \quad 1 \leq i \leq c$$

- 7: Tính khoảng cách $D_{ij} = \mathcal{L}_2(\theta_i^{(t)}(x), f_j^{\text{train}}(x))$
- 8: Cập nhật mức độ phân vùng

$$\mu_{ij}^{(t)} = \frac{1}{\sum_{s=1}^c \left(\frac{\omega_i^{(t-1)}}{D_{ij}^2 / D_{sj}^2} \right)^{\frac{1}{m-1}}}$$

- 9: Cập nhật trọng số kích thước lớp

$$\omega_i^{(t)} = \frac{1}{n_{\text{train}}} \sum_{j=1}^{n_{\text{train}}} \mu_{ij}^{(t)}$$

- 10: **end while**
- 11: Lưu $\Theta^* \leftarrow \{\theta_i^{(t)}\}, \mu^* = \{\mu_{ij}^{(t)}\}$
- 12: **for** $j = 1$ **to** n **do** ▷ Giai đoạn 2
- 13: Tính khoảng cách $D_{ij}^{(\text{test})} = \mathcal{L}_2(\theta_i^*(x), f_j^{(\text{test})}(x))$
- 14: Gán nhãn phân loại Bayes cho $f_j^{(\text{test})}$

$$c_j^* = \arg \max_i \left\{ \frac{\mu_{ij} \exp(-D_{ij}^{(\text{test})} / \tau)}{\sum_s \mu_{sj} \exp(-D_{sj}^{(\text{test})} / \tau)} \right\}$$

- 15: **end for**
 - 16: **return** c_j^* với $j = 1; \dots; n_{\text{test}}$ ▷ Nhãn của các hàm mật độ kiểm tra
 - 17: **end procedure**
-

2.3.3 Tham số đánh giá chất lượng

Đối với thuật toán phân loại, ta đánh giá kết quả dự đoán thông qua độ chính xác của mô hình trên tập dữ liệu chưa được huấn luyện. Kết quả phân loại thường được tóm tắt trong ma trận nhầm lẫn, thể hiện số lượng dự đoán đúng và sai của mô hình. Giả sử ta có một bài toán phân loại nhị phân với hai lớp { Dương tính; Âm tính }. Ma trận nhầm lẫn có dạng

	Dự đoán dương tính	Dự đoán âm tính
Thực tế dương tính	Dương tính thật ($\#TP$)	Âm tính giả ($\#FN$)
Thực tế âm tính	Dương tính giả ($\#FP$)	Âm tính thật ($\#TN$)

Ví dụ khi ta phân loại các ca có bệnh B hoặc không có bệnh B, $\#TP$ thể hiện số lượng dự đoán đúng kết luận có bệnh B; $\#FP$ là số dự đoán đúng không bệnh. Ngược lại $\#FN$ là số dự đoán kết luận không bệnh, nhưng thực tế là có; và $\#FP$ là số dự đoán kết luận có bệnh B, nhưng thực tế là không. Từ ma trận nhầm lẫn, ta định nghĩa các chỉ số phổ biến khác. Các chỉ số trong Bảng 2.6 cung cấp cơ sở định lượng cho việc đánh giá hiệu năng mô hình,

Bảng 2.6. Mô tả các chỉ số đánh giá phân loại

Chỉ số	Công thức	Ý nghĩa	Phạm vi
Độ chính xác (ACC)	$\frac{\#TP + \#TN}{\#TP + \#TN + \#FP + \#FN}$	Tỷ lệ dự đoán đúng trên tổng số mẫu	[0, 1]
Độ nhạy (PRE)	$\frac{\#TP}{\#TP + \#FP}$	Tỷ lệ mẫu được dự đoán dương tính thật	[0, 1]
Độ chuyên, TPR (REC)	$\frac{\#TP + \#FN}{2 \cdot \text{Precision} \cdot \text{Recall}}$	Tỷ lệ nhận diện đúng dương tính	[0, 1]
F1-score	$\frac{\text{Precision} + \text{Recall}}{2}$	Trung bình điều hoà giữa Precision và Recall	[0, 1]
FPR	$\frac{\#FP}{\#FP + \#TN}$	Tỷ lệ dự đoán sai âm tính thành dương tính	[0, 1]
AUC-ROC	$\int_0^1 \text{TPR}(\text{FPR}) d\text{FPR}$	Diện tích dưới đường cong ROC	[0, 1]
AUC-PR	$\int_0^1 \text{Precision}(\text{Recall}) d\text{Recall}$	Diện tích dưới đường cong Precision-Recall	[0, 1]

Trong đó, các chỉ số cơ bản $\text{Precision} = \frac{\#TP}{\#TP + \#FP}$ và $\text{Recall} = \frac{\#TP}{\#TP + \#FN}$

Nhận xét. Độ chính xác (Accuracy) tuy trực quan và dễ diễn giải nhưng chỉ đưa ra tỷ lệ tổng quát các dự đoán đúng, bỏ qua cấu trúc mất cân bằng giữa các lớp và không phản ánh mức độ rủi ro gắn với từng lỗi. Trong các bài toán mà sai lầm ở một lớp có hậu quả lớn, F1-score và AUC-ROC được ưu tiên vì chúng thể hiện sự cân bằng giữa Precision và Recall, cũng như khả năng phân biệt mô hình qua toàn bộ miền ngưỡng. Đặc biệt với dữ liệu mất cân bằng, hai chỉ số AUC-PR và F1-score thường cho hiệu quả tốt hơn Accuracy hoặc AUC-ROC [75].


2.3.4 Ví dụ minh họa

a. Dữ liệu mô phỏng

Ví dụ 2.2 (Hàm Gauss-lệch, ba lớp). Giả sử phân phối lệch-Gauss từ <http://azzalini.stat.unipd.it/SN/>. Hàm mật độ của phân phối lệch-Gauss được định nghĩa như sau.

$$f(x|\xi;\sigma;\lambda) = \frac{2}{\lambda} \phi\left(\frac{x-\xi}{\sigma}\right) \Phi\left(\lambda \frac{x-\xi}{\sigma}\right),$$

trong khung nghiên cứu này, tham số vị trí ξ_i được lấy mẫu từ các phân phối chuẩn $\mathcal{N}(0;0.2)$, $\mathcal{N}(2;0.2)$ và $\mathcal{N}(-2;0.2)$ tương ứng cho chòm, 1, 2 và 3. Các tham số độ lệch-Gauss được đặt là $\sigma_i = [0; 10; -10]$, trong khi các tham số lệch được xác định là $\lambda_i = [1; 2; 2]$, nhằm tạo ra sự bất đối xứng giữa các lớp. Các hàm mật độ của ba lớp này được minh họa trong Hình 2.10(a), với tỷ lệ $IR = 1 : 20 : 20$ tương ứng cho ba lớp, với lớp nhỏ nhất (lớp 1) có 10 hàm mật độ.



Hình 2.10. Minh họa dữ liệu Ví dụ 2.2

Chú thích: (a) Toàn bộ dữ liệu hàm mật độ, và (b) Các hàm mật độ kiểm tra được lấy ngẫu nhiên trong dữ liệu.

b. Các bước thực hiện

Luận văn thực hiện các bước trong Thuật toán 1 một cách tuần tự. Thuật toán gồm hai phần bao gồm tìm xác suất tiên nghiệm và phân lớp Bayes. Thuật toán tìm xác suất tiên nghiệm là IFCF (Thuật toán 5) với khoảng cách tiêu chuẩn $\mathcal{L}_2^2$ và các tham số liên quan bao gồm $m = 2,0$, $c = 3$, và khởi tạo bằng k -means++. Sau đó, phân lớp Bayes xác định các lớp mà tập kiểm tra thuộc về.


Bước 1. Tiền xử lý. Trong bước này, luận văn chia dữ liệu thành hai tập hợp các hàm mật độ huấn luyện và kiểm tra. Tập huấn luyện có chức năng đào tạo các hàm mật độ để xác định tiên nghiệm cho tập kiểm tra. Tập kiểm tra được chia ngẫu nhiên như sau. Chọn cố định số lượng phần tử trong tập kiểm tra là $n_1 = 2; n_2 = 10; n_3 = 8$. Mỗi hàm mật độ $f_j^{(test)}$, $j = 1; \dots; 20$ được gán vào tập kiểm tra là tổ hợp $C_n^{n_i}$, $i = 1 \div 3$ để mỗi lớp đều có hàm mật độ kiểm tra. Tập huấn luyện là phần còn lại sau khi đã chọn ngẫu nhiên kiểm tra. Hình 2.10 thể hiện các hàm mật độ kiểm tra chọn ngẫu nhiên từ dữ liệu. Ta có số lượng tập huấn luyện và kiểm tra như sau

Bảng 2.7. Phân bố số lượng và tỷ lệ hàm mật độ trong tập huấn luyện và kiểm tra đối với Ví dụ 2.2.

Tập dữ liệu	Lớp 1	Lớp 2	Lớp 3	Tổng cộng
Huấn luyện	8 (2,1%)	190 (48,7%)	192 (49,2%)	390
Kiểm tra	2 (10,0%)	10 (50,0%)	8 (40,0%)	20
Tổng cộng	10 (2,5%)	200 (50,0%)	200 (47,5%)	410

Bước 2. Xác định tiên nghiệm. Bước này đánh giá tiên nghiệm dựa vào phân tích chùm hàm mật độ IFCF trên tập huấn luyện.

Bước 2.1. Khởi tạo tập hợp ba hàm mật độ trọng tâm $\Theta^{(t=0)}$ bằng k -means++. Ta có Hình 2.11(a) thể hiện ba hàm mật độ trọng tâm khởi tạo cho ba lớp lần lượt là $\Theta = \{f_{98}; f_6; f_{226}\}$. Khi không có thông tin gì về kích thước lớp, ta khởi tạo $\omega_i = 1/c = 1/3$ cho cả ba lớp. Tại bước lặp thứ nhất $t = 1$, ta cập nhật các giá trị của U và Θ .



Hình 2.11. Quá trình biến đổi của các trọng tâm đối với Ví dụ 2.2

Chú thích: (a) Khởi tạo từ k -means++, (b) Vòng lặp thứ nhất $t = 1$, (c) Vòng lặp thứ hai $t = 2$, (d) Vòng lặp cuối cùng.

Bước 2.2. Ta tiến hành tính khoảng cách $\mathcal{L}_2(\theta_i; f_j)$ giữa các trọng tâm khởi tạo với tất cả các hàm mật độ xác suất còn lại. Ở đây, luận văn trình bày cụ thể cột đầu tiên như sau.

$$D_{11} = \mathcal{L}_2^2(f_{98}; f_1) = 0,488, D_{21} = \mathcal{L}_2^2(f_6; f_1) = 0,037, D_{31} = \mathcal{L}_2^2(f_{226}; f_1) = 0,523$$

Tổng hợp lại, ta có ma trận khoảng cách $D = D^2(\theta_i; f_j) = \mathcal{L}_2^2$.

$$D^{(t=1)} = \begin{bmatrix} 0.488 & 0.489 & 0.502 & \cdots & 0.528 & 0.529 \\ 0.037 & 0.036 & 0.013 & \cdots & 0.509 & 0.493 \\ 0.523 & 0.523 & 0.521 & \cdots & 0.003 & 0.042 \end{bmatrix}_{3 \times 390}$$

Bước 2.3. Cập nhật ma trận $U^{(t=1)}$ theo Công thức (2.2) theo ma trận khoảng cách D vừa tính và cả ba $\omega_i = 1/3, i = 1 \div 3$. Ở đây, luận văn trình bày cụ thể cột đầu tiên

như sau

$$\begin{bmatrix} \mu_{11} \\ \mu_{12} \\ \mu_{13} \end{bmatrix} = \begin{bmatrix} \frac{1}{1 + \left(\frac{f_{c2}}{f_{c1}} \frac{D_{11}}{D_{21}}\right)^{\frac{1}{m-1}} + \left(\frac{f_{c3}}{f_{c1}} \frac{D_{11}}{D_{31}}\right)^{\frac{1}{m-1}}} \\ \frac{1}{\left(\frac{f_{c2}}{f_{c1}} \frac{D_{12}}{D_{22}}\right)^{\frac{1}{m-1}} + 1 + \left(\frac{f_{c3}}{f_{c1}} \frac{D_{12}}{D_{32}}\right)^{\frac{1}{m-1}}} \\ \frac{1}{\left(\frac{f_{c2}}{f_{c1}} \frac{D_{13}}{D_{23}}\right)^{\frac{1}{m-1}} + \left(\frac{f_{c3}}{f_{c1}} \frac{D_{13}}{D_{33}}\right)^{\frac{1}{m-1}} + 1} \end{bmatrix} = \begin{bmatrix} 0,066 \\ 0,872 \\ 0,062 \end{bmatrix}.$$

Tổng hợp các tính toán trên, ta có ma trận phân vùng tại vòng lặp $t = 1$ như sau.

$$U^{(t=1)} = \begin{bmatrix} 0.066 & 0.064 & 0.024 & \dots & 0.005 & 0.068 \\ 0.872 & 0.877 & 0.953 & \dots & 0.005 & 0.073 \\ 0.062 & 0.060 & 0.023 & \dots & 0.990 & 0.859 \end{bmatrix}_{3 \times 390}.$$

Bước 2.4. Cập nhật trọng tâm chùm bằng Công thức 2.7. Hình 2.11(b) cho ta cụ thể trọng tâm sau khi cập nhật ở bước $t = 1$.

Bước 2.5. Cập nhật lại kích thước chùm $\omega_i^{(t=1)}$, $i = 1 \div 3$ bằng Công thức trung bình U . Ta có, $\omega_1 = 0,489$; $\omega_2 = 0,053$; $\omega_3 = 0,456$.

Ta tính tiêu chí dừng giữa $U^{(t=1)}$ và $U^{(t=0)}$ được tính bởi công thức

$$\|U^{(t=1)} - U^{(t=0)}\| = 1,333 < \varepsilon$$

Ta quyết định tiếp tục vòng lặp thứ 2, $t = 2$. Tương tự ta cũng cập nhật được ma trận khoảng cách D , ma trận phân vùng U , kích thước chùm ω_i và trọng tâm Θ_i .

$$D^{(t=2)} = \begin{bmatrix} 0.469 & 0.470 & 0.486 & \dots & 0.517 & 0.518 \\ 0.023 & 0.022 & 0.010 & \dots & 0.409 & 0.394 \\ 0.508 & 0.508 & 0.503 & \dots & 0.006 & 0.007 \end{bmatrix}, U^{(t=2)} = \begin{bmatrix} 0.244 & 0.238 & 0.139 & \dots & 0.012 & 0.015 \\ 0.545 & 0.555 & 0.735 & \dots & 0.002 & 0.002 \\ 0.211 & 0.206 & 0.126 & \dots & 0.986 & 0.983 \end{bmatrix}$$

Sau 21 vòng lặp ta dừng thuật toán do thỏa mãn điều kiện dừng. Kết quả nhận được là trọng tâm $\Theta^{(t=21)}$ và ma trận phân vùng $U^{(t=21)}$ cuối cùng.

Bước 3. Phân lớp Bayes. Một phần tử mới được xếp lớp bất kỳ nếu hậu nghiệm của nó là lớn nhất. Vì vậy, ta tính hậu nghiệm từ kết quả ở **Bước 2.** cho tập kiểm tra. Ở mỗi hàm trọng tâm θ_i ở bước 2, ta tính khoảng cách giữa nó đến từng phần tử của $f_j^{(test)}$,

$j = 1 \div 20$. Ta có,

$$D^{(test)} = \begin{bmatrix} 0.490 & 0.494 & 0.001 & \cdots & 0.494 & 0.001 \\ 0.002 & 0.005 & 0.495 & \cdots & 0.005 & 0.495 \\ 0.494 & 0.491 & 0.516 & \cdots & 0.491 & 0.516 \end{bmatrix}_{3 \times 20},$$

và

$$U^{(test)} = \begin{bmatrix} 0.126 & 0.240 & 0.998 & \cdots & 0.240 & 0.998 \\ 0.748 & 0.518 & 0.000 & \cdots & 0.518 & 0.000 \\ 0.126 & 0.242 & 0.002 & \cdots & 0.242 & 0.002 \end{bmatrix}_{3 \times 20}.$$

Vì vậy, ta có thể tính được xác suất hậu nghiệm của các hàm mật độ kiểm tra với $\tau = \overline{D_{ij}}$ là

$$\mathbb{P}(c = c_i; f = f_j^{(test)}) = \frac{U_{ij} \exp(-D_{ij}/\tau)}{\sum_s U_{sj} \exp(-D_{sj}/\tau)} = \begin{bmatrix} 0.056 & 0.128 & 0.999 & \cdots & 0.128 & 0.999 \\ 0.888 & 0.741 & 0.000 & \cdots & 0.741 & 0.000 \\ 0.055 & 0.131 & 0.001 & \cdots & 0.131 & 0.001 \end{bmatrix}_{3 \times 20}$$

Từ đây ta biết được các hàm mật độ được xếp vào lớp c_i là $\hat{y}_j = \{2; 2; \underbrace{1; 1; \dots; 1}_{10 \text{ lần}}; \underbrace{3; \dots; 3}_{8 \text{ lần}}\}$.


Tuy nhiên, mỗi lớp trên dựa vào sự ngẫu nhiên của khởi tạo nên chưa phải là lớp thật sự. Do đó, ta biến đổi qua ánh xạ hoán vị tối ưu giữa nhãn lớp dự đoán và nhãn thực tế, tức là

$$\pi = \arg \max_{\pi \in S_c} \frac{1}{n_{test}} \sum_{j=1}^{n_{test}} \mathbf{1}_{\{\pi(\hat{y}_j) = y_j\}},$$

trong đó S_c là hoán vị của c . Từ đây ta tính được các chỉ số đánh giá phân lớp bao gồm $ACC = 1,00$, $AUC-ROC = 1,00$.

c. Kết quả số

Luận văn lặp lại thuật toán phân loại Bayes-IFCF cho 30 lần ngẫu nhiên ở bước chọn dữ liệu hàm mật độ kiểm tra. Các chỉ số đánh giá được ghi nhận bao gồm $AUC - ROC$, $F1 - score$, và đánh giá thuật toán đề xuất Bayes-IFCF so với những thuật toán đã có bao gồm Bayes-U (phân phối đều giữa ba lớp), Bayes-L (phương pháp Laplace- $\alpha = 1$), Bayes-J (phương pháp Jeffreys- $\alpha = \frac{1}{2}$), Bayes-FCM (phân tích chùm mờ).



Hình 2.12. Kết quả ANOVA cho các chỉ số phân loại đối với Ví dụ 2.2
Chú thích: (a) Độ chính xác ACC, (b) Độ chính xác cân bằng GM và (c) Chỉ số F_1 -score.

Kết quả so sánh bằng kiểm định Friedman–Nemenyi (Hình 2.12) cho thấy sự khác biệt rõ rệt giữa các phương pháp phân loại. Trong cả ba chỉ số đánh giá, xác suất phân loại dựa vào tiên nghiệm đều và dựa vào phương pháp phân tích cụm IFCF đạt hạng trung bình thấp nhất ($1,5 \div 1,6$), cho thấy hiệu năng ổn định và vượt trội. Ngược lại, phương pháp Laplace và Jeffreys có hạng trung bình cao hơn (4,13), phản ánh kết quả kém hơn đáng kể theo cả độ chính xác, độ chính xác cân bằng và chỉ số F_1 . Phương pháp FCF nằm ở mức trung bình với hạng trung bình là 3,58, chỉ cải thiện nhẹ so với hai biến thể tiên nghiệm không đều.

Tổng kết chương 2

Chương 2 tập trung vào giới thiệu thuật toán nhận dạng thống kê cho dữ liệu hàm mật độ xác suất chống chịu được với tình trạng mất cân bằng. Để khắc phục các hiệu ứng bất lợi, chương này đề xuất thuật toán IFCF. Về phân loại, chương này tổng quan các phương pháp hiện có và giới thiệu việc ứng dụng nguyên tắc phân loại Bayes-IFCF. Chương này cũng hệ thống hóa các chỉ số đánh giá hiệu suất mô hình nhận dạng thống kê.

CHƯƠNG 3

ỨNG DỤNG CHO DỮ LIỆU HÌNH ẢNH

3.1 Trích xuất đặc trưng của hình ảnh thành hàm mật độ xác suất

Hình ảnh số được cấu thành từ các điểm ảnh, điểm ảnh lưu trữ thông tin về cường độ sáng hoặc véc-tơ màu. Kích thước ảnh thường được biểu diễn bởi số hàng và số cột của điểm ảnh, ví dụ $M \times N$ cho ảnh hai chiều, hoặc $M \times N \times 3$ cho ảnh màu RGB. Một điểm ảnh tại vị trí (i, j) có thể được biểu diễn bằng giá trị $I(i, j)$ trong miền cường độ $[0, 255]$ (với ảnh 8-bit), hoặc được chuẩn hóa về miền $[0; 1]$ trong các xử lý số. Xử lý hình ảnh là cầu nối giữa toán học rời rạc, xác suất thống kê và trí tuệ nhân tạo, đóng vai trò nền tảng trong các lĩnh vực như thị giác máy tính, chẩn đoán y học hình ảnh, và hệ thống tự động nhận dạng.

3.1.1 Vấn đề trích xuất đặc trưng của hình ảnh

Trong xử lý ảnh, đặc trưng là những thông tin tóm tắt để mô hình nhận dạng thống kê phân biệt giữa các lớp hoặc đối tượng. Có thể phân chia đặc trưng thành hai loại bao gồm thủ công dùng cho thống kê và học được dùng cho máy học/học sâu [76]. Trong thống kê cổ điển, đặc trưng thường được tính toán trực tiếp từ phân bố cường độ hoặc phân bố điểm ảnh, sau đó đưa vào mô hình. Loris Nanni (2017) [76] cho rằng “*Việc thiết kế các tính năng thủ công thường liên quan đến việc cân bằng giữa độ chính xác và hiệu quả tính toán*”.

Ở đây, hình ảnh là biểu diễn số hóa của thông tin thị giác, được cấu thành từ các điểm ảnh (pixel) theo ma trận hai chiều, trong đó mỗi điểm lưu giá trị cường độ hoặc màu sắc. Trong xử lý ảnh, hình ảnh được xem là một dạng tín hiệu hai chiều có thể phân tích, biến đổi, và trích xuất thông tin. Quá trình trích xuất hình ảnh được ứng dụng rộng rãi trong các lĩnh vực như nhận dạng mẫu, phân loại ảnh, phát hiện vật thể, thị giác máy tính, chẩn đoán hình ảnh y tế, viễn thám, và trong các mô hình học sâu nhằm tự động học biểu diễn từ dữ liệu ảnh thô.

3.1.2 Ước lượng hàm mật độ xác suất đại diện cho hình ảnh

Ước lượng hàm mật độ là bài toán phái sinh khi dữ liệu cần được chuyển thành dữ liệu hàm mật độ. Thông thường một đối tượng véc-tơ được chuyển đổi thành hàm mật

độ Gauss đa chiều như [49] với kỳ vọng là trung bình mẫu và độ lệch chuẩn chứa mức độ không chắc chắn thường là $\pm 5\%$.

Khi chuyển dữ liệu hình ảnh sang dạng hàm mật độ, ý tưởng chính là xem hình ảnh hoặc một phần của hình ảnh như một biểu diễn phân bố xác suất. Cách tiếp cận này cho phép thay thế tập hợp rời rạc các điểm ảnh bằng một hàm liên tục. Các phương pháp ước lượng phổ biến thường dựa trên hình ảnh toàn cục hoặc trên các khối cục bộ. Trong phần này, hai hướng tiếp cận chính được trình bày và phân tích.

a. Ước lượng dựa trên màu sắc

Xét một ảnh $I \in \mathbb{R}^{M \times N \times C}$. Mỗi điểm ảnh được ký hiệu bởi chỉ số $p \in \{1, \dots, MN\}$ và có thể được ánh xạ thành véc tơ đặc trưng $f_I \in \mathbb{R}^d$ trong không gian cường độ xám hoặc trong không gian màu RGB. Để tiến hành ước lượng, trước tiên toàn bộ ảnh được duỗi thẳng thành véc tơ một chiều


$$x = \text{vec}(I) = (I_{11}, I_{12}, \dots, I_{1N}, I_{21}, \dots, I_{MN})^T \in \mathbb{R}^{MN}.$$

Quá trình duỗi thẳng giúp chuyển đổi ảnh ma trận hai chiều thành dữ liệu véc-tơ một chiều. Tập hợp $\{x_p\}_{p=1}^{MN}$ được coi như một mẫu độc lập từ phân bố xác suất cường độ. Trên cơ sở đó, áp dụng phương pháp ước lượng mật độ hạt nhân với hạt nhân Gauss và quy tắc chọn băng thông của Silverman. Công thức cụ thể của hàm mật độ ước lượng được viết là

$$\hat{f}(u) = \frac{1}{MNh} \sum_{p=1}^{MN} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(u-x_p)^2}{2h^2}\right),$$

trong đó $h = 0.9\hat{\sigma}(MN)^{-1/5}$ với $\hat{\sigma}$ là độ lệch chuẩn của tập cường độ toàn cục.


Cách tiếp cận này sử dụng trực tiếp toàn bộ điểm ảnh, do đó phản ánh đặc tính màu sắc toàn cục của hình ảnh. Hình 3.1 thể hiện quá trình biến đổi hình ảnh thành hàm mật độ với hình ảnh gốc có kích thước 32×32 với phân bố không đồng đều có hai chấm ở hai phía. Hàm mật độ hạt nhân cho thấy phân bố cường độ xám của ảnh tập trung trong một khoảng giá trị hẹp phản ánh mức sáng tối của ảnh.



Hình 3.1. Minh họa quá trình chuyển đổi dữ liệu ảnh thành hàm mật độ dựa trên màu sắc.

b. Ước lượng dựa vào khối màu

Một hướng tiếp cận khác là phân chia ảnh thành các khối nhỏ có kích thước $s \times s$ và không chồng lấp từ phải sang trái, và từ trên xuống dưới. Mỗi ma trận vuông P_k được ánh xạ thành véc-tơ $z_k = \text{vec}(P_k) \in \mathbb{R}^{s^2}$. Trong từng khối, tập hợp $\{z_{k,p}\}$ được coi là mẫu cục bộ. Với mỗi khối, tiến hành ước lượng mật độ bằng công thức hạt nhân Gauss, bằng thông vẫn được lựa chọn theo quy tắc Silverman. Các hàm mật độ cục bộ $\hat{f}_k(u)$ là kết quả sau khi ước lượng cho từng khối. Hình 3.2 thể hiện bốn khối màu của hình ảnh mô phỏng (của Hình 3.1) đánh theo thứ tự 1 ÷ 4 theo thứ tự từ trái sang phải, từ trên xuống dưới. Cách tiếp cận này duy trì thông tin màu sắc cho từng khối hình ảnh, phù hợp cho bài toán phân tích chùm vì sự phân biệt của nó trong các vùng màu sắc khác nhau. Khối đầu chứa vùng sáng, khối cuối chứa vùng tối, hai khối còn lại nằm trên các vùng trung gian có mức xám thay đổi dần. Hàm mật độ của khối đầu có phân bố tập trung ở cường độ cao, thể hiện sự hiện diện của vùng sáng. Ngược lại, khối cuối có phân bố nghiêng về cường độ thấp phản ánh sự tồn tại của một vùng tối.




Hình 3.2. Minh họa quá trình chuyển đổi dữ liệu ảnh thành hàm mật độ dựa trên khối màu.

3.2 Ứng dụng của bài toán phân tích chùm

3.2.1 Dữ liệu

Ví dụ 3.1. Luận văn mô phỏng một tập dữ liệu ảnh mất cân bằng và định nghĩa trước hai chùm là sự khác biệt màu sắc của hai ảnh kết cấu. Hai ảnh gốc (kích thước 200×200 pixel với 256 mức xám) có cường độ nền khác nhau, $D83$ và $D102$. Những ảnh này được lấy từ cơ sở dữ liệu Kết cấu Brodatz tại https://multibandtexture.recherche.usherbrooke.ca/original_brodatz.html và được cắt ngẫu nhiên và phân bố đều thành 64×64 ảnh. Sau đó, các ảnh được ghép lại thành một tập dữ liệu mất cân bằng với IR dao động từ 10 đến 70.

Hình 3.3(a), và (b) minh họa một ảnh đã cắt và các hàm mật độ được trích xuất của nó. Khi xem xét Hình 3.3(c), (d), và (e), chúng tôi nhận thấy thiếu sự khác biệt rõ ràng và nguy cơ mất cân bằng đáng kể trong tập dữ liệu. Chúng tôi nhận thức và chia nội dung của tập dữ liệu ảnh thành hai chùm do tính chất tiên nghiệm của nó ($D83$ và $D102$). Thách thức hiện tại là phân tích hình ảnh thành các chùm tương ứng một cách nhanh chóng.




Hình 3.3. Các hình ảnh được cắt từ tập dữ liệu Brodatz.

Chú thích (a) Hình ảnh $D83$ và (b) Hình ảnh $D102$; (c) Hàm mật độ trích xuất 1 : 10, (d) Hàm mật độ trích xuất 1 : 50, và (e) Hàm mật độ trích xuất 1 : 100

Ví dụ 3.2. Hình ảnh Landsat-8 (512×256 pixel) bao phủ Đảo Yam cho thấy nguồn mất cân bằng ở cấp độ biển và đảo từ <https://oceancolor.gsfc.nasa.gov/>. Các bãi san hô nông, bãi cát nhỏ và các mảng thảm thực vật trên đảo bị áp đảo rất nhiều bởi

các pixel ở vùng nước sâu. Độ lệch nghiêm trọng này đòi hỏi một thuật toán phân cụm mất cân bằng.



Hình 3.4. Hình ảnh thực tế và các hàm mật độ xác suất trích xuất từ khối màu
Chú thích: (a) Hình ảnh Landsat đã chuyển về ảnh xám, và (b) Mật độ của các khối màu (4×4)

Để phân đoạn hình ảnh này theo màu, trước tiên hình ảnh được chuyển đổi ảnh thang độ xám và quét cửa sổ trượt các mảng ($p \times p$) không chồng lấn từ trái sang phải, từ trên xuống dưới. Mỗi mảng giờ được làm phẳng thành một véc-tơ ($p \times p$)-pixel, hàm mật độ cường độ của nó được ước tính thông qua hàm mật độ hạt nhân (Chương 1, minh họa ở Hình 3.2), và khối lập phương ($\text{patch} \times h \times \text{pdf}$) kết quả trên 3-D được lưu trữ để phân cụm các mảng. Ở đây, kích thước khối màu được đặt cố định là 4×4 .

3.2.2 Phương pháp thực hiện

Để so sánh công bằng giữa các thuật toán được đề xuất, luận văn giới thiệu các thuật toán cơ sở bao gồm KCF [13], FCF theo CWD [23], FCM theo $\mathcal{L}_1$ [22] chuyên dùng để phân cụm các hàm mật độ. Bảng 3.1 mô tả các tham số và cơ sở của phương pháp được đề xuất.


Bảng 3.1. Cấu hình thuật toán phân cụm cho phân tích so sánh

Phương pháp	Mô tả	Tham số đầu vào
FCF- $\mathcal{L}_1$ [22]	dựa trên c -means mờ truyền thống với $\mathcal{L}_1$ giữa hai hàm mật độ	$\text{maxIter} = 500, m = 2, \epsilon = 1 \times 10^{-6}$
FCF-CWD [23]	dựa trên c -means mờ truyền thống c -means với khoảng cách độ rộng cụm giữa hai hàm mật độ	$\text{maxIter} = 500, m = 2, \epsilon = 1 \times 10^{-6}$
KCF [13]	dựa trên k -means truyền thống với khoảng cách $\mathcal{L}_1$ giữa hai hàm mật độ	$\text{maxIter} = 500$
IFCF (Đề xuất)	dựa trên c -means mờ cải tiến cho hàm mật độ mất cân bằng	$\text{maxIter} = 500, m = 2, \epsilon = 1 \times 10^{-6}$

3.2.3 Kết quả thực hiện

a. Ví dụ 3.1

Theo kết quả phân vùng, các bảng của Hình 3.5(a)–Hình 3.5(d) hiển thị thành viên trên mỗi mẫu của từng thuật toán cụm (ngoại trừ FCF- $\mathcal{L}_1$) với $IR = 80$.



Hình 3.5. Ma trận phân vùng của các phương pháp tại $IR = 80$

Hình 3.6 minh họa ma trận phân vùng của bốn phương pháp tại mức mất cân bằng $IR = 80$. Có thể thấy rõ sự khác biệt đáng kể giữa các kỹ thuật trong khả năng duy trì ranh giới phân cụm khi dữ liệu bị lệch mạnh.

Cụ thể, IFCCF thể hiện cấu trúc phân cụm ổn định, hai cụm được tách biệt rõ ràng, hầu như không xuất hiện hiện tượng nhiễu hoặc lẫn mẫu giữa các vùng. Ngược lại, Self-Updating cho thấy sự phân cụm cứng nhưng lại tự động xem xét trong ba cụm chứ không phải hai như cần thiết. Thuật toán FCD-CWD và KCF đều thể hiện sự dao động mạnh và phân vùng ngẫu nhiên do các dải phân cụm xen kẽ dày đặc phản ánh hiện tượng sụp đổ phân cụm ngẫu nhiên, đặc trưng khi IR cao.


Hơn nữa, để đánh giá tính xác thực của phân vùng, Bảng 3.2 cho thấy IFCCF đạt kết quả tốt, có khả năng chống nhiễu cao và duy trì hiệu suất tính toán ổn định.

Một mặt, FCF-CWD và FCF- $\mathcal{L}_1$ cho kết quả gần như giống hệt nhau về mặt thống kê trên mọi phép đo, cho thấy việc hiệu chỉnh khoảng cách không mang lại lợi ích đáng kể trong các môi trường dữ liệu mất cân bằng. Ngoài ra, KCF thể hiện sự suy giảm chất lượng rõ rệt tại $IR \geq 80$, khi ARI giảm mạnh từ 1,00 xuống 0,02 và chỉ số $Dunn$ giảm xuống 0,00. Điều này phản ánh sự tồn tại của một ngưỡng nhiễu tối hạn, vượt qua ngưỡng này các phương pháp trọng tâm cổ điển sẽ mất đi cấu trúc cụm. Bên cạnh đó, SUP đạt được giá trị *Silhouette* bằng 1,00 nhưng đồng thời tạo ra các giá trị $Dunn$ dao động mạnh, từ 6112 tại $IR = 20$ xuống 141 tại $IR = 80$, cho thấy tính đồng nhất nội bộ của cụm là tốt. Tuy nhiên, phương pháp này chỉ ổn định trong khoảng 4 ÷ 5 lần lặp,

Bảng 3.2. So sánh các thuật toán đề xuất và các thuật toán cơ sở đối với Ví dụ 3.2

Chỉ số	IR	FCF-CWD	FCM- $\mathcal{L}_1$	KCF	IFCF
ARI	20	0,12 $\pm$ 0,19	0,12 $\pm$ 0,19	1,00 $\pm$ 0,00	1,00 $\pm$ 0,00
	50	0,01 $\pm$ 0,00	0,01 $\pm$ 0,00	1,00 $\pm$ 0,00	1,00 $\pm$ 0,00
	80	0,00 $\pm$ 0,00	0,00 $\pm$ 0,00	0,02 $\pm$ 0,00	1,00 $\pm$ 0,00
	100	0,00 $\pm$ 0,00	0,00 $\pm$ 0,00	0,02 $\pm$ 0,00	1,00 $\pm$ 0,00
NMI	20	0,14 $\pm$ 0,12	0,14 $\pm$ 0,12	1,00 $\pm$ 0,00	1,00 $\pm$ 0,00
	50	0,04 $\pm$ 0,00	0,04 $\pm$ 0,00	1,00 $\pm$ 0,00	1,00 $\pm$ 0,00
	80	0,03 $\pm$ 0,00	0,03 $\pm$ 0,00	0,04 $\pm$ 0,00	1,00 $\pm$ 0,00
	100	0,02 $\pm$ 0,00	0,02 $\pm$ 0,00	0,03 $\pm$ 0,00	1,00 $\pm$ 0,00
Dunn	20	0,00 $\pm$ 0,00	0,00 $\pm$ 0,00	6,31 $\pm$ 0,00	6,31 $\pm$ 0,00
	50	0,00 $\pm$ 0,00	0,00 $\pm$ 0,00	7,66 $\pm$ 0,00	7,66 $\pm$ 0,00
	80	0,00 $\pm$ 0,00	0,00 $\pm$ 0,00	0,00 $\pm$ 0,00	6,68 $\pm$ 0,00
	100	0,00 $\pm$ 0,00	0,00 $\pm$ 0,00	0,00 $\pm$ 0,00	5,80 $\pm$ 0,00
Silhouette	20	0,41 $\pm$ 0,29	0,41 $\pm$ 0,28	0,99 $\pm$ 0,00	0,99 $\pm$ 0,00
	50	0,19 $\pm$ 0,01	0,19 $\pm$ 0,01	0,99 $\pm$ 0,00	0,99 $\pm$ 0,00
	80	0,23 $\pm$ 0,00	0,23 $\pm$ 0,00	0,34 $\pm$ 0,00	0,99 $\pm$ 0,00
	100	0,25 $\pm$ 0,00	0,25 $\pm$ 0,00	0,36 $\pm$ 0,00	0,99 $\pm$ 0,00
Time	20	0,01 $\pm$ 0,01	0,01 $\pm$ 0,01	0,01 $\pm$ 0,00	0,02 $\pm$ 0,00
	50	0,03 $\pm$ 0,01	0,02 $\pm$ 0,01	0,04 $\pm$ 0,02	0,04 $\pm$ 0,02
	80	0,03 $\pm$ 0,01	0,02 $\pm$ 0,01	0,06 $\pm$ 0,02	0,07 $\pm$ 0,00
	100	0,04 $\pm$ 0,02	0,03 $\pm$ 0,02	0,07 $\pm$ 0,03	0,11 $\pm$ 0,02
Iterations	20	8,00 $\pm$ 5,00	8,00 $\pm$ 5,00	3,50 $\pm$ 1,00	5,00 $\pm$ 1,00
	50	9,50 $\pm$ 7,00	9,50 $\pm$ 7,00	12,00 $\pm$ 5,00	7,00 $\pm$ 1,00
	80	7,00 $\pm$ 3,00	7,00 $\pm$ 3,00	14,00 $\pm$ 4,00	9,00 $\pm$ 1,00
	100	7,00 $\pm$ 3,00	7,00 $\pm$ 3,00	11,00 $\pm$ 3,00	10,00 $\pm$ 1,00

trong khi thời gian chạy tăng tuyến tính (lớn hơn 49,s tại $IR = 100$), thể hiện sự không tương xứng giữa số lần lặp và hiệu quả tính toán thực tế. Mặt khác, IFCF là phương pháp đầu tiên được chứng minh là hoạt động đồng thời trên cả năm tiêu chí $ARI = NMI = 1,0$, chỉ số $Dunn$ khoảng 6,0, chỉ số $Silhouette$ khoảng 0,99, thời gian chạy nhỏ hơn 0,11 giây và hội tụ trong 5 ÷ 10 lần lặp trên các thiết lập cho trước. Qua đó, kết quả này khẳng định hơn khả năng chống mất cân bằng, và tính nhỏ gọn.

**Hình 3.6.** Khảo sát sự biến đổi của tham số đối với Ví dụ 3.1


Các đường cong trong Hình 3.6 có cùng trục hoành $m \in \{1,1; 1,5; 2,0; 2,5; 5,0; 10,0\}$ và trục tung là ARI và $Silhouette$. Trong các Hình 3.6, chỉ có đường cong $IR = 20$ cho kết quả ARI cao, trong khi các đường cong từ hơn 50 đều bị giảm về 0,00 ngay từ giá trị m thấp.

Nhìn chung, kết quả thực nghiệm cho thấy hiệu suất phân chùm phụ thuộc rõ rệt vào tham số mờ m khi IR thay đổi. Trong thuật toán đề xuất, phân chùm chất lượng cao được duy trì đối với các giá trị m nhỏ, bất kể IR . Khi m tăng, sự suy giảm hiệu suất xảy ra đột ngột hơn đối với các giá trị IR cao hơn; tuy nhiên, phương pháp đề xuất cho thấy sự suy giảm chậm hơn đáng kể so với hành vi FCF thông thường được báo cáo trong các nghiên cứu trước đó [22].

Cụ thể, đối với $IR = 20$ hoặc 50, cả ARI và $Silhouette$ vẫn gần tối ưu cho đến khi $m = 5$, sau đó điểm số giảm mạnh. Trong khi đó, đối với $IR > 80$ cao hơn, phân chùm mờ thông thường, như được ghi nhận trong các công trình trước đây [13, 58], có xu hướng mất khả năng phân tách chùm ở mức $m = 2$ nhỏ hơn nhiều, thường dẫn đến các phép gán gần như ngẫu nhiên. Ngược lại, phương pháp đề xuất làm chậm quá trình suy giảm này, duy trì chất lượng phân chùm ổn định hơn trên phạm vi giá trị m rộng hơn.

b. Ví dụ 3.2

Hình 3.7 cho thấy kết quả phân tích chùm BKIFF với số chùm c tăng dần từ $2 \div 10$ được áp dụng để phân đoạn ảnh Landsat của đảo Yam và vùng biển xung quanh, cho thấy mức độ chi tiết của việc tách lớp phủ đất tăng lên theo số chùm c .



Hình 3.7. Phương pháp IFCEP được đề xuất áp dụng cho ảnh Landsat


Kết quả là, trên $c = 2 \div 10$, quá trình phân đoạn BKIFF diễn ra đơn điệu và không tạo ra các hiện tượng nhiễu hạt muối tiêu. Ở $c = 2$, thuật toán phân tách cảnh thành vùng nước sâu và các vùng ven biển xung quanh. Khi chùm c tăng dần về phía 3, độ tương phản quang phổ giữa các rạn san hô và hòn đảo trở nên rõ ràng hơn, qua đó cho thấy các đường viền hiển thị sắc nét hơn. Tiếp đến, trong khoảng $c = 4 \div 6$, hòn đảo trở nên nổi bật hơn, thể hiện rõ các khu vực cát nhẹ, thảm thực vật và các vùng biển khác nhau. Đồng thời, một lớp mới được hình thành để làm nổi bật sự khác biệt trong nước biển. Hơn nữa, ở các lớp vi mô $c = 7 \div 9$, các đặc điểm như bãi cát mỏng, chiếm chưa đến 0,5% tổng số pixel, vẫn được nhóm lại, cho thấy khả năng của thuật toán trong việc bảo tồn các dấu hiệu cường độ sáng nhỏ. Cuối cùng, ở $c = 10$, không có chùm nào bị phá vỡ, thể hiện tính nhất quán không gian nội tại của thuật toán. Tóm lại, số chùm trung bình c từ $4 \div 6$ được xem là phù hợp nhất để cân bằng giữa khả năng phân biệt lớp phủ và khả năng khái quát hóa đối với Ví dụ 3.2. Ngược lại, các giá trị c cao hơn thích hợp hơn cho các nghiên cứu vi mô, nơi cần điều tra sâu và phân tích chi tiết hơn.

3.3 Ứng dụng của bài toán phân loại

3.3.1 Dữ liệu

Ví dụ 3.3 (Phân loại màu sắc của các loại đất). Bốn loại đất được lựa chọn để xây dựng tập dữ liệu bao gồm Alluvial Soil, Black Soil, Cinder Soil và Red Soil. Ban đầu, mỗi loại đất chỉ có một hình ảnh gốc, được chuẩn hoá về thang cường độ xám $[0, 1]$. Sau đó, hình ảnh này được sử dụng để sinh thêm các mẫu hình nhân tạo nhằm mô phỏng sự biến thiên tự nhiên của bề mặt vật lý.

Cụ thể, hình ảnh gốc của mỗi lớp được xoay ngẫu nhiên trong khoảng $[-10^\circ, 10^\circ]$ và đồng thời được cắt ngẫu nhiên một vùng con có tỉ lệ từ $80\% \div 100\%$ so với kích thước ban đầu. Nhờ quá trình biến đổi này, tập dữ liệu thu được vừa đa dạng hơn về đặc trưng hình ảnh, vừa phản ánh tốt hơn sự khác biệt thực tế giữa các loại đất. Kết quả là, một tập dữ liệu mất cân bằng được tạo ra theo tỉ lệ $1 : 10 : 10 : 20$ tương ứng với bốn lớp, với số mẫu mỗi lớp Alluvial Soil, Black Soil, Cinder Soil và Red Soil lần lượt là $[10; 100; 100; 200]$.



Hình 3.8. Dữ liệu phân loại màu sắc của các loại đất đối với Ví dụ 3.3

3.3.2 Phương pháp thực hiện

Tập hợp các hàm mật độ $f_j(x)$ được nội suy trên lưới đều $\Omega = [0, 1]$ gồm 256 điểm. Kết quả cuối cùng là một tập dữ liệu gồm $N = 410$ hàm mật độ xác suất với kích thước mỗi hàm 256 điểm. Hình 3.8(b) minh họa ngẫu nhiên 10 hàm mật độ chia theo từng lớp đất. Sau đó, luận văn đánh giá việc phân loại bốn hình ảnh mới ngẫu nhiên trong bốn lớp (mỗi lớp lấy ngẫu nhiên một hình ảnh kiểm tra). Các chỉ số phân loại sau đó được thống kê sau 30 lần chọn mẫu ngẫu nhiên có hoàn lại, bao gồm độ chính xác ACC , độ chính xác cân bằng GM và chỉ số F_1 -score

3.3.3 Kết quả thực hiện

Kết quả trong Bảng 3.3 cho thấy sự khác biệt rõ rệt giữa các phương pháp phân loại hàm mật độ.

Bảng 3.3. Kết quả so sánh các mô hình Bayes với các tiên nghiệm khác nhau đối với Ví dụ 3.3

Phương pháp	ACC	GM	F_1 -score	Thời gian (s)
Bayes-IFCF	$1,00 \pm 0,00$	$1,00 \pm 0,00$	$1,00 \pm 0,00$	0,04
Bayes-FCF	$0,84 \pm 0,12$	$0,37 \pm 0,49$	$0,79 \pm 0,16$	0,14
Bayes-U	$0,75 \pm 0,00$	$0,00 \pm 0,00$	$0,67 \pm 0,00$	0,00
Bayes-L	$0,50 \pm 0,00$	$0,00 \pm 0,00$	$0,38 \pm 0,00$	0,00
Bayes-J	$0,50 \pm 0,00$	$0,00 \pm 0,00$	$0,38 \pm 0,00$	0,00

Ba phương pháp Bayes sử dụng các tiên nghiệm khác nhau, bao gồm phân phối đều, Laplace và Jeffreys, đều cho hiệu năng thấp hơn đáng kể. Cụ thể, mô hình Bayes-Uniform chỉ đạt ACC là 0,75 và chỉ số F_1 là 0,67, trong khi Bayes-Laplace và Bayes-Jeffreys đều dừng ở mức $ACC = 0,50$ và $F_1 = 0,38$. Điều này cho thấy rằng, trong bối

cảnh dữ liệu có sự mất cân bằng nghiêm trọng, việc giả định tiên nghiệm đều hoặc hiệu chỉnh đơn giản bằng α là không đủ để khắc phục sai lệch xác suất giữa các lớp. Ngược lại, mô hình Bayes-IFCF đã đạt hiệu quả cao nhất về độ chính xác, cân bằng phân loại và tính ổn định toàn cục. Điều này chứng minh mô hình này có khả năng nhận dạng chính xác toàn bộ các lớp mà không xảy ra hiện tượng mất cân bằng hay suy giảm nhạy cảm giữa các lớp nhỏ và lớp lớn. Hơn nữa, thời gian huấn luyện của tất cả các phương pháp đều nhỏ hơn 0,20s, cho thấy tính khả thi cao khi áp dụng trong thực nghiệm thực tế.

Tổng kết chương 3

Chương 3 của luận văn tập trung vào việc áp dụng các phương pháp nhận dạng mất cân bằng vào các ứng dụng thực tế trên dữ liệu hình ảnh. Cụ thể, thuật toán phân tích chùm mờ cải tiến IFCF đã được triển khai trên dữ liệu ảnh kết cấu Brodatz và dữ liệu hình ảnh Landsat-8 (Đảo Yam). Bên cạnh đó, mô hình phân loại Bayes-IFCF được áp dụng để phân loại màu sắc của bốn loại đất trong điều kiện tỷ lệ IR cao.

PHẦN KẾT LUẬN

1 Kết luận

Nhận dạng thống kê cho hàm mật độ xác suất là một chủ đề mới, vì cho đến hiện tại, các lý thuyết và ứng dụng của nó vẫn cần nhiều nỗ lực xây dựng. Đây là một vấn đề then chốt đối với sự phát triển của các hệ thống AI dự đoán, bởi các thuật toán truyền thống thường dễ bị thiên lệch về lớp đa số, làm giảm hiệu quả nhận dạng các lớp thiểu số quan trọng. Một số điểm tổng kết trong cả ba chương có thể được tóm lược như sau.

Trước hết, về lý thuyết cơ sở, luận văn đã đề xuất thuật toán IF CF, được thiết kế nhằm giải quyết “hiệu ứng đồng nhất”. Thuật toán IF CF cải tiến hàm mục tiêu bằng cách đưa vào trọng số nghịch đảo kích thước mờ của chùm, qua đó giúp trung hòa đóng góp của các chùm lớn hơn. Nhờ vậy, phương pháp này duy trì được tính ổn định của phân chùm ngay cả ở các tỷ lệ IR cao. Bên cạnh đó, luận văn cũng đã thiết lập nguyên tắc phân loại Bayes-IF CF như một sự mở rộng tự nhiên của IF CF sang bài toán phân loại có giám sát, thông qua việc giới thiệu mô hình Bayes-IF CF. Phương pháp này sử dụng ma trận phân vùng mờ được tính toán từ IF CF để xác định xác suất tiên nghiệm động cho các lớp. Nhờ đó, cách tiếp cận tiên nghiệm động này cho thấy hiệu quả vượt trội so với các giả định tiên nghiệm tĩnh truyền thống (như tiên nghiệm đều, Laplace hay Jeffreys).

Tiếp theo, về các áp dụng số, luận văn đã cung cấp bằng chứng thực nghiệm thông qua việc áp dụng các thuật toán đề xuất cho dữ liệu hình ảnh có tỷ lệ IR cao, bao gồm dữ liệu kết cấu Brodatz và ảnh Landsat. Kết quả cho thấy, IF CF đạt hiệu suất gần như hoàn hảo ($ARI = 1,00$, $NMI = 1,00$) và vẫn duy trì ổn định ngay cả khi IR tăng đến 100. Tương tự, mô hình Bayes-IF CF cũng cho kết quả nhất quán và chính xác trong bài toán phân loại các loại đất.

2 Định hướng nghiên cứu

Về mặt lý thuyết, các hướng phát triển tiếp theo được định hình nhằm mở rộng và hoàn thiện khung phương pháp luận cho nhận dạng thống kê dựa trên hàm mật độ xác suất.

Một là, phát triển các mô hình nhận dạng kết hợp để đồng thời giải quyết hai hiệu ứng “đồng nhất” và “xi phông”. Thuật toán IF CF được đề xuất trong luận văn đã góp

phần giảm thiểu “hiệu ứng đồng nhất”. Tuy nhiên, các thuật toán phân cụm vẫn phải đối mặt với “hiệu ứng xi phong”, trong đó các phần tử biên của lớp nhỏ có xu hướng bị kéo lệch về cụm lớn hơn.

Hai là, thiết lập các điều kiện và chứng minh tính hội tụ nghiêm ngặt khi sử dụng các f -phân kỳ. Hiện nay, cơ sở toán học cho việc phân tích cụm với các phân kỳ này vẫn còn là một khoảng trống kiến thức cần được nghiên cứu và hoàn thiện trong tương lai.

Ba là, thiết kế và triển khai các phiên bản học không giám sát trực tuyến nhằm cập nhật trọng tâm và ma trận phân vùng dựa trên các lô dữ liệu nhỏ hoặc từng hàm mật độ khi chúng đến liên tục. Nhờ vậy, có thể giảm đáng kể yêu cầu về bộ nhớ và thời gian tính toán, đồng thời nâng cao khả năng xử lý trong môi trường dữ liệu động.

Trên phương diện ứng dụng, các hướng mở rộng được định hướng nhằm tăng tính thực tiễn và khả năng triển khai của mô hình trong các lĩnh vực khác nhau.

Một là, phát triển các kỹ thuật trích xuất đặc trưng tiên tiến hơn để biểu diễn các đặc tính hình ảnh phức tạp như kết cấu và hình dạng thành hàm mật độ xác suất. Đồng thời, nên mở rộng việc trích xuất đặc trưng mật độ để xử lý dữ liệu ảnh đa kênh màu.

Hai là, xây dựng cơ chế xác định siêu tham số tối ưu cho các thuật toán phân cụm hàm mật độ. Song song đó, phát triển các công cụ giải thích-AI chuyên biệt cho các mô hình nhận dạng thống kê hàm mật độ nhằm tăng tính minh bạch và khả năng diễn giải, giúp người dùng hiểu rõ lý do mô hình phân loại một mẫu vào lớp thiếu số.

Ba là, mở rộng việc áp dụng nhận dạng thống kê cho dữ liệu hàm mật độ đa chiều vốn xuất hiện ngày càng nhiều trong các nghiên cứu về mối tương quan phức tạp giữa các biến.

TÀI LIỆU THAM KHẢO

- [1] A. Belhadi, V. Mani, S. S. Kamble, S. A. R. Khan, and S. Verma, “Artificial intelligence-driven innovation for enhancing supply chain resilience and performance under the effect of supply chain dynamism: an empirical investigation,” *Annals of Operations Research*, vol. 333, no. 2, pp. 627–652, 2024.
- [2] A. I. Act, “Artificial intelligence act,” *Euroopan unioni. Luettavissa: <https://artificialintelligen>*, 2023.
- [3] T. Mollema, “‘ai colonialism’ is a conceptual metaphor,” Master’s thesis, 2024.
- [4] P. K. Dey, S. Chowdhury, A. Abadie, E. Vann Yaroson, and S. Sarkar, “Artificial intelligence-driven supply chain resilience in vietnamese manufacturing small-and medium-sized enterprises,” *International Journal of Production Research*, vol. 62, no. 15, pp. 5417–5456, 2024.
- [5] C. M. Bishop and H. Bishop, *Deep Learning: Foundations and Concepts*. Springer, 2024.
- [6] S. Theodoridis and K. Koutroumbas, *Pattern recognition*. Elsevier, 2006.
- [7] J. C. Bezdek, R. Ehrlich, and W. Full, “Fcm: The fuzzy *c*-means clustering algorithm,” *Computers & geosciences*, vol. 10, no. 2-3, pp. 191–203, 1984.
- [8] J. Macqueen, “Some methods for classification and analysis of multivariate observations,” in *Proceedings of 5-th Berkeley Symposium on Mathematical Statistics and Probability/University of California Press*, 1967.
- [9] A. R. Webb, *Statistical pattern recognition*. John Wiley & Sons, 2003.
- [10] D. Zha, Z. P. Bhat, K.-H. Lai, F. Yang, Z. Jiang, S. Zhong, and X. Hu, “Data-centric artificial intelligence: A survey,” *arXiv preprint arXiv:2303.10158*, 2023.
- [11] C. Cortes, “Support-vector networks,” *Machine Learning*, 1995.
- [12] A. L. S. Maia and F. d. A. de Carvalho, “Holt’s exponential smoothing and neural network models for forecasting interval-valued time series,” *International Journal of Forecasting*, vol. 27, no. 3, pp. 740–759, 2011.
- [13] T. Nguyen-Trang, Y. Nguyen-Hoang, and T. Vo-Van, “A new semi-supervised clustering algorithm for probability density functions and applications,” *Neural Computing and Applications*, vol. 36, no. 11, pp. 5965–5980, 2024.
- [14] X. Hu, H. Chen, J. Zhang, H. Chen, S. Liu, X. Li, Y. Wang, and X. Xue, “Gat-cobo: Cost-sensitive graph neural network for telecom fraud detection,” *IEEE Transactions on Big Data*, 2024.
- [15] G. H. Nguyen, A. Bouzerdoun, and S. L. Phung, “Learning pattern classification tasks with imbalanced data sets,” *Pattern recognition*, vol. 10, no. 2009, pp. 1322–1328, 2009.

- [16] Y. Tang, Y.-Q. Zhang, N. V. Chawla, and S. Krasser, "Svms modeling for highly imbalanced classification," *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)*, vol. 39, no. 1, pp. 281–288, 2008.
- [17] T. Vo Van and T. Pham-Gia, "Clustering probability distributions," *Journal of Applied Statistics*, vol. 37, no. 11, pp. 1891–1910, 2010.
- [18] L. Billard and E. Diday, *Symbolic data analysis: Conceptual statistics and data mining*. John Wiley & Sons, 2012.
- [19] A. Irpino and R. Verde, "Basic statistics for distributional symbolic variables: a new metric-based approach," *Advances in Data Analysis and Classification*, vol. 9, no. 2, pp. 143–175, 2015.
- [20] F. Gullo, G. Ponti, A. Tagarelli, and S. Greco, "A hierarchical algorithm for clustering uncertain data via an information-theoretic approach," in *2008 Eighth IEEE International Conference on Data Mining*, pp. 821–826, IEEE, 2008.
- [21] A. Azzalini, "A class of distributions which includes the normal ones," *Scandinavian journal of statistics*, pp. 171–178, 1985.
- [22] T. Nguyentrang and T. Vovan, "Fuzzy clustering of probability density functions," *Journal of Applied Statistics*, vol. 44, no. 4, pp. 583–601, 2017.
- [23] T. Vovan, "Cluster width of probability density functions," *Intelligent Data Analysis*, vol. 23, no. 2, pp. 385–405, 2019.
- [24] A. Wald, "Statistical decision functions," in *Breakthroughs in Statistics: Foundations and Basic Theory*, pp. 342–357, Springer, 1950.
- [25] T. Nguyen-Trang, T. Nguyen-Thoi, and T. Vo-Van, "Globally automatic fuzzy clustering for probability density functions and its application for image data," *Applied Intelligence*, vol. 53, no. 15, pp. 18381–18397, 2023.
- [26] T. Nguyen-Trang, T. Nguyen-Thoi, K.-N. Nguyen-Thi, and T. Vo-Van, "Balance-driven automatic clustering for probability density functions using metaheuristic optimization," *International Journal of Machine Learning and Cybernetics*, vol. 14, no. 4, pp. 1063–1078, 2023.
- [27] M. Fréchet, "Les éléments aléatoires de nature quelconque dans un espace distancié," in *Annales de l'institut Henri Poincaré*, vol. 10, pp. 215–310, 1948.
- [28] S. M. Ali and S. D. Silvey, "A general class of coefficients of divergence of one distribution from another," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 28, no. 1, pp. 131–142, 1966.
- [29] C. Villani *et al.*, *Optimal transport: old and new*, vol. 338. Springer, 2008.
- [30] K. Florek, J. Łukaszewicz, J. Perkal, H. Steinhaus, and S. Zubrzycki, "Sur la liaison et la division des points d'un ensemble fini," in *Colloquium mathematicum*, vol. 2, pp. 282–285, 1951.
- [31] T. Sorensen, "A method of establishing groups of equal amplitude in plant sociology based on similarity of species content and its application to analyses of the vegetation on danish commons," *Biologiske skrifter*, vol. 5, pp. 1–34, 1948.

- [32] J. H. Ward Jr, "Hierarchical grouping to optimize an objective function," *Journal of the American statistical association*, vol. 58, no. 301, pp. 236–244, 1963.
- [33] K. Matusita, "On the notion of affinity of several distributions and some of its applications," *Annals of the institute of Statistical Mathematics*, vol. 19, pp. 181–192, 1967.
- [34] G. T. Toussaint, "Some inequalities between distance measures for feature evaluation," *IEEE Transactions on Computers*, vol. 21, no. 04, pp. 409–410, 1972.
- [35] T. VoVan and T. NguyenTrang, "Similar coefficient for cluster of probability density functions," *Communications in Statistics-Theory and Methods*, vol. 47, no. 8, pp. 1792–1811, 2018.
- [36] D. S. Watson, "On the philosophy of unsupervised learning," *Philosophy & Technology*, vol. 36, no. 2, p. 28, 2023.
- [37] S. C. Johnson, "Hierarchical clustering schemes," *Psychometrika*, vol. 32, no. 3, pp. 241–254, 1967.
- [38] J. C. Dunn, "A fuzzy relative of the isodata process and its use in detecting compact well-separated clusters," 1973.
- [39] J. C. Bezdek, *Pattern recognition with fuzzy objective function algorithms*. Springer Science & Business Media, 2013.
- [40] J. C. Bezdek, "A convergence theorem for the fuzzy isodata clustering algorithms," *IEEE transactions on pattern analysis and machine intelligence*, no. 1, pp. 1–8, 1980.
- [41] R. J. Hathaway and J. C. Bezdek, "Recent convergence results for the fuzzy c-means clustering algorithms," *Journal of Classification*, vol. 5, no. 2, pp. 237–247, 1988.
- [42] W. I. Zangwill, "Nonlinear programming: a unified approach," (*No Title*), 1969.
- [43] L. Groll and J. Jakel, "A new convergence proof of fuzzy *c*-means," *IEEE Transactions on Fuzzy Systems*, vol. 13, no. 5, pp. 717–720, 2005.
- [44] R. A. Fisher, "The use of multiple measurements in taxonomic problems," *Annals of eugenics*, vol. 7, no. 2, pp. 179–188, 1936.
- [45] F. Rosenblatt, "Principles of neurodynamics: Perceptrons and the theory of brain mechanisms," 1961.
- [46] H. Huynh-Van, T. Le-Hoang, and T. Vo-Van, "Classifying for images based on the extracted probability density function and the quasi bayesian method," *Computational Statistics*, vol. 39, no. 5, pp. 2677–2701, 2024.
- [47] T. Vo-Van and D. PhamToan, "A supervised learning algorithm based on the quasi-bayesian method for the probability density functions and application for medical data," *Knowledge-Based Systems*, vol. 299, p. 112003, 2024.
- [48] B. Akturk, U. Beyaztas, H. L. Shang, and A. Mandal, "Robust functional logistic regression," *Advances in Data Analysis and Classification*, pp. 1–25, 2024.
- [49] J. Ren, S. D. Lee, X. Chen, B. Kao, R. Cheng, and D. Cheung, "Naive bayes classification of uncertain data," in *2009 Ninth IEEE international conference on data mining*, pp. 944–949, IEEE, 2009.

- [50] M. Minami and C. E. Lennert-Cody, "Regression tree and clustering for distributions, and homogeneous structure of population characteristics," *Journal of Agricultural, Biological and Environmental Statistics*, pp. 1–20, 2024.
- [51] B. Tavakkol and Y. Son, "Fuzzy kernel k-medoids clustering algorithm for uncertain data objects," *Pattern Analysis and Applications*, vol. 24, no. 3, pp. 1287–1302, 2021.
- [52] A. K. Jain, "Data clustering: 50 years beyond k -means," *Pattern recognition letters*, vol. 31, no. 8, pp. 651–666, 2010.
- [53] A. Saxena, M. Prasad, A. Gupta, N. Bharill, O. P. Patel, A. Tiwari, M. J. Er, W. Ding, and C.-T. Lin, "A review of clustering techniques and developments," *Neurocomputing*, vol. 267, pp. 664–681, 2017.
- [54] T. Dinh, H. Wong, P. Fournier-Viger, D. Lisik, M.-Q. Ha, H.-C. Dam, and V.-N. Huynh, "Categorical data clustering: 25 years beyond k -modes," *Expert Systems with Applications*, vol. 272, p. 126608, 2025.
- [55] T. Vovan, "Classifying for images based on the extracted color scales and representative probability density functions," *Expert Systems with Applications*, p. 128456, 2025.
- [56] D. Pham-Toan, T. Vo-Van, A. Pham-Chau, T. Nguyen-Trang, and D. Ho-Kieu, "A new binary adaptive elitist differential evolution based automatic k -medoids clustering for probability density functions," *Mathematical Problems in Engineering*, vol. 2019, no. 1, p. 6380568, 2019.
- [57] D. Phamtoan and T. Vovan, "Automatic fuzzy clustering for probability density functions using the genetic algorithm," *Neural Computing and Applications*, vol. 34, no. 17, pp. 14609–14625, 2022.
- [58] T. Nguyen-Trang, T. Vo-Van, and H. Che-Ngoc, "An efficient automatic clustering algorithm for probability density functions and its applications in surface material classification," *Statistica Neerlandica*, vol. 78, no. 1, pp. 244–260, 2024.
- [59] H. Tran-Nam, T. Nguyen-Trang, and H. Che-Ngoc, "A new possibilistic-based clustering method for probability density functions and its application to detecting abnormal elements," *Scientific Reports*, vol. 14, no. 1, p. 17871, 2024.
- [60] J.-H. Chen and W.-L. Hung, "A jackknife entropy-based clustering algorithm for probability density functions," *Journal of Statistical Computation and Simulation*, vol. 91, no. 5, pp. 861–875, 2021.
- [61] R. Okano and M. Imaizumi, "Wasserstein k -centres clustering for distributional data," *arXiv preprint arXiv:2407.08228*, 2024.
- [62] J. Noordam, W. Van Den Broek, and L. Buydens, "Multivariate image segmentation with cluster size insensitive fuzzy c-means," *Chemometrics and intelligent laboratory systems*, vol. 64, no. 1, pp. 65–78, 2002.
- [63] P.-L. Lin, P.-W. Huang, C.-H. Kuo, and Y. Lai, "A size-insensitive integrity-based fuzzy c-means method for data clustering," *Pattern Recognition*, vol. 47, no. 5, pp. 2042–2056, 2014.
- [64] Y. Liu, T. Hou, B. Kang, and F. Liu, "Unsupervised binning of metagenomic assembled contigs using improved fuzzy c-means method," *IEEE/ACM transactions on computational biology and bioinformatics*, vol. 14, no. 6, pp. 1459–1467, 2016.

- [65] H. Yu, H. Li, X. Xu, Q. Gao, and R. Lan, "Suppressed possibilistic fuzzy c-means clustering based on shadow sets for noisy data with imbalanced sizes," *Applied Soft Computing*, vol. 167, p. 112263, 2024.
- [66] Y. He, "Imbalanced data clustering using equilibrium k-means," *arXiv preprint arXiv:2402.14490*, 2024.
- [67] S. Askari, "Fuzzy c-means clustering algorithm for data with unequal cluster sizes and contaminated with noise and outliers: Review and development," *Expert Systems with Applications*, vol. 165, p. 113856, 2021.
- [68] H. Xiong, J. Wu, and J. Chen, "K-means clustering versus validation measures: a data distribution perspective," in *Proceedings of the 12th ACM SIGKDD international conference on Knowledge discovery and data mining*, pp. 779–784, 2006.
- [69] A. M. Ikotun, F. Habyarimana, and A. E. Ezugwu, "Cluster validity indices for automatic clustering: A comprehensive review," *Heliyon*, 2025.
- [70] S. Fillmore-Patrick, "The logit model measurement problem," *Philosophy of Science*, vol. 92, no. 2, p. 285–303, 2025.
- [71] T. Vovan, H. Nguyenthikim, and D. Phamtoan, "Multi-class classification using a new bayesian method," *Model Assisted Statistics and Applications*, vol. 18, no. 3, pp. 257–266, 2023.
- [72] I. Pavlů, A. Menafoglio, E. Bongiorno, and K. Hron, "Classification of probability density functions in the framework of bayes spaces: methods and applications," *SORT: statistics and operations research transactions*, vol. 47, no. 2, pp. 295–322, 2023.
- [73] T. A. N. Tran, A. T. N. Nguyen, and D. PhamToan, "A novel supervised learning model for mri image using fuzzy clustering and naïve bayes algorithms," *Model Assisted Statistics and Applications*, p. 15741699251334321, 2025.
- [74] T. Vo-Van, "Developing an image classification algorithm based on the novel measure combined with quasi-bayesian method for representing probability density function," *Annals of Operations Research*, pp. 1–26, 2025.
- [75] M. Ghanem, A. K. Ghaith, V. G. El-Hajj, A. Bhandarkar, A. De Giorgio, A. Elmi-Terander, and M. Bydon, "Limitations in evaluating machine learning models for imbalanced binary outcome classification in spine surgery: a systematic review," *Brain Sciences*, vol. 13, no. 12, p. 1723, 2023.
- [76] L. Nanni, S. Ghidoni, and S. Brahnam, "Handcrafted vs. non-handcrafted features for computer vision classification," *Pattern recognition*, vol. 71, pp. 158–172, 2017.
- [77] E. Schubert, "Stop using the elbow criterion for k-means and how to choose the number of clusters instead," *ACM SIGKDD Explorations Newsletter*, vol. 25, no. 1, pp. 36–42, 2023.
- [78] C. Goutte, P. Toft, E. Rostrup, F. Å. Nielsen, and L. K. Hansen, "On clustering fmri time series," *NeuroImage*, vol. 9, no. 3, pp. 298–310, 1999.
- [79] S. Leonelli, *Data-centric biology: A philosophical study*. University of Chicago Press, 2019.
- [80] D. S. Watson, "Reply to tom sterkenburg's commentary," *Philosophy & Technology*, vol. 36, no. 4, p. 69, 2023.

- [81] W. J. T. Mollema, “Responding to the watson-sterkenburg debate on clustering algorithms and natural kinds,” 2024.
- [82] I. van der Linde, “Why the confusion matrix fails as a model of knowledge,” *AI & SOCIETY*, pp. 1–2, 2025.
- [83] A. Erasmus, T. D. Brunet, and E. Fisher, “What is interpretability?,” *Philosophy & Technology*, vol. 34, no. 4, pp. 833–862, 2021.
- [84] L.-V. Herm, K. Heinrich, J. Wanner, and C. Janiesch, “Stop ordering machine learning algorithms by their explainability! a user-centered investigation of performance and explainability,” *International Journal of Information Management*, vol. 69, p. 102538, 2023.

PHỤ LỤC A LÝ THUYẾT BỔ SUNG VÀ MÃ NGUỒN

Phần này cung cấp lý thuyết và các thuật toán của luận văn.

Bảng 3.4. Một số hàm cơ sở $\psi_m(x)$ phổ biến trong hồi quy logistic cho dữ liệu hàm mật độ

Hàm cơ sở	Công thức $\psi_m(x)$	Miền xác định
Gaussian (RBF)	$\psi_m(x) = \exp\left(-\frac{(x-\mu_m)^2}{2\sigma_m^2}\right)$	$x \in \mathbb{R}$
Hàm sóng con (Wavelet)	$\psi_m(x) = 2^{jm/2} \psi(2^j x - k_m)$	$x \in \mathbb{R}$
Chuỗi Fourier	$\psi_m^{(\cos)}(x) = \cos\left(\frac{2\pi m x}{T}\right), \quad \psi_m^{(\sin)}(x) = \sin\left(\frac{2\pi m x}{T}\right)$	$x \in [0, T]$
Đa thức Bernstein	$\psi_m(x) = \binom{n}{m} x^m (1-x)^{n-m}$	$x \in [0, 1]$
Đa thức Legendre	$\psi_m(x) = \frac{1}{2^m m!} \frac{d^m}{dx^m} [(x^2 - 1)^m]$	$x \in [-1, 1]$
B-spline	$\psi_m(x) = \frac{x-t_m}{t_{m+k}-t_m} \psi_{m,k-1}(x) + \frac{t_{m+k+1}-x}{t_{m+k+1}-t_{m+1}} \psi_{m+1,k-1}(x),$ với $\psi_{m,0}(x) = \mathbf{1}_{[t_m, t_{m+1})}(x)$	$x \in \mathbb{R}$

Algorithm 2: Giải thuật phân cụm thứ bậc tích tụ (HCF)

```

1: procedure HCF( $\mathcal{F}; \Delta$ ) ▷ Cho trước liên kết
2:    $t \leftarrow 0$ 
3:   Khởi tạo:  $\mathcal{F}^{(t=0)} = \{\{f_1\}; \{f_2\}; \dots; \{f_n\}\}$ 
4:   while  $n - t > 1$  do
5:     Chọn hai  $c_i, c_j \in \mathcal{F}^{(t=0)}$  sao cho thỏa tại vị trí  $(c_i; c_j) = \arg \min_{c_u, c_v \in \mathcal{F}^{(t=0)}} \Delta(c_u; c_v)$ .
6:     Gộp  $c \leftarrow c_i \cup c_j$ 
7:     Cập nhật  $\mathcal{F}^{t+1} \leftarrow \left( \mathcal{F}^{(t)} \setminus \{c_i; c_j\} \right) \cup \{c\}$ 
8:      $t \leftarrow t + 1$ 
9:   end while
10:  return Cây phân cấp
11: end procedure

```

Algorithm 3: Giải thuật phân tích cụm (KCF)

```

1: procedure KCF( $c; \varepsilon$ ) ▷ Cho trước số cụm  $c$ 
2:    $t \leftarrow 0$ 
3:   Khởi tạo  $\mu^{(t)}$  và  $\Theta^{(t)}$  ngẫu nhiên
4:   while  $\|J^{(t+1)} - J^{(t)}\| < \varepsilon$  do
5:      $t \leftarrow t + 1$ 
6:     Cập nhật  $\mu^{(t+1)}$  bằng Công thức  $\mu_{ij} = \mathbf{1}_{\{j \in c_i\}}$ 
7:     Cập nhật  $\Theta^{(t+1)}$  bằng Công thức (1.2)
8:   end while
9:   return  $\mu$  và  $\Theta$ . ▷ Ma trận phân vùng và hàm mật độ đại diện
10: end procedure

```

Algorithm 4: Giải thuật phân tích chùm mờ (FCF)

```
1: procedure FCF( $c; \varepsilon$ ) ▷ Cho trước số chùm  $c$ 
2:    $t \leftarrow 0$ 
3:   Khởi tạo  $\mu^{(t)}$  và  $\Theta^{(t)}$  ngẫu nhiên
4:   while  $\|\mu^{(t+1)} - \mu^{(t)}\| < \varepsilon$  do
5:      $t \leftarrow t + 1$ 
6:     Cập nhật  $\Theta^{(t+1)}$  bằng Công thức (1.3)
7:     Cập nhật  $\mu^{(t+1)}$  bằng Công thức (1.4) và (1.5)
8:   end while
9:   return  $\mu$  và  $\Theta$ . ▷ Ma trận phân vùng và hàm mật độ đại diện
10: end procedure
```

Algorithm 5: Giải thuật phân tích chùm mờ cải tiến (IFCF)

```
1: procedure IFCF( $c; \varepsilon$ ) ▷ Cho trước số chùm  $c$ 
2:    $t \leftarrow 0$ 
3:   Khởi tạo  $\mu^{(t)}$  và  $\Theta^{(t)}$  ngẫu nhiên và  $\omega_i^{(t)} = 0$ 
4:   while  $\|\mu^{(t+1)} - \mu^{(t)}\| < \varepsilon$  do
5:      $t \leftarrow t + 1$ 
6:     Cập nhật  $\Theta^{(t+1)}$  bằng Công thức (2.7)
7:     Cập nhật  $\mu^{(t+1)}$  bằng Công thức (2.2) và (C1)
8:     Tính  $\omega_i^{(t+1)} \leftarrow \frac{1}{n} \sum_{j=1}^n \mu_{ij}^{(t+1)}, \quad 1 \leq i \leq c$ 
9:   end while
10:  return  $\mu, \Theta$ , và  $\omega$ . ▷ Ma trận phân vùng, hàm mật độ đại diện, trọng số chùm
11: end procedure
```

Về tài nguyên tính toán, luận văn này chạy trên hệ điều hành Ubuntu 24.04.2 LTS, nhân Linux 6.11.0-19-generic, 11th Gen Intel® Core™ i5-11400H×12, bộ nhớ 16.0 GiB.

Việc thực thi mã nguồn được sử dụng trong môi trường ảo của Anaconda tên là ‘proclustEnv’. Các mã Python được sử dụng trong luận văn này được lưu trữ tại <https://github.com/hungtrannam/probclust>. Các thư viện trên được lưu trong tệp requirements.yml và có thể được cài đặt tự động bằng lệnh

```
conda install environment.yml
```

Đây là danh sách các thư viện Python cần thiết để thực thi toàn bộ mã nguồn trong luận văn.

```
numpy matplotlib pandas tqdm seaborn optuna argparse
torch torchvision torchmetrics scikit-learn einops optunahub cmaes
gpustat statsmodels gputil shap ipykernel opencv-python
scikit-image pyvis scikit-posthocs forestplot
```

PHỤ LỤC B KẾT QUẢ

Ví dụ 3.4 (Liên kết các chùm hàm mật độ). Giả sử ta có ba chùm hàm mật độ xác suất Gauss $\mathcal{F}; \mathcal{G}$ và $\mathcal{H}$. Tính các liên kết $\Delta(\mathcal{F}; \mathcal{G})$ và $\Delta(\mathcal{F} \cup \mathcal{G}; \mathcal{H})$ biết khoảng cách giữa hai hàm mật độ là $\mathcal{L}_2$ và các chùm

$$\begin{aligned}\mathcal{F} &= \{f_1 = \mathcal{N}(0, 3; 1), f_2 = \mathcal{N}(1; 1)\}, \\ \mathcal{G} &= \{g_1 = \mathcal{N}(4, 0; 1), g_2 = \mathcal{N}(5, 5; 1), g_3 = \mathcal{N}(4, 8; 1)\}, \\ \mathcal{H} &= \{h_1 = \mathcal{N}(9, 1; 1), h_2 = \mathcal{N}(8, 0; 1)\}.\end{aligned}$$

Bài giải 3.4. Vì các phương sai của hàm mật độ Gauss đều bằng 1. Nên ta có thể tính $\mathcal{L}_2$ bằng công thức tổng quát $\mathcal{L}_2(u; v) = \left(2 - 2 \exp\left(-\frac{(\mu_u - \mu_v)^2}{4\sigma^2}\right)\right)^{1/2}$. Sau khi tính toán, ta nhận được ma trận khoảng cách từng đôi một.

	$\{f_1$	$f_2\}$	$\{g_1$	g_2	$g_3\}$	$\{h_1$	$h_2\}$
f_1							
f_2	0,26						
g_1	0,74	0,71					
g_2	0,75	0,75	0,49				
g_3	0,75	0,74	0,29	0,26			
h_1	0,75	0,75	0,75	0,74	0,75		
h_2	0,75	0,75	0,74	0,67	0,72	0,38	

Từ đây, ta có thể dễ dàng tính được các liên kết $\Delta(\mathcal{F}, \mathcal{G})$ thông qua ma trận này. Ta có,

$$\begin{aligned}\Delta_{\min}(\mathcal{F}, \mathcal{G}) &= \min \{ \mathcal{L}_2(f_1, g_1), \mathcal{L}_2(f_1, g_2), \mathcal{L}_2(f_1, g_3), \mathcal{L}_2(f_2, g_1), \mathcal{L}_2(f_2, g_2), \mathcal{L}_2(f_2, g_3) \} \\ &= \min\{0,74; 0,75; 0,75; 0,71; 0,75; 0,74\} = 0,71, \\ \Delta_{\max}(\mathcal{F}, \mathcal{G}) &= \max \{ \mathcal{L}_2(f_1, g_1), \mathcal{L}_2(f_1, g_2), \mathcal{L}_2(f_1, g_3), \mathcal{L}_2(f_2, g_1), \mathcal{L}_2(f_2, g_2), \mathcal{L}_2(f_2, g_3) \} \\ &= \max\{0,74; 0,75; 0,75; 0,71; 0,75; 0,74\} = 0,75, \\ \Delta_{\text{avg}}(\mathcal{F}, \mathcal{G}) &= \frac{1}{6} \sum_{\substack{f \in \mathcal{F} \\ g \in \mathcal{G}}} \mathcal{L}_2(f, g) = 0,17(0,74 + 0,75 + 0,75 + 0,71 + 0,75 + 0,74) = 0,74, \\ \Delta_{\text{centroid}}(\mathcal{F}, \mathcal{G}) &= \mathcal{L}_2(\theta_{\mathcal{F}}; \theta_{\mathcal{G}}) = \left(2 - 2 \exp \left(-\frac{(0,65 - 4,77)^2}{4} \right) \right)^{1/2} = 1,41, \\ &\text{với } \theta_{\mathcal{F}} = (0,3 + 1,0)/2 = 0,65; \theta_{\mathcal{G}} = (4,0 + 5,5 + 4,8)/3 = 4,77, \\ \Delta_{\text{Ward}}(\mathcal{F}, \mathcal{G}) &= \frac{\#\mathcal{F} \cdot \#\mathcal{G}}{\#\mathcal{F} + \#\mathcal{G}} \cdot \mathcal{L}_2^2(\theta_{\mathcal{F}}, \theta_{\mathcal{G}}) = \frac{2 \cdot 3}{2 + 3} \cdot (1,41)^2 = 2,39,\end{aligned}$$

Tương tự, ta cũng có kết quả cho $\Delta(\mathcal{F} \cup \mathcal{G}; \mathcal{H})$ là

$$\begin{aligned}\Delta_{\min}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) &= 0,67; \Delta_{\max}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) = 0,75; \Delta_{\text{avg}}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) = 0,74, \\ \Delta_{\text{centroid}}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) &= 1,41; \Delta_{\text{Ward}}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) = 2,86.\end{aligned}$$

Bài giải Ví dụ 1.5. Đầu tiên, ta xem thứ tự của μ_i chính là thứ tự của dữ liệu hàm mật độ f_i , tính toán các khoảng cách từng đôi hàm mật độ bất kỳ bằng khoảng cách $\mathcal{L}_2(f_i; f_j)$ với $i; j = 1; \dots; 7$, ta nhận được ma trận khoảng cách

	f_1	f_2	f_3	f_4	f_5	f_6	f_7
f_1							
f_2	0,74						
f_3	0,75	0,75					
f_4	0,26	0,71	0,75				
f_5	0,75	0,49	0,74	0,75			
f_6	0,75	0,74	0,38	0,75	0,67		
f_7	0,75	0,29	0,75	0,74	0,26	0,72	

Ta thấy khoảng cách $D(f_1; f_4) = D(f_5; f_7) = 0,26$ là khoảng cách nhỏ nhất nên ta

chọn một trong hai. Trường hợp này, ta chọn hàm mật độ f_1 và f_4 xếp vào một chùm $\{f_1; f_4\}$. Tiến hành tính toán liên kết đủ giữa chùm $\{f_1; f_4\}$ với các hàm mật độ khác. Ta có

$$\begin{aligned}\Delta(\{f_1; f_4\}; f_2) &= \max\{D(f_1; f_2); D(f_4; f_2)\} = \max\{0,74; 0,71\} = 0,74, \\ \Delta(\{f_1; f_4\}; f_3) &= \max\{D(f_1; f_3); D(f_4; f_3)\} = \max\{0,75; 0,75\} = 0,75, \\ \Delta(\{f_1; f_4\}; f_5) &= \max\{D(f_1; f_5); D(f_4; f_5)\} = \max\{0,75; 0,75\} = 0,75, \\ \Delta(\{f_1; f_4\}; f_6) &= \max\{D(f_1; f_6); D(f_4; f_6)\} = \max\{0,75; 0,75\} = 0,75, \\ \Delta(\{f_1; f_4\}; f_7) &= \max\{D(f_1; f_7); D(f_4; f_7)\} = \max\{0,75; 0,74\} = 0,75.\end{aligned}$$

Ta xóa dòng/cột f_1 và f_4 và thay bằng một dòng/cột mới là $\{f_1; f_4\}$, ta được ma trận khoảng cách mới

		$\{f_1; f_4\}$	f_2	f_3	f_5	f_6	f_7
$D^{(t=1)} =$	$\{f_1; f_4\}$						
	f_2	0,74					
	f_3	0,75	0,75				
	f_5	0,75	0,49	0,74			
	f_6	0,75	0,74	0,38	0,67		
	f_7	0,75	0,29	0,75	0,26	0,72	

Tiếp theo, ta thấy $D(f_5; f_7) = 0,26$ là cách nhỏ nhất nên ta xếp hai hàm mật độ này thành một chùm mới $\{f_5; f_7\}$. Tiến hành tính toán liên kết đủ giữa chùm $\{f_5; f_7\}$ với các hàm mật độ khác. Ta có

$$\begin{aligned}\Delta(\{f_5; f_7\}; \{f_1; f_4\}) &= \max\{D(f_5; f_1); D(f_5; f_4); D(f_7; f_1); D(f_7; f_4)\} = 0,75, \\ \Delta(\{f_5; f_7\}; f_2) &= \max\{D(f_5; f_2); D(f_7; f_2)\} = 0,49, \\ \Delta(\{f_5; f_7\}; f_3) &= \max\{D(f_5; f_3); D(f_7; f_3)\} = 0,75, \\ \Delta(\{f_5; f_7\}; f_6) &= \max\{D(f_5; f_6); D(f_7; f_6)\} = 0,72.\end{aligned}$$

Ta xóa dòng/cột f_5 và f_7 và thay bằng một dòng/cột mới là $\{f_5; f_7\}$, ta được ma

trận khoảng cách mới

		$\{f_1, f_4\}$	f_2	f_3	$\{f_5, f_7\}$	f_6
$D^{(t=2)} =$	$\{f_1, f_4\}$					
	f_2	0,75				
	f_3	0,75	0,75			
	$\{f_5, f_7\}$	0,75	0,49	0,75		
	f_6	0,75	0,74	0,38	0,72	

Tiếp theo, ta thấy $D(f_3; f_6) = 0,38$ là cách nhỏ nhất nên ta xếp hai hàm mật độ này thành một chùm mới $\{f_3; f_6\}$. Tiến hành tính toán liên kết đủ giữa chùm $\{f_3; f_6\}$ với các hàm mật độ khác. Ta có

$$\begin{aligned}\Delta(\{f_3; f_6\}; \{f_1; f_4\}) &= \max\{D(f_3; f_1); D(f_3; f_4); D(f_6; f_1); D(f_6; f_4)\} = 0,75, \\ \Delta(\{f_3; f_6\}; \{f_5; f_7\}) &= \max\{D(f_3; f_5); D(f_3; f_7); D(f_6; f_5); D(f_6; f_7)\} = 0,75, \\ \Delta(\{f_3; f_6\}; f_2) &= \max\{D(f_5; f_3); D(f_7; f_3)\} = 0,75,\end{aligned}$$

Ta xóa dòng/cột f_3 và f_6 và thay bằng một dòng/cột mới là $\{f_3; f_6\}$, ta được ma trận khoảng cách mới

		$\{f_1, f_4\}$	f_2	$\{f_5, f_7\}$	$\{f_3, f_6\}$
$D^{(t=3)} =$	$\{f_1, f_4\}$				
	f_2	0,75			
	$\{f_5, f_7\}$	0,75	0,49		
	$\{f_3, f_6\}$	0,75	0,75	0,75	

Tiếp theo, ta thấy $D(\{f_5; f_7\}; f_2) = 0,49$ là cách nhỏ nhất nên ta xếp hàm mật độ f_2 này vào chùm $\{f_5; f_7\}$. Tiến hành tính toán liên kết đủ giữa chùm $\{f_2; f_5; f_7\}$ với các hàm mật độ khác. Ta có

$$\begin{aligned}\Delta(\{f_2, f_5, f_7\}, \{f_1, f_4\}) &= \max\{D(f_2; \{f_1; f_4\}); D(f_5; \{f_1; f_4\}); D(f_7; \{f_1; f_4\})\} = 0,75, \\ \Delta(\{f_2, f_5, f_7\}, \{f_3, f_6\}) &= \max\{D(f_2; \{f_3; f_6\}); D(f_5; \{f_3; f_6\}); D(f_7; \{f_3; f_6\})\} = 0,75.\end{aligned}$$

Ta xóa dòng/cột f_2 và $\{f_5; f_7\}$ và thay bằng một dòng/cột mới là $\{f_2; f_5; f_7\}$, ta được ma trận khoảng cách mới

		$\{f_1, f_4\}$	$\{f_2, f_5, f_7\}$	$\{f_3, f_6\}$
$D^{(t=4)} =$	$\{f_1, f_4\}$			
	$\{f_2, f_5, f_7\}$	0,75		
	$\{f_3, f_6\}$	0,75	0,75	

Cuối cùng, ta chọn xếp chòm $\{f_2, f_5, f_7\}$ vào chòm $\{f_3, f_6\}$ dựa vào khoảng cách chính xác nhỏ nhất (4 chữ số thập phân). Vậy ta có chòm $\{f_2; f_5; f_3; f_6\}$. Ta xếp chòm còn lại vào chòm mới này, thuật toán kết thúc.

```
In [4]: import sys
import os

project_root = os.path.abspath("..")
if project_root not in sys.path:
    sys.path.insert(0, project_root)
```


```
In [5]: import numpy as np
from data.data_loader import generateGauss
from utils.integral import grid
from Models.clustering import HCF
```

```
In [ ]: bandwidth = 0.01
grid_x = grid(bandwidth, start=-5, end=15)
mu = np.array([0.3, 4.0, 9.1, 1.0, 5.5, 8.0, 4.8])
sig = np.array([1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0])
F_data = generateGauss(mu, sig, grid_x)
```

```
In [7]: cluster=HCF.Model(
    grid_x=grid_x,
    max_depth=7,
    distance_metric='L1',
    linkage='complete',
    bandwidth=bandwidth
)
cluster.fit(F_data)
cluster.print_tree()
```

```
├─ root (7 samples): [0, 1, 2, 3, 4, 5, 6]
│   ├── root0 (2 samples): [0, 3]
│   │   ├── root00 (1 samples): [0]
│   │   └── root01 (1 samples): [3]
│   ├── root1 (5 samples): [1, 4, 6, 2, 5]
│   │   ├── root10 (3 samples): [1, 4, 6]
│   │   │   ├── root100 (1 samples): [1]
│   │   │   ├── root101 (2 samples): [4, 6]
│   │   │   │   ├── root1010 (1 samples): [4]
│   │   │   │   └── root1011 (1 samples): [6]
│   │   └── root11 (2 samples): [2, 5]
│   │       ├── root110 (1 samples): [2]
│   │       └── root111 (1 samples): [5]
```

Bài giải Ví dụ 1.6. Cho $c = 3$, $\varepsilon = 10^{-3}$, Các trọng tâm khởi tạo ngẫu nhiên bởi $\theta_1(x) \sim \mathcal{N}(0; 1)$, $\theta_2(x) \sim \mathcal{N}(2; 1)$, $\theta_3(x) \sim \mathcal{N}(5; 1)$. Ta cũng khởi tạo các phần tử trong ma trận U tuân theo phân phối Dirichlet. Ma trận khoảng cách D trong đó hàng i là θ_i , cột j là f_j , các khoảng cách được tính bởi $\mathcal{L}_2$ dựa vào trọng tâm và phân vùng như sau




Hình 3.9. Khởi tạo ngẫu nhiên của FCF

Khoảng cách $D^{(t=0)}$ với $\mathcal{L}_2 = \|\mathcal{N}(\mu; 1) - \mathcal{N}(\nu; 1)\|_2 = \left[\frac{1}{\sqrt{\pi}} \left(1 - e^{-(\mu-\nu)^2/4} \right) \right]^{1/2}$, ta có

$$\begin{aligned} D_{11} &= \left[\frac{1}{\sqrt{\pi}} \left(1 - e^{-(0,3)^2/4} \right) \right]^{1/2} = 0,11, \\ D_{21} &= \left[\frac{1}{\sqrt{\pi}} \left(1 - e^{-(1,7)^2/4} \right) \right]^{1/2} = 0,54, \\ D_{31} &= \left[\frac{1}{\sqrt{\pi}} \left(1 - e^{-(4,7)^2/4} \right) \right]^{1/2} = 0,75. \end{aligned}$$

Tóm lại, ta thu được ma trận khoảng cách D tại Hình 3.9(b). Hơn nữa, Ma trận phân vùng $U^{(1)}$ với $m = 2$ cũng được tính toán như sau. Vì không có $D_{ij} = 0$ nên dùng công thức cập nhật từ (1.4), ta có $u_{ij}^{(1)} = \left(\sum_{k=1}^3 \left(\frac{D_{ij}}{D_{kj}} \right)^2 \right)^{-1}; \forall j$. Suy ra ta thu được ma trận phân vùng U (tại Hình 3.9(a)) từ cách tính cho cột $j = 1$ như sau

$$\begin{aligned} u_{11} &= \left[1 + \left(\frac{0,112}{0,54} \right)^2 + \left(\frac{0,11}{0,75} \right)^2 \right]^{-1} = 0,94, \\ u_{21} &= \left[\left(\frac{0,54}{0,11} \right)^2 + 1 + \left(\frac{0,54}{0,75} \right)^2 \right]^{-1} = 0,04, \\ u_{31} &= \left[\left(\frac{0,75}{0,11} \right)^2 + \left(\frac{0,75}{0,54} \right)^2 + 1 \right]^{-1} = 0,02. \end{aligned}$$




Hình 3.10. Vòng lặp $t = 1$ của FCF

Gom toàn bộ cột, ta nhận được ma trận phân vùng sau vòng lặp đầu tiên là U . Với chuẩn $\mathcal{L}_2$ trên hàm, theo (1.5). Để tính toán tiêu chuẩn dừng, ta tính theo công thức


$$\left\| \mu^{(t+1)} - \mu^{(t)} \right\| = 0,96.$$

Vì chuẩn này chưa nhỏ hơn tiêu chuẩn dừng, ta tiếp tục lặp lại quá trình trên. Sau $t = 9$ vòng lặp, thuật toán FCF dừng với chuẩn là $6,12 \times 10^{-4}$.



Hình 3.11. Vòng lặp $t = 9$ của FCF

Ta có quá trình biến đổi ở mỗi vòng lặp đối với các trọng tâm ở Hình 3.12. Khác với các điểm rời rạc, trọng tâm FCM chỉ tịnh tiến trong không gian tọa độ, các trọng tâm hàm mật độ xác suất trong FCF vừa biến dạng hình dạng vừa dịch chuyển vị trí.



Hình 3.12. Thay đổi của trọng tâm chùm FCF qua các vòng lặp

Bảng 3.5. Kết quả so sánh các khoảng cách theo chỉ số ARI đối với Ví dụ 2.1

Khoảng cách	meanrank	median	mad	ci_lower	ci_upper	effect_size	magnitude	effect_size_above	magnitude above
D_H	4.0	-0.001551	0.017663	-0.019214	0.93993	0.000000	negligible	0.000000	negligible
$\mathcal{L}_2$	3.9	-0.010574	0.009523	-0.020588	0.932119	0.428897	small	0.428897	small
D_{JS}	3.8	-0.001818	0.011585	-0.013402	0.93993	0.012035	negligible	-0.556951	medium
W_2	2.1	0.881896	0.118104	0.450172	1.000000	-7.056713	large	-7.103256	large
D_{BC}	1.2	0.883307	0.003776	0.879531	1.000000	-46.730339	large	-0.011391	negligible

Bảng 3.6. Kết quả so sánh các khoảng cách theo chỉ số đối với NMI Ví dụ 2.1

Khoảng cách	meanrank	median	mad	ci_lower	ci_upper	effect_size	magnitude	effect_size_above	magnitude above
D_H	4.2	0.028672	0.002723	0.025949	0.876524	0.000000	negligible	0.000000	negligible
$\mathcal{L}_2$	3.9	0.051818	0.024099	0.027092	0.862962	-0.910378	large	-0.910378	large
D_{JS}	3.6	0.051341	0.025252	0.026089	0.876524	-0.851356	large	0.013043	negligible
W_2	2.1	0.796297	0.176127	0.363509	1.000000	-4.156832	large	-3.993718	large
D_{BC}	1.2	0.800313	0.009732	0.790582	1.000000	-72.836544	large	-0.021719	negligible

Bảng 3.7. Kết quả so sánh các khoảng cách theo chỉ số *Silhouette* đối với Ví dụ 2.1

Khoảng cách	meanrank	mean	std	ci_lower	ci_upper	effect_size	magnitude	effect_size_above	magnitude above
D_H	4.2	0.495819	0.029603	0.466216	0.659092	0.000000	negligible	0.000000	negligible
D_{JS}	4.0	0.495607	0.029312	0.466295	0.659092	0.004854	negligible	0.004854	negligible
$\mathcal{L}_2$	3.5	0.481554	0.014613	0.432698	0.659092	0.412173	small	0.409274	small
W_2	2.1	0.620630	0.022065	0.592853	0.659092	-3.224505	large	-5.012632	large
D_{BC}	1.2	0.620630	0.006647	0.611582	0.672148	-3.923972	large	0.000000	negligible

Bảng 3.8. Kết quả so sánh các khoảng cách theo chỉ số Thời gian chạy đối với Ví dụ 2.1

Khoảng cách	meanrank	mean	std	ci_lower	ci_upper	effect_size	magnitude	effect_size_above	magnitude above
D_{BC}	4.6	0.067778	0.064004	-0.064007	0.199564	0.000000	negligible	0.000000	negligible
$\mathcal{L}_2$	3.6	0.115243	0.080680	-0.050879	0.281365	-0.651793	medium	-0.651793	medium
W_2	3.6	0.090621	0.051703	-0.015836	0.197077	-0.392616	small	0.363381	small
D_H	2.2	0.367436	0.334679	-0.321673	1.056545	-1.243690	large	-1.155995	large
D_{JS}	1.0	1.241478	1.076920	-0.975915	3.458871	-1.538590	large	-1.096083	large

PHỤ LỤC C BÀN LUẬN

1. Về phương pháp trích xuất hình ảnh

Qua các Ví dụ số ta có thể thấy, việc phân đoạn hay phân loại dữ liệu hình ảnh có thể dựa trên màu sắc đặc trưng của các đối tượng. Sử dụng hàm mật độ xác suất để biểu diễn hình ảnh mang lại nhiều lợi thế đáng chú ý tính rõ ràng và trực quan qua phân tích chùm. Hơn nữa, nó có tính ổn định khi hình ảnh bị xoay. Phương pháp ước lượng hàm mật độ dựa trên màu sắc phản ánh rõ đặc tính sáng/tối toàn cục của hình ảnh.

Tuy nhiên, việc trích xuất này cần một số tiền giả định về việc màu sắc phải cố định và hạn chế sai lệch. Vì sử dụng các thang màu RGB hoặc xám làm cho bài toán phân loại phải là phân loại màu sắc mà không phải hình dạng hay kết cấu. Ví dụ, việc trích xuất các loại củ quả như ớt chuông, củ cải, táo, các loại này có nhiều màu sắc (như táo đỏ, táo xanh) nên không thể dùng trích xuất loại này. Hơn nữa, các sai lệch về độ sáng của hình ảnh cũng ảnh hưởng đến kết quả trích xuất. Phương pháp dựa trên màu sắc (hoặc khối màu) không duy trì được thông tin hình học. Tức là, ta không thể sử dụng thuật toán để đánh giá nội dung hình ảnh như nhận dạng khuôn mặt, đánh dấu các vị trí chứa các bất thường của hình ảnh X-quang.

2. Về thuật toán phân tích chùm các hàm mật độ xác suất

Phân tích chùm phân vùng dựa vào trọng tâm rất đơn giản. đặc biệt trong quá trình lặp lại việc cập nhật ma trận phân vùng và trọng tâm chùm. Thuật toán KCF và FCF có độ phức tạp thời gian tương đối thấp là $\mathcal{O}(ncdi)$ và độ phức tạp không gian là $\mathcal{O}(nc)$ hoặc $\mathcal{O}(n + cd)$. Hơn nữa, sử dụng phân tích chùm có lại tiềm năng lớn trong việc khám phá các cấu trúc ẩn và những mối quan hệ có ý nghĩa giữa các mẫu dữ liệu, từ đó hỗ trợ các phân tích chuyên sâu.

Tuy nhiên, nó cũng có một số khuyết điểm bao gồm tính không xác định của các siêu tham số, chất lượng dữ liệu đầu vào và khả năng giải thích của mô hình. Đầu tiên, họ thuật toán này không cung cấp c chùm tối ưu. Đôi khi, ta không có tri thức về số lượng c , dẫn đến khó khăn khi phân chùm các mẫu có số chiều lớn [77], và nguy cơ quá

khớp. Theo Goutte *et al.*, “*khi số lượng chùm không phản ánh trong dữ liệu, kết quả cuối cùng cơ bản là vô nghĩa*” [78]. Ngoài ra, do giả định tối ưu lỗi, thuật toán dựa trên trọng tâm thường hoạt động hiệu quả nhất với hình dạng gần cầu, và có thể gặp thách thức khi áp dụng cho dữ liệu chứa nhiễu, ngoại lệ, có chồng lấp giữa các chùm hoặc có sự chênh lệch lớn về kích thước và mật độ. Cuối cùng, hàm mật độ trọng tâm chùm ban đầu cũng ảnh hưởng đến kết quả tối ưu dù đã có nhiều khuyến nghị như *k-means++*. Ngược lại, phân tích chùm thứ bậc không đòi hỏi tiên nghiệm về số chùm, nhưng chi phí tính toán cao, đặc biệt với dữ liệu lớn khi cần tính toàn bộ ma trận khoảng cách.

Tóm lại, các thuật toán phân tích chùm mang lại tiềm năng lớn trong việc khám phá các cấu trúc ẩn và những mối quan hệ có ý nghĩa giữa các mẫu dữ liệu, từ đó hỗ trợ các phân tích chuyên sâu và mở ra nhiều ứng dụng tiềm năng [13, 22]. Mặc dù kết quả của các thuật toán phân tích chùm có thể chịu ảnh hưởng bởi dữ liệu đầu vào, thể loại tự nhiên và lựa chọn thuật toán, chúng vẫn đóng vai trò là công cụ mạnh mẽ giúp người dùng nhận diện và diễn giải các mẫu tốt hơn. Qua đó, *các loại tự nhiên có là những gì thuật toán phân chùm phần nào hướng đến trong điều kiện lý tưởng không* là một chủ đề nghiên cứu đầy hứa hẹn, tiếp tục được quan tâm và mở rộng trong cộng đồng khoa học thống kê [36, 79–81].

3. Về thuật toán phân tích chùm các hàm mật độ xác suất

Thuật toán IFCF cải tiến hàm mục tiêu giúp trung hòa đóng góp của các chùm lớn hơn, từ đó giảm “hiệu ứng đồng nhất”. Tuy nhiên, trong quá trình lặp, giả sử hai trọng tâm Θ được xác định, khi đó với bất kỳ hàm mật độ j thuộc chùm c_1 , các mức độ phân vùng được cập nhật theo Công thức (2.2), và điều kiện $\sum_{j=1}^c u_{ij} = 1$, có thể được viết lại thành

$$\frac{1}{1 + \left(\frac{\omega_2}{\omega_1}\right)^{\frac{1}{m-1}} \left(\frac{\mathcal{L}_2^2(\theta_1; f_j)}{\mathcal{L}_2^2(\theta_2; f_j)}\right)^{\frac{1}{m-1}}} + \frac{1}{\left(\frac{\omega_1}{\omega_2}\right)^{\frac{1}{m-1}} \left(\frac{\mathcal{L}_2^2(\theta_2; f_j)}{\mathcal{L}_2^2(\theta_1; f_j)}\right)^{\frac{1}{m-1}} + 1} = 1.$$

Khi $\omega_1 \rightarrow \infty$, ta có $\lim_{\omega_1 \rightarrow \infty} \mu_{i1} = 1$, $\lim_{\omega_1 \rightarrow \infty} \mu_{i2} = 0$. Điều này cho thấy khi tỷ lệ mất cân bằng (IR) tăng đến vô cùng, mức độ phân vùng mờ cho chùm lớn sẽ tiến về 1, và chùm nhỏ sẽ tiến về 0. Hiện tượng này được gọi là phân cực trong các mức độ phân vùng.

4. Về thuật toán phân loại các hàm mật độ xác suất

Mô hình Bayes-IFCF được thiết lập để giải quyết vấn đề phân loại trong điều kiện mất cân bằng dữ liệu nghiêm trọng. Phương pháp này đạt được sự vượt trội bằng cách

sử dụng kết quả từ thuật toán phân chùm IFCF, được chứng minh là hiệu quả hơn hẳn so với các giả định tiên nghiệm tĩnh truyền thống như phân phối đều (Bayes-U), Laplace (Bayes-L), hay Jeffreys (Bayes-J). Tuy nhiên, cách hình thành mô hình Bayes-IFCF vẫn bộc lộ một hạn chế đáng chú ý. Việc kết hợp trực tiếp mức độ phân vùng với hàm suy giảm theo khoảng cách giúp tăng khả năng nhận dạng trong thực nghiệm, song lại khiến diễn giả xác suất hậu nghiệm trở nên không rõ ràng. Khi hệ số thành viên được dùng như xác suất tiên nghiệm và được nhân tiếp với biến đổi của khoảng cách, xác suất kết quả không còn phản ánh niềm tin về lớp một cách thuần túy, mà trở thành một đại lượng mang tính kinh nghiệm. Dẫu vậy, trong các tình huống dữ liệu mất cân bằng nghiêm trọng, cách tiếp cận này vẫn cho thấy hiệu quả thực tiễn đáng kể.


5. Về các chỉ số đánh giá nhận dạng hàm mật độ xác suất

Lưu ý, các chỉ số này định lượng hình thức, nhưng không phải chất lượng và tính tin cậy. Ma trận nhầm lẫn cung cấp thông tin về số lượng dự đoán đúng/sai tại một ngưỡng, nhưng không đánh giá tính hợp lý của bằng chứng nó nhận biết. Ian van der Linde (2025) nhấn mạnh *một mô hình có thể dự đoán đúng và có bằng chứng nhưng dựa trên đặc trưng hoặc bằng chứng không liên quan sẽ dẫn đến kết quả dù đúng nhưng không thể coi là quy luật tổng quát* [82].

Do vậy, để đánh giá mô hình một cách đầy đủ và tin cậy, cần kết hợp nhiều thước đo. Quan trọng hơn, việc tối ưu hiệu năng đi kèm với chú trọng giải thích lý do dự đoán [83, 84], thông qua giải thích-AI (XAI), tương tác người dùng và tiêu chuẩn đánh giá phù hợp, sẽ nâng cao độ tin cậy và giá trị ứng dụng thực tiễn của mô hình.

CHỈ MỤC

- k -mean++, 46
- k -means++, 56, 92
- Affinity Bhattacharyya, 16
- bộ mã hóa (encoding), 19
- dữ liệu đặc trưng (symbolic data), 4, 30
- giải thích AI (XAI), 72
- giải thích-AI (eXplainable AI), 93
- hiệu suất phân cụm (Cluster Validity Indices), 43
- hàm cơ sở (basis functions), 25
- hàm hệ số $\beta(x)$ (β -functional coefficient), 25
- hàm mất mát (loss function), 25, 50
- hàm phân vị (quantile function), 4
- Hạt nhân χ^2 (Chi-squared kernel), 17
- Hạt nhân Bhattacharyya, 17
- hạt nhân chuẩn (Gaussian kernel), 17
- hạt nhân tuyến tính (Linear kernel), 17
- hằng số chặn (intercept), 25
- học không giám sát trực tuyến (Online unsupervised learning), 72
- khoảng cách Wasserstein (Wasserstein distance), 13
- không gian véc-tơ Hilbert (Hilbert vector space), 5
- liên kết (linkage), 17
- lô dữ liệu nhỏ (mini-batch), 72
- ma trận nhầm lẫn (confusion matrix), 53
- máy véc-tơ hỗ trợ (support vector machine), 24
- môi trường ảo (virtual environment), 80
- nhận dạng không được giám sát (unsupervised recognition), 1
- nhận dạng mẫu (pattern recognition), 60
- nhận dạng được giám sát (supervised recognition), 1
- phép nhân điểm (point-wise product), 5
- phương pháp hình thang (trapezoidal method), 18
- phương pháp tăng cường mẫu (resampling methods), 34
- quá khớp (overfitting), 92
- siêu tham số (hyper-parametre), 91
- thông minh nhân tạo (AI), 1
- thị giác máy tính (computer vision), 60
- tỷ lệ mất cân bằng (Imbalance Ratio), 33
- vận chuyển tối ưu (optimal transport), 13
- ánh xạ nhiều-đến-một (many-to-one map), 19
- điểm ngoại lệ (outliers), 92
- đặc trưng hình dạng (shape feature), 72
- đặc trưng kết cấu (texture feature), 72
- độ dốc (gradient method), 22



DOI:10.22144/ctujos.2025.111

CẢI TIẾN THUẬT TOÁN TỰ CẬP NHẬT CHÙM CHO CÁC HÀM MẬT ĐỘ XÁC SUẤT

Trần Nam Hưng, Châu Ngọc Thơ và Võ Văn Tài*

Khoa Khoa học Tự nhiên, Đại học Cần Thơ, Việt Nam

*Tác giả liên hệ (Corresponding author): vvtai@ctu.edu.vn

Thông tin chung (Article Information)

Nhận bài (Received): 06/01/2025

Sửa bài (Revised): 29/01/2025

Duyệt đăng (Accepted): 11/05/2025

Title: Improving the cluster self-update algorithm for probability density functions

Author: Tran Nam Hung, Chau Ngoc Tho and Vo Van Tai*

Affiliation(s): College of Natural Science, Can Tho University, Viet Nam

TÓM TẮT

Nghiên cứu được thực hiện nhằm cải tiến thuật toán tự cập nhật chùm cho các hàm mật độ xác suất (PDF) khi tham số trong thuật toán được chọn thích ứng với từng tập dữ liệu thay vì là một hằng số như các thuật toán trước đó. Thuật toán đề nghị được trình bày chi tiết các bước thực hiện và ví dụ số minh họa. Thuật toán đề nghị cũng được áp dụng cho dữ liệu ảnh khi các pixel của chúng được trích xuất và biểu diễn thành các PDF đại diện. Áp dụng cho dữ liệu số và dữ liệu ảnh, thuật toán đề nghị đã cho kết quả tốt và thuận lợi hơn một số thuật toán được công bố gần đây.

Từ khóa: Dữ liệu ảnh, hàm mật độ xác suất, phân tích chùm, tự cập nhật chùm

ABSTRACT

This research improves the cluster self-update algorithm for probability density functions (PDFs) when the parameter is selected based on each dataset rather than being constant, as in previous algorithms. The proposed algorithm is presented in detail with step-by-step procedures and numerical examples. It is also applied to image data, where the pixels are extracted and represented as representative PDFs. Applying numerical examples and images demonstrates that the proposed algorithm obtains good results and outperforms some recently published algorithms.

Keywords: Image data, probability density function, cluster analysis, cluster self-update

1. GIỚI THIỆU

Phân tích chùm là công cụ học không được giám sát, với mục tiêu khai phá và phân bố dữ liệu phi cấu trúc thành các chùm, sao cho những đối tượng trong cùng chùm có được sự tương đồng theo những đặc tính chung nào đó. Trong xử lý dữ liệu lớn, phân tích chùm được xem là nền tảng không thể thiếu nên nó đã và đang nhận được rất nhiều sự quan tâm của các nhà nghiên cứu (Hung et al., 2015; Chen et al., 2020; Le et al., 2023).

Phân tích chùm có thể thực hiện cho dữ liệu điểm, dữ liệu khoảng và dữ liệu hàm mật độ xác suất (PDF). Phân tích chùm cho dữ liệu điểm được đề nghị từ rất sớm, được phát triển rất mạnh cả lý thuyết và ứng dụng (Vo & Nguyen, 2018; Hung et al., 2021; Vo et al., 2023). Trong thực tế, chúng ta cũng lưu trữ nhiều dữ liệu khoảng như giá thấp nhất và cao nhất của cổ phiếu, vàng, đô la. Các dữ liệu thời tiết như nhiệt độ, lượng mưa, độ ẩm,... cũng thường được ghi nhận dưới dạng khoảng. Do đó, việc phân tích chùm cho dữ liệu khoảng đã được đề nghị (Le et al., 2023). Khi dữ liệu lớn, mỗi đối tượng cần

được xem là một phân phối hay dữ liệu phức tạp như hình ảnh có thể được đại diện bởi một phân phối thì phân tích chùm cho các PDF đã được đề nghị (Chen & Hung, 2015; Chen et al., 2020). So với dữ liệu số và dữ liệu khoảng, phân tích chùm cho các PDF được đánh giá phức tạp hơn, đặc biệt là ứng dụng. Sự phức tạp thể hiện trong độ đo đánh giá sự tương tự của các PDF và trong các tính toán. Việc phân tích chùm cho các PDF được nghiên cứu này quan tâm.

Có nhiều thuật toán phân tích chùm khác nhau đã được đề nghị như: thuật toán thứ bậc, không thứ bậc, cực đại hoá kỳ vọng. Khi xây dựng thuật toán phân tích chùm, việc xác định số chùm thích hợp và những phần tử cụ thể trong mỗi chùm là hai vấn đề quan trọng cần phải được giải quyết. Khi hai vấn đề này được thực hiện trong cùng một thuật toán thì nó được gọi là thuật toán tự cập nhật chùm (cluster self-update algorithm, CSU). CSU lần đầu tiên được giới thiệu bởi Chen and Shiu (2007), với ý tưởng đơn giản là các đối tượng thuộc cùng một chùm qua thuật toán hội tụ đến cùng một phần tử. Trong CSU, sự hội tụ của thuật toán cũng như kết quả phân tích chùm phụ thuộc vào một hằng số mà nó được chọn cố định cho tất cả dữ liệu. Sau năm 2015, CSU được phát triển nhanh với nhiều cải tiến mới về vấn đề bán kính lân cận. Chen and Hung (2015) đã phát triển bán kính lân cận bởi giá trị trung bình các khoảng cách. Sự thay đổi này được áp dụng vào dữ liệu hàm mờ và dạng cầu (Hung & Yang, 2015). Việc sử dụng bán kính lân cận bởi trung bình khoảng cách thích ứng được với những tập dữ liệu có nhiều đặc tính khác nhau của thực tế, tuy nhiên nhiều trường hợp vẫn không cho kết quả phân tích chùm thích hợp. Để cải tiến nhược điểm này của chính mình, Shiu and Chen (2016) đã đề nghị mô hình tĩnh và động qua mỗi lần lặp. Sự cải tiến này đã tạo ra sự thích ứng hơn với dữ liệu của thuật toán nên nhận được những kết quả tốt cho nhiều tập dữ liệu. Tuy nhiên, các tham số trong thuật toán của Chen and Chiu (2016) thực chất vẫn là hằng số. Người sử dụng khi thực hiện vẫn phải cài đặt trước ba tham số như bán kính lân cận, tham số hội tụ và hàm hạt nhân.

Về tham số hội tụ trong CSU, một số công bố quan trọng sau đã được quan tâm. Trong Chen and Shiu (2007), tham số này được sử dụng cố định là 1. Với Chen and Shiu (2016), nó được thành lập dựa trên bán kính và số vòng lặp. Một đề nghị đáng chú ý của Chen and Hung (2015) là chọn tham số hội tụ bằng phương sai của từng đôi khoảng cách. Thuật toán cải tiến này cũng được áp dụng cho dữ liệu khoảng bởi Hung et al. (2016), nghiên cứu của Le et al. (2023) cho rằng, việc chọn tham số bằng trung

bình và phương sai chưa giải quyết được vấn đề phát hiện nhiễu nên đã lần lượt thay bằng trung vị và khoảng tứ phân vị. Pham and Vo (2023) tập trung sử dụng tự cập nhật cho mờ hóa dữ liệu chuỗi thời gian với sự thay đổi tham số cho từng trường hợp cụ thể. Tất cả các nghiên cứu trên đều khẳng định rằng việc tham số trong thuật toán CSU quyết định số chùm thích hợp cũng như những phần tử trong mỗi chùm, nhưng việc xác định tối ưu cho nó vẫn là bài toán chưa có lời giải cuối cùng.

Thuật toán CSU được nghiên cứu với những đóng góp chính sau:

- (i) Tổng quát hoá việc chọn tham số trong thuật toán CSU, phù hợp với từng tập dữ liệu để tối ưu kết quả xây dựng chùm.
- (ii) Ứng dụng cho dữ liệu ảnh khi đặc trưng pixel của chúng được trích xuất để chứng minh sự hiệu quả của thuật toán đề nghị.

2. CÁC VẤN ĐỀ LIÊN QUAN

2.1. Hàm mật độ xác suất trọng tâm

Trong các thuật toán xây dựng chùm cho dữ liệu PDF, việc xác định hàm trọng tâm của các chùm là vấn đề quan trọng. Trong nghiên cứu này, hàm trọng tâm được đề nghị thông qua các định nghĩa sau.

Định nghĩa 1. (Hàm hạt nhân) Hàm ϕ được gọi là hàm hạt nhân khi và chỉ khi nó thoả các điều kiện sau:

- (i) $0 \leq \phi(u, v) \leq 1$; $\phi(u, v) = 1$ khi $u = v$,
- (ii) $\phi(u, v)$ chỉ phụ thuộc vào khoảng cách $d(u, v)$ giữa hai phần tử.
- (iii) $\phi(u, v)$ là hàm nghịch biến theo khoảng cách của $d(u, v)$.

Định nghĩa 2. (Hàm mật độ xác suất trọng tâm) Cho m chùm $\{C_1, C_2, \dots, C_m\}$ của n -PDF $\{f_1, f_2, \dots, f_n\}$, ($m \leq n$). Khi đó, hàm

$$\theta_i = \sum_{i < j} \left(\frac{\phi(f_i, f_j)}{\sum_{i < j} \phi(f_i, f_j)} \times f_j \right), i = 1, 2, \dots, m$$

được gọi là hàm trọng tâm của chùm C_i .

Ta có 2 nhận xét sau:

- Vì hàm $\phi(\cdot)$ không âm và có giá trị trong đoạn $[0; 1]$, nên hàm trọng tâm θ_i cũng không âm.

- Mặt khác ta có

$\sum_{i < j} \frac{\phi(f_i, f_j)}{\sum_{i < j} \phi(f_i, f_j)} = 1, \int f_j(x) dx = 1$ (vì $f(x)$ là một PDF).

Do đó

$$\begin{aligned}\int \theta_i(x) dx &= \int \sum_{i < j} \left(\frac{\phi(f_i, f_j)}{\sum_{i < j} \phi(f_i, f_j)} \times f_j(x) \right) dx \\ &= \left(\sum_{i < j} \frac{\phi(f_i, f_j)}{\sum_{i < j} \phi(f_i, f_j)} \right) \int f_j(x) dx = 1.\end{aligned}$$

Từ hai nhận xét trên, ta kết luận được hàm trọng tâm của một chùm cũng là một PDF.

2.2. Khoảng cách của hai hàm mật độ xác suất

Định nghĩa 3. (Khoảng cách L_1) Cho hai PDF $f_1(x)$ và $f_2(x)$, $x \in \mathbb{R}$. Khi đó, khoảng cách L_1 giữa $f_1(x)$ và $f_2(x)$ được định nghĩa là:

$$\|f_1, f_2\|_1 = \int |f_1(x) - f_2(x)| dx.$$

Từ định nghĩa trên, ta có $0 \leq \|f_1, f_2\|_1 \leq 2$. Khi hai PDF càng xa nhau thì khoảng cách này càng lớn và ngược lại. Nếu hai PDF trùng nhau thì khoảng cách bằng 1 và nếu hai PDF rời nhau hoàn toàn thì khoảng cách này bằng 2.

2.3. Trích xuất ảnh thành hàm mật độ xác suất đại diện

Để nhận dạng ảnh, trước hết chúng ta phải trích xuất đặc trưng của nó. Các đặc trưng của ảnh có thể được sử dụng là hình dạng, màu sắc và kết cấu. Trong nghiên cứu này, đặc trưng màu sắc được sử dụng thông qua các điểm pixel của ảnh.


Sau khi các đặc trưng được trích xuất, chúng ta phải biểu diễn chúng thành một đối tượng nào đó để nhận dạng. Thông thường đối tượng đại diện cho ảnh là ma trận, các điểm và các khoảng. Đối tượng đại diện cho ảnh là PDF được sử dụng với các bước thực hiện cụ thể sau:

Bước 1. Chuyển đổi hình ảnh màu bất kỳ về dạng ảnh màu xám.

Bước 2. Chuyển ma trận điểm ảnh thành một véc tơ cột bằng cách duỗi thẳng tất cả giá trị pixel.

Bước 3. Ước lượng PDF cho mỗi ảnh dựa vào kết quả của Bước 2.

Như vậy, việc nhận dạng hay phân biệt các hình ảnh với nhau dựa vào sự khác biệt màu sắc thông qua các PDF đại diện. Kết quả thể hiện ở Hình 1 minh họa các bước trích xuất đặc trưng pixel của mỗi ảnh thành một PDF.



Hình 1. Minh họa các bước trích xuất mỗi hình ảnh thành PDF

Có nhiều phương pháp tham số và phi tham số để ước lượng PDF. Trong nghiên cứu này, phương pháp hàm hạt nhân, một phương pháp phi tham số được sử dụng phổ biến hiện nay được sử dụng. Với dữ liệu là các điểm $\{x_1, x_2, \dots, x_N\}$, PDF ước lượng theo phương pháp hàm hạt nhân có dạng:

$$\hat{f}(x) = \frac{1}{N} \frac{1}{h} \sum_{i=1}^N K\left(\frac{x - x_i}{h}\right), \quad (1)$$

trong đó,

- x_i là dữ liệu thứ i với $i = 1, 2, \dots, N$,
- h là tham số trơn,
- $K(\cdot)$ là hàm hạt nhân thỏa mãn hai điều kiện

$$K(\cdot) \geq 0 \text{ và } \int K(x) dx = 1.$$

Khi có một tập dữ liệu cụ thể, kết quả ước lượng PDF từ tập dữ liệu này phụ thuộc vào việc chọn tham số trơn và hàm hạt nhân. Mặc dù có nhiều nghiên cứu quan tâm đến hai vấn đề này nhưng vẫn chưa có một phương pháp nào được xem hiệu quả cho tất cả số liệu. Trong nghiên cứu này, hàm hạt nhân được chọn có dạng chuẩn $K(x) = \frac{1}{\sqrt{2\pi}} \exp(-x^2/2)$ và tham số trơn được chọn theo đề nghị của Bowman and Azzalini (1997). Cụ thể, $h = (4/3)^{1/5} \cdot \sigma \cdot N^{1/5}$, với N và σ lần lượt là số phần tử và độ lệch chuẩn của tập dữ liệu.

2.4. Tiêu chuẩn đánh giá chất lượng của thuật toán phân tích chùm

Khi chùm được xây dựng, để đánh giá hiệu quả của các thuật toán phân tích chùm với nhau, có thể căn cứ vào nhiều tham số thống kê. Trong nghiên cứu này, tham số ARI và G-mean được sử dụng.

(i) Chỉ số ARI (*Adjusted Rand Index*) đo mức độ tương đồng giữa kết quả phân chùm của thuật toán và thực tế. Chỉ số này được cho bởi công thức sau:

$$\begin{aligned}ARI &= \frac{\sum_{ij} \binom{n_{ij}}{2} - \left[\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2} / \binom{n}{2} \right]}{\frac{1}{2} \left[\sum_i \binom{a_i}{2} + \sum_j \binom{b_j}{2} \right] - \left[\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2} / \binom{n}{2} \right]}\end{aligned}$$

trong đó,

- n_{ij} : Số phần tử chung giữa chùm thực tế thứ i và chùm của thứ j của thuật toán,
- $a_i = \sum_j n_{ij}$: Tổng số phần tử trong chùm thực tế thứ i ,
- $=$: Tổng số phần tử trong chùm thứ j của thuật toán,
- n : Tổng số phần tử trong tập dữ liệu.
- $:$: Số tổ hợp chập hai của n , biểu thị tổng số cặp mẫu.

ARI có giá trị trong đoạn $[-1; 1]$, với ARI càng lớn thì kết quả phân tích chùm càng tốt và ngược lại. Khi kết quả phân tích chùm hoàn toàn khớp với thực tế thì giá trị của ARI là 1 và ngược lại, khi kết quả phân tích chùm hoàn toàn khác thực tế thì ARI nhận giá trị là -1 . Giá trị ARI bằng 0 khi các đối tượng được phân bổ ngẫu nhiên vào các chùm.

(ii) Độ nhạy (*Sensitivity*) có công thức là $\frac{TP}{TP+FN}$ và độ chuyên (*Specificity*) có công thức là $\frac{TN}{TN+FP}$, trong đó TP là số cặp điểm được phân chùm đúng vào cùng một chùm, FN là số cặp điểm thuộc cùng chùm nhưng bị phân chùm sai, TN là số cặp điểm thuộc các chùm khác nhau và được phân chùm đúng, FP là số cặp điểm thuộc các chùm khác nhau nhưng bị phân chùm sai.

(iii) Chỉ số trung bình nhân ($G\text{-mean}$) là căn bậc hai của tích độ nhạy và độ chuyên. Cụ thể:

$$G\text{-means} = \sqrt{Sensitivity \times Specificity}.$$

Ta có $G\text{-means}$ có giá trị $[0; 1]$. $G\text{-means}$ có giá trị càng lớn thì kết quả phân tích chùm càng tốt và ngược lại. Khi $G\text{-means}$ bằng 1 thì kết quả phân tích chùm là hoàn hảo.

3. THUẬT TOÁN PHÂN TÍCH CHÙM ĐỀ NGHỊ

Cho tập n PDF: $F = \{f_1, f_2, \dots, f_n\}$ trong không gian d -chiều. Gọi ϵ là một số dương nhỏ tùy ý và $T \in N^*$ là số lần lặp tối đa của thuật toán. Thuật toán CSU cải tiến cho F gồm bốn bước sau:

Bước 1. Tại vòng lặp $t = 0$, ta gán dãy trọng tâm khởi tạo chính là các PDF ban đầu. Tức là

$$\theta^{(0)} = \{\theta_1^{(0)}, \theta_2^{(0)}, \dots, \theta_n^{(0)}\} \equiv \{f_1^{(0)}, f_2^{(0)}, \dots, f_n^{(0)}\}.$$

Bước 2. Lấy ngẫu nhiên không lặp theo phân phối đều một tập hợp con S của F có lực lượng $\lfloor n/2 \rfloor$.

Bước 3. Tại vòng lặp $t + 1$, nâng cấp trọng tâm $\theta^{(t+1)}$ theo công thức sau:

$$\theta_i^{(t+1)} = \sum_{\theta_j^{(t)} \in S} \left(\frac{\phi(\theta_i^{(t)}, \theta_j^{(t)})}{\sum_{\theta_k^{(t)} \in S} \phi(\theta_i^{(t)}, \theta_k^{(t)})} \times \theta_j^{(t)} \right) \quad (2)$$

với $i, j = 1, 2, \dots, n$, $i \leq j$ và $\phi(\theta_i^{(t)}, \theta_j^{(t)})$ là hàm hạt nhân chặt cụt được xác định bởi

$$\phi(\theta_i^{(t)}, \theta_j^{(t)}) = \begin{cases} \exp(L_1(\theta_i^{(t)}, \theta_j^{(t)})/\lambda) & (a), \\ 0 & (b) \end{cases}$$

với điều kiện của (a) là $L_1(\theta_i^{(t)}, \theta_j^{(t)}) \leq \mu_d \alpha_{ij}(t)$, và điều kiện của (b) là $L_1(\theta_i^{(t)}, \theta_j^{(t)}) > \mu_d \alpha_{ij}(t)$.

Trong hàm hạt nhân chặt cụt, ta có

- $L_1(\theta_i^{(t)}, \theta_j^{(t)})$ là khoảng cách từng đôi giữa hai PDF trọng tâm bất kỳ ở vòng lặp t ,

- $\mu_d = \frac{1}{\binom{n}{2}} \sum_{i < j} L_1(\theta_i^{(t)}, \theta_j^{(t)})$ là trung bình của từng đôi các khoảng cách L_1 ,

- $\alpha_{ij}(t+1) = \frac{\alpha_{ij}(t)}{1 + \alpha_{ij}(t) \phi(\theta_i^{(t)}, \theta_j^{(t)})}$, $\alpha_{ij}(0) = 1$ là tốc độ học,

- $\lambda = \frac{\sigma_d}{1+t}$ là tốc độ hội tụ, trong đó tham số $\sigma_d = \sqrt{\frac{1}{\binom{n}{2}} \sum_{i < j} (L_1(\theta_i^{(t)}, \theta_j^{(t)}) - \mu_d)^2}$ là phương sai của từng đôi các khoảng cách.

Bước 4. Lặp lại Bước 2 và Bước 3 t lần hoặc điều kiện sau được thỏa:

$$\|\theta^{(t)} - \theta^{(t-1)}\| = \max\{L_1(\theta_i^{(t)}, \theta_j^{(t)})\} < \epsilon, \quad (3)$$

trong đó ϵ là một số dương nhỏ tùy ý. Trong các ví dụ số và ứng dụng của nghiên cứu này, $\epsilon = 10^{-6}$ được chọn.

Khi thuật toán đề nghị kết thúc, nếu $\theta^{(t)}$ có bao nhiêu phần tử thì chúng ta chia tập dữ liệu ban đầu F thành bấy nhiêu chùm. Những phần tử cùng hội tụ về chung một PDF đại diện thì được xếp chung một chùm.

Nhận xét. Ta có một số nhận xét sau về thuật toán đề nghị.

(i) Ở Bước 2, các tập hợp con được chọn chỉ chiếm 50% dữ liệu ban đầu và không ảnh hưởng đến kết quả của thuật toán nhưng lại làm giảm đáng kể

sự lặp lại của thuật toán và tăng khả năng tìm kiếm các đối tượng mới một cách ngẫu nhiên.

(ii) Điều kiện (a) và (b) là một sự cải tiến quan trọng trong thuật toán đề nghị so với các thuật toán trước đó. Bán kính của lân cận $r(t) = \mu_d \alpha_{ij}(t)$ thay đổi qua từng vòng lặp t bởi tốc độ học $\alpha_{ij}(t)$ và co giãn độ lớn với khoảng cách trung bình μ_d thay vì cố định như các thuật toán trước đó. Các lân cận cũng có sự tự cập nhật dựa trên ý tưởng của Self-Organizing Map về lượng tử hóa véc tơ mạng nơ-ron. Khi khoảng cách L_1 của hai PDF bất kỳ lớn hơn bán kính lân cận, trọng tâm đó không được xem xét và gán trọng số là 0. Ngược lại, khi khoảng này nằm trong bán kính cho phép, ta xem xét trọng số và di chuyển trọng tâm.

(iii) Việc chọn $\lambda = \frac{\sigma_d}{1+t}$ cũng là một đóng góp của nghiên cứu này. Thay vì λ là một hằng số cố định (tĩnh), λ trong thuật toán đề nghị được xem là động. Giá trị của nó phụ thuộc vào phương sai của từng đôi khoảng cách (σ_d) và giảm liên tục từ σ_d về 0. Khi vòng lặp t càng lớn, tốc độ hội tụ λ càng nhỏ, làm cho trọng số ϕ càng cao. Từ đó, hàm ϕ giúp các trọng tâm di chuyển chậm hơn. Điều này cho phép thuật toán đề nghị có kết quả hợp lý hơn khi các phần tử có nhiều sự chồng lấp.

4. VÍ DỤ SỐ

4.1. Ví dụ 1

Gọi F là tập gồm 20 PDF có phân phối chuẩn 2 chiều với các véc tơ trung bình được sinh ngẫu nhiên theo phân phối chuẩn và hiệp phương sai theo phân phối đều. Chi tiết dữ liệu mô phỏng xem xét gồm bốn chùm, mỗi chùm gồm 5 PDF lần lượt có véc tơ trung bình như sau:

Chùm 1: $\mu_1 \sim N((-1, -1)^T; 0,05I_2)$,

Chùm 2: $\mu_2 \sim N((1, 1)^T; 0,05I_2)$,


Chùm 3: $\mu_3 \sim N((1, -1)^T; 0,05I_2)$,

Chùm 4: $\mu_4 \sim N((-1, 1)^T; 0,05I_2)$,

trong đó: I_2 là ma trận đơn vị cấp 2. Ma trận hiệp phương sai của các phân phối được xác định như sau:

$$\Sigma = \begin{pmatrix} 0,5 & u/2 \\ u/2 & 0,5 \end{pmatrix}, u \sim U[0, 1].$$

Hình 2a thể hiện đồ thị bề mặt 3D của 20 PDF và Hình 2b là đường đồng mức của chúng.



Hình 2. (a) Đồ thị bề mặt của 20 PDF có phân phối chuẩn hai chiều; và (b) Đường đồng mức của các PDF


Hình 2 cho thấy các PDF ở ví dụ này có tỷ lệ chồng lấp khá cao giữa các nhóm nên có thể là một thách thức cho bài toán phân tích chùm.

Ta lần lượt thực hiện các bước trong thuật toán đề nghị với kết quả thực hiện như sau:

Bước 1. Xây dựng PDF trọng tâm ban đầu trùng với toàn bộ PDF đã cho. Cụ thể, ta có

$$\theta^{(0)} = \{\theta_1^{(0)}, \theta_2^{(0)}, \dots, \theta_{20}^{(0)}\} \equiv \{f_1, f_2, \dots, f_{20}\}.$$

Tính từng đôi các khoảng cách $L_1(\theta_i^{(0)}, \theta_j^{(0)})$ giữa hai trọng tâm bất kỳ, ta nhận được kết quả được thể hiện ở Hình 3.



Hình 3. Ma trận khoảng cách các trọng tâm

Tính khoảng cách trung bình và phương sai của các khoảng cách, ta nhận được kết quả:


$$\mu_d = 1,50 \text{ và } \sigma_d = 0,54.$$

Bước 2. Chia $\lfloor n/2 \rfloor = 10$ PDF một cách ngẫu nhiên theo phân phối đều, tức là ta chọn các PDF trong tập S để khảo sát trọng số, trong đó,

$$S = \{1; 3; 4; 7; 8; 9; 14; 18; 19; 20\}.$$


Bước 3. Vì tại vòng lặp đầu tiên $t = 0$, $\alpha_{ij}(0) = 1$, bán kính lân cận lúc này là $\mu_d = 1,50$ nên tốc độ hội tụ λ có giá trị bằng $\sigma_d = 0,54$. Khi đó, ma trận

ϕ giữa hai trọng tâm thuộc tập hợp S được tính với kết quả thể hiện trong Hình 4.



Hình 4. Ma trận hàm hạt nhân ϕ

Bước 3. Tiến hành nâng cấp các trọng tâm theo công thức (2) ta nhận được sự biến đổi của trọng tâm $\theta_i^{(1)}, i = 1; 2; 3; 4$, trong đó đồ thị đường đồng mức của chúng được thể hiện bởi Hình 5.




Hình 5. Đường đồng mức của các trọng tâm tại vòng lặp thứ nhất ($t = 1$)

Bước 4. Tính điều kiện dừng theo công thức (3), ta có

$$\epsilon = \|\theta^{(1)} - \theta^{(0)}\| = \max|\theta_{ij}^{(1)} - \theta_{ij}^{(0)}| = 0,08.$$

Vì điều kiện dừng chưa thỏa mãn ($\epsilon > 10^{-6}$), nên ta tiếp tục lặp lại Bước 2 và Bước 3 với sự cập nhật của các trọng tâm $\theta_i^{(1)}, i = 1; 2; 3; 4$. Sau 13 vòng lặp, thuật toán hội tụ. Quá trình dừng ứng với giá trị của ϵ qua 13 vòng lặp được mô tả trong Hình 6.




Hình 6. Quá trình dừng của thuật toán đề nghị qua 13 vòng lặp

Chi tiết PDF trọng tâm của một số vòng lặp có các đường đồng mức được trình bày trong Hình 7.

Kết quả thể hiện ở Hình 7 cho thấy rằng sau mỗi vòng lặp, các trọng tâm hội tụ về bốn cụm. Tại vòng lặp thứ 13, chúng ta có bốn trọng tâm một cách rõ ràng. Do đó, ta có bốn cụm. Vì các PDF chung một nhóm ban đầu đều hội tụ về cùng một PDF trọng tâm nên chúng ta cũng có các cụm với các PDF đúng như ban đầu.

Để đánh giá hiệu quả của thuật toán đề nghị so với các thuật toán khác, các chỉ số ARI và $G-Mean$ được xem xét. Thuật toán đề nghị được so sánh với các thuật toán được công bố trong những năm gần đây như thuật toán của Chen and Hung (2015), Hung et al. (2021) và Le et al. (2023). Mỗi thuật toán được thực hiện 30 lần lặp lại và đánh giá kết quả trên trung vị của các hệ số đánh giá. Cụ thể sự khác biệt của các trung vị được kiểm tra dựa vào phương pháp Kruskal-Wallis với mức ý nghĩa 0,05. Kết quả so sánh của các thuật toán cho tập dữ liệu này được trình bày trong Bảng 1.

Bảng 1 cho thấy mức độ hiệu quả của các thuật toán phân tích cụm được xem xét. Về chỉ số ARI , các thuật toán được so sánh đều ở mức rất thấp (0,00 - 0,30), trong khi thuật toán đề nghị đã cho kết quả vượt trội, đạt mức tối ưu ($ARI = 1$). Kết quả kiểm định Kruskal-Wallis chứng minh sự khác biệt trung vị của thuật toán đề nghị với các thuật toán khác với mức ý nghĩa $p < 0,05$. Chúng ta cũng có những nhận xét tương tự về sự vượt trội của thuật toán đề nghị so với các thuật toán khác khi căn cứ vào tham số $G-means$.




Hình 7. Đường đồng mức của các PDF trọng tâm tại một số vòng lặp

Bảng 1. Kết quả phân tích cụm của các thuật toán tự cập nhật cho 20 PDF

Thuật toán	<i>ARI</i>	<i>G-means</i>
Chen and Hung (2015)	0,30	0,71
Hung et al. (2021)	0,30	0,71
Le et al. (2023)	0,85	0,91
Thuật toán đề nghị	1,00	1,00
Kruskal-Wallis	< 0,05	< 0,05

Đường đồng mức các PDF trọng tâm ở vòng lặp cuối cùng cho các thuật toán được so sánh được vẽ, ta nhận được Hình 8.




Hình 8. Trọng tâm ở vòng lặp cuối cùng của các thuật toán

Kết quả được thể hiện ở Hình 8 thể hiện sự khác biệt về mặt trọng tâm của các thuật toán được xem xét và thuật toán đề nghị. Rõ ràng, các thuật toán được so sánh hầu như có xu hướng co lại và cho số lượng chùm thấp. Cụ thể, thuật toán của Chen and Hung (2015) và Hung et al. (2021) cho kết quả hai chùm, trong khi thuật toán của Shiu and Chen (2016) và Le et al. (2023) chỉ cho một chùm duy nhất. Như vậy so với thực tế, các thuật toán được so sánh đã xác định sai số chùm, trong khi thuật toán đề nghị đã thể hiện sự hợp lý trong xác định số chùm với tập dữ liệu này. Hơn nữa, các tham số đánh giá đã cho thấy ưu điểm của nó so với các thuật toán mạnh đã được đề nghị trước đó. Sự khác biệt lớn nhất của thuật toán đề nghị với các thuật toán còn lại

là sự thích ứng trong môi trường các phân tử gần nhau, ít có sự khác nhau về mặt khoảng cách và có sự chồng lấp cao.

4.2. Ứng dụng cho dữ liệu ảnh

Phần này áp dụng thuật toán đề nghị để phân tích chùm cho hình ảnh ba loại trái cây. Các ảnh này được trích từ tập dữ liệu có tên *Natural Color Dataset for Colorization Task* và được tải miễn phí từ website: <https://www.kaggle.com/datasets/tyrionlannisterlzy/natural-color-dataset-for-colorization-task>. Cụ thể, tập dữ liệu được xem xét gồm có 45 ảnh với 15 ảnh quả chuối, 25 ảnh quả lựu và 5 ảnh quả cà tím. Hình 9 minh họa một hình ảnh cho mỗi nhóm.




Hình 9. Ba mẫu hình ảnh của tập dữ liệu ảnh được xem xét

Đầu tiên, chúng ta trích xuất đặc trưng của mỗi ảnh và biểu diễn chúng thành PDF như đã đề nghị. Các PDF nhận được đại diện cho 45 hình ảnh được trình bày ở Hình 9.


Tiếp tục thực hiện từng bước trong thuật toán đề nghị, sau 30 vòng lặp, thuật toán dừng, khi đó ta có được Hình 10.

Hình 10 cho thấy, 45 PDF ban đầu đã hội tụ về ba PDF trọng tâm. Như vậy, thuật toán đề nghị đã cho kết quả ba chùm. Đây là một kết quả phân tích chùm đúng so với thực tế.



Hình 10. Dữ liệu 45 hàm mật độ xác suất được trích xuất từ dữ liệu hình ảnh

Thuật toán đề nghị cũng được so sánh với các thuật toán khác qua các tham số *ARI* và *G-means* với 30 lần lặp lại. Kết quả so sánh của các thuật toán được trình bày trong Bảng 2.



Hình 11. Các PDF trọng tâm của vòng lặp cuối cùng

Bảng 2. Kết quả phân tích cụm của các thuật toán cho tập dữ liệu ảnh

Thuật toán	ARI	G-means
Chen & Hung (2015)	0,85	0,93
Hung et al. (2021)	-0,02	0,18
Lethikim et al. (2023)	0,82	0,89
Thuật toán đề nghị	0,90	0,95
Kruskal-Wallis	< 0,05***	< 0,05***

Bảng 2 một lần nữa cho thấy thuật toán đề nghị có hiệu quả cao và vượt trội một cách có ý nghĩa so với các thuật toán được so sánh với tập dữ liệu hình ảnh này.

TÀI LIỆU THAM KHẢO (REFERENCES)

- Bowman, A. W., & Azzalini, A. (1997). *Applied smoothing techniques for data analysis: the kernel approach with S-Plus illustrations*. <https://global.oup.com/academic/> Oxford University Press
- Chen, T. L., & Shiu, S. Y. (2007). A new clustering algorithm based on self-updating process. *Proceeding about Atistical Computing, Salt Lake City, Utah 2034*, 1-5. <https://api.semanticscholar.org/CorpusID:18819116>
- Chen, J. H., Chang, Y. C., & Hung, W. L. (2020). A self-organizing clustering algorithm for functional data. *Communications in Statistics-Simulation & Computation*, 49(5), 1237–1263. <https://doi.org/10.1080/03610918.2018.1494280>
- Chen, J. H., & Hung, W. L. (2015). An automatic clustering algorithm for probability density functions. *Journal of statistical computation & simulation*, 85(15), 3047–3063. <https://doi.org/10.1111/stan.12315>
- Chen, T. L., & Shiu, S. Y. (2016). A new clustering algorithm based on self-updating process. *In proceedings Statistical Computing, Salt Lake City, Utah, 2034*, 2038. <https://api.semanticscholar.org/CorpusID:18819116>
- Hung, W. L., Chang-Chien, S. J., & Yang, M. S. (2015). An intuitive clustering algorithm for spherical data with application to extrasolar planets. *Journal of Applied Statistics*, 42(10), 2220–2232. <https://doi.org/10.1080/02664763.2015.1023271>
- Hung, W. L., & Yang, J. H. (2015). Automatic clustering algorithm for fuzzy data. *Journal of Applied Statistics*, 42(7), 1503–1518. <https://doi.org/10.1080/02664763.2014.1001326>
- Hung, W. L., Yang, J. H., & Shen, K. F. (2016). Self-updating clustering algorithm for interval-valued data. *In 2016 IEEE International Conference on Fuzzy Systems (FUZZ-IEEE)*, 1494–1500. <https://doi.org/10.1109/FUZZ-IEEE.2016.7737867>
- Hung, W. L., Yang, J. H., Song, I. W., & Chang, Y. C. (2021). A modified self-updating clustering algorithm for application to dengue gene expression data. *Communications in Statistics-Simulation & Computation*, 50(2), 483–500. <https://doi.org/10.1080/03610912018.1563149>

5. KẾT LUẬN

Thuật toán tự cập nhật cụm cho các PDF được cải tiến trong nghiên cứu. Thuật toán đề nghị tập trung việc xác định tham số thích hợp mà các thuật toán trước đó chưa có sự giải quyết triệt để. Với các chọn tham số động, phụ thuộc vào sự biến động mức độ tương tự của các phần tử thông qua độ lệch chuẩn từng đôi khoảng cách giữa các trọng tâm, thuật toán đề nghị có thể thích ứng với nhiều tập dữ liệu khác nhau. Kết quả kiểm tra thuật toán đề nghị qua dữ liệu mô phỏng và dữ liệu ảnh đã cho thấy sự hợp lý của thuật toán. Kết quả so sánh trên các tập dữ liệu này thông qua các tham số đánh giá cũng cho thấy thuật toán đề nghị có ưu điểm vượt trội so với nhiều thuật toán mạnh được công bố trước đó. Trong thời gian tới, thuật toán đề nghị được kiểm tra trên những tập dữ liệu có tính đặc thù như chuỗi thời gian để áp dụng trong xây dựng mô hình dự báo.

LỜI CẢM TẠ

Công trình này được tài trợ bởi Chương trình học bổng đào tạo thạc sĩ, tiến sĩ trong nước của Quỹ Đổi mới sáng tạo Vingroup (VINIF), mã số VINIF.2024.ThS.56.

- Le, K. T. N., Le, H. T., & Vo, V. T. (2023). Automatic clustering algorithm for interval data based on overlap distance. *Communications in Statistics-Simulation & Computation*, 52(5), 2194–2209.
<https://doi.org/10.1080/03610918.2021.1900248>
- Pham, D. T., & Vo, T. V. (2024). Improving fuzzy clustering model for probability density functions using the two-objective genetic algorithm. *Multimedia Tools & Applications* 83, 45291–45314.
<https://doi.org/10.1007/s11042-023-17217-5>.
- Shiu, S. Y., & Chen, T. L. (2016). On the strengths of the self-updating process clustering algorithm. *Journal of Statistical Computation & Simulation*, 86(5), 1010–1031.
<https://doi.org/10.1080/00949655.2015.1049605>
- Vo, T. V., & Nguyen, T. T. (2018). Similar coefficient of cluster for discrete elements. *Sankhya B, The Indian Journal of Statistics*, 80(1), 19 - 36.
<https://doi.org/10.1007/s13571-018-0159-0>
- Vo, T. V., Nguyen, Y. H., Dang, S. (2023). An automatic fuzzy clustering algorithm for discrete elements. *Journal of the Operations Research Society of China*, 11, 309-325.
<https://doi.org/10.1007/s40305-021-00388-z>