

BỘ GIÁO DỤC VÀ ĐÀO TẠO
ĐẠI HỌC CẦN THƠ

TRẦN NAM HƯNG

NHẬN DẠNG THỐNG KÊ
CHO HÀM MẬT ĐỘ XÁC SUẤT MẤT CÂN BẰNG
VÀ ỨNG DỤNG CHO DỮ LIỆU HÌNH ẢNH

LUẬN VĂN TỐT NGHIỆP THẠC SĨ

NGÀNH: LÝ THUYẾT XÁC SUẤT VÀ THỐNG KÊ TOÁN HỌC
MÃ SỐ: 8 46 01 06

NĂM 2025

BỘ GIÁO DỤC VÀ ĐÀO TẠO
ĐẠI HỌC CẦN THƠ

TRẦN NAM HÙNG
MÃ SỐ HỌC VIÊN: M1823002

NHẬN DẠNG THỐNG KÊ
CHO HÀM MẬT ĐỘ XÁC SUẤT MẤT CÂN BẰNG
VÀ ỨNG DỤNG CHO DỮ LIỆU HÌNH ẢNH

LUẬN VĂN TỐT NGHIỆP THẠC SĨ
NGÀNH LÝ THUYẾT XÁC SUẤT VÀ THỐNG KÊ TOÁN HỌC
MÃ SỐ: 8 46 01 06

CÁN BỘ HƯỚNG DẪN
PGS. TS. VÕ VĂN TÀI

NĂM 2025

CHẤP THUẬN CỦA HỘI ĐỒNG

Luận văn này với tựa đề là “**Nhận dạng thống kê cho hàm mật độ xác suất mất cân bằng và ứng dụng cho dữ liệu hình ảnh**”, do học viên Trần Nam Hưng thực hiện theo sự hướng dẫn của PGs. TS. Võ Văn Tài. Luận văn đã báo cáo và được Hội đồng chấm luận văn thông qua ngày , tháng , năm . Luận văn đã được chỉnh sửa theo góp ý và được Hội đồng chấm luận văn xem lại.

Thư ký
(Ký tên)*

Ủy viên
(Ký tên)

Phản biện 1
(Ký tên)*

Phản biện 2
(Ký tên)

Người hướng dẫn
(Ký tên)*

Chủ tịch hội đồng
(Ký tên)

*: Ghi đầy đủ học hàm, học vị và họ tên

LỜI CẢM TẠ

Luận văn tốt nghiệp này được tài trợ bởi Chương trình học bổng đào tạo thạc sĩ, tiến sĩ trong nước của Quỹ Đổi mới sáng tạo Vingroup (VINIF), mã số VINIF.2024.ThS.56.

Cần Thơ, ngày tháng năm

Tác giả

(Ký, họ và tên)

TÓM TẮT NỘI DUNG

ABSTRACT

LỜI CAM ĐOAN

Tôi tên là Trần Nam Hưng, là học viên cao học ngành Lý thuyết Xác suất và Thống kê Toán học khóa 2023–2025. Tôi xin cam đoan luận văn này là công trình nghiên cứu khoa học thực sự của bản thân tôi được sự hướng dẫn của PGS. TS. Võ Văn Tài.

Các thông tin được sử dụng tham khảo trong đề tài luận văn được thu thập từ các nguồn đáng tin cậy, đã được kiểm chứng, được công bố rộng rãi và được tôi trích dẫn nguồn gốc rõ ràng ở phần Danh mục Tài liệu tham khảo. Các kết quả nghiên cứu được trình bày trong luận văn/đề án này là do chính tôi thực hiện một cách nghiêm túc, trung thực và không trùng lặp với các đề tài khác cùng cấp đã được công bố trước đây. Tác giả đồng ý về việc Nhà trường có quyền công bố và phổ biến để phục vụ nhu cầu đào tạo, nghiên cứu khoa học (NCKH) và phục vụ cộng đồng.

Tôi xin lấy danh dự và uy tín của bản thân để đảm bảo cho lời cam đoan này.

Cần Thơ, ngày tháng năm

Người hướng dẫn
(Ký tên)

Tác giả thực hiện
(Ký tên)

LÝ LỊCH CÁ NHÂN

1 Lý lịch sơ lược

Họ và tên	Trần Nam Hưng	Giới tính	Nam
Ngày sinh	03/4/2001	Dân tộc	Kinh
Nơi sinh	phường Cái Khế, TP. Cần Thơ	Điện thoại	(+84) 765 143 365
Trình độ	Cử nhân Toán Ứng Dụng	Năm tốt nghiệp	2023
Email	hung1823002@gstudent.ctu.edu.vn		
Địa chỉ	Số 86/11B, đường Cách Mạng Tháng Tám, phường Bình Thủy, TP. Cần Thơ		

2 Quá trình Đào tạo

Trình độ	Thời gian	Địa chỉ
THPT	2016–2019	Trường THPT Thực hành Sư phạm – Đại học Cần Thơ. Hệ đào tạo: Chính quy.
Đại học	2019–2023	Khoa Khoa học Tự nhiên – Đại học Cần Thơ. Ngành học: Toán Ứng Dụng; Hệ đào tạo: Chính quy. Trình độ ngoại ngữ: B2
Thạc sĩ	2023–2025	Khoa Khoa học Tự nhiên – Đại học Cần Thơ. Ngành học: Lý thuyết Xác suất và Thống kê Toán học; Hệ đào tạo: Chính quy. Trình độ ngoại ngữ: B2

3 Danh mục các công trình đã công bố

Bài báo khoa học hỗ trợ nội dung luận văn Thạc sĩ của tác giả

- **T. N. Hưng**, C. N. Thơ, và V. V. Tài, “*Cải tiến thuật toán tự cập nhật chòm cho các hàm mật độ xác suất*”, CTU J. Sci., vol 61, số p.h 4, tháng 8 2025,
- T. M. Lượng, N. K. Ngân, **T. N. Hưng**, N. H. Chi, N. N. Huỳnh, và V. V. Tài, “*Thuật toán xây dựng chòm ảnh dựa trên các pixel màu được trích xuất*”, CTU J. Sci., vol 60, số p.h CD Khoa học tự nhiên, tr 98-107, tháng 8 2024.

Bài báo khoa học hỗ trợ liên quan của tác giả

- **Tran-Nam, H.** & Che-Ngoc, H. . IEEE Access (2025). <https://doi.org/10.1038/s41598-024-68323-9>
- **Tran-Nam, H.**, Nguyen-Trang, T. & Che-Ngoc, H. *A new possibilistic-based clustering method for probability density functions and its application to detecting abnormal elements.* Sci Rep 14, 17871 (2024). <https://doi.org/10.1038/s41598-024-68323-9>

Cần Thơ, ngày tháng năm

Tác giả

(Ký, họ và tên)

MỤC LỤC

CHẤP THUẬN CỦA HỘI ĐỒNG	i
LỜI CẢM TẠ	ii
TÓM TẮT NỘI DUNG	iii
ABSTRACT	iv
LỜI CAM ĐOAN	v
LÝ LỊCH CÁ NHÂN	vi
DANH SÁCH BẢNG	xi
DANH SÁCH HÌNH VẼ	xii
DANH SÁCH KÝ HIỆU TOÁN HỌC	xiii
DANH SÁCH TỪ VIẾT TẮT	xiv
PHẦN MỞ ĐẦU	1
1 Lý do chọn đề tài	1
2 Mục đích nghiên cứu	2
3 Đối tượng và phạm vi nghiên cứu	2
4 Phương pháp nghiên cứu	2
5 Cấu trúc luận văn	3
PHẦN NỘI DUNG	3
1 KIẾN THỨC CHUẨN BỊ	4
1.1 Hàm mật độ xác suất	4
1.2 Một số hàm mật độ thông dụng	6
1.3 Một số hàm mật độ bổ sung	8

1.4	Ước lượng hàm mật độ xác suất	10
1.5	Độ đo đánh giá sự tương tự của các hàm mật độ xác suất	11
1.5.1	Sự tương tự của hai hàm mật độ xác suất	11
1.5.2	Sự tương tự của nhiều hơn hai hàm mật độ xác suất	16
1.6	Phương pháp số xấp xỉ tích phân	18
1.7	Phân tích chùm cho hàm mật độ xác suất	18
1.7.1	Phân tích chùm không mờ	18
1.7.2	Phân tích chùm mờ	21
1.8	Phân loại cho hàm mật độ xác suất	23
1.8.1	Hồi quy logistics	23
1.8.2	Máy véc-tơ hỗ trợ	25
1.8.3	Phương pháp naive Bayes	26
	Tổng kết chương 1	27

2 NHẬN DẠNG THỐNG KÊ CHO HÀM MẬT ĐỘ XÁC SUẤT VỚI DỮ LIỆU MẮT CÂN BẰNG 28

2.1	Giới thiệu	28
2.1.1	Phương pháp phân tích chùm hàm mật độ xác suất	28
2.1.2	Phương pháp phân loại hàm mật độ xác suất	29
2.2	Giới thiệu bài toán phân tích chùm cho dữ liệu mắt cân bằng	30
2.2.1	Thuật toán	30
2.2.2	Sự hội tụ của thuật toán	30
2.2.3	Tham số đánh giá chất lượng	30
2.2.4	Ví dụ minh họa	33
2.3	Giới thiệu bài toán phân loại cho dữ liệu mắt cân bằng	33
2.3.1	Thuật toán	33
2.3.2	Sự hội tụ của thuật toán	33
2.3.3	Tham số đánh giá chất lượng	33
2.3.4	Ví dụ minh họa	34
	Tổng kết chương 2	34

3 ỨNG DỤNG CHO DỮ LIỆU HÌNH ẢNH 35

3.1	Trích xuất đặc trưng của hình ảnh thành hàm mật độ xác suất	35
3.1.1	Vấn đề trích xuất đặc trưng của hình ảnh	35
3.1.2	Ước lượng hàm mật độ xác suất đại diện cho hình ảnh	35
3.2	Ứng dụng của bài toán phân tích chùm	35
3.2.1	Dữ liệu	35
3.2.2	Phương pháp thực hiện	35

3.2.3	Kết quả thực hiện	35
3.3	Ứng dụng của bài toán phân loại	35
3.3.1	Dữ liệu	35
3.3.2	Phương pháp thực hiện	35
3.3.3	Kết quả thực hiện	35
3.4	Bàn luận	35
3.4.1	Về thuật toán phân tích chùm các hàm mật độ xác suất	35
	Tổng kết chương 3	36
	PHẦN KẾT LUẬN	37
	TÀI LIỆU THAM KHẢO	37
	PHỤ LỤC	43
	CHỈ MỤC	52

DANH SÁCH BẢNG

1.1	Một số hàm hạt nhân phổ biến dùng trong ước lượng mật độ hạt nhân	11
1.2	Bảng tổng kết các loại khoảng cách giữa hai hàm mật độ xác suất	12
1.3	Các kết quả khoảng cách giữa hai hàm mật độ đều	15
1.4	Bảng tổng kết các loại liên kết Δ giữa hai chùm hàm mật độ xác suất	17
1.5	Tổng kết các tương tự giữa các chùm hàm mật độ xác suất	17
1.6	So sánh độ phức tạp của ba thuật toán phân chùm	23
2.1	Tổng quan lịch sử nghiên cứu phân tích chùm cho hàm mật độ xác suất	29
2.2	Mô tả các chỉ số đánh giá phân loại	34
3.1	Một số hàm cơ sở $\psi_m(x)$ phổ biến trong hồi quy logistic cho dữ liệu hàm mật độ	51

DANH SÁCH HÌNH VẼ

1.1	Minh họa hai hàm mật độ xác suất đại diện một chùm hàm mật độ $\mathcal{F}$	10
1.2	So sánh các hàm hạt nhân trong ước lượng mật độ xác suất	11
1.3	Dãy khoảng cách $D(f_1, f_2)$ giữa hai hàm mật độ Gauss $\mathcal{N}(0, 1)$ và $\mathcal{N}(\mu, 1)$	13
1.4	Các trường hợp trong khoảng cách giữa hai hàm mật độ đều $f_1(x)$ và $f_2(x)$	15
1.5	Kết quả phân cấp thứ bậc tích tụ đối với Ví dụ 1.4	21
1.6	Biểu đồ phân vùng mờ theo khoảng cách D_{1j} với các hệ số m khác nhau.	22
1.7	Hàm $\hat{\beta}(x)$ được ước lượng qua 10 hàm cơ sở Gauss.	25
2.1	Một số chỉ số đánh giá và số chùm tối ưu được đề xuất từ phương pháp khuỷu tay	32

DANH SÁCH KÝ HIỆU TOÁN HỌC¹

Ký hiệu	Mô tả
X, Y, Z, S	Biến ngẫu nhiên
Y	Tập nhãn của dữ liệu (đối với bài toán phân loại)
$D, U, U^\top$	Ma trận, ma trận chuyển vị
$\mathcal{F}, \mathcal{G}, \mathcal{H}, \mathcal{P}, \mathcal{Q}$	Tập hợp
$\#\mathcal{F}$	Lực lượng của tập hợp $\mathcal{F}$
$\mathbb{R}, \mathbb{R}_{>0}, \mathbb{N}, \mathbb{N}_{>0}$	Số thực, số thực dương, số tự nhiên, số tự nhiên dương
$\mathbb{E}(\cdot)$	Kỳ vọng của biến ngẫu nhiên
$\text{Var}(\cdot)$	Phương sai của biến ngẫu nhiên
$\text{Trace}(\cdot)$	Vết của ma trận
$ \cdot $	Định thức của ma trận
$f \oplus g$	Toán tử tích chập giữa hai hàm mật độ f và g
$\mathbf{1}_{\{\cdot\}}$	Hàm logic (bằng 1 nếu thỏa điều kiện $\{\cdot\}$, ngược lại là 0)
$\text{sign}(\cdot)$	Hàm xét dấu (bằng $+1$ nếu thỏa điều kiện $(\cdot)$, ngược lại là -1)
$\ell(\cdot)$	Hàm mất mát
$\mathcal{L}(\cdot)$	Hàm L'Arange
$\langle \cdot, \cdot \rangle$	Tích trong của hai ma trận

¹Các ký hiệu đã được thống nhất, các ký hiệu khác sẽ được làm rõ trong luận văn

DANH SÁCH TỪ VIẾT TẮT

Từ viết tắt	Nghĩa Tiếng Việt	Nghĩa Tiếng Anh
AI	Trí thông minh nhân tạo	Artificial Intelligence
CVI	Chỉ số đánh giá phân tích cụm	Clustering Validation Indices
KCF	Thuật toán k -means cho hàm mật độ xác suất	k -means for probability density Function
FCF	Thuật toán phân cụm mờ cho hàm mật độ xác suất	Fuzzy c -means for probability density Function
HCF	Thuật toán phân cấp thứ bậc cho hàm mật độ xác suất	Hierarchical Clustering for probability density Function
SUP	Thuật toán phân cụm tự cập nhật	Self-Updating Processing
XAI	Trí tuệ nhân tạo giải thích được	eXplainable Artificial Intelligence

PHẦN MỞ ĐẦU

1 Lý do chọn đề tài

Nghiên cứu – phát triển các nguyên tắc và ứng dụng hệ thống thông minh nhân tạo (AI) là yếu tố then chốt nhằm thúc đẩy tăng trưởng kinh tế bền vững ở các quốc gia [1, 2]. Với khả năng ứng dụng đa ngành – đa chiều, AI không chỉ cải thiện năng suất lao động mà còn mở ra nhiều cơ hội việc làm, góp phần xây dựng nền kinh tế số [3], nâng cao tiện ích, thu nhập và chất lượng cuộc sống [4]. Trong sự phát triển của AI, nhận dạng thống kê được xem là một trong những kiến thức nền tảng nhằm phát triển các AI dự đoán hiện nay.

Nhận dạng thống kê gồm có hai bài toán chính: nhận dạng được giám sát và không được giám sát [5, 6]. Nhận dạng không được giám sát là việc chia dữ liệu thành các cụm sao cho các phần tử trong cùng một cụm có sự tương tự nhiều hơn so với các phần tử bên ngoài cụm đó [7, 8]. Do đó, nó còn được gọi là bài toán phân tích cụm. Phân tích cụm là cơ sở của việc lưu trữ, trích xuất và xử lý dữ liệu lớn nên được rất nhiều nhà thống kê và công nghệ thông tin quan tâm. Nhận dạng được giám sát là việc xếp một phần tử vào một nhóm trong các nhóm đã biết một cách thích hợp [5, 9]. Do đó, nó còn được gọi là bài toán phân loại. Phân loại đã và đang được áp dụng trong nhiều lĩnh vực khác nhau. Chẳng hạn, trong y tế hoạt động chẩn đoán bệnh của các bác sĩ xem một người có bệnh hay không có bệnh B, loại nào trong bệnh B thực chất là thực hiện bài toán phân loại. Trong lĩnh vực xã hội và an ninh, việc nhận dạng khuôn mặt, chữ ký, dấu vân tay,... cũng chính là thực hiện bài toán phân loại.

Dữ liệu cho nhận dạng thống kê có thể là dữ liệu rời rạc, dữ liệu khoảng và hàm mật độ xác suất. Nhận dạng thống kê cho dữ liệu rời rạc đã được xem xét đầu tiên đã và đang được nghiên cứu rất nhiều [7, 10, 11]. Trong thực tế, chúng ta cũng lưu trữ nhiều dữ liệu khoảng như nhiệt độ, lượng mưa, giá chứng khoán nên nhận dạng cho kiểu dữ liệu này đã được đề xuất và phát triển. Khi dữ liệu lớn và phức tạp như hình ảnh, đối tượng hình ảnh có thể được xem là một hàm mật độ xác suất trong một số phương pháp biểu diễn [12], do đó nhận dạng thống kê cho hàm mật độ xác suất được đề xuất.

Xét về số lượng phần tử trong các nhóm, dữ liệu có thể được gọi là mất cân bằng và không mất cân bằng. Khi số lượng phần tử của các nhóm không có sự chênh lệch nhiều thì nó được gọi là không mất cân bằng. Trong nhận dạng dữ liệu của thực tế, nhiều trường hợp

chúng ta gặp phải dữ liệu mất cân bằng. Đó là kiểu dữ liệu mà một nhóm hoặc một số ít nhóm có số lượng phần tử quá nhỏ so với các nhóm còn lại [13]. Khi một mô hình nhận dạng phải đối mặt với chênh lệch lớn về số lượng mẫu, nó dễ dàng bị thiên lệch về lớp đa số, dẫn đến hiệu quả thấp trong việc nhận dạng các mẫu của lớp thiểu số [14]. Chẳng hạn, trong tầm soát ung thư, ca bị bệnh có thể ít hơn 1000 lần so với trường hợp không bị bệnh [15]. Khi đó các thuật toán nhận dạng truyền thống sẽ không phát huy hiệu quả vì nó có xu hướng thiên vị lớp đa số mà bỏ qua lớp thiểu số. Trong trường hợp này, độ chính xác của các lớp thiểu số là quan trọng hơn [13], bởi vì việc tầm soát sai người mắc ung thư là khỏe mạnh gây ra tổn thất tính mạng lớn hơn nhiều so với sai lầm ngược lại.

Theo sự hiểu biết của chúng tôi, nhận dạng thông kê cho dữ liệu mất cân bằng với các phần tử rời rạc đã được quan tâm trong những năm gần đây. Tuy nhiên với dữ liệu hàm mật độ xác suất hầu như chưa được xem xét. Từ sự phân tích trên, đề tài **“Nhận dạng thông kê cho hàm mật độ xác suất mất cân bằng và ứng dụng cho dữ liệu hình ảnh”** được chọn làm luận văn tốt nghiệp.

2 Mục đích nghiên cứu

- Xây dựng thuật toán phân loại và phân tích chùm cho hàm mật độ xác suất với dữ liệu mất cân bằng;
- Áp dụng hai thuật toán trên cho dữ liệu hình ảnh khi các đặc trưng của nó được trích xuất và đại diện bởi hàm mật độ xác suất để nhận dạng.

3 Đối tượng và phạm vi nghiên cứu

3.1 Đối tượng nghiên cứu

- Thuật toán phân loại và phân tích chùm với dữ liệu mất cân bằng;
- Dữ liệu hình ảnh được trích xuất thành các đối tượng đại diện.

3.2 Phạm vi nghiên cứu

- Các thuật toán phân tích chùm và phân loại cho hàm mật độ xác suất;
- Dữ liệu hình ảnh được trích xuất thành hàm mật độ xác suất đại diện;
- Vấn đề tính toán của các phương pháp phân loại, phân tích chùm.

4 Phương pháp nghiên cứu

- *Nghiên cứu lý thuyết*: Phân tích – tổng kết, phân loại – hệ thống hóa kiến thức về lĩnh vực

nhận dạng thống kê; So sánh đánh giá ưu điểm và nhược điểm của các thuật toán.

- *Thực nghiệm khoa học*: Thực hiện các ví dụ số minh họa lý thuyết trong môi trường mô phỏng nhằm đánh giá các mô hình nhận dạng qua nhiều tiêu chí cụ thể, từ đó xử lý so sánh kết quả bằng các phân tích thống kê.

5 Cấu trúc luận văn

Luận văn bao gồm phần mở đầu, phần nội dung và phần kết luận, trong đó phần nội dung gồm ba chương:

Chương 1. *Kiến thức chuẩn bị*

Chương 2. *Nhận dạng thống kê cho hàm mật độ xác suất với dữ liệu mất cân bằng*

Chương 3. *Ứng dụng cho dữ liệu hình ảnh*

CHƯƠNG 1

KIẾN THỨC CHUẨN BỊ

1.1 Hàm mật độ xác suất

Hàm mật độ xác suất là khách thể nghiên cứu của một số nhà thống kê hiện đại [16, 51, 52]. Nó là một phần của dữ liệu đặc trưng bao gồm hữu hạn các xác suất, khoảng và hàm mật độ [52]. Ở đây, luận văn chỉ hệ thống hóa những kiến thức có liên quan.

Định nghĩa 1.1 (Biến ngẫu nhiên). Một biến ngẫu nhiên X trong không gian xác suất $(\Omega, \mathcal{E}, \mathbb{P})$ là một hàm Borel đo được từ Ω đến $\mathbb{R}$, tức là $X : (\Omega, \mathcal{E}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$.

Tương tự, ta mở rộng biến ngẫu nhiên d -chiều cho véc-tơ $\mathbf{X} = (X_1, X_2, \dots, X_d)$ trong $\mathbb{R}^d$, với mỗi thành phần $X_i, (i = 1, 2, \dots, d)$ là biến ngẫu nhiên trên $(\Omega, \mathcal{E}, \mathbb{P})$, nhận giá trị trong $\mathbb{R}$.

Định nghĩa 1.2 (Biến ngẫu nhiên d -chiều). Biến ngẫu nhiên d -chiều là một hàm Borel đo được từ không gian xác suất đến không gian Euclid $\mathbb{R}^d$, tức là $\mathbf{X} : (\Omega, \mathcal{E}) \rightarrow (\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$.

Định nghĩa 1.3 (Hàm phân phối). Hàm phân phối của biến ngẫu nhiên X là hàm $P := P_X : \mathbb{R} \rightarrow [0; 1]$ được định nghĩa bởi $P(x) = \mathbb{P}\{\omega : X(\omega) \leq x\}, \forall x \in \mathbb{R}$.

Tính chất 1.1. Phân phối P thỏa các tính chất sau.

1. P không giảm,
2. $\lim_{x \rightarrow \infty} P(x) = 1$ và $\lim_{x \rightarrow -\infty} P(x) = 0$,
3. P liên tục phải, tức là $\lim_{x \downarrow y} P(y) = P(x)$,
4. Nếu $P(x_-) = \lim_{y \uparrow x} P(y)$ thì $P(x_-) = \mathbb{P}(X < x)$,
5. $\mathbb{P}(X = x) = P(x) - P(x_-)$.

Định nghĩa 1.4 (Hàm phân vị). Cho phân phối P trên $\mathbb{R}$, hàm phân vị $F^{-1} : [0; 1] \rightarrow \mathbb{R}$ được định nghĩa bởi $F^{-1}(s) = \inf\{x \in \mathbb{R} : P(x) \geq s\}, s \in [0; 1]$.

Tính chất 1.2. Hàm phân vị F^{-1} thỏa các tính chất sau.

1. F^{-1} không giảm: nếu $s_1 \leq s_2$ thì $F^{-1}(s_1) \leq F^{-1}(s_2)$,
2. Nếu P liên tục, $P(F^{-1}(s)) = s$ và $F^{-1}(P(x)) = x$,

3. Kỳ vọng và phương sai được biểu diễn qua F^{-1} dưới công thức $\mathbb{E}(X) = \int_0^1 F^{-1}(s) ds$ và $\text{Var}(X) = \mathbb{E}(X^2) - \mathbb{E}^2(X)$,

4. Nếu P đối xứng quanh μ , ta có quan hệ đối xứng $F^{-1}(1-s) = 2\mu - F^{-1}(s)$.

Định nghĩa 1.5 (Hàm mật độ xác suất). Họ các hàm phân phối $P: \mathbb{R}^d \rightarrow [0, \infty]$ là liên tục tuyệt đối trong $(\Omega, \mathcal{B})$ -đo được với μ hoặc là độ đo Lebesgue hoặc độ đo đếm. Khi này, hàm mật độ trong không gian thực được định nghĩa là

$$\forall x, f(x) = \frac{dP}{d\mu}(x) = \begin{cases} f(s), & \text{nếu } \mu \text{ là độ đo Lebesgue,} \\ \mathbb{P}(X = x) = p(x), & \text{nếu } \mu \text{ là độ đo đếm.} \end{cases}$$

Tính chất 1.3. Hàm mật độ thỏa mãn các tính chất sau.

1. Hàm mật độ xác suất liên tục $f(x)$ là hàm không âm, $f(x) \geq 0, \forall x \in \Omega$,
2. Tích phân $f(x)$ trên toàn miền Ω bằng 1,
3. Xác suất trên tập con Borel $A \subseteq \Omega$ được tính bằng tích phân $\mathbb{P}(X \in A) = \int_A f(x) dx$,
4. Công thức xác suất trong tập Borel thực

$$\mathbb{P}(a < x < b) = \mathbb{P}(a < x \leq b) = \mathbb{P}(a \leq x < b) = \mathbb{P}(a \leq x \leq b) = \int_a^b f(x) dx.$$

Nhận xét. Các hàm phân phối P , và phân vị F^{-1} đều không bảo toàn trong không gian véc-tơ Hilbert. Các giá trị của mật độ xác suất liên tục thì có thể tùy ý, nhưng phải thỏa mãn Tính chất 1.3. Một xác suất tại điểm $x = x_0$ không được khảo sát trong hàm mật độ liên tục tuyệt đối mà ở một tập Borel thực như Tính chất 1.3.(3). Tức là xác suất tại điểm bất kì luôn bằng 0 đối với biến ngẫu nhiên X liên tục.

Ta có thể tổng quát hóa tập các hàm mật độ thành không gian con lồi của $\mathcal{L}^1(\Omega)$ và đóng trong tô-pô chuẩn $\mathcal{F}(\Omega) = \{f: \Omega \rightarrow \mathbb{R}^+ | \int_{\Omega} f(x) d\mu(x) = 1\}$.

Định nghĩa 1.6. Hai tham số kỳ vọng và phương sai của biến ngẫu nhiên X được định nghĩa bởi $\mathbb{E}(X) = \int_{\Omega} xf(x) dx < \infty$, và $\text{Var}(X) = \int_{\Omega} (x - \mathbb{E}(X))^2 f(x) dx$.

Định nghĩa 1.7. Với các đối tượng hàm mật độ, toán tử tổng và tích có hướng được thay thế bởi phép nhân điểm và lũy thừa. Tức là, $(f \oplus g)(x) = f(x)g(x)$ và $(\alpha \odot f)(x) = f^\alpha(x)$, với $\alpha \in \mathbb{R}$.

Định nghĩa 1.8 (Dữ liệu hàm mật độ 1-chiều). Dữ liệu hàm mật độ là một bộ đối tượng không chắc chắn o có dạng $(o_1, o_2, \dots, o_n)$ [17]. Mỗi đối tượng o_j chứa một cặp (I_j, f_j) với mỗi $1 \leq j \leq n$, trong đó $I_j = [l_j, u_j]$ là khoảng xác định của o_j và $f: \mathbb{R} \rightarrow \mathbb{R}^+$ là hàm mật độ xác suất xếp các giá trị xác suất vào mỗi $x \in I_j$ sao cho

$$\int_{x \in I_j} f_j(x) dx = 1, \text{ và } \int_{x \in \mathbb{R} \setminus I_j} f_j(x) dx = 0.$$

Định nghĩa 1.9 (Dữ liệu hàm mật độ d -chiều). Dữ liệu hàm mật độ d -chiều là một bộ đối tượng không chắc chắn $\mathbf{o}$ có dạng $(\mathbf{o}_1, \mathbf{o}_2, \dots, \mathbf{o}_n)$ [17]. Mỗi đối tượng $\mathbf{o}_j$ chứa một cặp $(\mathbf{R}_j, f_j)$ với mỗi $1 \leq j \leq n$, trong đó $\mathbf{R}_j = [l_1, u_1] \times \dots \times [l_d, u_d] \subseteq \mathbb{R}^d$ là vùng xác định d -chiều của $\mathbf{o}_j$ và $f : \mathbb{R}^d \rightarrow \mathbb{R}^{d+}$ là hàm mật độ xác suất xếp các giá trị xác suất vào mỗi $\mathbf{x} \in \mathbf{R}_j$ sao cho

$$\int_{\mathbf{x} \in \mathbf{R}_j} f_j(\mathbf{x}) d\mathbf{x} = 1, \text{ và } \int_{\mathbf{x} \in \mathbb{R} \setminus \mathbf{R}_j} f_j(\mathbf{x}) d\mathbf{x} = 0.$$

Để minh họa và mô phỏng, luận văn này làm việc trên dữ liệu các hàm mật độ định nghĩa trên toàn không gian mẫu $I = \mathbb{R}$ hoặc $\mathbf{R} = \mathbb{R}^d$, và ký hiệu xuyên suốt là $\mathcal{F} = \{f_1(x), \dots, f_n(x)\}$. Để đơn giản hóa, luận văn này giả định các đối tượng hàm mật độ là độc lập.

1.2 Một số hàm mật độ thông dụng

Hàm mật độ xác suất cụ thể được nghiên cứu bởi các nhà khoa học thực nghiệm và thỏa mãn các Tính chất 1.3.

Định nghĩa 1.10 (Hàm mật độ Gauss). Biến ngẫu nhiên liên tục X tuân theo mật độ Gauss (chuẩn) với hai tham số μ và σ^2 (trong đó $\mu \in \mathbb{R}$ và $\sigma^2 \in \mathbb{R}_{>0}$) nếu nó có hàm mật độ xác suất là

$$\mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), x \in \mathbb{R}.$$

Định lý 1.1 (Kỳ vọng và phương sai). Kỳ vọng và phương sai của biến ngẫu nhiên X có hàm mật độ xác suất Gauss là $\mathbb{E}(X) = \mu$, $\text{Var}(X) = \sigma^2$.

Hàm mật độ Gauss có dáng điệu hình cong đối xứng và miền xác định khắp không gian. Đặc trưng kỳ vọng μ chính là giá trị cực đại và xác định vị trí của hàm mật độ, đặc trưng phương sai Σ thể hiện độ phân tán hay độ cao của hàm, phương sai càng nhỏ thì hàm mật độ càng cao và hẹp. Thông thường, dữ liệu rời rạc thường được biến đổi thành dữ liệu hàm mật độ qua biểu diễn của hàm mật độ Gauss (khi ước lượng tham số) hoặc nhân-Gauss (khi ước lượng phi tham số). Hơn hết, định lý giới hạn trung tâm chứng minh tổng các biến ngẫu nhiên độc lập có phân phối xấp xỉ Gauss.

Bổ đề 1.1 (Tổng hai hàm mật độ Gauss). Cho hai biến ngẫu nhiên độc lập $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2)$ và $X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$. Khi đó tổng $S = X_1 + X_2$ cũng là biến ngẫu nhiên có hàm mật độ Gauss, tức là $S \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$.

Bổ đề 1.2 (Tích phân của hai hàm mật độ Gauss). Cho hai hàm mật độ Gauss $\mathcal{N}(\mu_1, \sigma_1^2)$ và $\mathcal{N}(\mu_2, \sigma_2^2)$ với kỳ vọng $\mu_1, \mu_2 \in \mathbb{R}$, và phương sai $\sigma_1^2, \sigma_2^2 > 0$. Khi đó, tích phân giữa hai hàm mật độ được xác định bởi

$$\int_{\Omega} \mathcal{N}(\mu_1, \sigma_1^2) \cdot \mathcal{N}(\mu_2, \sigma_2^2) dx = \frac{1}{\sqrt{2\pi(\sigma_1^2 + \sigma_2^2)}} \exp\left(-\frac{(\mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right).$$

Chứng minh. Xét tích phân

$$\begin{aligned}
I &= \int_{-\infty}^{\infty} \mathcal{N}(x; \mu_1, \sigma_1^2) \cdot \mathcal{N}(x; \mu_2, \sigma_2^2) dx = \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{(x-\mu_1)^2}{2\sigma_1^2} - \frac{(x-\mu_2)^2}{2\sigma_2^2}\right) dx \\
&= \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{1}{2}\underbrace{\left(\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}\right)}_{:=1/\sigma^2} x^2 + \underbrace{\left(\frac{\mu_1}{\sigma_1^2} + \frac{\mu_2}{\sigma_2^2}\right)}_{:=\mu} x - \frac{\mu_1^2}{2\sigma_1^2} - \frac{\mu_2^2}{2\sigma_2^2}\right) dx \\
&= \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{1}{2}\sigma^2(x-\mu)^2 - \frac{(\mu_1-\mu_2)^2}{2(\sigma_1^2+\sigma_2^2)}\right) dx \\
&= \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{(\mu_1-\mu_2)^2}{2(\sigma_1^2+\sigma_2^2)}\right) \underbrace{\int_{-\infty}^{\infty} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right) dx}_{=\sqrt{2\pi}\sigma^2} \\
&= \frac{\sqrt{2\pi}\sigma^2}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{(\mu_1-\mu_2)^2}{2(\sigma_1^2+\sigma_2^2)}\right).
\end{aligned}$$

Từ đây, ta suy ra được điều phải chứng minh. ■

Định nghĩa 1.11 (Hàm mật độ Gauss d -chiều). Biến ngẫu nhiên liên tục d -chiều X tuân theo mật độ Gauss (chuẩn) với hai tham số μ và Σ (trong đó $\mu \in \mathbb{R}^d$ và Σ thuộc đa tập của ma trận đối xứng xác định dương) nếu nó có hàm mật độ xác suất là

$$\mathcal{N}(x; \mu, \Sigma) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x-\mu)^\top \Sigma^{-1}(x-\mu)\right), x \in \mathbb{R}^d,$$

trong đó, $|\Sigma|$ là định thức của ma trận hiệp phương sai.

Định lý 1.2 (Kỳ vọng và hiệp phương sai). Kỳ vọng và phương sai của biến ngẫu nhiên X có hàm mật độ xác suất Gauss là $\mathbb{E}(X) = \mu$, $\text{Cov}(X) = \Sigma$.

Bổ đề 1.3 (Tổng hai hàm mật độ Gauss d -chiều). Cho hai biến ngẫu nhiên độc lập $X_1 \sim \mathcal{N}(\mu_1, \Sigma_1)$ và $X_2 \sim \mathcal{N}(\mu_2, \Sigma_2)$. Khi đó tổng $S = X_1 + X_2$ cũng là biến ngẫu nhiên có hàm mật độ Gauss, tức là $S \sim \mathcal{N}(\mu_1 + \mu_2, \Sigma_1 + \Sigma_2)$.

Bổ đề 1.4 (Tích phân của hai hàm mật độ Gauss d -chiều). Cho hai hàm mật độ Gauss d -chiều $\mathcal{N}(\mu_1, \Sigma_1)$ và $\mathcal{N}(\mu_2, \Sigma_2)$ với véc-tơ kỳ vọng $\mu_1, \mu_2 \in \mathbb{R}^d$, và ma trận hiệp phương sai Σ_1, Σ_2 xác định dương. Khi đó, tích phân giữa hai hàm mật độ được xác định bởi

$$\begin{aligned}
\int_{\Omega} \mathcal{N}(\mu_1, \Sigma_1) \cdot \mathcal{N}(\mu_2, \Sigma_2) dx &= \frac{1}{(2\pi)^{d/2} |\Sigma_1 + \Sigma_2|^{1/2}} \\
&\times \exp\left(-\frac{1}{2}(\mu_1 - \mu_2)^\top (\Sigma_1 + \Sigma_2)^{-1} (\mu_1 - \mu_2)\right).
\end{aligned}$$

Nhận xét. Hàm mật độ $h(x)$ của tổng $S = X + Y$ hai biến ngẫu nhiên độc lập là kết quả của tích chập giữa các hàm mật độ tương ứng, tức là $h(x) = f_X(x) \oplus g_Y(x)$.

Ngoài ra, các phát triển bất đối xứng của Gauss điển hình là hàm Gauss-lệch [18]. với hàm mật độ của nó được định nghĩa như sau.

Định nghĩa 1.12 (Hàm mật độ Gauss-lệch). Biến ngẫu nhiên liên tục X tuân theo mật độ Gauss-lệch (chuẩn-lệch) [18] với ba tham số μ , σ^2 và α (trong đó $\mu, \alpha \in \mathbb{R}$ và $\sigma^2 \in \mathbb{R}_{>0}$) nếu nó có hàm mật độ xác suất là

$$\mathcal{S}\mathcal{N}(x; \mu, \sigma^2, \alpha) = \frac{2}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \int_{-\infty}^{\alpha(x-\mu)/\sigma} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{t^2}{2}\right) dt, x \in \mathbb{R}.$$

Hàm mật độ Gauss-lệch nhận thêm một tham số thể hiện mức độ lệch α . Khi giá trị α càng lớn, độ lệch so với kỳ vọng μ càng lớn. Khi $\alpha = 0$, phân phối này trở về Gauss như Định nghĩa 1.10.

Định lý 1.3 (Kỳ vọng và phương sai). Kỳ vọng và phương sai của biến ngẫu nhiên X có hàm mật độ xác suất Gauss-lệch là $\mathbb{E}(X) = \mu + \sigma\delta\sqrt{\frac{2}{\pi}}$, $\text{Var}(X) = \sigma^2\left(1 - \frac{2\delta^2}{\pi}\right)$, với $\delta = \frac{\alpha}{\sqrt{1+\alpha^2}}$ nằm trong $(-1, 1)$.

Định nghĩa 1.13 (Hàm mật độ đều). Biến ngẫu nhiên liên tục X tuân theo phân phối đều trên đoạn $[l, u]$ (với $l < u$ và $l, u \in \mathbb{R}$) nếu nó có hàm mật độ xác suất là

$$\mathcal{U}(x; l, u) = \begin{cases} \frac{1}{u-l}, & x \in [l, u], \\ 0, & x \notin [l, u]. \end{cases}$$

Định lý 1.4 (Kỳ vọng và phương sai). Kỳ vọng và phương sai của biến ngẫu nhiên X có hàm mật độ xác suất đều là $\mathbb{E}(X) = \frac{l+u}{2}$, $\text{Var}(X) = \frac{(u-l)^2}{12}$.

Định nghĩa 1.14 (Hàm mật độ đều d -chiều). Biến ngẫu nhiên liên tục d -chiều $\mathbf{X}$ tuân theo phân phối đều trên hình hộp $[l_1, u_1] \times \cdots \times [l_d, u_d]$ (với $l_i < u_i$, $l_i, u_i \in \mathbb{R}$) nếu nó có hàm mật độ xác suất là

$$\mathcal{U}(\mathbf{x}; \mathbf{l}, \mathbf{u}) = \begin{cases} \prod_{i=1}^d \frac{1}{u_i-l_i}, & \mathbf{x} \in [l_1, u_1] \times \cdots \times [l_d, u_d], \\ 0, & \text{ngược lại.} \end{cases}$$

Định lý 1.5 (Kỳ vọng và hiệp phương sai). Kỳ vọng và phương sai của biến ngẫu nhiên $\mathbf{X}$ có hàm mật độ xác suất đều là $\mathbb{E}(\mathbf{X}) = \frac{\mathbf{l}+\mathbf{u}}{2}$, $\text{Cov}(\mathbf{X}) = \text{diag}\left(\frac{(u_1-l_1)^2}{12}, \dots, \frac{(u_d-l_d)^2}{12}\right)$.

1.3 Một số hàm mật độ bổ sung

Gần đây, các thuật toán phân tích chùm dựa vào trọng tâm đề xuất bổ sung hàm mật độ xác suất trọng tâm (hay hàm mật độ đại diện của chùm) [19, 20]. Nó có chức năng như trung bình có trọng số của tổng các hàm mật độ trong chùm.

Định nghĩa 1.15 (Hàm mật độ đại diện chùm). Cho tập $\mathcal{F}$ gồm n -hàm mật độ xác suất, trong đó, $\mathcal{F} = \{f_1(x), f_2(x), \dots, f_n(x)\}$ với $n \geq 2$. Ta phân bổ $\mathcal{F}$ vào c -chùm ($1 < c \leq n$),

khi này hàm mật độ đại diện của các chùm c_i là

$$\theta_i(x) = \frac{\sum_{j=1}^n \mu_{ij} \times f_j(x)}{\sum_{j=1}^n \mu_{ij}}, \quad (1.1)$$

trong đó, μ_{ij} là trọng số phân bố hàm mật độ $f_j(x)$ bất kỳ vào chùm c_i [21].

Dựa vào định nghĩa trên, ta dễ dàng nhận được θ_i cũng là một hàm mật độ thỏa Tính chất 1.3.

Chứng minh. Các giá trị trọng số $0 \leq \mu_{ij} \leq 1$ nên các θ_i liên tục không âm, và

$$\int_{\Omega} \theta_i(x) dx = \int_{\Omega} \frac{\sum_{j=1}^n \mu_{ij} \times f_j(x)}{\sum_{j=1}^n \mu_{ij}} dx = \frac{\sum_{j=1}^n \mu_{ij} \times \int_{\Omega} f_j(x) dx}{\sum_{j=1}^n \mu_{ij}} = 1.$$

Định lý 1.6. Kỳ vọng của biến ngẫu nhiên X có hàm mật độ xác suất đại diện $\theta_i(x)$ là

$$\mathbb{E}_{\theta_i}(X) = \frac{\sum_{j=1}^n \mu_{ij} \mathbb{E}_{f_j}(X)}{\sum_{j=1}^n \mu_{ij}}.$$

Chứng minh. Ta có

$$\mathbb{E}_{\theta_i}(X) = \int_{\Omega} x \theta_i(x) dx = \int_{\Omega} x \frac{\sum_{j=1}^n \mu_{ij} f_j(x)}{\sum_{j=1}^n \mu_{ij}} dx = \frac{1}{\sum_{j=1}^n \mu_{ij}} \sum_{j=1}^n \mu_{ij} \underbrace{\int_{\Omega} x f_j(x) dx}_{=\mathbb{E}_{f_j}(X)}.$$

Từ đây, ta suy ra điều phải chứng minh. ■

Ta cũng mở rộng được cho hàm mật độ đại diện chùm đến không gian d -chiều tương tự cho véc-tơ ngẫu nhiên $\mathbf{X}$ và nó cũng thỏa mãn các tính chất của một hàm mật độ xác suất. Mới đây, Thao Nguyen-Trang *et al.* [22, 23] đề xuất hàm mật độ đại diện Gauss như là một phiên bản Gauss hóa của hàm Fréchet [24].

Định nghĩa 1.16 (Hàm mật độ đại diện Gauss). Hàm mật độ đại diện Gauss có dạng phân phối chuẩn sao cho tổng khoảng cách giữa chúng đến các hàm mật độ khác là nhỏ nhất [24], tức là


$$\theta_i(x) = \arg \min_{\mathcal{N}(\mu, \sigma)} \sum_{j=1}^n \mu_{ij} D(\mathcal{N}(\mu, \sigma), f_j(x)).$$

trong đó, $D(\mathcal{N}(\mu, \sigma), f_j(x))$ là khoảng cách giữa hai hàm mật độ Gauss trong tổng thể.

Nhận xét. Hàm mật độ đại diện Gauss là hàm trung bình Fréchet nên có nghiệm duy nhất [24]. Khác với (1.1), hàm mật độ này chỉ cần tìm một hàm Gauss duy nhất mà không cần tổ hợp các f_j giúp tăng khả năng khái quát hóa. Ta cũng có phương sai Fréchet $v_j(x) = \mathbb{E}(D^2(\mathcal{N}(\mu, \sigma), f_j(x)))$.

Hình 1.1 minh họa cụ thể hai cách biểu diễn hàm mật độ đại diện trong cùng một chùm hàm Gauss. Để thấy sự khác biệt, hàm mật độ đại diện tập trung vào phân bố trung bình của

nó tại các chòm, còn hàm mật độ đại diện Gauss lựa chọn vị trí dựa vào khoảng cách các hàm mật độ với nhau.



Chú thích: Hàm mật độ đại diện thể hiện bằng đường thẳng in đậm cho ba hàm Gauss minh họa bằng nét đứt (a) dựa vào trọng số phân bố đều giữa ba hàm $\mu_{ij} = 1/3$, và (b) dựa vào vị trí tối ưu. Ta có thể nói hàm mật độ đại diện này là kỳ vọng của các tổng thể khác nhau. Nguồn: Minh họa của tác giả.

Hình 1.1. Minh họa hai hàm mật độ xác suất đại diện một chòm hàm mật độ $\mathcal{F}$.

1.4 Ước lượng hàm mật độ xác suất


Trong thực tế, ta cần phải ước lượng hàm mật độ xác suất dựa vào dữ liệu rời rạc, luận văn này sử dụng phương pháp ước lượng hàm hạt nhân để chuyển từ bài toán rời rạc sang hàm mật độ xác suất.

Định nghĩa 1.17 (Ước lượng hàm mật độ bằng phương pháp hàm hạt nhân). Giả sử ta có một tập dữ liệu rời rạc gồm n quan sát x_j với $j = 1, \dots, n$ trong không gian $\mathbb{R}^d$. Mỗi điểm $x_j = (x_{1j}, x_{2j}, \dots, x_{dj})^\top$. Hàm mật độ xác suất tại điểm $x = (x_1, x_2, \dots, x_d)^\top$ được ước lượng bằng phương pháp hạt nhân bởi

$$\hat{f}(x) = \frac{1}{n \prod_{i=1}^d bw_i} \sum_{j=1}^n \prod_{i=1}^d \kappa_i \left(\frac{x_i - x_{ij}}{bw_i} \right),$$

trong đó κ_i là hàm hạt nhân theo chiều i có tính chất $\kappa(\cdot) \geq 0$ và $\int \kappa(z) dz = 1$, tham số $bw_i > 0$ là tham số trơn ứng với chiều đó.

Nhận xét. Khi tham số trơn bw nhỏ, hàm mật độ ước lượng sẽ kém trơn và có thể dao động mạnh; ngược lại, nếu bw lớn thì hàm trở nên trơn hơn nhưng có thể làm mất chi tiết quan trọng của phân phối gốc. Các nghiên cứu đã chỉ ra rằng việc lựa chọn tham số trơn có ảnh hưởng lớn hơn đáng kể so với việc lựa chọn loại hàm hạt nhân.



Chú thích: Vùng xám là phân phối thực tế $X \sim 0,3\mathcal{N}(0;1) + 0,7\mathcal{N}(5;1)$, cùng một tham số trơn, các hàm hạt nhân có ảnh hưởng đến độ mượt và khả năng khớp với hàm mật độ thực tế. Nguồn: Minh họa của tác giả.

Hình 1.2. So sánh các hàm hạt nhân trong ước lượng mật độ xác suất

Trong trường hợp đơn giản, có thể chọn cùng một hàm hạt nhân và cùng một tham số trơn cho tất cả các chiều, tức là $\kappa_i \equiv \kappa$ và $bw_i = bw$ với mọi $i = 1, \dots, d$. Một số hàm hạt nhân phổ biến được liệt kê trong Bảng 1.1. Luận văn này khảo sát hàm mật độ ước lượng từ hàm hạt nhân Gauss và Epanechnikov với tham số trơn cố định và được tính bởi công thức của Scott, $bw = 1.06 \times \text{Var}(x_j) \times n^{-1/5}$.

Bảng 1.1. Một số hàm hạt nhân phổ biến dùng trong ước lượng mật độ hạt nhân

Tên hàm	$\kappa(z)$	Miền xác định	Khả vi
Hình chữ nhật	$(1/2)\mathbf{1}_{\{ z \leq 1\}}$	$[-1; 1]$	
Tam giác	$(1 - z)\mathbf{1}_{\{ z \leq 1\}}$	$[-1; 1]$	$\mathcal{C}^0$
Epanechnikov	$(3/4)(1 - z^2)\mathbf{1}_{\{ z \leq 1\}}$	$[-1; 1]$	$\mathcal{C}^0$
Gauss	$\frac{1}{\sqrt{2\pi}} \exp(-z^2/2)$	$(-\infty, \infty)$	$\mathcal{C}^\infty$
Logistic	$\frac{\exp(-z)}{1 + \exp(-z)^2}$	$(-\infty, \infty)$	$\mathcal{C}^\infty$

1.5 Độ đo đánh giá sự tương tự của các hàm mật độ xác suất

Khoảng cách là độ đo xa-gần các vật thể. Ở đây, khái niệm *khoảng cách* bao hàm cả độ đo phân biệt.

1.5.1 Sự tương tự của hai hàm mật độ xác suất

Định nghĩa 1.18 (Khoảng cách hàm mật độ). Hàm $D : \mathcal{F} \times \mathcal{G} \rightarrow \mathbb{R}$ được gọi là khoảng cách của hai hàm mật độ $f \in \mathcal{F}$ và $g \in \mathcal{G}$ nếu nó thỏa mãn ba điều kiện [25]

1. $D(f, g) \geq 0$,

2. $D(f, g) = 0$ khi và chỉ khi $f \equiv g$ hầu khắp nơi, và

3. $D(f, g) = D(g, f)$.

Theo Định nghĩa 1.18, khoảng cách giữa hai hàm mật độ thỏa mãn các tiên đề của mê-tríc. Trong lý thuyết thống kê và thông tin, một mê-tríc được gọi là *khoảng cách* và nửa mê-tríc gọi là *phân kỳ*. Ta cũng có mối quan hệ giữa hai hàm mật độ đối mới trọng tâm bất kỳ trong mê-tríc.

Bổ đề 1.5 (Bất đẳng thức tam giác). Với mọi $f_j, f_k \in c_i$ và trọng tâm chùm θ_i có khoảng cách là mê-tríc, ta có bất đẳng thức tam giác $D(f_j, f_k) \leq D(f_j, \theta_i) + D(f_k, \theta_i)$.

Bảng 1.2 làm rõ các công thức khoảng cách và độ đo tương tự giữa hai hàm mật độ xác suất theo tiếp cận xác suất.


Bảng 1.2. Bảng tổng kết các loại khoảng cách giữa hai hàm mật độ xác suất

Khoảng cách	$D(f, g)$	Miền giá trị	Đối xứng	Tam giác	Không âm
Chernoff	$-\log \left(\int_{\Omega} f(x)^s g(x)^{1-s} dx \right)$	$[0, \infty)$	✓		✓
$\mathcal{L}_p$	$(\int_{\Omega} f(x) - g(x) ^p dx)^{1/p}$	–	✓	✓	✓
Matusita	$[2(1 - \int_{\Omega} f(x)^{1/2} g(x)^{1/2} dx)]^{1/2}$	$[0, \sqrt{2}]$	✓	✓	✓
Hellinger [26]	$1 - (\int_{\Omega} f(x)g(x) dx)^{1/2}$	$[0, 1]$	✓	✓	✓
Kullback–Leibler	$\int_{\Omega} f(x) \log \frac{f(x)}{g(x)} dx$	$[0, \infty)$			✓

Nguồn: Tác giả tổng hợp

Nhận xét. Nhìn vào Bảng 1.2, có thể thấy khoảng cách Chernoff là một tổng quát hóa của khoảng cách Bhattacharyya khi chọn $s = 1/2$. Đáng chú ý, cả hai loại khoảng cách $\mathcal{L}_p$ và Hellinger đều thỏa mãn đầy đủ các tính chất mê-tríc, còn Kullback–Leibler không đối xứng và vi phạm bất đẳng thức tam giác.

Ở Hình 1.3, chúng tôi ghi nhận giá trị khoảng cách $f_1 \sim \mathcal{N}(0, 1)$ và $f_2 \sim \mathcal{N}(\mu, 1)$ với μ trượt từ -10 đến 20 . Ta thấy được tính bị chặn của các loại khoảng cách này đúng với lý thuyết tại Bảng 1.2.



Nguồn: Minh họa của tác giả

Hình 1.3. Dãy khoảng cách $D(f_1, f_2)$ giữa hai hàm mật độ Gauss $\mathcal{N}(0, 1)$ và $\mathcal{N}(\mu, 1)$

Nhận xét. Ta thấy khi hai hàm mật độ f_2 cách nhau quá xa hàm f_1 , trường hợp này là $|\mu_2| \gg 0$, tất cả loại khoảng cách hàm mật độ đều bão hòa và không đo được sự khác biệt. Lúc này hai hàm mật độ về mặt không gian rất xa nhau, nhưng khoảng cách không thể đo xa hơn nữa vì nó đã đạt đến ngưỡng lớn nhất. Đây là hạn chế không giữ được vị trí hình học đối với các khoảng cách hàm mật độ.

Luận văn này giới thiệu khoảng cách Wasserstein (hay Kantorovich–Rubinstein), là một mê-tríc hỗ trợ tốt cho tính toán khoảng cách các hàm mật độ không chồng lấp [27] thỏa Định nghĩa 1.18 và bất đẳng thức tam giác. Khoảng cách này được phát triển trong bài toán vận chuyển tối ưu, nhưng chưa được nghiên cứu trong lĩnh vực nhận dạng hàm mật độ.

Định nghĩa 1.19 (Khoảng cách p -Wasserstein). Khoảng cách p -Wasserstein ($p \geq 1$) giữa hai độ đo xác suất μ và ν trong không gian $\mathbb{R}^d$ được định nghĩa là

$$W_p(\mu, \nu) = \inf_{\substack{X \sim \mu \\ Y \sim \nu}} (\mathbb{E} \|X - Y\|^p)^{1/p} = \left(\inf_{\gamma \in \Gamma(\mu, \nu)} \int_{M \times M} d(x, y)^p d\gamma(x, y) \right)^{1/p},$$

Khoảng cách p -Wasserstein đo mức chênh lệch tối ưu giữa hai phân phối xác suất, xét trên tất cả các phép ghép cặp khả dĩ. Tức là nó tính đến công sức để di chuyển và tái sắp xếp khối lượng từ hàm này sang hàm kia. Ở đây, chúng tôi sử dụng $p = 2$ để tính toán đo độ khác biệt giữa hai mật độ xác suất liên tục. Trong thực tế, ta tính toán cụ thể khoảng cách này bằng cách biểu diễn nó qua hàm phân vị. Ta có Định lý 1.7.

Định lý 1.7. Khoảng cách p -Wasserstein giữa hai độ đo xác suất μ và ν có thể được biểu diễn dưới dạng phân vị trong trường hợp 1-chiều bởi định nghĩa

$$W_p^p(\mu, \nu) = \int_0^1 |F_\mu^{-1}(s) - F_\nu^{-1}(s)|^p ds,$$

trong đó F_μ^{-1} và F_ν^{-1} lần lượt là hàm phân vị của μ và ν (Xem Định nghĩa 1.4).

Định lý 1.8 (Khoảng cách 2-Wasserstein giữa hai hàm mật độ Gauss 1 chiều). *Giả sử hai hàm mật độ $f_1(x) \sim \mathcal{N}(\mu_1, \sigma_1^2)$ và $f_2(x) \sim \mathcal{N}(\mu_2, \sigma_2^2)$ là hai phân bố Gauss một chiều. Khi đó, khoảng cách 2-Wasserstein giữa chúng là $D_W^2(f_1, f_2) = (\mu_1 - \mu_2)^2 + (\sigma_1 - \sigma_2)^2$.*

Chứng minh. Dựa vào Định lý 1.7, ta xét hàm phân vị Gauss $F_i^{-1}(u) = \mu_i + \sigma_i \Phi^{-1}(u)$, với $\Phi^{-1}(u)$ là phân vị chuẩn $\mathcal{N}(0, 1)$. Khi đó,

$$\begin{aligned} D_W^2(f_1, f_2) &= \int_0^1 (\mu_1 + \sigma_1 \Phi^{-1}(u) - \mu_2 - \sigma_2 \Phi^{-1}(u))^2 du \\ &= \int_0^1 ((\mu_1 - \mu_2) + (\sigma_1 - \sigma_2) \Phi^{-1}(u))^2 du \\ &= \int_0^1 [(\mu_1 - \mu_2)^2 + 2(\mu_1 - \mu_2)(\sigma_1 - \sigma_2) \Phi^{-1}(u) + (\sigma_1 - \sigma_2)^2 (\Phi^{-1}(u))^2] du \\ &= (\mu_1 - \mu_2)^2 \underbrace{\int_0^1 du}_{=1} + 2(\mu_1 - \mu_2)(\sigma_1 - \sigma_2) \underbrace{\int_0^1 \Phi^{-1}(u) du}_{=0} + (\sigma_1 - \sigma_2)^2 \underbrace{\int_0^1 (\Phi^{-1}(u))^2 du}_{=1}. \end{aligned}$$

Từ đây ta suy ra được điều phải chứng minh. ■


Tương tự ta cũng suy ra được phương pháp chứng minh cho các Định lý khoảng cách sau.

Định lý 1.9 (Khoảng cách 2-Wasserstein giữa hai hàm mật độ Gauss d -chiều). *Giả sử hai hàm mật độ $f_1(x) \sim \mathcal{N}(\mu_1, \Sigma_1)$ và $f_2(x) \sim \mathcal{N}(\mu_2, \Sigma_2)$ là hai phân bố Gauss trong $\mathbb{R}^d$. Khi đó, khoảng cách 2-Wasserstein giữa chúng là*

$$D_W^2(f_1, f_2) = \|\mu_1 - \mu_2\|_2^2 + \text{Tr} \left(\Sigma_1 + \Sigma_2 - 2(\Sigma_2^{1/2} \Sigma_1 \Sigma_2^{1/2})^{1/2} \right).$$

Định lý 1.10 (Khoảng cách 2-Wasserstein giữa hai phân phối đều 1-chiều). *Giả sử hai hàm mật độ $f_1(x) \sim \mathcal{U}[a_1, b_1]$ và $f_2(x) \sim \mathcal{U}[a_2, b_2]$ là hai phân phối đều một chiều. Khi đó, khoảng cách 2-Wasserstein giữa chúng là $D_W^2(f_1, f_2) = (\mu_1 - \mu_2)^2 + \frac{1}{12}(l_1 - l_2)^2$, trong đó $m_i = \frac{a_i + b_i}{2}$ là trung điểm và $l_i = b_i - a_i$ là độ dài của khoảng $[a_i, b_i]$.*

Ví dụ 1.1 (So sánh các loại khoảng cách hàm mật độ). Xét hai hàm mật độ xác suất đều $f_1(x)$ và $f_2(x)$. Hình 1.4 mô tả bốn tình huống khoảng cách giữa hai hàm mật độ này.



Chú thích: Bốn trường hợp mật độ đều với (a) hai hàm rời nhau, cùng chiều rộng; (b) hai hàm rời nhau, khác chiều rộng; (c) hai hàm rời nhau, cách xa nhau; và (d) hai hàm chồng lấp. Ở đây, ô vuông trắng $\square$ biểu thị hàm mật độ $f_1(x)$ và ô vuông xám $\blacksquare$ biểu thị hàm mật độ $f_2(x)$. Nguồn: Minh họa của tác giả.

Hình 1.4. Các trường hợp trong khoảng cách giữa hai hàm mật độ đều $f_1(x)$ và $f_2(x)$.

Ta có Bảng 1.3 tổng hợp kết quả các phép đo này trong bốn tình huống.

Bảng 1.3. Các kết quả khoảng cách giữa hai hàm mật độ đều

$D(f_1, f_2)$	Trường hợp (a)	Trường hợp (b)	Trường hợp (c)	Trường hợp (d)
$\mathcal{L}_1$	2,0	2,0	2,0	1,0
$\mathcal{L}_2$	1,7	$\sqrt{1,5}$	1,7	0,5
D_B^1	∞	∞	∞	0,5
D_H^2	1,0	1,0	1,0	$\sqrt{0,5}$
D_W^3	3,0	3,5	6,0	1,0

Chú thích: ¹ khoảng cách Bhattacharyya; ² khoảng cách Hellinger; ³ khoảng cách Wasserstein. Nguồn: Tác giả tính toán

Trước hết, các khoảng cách $\mathcal{L}_1$ và $\mathcal{L}_2$ trong các trường hợp (a), (b), và (c), mặc dù $f_1(x)$ và $f_2(x)$ nằm xa dần, nhưng các giá trị $\mathcal{L}_1$ và $\mathcal{L}_2$ hầu như không đổi (đều bằng 2 hoặc $\sqrt{2}$). Khoảng cách này nhận biết được khác biệt hình dáng và phân bố, nhưng không nhận biết tốt yếu tố vị trí trong không gian. Hệ số Bhattacharyya và khoảng cách Hellinger chỉ có ý nghĩa trong trường hợp (d), khi có phần chồng lấp giữa $f_1(x)$ và $f_2(x)$. Điều này cho thấy chúng nhạy với mức độ chồng lấp, nhưng không phân biệt được hai hàm độc lập nhau.

Ngược lại, khoảng cách Wasserstein nhạy cảm với vị trí hình học, hình dáng và phân bố. Khi so (a) và (c), ta thấy khoảng cách này tăng rất lớn cho thấy hiệu quả so sánh vị trí. Xét (a) và (b), khi thay đổi hình dáng hàm mật độ, khoảng cách này cũng có sự khác biệt. Đáng chú ý, khoảng cách $\mathcal{L}_2$ và D_W là trái ngược nhau. Khi thay đổi hình dáng đồ thị, khoảng cách $\mathcal{L}_2$ giảm nhưng D_W lại tăng lên. Cuối cùng, trường hợp (d) cho thấy khoảng cách cũng có ý nghĩa

khi chồng lấp.

Định nghĩa 1.20 (Affinity). Hàm $\rho : f \rightarrow [0, 1]$ được gọi là affinity của hai hàm mật độ $f_1(x)$ và $f_2(x)$ nếu nó thỏa mãn ba điều kiện

1. $0 \leq \rho(f_1, f_2) \leq 1$,
2. $\rho(f_1, f_2) = 1$ nếu và chỉ nếu $f_1 \equiv f_2$, và
3. mỗi dãy hàm $\{f_n\}$ thì $\rho(f_n, f_0) \rightarrow 1$

Nhận xét. Affinity đo lường sự giống nhau giữa hai hàm mật độ theo vị trí. Vì vậy, ta có tương quan giữa Affinity và Khoảng cách giữa hai hàm mật độ xác suất $f_1(x)$ và $f_2(x)$ là $D(f_1, f_2) = 1 - \rho(f_1, f_2)$.

Ví dụ 1.2. Affinity cơ bản cho tương tự hai hàm mật độ $f_1(x)$ và $f_2(x)$ là Affinity Bhattacharyya với $\rho_B(f_1, f_2) = \int_{\Omega} \sqrt{f_1(x)f_2(x)} dx$.

Định nghĩa 1.21 (Hàm hạt nhân của khoảng cách). Hàm $K : \mathcal{F} \times \mathcal{F} \rightarrow [0; 1]$ với tập $\mathcal{F}$ được gọi là hạt nhân (hạch) giữa hai hàm mật độ $f_1(x), f_2(x)$ nếu nó thỏa mãn

1. $0 \leq K(f_1, f_2) \leq 1$,
2. $K(f_1, f_2) = K(f_2, f_1), \forall f_1, f_2 \in \mathcal{F}$,
3. với mọi tập hữu hạn $\{f_1, \dots, f_n\} \subset \mathcal{F}$ và các hệ số $\alpha_1, \dots, \alpha_n \in \mathbb{R}$, hàm hạt nhân là xác định dương, tức là $\sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j K(f_i, f_j) \geq 0$.

Ví dụ 1.3. Hai hạt nhân cơ bản cho khoảng cách hai hàm mật độ $f_1(x)$ và $f_2(x)$ là hạt nhân chuẩn $K_G(f_1, f_2) = \exp\left(-\frac{D^2(f_1, f_2)}{\beta \sigma^2}\right)$, trong đó, D thuộc họ khoảng cách $\mathcal{L}_p$ để đảm bảo tính mê-tríc và $\beta \in \mathbb{R}_{>0}$, và hạt nhân Bhattacharyya $K_B(f_1, f_2) = \int_{\Omega} \sqrt{f_1(x)f_2(x)} dx$.

Hàm hạt nhân $K(\cdot, \cdot)$ càng gần 1 thì hai hàm mật độ càng giống nhau và ngược lại. Ở đây, việc chuyển đổi từ hàm hạt nhân đến khoảng cách được cho bởi $D = 1 - K_G$ khi các hạt nhân chuẩn hóa $[0; 1]$, hoặc $D = 2(1 - K_H)$ khi là hạt nhân Bhattacharyya.

Định nghĩa 1.22 (Ma trận khoảng cách từng đôi). Cho tập n hàm mật độ $\{f_1, f_2, \dots, f_n\}$, ma trận khoảng cách $D \in \mathbb{R}^{n \times n}$ là một ma trận đối xứng và có $\text{Trace}(D) = 0$, được định nghĩa bởi $D_{ij} = D(f_i, f_j)$, với mọi $i, j \in \{1, \dots, n\}$.

1.5.2 Sự tương tự của nhiều hơn hai hàm mật độ xác suất

a. Liên kết chùm hàm mật độ

Giả sử hai chùm hàm mật độ không rỗng $\mathcal{F}$ và $\mathcal{G}$ chứa hữu hạn phần tử và $D(f, g)$ là khoảng cách giữa hai hàm mật độ, $f \in \mathcal{F}$ và $g \in \mathcal{G}$. Khoảng cách giữa hai chùm hàm mật độ gọi là liên kết, là một ánh xạ $\delta : \mathcal{P}(X) \times \mathcal{P}(X) \times \mathcal{M}(X) \rightarrow \mathbb{R}_+$, trong đó, $\mathcal{P}(X)$ là tập lũy thừa của X .

Bảng 1.4. Bảng tổng kết các loại liên kết Δ giữa hai chùm hàm mật độ xác suất

Liên kết	Ký hiệu	Δ
Liên kết đơn ¹ (SLINK)[28]	$\Delta_{\min}$	$\min_{f \in \mathcal{F}, g \in \mathcal{G}} D(f, g)$
Liên kết đủ ² (CLINK)[29]	$\Delta_{\max}$	$\max_{f \in \mathcal{F}, g \in \mathcal{G}} D(f, g)$
Liên kết tâm (UPGMC)	Δ_{centroid}	$D(\theta_{\mathcal{F}}, \theta_{\mathcal{G}})$
Liên kết trung bình (UPGMA)	Δ_{avg}	$\frac{1}{\#\mathcal{F}\#\mathcal{G}} \sum_{f \in \mathcal{F}, g \in \mathcal{G}} D(f, g)$
Liên kết Ward [30]	Δ_{Ward}	$\frac{\#\mathcal{F}\#\mathcal{G}}{\#\mathcal{F} + \#\mathcal{G}} D^2(\theta_{\mathcal{F}}, \theta_{\mathcal{G}})$

Chú thích: ¹: Khoảng cách lớn nhất; ²: Khoảng cách bé nhất. Nguồn: Tác giả tổng hợp

Khi hai ta cần tính khoảng cách từ hợp hai chùm hàm $\mathcal{F} \cup \mathcal{G}$ đến một chùm hàm $\mathcal{H}$, ta cũng có thể sử dụng các loại liên kết trên. Trong thực tế, các liên kết Δ được biến đổi thành

$$\begin{aligned}\Delta_{\min}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) &= \min \{D_{f \in \mathcal{F}, h \in \mathcal{H}}(f, h), D_{f \in \mathcal{G}, h \in \mathcal{H}}(g, h)\}, \\ \Delta_{\max}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) &= \max \{D_{f \in \mathcal{F}, h \in \mathcal{H}}(f, h), D_{f \in \mathcal{G}, h \in \mathcal{H}}(g, h)\}, \\ \Delta_{\text{avg}}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) &= \frac{1}{\#(\mathcal{F} \cup \mathcal{G}) \cdot \#\mathcal{H}} \sum_{\substack{f \in \mathcal{F} \cup \mathcal{G} \\ h \in \mathcal{H}}} D(f, h), \\ \Delta_{\text{centroid}}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) &= D(\theta_{\mathcal{F} \cup \mathcal{G}}, \theta_{\mathcal{H}}), \\ \Delta_{\text{Ward}}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) &= \frac{\#(\mathcal{F} \cup \mathcal{G}) \cdot \#\mathcal{H}}{(\#\mathcal{F} \cup \#\mathcal{G}) \cup \#\mathcal{H}} D^2(\theta_{\mathcal{F} \cup \mathcal{G}}, \theta_{\mathcal{H}}).\end{aligned}$$

b. Tương tự chùm hàm mật độ

Giả sử tập hợp $\mathcal{F}$ có nhiều hơn hai phần tử ($n > 2$)

Bảng 1.5. Tổng kết các tương tự giữa các chùm hàm mật độ xác suất

Tương tự	$\Delta(\mathcal{F})$
Affinity của Matusita [31]	$\int_{\Omega} \left(\prod_{j=1}^n f_j(x) \right)^{1/n} dx$
Affinity của Toussaint [32]	$\int_{\Omega} \left(\prod_{j=1}^n f_j(x) \right)^{\alpha_j} dx$
Độ rộng chùm [16]	$\int_{\Omega} f_{\max}(x) dx - 1$
Hệ số tương tự chùm [33]	$\frac{k}{k-1} \left(1 - \frac{1}{k} \int_{\Omega} f_{\max}(x) dx \right)$

Nguồn: Tác giả tổng hợp

Nhận xét. Trong Bảng 1.5 Affinity Toussaint suy biến thành Affinity Matusita khi $\alpha_1 = \alpha_2 = \dots = \alpha_n = \frac{1}{n}$. Khi Affinity của Matusita có $n = 2$ thì nó trở thành hệ số Bhattacharyya []. Cuối cùng, hệ số tương tự chùm chuẩn hóa tuyến tính độ rộng chùm.

1.6 Phương pháp số xấp xỉ tích phân

Các tích phân trong lĩnh vực hàm mật độ cần xấp xỉ bằng phương pháp số. Luận văn này, chúng tôi chọn sử dụng phương pháp hình thang nhằm cải thiện độ chính xác so với tổng Riemann nhưng cũng không tốn quá nhiều tài nguyên như Monte Carlo hay Simpsons. Một tích phân trên miền $\Omega \subset \mathbb{R}^d$ được xấp xỉ bằng công thức tổng quát $\int_{\Omega} f(x) dx = \lim_{h \rightarrow 0} \sum_i h^d w_i f(x_i)$. Khi này, giả sử hàm $f : [a, b] \rightarrow \mathbb{R}$, chia đoạn $[a, b]$ thành n , phương pháp hình thang một chiều xấp xỉ tích phân

$$\int_a^b f(x) dx \approx \frac{h}{2} \left(f(x_0) + 2 \sum_{i=1}^{n-1} f(x_i) + f(x_n) \right),$$

trong đó $x_i = a + ih, i = 0, \dots, n$.

1.7 Phân tích chùm cho hàm mật độ xác suất

1.7.1 Phân tích chùm không mờ

Phân tích chùm không mờ (hay phân chùm cứng) yêu cầu một phần tử chỉ thuộc duy nhất một chùm cố định. Tiểu mục này trình bày hai khía cạnh chính của phân tích chùm bao gồm phân tích chùm phân vùng (dựa trên trọng tâm) và phân cấp thứ bậc.

a. Phân tích chùm k -means

Phân tích chùm phân vùng giả sử $\mathcal{S}$ là tập các véc-tơ d -chiều x_j , trong đó $j = 1, 2, \dots, n$. Mỗi đối tượng o_j liên hệ với hàm mật độ xác suất $f_j(x)$. Tập $\mathcal{F}$ gồm họ n -hàm mật độ trên Ω . Bài toán phân tích chùm phân bổ j -hàm mật độ vào c -chùm nguyên, với $i = 1, 2, \dots, c$ thỏa mãn ba ràng buộc

1. Hợp tất cả các chùm $\bigcup_i c_i$ bằng $\mathcal{F}$,
2. Giao của mỗi chùm là rỗng, $c_i \cap c_j = \emptyset$, với mỗi $i \neq j$,
3. Lực lượng của mỗi chùm là khác rỗng, $|c_i| \neq \emptyset$.

Phép gán này được mô tả bằng một ánh xạ nhiều-đến-một, hay còn gọi là bộ mã hóa $c_i = c(f_j)$, trong đó đối tượng f_j gán vào chùm c_i là duy nhất. Cụ thể, ràng buộc 1 đảm bảo tất cả các đối tượng phải được phân tách thành các chùm, trong đó, mỗi chùm phải chứa ít nhất một phần tử (ràng buộc 3) và không có đối tượng nào được xếp vào cùng một chùm (ràng buộc 2). Phân tích chùm KCF là bài toán tối thiểu đơn mục tiêu cho tổng các bình phương khoảng cách trong chùm các hàm mật độ [8, 12, 16], tức là

$$\text{Minimise : } J(U, \Theta | \mathcal{F}, c) = \sum_{i=1}^c \sum_{f_j(x) \in c_i} \mu_{ij} D^2(\theta_i, f_j), \quad (\text{KCF})$$

trong đó, hàm $\theta_i(x)$ là hàm mật độ trọng tâm của chùm thứ c_i . Ký hiệu $D^2(\theta_i, f_j)$ là khoảng cách giữa hàm mật độ trọng tâm $\theta_i(x)$ đến các đối tượng $f_j(x)$ còn lại trong dữ liệu. Ta cũng có μ_{ij} là biến tiềm ẩn thể hiện mức độ thành viên của hàm mật độ $f_j(x)$ thỏa $\mu_{ij} = 1_{\{j \in c_i\}}$. Tức là $\mu_{ij} = 1$ nếu hàm j thuộc chùm c_i và $\mu_{ij} = 0$ nếu ngược lại.

Chứng minh. Điều kiện $\sum_i \mu_{ij} = 1$ đảm bảo rằng mỗi hàm f_j được gán vào đúng một chùm duy nhất. Tập tất cả các ma trận U là hữu hạn, và việc cố định U biến hàm mục tiêu KCF trở thành hàm tuyến tính theo U . Đặc biệt, với θ_i cố định, giá trị J được tối thiểu khi gán f_j vào chùm c_i sao cho $D^2(f_j, \theta_i)$ nhỏ nhất, tức là $\mu_{ij} = 1_{\{i = \arg \min_\ell D^2(f_j, \theta_\ell)\}}$. ■

Bổ đề 1.6 (Thành lập hàm mật độ đại diện). Giả sử $\mathcal{F}$ -hàm mật độ được phân thành c -chùm qua các mức độ thành viên μ_{ij} , với bình phương khoảng cách $D^2(\theta_i, f_j)$. Khi đó, hàm mật độ đại diện $\theta_i^*(x)$ tối ưu trên mỗi chùm c_i được cho bởi công thức

$$\theta_i^*(x) = \frac{\sum_{f_j \in c_i} \mu_{ij} f_j(x)}{\sum_{f_j \in c_i} \mu_{ij}}.$$

Chứng minh. Từ hàm mục tiêu KCF, ta tính các đạo hàm riêng theo c_i .

$$\begin{aligned} \frac{\partial}{\partial \theta_i(x)} J(\mathcal{F}, c) &= \frac{\partial}{\partial \theta_i} \sum_{i=1}^c \sum_{f_j(x) \in c_i} \mu_{ij} D^2(\theta_i, f_j(x)) = \sum_{i=1}^c \sum_{f_j(x) \in c_i} \mu_{ij} \frac{\partial}{\partial \theta_i(x)} \int_{\Omega} (\theta_i(x) - f_j(x))^2 dx \\ &= \sum_{f_j(x) \in c_i} \mu_{ij} \int_{\Omega} 2(\theta_i(x) - f_j(x)) dx. \end{aligned}$$

Để hàm J đạt cực trị, ta cho đạo hàm vừa tính bằng 0. Tức là,

$$\sum_{f_j(x) \in c_i} \mu_{ij} \int_{\Omega} 2(\theta_i(x) - f_j(x)) dx = 0 \Leftrightarrow \theta_i(x) \sum_{f_j(x) \in c_i} \mu_{ij} = \sum_{f_j(x) \in c_i} \mu_{ij} f_j(x).$$

Từ đây suy ra điều phải chứng minh. Tóm lại, mật độ đại diện tối ưu để cực tiểu hàm mục tiêu là hàm mật độ trọng tâm (1.1) các hàm mật độ trong các chùm. ■

Nhận xét. Vì mỗi hàm mật độ trọng tâm (1.1) được đại diện trừu tượng bằng trung bình có trọng số của từng chùm, nên kết quả trọng tâm này có thể không đồng nhất với bất kỳ đối tượng nào trong mẫu. Thay vào đó, mật độ trọng tâm này nằm bất kỳ trong không gian, đóng vai trò như một đối tượng tham chiếu để các hàm mật độ khác so sánh [38].

Một hàm mật độ mới h được gán vào chùm c_k nếu $k = \arg \min_i D^2(h, \theta_i)$. Hơn nữa, vì ma trận phân vùng $\mu_{ij} = 1_{\{j \in c_i\}}$ nên ta có thể rút gọn hàm mật độ đại diện (1.1) thành trung bình Fréchet

$$\theta_i(x) = \frac{1}{\#c_i} \sum_{f_j(x) \in c_i} f_j(x). \quad (1.2)$$

Bổ đề 1.7 (Sự hội tụ của thuật toán KCF). Sau mỗi bước lặp của thuật toán KCF, hàm mục tiêu $J^{(t)}$ luôn giảm tại hữu hạn bước lặp t .

Chứng minh. Gọi $\mathcal{Z}^{(t)} = \{c_1^{(t)}, \dots, c_k^{(t)}\}$ là phân hoạch tại bước t , với hàm trọng tâm $\theta_i^{(t)}(x)$ và hàm mục tiêu $J^{(t)}$. Khi trọng tâm $\theta_i^{(t)}$ cố định, mỗi hàm f được gán vào chùm gần nhất. Khi đó, $\sum_{i=1}^k \sum_{f \in c_i^{(t+1)}} D^2(f, \theta_i^{(t)}) \leq J^{(t)}$, (1). Còn khi chùm $c_i^{(t+1)}$ cố định, hàm trọng tâm $\theta_i^{(t+1)}$ được cập nhật sao cho $\sum_{f \in c_i^{(t+1)}} D^2(f, \theta_i^{(t+1)}) \leq \sum_{f \in c_i^{(t+1)}} D^2(f, \theta_i^{(t)})$, (2). Cộng (1) và (2) ta được giá trị $J^{(t+1)} = \sum_{i=1}^k \sum_{f \in c_i^{(t+1)}} D^2(f, \theta_i^{(t+1)}) \leq J^{(t)}$. Hơn nữa, ta có chặn dưới $J^{(t)} - J^{(t+1)} \geq \sum_{i=1}^k |c_i^{(t+1)}| \cdot D^2(\theta_i^{(t)}, \theta_i^{(t+1)})$. Suy ra, thuật toán hội tụ đơn điệu và dừng sau hữu hạn bước do số phân hoạch hữu hạn. ■

b. Phân tích chùm thứ bậc


Phân cấp thứ bậc giả định tập $\mathcal{P}$ trong [39]

Định lý 1.11 (Hội tụ của thuật toán HCF). *Giải thuật HCF luôn hội tụ sau $n - 1$ bước hợp nhất và tạo thành một cây nhị phân có n nút lá và $n - 1$ nút trong.*

Chứng minh. Mỗi lần hợp nhất, một cặp c_i, c_j được thay thế bằng chùm $c_i \cup c_j$, và giữ nguyên các chùm còn lại. Ta có $\forall c \in C_t, \exists c' \in C_{t+1}$ sao cho $c \subseteq c'$, tức là C_{t+1} phân rã nhỏ hơn C_t . ■

Ví dụ 1.4 (Phân cấp thứ bậc hàm Gauss 1-chiều). Cho bảy hàm mật độ chuẩn một chiều $\mathcal{F}$ cho bởi Vo-Van, Tai and Pham-Gia, T., [16] có phương sai đồng nhất $\sigma_i^2 = 1, i = 1, \dots, 7$ và các trung bình lần lượt là $\mu_i = \{0, 3; 4, 0; 9, 1; 1, 0; 5, 5; 8, 0; 4, 8\}$. Phân cấp thứ bậc với khoảng cách $D(f_1, f_2) = \mathcal{L}_2$ và liên kết $\Delta_{\max}(\mathcal{F}_1, \mathcal{F}_2)$ là liên kết đủ.

Ta có kết quả phân cấp thứ bậc tích tụ bởi Hình 1.5 và bài giải chi tiết được phân tích trong Phụ lục B (tr. 44). Quá trình phân cấp được thực hiện với hai phương pháp liên kết đủ liên kết Ward. Nhìn Hình 1.5, ta thấy phương pháp liên kết đủ có xu hướng tạo ra các chùm nhỏ, chặt chẽ, và nhạy cảm với nhiễu ở biên. Ngược lại, liên kết Ward cho kết quả các chùm có tính đồng nhất cao hơn về phân bố, làm cây phân cấp cân đối.



Chú thích: Cây phân cấp ở phía trên thể hiện cách sắp xếp và nhóm các hàm mật độ dựa trên liên kết, phần dưới thể hiện ma trận khoảng cách tương ứng với từng hàm mật độ đó. Nguồn: Minh họa của tác giả

Hình 1.5. Kết quả phân cấp thứ bậc tích tụ đối với Ví dụ 1.4

1.7.2 Phân tích chùm mờ

Phân tích chùm mờ được xây dựng lần đầu tiên cho hàm mật độ bởi Thao Nguyen-Trang and Tai Vo-Van [19] với sự phát triển từ phần tử rời rạc do [40]. Khác biệt giữa nó với phân chùm cứng là sự chấp nhận thuộc nhiều chùm của một phần tử với một *mức độ phân vùng* mềm hơn. Điều này hữu ích khi ranh giới giữa các hàm là không chắc chắn.

Giả sử $\mathcal{F}$ chưa được gán nhãn, mục tiêu của bài toán là tối thiểu hóa tổng trọng số các giá trị hàm thành viên với siêu tham số m và khoảng cách.

$$\text{Minimise : } J(U, \Theta | \mathcal{F}, c, m) = \sum_{i=1}^c \sum_{j=1}^n \mu_{ij}^m D^2(\theta_i, f_j), \quad (\text{FCF})$$

$$\text{s.t : } \sum_{i=1}^c \mu_{ij} = 1, \quad \forall j \in 1, \dots, n, \quad (\text{C1})$$

$$\mu_{ij} \in [0; 1], \quad \forall i \in 1, \dots, c, \forall j \in 1, \dots, n, \quad (\text{C2})$$

$$\sum_{j=1}^n \mu_{ij} > 0, \quad \forall i \in 1, \dots, c. \quad (\text{C3})$$

Thuật toán phân tích chùm mờ cho phần tử rời rạc đã được chứng minh là tối ưu toàn cục bởi [37, 41, 42] qua định lý Zangwill [43]. Đặc biệt, [44] mới đây chứng minh sự hội tụ toàn cục qua thuật toán độ dốc. Do đó, luận văn này chỉ giới thiệu Định lý 1.12 trình bày sự thành lập của ma trận phân vùng và hàm mật độ đại diện từ hàm mục tiêu J cho dữ liệu hàm mật độ xác suất.

Định lý 1.12. Cho $\mathcal{F}$ chứa $n > c$ hàm mật độ xác suất và $m > 1$. Xét $D_{ij} = D(\theta_i, f_j)$


với $1 \leq j \leq n, 1 \leq i \leq c$. Với mỗi j , xác định các tập $I_j = \{i \mid D_{ij} = 0, 1 \leq i \leq c\}$ và tập $I_j^c = \{1, \dots, c\} \setminus I_j$. Khi đó J có thể đạt cực tiểu toàn cục khi và chỉ khi

$$\theta_i^*(x) = \frac{\sum_{j=1}^n (\mu_{ij}^*)^m f_j(x)}{\sum_{j=1}^n (\mu_{ij}^*)^m}, \text{ và} \quad (1.3)$$

$$\mu_{ij}^* = \frac{(D_{ij}^*)^{-1/(m-1)}}{\sum_{l=1}^n (D_{lj}^*)^{-1/(m-1)}}, \text{ nếu } I_j \neq \emptyset, \text{ và}, \quad (1.4)$$

$$\mu_{ij}^* = 0, \forall i \in I_j^c \text{ và } \sum_{i \in I_j^c} \mu_{ij}^* = 1, \text{ nếu } I_j \neq \emptyset, \quad (1.5)$$

Nhận xét. Ở đây, tham số m thể hiện mức độ mờ của ma trận phân vùng μ_{ij} . Để minh họa ảnh hưởng của tham số m , ta giả định hai chòm với $D_{2j} = 2 - D_{1j}$, và xét giá trị μ_{1j} theo khoảng cách này chạy từ 0 đến 2. Hình 1.6 trực quan hóa cách m điều chỉnh mức độ. Khi $m \rightarrow 1$, ma trận phân vùng kết quả sẽ tiến về ma trận phân vùng không mờ ($\mu_{ij} = 1_{\{j \in c_i\}}\rangle$). Khi $m \rightarrow \infty$, các giá trị μ_{ij} sẽ trở nên bằng nhau ($= 1/c$) làm mất khả năng gán các hàm mật độ xác suất vào các chòm. Nhiều nghiên cứu tổng quát hóa tham số m đã được đặt ra sau khi thuật toán này công bố. Tuy nhiên, cho đến nay các nhà phân tích vẫn chọn tiêu biểu $m = 2$ vì tính dễ giải thích [7, 41].



Chú thích: Giá trị μ_{1j} tại trục tung biểu diễn mức độ phân vùng tại chòm 1 theo khoảng cách $D_{1j} = \mathcal{L}_1(f_1, f_j)$ với các giá trị $m = 1,1; 1,5; 2,0; 3,0; 5,0; 10,0$. Khi $m \rightarrow 1$, đường phân vùng trở nên gãy; khi m tăng, đường cong trở nên phẳng và đều ở $y = 1/2$. Nguồn: Minh họa của tác giả.

Hình 1.6. Biểu đồ phân vùng mờ theo khoảng cách D_{1j} với các hệ số m khác nhau.

Thuật toán phân chòm mờ FCF được thực hiện qua hai bước cập nhật trọng tâm và cập nhật ma trận phân vùng [7, 19] (Thuật toán 3). Kết thúc thuật toán ta nhận được ma trận phân vùng U_f và các trọng tâm chòm Θ . Trong đó, tiêu chuẩn dừng cho FCF là chênh lệch tuyệt đối tối đa giữa các phần tử của ma trận phân vùng $\mu^{(t)}$ và $\mu^{(t-1)}$ liên tiếp phải thấp hơn ngưỡng dương ε cho trước. Cuối cùng, ta có thể giải mờ theo quy tắc $c_i = \arg \max_i \mu_{ij}$. Tức là một hàm mật độ $f_j(x)$ được xếp vào chòm c_i khi và chỉ khi nó có mức độ phân vùng tại chòm đó là cao nhất.

Ví dụ 1.5 (Phân chùm mờ hàm Gauss 1-chiều). Ta sử dụng lại dãy hàm mật độ trong Ví dụ 1.4. Phân tích $\mathcal{F}$ thành ba chùm, biết $m = 2$ và khoảng cách là $\mathcal{L}_2$. Ta có kết quả sau khi thực hiện các vòng lặp được giải chi tiết ở Phụ lục (tr. 44).

Nhận xét. So với kết quả phân tích chùm KCF, kết quả của phân tích chùm FCF mang tính tổng quát hơn. Dựa vào giá trị phân vùng μ_{ij} , ta nhận thấy được mức độ tin cậy một hàm mật độ $f_j(x)$ xếp vào chùm c_i . Nếu giá trị phân vùng μ_{ij} tại chùm c_i này lớn, ta có thể chắc chắn vào kết quả phân bổ, ngược lại, nếu giá trị này không cao, ta biết được hàm mật độ này có khả năng thuộc vào một chùm khác hoặc một chùm mới thay vì thuộc vào chùm c_i .

So sánh về mặt phức tạp thời gian và phức tạp dung lượng, Bảng 1.6 cho thấy phương pháp k -mean đơn giản hơn và ít tốn tài nguyên tính toán hơn so với Fuzzy c -mean và thuật toán thứ bậc.

Bảng 1.6. So sánh độ phức tạp của ba thuật toán phân chùm

Thuật toán	Phức tạp thời gian	Phức tạp không gian
Phân chùm KCF	$\mathcal{O}(ncdi)$	$\mathcal{O}(n + cd)$
Phân cấp HCF	$\mathcal{O}(n^2 \log n)$	$\mathcal{O}(n^2)$
Phân chùm SUP		
Phân chùm FCF	$\mathcal{O}(ncdi)$	$\mathcal{O}(nc)$

Chú thích: n là # đối tượng trong dữ liệu, c là # chùm, d là # chiều dữ liệu, i là # vòng lặp.

1.8 Phân loại cho hàm mật độ xác suất

Ở dữ liệu rời rạc, bốn thuật toán phân loại kinh điển dựa vào thống kê là Naive Bayes, Cây quyết định, hồi quy Logistics, phân biệt Fisher [45] và Perceptron [46] đã được áp dụng phát triển cho đến hiện nay. Trong khi đó, các phát triển phân loại hàm mật độ chỉ dựa trên phương pháp Bayes. Luận văn này tập trung nghiên cứu phương pháp hồi quy logistics, máy véc-tơ hỗ trợ, và đặc biệt là phương pháp Bayes cho dữ liệu hàm mật độ [47, 48].

1.8.1 Hồi quy logistics

Phương pháp này được tổng quát hóa cho dữ liệu hàm bởi các nghiên cứu của Akturk et al. [49]. Luận văn này cụ thể hóa cho hàm mật độ xác suất. Mô hình hồi quy logistic cho dữ liệu hàm mật độ có dạng

$$\pi_j = \mathbb{P}(Y_j = 1 | f(x) = f_j(x)) = \frac{\exp\{\beta_0 + \int_{\Omega} f(x)\beta(x) dx\}}{1 + \exp\{\beta_0 + \int_{\Omega} f(x)\beta(x) dx\}}, \quad (1.6)$$

trong đó $\beta_0 \in \mathbb{R}$ là hằng số chặn, và $\beta(x) \in \mathcal{L}_2[\Omega]$ là hàm hệ số cần ước lượng. Để giải phương trình (1.6), biến đổi logit được sử dụng

$$\ell_j = \log \left(\frac{\pi_j}{1 - \pi_j} \right) = \beta_0 + \int_{\Omega} f(x) \beta(x) dx.$$

Mục tiêu tiếp theo là ước lượng β_0 và hàm $\beta(x)$. Do $\beta(x)$ là vô hạn chiều, ta chiếu hàm này vào một tập hàm cơ sở chọn trước để ước lượng, cụ thể là hàm Gauss, wavelet, chuỗi Fourier, đa thức Bernstein và Legendre, hoặc B-spline (Xem thêm Bảng 3.1 tại Phụ lục C, tr. 51). Khi đó,

$$\ell_j = \beta_0 + \sum_{m=1}^M \theta_m \underbrace{\int_{\Omega} \psi_m(x) f_j(x) dx}_{=: \Phi = \phi_{j,m}},$$

trong đó $\phi_{j,m}$ là mô-men của hàm mật độ $f_j(x)$ trên hàm cơ sở $\psi_m(x)$.

Bài toán ước lượng $\beta(x)$ chuyển thành cực đại hóa log-likelihood của hồi quy logistics

$$\ell(\beta_0, \beta(x)) = \max_{\substack{\beta_0 \in \mathbb{R}, \\ \beta(x) \in \mathbb{R}^M}} \left\{ \underbrace{\sum_{j=1}^n [y_j \log \pi_j + (1 - y_j) \log(1 - \pi_j)]}_{\text{Logistics}} - \underbrace{\lambda_1 \sum_{m=1}^M |\beta_m(x)|}_{\text{Lasso}} - \underbrace{\frac{\lambda_2}{2} \sum_{m=1}^M \beta_m(x)^2}_{\text{Ridge}} \right\},$$


trong đó, $\pi_j = \mathbb{P}(Y_j = 1 | f(x))$ và ℓ là hàm mất mát.

Định lý 1.13. *Hàm mất mát ℓ là một hàm lồi theo cả β_0 và $\beta(x)$. Nếu $\lambda_2 > 0$ thì hàm này lồi nghiêm ngặt. Vì vậy, nghiệm tối ưu toàn cục luôn tồn tại duy nhất.*

Từ Định lý 1.13, ta tính được Gradient theo hệ số $\beta(x)$ với $\hat{y}_j = \pi_j$ là xác suất dự đoán, có dạng $\nabla_{\beta} \ell = \Phi^T(y - \hat{y}) - \lambda_1 \text{sign}(\beta(x)) - \lambda_2 \beta$, mà qua đó ta có nhiều phương pháp tối ưu như tối ưu độ dốc như ADAM, hay các quasi-Newton khác như L-BFG-S.

Ví dụ 1.6 (Phân loại hàm mật độ bằng hồi quy logistic). Xét hai lớp hàm mật độ Gauss $\mathcal{F}$ và $\mathcal{G}$ với các trung tâm lần lượt là $\mu_{\mathcal{F}} = \{1, 0; 1, 5; 2, 0; 2, 5; 6, 0\}$, và $\mu_{\mathcal{G}} = \{4, 5; 7, 5; 8, 5; 8, 0; 9, 0\}$, trong đó phương sai lần lượt là $\sigma_{\mathcal{F}}^2 = 0, 4$ và $\sigma_{\mathcal{G}}^2 = 0, 9$. Bài toán đặt ra là phân loại một hàm mật độ Gauss mới $h(x) = \mathcal{N}(3, 0; 0, 9)$ vào một trong hai lớp $\mathcal{F}$ hoặc $\mathcal{G}$.

Sử dụng $M = 10$ hàm cơ sở Gauss, ta ước lượng được hàm hệ số $\hat{\beta}(x)$, phản ánh đóng góp của từng miền x đối với phân loại. Hàm $\hat{\beta}(x)$ được tái tạo và minh họa ở Hình 1.7.



Hình 1.7. Hàm $\hat{\beta}(x)$ được ước lượng qua 10 hàm cơ sở Gauss.

Tiếp theo, để phân loại h , ta cũng chiếu lên không gian cơ sở. Hàm h được chiếu lên 10 hàm cơ sở Gauss để tạo thành véc-tơ đặc trưng được đưa vào mô hình logistic đã huấn luyện. Cuối cùng, mô hình logistic dự đoán xác suất h thuộc lớp $\mathcal{F}$ là 43,26%. Do đó, ta phân loại $h(x)$ vào lớp $\mathcal{F}$.

Nhận xét. Hàm hệ số $\hat{\beta}(x)$ đóng vai trò như một công cụ giải thích quan trọng, cho phép đánh giá mức độ đóng góp của từng miền $x \in \Omega$ đối với quá trình phân loại nhị phân. Đáng chú ý, $\hat{\beta}(x)$ cung cấp một dạng giải thích bằng tính năng, giúp ta hiểu thêm nguồn gốc của từng đóng góp riêng lẻ đến xác suất phân loại.

Hình 1.7 cho thấy $\hat{\beta}(x)$ dao động quanh trục 0 với cả miền dương và âm, phản ánh rằng các vùng khác nhau của x có ảnh hưởng trái ngược đến xác suất dự đoán. Những vùng mà $\hat{\beta}(x) > 0$ sẽ tăng xác suất dự đoán lớp 1, và ngược lại. Cụ thể, các hệ số ψ_5 và ψ_8 có giá trị dương thể hiện tác động tăng xác suất dự đoán, trong khi ψ_3 và ψ_6 mang giá trị âm, góp phần làm giảm xác suất của lớp $\mathcal{F}$. Việc áp dụng các kỹ thuật chuẩn hoá Ridge làm giảm hệ số một cách đồng đều, còn Lasso tạo ra sự chọn lọc hàm cơ sở ψ_m quan trọng.

1.8.2 Máy véc-tơ hỗ trợ

Cho tập huấn luyện $\mathcal{D} = \{(f_j, y_j)\}_{j=1}^n, f_j \in \mathcal{F}, y_j \in \{-1, 1\}$. Bài toán máy véc-tơ hỗ trợ lồi mềm được xây dựng từ nguyên lý cực tiểu hoá độ lớn véc-tơ trọng số w và cho phép sai

số điều chỉnh được bởi các biến ξ_j , tức là

$$\begin{aligned} \text{Maximise : } & \frac{1}{2} \|\mathbf{w}\|_{\mathcal{H}}^2 + C \sum_{j=1}^n \xi_j, \\ \text{S.t. : } & y_j (\langle \mathbf{w}, \Phi(f_j) \rangle + b) \geq 1 - \xi_j, \\ & \xi_j \geq 0, \quad j = 1, \dots, n. \end{aligned}$$

Hàm L'Agrange tương ứng được cho bởi

$$\mathcal{L}(\mathbf{w}, b, \xi, \alpha, \mu) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{j=1}^n \xi_j - \sum_{j=1}^n \alpha_j [y_j (\langle \mathbf{w}, \Phi(f_j) \rangle + b) - (1 - \xi_j)] - \sum_{j=1}^n \mu_j \xi_j.$$

Lấy đạo hàm theo $\mathbf{w}$ và đặt $\nabla_{\mathbf{w}} \mathcal{L} = 0$. ta có $\mathbf{w} = \sum_{j=1}^n \alpha_j y_j \Phi(f_j)$. Thay vào hàm L'Agrange, ta được bài toán đối ngẫu của SVM được định nghĩa bởi

$$\begin{aligned} \text{Maximise : } & \sum_{j=1}^n \alpha_j - \frac{1}{2} \sum_{j=1}^n \sum_{k=1}^n \alpha_j \alpha_k y_j y_k \underbrace{\langle \Phi(f_j), \Phi(f_k) \rangle}_{K(f_j, f_k)}, \quad (\text{SVM}) \\ \text{S.t. : } & 0 \leq \alpha_j \leq C, \quad \sum_{j=1}^n \alpha_j y_j = 0. \quad (1.7) \end{aligned}$$

Định lý 1.14. SVM là bài toán tối ưu lồi nghiêm ngặt trên đa diện lồi compact, do đó tồn tại duy nhất nghiệm véc-tơ $\alpha^* \in \mathbb{R}^n$.

Chứng minh. Ma trận Gram $\mathbf{G}_{jk} = y_j y_k K(f_j, f_k)$ là xác định dương do K là kernel thỏa mãn điều kiện Mercer. Hàm mục tiêu là hiệu của một hàm tuyến tính và một dạng toàn phương xác định dương nên lồi nghiêm ngặt. Nhờ đó, tồn tại nghiệm cực đại duy nhất theo định lý Weierstrass.

Định lý 1.15. Tại nghiệm α^* , khoảng cách đến siêu phẳng tối ưu là

$$\rho = \frac{1}{\|\mathbf{w}\|} = \left(\sum_{j=1}^n \sum_{k=1}^n \alpha_j^* \alpha_k^* y_j y_k K(f_j, f_k) \right)^{-1/2}.$$

Khi đó, hàm phân lớp tương ứng đối với hàm mật độ mới h là

$$\hat{y}(h) = \text{sign}(g(h)) = \text{sign} \left(\sum_{j=1}^n \alpha_j^* y_j K(f_j, h) + b^* \right).$$

1.8.3 Phương pháp naive Bayes

a Thuật toán phân lớp

Phương pháp Bayes đã được nhiều nhà thống kê quan tâm cho dữ liệu hàm mật độ xác suất tại []. Một dữ liệu hàm mật độ có hai lớp $Y = 0$ hoặc 1 và một hàm mới $h(x)$ cần phân loại. Khi đó, xác suất hậu nghiệm Bayes để xếp hàm mật độ h vào một trong hai lớp này là

$$\mathbb{P}(\mathcal{F} | h) = \frac{\mathbb{P}(\mathcal{F}) f(h | \mathcal{F})}{\mathbb{P}(\mathcal{F}) f(h | \mathcal{F}) + \mathbb{P}(\mathcal{G}) f(h | \mathcal{G})}, \text{ và } \mathbb{P}(\mathcal{G} | h) = 1 - \mathbb{P}(\mathcal{F} | h).$$

Khi này ta có quy tắc phân loại hàm mật độ $h(x)$, giả sử không có thông tin tiên nghiệm, ta lấy $\mathbb{P}(\mathcal{F}) = \mathbb{P}(\mathcal{G}) = 1/2$, hàm mật độ h được phân loại vào lớp $\mathcal{F}$ nếu $f(h|\mathcal{F}) > f(h|\mathcal{G})$ và ngược lại. Với nhiều lớp, ta tổng quát

$$\mathbb{P}(c_k|h) = \frac{\mathbb{P}(c_k)f(h|c_k)}{\sum_i \mathbb{P}(c_i)f(h|c_i)},$$

và phân loại h vào lớp c_k nào có xác suất hậu nghiệm lớn nhất, $c_i = \arg \max_i \mathbb{P}(c_i|h)$.

b Xác định tiên nghiệm

Trong bài toán phân loại Bayes, xác suất tiên nghiệm $\mathbb{P}(c_k)$ thường được ước lượng bằng nhiều cách khác nhau, thông thường là dựa vào kiến thức chuyên gia hoặc thông tin trong lịch sử nghiên cứu tương tự hoặc dữ liệu lớn. Trong trường hợp không có thông tin tiên nghiệm nào, ta có thể giả định mọi lớp đều có xác suất bằng nhau, tức là $\mathbb{P}(c_k) = 1/k$. Trong nhiều tình huống, xác suất tiên nghiệm còn có thể ước lượng từ tần suất xuất hiện của các lớp trong tập dữ liệu huấn luyện. Khi đó, $\mathbb{P}(c_k) = n_k/n$ trong đó n_k là số lượng mẫu thuộc lớp c_k và n là tổng số mẫu. Tuy nhiên, phương pháp này có thể gặp vấn đề khi dữ liệu ít hoặc có xác suất bằng 0 cho một số lớp, phương pháp Laplace được sử dụng để điều chỉnh, $\mathbb{P}(c_k) = (n_k + \alpha)/(n + \alpha k)$, trong đó $\alpha > 0$ và k là số lớp.

Tổng kết Chương 1

Chương 1 trình bày cơ sở lý thuyết của hàm mật độ xác suất, các phép đo khoảng cách và phương pháp phân tích chùm/phân loại. Những kiến thức này đóng vai trò nền tảng cho các chương tiếp theo.

CHƯƠNG 2

NHẬN DẠNG THÔNG KÊ CHO HÀM MẬT ĐỘ XÁC SUẤT VỚI DỮ LIỆU MẤT CÂN BẰNG

2.1 Giới thiệu

Hàm mật độ xác suất được xem là dạng dữ liệu đặc trưng với cấu trúc phức tạp hơn. Phần lớn các công trình hiện nay tập trung vào mô phỏng chùm hàm mật độ [22, 48]. Trong thực tiễn, dữ liệu 1-chiều cho phép khám phá quy luật phân bố, chẳng hạn nghiên cứu về Cá hồi vây vàng (*Yellowfin tuna*) của [50] đã thể hiện phân bố chiều dài cá theo từng ô tọa độ tại Thái Bình Dương. Bên cạnh đó, các phân phối liên quan đến phân phối tỷ giá theo ngày, khí hậu ở các trạm theo năm, hay mật độ tuổi giữa hai giới, chỉ số sức khỏe theo độ tuổi [51, 52] cũng là ví dụ tiêu biểu cho dạng 1-chiều. Đặc biệt, dữ liệu hàm mật độ còn có thể được xây dựng từ hình ảnh thông qua việc trích xuất màu sắc [12, 48]. Trong khi đó, dữ liệu 2-chiều thường xuất hiện trong các nghiên cứu về mối tương quan, ví dụ phân tích điểm số sinh viên giữa các khoa/viện tại Đại học Cần Thơ [20]. Tuy vậy, và quá trình thu thập thường mất nhiều thời gian. Hơn nữa, không gian vô hạn chiều khiến ước lượng khó lưu trữ. Do đó, nhiều phương pháp tiếp cận mới từ nhận dạng thông kê đã giải quyết nhu cầu phân tích dạng dữ liệu này đối với thực tế. Chúng bao gồm phân tích chùm và phân loại hàm mật độ xác suất.

2.1.1 Phương pháp phân tích chùm hàm mật độ xác suất

Phân tích chùm là một nhánh chính của nhận dạng không được giám sát [34–36]. Nó có nhiệm vụ khám phá dựa vào sự tương tự giữa các mẫu trong dữ liệu đầu vào [5, 9]. Ví dụ như khi ta cần khoanh vùng khối u trong hình ảnh MRI, hay trong các báo cáo định tính cần nhóm/tổng hợp ý kiến hay quan điểm theo các chủ đề khác nhau. Nhiều họ các phân chùm có cách phân chia khác nhau, nhưng mục tiêu chung là sự phân bố tối thiểu khoảng cách phần tử trong chùm trong khi vẫn giữ tối đa khoảng cách phần tử giữa các chùm. Các thuật toán này được chia thành hai loại dựa theo lý thuyết mờ [37] là phân chùm không mờ (bao gồm k -mean [12], phân cấp thứ bậc và phân chùm tự cập nhật) và phân chùm mờ (bao gồm Fuzzy c -means [19, 20]).

Trong nước, Bảng 2.1 cho thấy ba xu thế nổi bật: (i) dịch chuyển từ mô hình cứng sang

mờ/khả dĩ và bán giám sát; (ii) từ độ đo hình học đơn giản sang độ đo thích nghi không gian hàm mật độ; và (iii) từ c -chùm cố định sang tự động hoá nhờ tối ưu hoá metaheuristic. Giai đoạn khởi đầu (2019) tập trung vào phân chùm cứng với độ đo chuyên biệt CWD [20], song đã sớm mở rộng bằng các chiến lược tiến hoá (DE) để vừa phân chùm vừa xác định số chùm. Từ 2020–2021, các phương pháp mờ và entropy xuất hiện, khai thác đa dạng độ đo ($\mathcal{L}_1$, $\mathcal{L}_2$, kernel Gauss) nhằm nắm bắt khác biệt hình dạng của phân bố. Trong giai đoạn 2022–2023, các tiếp cận mờ được củng cố bởi mục tiêu cân bằng và đa mục tiêu [23], đồng thời được tích hợp metaheuristic cải tiến [22], hướng đến tự động hóa toàn diện. Đến năm 2024, hai nhánh mới được ghi nhận bao gồm phân tích chùm khả dĩ nhằm tăng cường khả năng nhận diện ngoại lệ và hướng mờ bán giám sát khai thác nhãn hạn chế để nâng cao ổn định khi ranh giới chùm chồng lấp.

Năm	Loại mô hình	Phương pháp	Khoảng cách	Tự động số chùm
[20] 2019	Cứng	k-Medoids	CWD-based	Không
2019	Phân chùm cứng	Binary elitist DE	$\mathcal{L}_2$	Có
2020	Phân chùm mờ	Genetic Alg.	$\mathcal{L}_1$	Có
2020	Entropy	Jackknife entropy	$\mathcal{L}_1$ Kernel Gauss	Không
2021	Phân chùm mờ	Kernel K-Medoids	$\mathcal{L}_1$, Kernel Gauss	Không
[23] 2022	Phân chùm mờ	Balance-driven + MO	$\mathcal{L}_2$	Có
2023	Phân chùm mờ	Prototype-based DE	$\mathcal{L}_1$ Kernel Gauss	Có
[22] 2023	Phân chùm mờ	GA cải tiến	$\mathcal{L}_1$	Có
2024	phân chùm khả dĩ	Possibilistic objective	$\mathcal{L}_2$	Không
2024	Phân chùm mờ bán giám sát	Fuzzy + bán giám sát	$\mathcal{L}_1$	Có

Bảng 2.1. Tổng quan lịch sử nghiên cứu phân tích chùm cho hàm mật độ xác suất

2.1.2 Phương pháp phân loại hàm mật độ xác suất

Phương pháp phân loại là một nhánh của nhận dạng có giám sát, phát triển với mục tiêu thành lập quy tắc quy nạp có chức năng phân tách được các lớp quan tâm với sai lầm thực nghiệm tối thiểu. Các quy luật đánh giá có bệnh B hay không dựa vào những dữ liệu cho trước chính là thực hiện bài toán phân loại. Hay phân biệt được hữu hạn các biểu cảm khuôn mặt dựa vào hình ảnh cũng phải thực hiện bài toán phân loại. Đầu ra của mô hình phân loại là ước tính hoặc dự đoán hữu hạn các nhãn cho trước (không đo được) với dữ liệu mới chưa được mô hình hóa [53].

Trong bài toán phân loại, ta giả sử tồn tại một không gian đầu vào $\mathcal{F}$ và tập nhãn rời rạc $Y = \{1, 2, \dots, C\}$. Cặp dữ liệu (f, y) là biến ngẫu nhiên có phân phối chung $P_{\mathcal{F}, Y}$ trên $\mathcal{F} \times Y$. Mục tiêu của bài toán là tìm một ánh xạ phân loại $h : \mathcal{F} \rightarrow Y$ thuộc không gian giả thuyết $\mathcal{H}$ sao cho tối thiểu hóa giá trị kỳ vọng của hàm mất mát $\ell : Y \times Y \rightarrow \mathbb{R}_{\geq 0}$, tức là $h^* = \arg \min_{h \in \mathcal{H}} \mathbb{E}(f, y) \sim P_{\mathcal{F}, Y} [\ell(h(f), y)]$. Tuy nhiên, do phân phối thực $P_{\mathcal{F}, Y}$ là chưa biết,

ta cần tiếp cận qua một tập huấn luyện $\mathcal{D}_n = \{(f_1, y_1), \dots, (f_n, y_n)\} \subset \mathcal{F} \times Y$. Vì vậy, ta giải bài toán

$$\hat{h}_n = \arg \min_{h \in \mathcal{H}} \frac{1}{n} \sum_{j=1}^n \ell(h(f_j), y_j).$$

Phương pháp phân loại cho hàm mật độ xác suất là một bài toán mới mẻ nên còn nhiều thách thức lớn cả bề sâu và bề rộng [].

Nhìn chung cho đến nay, hai phương pháp chính để phân loại là từ hai góc nhìn. Xem hàm mật độ là một véc-tơ hữu hạn chiều hay hàm vô hạn chiều.

2.2 Giới thiệu bài toán phân tích chùm cho dữ liệu mất cân bằng

Phân tích chùm cho dữ liệu mất cân bằng là chủ đề phát triển để giải quyết nhu cầu thực tế. Bài toán khoanh vùng hình ảnh hòn đảo giữa đại dương được ghi nhận là có sự mất cân bằng, hay phân đoạn chuỗi tín hiệu hiếm như động đất cũng có tính chất mất cân bằng hơn tín hiệu nền yên tĩnh. Dữ liệu lúc này có sự chênh lệch lớn giữa các loại trong tự nhiên và tồn tại hai tình trạng: Kích thước chùm và số lượng phần tử trong chùm mất cân bằng. Kích thước chùm mất cân bằng xảy ra khi các chùm có độ phân tán khác biệt đáng kể về đường kính hoặc mật độ. Trong khi đó, mất cân bằng số lượng khi tổng mẫu chùm chênh lệch lớn.

Trong lĩnh vực phân tích chùm, để giải quyết vấn đề mất cân bằng tự nhiên, đa số phương pháp tập trung cải thiện thuật toán, trong khi các phương pháp tăng cường mẫu ít được áp dụng do khó xác định chùm tiềm ẩn. Ở dữ liệu rời rạc, thuật toán phân tích chùm mất cân bằng đã được giải quyết rất tốt.

Tuy nhiên, các thuật toán này thường giả định các chùm có cùng kích thước [54]. Khi có sự khác biệt lớn về số lượng phần tử hoặc kích thước chùm không đồng đều, các thuật toán phân chùm phân vùng có xu hướng tạo ra độ lệch trọng tâm đáng kể đối với các chùm có kích thước nhỏ [55].

2.2.1 Thuật toán

2.2.2 Sự hội tụ của thuật toán

2.2.3 Tham số đánh giá chất lượng

Đánh giá phân tích chùm cho biết độ hiệu quả thực thi của thuật toán bao gồm độ chính xác và độ phù hợp với thực tế. Các chỉ số đánh giá hiệu suất chùm (CVI) được sử dụng để đánh giá mối quan hệ giữa các thuộc tính của chùm đã hình thành bao gồm tính kết nối, tính gắn kết, tính đối xứng và tính tách biệt [56]. Đánh giá kết quả phân tích chùm diễn ra trong hai trường hợp: đánh giá bên trong và bên ngoài. Tiêu chí đánh giá ngoài cung cấp độ chính

xác giữa nhãn thực tế và nhãn kết quả của phân tích chùm trong các ví dụ mô phỏng. Nhưng trong thực tế, ta không có thông tin chính xác của nhãn nên phải đánh giá nội bộ. Đánh giá nội bộ cung cấp độ phù hợp của các chùm trong dữ liệu chưa được gán nhãn.


a. Đánh giá bên trong

Chỉ số Silhouette Chỉ số Silhouette $S = \text{mean}(s(f_j))$ đo mức độ phù hợp của một hàm mật độ f_j với chùm mà nó được gán nhãn, so với chùm gần nhất khác, trong đó $s(f_j) = \frac{b(f_j) - a(f_j)}{\max\{a(f_j), b(f_j)\}}$, với $a(f_j) = \frac{1}{|c_k| - 1} \sum_{\substack{f \in c_k \\ f \neq f_j}} D(f_j, f)$ là khoảng cách trung bình giữa f_j và tất cả các hàm mật độ khác trong chùm c_k chứa nó, và $b(f_j) = \min_{l \neq k} \frac{1}{|c_l|} \sum_{f \in c_l} D(f_j, f)$ là khoảng cách trung bình giữa f_j và các hàm mật độ trong chùm gần nhất c_l với $l \neq k$.

Chỉ số Dunn Chỉ số Dunn đánh giá mức độ tách biệt giữa các chùm, được định nghĩa bởi $D = \frac{\min_{k \neq l} \Delta_{\min}(c_k, c_l)}{\max_m \Delta(c_m)}$, trong đó, $\Delta_{\min}(c_k, c_l) = \min_{\substack{f \in c_k \\ g \in c_l}} D(f, g)$ là liên kết nhỏ nhất giữa hai chùm c_k và c_l , và $\Delta(c_m) = \max_{f, g \in c_m} D(f, g)$ là đường kính lớn nhất của chùm c_m .

Chỉ số Davies–Bouldin Chỉ số Davies–Bouldin đo mức độ tương đồng giữa các chùm, được định nghĩa bởi $DI = \frac{1}{K} \sum_{k=1}^K \max_{l \neq k} \left\{ \frac{S_k + S_l}{D(\theta_k, \theta_l)} \right\}$, trong đó, $S_k = \frac{1}{|c_k|} \sum_{f \in c_k} D(f, \theta_k)$ là độ phân tán trung bình của chùm c_k , θ_k là trọng tâm của chùm c_k , $D(\theta_k, \theta_l)$ là khoảng cách giữa hai trọng tâm θ_k và θ_l và k là số chùm.

Chỉ số Silhouette và Dunn có giá trị càng nhỏ, kết quả phân tích chùm càng tốt. Ngược lại, chỉ số Davies–Bouldin càng nhỏ càng tốt. Ngoài ra, hệ số tương tự chùm (Bảng 1.5) cũng đã được xem như một chỉ số bên ngoài để đánh giá sự tương tự của hai chùm hàm mật độ [33].



Chú thích: Hình ở trên thể hiện chỉ số Silhouette và Dunn vì chúng càng lớn càng tốt. Ngược lại, chỉ số DBI càng nhỏ càng tốt. Điểm khuỷu tay là điểm mà ở đó độ dốc giữa hai dãy cụm bất kỳ đạt cực đại. Ở đây, ta thấy chỉ số Silhouette và DBI đều đề xuất k -cụm tối ưu là $k = 3$. Trong khi đó, chỉ số Dunn cho kết quả $k = 6$.

Hình 2.1. Một số chỉ số đánh giá và số cụm tối ưu được đề xuất từ phương pháp khuỷu tay với dữ liệu hàm mật độ ở Ví dụ 1.4.

b. Đánh giá bên ngoài

Đánh giá bên ngoài được sử dụng khi có nhãn thực tế $\mathcal{P} = \{\mathcal{F}_1, \dots, \mathcal{F}_R\}$ của tập hàm mật độ $\mathcal{F} = \{f_1, \dots, f_n\}$ và kết quả phân cụm $\mathcal{G} = \{\mathcal{G}_1, \dots, \mathcal{G}_K\}$. Xét các cặp (f_i, f_j) , ta có các trường hợp

$$\begin{aligned}
 a &= \#\{(f_i, f_j) \mid f_i, f_j \in \mathcal{F}_r \cap \mathcal{G}_k\}, \\
 b &= \#\{(f_i, f_j) \mid f_i, f_j \in \mathcal{F}_r, f_i \in \mathcal{G}_k, f_j \in \mathcal{G}_l, k \neq l\}, \\
 c &= \#\{(f_i, f_j) \mid f_i, f_j \in \mathcal{G}_k, f_i \in \mathcal{F}_r, f_j \in \mathcal{F}_s, r \neq s\}, \\
 d &= \#\{(f_i, f_j) \mid f_i \in \mathcal{F}_r \cap \mathcal{G}_k, f_j \in \mathcal{F}_s \cap \mathcal{G}_l, r \neq s, k \neq l\}.
 \end{aligned}$$

Rand Index Rand Index đo mức độ tương đồng giữa $\mathcal{P}$ và $\mathcal{G}$. Ta có $RI = 1$ nếu phân cụm trùng hoàn toàn với nhãn thực tế, được định nghĩa là $RI = \frac{a+d}{a+b+c+d}$,

Adjusted Rand Index ARI hiệu chỉnh RI để loại bỏ trùng khớp ngẫu nhiên. $ARI = \frac{RI - \mathbb{E}(RI)}{\max(RI) - \mathbb{E}(RI)}$,

Fowlkes–Mallows Index Đo độ tương đồng cặp đúng/sai $FMI = \sqrt{\frac{a}{a+b} \cdot \frac{a}{a+c}}$

Jaccard Index Tỷ lệ cặp cùng một cụm so với tổng cặp liên quan $J = \frac{a}{a+b+c}$

Normalized Mutual Information NMI đo mức độ phụ thuộc giữa hai phân hoạch $\mathcal{P}$ và $\mathcal{Q}$,

$$NMI = \frac{2I(\mathcal{P}, \mathcal{Q})}{H(\mathcal{P}) + H(\mathcal{Q})},$$

trong đó, với $p_i = \frac{\#\mathcal{F}_i}{n}$, $p_j = \frac{\#\mathcal{G}_j}{n}$, $p_{ij} = \frac{\#(\mathcal{F}_i \cap \mathcal{G}_j)}{n}$, ta có, $I(\mathcal{P}, \mathcal{Q}) = \sum_{i,j} p_{ij} \log \frac{p_{ij}}{p_i p_j}$, với $H(\mathcal{P}) = -\sum_i p_i \log p_i$, $H(\mathcal{Q}) = -\sum_j p_j \log p_j$.

2.2.4 Ví dụ minh họa

2.3 Giới thiệu bài toán phân loại cho dữ liệu mất cân bằng

Trong ngữ cảnh dữ liệu dạng hàm mật độ xác suất, mất cân bằng không chỉ đến từ số lượng phân phối mẫu không đồng đều mà còn từ sự khác biệt về dạng phân phối, độ phân tán và độ cao của các đỉnh hàm. Điều này đặt ra nhu cầu phát triển các phương pháp phân loại đặc thù, có khả năng cân nhắc cả hình dạng và độ chênh lệch giữa các hàm mật độ trong quá trình học và đánh giá.

2.3.1 Thuật toán

2.3.2 Sự hội tụ của thuật toán

2.3.3 Tham số đánh giá chất lượng

Đối với thuật toán phân loại, ta đánh giá kết quả dự đoán thông qua độ chính xác của mô hình trên tập dữ liệu chưa được huấn luyện. Kết quả phân loại thường được tóm tắt trong ma trận nhầm lẫn, thể hiện số lượng dự đoán đúng và sai của mô hình. Giả sử ta có một bài toán phân loại nhị phân với hai lớp { Dương tính, Âm tính }. Ma trận nhầm lẫn có dạng

	Dự đoán dương tính	Dự đoán âm tính
Thực tế dương tính	Dương tính thật ($\#TP$)	Âm tính thật ($\#FN$)
Thực tế âm tính	Dương tính giả ($\#FP$)	Âm tính giả ($\#TN$)

Từ ma trận nhầm lẫn, ta định nghĩa các chỉ số phổ biến khác. Các chỉ số trong Bảng 2.2 cung cấp cơ sở định lượng cho việc đánh giá hiệu năng mô hình,

Bảng 2.2. Mô tả các chỉ số đánh giá phân loại

Chỉ số	Công thức	Ý nghĩa	Phạm vi
Độ chính xác (ACC)	$\frac{\#TP + \#TN}{\#TP + \#TN + \#FP + \#FN}$	Tỷ lệ dự đoán đúng trên tổng số mẫu	[0, 1]
Độ nhạy (PRE)	$\frac{\#TP}{\#TP + \#FP}$	Tỷ lệ mẫu được dự đoán dương tính thật	[0, 1]
Độ chuyên, TPR (REC)	$\frac{\#TP + \#FN}{2 \cdot \text{Precision} \cdot \text{Recall}}$	Tỷ lệ nhận diện đúng dương tính	[0, 1]
F1-score	$\frac{\text{Precision} + \text{Recall}}{\#FP}$	Trung bình điều hoà giữa Precision và Recall	[0, 1]
FPR	$\frac{\#FP + \#TN}{\#FP + \#TN}$	Tỷ lệ dự đoán sai âm tính thành dương tính	[0, 1]
AUC-ROC	$\int_0^1 \text{TPR}(\text{FPR}) d\text{FPR}$	Diện tích dưới đường cong ROC	[0, 1]
AUC-PR	$\int_0^1 \text{Precision}(\text{Recall}) d\text{Recall}$	Diện tích dưới đường cong Precision-Recall	[0, 1]

Nhận xét. Các chỉ số này định lượng hình thức, nhưng không phải chất lượng và tính tin cậy. Ma trận nhầm lẫn cung cấp thông tin về số lượng dự đoán đúng/sai tại một ngưỡng, nhưng không đánh giá tính hợp lý của bằng chứng nó nhận biết. Ian van der Linde (2025) nhấn mạnh *một mô hình có thể dự đoán đúng và có bằng chứng nhưng dựa trên đặc trưng hoặc bằng chứng không liên quan sẽ dẫn đến kết quả dù đúng nhưng không thể coi là quy luật tổng quát* [57].

Độ chính xác (Accuracy) tuy trực quan và dễ diễn giải nhưng chỉ đưa ra tỷ lệ tổng quát các dự đoán đúng, bỏ qua cấu trúc mất cân bằng giữa các lớp và không phản ánh mức độ rủi ro gắn với từng lỗi. Trong các bài toán mà sai lầm ở một lớp có hậu quả lớn, F1-score và AUC-ROC được ưu tiên vì chúng thể hiện sự cân bằng giữa Precision và Recall, cũng như khả năng phân biệt mô hình qua toàn bộ miền ngưỡng. Đặc biệt với dữ liệu mất cân bằng, hai chỉ số AUC-PR và F1-score thường cho hiệu quả tốt hơn Accuracy hoặc AUC-ROC [58].

Do vậy, để đánh giá mô hình một cách đầy đủ và tin cậy, cần kết hợp nhiều thước đo. Quan trọng hơn, việc tối ưu hiệu năng đi kèm với chú trọng giải thích lý do dự đoán [59, 60], thông qua giải thích-AI (XAI), tương tác người dùng và tiêu chuẩn đánh giá phù hợp, sẽ nâng cao độ tin cậy và giá trị ứng dụng thực tiễn của mô hình.

2.3.4 Ví dụ minh họa

Tổng kết chương 2

CHƯƠNG 3

ỨNG DỤNG CHO DỮ LIỆU HÌNH ẢNH

3.1 Trích xuất đặc trưng của hình ảnh thành hàm mật độ xác suất

3.1.1 Vấn đề trích xuất đặc trưng của hình ảnh

3.1.2 Ước lượng hàm mật độ xác suất đại diện cho hình ảnh

Ước lượng hàm mật độ là bài toán phái sinh khi dữ liệu cần được chuyển thành dữ liệu hàm mật độ.

3.2 Ứng dụng của bài toán phân tích chùm

3.2.1 Dữ liệu

3.2.2 Phương pháp thực hiện

3.2.3 Kết quả thực hiện

3.3 Ứng dụng của bài toán phân loại

3.3.1 Dữ liệu

3.3.2 Phương pháp thực hiện

3.3.3 Kết quả thực hiện

3.4 Bàn luận

3.4.1 Về thuật toán phân tích chùm các hàm mật độ xác suất

Phân tích chùm phân vùng dựa vào trọng tâm rất đơn giản. Tuy nhiên, nó cũng có một số khuyết điểm bao gồm tính không xác định của các siêu tham số, chất lượng dữ liệu đầu vào và khả năng giải thích của mô hình. Đầu tiên, họ thuật toán này không cung cấp c chùm tối ưu. Đôi khi, ta không có tri thức về số lượng c , dẫn đến khó khăn khi phân chùm các mẫu có số chiều lớn [61], và nguy cơ quá khớp. Theo Goutte *et al.*, “*khi số lượng chùm không phản ánh trong dữ liệu, kết quả cuối cùng cơ bản là vô nghĩa*” [62]. Ngoài ra, do giả định tối ưu lỗi, thuật toán dựa trên trọng tâm thường hoạt động hiệu quả nhất với hình dạng gần cầu, và có thể gặp thách thức khi áp dụng cho dữ liệu chứa nhiễu, ngoại lệ, có chồng lấp giữa các chùm hoặc

có sự chênh lệch lớn về kích thước và mật độ. Cuối cùng, hàm mật độ trọng tâm chùm ban đầu cũng ảnh hưởng đến kết quả tối ưu dù đã có nhiều khuyến nghị như k -means⁺⁺, X-means.

Ngược lại, phân tích chùm thứ bậc không đòi hỏi tiên nghiệm về số chùm, nhưng chi phí tính toán cao, đặc biệt với dữ liệu lớn khi cần tính toàn bộ ma trận khoảng cách

Tóm lại, các thuật toán phân tích chùm mang lại tiềm năng lớn trong việc khám phá các cấu trúc ẩn và những mối quan hệ có ý nghĩa giữa các mẫu dữ liệu, từ đó hỗ trợ các phân tích chuyên sâu và mở ra nhiều ứng dụng tiềm năng [12, 19]. Mặc dù kết quả của các thuật toán phân tích chùm có thể chịu ảnh hưởng bởi dữ liệu đầu vào, thể loại tự nhiên và lựa chọn thuật toán, chúng vẫn đóng vai trò là công cụ mạnh mẽ giúp người dùng nhận diện và diễn giải các mẫu tốt hơn. Qua đó, *các loại tự nhiên có là những gì thuật toán phân chùm phần nào hướng đến trong điều kiện lý tưởng không* là một chủ đề nghiên cứu đầy hứa hẹn, tiếp tục được quan tâm và mở rộng trong cộng đồng khoa học thống kê [38, 63–65].

Tổng kết chương 3

PHẦN KẾT LUẬN

- Tổng kết các vấn đề đã thực hiện trong đề cương;
- Đánh giá những khó khăn, hạn chế của các mô hình về mặt lý thuyết và ứng dụng;
- Đưa ra những định hướng có thể phát triển trong tương lai

1 Kết luận

Trí tuệ nhân tạo là trọng tâm, là mũi đột phá chính của phát triển khoa học công nghệ, đổi mới sáng tạo và chuyển đổi số.

2 Định hướng nghiên cứu

TÀI LIỆU THAM KHẢO

- [1] A. Belhadi, V. Mani, S. S. Kamble, S. A. R. Khan, and S. Verma, “Artificial intelligence-driven innovation for enhancing supply chain resilience and performance under the effect of supply chain dynamism: an empirical investigation,” *Annals of Operations Research*, vol. 333, no. 2, pp. 627–652, 2024.
- [2] A. I. Act, “Artificial intelligence act,” *Euroopan unioni. Luettavissa: <https://artificialintelligen>*, 2023.
- [3] T. Mollema, “‘ai colonialism’ is a conceptual metaphor,” Master’s thesis, 2024.
- [4] P. K. Dey, S. Chowdhury, A. Abadie, E. Vann Yaroson, and S. Sarkar, “Artificial intelligence-driven supply chain resilience in vietnamese manufacturing small-and medium-sized enterprises,” *International Journal of Production Research*, vol. 62, no. 15, pp. 5417–5456, 2024.
- [5] C. M. Bishop and H. Bishop, *Deep Learning: Foundations and Concepts*. Springer, 2024.
- [6] S. Theodoridis and K. Koutroumbas, *Pattern recognition*. Elsevier, 2006.
- [7] J. C. Bezdek, R. Ehrlich, and W. Full, “Fcm: The fuzzy c -means clustering algorithm,” *Computers & geosciences*, vol. 10, no. 2-3, pp. 191–203, 1984.
- [8] J. Macqueen, “Some methods for classification and analysis of multivariate observations,” in *Proceedings of 5-th Berkeley Symposium on Mathematical Statistics and Probability/University of California Press*, 1967.
- [9] A. R. Webb, *Statistical pattern recognition*. John Wiley & Sons, 2003.
- [10] D. Zha, Z. P. Bhat, K.-H. Lai, F. Yang, Z. Jiang, S. Zhong, and X. Hu, “Data-centric artificial intelligence: A survey,” *arXiv preprint arXiv:2303.10158*, 2023.
- [11] C. Cortes, “Support-vector networks,” *Machine Learning*, 1995.
- [12] T. Nguyen-Trang, Y. Nguyen-Hoang, and T. Vo-Van, “A new semi-supervised clustering algorithm for probability density functions and applications,” *Neural Computing and Applications*, vol. 36, no. 11, pp. 5965–5980, 2024.
- [13] X. Hu, H. Chen, J. Zhang, H. Chen, S. Liu, X. Li, Y. Wang, and X. Xue, “Gat-cobo: Cost-sensitive graph neural network for telecom fraud detection,” *IEEE Transactions on Big Data*, 2024.

- [14] G. H. Nguyen, A. Bouzerdoum, and S. L. Phung, "Learning pattern classification tasks with imbalanced data sets," *Pattern recognition*, vol. 10, no. 2009, pp. 1322–1328, 2009.
- [15] Y. Tang, Y.-Q. Zhang, N. V. Chawla, and S. Krasser, "Svms modeling for highly imbalanced classification," *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)*, vol. 39, no. 1, pp. 281–288, 2008.
- [16] T. Vo Van and T. Pham-Gia, "Clustering probability distributions," *Journal of Applied Statistics*, vol. 37, no. 11, pp. 1891–1910, 2010.
- [17] F. Gullo, G. Ponti, A. Tagarelli, and S. Greco, "A hierarchical algorithm for clustering uncertain data via an information-theoretic approach," in *2008 Eighth IEEE International Conference on Data Mining*, pp. 821–826, IEEE, 2008.
- [18] A. Azzalini, "A class of distributions which includes the normal ones," *Scandinavian journal of statistics*, pp. 171–178, 1985.
- [19] T. Nguyentrang and T. Vovan, "Fuzzy clustering of probability density functions," *Journal of Applied Statistics*, vol. 44, no. 4, pp. 583–601, 2017.
- [20] T. Vovan, "Cluster width of probability density functions," *Intelligent Data Analysis*, vol. 23, no. 2, pp. 385–405, 2019.
- [21] A. Wald, "Statistical decision functions," in *Breakthroughs in Statistics: Foundations and Basic Theory*, pp. 342–357, Springer, 1950.
- [22] T. Nguyen-Trang, T. Nguyen-Thoi, and T. Vo-Van, "Globally automatic fuzzy clustering for probability density functions and its application for image data," *Applied Intelligence*, vol. 53, no. 15, pp. 18381–18397, 2023.
- [23] T. Nguyen-Trang, T. Nguyen-Thoi, K.-N. Nguyen-Thi, and T. Vo-Van, "Balance-driven automatic clustering for probability density functions using metaheuristic optimization," *International Journal of Machine Learning and Cybernetics*, vol. 14, no. 4, pp. 1063–1078, 2023.
- [24] M. Fréchet, "Les éléments aléatoires de nature quelconque dans un espace distancié," in *Annales de l'institut Henri Poincaré*, vol. 10, pp. 215–310, 1948.
- [25] S. M. Ali and S. D. Silvey, "A general class of coefficients of divergence of one distribution from another," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 28, no. 1, pp. 131–142, 1966.
- [26] T. Kailath, "The divergence and bhattacharyya distance measures in signal selection," *IEEE transactions on communication technology*, vol. 15, no. 1, pp. 52–60, 1967.
- [27] C. Villani *et al.*, *Optimal transport: old and new*, vol. 338. Springer, 2008.

- [28] K. Florek, J. Łukaszewicz, J. Perkal, H. Steinhaus, and S. Zubrzycki, “Sur la liaison et la division des points d’un ensemble fini,” in *Colloquium mathematicum*, vol. 2, pp. 282–285, 1951.
- [29] T. Sorensen, “A method of establishing groups of equal amplitude in plant sociology based on similarity of species content and its application to analyses of the vegetation on danish commons,” *Biologiske skrifter*, vol. 5, pp. 1–34, 1948.
- [30] J. H. Ward Jr, “Hierarchical grouping to optimize an objective function,” *Journal of the American statistical association*, vol. 58, no. 301, pp. 236–244, 1963.
- [31] K. Matusita, “On the notion of affinity of several distributions and some of its applications,” *Annals of the institute of Statistical Mathematics*, vol. 19, pp. 181–192, 1967.
- [32] G. T. Toussaint, “Some inequalities between distance measures for feature evaluation,” *IEEE Transactions on Computers*, vol. 21, no. 04, pp. 409–410, 1972.
- [33] T. VoVan and T. NguyenTrang, “Similar coefficient for cluster of probability density functions,” *Communications in Statistics-Theory and Methods*, vol. 47, no. 8, pp. 1792–1811, 2018.
- [34] A. K. Jain, “Data clustering: 50 years beyond k -means,” *Pattern recognition letters*, vol. 31, no. 8, pp. 651–666, 2010.
- [35] A. Saxena, M. Prasad, A. Gupta, N. Bharill, O. P. Patel, A. Tiwari, M. J. Er, W. Ding, and C.-T. Lin, “A review of clustering techniques and developments,” *Neurocomputing*, vol. 267, pp. 664–681, 2017.
- [36] T. Dinh, H. Wong, P. Fournier-Viger, D. Lisik, M.-Q. Ha, H.-C. Dam, and V.-N. Huynh, “Categorical data clustering: 25 years beyond k -modes,” *Expert Systems with Applications*, vol. 272, p. 126608, 2025.
- [37] J. C. Bezdek, *Pattern recognition with fuzzy objective function algorithms*. Springer Science & Business Media, 2013.
- [38] D. S. Watson, “On the philosophy of unsupervised learning,” *Philosophy & Technology*, vol. 36, no. 2, p. 28, 2023.
- [39] S. C. Johnson, “Hierarchical clustering schemes,” *Psychometrika*, vol. 32, no. 3, pp. 241–254, 1967.
- [40] J. C. Dunn, “A fuzzy relative of the isodata process and its use in detecting compact well-separated clusters,” 1973.
- [41] J. C. Bezdek, “A convergence theorem for the fuzzy isodata clustering algorithms,” *IEEE transactions on pattern analysis and machine intelligence*, no. 1, pp. 1–8, 1980.
- [42] R. J. Hathaway and J. C. Bezdek, “Recent convergence results for the fuzzy c-means clustering algorithms,” *Journal of Classification*, vol. 5, no. 2, pp. 237–247, 1988.
- [43] W. I. Zangwill, “Nonlinear programming: a unified approach,” (*No Title*), 1969.

- [44] L. Groll and J. Jakel, “A new convergence proof of fuzzy *c*-means,” *IEEE Transactions on Fuzzy Systems*, vol. 13, no. 5, pp. 717–720, 2005.
- [45] R. A. Fisher, “The use of multiple measurements in taxonomic problems,” *Annals of eugenics*, vol. 7, no. 2, pp. 179–188, 1936.
- [46] F. Rosenblatt, “Principles of neurodynamics: Perceptrons and the theory of brain mechanisms,” 1961.
- [47] H. Huynh-Van, T. Le-Hoang, and T. Vo-Van, “Classifying for images based on the extracted probability density function and the quasi bayesian method,” *Computational Statistics*, vol. 39, no. 5, pp. 2677–2701, 2024.
- [48] T. Vo-Van and D. PhamToan, “A supervised learning algorithm based on the quasi-bayesian method for the probability density functions and application for medical data,” *Knowledge-Based Systems*, p. 112003, 2024.
- [49] B. Akturk, U. Beyaztas, H. L. Shang, and A. Mandal, “Robust functional logistic regression,” *Advances in Data Analysis and Classification*, pp. 1–25, 2024.
- [50] M. Minami and C. E. Lennert-Cody, “Regression tree and clustering for distributions, and homogeneous structure of population characteristics,” *Journal of Agricultural, Biological and Environmental Statistics*, pp. 1–20, 2024.
- [51] A. Iripino and R. Verde, “Basic statistics for distributional symbolic variables: a new metric-based approach,” *Advances in Data Analysis and Classification*, vol. 9, no. 2, pp. 143–175, 2015.
- [52] L. Billard and E. Diday, *Symbolic data analysis: Conceptual statistics and data mining*. John Wiley & Sons, 2012.
- [53] S. Fillmore-Patrick, “The logit model measurement problem,” *Philosophy of Science*, vol. 92, no. 2, p. 285–303, 2025.
- [54] S. Askari, “Fuzzy *c*-means clustering algorithm for data with unequal cluster sizes and contaminated with noise and outliers: Review and development,” *Expert Systems with Applications*, vol. 165, p. 113856, 2021.
- [55] H. Yu, H. Li, X. Xu, Q. Gao, and R. Lan, “Suppressed possibilistic fuzzy *c*-means clustering based on shadow sets for noisy data with imbalanced sizes,” *Applied Soft Computing*, vol. 167, p. 112263, 2024.
- [56] A. M. Ikotun, F. Habyarimana, and A. E. Ezugwu, “Cluster validity indices for automatic clustering: A comprehensive review,” *Heliyon*, 2025.
- [57] I. van der Linde, “Why the confusion matrix fails as a model of knowledge,” *AI & SOCIETY*, pp. 1–2, 2025.

- [58] M. Ghanem, A. K. Ghaith, V. G. El-Hajj, A. Bhandarkar, A. De Giorgio, A. Elmi-Terander, and M. Bydon, “Limitations in evaluating machine learning models for imbalanced binary outcome classification in spine surgery: a systematic review,” *Brain Sciences*, vol. 13, no. 12, p. 1723, 2023.
- [59] A. Erasmus, T. D. Brunet, and E. Fisher, “What is interpretability?,” *Philosophy & Technology*, vol. 34, no. 4, pp. 833–862, 2021.
- [60] L.-V. Herm, K. Heinrich, J. Wanner, and C. Janiesch, “Stop ordering machine learning algorithms by their explainability! a user-centered investigation of performance and explainability,” *International Journal of Information Management*, vol. 69, p. 102538, 2023.
- [61] E. Schubert, “Stop using the elbow criterion for k-means and how to choose the number of clusters instead,” *ACM SIGKDD Explorations Newsletter*, vol. 25, no. 1, pp. 36–42, 2023.
- [62] C. Goutte, P. Toft, E. Rostrup, F. Å. Nielsen, and L. K. Hansen, “On clustering fmri time series,” *NeuroImage*, vol. 9, no. 3, pp. 298–310, 1999.
- [63] S. Leonelli, *Data-centric biology: A philosophical study*. University of Chicago Press, 2019.
- [64] D. S. Watson, “Reply to tom sterkenburg’s commentary,” *Philosophy & Technology*, vol. 36, no. 4, p. 69, 2023.
- [65] W. J. T. Mollema, “Responding to the watson-sterkenburg debate on clustering algorithms and natural kinds,” 2024.

PHỤ LỤC A MÃ NGUỒN

Về tài nguyên tính toán, chúng tôi chạy trên hệ điều hành Ubuntu 24.04.2 LTS, nhân Linux 6.11.0-19-generic, 11th Gen Intel® Core™ i5-11400H×12, bộ nhớ 16.0 GiB.

Việc thực thi mã nguồn được sử dụng trong môi trường ảo của Python. Các mã Python được sử dụng trong luận văn này được lưu trữ tại <https://github.com/hungtrannam/probclust>. Xin tham khảo tệp README.md trong kho GitHub để biết thêm thông tin chi tiết về cách sử dụng, ví dụ và mở rộng hệ thống. Các thư viện trên được lưu trong tệp requirements.txt và có thể được cài đặt tự động. Đây là danh sách các thư viện Python cần thiết để thực thi toàn bộ mã nguồn trong luận văn.

```
numpy==2.2.6 scipy==1.16.0 pandas==2.3.1 optuna==4.4.0 shap==0.48.0
scikit-learn==1.7.1 statsmodels==0.14.5 matplotlib==3.10.3 seaborn==0.13.2
torch==2.7.1 torchvision==0.22.1 triton==3.3.1 torchmetrics==1.7.4
ipykernel==6.29.5 jupyter_client==8.6.3 jupyter_core==5.8.1 tqdm==4.67.1
einops==0.8.1 numba==0.61.2 joblib==1.5.1 opencv-python
```

PHỤ LỤC B KẾT QUẢ

Ví dụ 3.1 (Liên kết các chùm hàm mật độ). Giả sử ta có ba chùm hàm mật độ xác suất Gauss $\mathcal{F}$, $\mathcal{G}$ và $\mathcal{H}$. Tính các liên kết $\Delta(\mathcal{F}, \mathcal{G})$ và $\Delta(\mathcal{F} \cup \mathcal{G}, \mathcal{H})$ biết khoảng cách giữa hai hàm mật độ là $\mathcal{L}_2$ và các chùm

$$\begin{aligned}\mathcal{F} &= \{f_1 = \mathcal{N}(0, 3; 1), f_2 = \mathcal{N}(1; 1)\}, \\ \mathcal{G} &= \{g_1 = \mathcal{N}(4, 0; 1), g_2 = \mathcal{N}(5, 5; 1), g_3 = \mathcal{N}(4, 8; 1)\}, \\ \mathcal{H} &= \{h_1 = \mathcal{N}(9, 1; 1), h_2 = \mathcal{N}(8, 0; 1)\}.\end{aligned}$$

Bài giải 3.1. Vì các phương sai của hàm mật độ Gauss đều bằng 1. Nên ta có thể tính $\mathcal{L}_2$ bằng công thức tổng quát $\mathcal{L}_2(u, v) = \left(2 - 2\exp\left(-\frac{(\mu_u - \mu_v)^2}{4\sigma^2}\right)\right)^{1/2}$. Sau khi tính toán, ta nhận được ma trận khoảng cách từng đôi một.

	$\{f_1$	$f_2\}$	$\{g_1$	g_2	$g_3\}$	$\{h_1$	$h_2\}$
f_1							
f_2	0,26						
g_1	0,74	0,71					
g_2	0,75	0,75	0,49				
g_3	0,75	0,74	0,29	0,26			
h_1	0,75	0,75	0,75	0,74	0,75		
h_2	0,75	0,75	0,74	0,67	0,72	0,38	

Từ đây, ta có thể dễ dàng tính được các liên kết $\Delta(\mathcal{F}, \mathcal{G})$ thông qua ma trận này. Ta có,

$$\begin{aligned}\Delta_{\min}(\mathcal{F}, \mathcal{G}) &= \min \{ \mathcal{L}_2(f_1, g_1), \mathcal{L}_2(f_1, g_2), \mathcal{L}_2(f_1, g_3), \mathcal{L}_2(f_2, g_1), \mathcal{L}_2(f_2, g_2), \mathcal{L}_2(f_2, g_3) \} \\ &= \min \{ 0,74; 0,75; 0,75; 0,71; 0,75; 0,74 \} = 0,71,\end{aligned}$$

$$\begin{aligned}\Delta_{\max}(\mathcal{F}, \mathcal{G}) &= \max \{ \mathcal{L}_2(f_1, g_1), \mathcal{L}_2(f_1, g_2), \mathcal{L}_2(f_1, g_3), \mathcal{L}_2(f_2, g_1), \mathcal{L}_2(f_2, g_2), \mathcal{L}_2(f_2, g_3) \} \\ &= \max \{ 0,74; 0,75; 0,75; 0,71; 0,75; 0,74 \} = 0,75,\end{aligned}$$

$$\Delta_{\text{avg}}(\mathcal{F}, \mathcal{G}) = \frac{1}{6} \sum_{\substack{f \in \mathcal{F} \\ g \in \mathcal{G}}} \mathcal{L}_2(f, g) = 0,17(0,74 + 0,75 + 0,75 + 0,71 + 0,75 + 0,74) = 0,74,$$

$$\Delta_{\text{centroid}}(\mathcal{F}, \mathcal{G}) = \mathcal{L}_2(\theta_{\mathcal{F}}, \theta_{\mathcal{G}}) = \left(2 - 2 \exp \left(-\frac{(0,65 - 4,77)^2}{4} \right) \right)^{1/2} = 1,41,$$

$$\text{với } \theta_{\mathcal{F}} = (0,3 + 1,0)/2 = 0,65, \theta_{\mathcal{G}} = (4,0 + 5,5 + 4,8)/3 = 4,77,$$

$$\Delta_{\text{Ward}}(\mathcal{F}, \mathcal{G}) = \frac{\#\mathcal{F} \cdot \#\mathcal{G}}{\#\mathcal{F} + \#\mathcal{G}} \cdot \mathcal{L}_2^2(\theta_{\mathcal{F}}, \theta_{\mathcal{G}}) = \frac{2 \cdot 3}{2 + 3} \cdot (1,41)^2 = 2,39,$$

Tương tự, ta cũng có kết quả cho $\Delta(\mathcal{F} \cup \mathcal{G}, \mathcal{H})$ là

$$\Delta_{\min}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) = 0,67, \Delta_{\max}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) = 0,75, \Delta_{\text{avg}}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) = 0,74,$$

$$\Delta_{\text{centroid}}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) = 1,41, \Delta_{\text{Ward}}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) = 2,86.$$

Bài giải Ví dụ 1.4. Đầu tiên, ta xem thứ tự của μ_i chính là thứ tự của dữ liệu hàm mật độ f_i , tính toán các khoảng cách từng đôi hàm mật độ bất kỳ bằng khoảng cách $\mathcal{L}_2(f_i, f_j)$ với $i, j = 1, \dots, 7$, ta nhận được ma trận khoảng cách

	f_1	f_2	f_3	f_4	f_5	f_6	f_7
f_1							
f_2	0,74						
f_3	0,75	0,75					
f_4	0,26	0,71	0,75				
f_5	0,75	0,49	0,74	0,75			
f_6	0,75	0,74	0,38	0,75	0,67		
f_7	0,75	0,29	0,75	0,74	0,26	0,72	

Ta thấy khoảng cách $D(f_1, f_4) = D(f_5, f_7) = 0,26$ là khoảng cách nhỏ nhất nên ta chọn một trong hai. Trường hợp này, ta chọn hàm mật độ f_1 và f_4 xếp vào một chùm $\{f_1, f_4\}$. Tiếp

hành tính toán liên kết đủ giữa chòm $\{f_1, f_4\}$ với các hàm mật độ khác. Ta có

$$\begin{aligned}\Delta(\{f_1, f_4\}, f_2) &= \max\{D(f_1, f_2), D(f_4, f_2)\} = \max\{0,74; 0,71\} = 0,74, \\ \Delta(\{f_1, f_4\}, f_3) &= \max\{D(f_1, f_3), D(f_4, f_3)\} = \max\{0,75; 0,75\} = 0,75, \\ \Delta(\{f_1, f_4\}, f_5) &= \max\{D(f_1, f_5), D(f_4, f_5)\} = \max\{0,75; 0,75\} = 0,75, \\ \Delta(\{f_1, f_4\}, f_6) &= \max\{D(f_1, f_6), D(f_4, f_6)\} = \max\{0,75; 0,75\} = 0,75, \\ \Delta(\{f_1, f_4\}, f_7) &= \max\{D(f_1, f_7), D(f_4, f_7)\} = \max\{0,75; 0,74\} = 0,75.\end{aligned}$$

Ta xóa dòng/cột f_1 và f_4 và thay bằng một dòng/cột mới là $\{f_1, f_4\}$, ta được ma trận khoảng cách mới

		$\{f_1, f_4\}$	f_2	f_3	f_5	f_6	f_7
$D^{(t=1)} =$	$\{f_1, f_4\}$						
	f_2	0,74					
	f_3	0,75	0,75				
	f_5	0,75	0,49	0,74			
	f_6	0,75	0,74	0,38	0,67		
	f_7	0,75	0,29	0,75	0,26	0,72	

Tiếp theo, ta thấy $D(f_5, f_7) = 0,26$ là cách nhỏ nhất nên ta xếp hai hàm mật độ này thành một chòm mới $\{f_5, f_7\}$. Tiến hành tính toán liên kết đủ giữa chòm $\{f_5, f_7\}$ với các hàm mật độ khác. Ta có

$$\begin{aligned}\Delta(\{f_5, f_7\}, \{f_1, f_4\}) &= \max\{D(f_5, f_1), D(f_5, f_4), D(f_7, f_1), D(f_7, f_4)\} = 0,75, \\ \Delta(\{f_5, f_7\}, f_2) &= \max\{D(f_5, f_2), D(f_7, f_2)\} = 0,49, \\ \Delta(\{f_5, f_7\}, f_3) &= \max\{D(f_5, f_3), D(f_7, f_3)\} = 0,75, \\ \Delta(\{f_5, f_7\}, f_6) &= \max\{D(f_5, f_6), D(f_7, f_6)\} = 0,72.\end{aligned}$$

Ta xóa dòng/cột f_5 và f_7 và thay bằng một dòng/cột mới là $\{f_5, f_7\}$, ta được ma trận

khoảng cách mới

		$\{f_1, f_4\}$	f_2	f_3	$\{f_5, f_7\}$	f_6
$D^{(t=2)} =$	$\{f_1, f_4\}$					
	f_2	0,75				
	f_3	0,75	0,75			
	$\{f_5, f_7\}$	0,75	0,49	0,75		
	f_6	0,75	0,74	0,38	0,72	

Tiếp theo, ta thấy $D(f_3, f_6) = 0,38$ là cách nhỏ nhất nên ta xếp hai hàm mật độ này thành một chùm mới $\{f_3, f_6\}$. Tiến hành tính toán liên kết đủ giữa chùm $\{f_3, f_6\}$ với các hàm mật độ khác. Ta có

$$\begin{aligned}\Delta(\{f_3, f_6\}, \{f_1, f_4\}) &= \max\{D(f_3, f_1), D(f_3, f_4), D(f_6, f_1), D(f_6, f_4)\} = 0,75, \\ \Delta(\{f_3, f_6\}, \{f_5, f_7\}) &= \max\{D(f_3, f_5), D(f_3, f_7), D(f_6, f_5), D(f_6, f_7)\} = 0,75, \\ \Delta(\{f_3, f_6\}, f_2) &= \max\{D(f_5, f_3), D(f_7, f_3)\} = 0,75,\end{aligned}$$

Ta xóa dòng/cột f_3 và f_6 và thay bằng một dòng/cột mới là $\{f_3, f_6\}$, ta được ma trận khoảng cách mới

		$\{f_1, f_4\}$	f_2	$\{f_5, f_7\}$	$\{f_3, f_6\}$
$D^{(t=3)} =$	$\{f_1, f_4\}$				
	f_2	0,75			
	$\{f_5, f_7\}$	0,75	0,49		
	$\{f_3, f_6\}$	0,75	0,75	0,75	

Tiếp theo, ta thấy $D(\{f_5, f_7\}, f_2) = 0,49$ là cách nhỏ nhất nên ta xếp hàm mật độ f_2 này vào chùm $\{f_5, f_7\}$. Tiến hành tính toán liên kết đủ giữa chùm $\{f_2, f_5, f_7\}$ với các hàm mật độ khác. Ta có

$$\begin{aligned}\Delta(\{f_2, f_5, f_7\}, \{f_1, f_4\}) &= \max\{D(f_2, \{f_1, f_4\}), D(f_5, \{f_1, f_4\}), D(f_7, \{f_1, f_4\})\} = 0,75, \\ \Delta(\{f_2, f_5, f_7\}, \{f_3, f_6\}) &= \max\{D(f_2, \{f_3, f_6\}), D(f_5, \{f_3, f_6\}), D(f_7, \{f_3, f_6\})\} = 0,75.\end{aligned}$$

Ta xóa dòng/cột f_2 và $\{f_5, f_7\}$ và thay bằng một dòng/cột mới là $\{f_2, f_5, f_7\}$, ta được

ma trận khoảng cách mới

		$\{f_1, f_4\}$	$\{f_2, f_5, f_7\}$	$\{f_3, f_6\}$
$D^{(t=4)} =$	$\{f_1, f_4\}$			
	$\{f_2, f_5, f_7\}$	0,75		
	$\{f_3, f_6\}$	0,75	0,75	

Cuối cùng, ta chọn xếp chòm $\{f_2, f_5, f_7\}$ vào chòm $\{f_3, f_6\}$ dựa vào khoảng cách chính xác nhỏ nhất (4 chữ số thập phân). Vậy ta có chòm $\{f_2, f_5, f_3, f_6\}$. Ta xếp chòm còn lại vào chòm mới này, thuật toán kết thúc.


```
In [4]: import sys
import os

project_root = os.path.abspath("..")
if project_root not in sys.path:
    sys.path.insert(0, project_root)
```

```
In [5]: import numpy as np
from data.data_loader import generateGauss
from utils.integral import grid
from Models.clustering import HCF
```

```
In [ ]: bandwidth = 0.01
grid_x    = grid(bandwidth, start=-5, end=15)
mu        = np.array([0.3, 4.0, 9.1, 1.0, 5.5, 8.0, 4.8])
sig       = np.array([1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0])
F_data    = generateGauss(mu, sig, grid_x)
```

```
In [7]: cluster=HCF.Model(
    grid_x=grid_x,
    max_depth=7,
    distance_metric='L1',
    linkage='complete',
    bandwidth=bandwidth
)
cluster.fit(F_data)
cluster.print_tree()
```

```
├─ root (7 samples): [0, 1, 2, 3, 4, 5, 6]
│   ├── root0 (2 samples): [0, 3]
│   │   ├── root00 (1 samples): [0]
│   │   └── root01 (1 samples): [3]
│   ├── root1 (5 samples): [1, 4, 6, 2, 5]
│   │   ├── root10 (3 samples): [1, 4, 6]
│   │   │   ├── root100 (1 samples): [1]
│   │   │   ├── root101 (2 samples): [4, 6]
│   │   │   │   ├── root1010 (1 samples): [4]
│   │   │   │   └── root1011 (1 samples): [6]
│   │   └── root11 (2 samples): [2, 5]
│   │       ├── root110 (1 samples): [2]
│   │       └── root111 (1 samples): [5]
```

Bài giải Ví dụ 1.5. Với các thông số ban đầu $c = 3$, $\varepsilon = 10^{-3}$, ta tiến hành thuật toán phân tích chùm mờ. Giả sử hàm mật độ xác suất trọng tâm $\theta_i(x)$ ở ba chùm lần lượt là $\theta_1(x) \sim \mathcal{N}(0; 1)$, $\theta_2(x) \sim \mathcal{N}(2; 1)$ và $\theta_3(x) \sim \mathcal{N}(5; 1)$ và phân vùng ở mỗi hàm f_j vào ba trọng tâm này là đều nhau, tức là $U^{(0)} = 1/3 \times \text{ones}(3; 7)$.

Tại vòng lặp đầu tiên $t = 1$, ta tính khoảng cách $\mathcal{L}_2$ giữa $\theta_i(x)$ đến bảy $f_j(x)$ ta được ma trận D_{ij}

$$D_{ij} = \begin{bmatrix} 0,11 & 0,74 & 0,75 & 0,35 & 0,75 & 0,75 & 0,75 \\ 0,54 & 0,60 & 0,75 & 0,35 & 0,73 & 0,75 & 0,68 \\ 0,75 & 0,35 & 0,75 & 0,74 & 0,19 & 0,71 & 0,08 \end{bmatrix}$$

Ta tiến hành cập nhật các giá trị phân vùng U bằng công thức (1.4) và (1.5) ta được

$$U^{(1)} = \begin{bmatrix} 0.94 & 0.14 & 0.33 & 0.45 & 0.06 & 0.32 & 0.01 \\ 0.04 & 0.22 & 0.33 & 0.45 & 0.06 & 0.32 & 0.01 \\ 0.02 & 0.64 & 0.33 & 0.10 & 0.88 & 0.36 & 0.98 \end{bmatrix}$$

PHỤ LỤC C LÝ THUYẾT BỔ SUNG

Bảng 3.1. Một số hàm cơ sở $\psi_m(x)$ phổ biến trong hồi quy logistic cho dữ liệu hàm mật độ

Hàm cơ sở	Công thức $\psi_m(x)$	Miền xác định
Gaussian (RBF)	$\psi_m(x) = \exp\left(-\frac{(x-\mu_m)^2}{2\sigma_m^2}\right)$	$x \in \mathbb{R}$
Hàm sóng con (Wavelet)	$\psi_m(x) = 2^{j_m/2} \psi(2^{j_m}x - k_m)$	$x \in \mathbb{R}$
Chuỗi Fourier	$\psi_m^{(\cos)}(x) = \cos\left(\frac{2\pi mx}{T}\right), \quad \psi_m^{(\sin)}(x) = \sin\left(\frac{2\pi mx}{T}\right)$	$x \in [0, T]$
Đa thức Bernstein	$\psi_m(x) = \binom{n}{m} x^m (1-x)^{n-m}$	$x \in [0, 1]$
Đa thức Legendre	$\psi_m(x) = \frac{1}{2^m m!} \frac{d^m}{dx^m} [(x^2 - 1)^m]$	$x \in [-1, 1]$
B-spline	$\psi_m(x) = \frac{x-t_m}{t_{m+k}-t_m} \psi_{m,k-1}(x) + \frac{t_{m+k+1}-x}{t_{m+k+1}-t_{m+1}} \psi_{m+1,k-1}(x),$ với $\psi_{m,0}(x) = \mathbf{1}_{[t_m, t_{m+1})}(x)$	$x \in \mathbb{R}$

Algorithm 1: Giải thuật phân tích cụm (KCF)

1: procedure KCF(c, ε)	▷ Cho trước số cụm c
2: $t \leftarrow 0$	
3: Khởi tạo $\mu^{(t)}$ và $\Theta^{(t)}$ ngẫu nhiên	
4: while $\ J^{(t+1)} - J^{(t)}\ < \varepsilon$ do	
5: $t \leftarrow t + 1$	
6: Cập nhật $\mu^{(t+1)}$ bằng Công thức $\mu_{ij} = \mathbf{1}_{\{j \in c_i\}}$	
7: Cập nhật $\Theta^{(t+1)}$ bằng Công thức (1.2)	
8: end while	
9: return μ và Θ .	▷ Ma trận phân vùng và hàm mật độ đại diện
10: end procedure	

Algorithm 2: Giải thuật phân cụm thứ bậc tích tụ (HCF)

```
1: procedure HCF
2:   Khởi tạo:  $P_n = \{c_1, c_2, \dots, c_N\}$  với  $c_j = \{f_j\}$ ,  $j = 1, \dots, n$ 
3:    $t \leftarrow 1$ 
4:   while  $n - t > 1$  do
5:     Chọn hai  $c_i, c_j \in P_{n-t+1}$  sao cho thỏa tiêu chí cục bộ
6:      $c_{n+t} \leftarrow c_i \cup c_j$ 
7:      $P_{n-t} \leftarrow (P_{n-t+1} \cup \{c_{n+t}\}) \setminus \{c_i, c_j\}$ 
8:      $t \leftarrow t + 1$ 
9:   end while
10: end procedure
```

Algorithm 3: Giải thuật phân tích cụm mờ (FCF)

```
1: procedure FCF( $c, \varepsilon$ ) ▷ Cho trước số cụm  $c$ 
2:    $t \leftarrow 0$ 
3:   Khởi tạo  $\mu^{(t)}$  và  $\Theta^{(t)}$  ngẫu nhiên
4:   while  $\|\mu^{(t+1)} - \mu^{(t)}\| < \varepsilon$  do
5:      $t \leftarrow t + 1$ 
6:     Cập nhật  $\Theta^{(t+1)}$  bằng Công thức (1.3)
7:     Cập nhật  $\mu^{(t+1)}$  bằng Công thức (1.4) và (1.5)
8:   end while
9:   return  $\mu$  và  $\Theta$ . ▷ Ma trận phân vùng và hàm mật độ đại diện
10: end procedure
```

CHỈ MỤC

- X-means, 36
- k -means⁺⁺, 36
- Affinity Bhattacharyya, 16
- bộ mã hóa (encoding), 18
- dữ liệu đặc trưng (symbolic data), 4, 28
- giải thích-AI (eXplainable AI), 34
- hàm cơ sở (basis functions), 24
- hàm hạt nhân Bhattacharyya
(Bhattacharyya kernel), 16
- hàm hạt nhân chuẩn (Gaussian kernel), 16
- hàm hệ số $\beta(x)$ (β -functional coefficient),
24
- hàm mất mát (loss function), 24, 29
- hàm phân vị (quantile function), 4
- hằng số chặn (intercept), 24
- ma trận nhầm lẫn (confusion matrix), 33
- máy véc-tơ hỗ trợ (support vector
machine), 23
- môi trường ảo (virtual environment), 43
- nhận dạng không được giám sát
(unsupervised recognition), 1
- nhận dạng được giám sát (supervised
recognition), 1
- phân cụm tự cập nhật (self-updating
process), 28
- phân cấp thứ bậc (hierarchical clustering),
28
- phép nhân điểm (point-wise product), 5
- phương pháp hình thang (trapezoidal
method), 18
- phương pháp tăng cường mẫu (resampling
methods), 30
- quá khớp (overfitting), 35
- siêu tham số (hyper-parametre), 35
- thông minh nhân tạo (AI), 1
- vận chuyển tối ưu (optimal transport), 13
- ánh xạ nhiều-đến-một (many-to-one map),
18
- điểm ngoại lệ (outliers), 35
- độ dốc (gradient method), 21