

BỘ GIÁO DỤC VÀ ĐÀO TẠO
ĐẠI HỌC CẦN THƠ

TRẦN NAM HƯNG

NHẬN DẠNG THỐNG KÊ
CHO HÀM MẬT ĐỘ XÁC SUẤT MẤT CÂN BẰNG
VÀ ỨNG DỤNG CHO DỮ LIỆU HÌNH ẢNH

LUẬN VĂN TỐT NGHIỆP THẠC SĨ

NGÀNH: LÝ THUYẾT XÁC SUẤT VÀ THỐNG KÊ TOÁN HỌC
MÃ SỐ: 8 46 01 06

NĂM 2025

BỘ GIÁO DỤC VÀ ĐÀO TẠO
ĐẠI HỌC CẦN THƠ

TRẦN NAM HÙNG
MÃ SỐ HỌC VIÊN: M1823002

NHẬN DẠNG THỐNG KÊ
CHO HÀM MẬT ĐỘ XÁC SUẤT MẤT CÂN BẰNG
VÀ ỨNG DỤNG CHO DỮ LIỆU HÌNH ẢNH

LUẬN VĂN TỐT NGHIỆP THẠC SĨ
NGÀNH LÝ THUYẾT XÁC SUẤT VÀ THỐNG KÊ TOÁN HỌC
MÃ SỐ: 8 46 01 06

CÁN BỘ HƯỚNG DẪN
PGS. TS. VÕ VĂN TÀI

NĂM 2025

CHẤP THUẬN CỦA HỘI ĐỒNG

Luận văn này với tựa đề là “**Nhận dạng thống kê cho hàm mật độ xác suất mất cân bằng và ứng dụng cho dữ liệu hình ảnh**”, do học viên Trần Nam Hưng thực hiện theo sự hướng dẫn của PGs. TS. Võ Văn Tài. Luận văn đã báo cáo và được Hội đồng chấm luận văn thông qua ngày , tháng , năm . Luận văn đã được chỉnh sửa theo góp ý và được Hội đồng chấm luận văn xem lại.

Thư ký
(Ký tên)*

Ủy viên
(Ký tên)

Phản biện 1
(Ký tên)*

Phản biện 2
(Ký tên)

Người hướng dẫn
(Ký tên)*

Chủ tịch hội đồng
(Ký tên)

*: Ghi đầy đủ học hàm, học vị và họ tên

LỜI CẢM ƠN

Luận văn tốt nghiệp này được tài trợ bởi Chương trình học bổng đào tạo thạc sĩ, tiến sĩ trong nước của Quỹ Đổi mới sáng tạo Vingroup (VINIF), mã số VINIF.2024.ThS.56.

Cần Thơ, ngày tháng năm

Tác giả

(Ký, họ và tên)

LỜI CAM ĐOAN

Tôi tên là Trần Nam Hưng, là học viên cao học ngành Lý thuyết Xác suất và Thống kê Toán học khóa 2023–2025. Tôi xin cam đoan luận văn này là công trình nghiên cứu khoa học thực sự của bản thân tôi được sự hướng dẫn của PGS. TS. Võ Văn Tài.

Các thông tin được sử dụng tham khảo trong đề tài luận văn được thu thập từ các nguồn đáng tin cậy, đã được kiểm chứng, được công bố rộng rãi và được tôi trích dẫn nguồn gốc rõ ràng ở phần Danh mục Tài liệu tham khảo. Các kết quả nghiên cứu được trình bày trong luận văn/đề án này là do chính tôi thực hiện một cách nghiêm túc, trung thực và không trùng lặp với các đề tài khác cùng cấp đã được công bố trước đây. Tác giả đồng ý về việc Nhà trường có quyền công bố và phổ biến để phục vụ nhu cầu đào tạo, nghiên cứu khoa học (NCKH) và phục vụ cộng đồng.

Tôi xin lấy danh dự và uy tín của bản thân để đảm bảo cho lời cam đoan này.

Cần Thơ, ngày tháng năm

Người hướng dẫn

(Ký tên)

Tác giả thực hiện

(Ký tên)

MỤC LỤC

PHẦN MỞ ĐẦU	1
1 Lý do chọn đề tài	1
2 Mục đích nghiên cứu	2
3 Đối tượng và phạm vi nghiên cứu	2
4 Phương pháp nghiên cứu	2
5 Cấu trúc luận văn	3
PHẦN NỘI DUNG	3
1 KIẾN THỨC CHUẨN BỊ	4
1.1 Hàm mật độ xác suất	4
1.2 Một số hàm mật độ thông dụng	6
1.3 Một số hàm mật độ bổ sung	9
1.4 Độ đo đánh giá sự tương tự của các hàm mật độ xác suất	12
1.4.1 Sự tương tự của hai hàm mật độ xác suất	12
1.4.2 Sự tương tự của nhiều hơn hai hàm mật độ xác suất	18
1.5 Phương pháp số xấp xỉ tích phân	20
1.6 Một số định lý hội tụ	20
1.7 Phân tích chùm cho hàm mật độ xác suất	21
1.7.1 Phân tích chùm không mờ	21
1.7.2 Phân tích chùm mờ	24
1.8 Phân loại cho hàm mật độ xác suất	28
1.8.1 Hồi quy logistics	28
1.8.2 Máy véc-tơ hỗ trợ	30
1.8.3 Phương pháp naive Bayes	30
1.9 Tổng kết Chương 1	31
2 NHẬN DẠNG THÔNG KÊ CHO HÀM MẬT ĐỘ XÁC SUẤT VỚI DỮ LIỆU MẤT CÂN BẰNG	32
2.1 Giới thiệu	32

2.1.1	Giới thiệu bài toán phân tích chùm cho dữ liệu mất cân bằng	32
2.1.2	Giới thiệu bài toán phân loại cho dữ liệu mất cân bằng	32
2.2	Các vấn đề liên quan	32
2.2.1	Tham số đánh giá thuật toán phân tích chùm	32
2.2.2	Tham số đánh giá thuật toán phân loại	34
2.2.3	Tham số đánh giá thuật toán phân loại	34
2.3	Phân tích chùm cho hàm mật độ xác suất với dữ liệu mất cân bằng	35
2.3.1	Thuật toán	35
2.3.2	Sự hội tụ của thuật toán	35
2.3.3	Ví dụ minh hoạ	35
2.4	Phân loại cho hàm mật độ xác suất với dữ liệu mất cân bằng	35
2.4.1	Thuật toán	35
2.4.2	Sự hội tụ của thuật toán	35
2.4.3	Ví dụ minh hoạ	35
2.5	Tổng kết chương 2	35
3	ỨNG DỤNG CHO DỮ LIỆU HÌNH ẢNH	36
3.1	Trích xuất đặc trưng của hình ảnh thành hàm mật độ xác suất	36
3.1.1	Vấn đề trích xuất đặc trưng của hình ảnh	36
3.1.2	Ước lượng hàm mật độ xác suất đại diện cho hình ảnh	36
3.2	Ứng dụng của bài toán phân tích chùm	36
3.2.1	Dữ liệu	36
3.2.2	Phương pháp thực hiện	36
3.2.3	Kết quả thực hiện	36
3.3	Ứng dụng của bài toán phân loại	36
3.3.1	Dữ liệu	36
3.3.2	Phương pháp thực hiện	36
3.3.3	Kết quả thực hiện	36
3.4	Tổng kết chương 3	36
	PHẦN KẾT LUẬN	37
	TÀI LIỆU THAM KHẢO	37
	PHỤ LỤC A	42
	PHỤ LỤC B	43
	CHỈ MỤC	48

DANH SÁCH HÌNH VẼ

1.1	Hàm mật độ xác suất Gauss trong các không gian 1-chiều và 2-chiều	8
1.2	Minh họa hai hàm mật độ xác suất đại diện một chùm hàm mật độ $\mathcal{F}$	11
1.3	So sánh các hàm hạt nhân trong ước lượng mật độ xác suất	12
1.4	Dãy khoảng cách giữa hai hàm mật độ Gauss $\mathcal{N}(0, 1)$ và $\mathcal{N}(\mu, 1)$	14
1.5	Các trường hợp trong khoảng cách giữa hai hàm mật độ đều $f_1(x)$ và $f_2(x)$. . .	16
1.6	Các loại liên kết giữa các chùm hàm mật độ xác suất.	18
1.7	Kết quả phân cấp thứ bậc tích tụ đối với Ví dụ 1.4	24
1.8	Biểu đồ phân vùng mờ theo khoảng cách D_{1j} với các hệ số m khác nhau. . . .	26
1.9	Hàm $\beta(x)$ được ước lượng qua 10 hàm cơ sở Gauss.	29

DANH SÁCH BẢNG

1.1	Một số hàm hạt nhân phổ biến dùng trong ước lượng mật độ hạt nhân	12
1.2	Bảng tổng kết các loại khoảng cách giữa hai hàm mật độ xác suất	13
1.3	Các kết quả khoảng cách giữa hai hàm mật độ đều	16
1.4	Bảng tổng kết các loại liên kết Δ giữa hai chùm hàm mật độ xác suất	18
1.5	Tổng kết các tương tự giữa các chùm hàm mật độ xác suất	19
1.6	So sánh độ phức tạp của ba thuật toán phân chùm	27
2.1	Mô tả các chỉ số đánh giá phân loại	35

DANH SÁCH GIẢI THUẬT

1	Giải thuật phân tích chùm KCF	23
2	Giải thuật phân cụm thứ bậc tích tụ (HCF)	23
3	Giải thuật phân tích chùm mờ (FCF)	26

DANH SÁCH KÝ HIỆU TOÁN HỌC

Ký hiệu	Mô tả
X, Y	Biến ngẫu nhiên
Y	Tập nhãn của dữ liệu (đối với bài toán phân loại)
$\mathbb{E}(\cdot)$	Kỳ vọng của biến ngẫu nhiên
$\text{Var}(\cdot)$	Phương sai của biến ngẫu nhiên
$ \cdot $	Định thức của ma trận
$\#\mathcal{F}$	Lực lượng của tập hợp $\mathcal{F}$

PHẦN MỞ ĐẦU

1 Lý do chọn đề tài

Nghiên cứu – phát triển các nguyên tắc và ứng dụng hệ thống thông minh nhân tạo (AI) là yếu tố then chốt nhằm thúc đẩy tăng trưởng kinh tế bền vững ở các quốc gia [1, 2]. Với khả năng ứng dụng đa ngành – đa chiều, AI không chỉ cải thiện năng suất lao động mà còn mở ra nhiều cơ hội việc làm, góp phần xây dựng nền kinh tế số, nâng cao tiện ích, thu nhập và chất lượng cuộc sống [3]. Trong sự phát triển của AI, nhận dạng thống kê được xem là một trong những kiến thức nền tảng nhằm phát triển các AI dự đoán hiện nay.

Nhận dạng thống kê gồm có hai bài toán chính: nhận dạng được giám sát và không được giám sát [4, 5]. Nhận dạng không được giám sát là việc chia dữ liệu thành các cụm sao cho các phần tử trong cùng một cụm có sự tương tự nhiều hơn so với các phần tử bên ngoài cụm đó [6, 7]. Do đó, nó còn được gọi là bài toán phân tích cụm. Phân tích cụm là cơ sở của việc lưu trữ, trích xuất và xử lý dữ liệu lớn nên được rất nhiều nhà thống kê và công nghệ thông tin quan tâm. Nhận dạng được giám sát là việc xếp một phần tử vào một nhóm trong các nhóm đã biết một cách thích hợp [4, 8]. Do đó, nó còn được gọi là bài toán phân loại. Phân loại đã và đang được áp dụng trong nhiều lĩnh vực khác nhau. Chẳng hạn, trong y tế hoạt động chẩn đoán bệnh của các bác sĩ xem một người có bệnh hay không có bệnh B, loại nào trong bệnh B thực chất là thực hiện bài toán phân loại. Trong lĩnh vực xã hội và an ninh, việc nhận dạng khuôn mặt, chữ ký, dấu vân tay,... cũng chính là thực hiện bài toán phân loại.

Dữ liệu cho nhận dạng thống kê có thể là dữ liệu rời rạc, dữ liệu khoảng và hàm mật độ xác suất. Nhận dạng thống kê cho dữ liệu rời rạc đã được xem xét đầu tiên đã và đang được nghiên cứu rất nhiều [6, 9, 10]. Trong thực tế, chúng ta cũng lưu trữ nhiều dữ liệu khoảng như nhiệt độ, lượng mưa, giá chứng khoán nên nhận dạng cho kiểu dữ liệu này đã được đề xuất và phát triển. Khi dữ liệu lớn và phức tạp như hình ảnh, đối tượng hình ảnh có thể được xem là một hàm mật độ xác suất trong một số phương pháp biểu diễn [11], do đó nhận dạng thống kê cho hàm mật độ xác suất được đề xuất.

Xét về số lượng phần tử trong các nhóm, dữ liệu có thể được gọi là mất cân bằng và không mất cân bằng. Khi số lượng phần tử của các nhóm không có sự chênh lệch nhiều thì nó được gọi là không mất cân bằng. Trong nhận dạng dữ liệu của thực tế, nhiều trường hợp

chúng ta gặp phải dữ liệu mất cân bằng. Đó là kiểu dữ liệu mà một nhóm hoặc một số ít nhóm có số lượng phần tử quá nhỏ so với các nhóm còn lại [12]. Khi một mô hình nhận dạng phải đối mặt với chênh lệch lớn về số lượng mẫu, nó dễ dàng bị thiên lệch về lớp đa số, dẫn đến hiệu quả thấp trong việc nhận dạng các mẫu của lớp thiểu số [13]. Chẳng hạn, trong tầm soát ung thư, ca bị bệnh có thể ít hơn 1000 lần so với trường hợp không bị bệnh [14]. Khi đó các thuật toán nhận dạng truyền thống sẽ không phát huy hiệu quả vì nó có xu hướng thiên vị lớp đa số mà bỏ qua lớp thiểu số. Trong trường hợp này, độ chính xác của các lớp thiểu số là quan trọng hơn [12], bởi vì việc tầm soát sai người mắc ung thư là khỏe mạnh gây ra tổn thất tính mạng lớn hơn nhiều so với sai lầm ngược lại.

Theo sự hiểu biết của chúng tôi, nhận dạng thông kê cho dữ liệu mất cân bằng với các phần tử rời rạc đã được quan tâm trong những năm gần đây. Tuy nhiên với dữ liệu hàm mật độ xác suất hầu như chưa được xem xét. Từ sự phân tích trên, đề tài **“Nhận dạng thông kê cho hàm mật độ xác suất mất cân bằng và ứng dụng cho dữ liệu hình ảnh”** được chọn làm luận văn tốt nghiệp.

2 Mục đích nghiên cứu

- Xây dựng thuật toán phân loại và phân tích chùm cho hàm mật độ xác suất với dữ liệu mất cân bằng;
- Áp dụng hai thuật toán trên cho dữ liệu hình ảnh khi các đặc trưng của nó được trích xuất và đại diện bởi hàm mật độ xác suất để nhận dạng.

3 Đối tượng và phạm vi nghiên cứu

3.1 Đối tượng nghiên cứu

- Thuật toán phân loại và phân tích chùm với dữ liệu mất cân bằng;
- Dữ liệu hình ảnh được trích xuất thành các đối tượng đại diện.

3.2 Phạm vi nghiên cứu

- Các thuật toán phân tích chùm và phân loại cho hàm mật độ xác suất;
- Dữ liệu hình ảnh được trích xuất thành hàm mật độ xác suất đại diện;
- Vấn đề tính toán của các phương pháp phân loại, phân tích chùm.

4 Phương pháp nghiên cứu

- *Nghiên cứu lý thuyết*: Phân tích – tổng kết, phân loại – hệ thống hóa kiến thức về lĩnh vực

nhận dạng thống kê; So sánh đánh giá ưu điểm và nhược điểm của các thuật toán.

- *Thực nghiệm khoa học*: Thực hiện các ví dụ số minh họa lý thuyết trong môi trường mô phỏng nhằm đánh giá các mô hình nhận dạng qua nhiều tiêu chí cụ thể, từ đó xử lý so sánh kết quả bằng các phân tích thống kê.

5 Cấu trúc luận văn

Luận văn bao gồm phần mở đầu, phần nội dung và phần kết luận, trong đó phần nội dung gồm ba chương:

Chương 1. *Kiến thức chuẩn bị*

Chương 2. *Nhận dạng thống kê cho hàm mật độ xác suất với dữ liệu mất cân bằng*

Chương 3. *Ứng dụng cho dữ liệu hình ảnh*

CHƯƠNG 1

KIẾN THỨC CHUẨN BỊ

1.1 Hàm mật độ xác suất

Hàm mật độ xác suất được xem như là khách thể nghiên cứu của các nhà thống kê từ những năm 2010 bởi Tai Vo-Van [15]. Ở đây, luận văn chỉ hệ thống hóa những kiến thức có liên quan trực tiếp đến đối tượng nghiên cứu (phần mở đầu).

Định nghĩa 1.1 (Biến ngẫu nhiên). Một biến ngẫu nhiên X trong không gian xác suất $(\Omega, \mathcal{E}, \mathbb{P})$ là một hàm Borel đo được từ Ω đến $\mathbb{R}$, tức là $X : (\Omega, \mathcal{E}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$.

Tương tự, ta mở rộng biến ngẫu nhiên d -chiều cho véc-tơ $\mathbf{X} = (X_1, X_2, \dots, X_d)$ trong $\mathbb{R}^d$, với mỗi thành phần $X_i, (i = 1, 2, \dots, d)$ là biến ngẫu nhiên trên $(\Omega, \mathcal{E}, \mathbb{P})$, nhận giá trị trong $\mathbb{R}$.

Định nghĩa 1.2 (Biến ngẫu nhiên d -chiều). Biến ngẫu nhiên d -chiều là một hàm Borel đo được từ không gian xác suất đến không gian Euclid $\mathbb{R}^d$, tức là $\mathbf{X} : (\Omega, \mathcal{E}) \rightarrow (\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$.

Định nghĩa 1.3 (Hàm phân phối). Hàm phân phối của biến ngẫu nhiên X là hàm $P := P_X : \mathbb{R} \rightarrow [0, 1]$ được định nghĩa bởi

$$P(x) = P\{\omega : X(\omega) \leq x\}, \forall x \in \mathbb{R}.$$

Tính chất 1.1. *Phân phối P thỏa mãn:*

1. P không giảm,
2. $\lim_{x \rightarrow \infty} P(x) = 1$ và $\lim_{x \rightarrow -\infty} P(x) = 0$,
3. P liên tục phải, tức là $\lim_{x \downarrow y} P(y) = P(x)$,
4. Nếu $P(x_-) = \lim_{y \uparrow x} P(y)$ thì $P(x_-) = \mathbb{P}(X < x)$,
5. $\mathbb{P}(X = x) = P(x) - P(x_-)$.

Định nghĩa 1.4 (Hàm phân vị). Cho phân phối P trên $\mathbb{R}$, hàm phân vị $F^{-1} : [0, 1] \rightarrow \mathbb{R}$ được định nghĩa bởi

$$F^{-1}(s) = \inf\{x \in \mathbb{R} : P(x) \geq s\}, \quad s \in [0, 1].$$

Tính chất 1.2. Hàm phân vị F^{-1} thỏa mãn:

1. F^{-1} không giảm: nếu $s_1 \leq s_2$ thì $F^{-1}(s_1) \leq F^{-1}(s_2)$,
2. Nếu P liên tục, $P(F^{-1}(s)) = s$ và $F^{-1}(P(x)) = x$,
3. Kỳ vọng và phương sai được biểu diễn qua F^{-1} dưới công thức

$$\mathbb{E}(X) = \int_0^1 F^{-1} ds, \text{ và } \text{Var}(X) = \mathbb{E}(X^2) - \mathbb{E}^2(X),$$

4. Nếu P đối xứng quanh μ , ta có quan hệ đối xứng $F^{-1}(1-s) = 2\mu - F^{-1}(s)$.

Định nghĩa 1.5 (Hàm mật độ xác suất). Họ các hàm phân phối $P: \mathbb{R}^d \rightarrow [0, \infty]$ là liên tục tuyệt đối trong $(\Omega, \mathcal{B})$ -đo được với μ hoặc là độ đo Lebesgue hoặc độ đo đếm. Khi này, hàm mật độ trong không gian thực được định nghĩa là

$$\forall x, f(x) = \frac{dP}{d\mu}(x) = \begin{cases} f(s), & \text{nếu } \mu \text{ là độ đo Lebesgue,} \\ \mathbb{P}(X = x) = p(x), & \text{nếu } \mu \text{ là độ đo đếm.} \end{cases}$$

Đây là khái niệm quan trọng trong luận văn này. Để cụ thể, chúng tôi tập trung khảo sát tính chất của hàm mật độ (μ là độ đo Lebesgue) liên tục tuyệt đối của biến ngẫu nhiên X . Các hàm mật độ cũng được định nghĩa trên tập số thực. Ta có thể tổng quát hóa đối tượng hàm mật độ thành không gian lồi

$$\mathcal{F} = \left\{ f: \Omega \rightarrow \mathbb{R}^+ \mid \int_{\Omega} f(x) d\mu(x) = 1 \right\}.$$

Tính chất 1.3.

1. Hàm mật độ xác suất liên tục $f(x)$ là hàm không âm, $f(x) \geq 0, \forall x \in \Omega$,
2. Tích phân $f(x)$ trên toàn miền Ω bằng 1,
3. Xác suất trên tập con Borel $A \subseteq \Omega$ được tính bằng tích phân $\mathbb{P}(X \in A) = \int_A f(x) dx$,
4. Công thức xác suất trong tập Borel thực

$$\mathbb{P}(a < x < b) = \mathbb{P}(a < x \leq b) = \mathbb{P}(a \leq x < b) = \mathbb{P}(a \leq x \leq b) = \int_a^b f(x) dx.$$

Nhận xét. Các giá trị của mật độ xác suất thì có thể tùy ý, nhưng phải thỏa mãn Tính chất 1.3. Tương tự, xác suất tại điểm $x = x_0$ bất kỳ không được khảo sát trong hàm mật độ liên tục tuyệt đối mà ở một tập Borel thực như Tính chất 1.3.(3), nghĩa là xác suất tại điểm bất kỳ luôn bằng 0 đối với biến ngẫu nhiên X liên tục.

Định nghĩa 1.6 (Tham số kỳ vọng và phương sai). Hai tham số kỳ vọng và phương sai của biến ngẫu nhiên X được định nghĩa bởi

$$\mathbb{E}(X) = \int_{\Omega} xf(x) dx < \infty, \text{ và } \text{Var}(X) = \int_{\Omega} (x - \mathbb{E}(X))^2 f(x) dx.$$

Định nghĩa 1.7 (Dữ liệu hàm mật độ 1-chiều). Dữ liệu hàm mật độ là một bộ đối tượng không chắc chắn o có dạng $(o_1, o_2, \dots, o_n)$ [16]. Mỗi đối tượng o_j chứa một cặp (I_j, f_j) với mỗi $1 \leq j \leq n$, trong đó $I_j = [l_j, u_j]$ là khoảng xác định của o_j và $f : \mathbb{R} \rightarrow \mathbb{R}^+$ là hàm mật độ xác suất xếp các giá trị xác suất vào mỗi $x \in I_j$ sao cho

$$\int_{x \in I_j} f_j(x) dx = 1, \text{ và } \int_{x \in \mathbb{R} \setminus I_j} f_j(x) dx = 0.$$

Định nghĩa 1.8 (Dữ liệu hàm mật độ d -chiều). Dữ liệu hàm mật độ d -chiều là một bộ đối tượng không chắc chắn o có dạng $(o_1, o_2, \dots, o_n)$ [16]. Mỗi đối tượng o_j chứa một cặp (R_j, f_j) với mỗi $1 \leq j \leq n$, trong đó $R_j = [l_1, u_1] \times \dots \times [l_d, u_d] \subseteq \mathbb{R}^d$ là vùng xác định d -chiều của o_j và $f : \mathbb{R}^d \rightarrow \mathbb{R}^{d+}$ là hàm mật độ xác suất xếp các giá trị xác suất vào mỗi $x \in R_j$ sao cho

$$\int_{x \in R_j} f_j(x) dx = 1, \text{ và } \int_{x \in \mathbb{R}^d \setminus R_j} f_j(x) dx = 0.$$

Để minh họa và mô phỏng, luận văn này tập trung chủ yếu vào dữ liệu các hàm mật độ mô phỏng định nghĩa trên toàn không gian mẫu $I = \mathbb{R}$ hoặc $R = \mathbb{R}^d$, và ký hiệu xuyên suốt là $\mathcal{F} = \{f_1(x), \dots, f_n(x)\}$. Về mặt nguyên tắc, dữ liệu hàm mật độ này có thể là rời rạc hoặc liên tục. Để đơn giản hóa, chúng tôi giả định các đối tượng là độc lập và cùng phân phối, và các dữ liệu hàm mật độ f_i là liên tục.

Nhận xét. Dữ liệu hàm mật độ xác suất có cấu trúc phức tạp và tốn nhiều thời gian thu thập. Hầu hết các dữ liệu hàm mật độ ta có thể bắt gặp đều là dữ liệu mô phỏng chùm hàm mật độ như [17, 18]. Trong thực tế, dữ liệu hàm mật độ 1-chiều cụ thể khám phá cơ cấu phân bố loài, là dữ liệu Cá hồi vây vàng (*Yellowfin tuna*) của [19] biểu diễn phân bố chiều dài của cá qua các ô tọa độ vùng biển Thái Bình Dương từ 2003 đến 2007. Ngoài ra, dữ liệu hàm mật độ 2-chiều thường gặp khi ứng dụng trong phân tích tương quan điểm số của sinh viên các khoa/viện thuộc trường Đại học Cần Thơ. Đặc biệt, dữ liệu hàm mật độ còn được thành lập dựa trên dữ liệu hình ảnh được trích xuất màu sắc nhưng vẫn rất hạn chế trong ứng dụng.

1.2 Một số hàm mật độ thông dụng

Trong thực tế, ta làm việc trên hàm mật độ xác suất cụ thể được nghiên cứu bởi các nhà khoa học thực nghiệm và thỏa mãn các Tính chất 1.3. Hàm mật độ Gauss, rất quan trọng trong thống kê, được trình bày qua định nghĩa sau.

Định nghĩa 1.9 (Hàm mật độ Gauss). Biến ngẫu nhiên liên tục X tuân theo mật độ Gauss (chuẩn) với hai tham số μ và σ^2 (trong đó $\mu \in \mathbb{R}$ và $\sigma^2 \in \mathbb{R}_{>0}$) nếu nó có hàm mật độ xác suất là

$$\mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), x \in \mathbb{R}.$$

Định lý 1.1 (Kỳ vọng và phương sai). Kỳ vọng và phương sai của biến ngẫu nhiên X có hàm mật độ xác suất Gauss là $\mathbb{E}(X) = \mu$, $\text{Var}(X) = \sigma^2$.

Bổ đề 1.1 (Tổng hai hàm mật độ Gauss). Cho hai biến ngẫu nhiên độc lập $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2)$ và $X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$. Khi đó tổng $S = X_1 + X_2$ cũng là biến ngẫu nhiên có hàm mật độ Gauss, tức là $S \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$.

Bổ đề 1.2 (Tích phân của hai hàm mật độ Gauss). Cho hai hàm mật độ Gauss $\mathcal{N}(\mu_1, \sigma_1^2)$ và $\mathcal{N}(\mu_2, \sigma_2^2)$ với kỳ vọng $\mu_1, \mu_2 \in \mathbb{R}$, và phương sai $\sigma_1^2, \sigma_2^2 > 0$. Khi đó, tích phân giữa hai hàm mật độ được xác định bởi

$$\int_{\Omega} \mathcal{N}(\mu_1, \sigma_1^2) \cdot \mathcal{N}(\mu_2, \sigma_2^2) dx = \frac{1}{\sqrt{2\pi(\sigma_1^2 + \sigma_2^2)}} \exp\left(-\frac{(\mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right).$$

Chứng minh. Xét tích phân

$$\begin{aligned} I &= \int_{-\infty}^{\infty} \mathcal{N}(x; \mu_1, \sigma_1^2) \cdot \mathcal{N}(x; \mu_2, \sigma_2^2) dx = \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{(x-\mu_1)^2}{2\sigma_1^2} - \frac{(x-\mu_2)^2}{2\sigma_2^2}\right) dx \\ &= \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{1}{2} \underbrace{\left(\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}\right)}_{:=1/\sigma^2} x^2 + \underbrace{\left(\frac{\mu_1}{\sigma_1^2} + \frac{\mu_2}{\sigma_2^2}\right)}_{:=\mu} x - \frac{\mu_1^2}{2\sigma_1^2} - \frac{\mu_2^2}{2\sigma_2^2}\right) dx \\ &= \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{1}{2}\sigma(x-\mu)^2 - \frac{(\mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right) dx \\ &= \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{(\mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right) \underbrace{\int_{-\infty}^{\infty} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right) dx}_{=\sqrt{2\pi\sigma^2}} \\ &= \frac{\sqrt{2\pi\sigma^2}}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{(\mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right). \end{aligned}$$

Từ đây, ta suy ra được điều phải chứng minh. ■

Định nghĩa 1.10 (Hàm mật độ Gauss d -chiều). Biến ngẫu nhiên liên tục d -chiều $\mathbf{X}$ tuân theo mật độ Gauss (chuẩn) với hai tham số μ và Σ (trong đó $\mu \in \mathbb{R}^d$ và Σ thuộc đa tạp của ma trận đối xứng xác định dương) nếu nó có hàm mật độ xác suất là

$$\mathcal{N}(\mathbf{x}; \mu, \Sigma) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \mu)^\top \Sigma^{-1}(\mathbf{x} - \mu)\right), \mathbf{x} \in \mathbb{R}^d,$$

trong đó, $|\Sigma|$ là định thức của ma trận hiệp phương sai.


Định lý 1.2 (Kỳ vọng và hiệp phương sai). Kỳ vọng và phương sai của biến ngẫu nhiên X có hàm mật độ xác suất Gauss là $\mathbb{E}(X) = \mu$, $\text{Cov}(X) = \Sigma$.

Bổ đề 1.3 (Tích phân của hai hàm mật độ Gauss d -chiều). Cho hai hàm mật độ Gauss d -chiều $\mathcal{N}(\mu_1, \Sigma_1)$ và $\mathcal{N}(\mu_2, \Sigma_2)$ với véc-tơ kỳ vọng $\mu_1, \mu_2 \in \mathbb{R}^d$, và ma trận hiệp phương sai Σ_1, Σ_2 xác định dương. Khi đó, tích phân giữa hai hàm mật độ được xác định bởi

$$\int_{\Omega} \mathcal{N}(\mu_1, \Sigma_1) \cdot \mathcal{N}(\mu_2, \Sigma_2) dx = \frac{1}{(2\pi)^{d/2} |\Sigma_1 + \Sigma_2|^{1/2}} \times \exp \left(-\frac{1}{2} (\mu_1 - \mu_2)^T (\Sigma_1 + \Sigma_2)^{-1} (\mu_1 - \mu_2) \right).$$

Bổ đề 1.4 (Tổng hai hàm mật độ Gauss d -chiều). Cho hai biến ngẫu nhiên độc lập $X_1 \sim \mathcal{N}(\mu_1, \Sigma_1)$ và $X_2 \sim \mathcal{N}(\mu_2, \Sigma_2)$. Khi đó tổng $S = X_1 + X_2$ cũng là biến ngẫu nhiên có hàm mật độ Gauss, tức là $S \sim \mathcal{N}(\mu_1 + \mu_2, \Sigma_1 + \Sigma_2)$.

Nhận xét. Hàm mật độ $h(x)$ của tổng $S = X + Y$ hai biến ngẫu nhiên độc lập là kết quả của tích chập giữa các hàm mật độ tương ứng, tức là $h(x) = f_X(x) * g_Y(x)$.



Chú thích: (a) Hàm mật độ xác suất Gauss trong không gian $\mathbb{R}$, cụ thể là $X \sim \mathcal{N}(0, 1)$, và (b) trong không gian $\mathbb{R}^2$, $X \sim \mathcal{N}([2, -1]^T, 1.5I_2)$. Nguồn: Minh họa của tác giả

Hình 1.1. Hàm mật độ xác suất Gauss trong các không gian 1-chiều và 2-chiều

Hình 1.1 cho thấy hàm Gauss có dáng điệu hình cong đối xứng có miền xác định khắp không gian. Đặc trưng kỳ vọng μ chính là giá trị cực đại và xác định vị trí của hàm mật độ, đặc trưng phương sai Σ thể hiện độ phân tán hay độ cao của hàm, phương sai càng nhỏ thì hàm mật độ càng cao và hẹp. Thông thường, dữ liệu rời rạc thường được biến đổi thành dữ liệu hàm mật độ qua biểu diễn của hàm mật độ Gauss (khi ước lượng tham số) hoặc nhân-Gauss (khi ước lượng phi tham số). Cuối cùng, định lý giới hạn trung tâm chứng minh tổng các biến ngẫu nhiên độc lập có phân phối xấp xỉ Gauss.

Ngoài ra, các phát triển bất đối xứng của Gauss điển hình là hàm Gauss-lệch [20]. với hàm mật độ của nó được định nghĩa như sau.

Định nghĩa 1.11 (Hàm mật độ Gauss-lệch). Biến ngẫu nhiên liên tục X tuân theo mật độ Gauss-lệch (chuẩn-lệch) [20] với ba tham số μ , σ^2 và α (trong đó $\mu, \alpha \in \mathbb{R}$ và $\sigma^2 \in \mathbb{R}_{>0}$) nếu nó có hàm mật độ xác suất là

$$\mathcal{S}\mathcal{N}(x; \mu, \sigma^2, \alpha) = \frac{2}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \int_{-\infty}^{\alpha(x-\mu)/\sigma} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{t^2}{2}\right) dt, x \in \mathbb{R}.$$

Hàm mật độ Gauss-lệch nhận thêm một tham số thể hiện mức độ lệch α . Khi giá trị α càng lớn, độ lệch so với kỳ vọng μ càng lớn. Khi $\alpha = 0$, phân phối này trở về Gauss như Định nghĩa 1.9.

Định lý 1.3 (Kỳ vọng và phương sai). Kỳ vọng và phương sai của biến ngẫu nhiên X có hàm mật độ xác suất Gauss-lệch là $\mathbb{E}(X) = \mu + \sigma\delta\sqrt{\frac{2}{\pi}}$, $\text{Var}(X) = \sigma^2\left(1 - \frac{2\delta^2}{\pi}\right)$, với $\delta = \frac{\alpha}{\sqrt{1+\alpha^2}}$ nằm trong $(-1, 1)$.

Định nghĩa 1.12 (Hàm mật độ đều). Biến ngẫu nhiên liên tục X tuân theo phân phối đều trên đoạn $[a, b]$ (với $a < b$ và $a, b \in \mathbb{R}$) nếu nó có hàm mật độ xác suất là

$$\mathcal{U}(x; a, b) = \begin{cases} \frac{1}{b-a}, & x \in [a, b], \\ 0, & x \notin [a, b]. \end{cases}$$

Định lý 1.4 (Kỳ vọng và phương sai). Kỳ vọng và phương sai của biến ngẫu nhiên X có hàm mật độ xác suất đều là $\mathbb{E}(X) = \frac{a+b}{2}$, $\text{Var}(X) = \frac{(b-a)^2}{12}$.

Định nghĩa 1.13 (Hàm mật độ đều d -chiều). Biến ngẫu nhiên liên tục d -chiều $\mathbf{X}$ tuân theo phân phối đều trên hình hộp $[a_1, b_1] \times \cdots \times [a_d, b_d]$ (với $a_i < b_i$, $a_i, b_i \in \mathbb{R}$) nếu nó có hàm mật độ xác suất là

$$\mathcal{U}(\mathbf{x}; \mathbf{a}, \mathbf{b}) = \begin{cases} \prod_{i=1}^d \frac{1}{b_i - a_i}, & \mathbf{x} \in [a_1, b_1] \times \cdots \times [a_d, b_d], \\ 0, & \text{ngược lại.} \end{cases}$$

Định lý 1.5 (Kỳ vọng và hiệp phương sai). Kỳ vọng và phương sai của biến ngẫu nhiên $\mathbf{X}$ có hàm mật độ xác suất đều là $\mathbb{E}(\mathbf{X}) = \frac{\mathbf{a}+\mathbf{b}}{2}$, $\text{Cov}(\mathbf{X}) = \text{diag}\left(\frac{(b_1-a_1)^2}{12}, \dots, \frac{(b_d-a_d)^2}{12}\right)$.

1.3 Một số hàm mật độ bổ sung

Gần đây, các thuật toán phân tích chùm dựa vào trọng tâm đề xuất bổ sung hàm mật độ xác suất trọng tâm (hay hàm mật độ đại diện của chùm) [21, 22]. Nó có chức năng như trung bình có trọng số của tổng các hàm mật độ trong chùm.

Định nghĩa 1.14 (Hàm mật độ đại diện chùm). Cho tập $\mathcal{F}$ gồm n -hàm mật độ xác suất, trong đó, $\mathcal{F} = \{f_1(x), f_2(x), \dots, f_n(x)\}$ với $n \geq 2$. Ta phân bổ $\mathcal{F}$ vào c -chùm ($1 < c \leq n$),

khi này hàm mật độ đại diện của các chùm c_i là

$$\theta_i(x) = \frac{\sum_{j=1}^n \mu_{ij} \times f_j(x)}{\sum_{j=1}^n \mu_{ij}}, \quad (1.1)$$

trong đó, μ_{ij} là trọng số phân bố hàm mật độ $f_j(x)$ bất kỳ vào chùm c_i .

Nhận xét. Dựa vào định nghĩa trên, ta dễ dàng nhận được θ_i cũng là một hàm mật độ thỏa Tính chất 1.3. Thật vậy, các giá trị trọng số $0 \leq \mu_{ij} \leq 1$ nên các θ_i liên tục không âm, và

$$\int_{\Omega} \theta_i(x) dx = \int_{\Omega} \frac{\sum_{j=1}^n \mu_{ij} \times f_j(x)}{\sum_{j=1}^n \mu_{ij}} dx = \frac{\sum_{j=1}^n \mu_{ij} \times \int_{\Omega} f_j(x) dx}{\sum_{j=1}^n \mu_{ij}} = 1.$$

Định lý 1.6. Kỳ vọng của biến ngẫu nhiên X có hàm mật độ xác suất đại diện $\theta_i(x)$ là

$$\mathbb{E}_{\theta_i}(X) = \frac{\sum_{j=1}^n \mu_{ij} \mathbb{E}_{f_j}(X)}{\sum_{j=1}^n \mu_{ij}}.$$

Chứng minh. Ta có

$$\mathbb{E}_{\theta_i}(X) = \int_{\Omega} x \theta_i(x) dx = \int_{\Omega} x \frac{\sum_{j=1}^n \mu_{ij} f_j(x)}{\sum_{j=1}^n \mu_{ij}} dx = \frac{1}{\sum_{j=1}^n \mu_{ij}} \sum_{j=1}^n \mu_{ij} \underbrace{\int_{\Omega} x f_j(x) dx}_{=\mathbb{E}_{f_j}(X)}.$$

Từ đây, ta suy ra điều phải chứng minh. ■


Ta cũng mở rộng được cho hàm mật độ đại diện chùm đến không gian d -chiều tương tự cho véc-tơ ngẫu nhiên $\mathbf{X}$ và nó cũng thỏa mãn các tính chất của một hàm mật độ xác suất.

Mới đây, Thao Nguyen-Trang *et al.* [17, 23] đề xuất hàm mật độ đại diện Gauss như là một phiên bản đơn giản hóa hàm mật độ kết hợp (1.1).

Định nghĩa 1.15 (Hàm mật độ đại diện Gauss). Hàm mật độ đại diện Gauss có dạng phân phối chuẩn $\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ sao cho tổng khoảng cách giữa chúng đến các hàm mật độ khác là nhỏ nhất, tức là

$$\theta_{G_i}(x) = \arg \min_{f(\boldsymbol{\mu}, \boldsymbol{\Sigma})} \sum_{j=1}^n \mu_{ij} D(f(\boldsymbol{\mu}, \boldsymbol{\Sigma}), f_j(x)).$$

Khác với (1.1), hàm mật độ này chỉ cần tìm một hàm Gauss duy nhất đại diện, không cần tổ hợp lồi các f_j . Điều này giúp giảm nhiều khi chùm chứa các thành phần phân tán bất thường, và tăng khả năng khái quát hóa. Hình 1.2 minh họa cụ thể hai cách biểu diễn hàm mật độ đại diện trong cùng một chùm hàm mật độ Gauss. Để thấy sự khác biệt, hàm mật độ đại diện tập trung vào phân bố trung bình của nó tại các chùm, còn hàm mật độ đại diện Gauss lựa chọn vị trí dựa vào khoảng cách các hàm mật độ với nhau.



Chú thích: Hàm mật độ đại diện thể hiện bằng đường thẳng in đậm cho ba hàm Gauss minh họa bằng nét đứt (a) dựa vào trọng số phân bố đều giữa ba hàm $\mu_{ij} = 1/3$, và (b) dựa vào vị trí tối ưu. Nguồn: Minh họa của tác giả

Hình 1.2. Minh họa hai hàm mật độ xác suất đại diện một chùm hàm mật độ $\mathcal{F}$.


Trong thực tế, ta cần phải ước lượng hàm mật độ xác suất dựa vào dữ liệu rời rạc, luận văn này sử dụng phương pháp ước lượng hàm hạt nhân để chuyển từ bài toán rời rạc sang hàm mật độ xác suất.

Định nghĩa 1.16 (Ước lượng hàm mật độ bằng phương pháp hàm hạt nhân). Giả sử ta có một tập dữ liệu rời rạc gồm n quan sát x_j với $j = 1, \dots, n$ trong không gian $\mathbb{R}^d$. Mỗi điểm $x_j = (x_{1j}, x_{2j}, \dots, x_{dj})^\top$. Hàm mật độ xác suất tại điểm $x = (x_1, x_2, \dots, x_d)^\top$ được ước lượng bằng phương pháp hạt nhân bởi

$$\hat{f}(x) = \frac{1}{n \prod_{i=1}^d bw_i} \sum_{j=1}^n \prod_{i=1}^d \kappa_i \left(\frac{x_i - x_{ij}}{bw_i} \right),$$

trong đó κ_i là hàm hạt nhân theo chiều i có tính chất $\kappa(\cdot) \geq 0$ và $\int \kappa(z) dz = 1$, tham số $bw_i > 0$ là tham số trơn ứng với chiều đó.

Nhận xét. Khi tham số trơn bw nhỏ, hàm mật độ ước lượng sẽ kém trơn và có thể dao động mạnh; ngược lại, nếu bw lớn thì hàm trở nên trơn hơn nhưng có thể làm mất chi tiết quan trọng của phân phối gốc. Các nghiên cứu đã chỉ ra rằng việc lựa chọn tham số trơn có ảnh hưởng lớn hơn đáng kể so với việc lựa chọn loại hàm hạt nhân.



Chú thích: Vùng xám là phân phối thực tế $X \sim 0,3\mathcal{N}(0; 1) + 0,7\mathcal{N}(5; 1)$, các hàm hạt nhân có ảnh hưởng đến độ mượt và khả năng khớp với hàm mật độ thực tế. Nguồn: Minh họa của tác giả.

Hình 1.3. So sánh các hàm hạt nhân trong ước lượng mật độ xác suất

Trong trường hợp đơn giản, có thể chọn cùng một hàm hạt nhân và cùng một tham số trơn cho tất cả các chiều, tức là $\kappa_i \equiv \kappa$ và $bw_i = bw$ với mọi $i = 1, \dots, d$. Một số hàm hạt nhân phổ biến được liệt kê trong Bảng 1.1. Luận văn này khảo sát hàm mật độ ước lượng từ hàm hạt nhân Gauss và Epanechnikov với tham số trơn cố định và được tính bởi công thức của Scott, $bw = 1.06 \times \text{Var}(x_j) \times n^{-1/5}$.

Bảng 1.1. Một số hàm hạt nhân phổ biến dùng trong ước lượng mật độ hạt nhân

Tên hàm	$\kappa(z)$	Miền xác định
Hình chữ nhật	$(1/2)\mathbf{1}_{ z \leq 1}$	$[-1; 1]$
Tam giác	$(1 - z)\mathbf{1}_{ z \leq 1}$	$[-1; 1]$
Epanechnikov	$(3/4)(1 - z^2)\mathbf{1}_{ z \leq 1}$	$[-1; 1]$
Gauss	$\frac{1}{\sqrt{2\pi}} \exp\left(-\frac{z^2}{2}\right)$	$(-\infty, \infty)$
Logistic	$\frac{\exp(-z)}{1 + \exp(-z)^2}$	$(-\infty, \infty)$

1.4 Độ đo đánh giá sự tương tự của các hàm mật độ xác suất

Khoảng cách là độ đo xa-gần các vật thể. Ở đây, khái niệm *khoảng cách* bao hàm cả *độ đo phân biệt*. Phần này giới thiệu một số loại khoảng cách đối với hai đối tượng hàm mật độ bao gồm: khoảng cách hai hàm mật độ, một hàm mật độ với một chùm hàm và giữa hai chùm hàm mật độ bất kỳ.

1.4.1 Sự tương tự của hai hàm mật độ xác suất

Cho f, g là hai hàm mật độ Radon-Nikodym tương ứng với độ đo trong không gian đo được $(\Omega, \mathcal{B})$ với $\mathcal{X} \subseteq \mathbb{R}^d$.

Định nghĩa 1.17 (Khoảng cách hàm mật độ). Hàm $D : \mathcal{F} \times \mathcal{G} \rightarrow \mathbb{R}$ được gọi là khoảng cách của hai hàm mật độ $f \in \mathcal{F}$ và $g \in \mathcal{G}$ nếu nó thỏa mãn ba điều kiện [24]

1. $D(f, g) \geq 0$,
2. $D(f, g) = 0$ khi và chỉ khi $f \equiv g$ hầu khắp nơi, và
3. $D(f, g) = D(g, f)$.

Theo Định nghĩa 1.17, khoảng cách giữa hai hàm mật độ thỏa mãn các tiên đề của mê-tríc. Trong lý thuyết thống kê và thông tin, một mê-tríc được gọi là *khoảng cách* và nửa mê-tríc gọi là *phân kỳ*.


Các khoảng cách của hai hàm mật độ xác suất được thành lập theo hai cách tiếp cận: véc-tơ và xác suất. Cách tiếp cận véc-tơ xem xét các mức giá trị là điểm trong không gian Euclide, nên chúng cũng có thể tính toán dựa vào các khoảng cách hình học thông thường. Bảng 1.2 làm rõ các công thức khoảng cách và độ đo tương tự giữa hai hàm mật độ xác suất.

Bảng 1.2. Bảng tổng kết các loại khoảng cách giữa hai hàm mật độ xác suất

Khoảng cách	$D(f, g)$	Miền giá trị	Đối xứng	Tam giác	Không âm
Chernoff	$-\log \left(\int_{\Omega} f(x)^s g(x)^{1-s} dx \right)$	$[0, \infty)$	✓		✓
$\mathcal{L}_p$	$\left(\int_{\Omega} f(x) - g(x) ^p dx \right)^{1/p}$	$[0, 2]$	✓	✓	✓
Matusita	$\left[2 \left(1 - \int_{\Omega} f(x)^{1/2} g(x)^{1/2} dx \right) \right]^{1/2}$	$[0, \sqrt{2}]$	✓	✓	✓
Hellinger [25]	$1 - \left(\int_{\Omega} f(x)g(x) dx \right)^{1/2}$	$[0, 1]$	✓	✓	✓

Nguồn: Tác giả tổng hợp

Nhận xét. Nhìn vào Bảng 1.2, có thể thấy khoảng cách Chernoff là một tổng quát hóa của khoảng cách Bhattacharyya khi chọn $s = 1/2$. Trong thực tiễn, các khoảng cách $\mathcal{L}_1$ và $\mathcal{L}_2$ thường được sử dụng phổ biến cho nhiều ứng dụng. Đáng chú ý, cả hai loại khoảng cách $\mathcal{L}_p$ và Hellinger đều thỏa mãn đầy đủ các tính chất mê-tríc trong không gian các hàm mật độ xác suất $\mathcal{F}$.



Nguồn: Minh họa của tác giả

Hình 1.4. Dãy khoảng cách giữa hai hàm mật độ Gauss $\mathcal{N}(0, 1)$ và $\mathcal{N}(\mu, 1)$

Ở Hình 1.4, chúng tôi ghi nhận giá trị khoảng cách khi duyệt qua từ $f_1 \sim \mathcal{N}(0, 1)$ và $f_2 \sim \mathcal{N}(\mu, 1)$ với μ chạy từ -10 đến 20 . Ta nhận ra khoảng cách $\mathcal{L}_1$ là hàm không trơn tại $\mu = 0$, tức f_1 trùng với f_2 . Đồng thời, ta trực quan tính bị chặn của các loại khoảng cách này đúng với lý thuyết tại Bảng 1.2.

Nhận xét. Ta thấy khi hai hàm mật độ f_2 cách nhau quá xa hàm f_1 , trường hợp này là $|\mu_2| \gg 0$, tất cả loại khoảng cách hàm mật độ đều bão hòa và không đo được sự khác biệt. Lúc này hai hàm mật độ về mặt không gian rất xa nhau, nhưng khoảng cách không thể đo xa hơn nữa vì nó đã đạt đến ngưỡng lớn nhất. Đây là hạn chế không giữ được vị trí hình học đối với các khoảng cách hàm mật độ.

Luận văn này giới thiệu khoảng cách Wasserstein (hay Kantorovich–Rubinstein), là một mê-tríc hỗ trợ tốt cho tính toán khoảng cách các hàm mật độ không chồng lấp [26] thỏa Định nghĩa 1.17 và bất đẳng thức tam giác. Khoảng cách này được phát triển trong bài toán vận chuyển tối ưu, nhưng chưa được nghiên cứu trong lĩnh vực nhận dạng hàm mật độ.

Định nghĩa 1.18 (Khoảng cách p -Wasserstein). Khoảng cách p -Wasserstein ($p \geq 1$) giữa hai độ đo xác suất μ và ν trong không gian $\mathbb{R}^d$ được định nghĩa là

$$W_p(\mu, \nu) = \inf_{\substack{X \sim \mu \\ Y \sim \nu}} (\mathbb{E} \|X - Y\|^p)^{1/p} = \left(\inf_{\gamma \in \Gamma(\mu, \nu)} \int_{M \times M} d(x, y)^p d\gamma(x, y) \right)^{1/p},$$

Khoảng cách p -Wasserstein đo mức chênh lệch tối ưu giữa hai phân phối xác suất, xét trên tất cả các phép ghép cặp khả dĩ. Tức là nó tính đến công sức để di chuyển và tái sắp xếp khối lượng từ hàm này sang hàm kia. Ở đây, chúng tôi sử dụng $p = 2$ để tính toán đo độ khác biệt giữa hai mật độ xác suất liên tục. Trong thực tế, ta tính toán cụ thể khoảng cách này bằng cách biểu diễn nó qua hàm phân vị. Ta có Định lý 1.7.

Định lý 1.7. Khoảng cách p -Wasserstein giữa hai độ đo xác suất μ và ν có thể được biểu diễn dưới dạng phân vị trong trường hợp 1-chiều bởi định nghĩa

$$W_p^p(\mu, \nu) = \int_0^1 |F_\mu^{-1}(s) - F_\nu^{-1}(s)|^p ds,$$

trong đó F_μ^{-1} và F_ν^{-1} lần lượt là hàm phân vị của μ và ν (Xem Định nghĩa 1.4).

Định lý 1.8 (Khoảng cách 2-Wasserstein giữa hai hàm mật độ Gauss 1 chiều). Giả sử hai hàm mật độ $f_1(x) \sim \mathcal{N}(\mu_1, \sigma_1^2)$ và $f_2(x) \sim \mathcal{N}(\mu_2, \sigma_2^2)$ là hai phân bố Gauss một chiều. Khi đó, khoảng cách 2-Wasserstein giữa chúng là $D_W^2(f_1, f_2) = (\mu_1 - \mu_2)^2 + (\sigma_1 - \sigma_2)^2$.

Chứng minh. Dựa vào Định lý 1.7, ta xét hàm phân vị Gauss $F_i^{-1}(u) = \mu_i + \sigma_i \Phi^{-1}(u)$, với $\Phi^{-1}(u)$ là phân vị chuẩn $\mathcal{N}(0, 1)$. Khi đó,

$$\begin{aligned} D_W^2(f_1, f_2) &= \int_0^1 (\mu_1 + \sigma_1 \Phi^{-1}(u) - \mu_2 - \sigma_2 \Phi^{-1}(u))^2 du \\ &= \int_0^1 ((\mu_1 - \mu_2) + (\sigma_1 - \sigma_2) \Phi^{-1}(u))^2 du \\ &= \int_0^1 [(\mu_1 - \mu_2)^2 + 2(\mu_1 - \mu_2)(\sigma_1 - \sigma_2) \Phi^{-1}(u) + (\sigma_1 - \sigma_2)^2 (\Phi^{-1}(u))^2] du \\ &= (\mu_1 - \mu_2)^2 \underbrace{\int_0^1 du}_{=1} + 2(\mu_1 - \mu_2)(\sigma_1 - \sigma_2) \underbrace{\int_0^1 \Phi^{-1}(u) du}_{=0} + (\sigma_1 - \sigma_2)^2 \underbrace{\int_0^1 (\Phi^{-1}(u))^2 du}_{=1}. \end{aligned}$$

Từ đây ta suy ra được điều phải chứng minh. ■


Tương tự ta cũng suy ra được phương pháp chứng minh cho các Định lý khoảng cách sau.

Định lý 1.9 (Khoảng cách 2-Wasserstein giữa hai hàm mật độ Gauss d -chiều). Giả sử hai hàm mật độ $f_1(x) \sim \mathcal{N}(\mu_1, \Sigma_1)$ và $f_2(x) \sim \mathcal{N}(\mu_2, \Sigma_2)$ là hai phân bố Gauss trong $\mathbb{R}^d$. Khi đó, khoảng cách 2-Wasserstein giữa chúng là

$$D_W^2(f_1, f_2) = \|\mu_1 - \mu_2\|_2^2 + \text{Tr} \left(\Sigma_1 + \Sigma_2 - 2(\Sigma_1^{1/2} \Sigma_2 \Sigma_1^{1/2})^{1/2} \right).$$

Định lý 1.10 (Khoảng cách 2-Wasserstein giữa hai phân phối đều 1-chiều). Giả sử hai hàm mật độ $f_1(x) \sim \mathcal{U}[a_1, b_1]$ và $f_2(x) \sim \mathcal{U}[a_2, b_2]$ là hai phân phối đều một chiều. Khi đó, khoảng cách 2-Wasserstein giữa chúng là $D_W^2(f_1, f_2) = (\mu_1 - \mu_2)^2 + \frac{1}{12}(l_1 - l_2)^2$, trong đó $m_i = \frac{a_i + b_i}{2}$ là trung điểm và $l_i = b_i - a_i$ là độ dài của khoảng $[a_i, b_i]$.

Ví dụ 1.1 (So sánh các loại khoảng cách hàm mật độ). Xét hai hàm mật độ xác suất đều $f_1(x)$ và $f_2(x)$. Hình 1.5 mô tả bốn tình huống khoảng cách giữa hai hàm mật độ này.



Chú thích: Bốn trường hợp mật độ đều với (a) hai hàm rời nhau, cùng chiều rộng; (b) hai hàm rời nhau, khác chiều rộng; (c) hai hàm rời nhau, cách xa nhau; và (d) hai hàm chồng lấp. Ở đây, ô vuông trắng $\square$ biểu thị hàm mật độ $f_1(x)$ và ô vuông xám $\blacksquare$ biểu thị hàm mật độ $f_2(x)$. Nguồn: Minh họa của tác giả.

Hình 1.5. Các trường hợp trong khoảng cách giữa hai hàm mật độ đều $f_1(x)$ và $f_2(x)$.

Xét trường hợp (a), ta tính các khoảng cách như sau

- $\mathcal{L}_1(f_1, f_2) = \int |f_1 - f_2| dx = \int (1 \times 1_{[2,3]}(x) + 1 \times 1_{[5,6]}(x)) dx = \int_2^3 1 dx + \int_5^6 1 dx = 2, 0,$
- $\mathcal{L}_2(f_1, f_2) = (\int (f_1 - f_2)^2 dx)^{1/2} = \left(\int_2^3 1^2 dx + \int_5^6 1^2 dx \right)^{1/2} = 1, 7,$
- $D_B(f_1, f_2)$ không xác định hữu hạn, tiến ra dương vô cùng vì $f_1(x)f_2(x) = 0, \forall x,$
- $D_H(f_1, f_2) = (1 - f_1(x)f_2(x))^{1/2} = \sqrt{1 - 0} = 1, 0,$
- $D_W^2(f_1, f_2) = 9$, vậy $D_W(f_1, f_2) = 3, 0.$

Bảng 1.3 tổng hợp kết quả các phép đo này trong bốn tình huống.

Bảng 1.3. Các kết quả khoảng cách giữa hai hàm mật độ đều

$D(f_1, f_2)$	Trường hợp (a)	Trường hợp (b)	Trường hợp (c)	Trường hợp (d)
$\mathcal{L}_1$	2,0	2,0	2,0	1,0
$\mathcal{L}_2$	1,7	$\sqrt{1,5}$	1,7	0,5
D_B^1	∞	∞	∞	0,5
D_H^2	1,0	1,0	1,0	$\sqrt{0,5}$
D_W^3	3,0	3,5	6,0	1,0

Chú thích: ¹ khoảng cách Bhattacharyya; ² khoảng cách Hellinger; ³ khoảng cách Wasserstein. Nguồn: Tác giả tính toán

Trước hết, các khoảng cách $\mathcal{L}_1$ và $\mathcal{L}_2$ trong các trường hợp (a), (b), và (c), mặc dù $f_1(x)$

và $f_2(x)$ nằm xa dần, nhưng các giá trị $\mathcal{L}_1$ và $\mathcal{L}_2$ hầu như không đổi (đều bằng 2 hoặc $\sqrt{2}$). Khoảng cách này nhận biết được khác biệt hình dáng và phân bố, nhưng không nhận biết tốt yếu tố vị trí trong không gian. Hệ số Bhattacharyya và khoảng cách Hellinger chỉ có ý nghĩa trong trường hợp (d), khi có phần chồng lấp giữa $f_1(x)$ và $f_2(x)$. Điều này cho thấy chúng nhạy với mức độ chồng lấp, nhưng không phân biệt được hai hàm độc lập nhau.

Ngược lại, khoảng cách Wasserstein thể hiện rõ sự nhạy cảm với vị trí hình học, và hình dáng và cả phân bố. Khi hai hàm mật độ cách xa hơn (a) và (c), ta thấy khoảng cách này tăng rất lớn cho thấy hiệu quả so sánh vị trí. Xét (a) và (b), ta thấy khi thay đổi hình dáng hàm mật độ, khoảng cách này cũng có sự khác biệt. Cuối cùng, trường hợp (d) cho thấy khoảng cách cũng nhận biết tốt cho hàm có chồng lấp. Đáng chú ý, trường hợp (a) và (b) của hai loại khoảng cách $\mathcal{L}_2$ và D_W là trái ngược nhau. Khi thay đổi hình dáng, khoảng cách $\mathcal{L}_2$ giảm nhưng D_W lại tăng lên.

Ta tiếp tục định nghĩa các khái niệm liên quan đến khoảng cách hai hàm mật độ.

Định nghĩa 1.19 (Affinity). Hàm $\rho : f \rightarrow [0, 1]$ được gọi là affinity của hai hàm mật độ $f_1(x)$ và $f_2(x)$ nếu nó thỏa mãn ba điều kiện

1. $0 \leq \rho(f_1, f_2) \leq 1$,
2. $\rho(f_1, f_2) = 1$ nếu và chỉ nếu $f_1 \equiv f_2$, và
3. mỗi dãy hàm $\{f_n\}$ thì $\rho(f_n, f_0) \rightarrow 1$

Nhận xét. Affinity đo lường sự giống nhau giữa hai hàm mật độ theo vị trí. Vì vậy, ta có tương quan giữa Affinity và Khoảng cách giữa hai hàm mật độ xác suất $f_1(x)$ và $f_2(x)$ là $D(f_1, f_2) = 1 - \rho(f_1, f_2)$.

Định nghĩa 1.20 (Hàm hạt nhân của khoảng cách). Giả sử $\mathcal{F}$ là không gian các hàm mật độ xác suất trên $(\Omega, \mathcal{A}, \mu)$. Hàm $K : \mathcal{F} \times \mathcal{F} \rightarrow [0; 1]$ được gọi là hạt nhân (hạch) giữa hai hàm mật độ $f_1(x), f_2(x)$ nếu nó thỏa mãn

1. $0 \leq K(f_1, f_2) \leq 1$,
2. $K(f_1, f_2) = K(f_2, f_1), \forall f_1, f_2 \in \mathcal{F}$,
3. với mọi tập hữu hạn $\{f_1, \dots, f_n\} \subset \mathcal{F}$ và hệ số $\alpha_1, \dots, \alpha_n \in \mathbb{R}$,

$$\sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j K(f_i, f_j) \geq 0.$$

Ví dụ 1.2. Hai hạt nhân cơ bản cho khoảng cách hai hàm mật độ $f_1(x)$ và $f_2(x)$ là hạt nhân chuẩn $K_G(f_1, f_2) = \exp\left(-\frac{D^2(f_1, f_2)}{2\sigma^2}\right)$, trong đó, D thuộc họ khoảng cách $\mathcal{L}_p$ để đảm bảo tính mê-tríc, và hạt nhân Bhattacharyya $K_B(f_1, f_2) = \int_{\Omega} \sqrt{f_1(x)f_2(x)} dx$.

Hàm hạt nhân $K(\cdot, \cdot)$ càng gần 1 thì hai hàm mật độ càng giống nhau và ngược lại. Ở đây, việc chuyển đổi từ hàm hạt nhân đến khoảng cách được cho bởi $D = 1 - K_G$ khi các hạt nhân chuẩn hóa $[0; 1]$, hoặc $D = 2(1 - K_H)$ khi là hạt nhân Bhattacharyya.

1.4.2 Sự tương tự của nhiều hơn hai hàm mật độ xác suất


a. Liên kết chùm hàm mật độ

Giả sử hai chùm hàm mật độ không rỗng $\mathcal{F}$ và $\mathcal{G}$ chứa hữu hạn phần tử và $D(f, g)$ là khoảng cách giữa hai hàm mật độ, $f \in \mathcal{F}$ và $g \in \mathcal{G}$. Khoảng cách giữa hai chùm hàm mật độ gọi là *liên kết*, là một ánh xạ $\delta : \mathcal{P}(X) \times \mathcal{P}(X) \times \mathcal{M}(X) \rightarrow \mathbb{R}_+$, trong đó, $\mathcal{P}(X)$ là tập lũy thừa của X .

Bảng 1.4. Bảng tổng kết các loại liên kết Δ giữa hai chùm hàm mật độ xác suất

Liên kết	Ký hiệu	Δ
Liên kết đơn ¹ [27]	$\Delta_{\min}$	$\min_{f \in \mathcal{F}, g \in \mathcal{G}} D(f, g)$
Liên kết đủ ² [28]	$\Delta_{\max}$	$\max_{f \in \mathcal{F}, g \in \mathcal{G}} D(f, g)$
Liên kết tâm	Δ_{centroid}	$D(\theta_{\mathcal{F}}, \theta_{\mathcal{G}})$
Liên kết trung bình	Δ_{avg}	$\frac{1}{\#\mathcal{F} \cdot \#\mathcal{G}} \sum_{f \in \mathcal{F}, g \in \mathcal{G}} D(f, g)$
Liên kết Ward [29]	Δ_{Ward}	$\frac{\#\mathcal{F} \cdot \#\mathcal{G}}{\#\mathcal{F} + \#\mathcal{G}} D^2(\theta_{\mathcal{F}}, \theta_{\mathcal{G}})$

Chú thích: ¹: Khoảng cách lớn nhất; ²: Khoảng cách bé nhất. Nguồn: Tác giả tổng hợp



(a) Liên kết đơn (SLINK) (b) Liên kết đủ (CLINK) (c) Liên kết tâm (UPGMC) (d) Liên kết trung bình (UPGMA) (e) Liên kết Ward

Chú thích: Các loại liên kết này giữa ba chùm hàm mật độ dựa trên (a) tổng khoảng cách nhỏ nhất, (b) tổng khoảng cách lớn nhất, (c) tổng khoảng cách giữa các hàm mật độ trọng tâm, (d) trung bình cộng tất cả các khoảng cách, (e) khoảng cách tối ưu có tổng bình phương các khoảng cách là lớn nhất. Nguồn: Tác giả vẽ lại từ Gao et al. [30]

Hình 1.6. Các loại liên kết giữa các chùm hàm mật độ xác suất.

Khi hai ta cần tính khoảng cách từ hợp hai chùm hàm $\mathcal{F} \cup \mathcal{G}$ đến một chùm hàm $\mathcal{H}$, ta

cũng có thể sử dụng các loại liên kết trên. Trong thực tế, các liên kết Δ được biến đổi thành

$$\begin{aligned}\Delta_{\min}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) &= \min \{D_{f \in \mathcal{F}, h \in \mathcal{H}}(f, h), D_{f \in \mathcal{G}, h \in \mathcal{H}}(g, h)\}, \\ \Delta_{\max}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) &= \max \{D_{f \in \mathcal{F}, h \in \mathcal{H}}(f, h), D_{f \in \mathcal{G}, h \in \mathcal{H}}(g, h)\}, \\ \Delta_{\text{avg}}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) &= \frac{1}{\#(\mathcal{F} \cup \mathcal{G}) \cdot \#\mathcal{H}} \sum_{\substack{f \in \mathcal{F} \cup \mathcal{G} \\ h \in \mathcal{H}}} D(f, h), \\ \Delta_{\text{centroid}}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) &= D(\theta_{\mathcal{F} \cup \mathcal{G}}, \theta_{\mathcal{H}}), \\ \Delta_{\text{Ward}}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) &= \frac{\#(\mathcal{F} \cup \mathcal{G}) \cdot \#\mathcal{H}}{(\#\mathcal{F} \cup \#\mathcal{G}) \cup \#\mathcal{H}} D^2(\theta_{\mathcal{F} \cup \mathcal{G}}, \theta_{\mathcal{H}}).\end{aligned}$$

Ví dụ 1.3 (Liên kết các chùm hàm mật độ). Giả sử ta có ba chùm hàm mật độ xác suất Gauss $\mathcal{F}, \mathcal{G}$ và $\mathcal{H}$. Tính các liên kết $\Delta(\mathcal{F}, \mathcal{G})$ và $\Delta(\mathcal{F} \cup \mathcal{G}, \mathcal{H})$ biết khoảng cách giữa hai hàm mật độ là $\mathcal{L}_2$ và

chùm $\mathcal{F} = \{f_1 = \mathcal{N}(0, 3; 1), f_2 = \mathcal{N}(1; 1)\}$,
chùm $\mathcal{G} = \{g_1 = \mathcal{N}(4, 0; 1), g_2 = \mathcal{N}(5, 5; 1), g_3 = \mathcal{N}(4, 8; 1)\}$, và
chùm $\mathcal{H} = \{h_1 = \mathcal{N}(9, 1; 1), h_2 = \mathcal{N}(8, 0; 1)\}$.

Ví dụ đã được giải chi tiết trong Phụ lục B (tr. 43) cụ thể hóa cách tính toán của các liên kết này.

b. Tương tự chùm hàm mật độ

Giả sử tập hợp $\mathcal{F}$ có nhiều hơn hai phần tử ($n > 2$)

Bảng 1.5. Tổng kết các tương tự giữa các chùm hàm mật độ xác suất

Tương tự	$\Delta(\mathcal{F})$
Affinity của Matusita [31]	$\int_{\Omega} \left(\prod_{j=1}^n f_j(x) \right)^{1/n} dx$
Affinity của Toussaint [32]	$\int_{\Omega} \left(\prod_{j=1}^n f_j(x) \right)^{\alpha_j} dx$
Độ rộng chùm [15]	$\int_{\Omega} f_{\max}(x) dx - 1$
Hệ số tương tự chùm [33]	$\frac{k}{k-1} \left(1 - \frac{1}{k} \int_{\Omega} f_{\max}(x) dx \right)$
Nguồn: Tác giả tổng hợp	

Nhận xét. Trong Bảng 1.5 trường hợp Affinity của Toussaint có các hệ số $\alpha_1 = \alpha_2 = \dots = \alpha_n = \frac{1}{n}$, nó trở thành Affinity của Matusita. Khi Affinity của Matusita có $n = 2$ thì nó trở thành hệ số Bhattacharyya []. Ngoài ra hệ số tương tự chùm chuẩn hóa tuyến tính độ rộng chùm.

1.5 Phương pháp số xấp xỉ tích phân

Trong khoa học máy tính, các khoảng cách giữa các hàm mật độ xác suất thường chứa các tích phân xác định, vốn không thể tính chính xác bằng phương pháp thông thường. Do đó, các tích phân này cần xấp xỉ bằng phương pháp số. Luận văn này, chúng tôi chọn sử dụng phương pháp hình thang nhằm cải thiện độ chính xác so với tổng Riemann nhưng cũng không tốn quá nhiều tài nguyên như Monte Carlo hay Simpsons. Một tích phân trên miền $\Omega \subset \mathbb{R}^d$ được xấp xỉ bằng công thức tổng quát

$$\int_{\Omega} f(x) dx = \lim_{h \rightarrow 0} \sum_i h^d w_i f(x).$$

Khi này, giả sử hàm $f : [a, b] \rightarrow \mathbb{R}$, chia đoạn $[a, b]$ thành n , phương pháp hình thang một chiều xấp xỉ tích phân

$$\int_a^b f(x) dx \approx \frac{h}{2} \left(f(x_0) + 2 \sum_{i=1}^{n-1} f(x_i) + f(x_n) \right),$$

trong đó $x_i = a + ih, i = 0, \dots, n$.

1.6 Một số định lý hội tụ

1.7 Phân tích chùm cho hàm mật độ xác suất

Phân tích chùm là một nhánh chính của nhận dạng không được giám sát [34–36]. Nó có nhiệm vụ khám phá dựa vào sự tương tự giữa các mẫu trong dữ liệu đầu vào [4, 8]. Ví dụ như khi ta cần khoanh vùng khối u trong hình ảnh MRI, hay trong các báo cáo định tính cần nhóm/tổng hợp ý kiến hay quan điểm theo các chủ đề khác nhau. Câu hỏi đặt ra là *làm thế nào chúng ta chắc chắn một loại hình chưa được quan sát cùng loại sẽ có cùng đặc điểm với một vài loại hình đã được quan sát*. Các thuật toán này sẽ thích hợp để khám phá các cấu trúc và mối quan hệ có ý nghĩa giữa các mẫu trong dữ liệu, tạo điều kiện thuận lợi các phân tích sâu hơn và cho nhiều ứng dụng [11, 21].

Thuật toán phân chùm dựa vào trọng tâm đề xuất hàm mục tiêu khác nhau, nhưng mục tiêu chung là sự phân bố tối thiểu khoảng cách phần tử trong chùm trong khi vẫn giữ tối đa khoảng cách phần tử giữa các chùm. Tác vụ này được chia thành hai loại theo lý thuyết mờ [37] là phân chùm không mờ (bao gồm k -mean [11], phân cấp thứ bậc và phân chùm tự cập nhật) và phân chùm mờ (bao gồm Fuzzy c -means [21, 22]).

1.7.1 Phân tích chùm không mờ

Phân tích chùm không mờ (hay phân chùm cứng) yêu cầu một phần tử chỉ thuộc duy nhất một chùm cố định. Tiểu mục này trình bày hai khía cạnh chính của phân tích chùm bao gồm phân tích chùm phân vùng (dựa trên trọng tâm) và phân cấp thứ bậc. Phân tích chùm phân vùng k -means và phân tích chùm tự cập nhật là các thuật toán đã được sử dụng tích cực cho dữ liệu hàm mật độ xác suất. Ngoài ra, chúng tôi bổ sung thêm một số kiến thức về phân cấp thứ bậc cũng đã được quan tâm trong lĩnh vực này.

a. Phân tích chùm k -means

Phân tích chùm phân vùng giả sử $\mathcal{S}$ là tập các véc-tơ d -chiều x_j , trong đó $j = 1, 2, \dots, n$. Mỗi đối tượng o_j liên hệ với hàm mật độ xác suất $f_j(x)$. Tập $\mathcal{F}$ gồm họ n -hàm mật độ trên Ω . Bài toán phân tích chùm phân bố j -hàm mật độ vào c -chùm nguyên, với $i = 1, 2, \dots, c$ thỏa mãn ba ràng buộc

1. Hợp tất cả các chùm $\bigcup_i c_i$ bằng $\mathcal{F}$,
2. Giao của mỗi chùm là rỗng, $c_i \cap c_j = \emptyset$, với mỗi $i \neq j$,
3. Lực lượng của mỗi chùm là khác rỗng, $|c_i| \neq \emptyset$.

Phép gán này được mô tả bằng một ánh xạ nhiều-đến-một, hay còn gọi là bộ mã hóa $c_i = c(f_j)$, trong đó đối tượng f_j gán vào chùm c_i là duy nhất. Cụ thể, ràng buộc 1 đảm bảo tất cả các đối tượng phải được phân tách thành các chùm, trong đó, mỗi chùm phải chứa ít

nhất một phần tử (ràng buộc 3) và không có đối tượng nào được xếp vào cùng một chùm (ràng buộc 2).

Thuật toán k -means lần đầu được đề cập bởi J. Macqueen [7] cho dữ liệu rời rạc nhưng mãi đến [11, 15], nó được mở rộng cho hàm mật độ với ý tưởng giải bài toán bán giám sát. Phân tích chùm KCF là bài toán tối thiểu đơn mục tiêu cho tổng các bình phương khoảng cách trong chùm các hàm mật độ, tức là

$$\text{Minimise : } J(U, \Theta | \mathcal{F}, c) = \sum_{i=1}^c \sum_{f_j(x) \in c_i} \mu_{ij} D^2(\theta_i, f_j), \quad (k\text{-means})$$

trong đó, μ_{ij} là biến tiềm ẩn thể hiện mức độ thành viên của hàm mật độ $f_j(x)$ thỏa $\mu_{ij} = 1_{j \in c_i}$. Tức là $\mu_{ij} = 1$ nếu hàm j thuộc chùm c_k và $\mu_{ij} = 0$ nếu ngược lại. Hàm $\theta_i(x)$ là hàm mật độ trọng tâm của chùm thứ c_i . Ký hiệu $D^2(\theta_i, f_j)$ là khoảng cách giữa hàm mật độ trọng tâm $\theta(x)$ đến các đối tượng $f_j(x)$ còn lại trong dữ liệu.

Bổ đề 1.5 (Thành lập hàm mật độ đại diện). *Giả sử $\mathcal{F}$ -hàm mật độ được phân thành c -chùm qua các mức độ thành viên μ_{ij} , với bình phương khoảng cách $D^2(\theta_i, f_j)$. Khi đó, hàm mật độ đại diện $\theta_i^*(x)$ tối ưu trên mỗi chùm c_i được cho bởi công thức*

$$\theta_i^*(x) = \frac{\sum_{f_j \in c_i} \mu_{ij} f_j(x)}{\sum_{f_j \in c_i} \mu_{ij}}.$$

Chứng minh. Từ hàm mục tiêu k -means, ta tính các đạo hàm riêng theo c_i .

$$\begin{aligned} \frac{\partial}{\partial \theta_i(x)} J(\mathcal{F}, c) &= \frac{\partial}{\partial \theta_i} \sum_{i=1}^c \sum_{f_j(x) \in c_i} \mu_{ij} D^2(\theta_i, f_j(x)) = \sum_{i=1}^c \sum_{f_j(x) \in c_i} \mu_{ij} \frac{\partial}{\partial \theta_i(x)} \int_{\Omega} (\theta_i(x) - f_j(x))^2 dx \\ &= \sum_{f_j(x) \in c_i} \mu_{ij} \int_{\Omega} 2(\theta_i(x) - f_j(x)) dx. \end{aligned}$$

Để hàm J đạt cực trị, ta cho đạo hàm vừa tính bằng 0. Tức là,

$$\sum_{f_j(x) \in c_i} \mu_{ij} \int_{\Omega} 2(\theta_i(x) - f_j(x)) dx = 0 \Leftrightarrow \theta_i(x) \sum_{f_j(x) \in c_i} \mu_{ij} = \sum_{f_j(x) \in c_i} \mu_{ij} f_j(x).$$

Từ đây suy ra điều phải chứng minh. Tóm lại, mật độ đại diện tối ưu để cực tiểu hàm mục tiêu là hàm mật độ trọng tâm (1.1) các hàm mật độ trong các chùm. ■

Nhận xét. Vì mỗi hàm mật độ trọng tâm (1.1) được đại diện trừu tượng bằng trung bình có trọng số của từng chùm, nên kết quả trọng tâm này có thể không đồng nhất với bất kỳ đối tượng nào trong mẫu. Thay vào đó, mật độ trọng tâm này nằm bất kỳ trong không gian, đóng vai trò như một đối tượng tham chiếu để các hàm mật độ khác so sánh [38]. Hơn nữa, vì ma trận phân vùng $\mu_{ij} = 1_{j \in c_i}$ nên ta có thể rút gọn hàm mật độ đại diện (1.1) thành

$$\theta_i(x) = \frac{1}{\#c_i} \sum_{f_j(x) \in c_i} f_j(x). \quad (1.2)$$

Algorithm 1: Giải thuật phân tích chùm KCF

```
1: procedure KCF( $c, \varepsilon$ ) ▷ Cho trước số chùm  $c$ 
2:    $t \leftarrow 0$ 
3:   Khởi tạo  $\mu^{(t)}$  và  $\Theta^{(t)}$  ngẫu nhiên
4:   while  $\|J^{(t+1)} - J^{(t)}\| < \varepsilon$  do
5:      $t \leftarrow t + 1$ 
6:     Cập nhật  $\mu^{(t+1)}$  bằng Công thức  $\mu_{ij} = 1_{j \in c_i}$ 
7:     Cập nhật  $\Theta^{(t+1)}$  bằng Công thức (1.2)
8:   end while
9:   return  $\mu$  và  $\Theta$ . ▷ Ma trận phân vùng và hàm mật độ đại diện
10: end procedure
```

Bổ đề 1.6 (Sự hội tụ). Sau mỗi bước lặp của thuật toán k -means, hàm mục tiêu k -means luôn giảm.

Chứng minh. Giả sử tập $\mathcal{Z}^{(t)} = \{\mathcal{F}_1^{(t)}, \dots, \mathcal{F}_k^{(t)}\}$ là phân hoạch của tập $\mathcal{F}$ tại bước lặp t bất kỳ và hàm mục tiêu $J^{(t)}$. Khi đó, $J^{(t+1)}$ có phân hoạch $\mathcal{Z}^{(t+1)}$ tại bước lặp tiếp theo. Ta cần chứng minh $J^{(t)} - J^{(t+1)} \geq \sum_{i=1}^c |\mathcal{F}_i^{(t+1)}| d(\theta_{\mathcal{F}_i^{(t)}} - \theta_{\mathcal{F}_i^{(t+1)}})$. ■

b. Phân tích chùm thứ bậc

Phân cấp thứ bậc giả định tập $\mathcal{P}$ trong [39]


Algorithm 2: Giải thuật phân cụm thứ bậc tích tụ (HCF)

```
1: procedure HCF
2:   Khởi tạo:  $P_n = \{c_1, c_2, \dots, c_N\}$  với  $c_j = \{f_j\}$ ,  $j = 1, \dots, n$ 
3:    $t \leftarrow 1$ 
4:   while  $n - t > 1$  do
5:     Chọn hai  $c_i, c_j \in P_{n-t+1}$  sao cho thỏa tiêu chí cục bộ
6:      $c_{n+t} \leftarrow c_i \cup c_j$ 
7:      $P_{n-t} \leftarrow (P_{n-t+1} \cup \{c_{n+t}\}) \setminus \{c_i, c_j\}$ 
8:      $t \leftarrow t + 1$ 
9:   end while
10: end procedure
```

Ví dụ 1.4 (Phân cấp thứ bậc hàm Gauss 1-chiều). Cho bảy hàm mật độ chuẩn một chiều $\mathcal{F}$ cho bởi Vo-Van, Tai and Pham-Gia, T., [15] có phương sai đồng nhất $\sigma_i^2 = 1, i = 1, \dots, 7$ và các trung bình lần lượt là $\mu_i = \{0, 3; 4, 0; 9, 1; 1, 0; 5, 5; 8, 0; 4, 8\}$. Hãy phân cấp thứ bậc với khoảng cách $D(f_1, f_2) = \mathcal{L}_2$ và liên kết $\Delta_{\max}(\mathcal{F}_1, \mathcal{F}_2)$ là liên kết đủ.

Bài giải. Ta có kết quả phân cấp thứ bậc tích tụ bởi Hình 1.7. Bài giải chi tiết được phân

tích trong Phụ lục B (tr. 43). Quá trình phân cấp được thực hiện với hai phương pháp liên kết đủ liên kết Ward. Nhìn Hình 1.7, ta thấy phương pháp liên kết đủ có xu hướng tạo ra các chùm nhỏ, chặt chẽ, và nhạy cảm với nhiễu ở biên. Ngược lại, liên kết Ward cho kết quả các chùm có tính đồng nhất cao hơn về phân bố, làm cây phân cấp cân đối.



Chú thích: Cây phân cấp ở phía trên thể hiện cách sắp xếp và nhóm các hàm mật độ dựa trên liên kết, phần dưới thể hiện ma trận khoảng cách tương ứng với từng hàm mật độ đó. Nguồn: Minh họa của tác giả

Hình 1.7. Kết quả phân cấp thứ bậc tích tụ đối với Ví dụ 1.4

c. Phân tích chùm tự cập nhật

Phân tích chùm tự cập nhật (SUP) lần đầu tiên được giới thiệu bởi Chen and Shiu năm 2007 [] với ý tưởng đơn giản là các đối tượng thuộc cùng một chùm sẽ hội tụ tại cùng một điểm. Thuật toán SUP được kết luận khắc phục hiệu quả các vấn đề tồn đọng trong k -means, đồng thời chứng minh được sự hội tụ qua các vòng lặp. Sau năm 2015, SUP được phát triển nhanh và nhiều cải tiến mới cho dữ liệu hàm mật độ.

1.7.2 Phân tích chùm mờ

Phân tích chùm mờ được xây dựng lần đầu tiên cho hàm mật độ bởi Thao Nguyen-Trang and Tai Vo-Van [21] với sự phát triển từ phần tử rời rạc do [40]. Khác biệt giữa nó với phân chùm cứng là sự chấp nhận thuộc nhiều chùm của một phần tử với một *mức độ phân vùng* mềm hơn. Điều này hữu ích khi ranh giới giữa các hàm là không chắc chắn.

Giả sử $\mathcal{F}$ chưa được gán nhãn, mục tiêu của bài toán là tối thiểu hóa tổng trọng số các giá

trị hàm thành viên với siêu tham số m và khoảng cách.

$$\text{Minimise : } J(U, \Theta | \mathcal{F}, c, m) = \sum_{i=1}^c \sum_{j=1}^n \mu_{ij}^m D^2(\theta_i, f_j), \quad (\text{FCF})$$

$$\text{s.t : } \sum_{i=1}^c \mu_{ij} = 1, \quad \forall j \in 1, \dots, n, \quad (\text{C1})$$

$$\mu_{ij} \in [0; 1], \quad \forall i \in 1, \dots, c, \forall j \in 1, \dots, n, \quad (\text{C2})$$

$$\sum_{j=1}^n \mu_{ij} > 0, \quad \forall i \in 1, \dots, c. \quad (\text{C3})$$

Thuật toán phân tích chùm mờ cho phần tử rời rạc đã được chứng minh là tối ưu toàn cục bởi [37, 41, 42] qua định lý Zangwill [43]. Đặc biệt, [44] mới đây chứng minh sự hội tụ toàn cục qua thuật toán độ dốc. Do đó, luận văn này chỉ giới thiệu Định lý 1.11 trình bày sự thành lập của ma trận phân vùng và hàm mật độ đại diện từ hàm mục tiêu J cho dữ liệu hàm mật độ xác suất.


Định lý 1.11. Cho $\mathcal{F}$ chứa $n > c$ hàm mật độ xác suất và $m > 1$. Xét $D_{ij} = D(\theta_i, f_j)$ với $1 \leq j \leq n, 1 \leq i \leq c$. Với mỗi j , xác định các tập $I_j = \{i | D_{ij} = 0, 1 \leq i \leq c\}$ và tập $I_j^c = \{1, \dots, c\} \setminus I_j$. Khi đó J có thể đạt cực tiểu toàn cục khi và chỉ khi

$$\theta_i^*(x) = \frac{\sum_{j=1}^n (\mu_{ij}^*)^m f_j(x)}{\sum_{j=1}^n (\mu_{ij}^*)^m}, \quad \text{và} \quad (1.3)$$

$$\mu_{ij}^* = \frac{(D_{ij}^*)^{-1/(m-1)}}{\sum_{l=1}^n (D_{lj}^*)^{-1/(m-1)}}, \quad \text{nếu } I_j \neq \emptyset, \quad \text{và}, \quad (1.4)$$

$$\mu_{ij}^* = 0, \forall i \in I_j^c \quad \text{và} \quad \sum_{i \in I_j^c} \mu_{ij}^* = 1, \quad \text{nếu } I_j \neq \emptyset, \quad (1.5)$$

Nhận xét. Ở đây, tham số m thể hiện mức độ mờ của ma trận phân vùng μ_{ij} . Để minh họa ảnh hưởng của tham số m , ta giả định hai chùm với $D_{2j} = 2 - D_{1j}$, và xét giá trị μ_{1j} theo khoảng cách này chạy từ 0 đến 2. Hình 1.8 trực quan hóa cách m điều chỉnh mức độ. Khi $m \rightarrow 1$, ma trận phân vùng kết quả sẽ tiến về ma trận phân vùng không mờ ($\mu_{ij} = 1_{j \in c_i}$). Khi $m \rightarrow \infty$, các giá trị μ_{ij} sẽ trở nên bằng nhau ($= 1/c$) làm mất khả năng gán các hàm mật độ xác suất vào các chùm.



Chú thích: Giá trị μ_{1j} tại trục tung biểu diễn mức độ phân vùng tại chòm 1 theo khoảng cách $\mathcal{L}_{1j}$ với các giá trị $m = 1,1; 1,5; 2,0; 3,0; 5,0; 10,0$. Khi $m \rightarrow 1$, đường phân vùng trở nên gãy; khi m tăng, đường cong trở nên phẳng và đều ở $y = 1/2$. Nguồn: Minh họa của tác giả.

Hình 1.8. Biểu đồ phân vùng mờ theo khoảng cách D_{1j} với các hệ số m khác nhau.

Nhiều nghiên cứu tổng quát hóa tham số m đã được đặt ra sau khi thuật toán này công bố. Tuy nhiên, cho đến nay các nhà phân tích vẫn chọn tiêu biểu $m = 2$ vì tính dễ giải thích. Luận văn này, chúng tôi chọn cố định $m = 2$.

Thuật toán phân chòm mờ FCF được thực hiện qua các bước như sau [6, 21].

Algorithm 3: Giải thuật phân tích chòm mờ (FCF)

```

1: procedure FCF( $c, \varepsilon$ ) ▷ Cho trước số chòm  $c$ 
2:    $t \leftarrow 0$ 
3:   Khởi tạo  $\mu^{(t)}$  và  $\Theta^{(t)}$  ngẫu nhiên
4:   while  $\|\mu^{(t+1)} - \mu^{(t)}\| < \varepsilon$  do
5:      $t \leftarrow t + 1$ 
6:     Cập nhật  $\Theta^{(t+1)}$  bằng Công thức (1.3)
7:     Cập nhật  $\mu^{(t+1)}$  bằng Công thức (1.4) và (1.5)
8:   end while
9:   return  $\mu$  và  $\Theta$ . ▷ Ma trận phân vùng và hàm mật độ đại diện
10: end procedure

```

Kết thúc thuật toán ta nhận được ma trận phân vùng U_f và các trọng tâm chòm Θ . Trong đó, tiêu chuẩn dừng cho FCF là chênh lệch tuyệt đối tối đa giữa các phần tử của ma trận phân vùng $\mu^{(t)}$ và $\mu^{(t-1)}$ liên tiếp phải thấp hơn ngưỡng dương ε cho trước. Cuối cùng, ta có thể giải mờ theo quy tắc $c_i = \arg \max_j \mu_{ij}$. Tức là một hàm mật độ $f_j(x)$ được xếp vào chòm c_i khi

và chỉ khi nó có mức độ phân vùng tại cụm đó là cao nhất.

Ví dụ 1.5 (Phân cụm mờ hàm Gauss 1-chiều). Ta sử dụng lại dãy hàm mật độ trong Ví dụ 1.4. Hãy phân tích $\mathcal{F}$ thành ba cụm, biết $m = 2$ và khoảng cách là $\mathcal{L}_2$.

Ta có kết quả sau khi thực hiện các vòng lặp được giải chi tiết ở Phụ lục (tr. 43).

Nhận xét. So với kết quả phân tích cụm KCF, kết quả của phân tích cụm FCF mang tính tổng quát hơn. Dựa vào giá trị phân vùng μ_{ij} , ta nhận thấy được mức độ tin cậy một hàm mật độ $f_j(x)$ xếp vào cụm c_i . Nếu giá trị phân vùng μ_{ij} tại cụm c_i này lớn, ta có thể chắc chắn vào kết quả phân bổ, ngược lại, nếu giá trị này không cao, ta biết được hàm mật độ này có khả năng thuộc vào một cụm khác hoặc một cụm mới thay vì thuộc vào cụm c_i .

So sánh về mặt phức tạp thời gian và phức tạp dung lượng, Bảng 1.6 cho thấy phương pháp k -mean đơn giản hơn và ít tốn tài nguyên tính toán hơn so với Fuzzy c -mean và thuật toán thứ bậc.

Bảng 1.6. So sánh độ phức tạp của ba thuật toán phân cụm

Thuật toán	Phức tạp thời gian	Phức tạp không gian
Phân cụm KCF	$\mathcal{O}(ncdi)$	$\mathcal{O}(n + cd)$
Phân cấp thứ bậc	$\mathcal{O}(n^2 \log n)$	$\mathcal{O}(n^2)$
Phân cụm tự SUP		
Phân cụm FCF	$\mathcal{O}(ncdi)$	$\mathcal{O}(nc)$

Chú thích: n là # đối tượng trong dữ liệu, c là # cụm, d là # chiều dữ liệu, i là # vòng lặp.

Nhận xét. Phân tích cụm phân vùng dựa vào trọng tâm rất đơn giản. Tuy nhiên, nó cũng có một số khuyết điểm bao gồm tính không xác định của các siêu tham số, chất lượng dữ liệu đầu vào và khả năng giải thích của mô hình. Đầu tiên, họ thuật toán này không cung cấp c cụm tối ưu. Đôi khi, ta không có tri thức về số lượng c , dẫn đến khó khăn khi phân cụm các mẫu có số chiều lớn dẫn đến nguy cơ quá khớp. Theo Goutte *et al.*, “*khi số lượng cụm không phản ánh trong dữ liệu, kết quả cuối cùng cơ bản là vô nghĩa*” [45]. Ngoài ra, do giả định tối ưu lồi, thuật toán dựa trên trọng tâm thường hoạt động hiệu quả nhất với hình dạng gần cầu, và có thể gặp thách thức khi áp dụng cho dữ liệu chứa nhiễu, ngoại lệ, có chồng lấp giữa các cụm hoặc có sự chênh lệch lớn về kích thước và mật độ. Cuối cùng, hàm mật độ trọng tâm cụm ban đầu cũng ảnh hưởng đến kết quả tối ưu dù đã có nhiều khuyến nghị như k -means⁺⁺, X-means.

Phân tích cụm thứ bậc thì không cần tiên nghiệm số lượng cụm c . Tuy nhiên, nó có độ phức tạp cao. Nhất là khi dữ liệu lớn, ta phải tính toán một khối lượng khoảng cách rất lớn. Phân tích cụm tự cập nhật

Tóm lại, kết quả thuật toán phân tích chùm có mặt của thiên kiến dữ liệu, tên nhãn và thuật toán. Thuật toán sẽ phụ thuộc vào các đầu vào do người dùng cung cấp và được chuyển dịch thành các đầu ra để người dùng diễn giải. Và liệu rằng thuật toán phân tích chùm có thật sự học được cách xác định các loại tự nhiên và khách quan hay không vẫn còn là câu hỏi bỏ ngõ giữa các nhà thống kê [38, 46, 47].

1.8 Phân loại cho hàm mật độ xác suất

Phương pháp phân loại là một nhánh của nhận dạng có giám sát, phát triển với mục tiêu thành lập quy tắc quy nạp có chức năng phân tách được các lớp quan tâm với sai lầm thực nghiệm tối thiểu. Các quy luật đánh giá có bệnh B hay không dựa vào những dữ liệu cho trước chính là thực hiện bài toán phân loại. Hay phân biệt được hữu hạn các biểu cảm khuôn mặt dựa vào hình ảnh cũng phải thực hiện bài toán phân loại. Đầu ra của mô hình phân loại là ước tính hoặc dự đoán hữu hạn các nhãn cho trước (không đo được) với dữ liệu mới chưa được mô hình hóa [48].

Trong bài toán phân loại, ta giả sử tồn tại một không gian đầu vào $\mathcal{F}$ và tập nhãn rời rạc $Y = \{1, 2, \dots, C\}$. Cặp dữ liệu (f, y) là biến ngẫu nhiên có phân phối chung $P_{\mathcal{F}, Y}$ trên $\mathcal{F} \times Y$. Mục tiêu của bài toán là tìm một ánh xạ phân loại $h : \mathcal{F} \rightarrow Y$ thuộc không gian giả thuyết $\mathcal{H}$ sao cho tối thiểu hóa giá trị kỳ vọng của hàm mất mát $\ell : Y \times Y \rightarrow \mathbb{R}_{\geq 0}$, tức là

$$h^* = \arg \min_{h \in \mathcal{H}} \mathbb{E}(f, y) \sim P_{\mathcal{F}, Y} [\ell(h(f), y)].$$

Tuy nhiên, do phân phối thực $P_{\mathcal{F}, Y}$ là chưa biết, ta cần tiếp cận qua một tập huấn luyện $\mathcal{D}_n = \{(f_1, y_1), \dots, (f_n, y_n)\} \subset \mathcal{F} \times Y$. Vì vậy, ta giải bài toán

$$\hat{h}_n = \arg \min_{h \in \mathcal{H}} \frac{1}{n} \sum_{j=1}^n \ell(h(f_j), y_j).$$

Bốn thuật toán phân loại dựa vào thống kê là Naive Bayes, Cây quyết định, hồi quy Logistics, phân biệt Fisher [49] và Perceptron [50]. Những phương pháp này là kinh điển và đã được áp dụng phát triển cho đến hiện nay. Nó cũng chính là cơ sở để xây dựng và áp dụng cho hàm mật độ xác suất với sự cải tiến, đặc biệt là phương pháp Bayes [18, 51].

Phương pháp phân loại cho hàm mật độ xác suất là một bài toán mới mẻ nên còn nhiều thách thức lớn cả bề sâu và bề rộng. Luận văn này tập trung nghiên cứu phương pháp hồi quy logistics, naive Bayes và máy véc-tơ hỗ trợ cho dữ liệu hàm mật độ.

1.8.1 Hồi quy logistics

Phương pháp này được tổng quát hóa cho dữ liệu hàm bởi các nghiên cứu của Akturk et al. [52]. Luận văn này cụ thể hóa cho hàm mật độ xác suất. Mô hình hồi quy logistic cho dữ

liệu hàm mật độ có dạng

$$\pi_i = \mathbb{P}(Y_j = 1 | \mathcal{F}(x) = \mathcal{F}_j(x)) = \frac{\exp\{\beta_0 + \int_{\Omega} \mathcal{F}(x)\beta(x) dx\}}{1 + \exp\{\beta_0 + \int_{\Omega} \mathcal{F}(x)\beta(x) dx\}}, \quad (1.6)$$

trong đó $\beta_0 \in \mathbb{R}$ là hằng số chặn, và $\beta(x) \in \mathcal{L}_2[\Omega]$ là hàm hệ số cần ước lượng. Để giải phương trình (1.6), biến đổi logit được sử dụng

$$l_j = \log\left(\frac{\pi_j}{1 - \pi_j}\right) = \beta_0 + \int_{\Omega} \mathcal{F}(x)\beta(x) dx.$$

Mục tiêu tiếp theo là ước lượng β_0 và hàm $\beta(x)$. Do $\beta(x)$ là vô hạn chiều, ta chiếu hàm này vào một tập hàm cơ sở chọn trước để ước lượng, cụ thể là hàm Gauss, wavelet, chuỗi Fourier, đa thức Bernstein và Legendre, hoặc B-spline. Khi đó,


$$l_j = \beta_0 + \sum_{m=1}^M \theta_m \underbrace{\int_{\Omega} \psi_m(x) \mathcal{F}_j(x) dx}_{=: \phi_{j,m}},$$

trong đó $\phi_{j,m}$ là mô-men của hàm mật độ $\mathcal{F}_j(x)$ trên hàm cơ sở $\psi_m(x)$. Khi đó, bài toán ước lượng $\beta(x)$ chuyển thành $\mathcal{L} = \max_{\beta_0, \theta} \sum_{j=1}^n [y_j \log \pi_j + (1 - y_j) \log(1 - \pi_j)]$. Ta sử dụng thuật toán độ dốc để tối ưu hóa hàm mục tiêu $\mathcal{L}$ này.

Ví dụ 1.6 (Phân loại hàm mật độ bằng hồi quy logistics). Giả sử hai lớp hàm mật độ Gauss $\mathcal{F}$ và $\mathcal{G}$ có μ_i ở hai lớp này lần lượt là

$$\mu_{\mathcal{F}} = \{1, 0; 1, 5; 2, 0; 2, 5; 6, 0\}, \text{ và } \mu_{\mathcal{G}} = \{4, 5; 7, 5; 8, 5; 8, 0; 8, 5\},$$

với $\sigma_{\mathcal{F}}^2 = 0,4$ và $\sigma_{\mathcal{G}}^2 = 0,9$. Hãy phân loại hàm mật độ Gauss mới $h(x) = \mathcal{N}(3, 0; 0, 9)$ vào một trong hai lớp.



Hình 1.9. Hàm $\beta(x)$ được ước lượng qua 10 hàm cơ sở Gauss.

Nhận xét. Hàm hệ số $\hat{\beta}(x)$ cho phép phân tích vai trò đóng góp của từng vùng x trong việc phân biệt nhị phân.

1.8.2 Máy véc-tơ hỗ trợ

1.8.3 Phương pháp naive Bayes

Phương pháp Bayes đã được nhiều nhà thống kê quan tâm cho dữ liệu hàm mật độ xác suất tại []. Cho không gian $\Omega \subset \mathbb{R}$ các hàm mật độ xác suất liên tục khả tích. Một dữ liệu hàm mật độ có hai lớp $Y = 0$ hoặc 1 và một hàm mới $h(x)$ cần phân loại. Khi đó, xác suất hậu nghiệm Bayes để xếp hàm mật độ h vào một trong hai lớp này là

$$\mathbb{P}(\mathcal{F} | h) = \frac{\mathbb{P}(\mathcal{F})f(h | \mathcal{F})}{\mathbb{P}(\mathcal{F})f(h | \mathcal{F}) + \mathbb{P}(\mathcal{G})f(h | \mathcal{G})}, \text{ và } \mathbb{P}(\mathcal{G} | h) = 1 - \mathbb{P}(\mathcal{F} | h).$$

Mật độ $f(h | \mathcal{F})$ biểu diễn khả năng quan sát hàm $h(x)$ nếu nó thuộc lớp $\mathcal{F}$. Vì vậy, ta ước lượng mật độ này bằng trung bình likelihood tích phân giữa hàm mật độ $h(x)$ và các hàm mật độ $f_j(x)$ trong lớp $\mathcal{F}$, tức là

$$f(h | \mathcal{F}) = \frac{1}{\#\mathcal{F}} \sum_{i=1}^{\#\mathcal{F}} \int_{\Omega} f_j(x)h(x) dx.$$

Khi này ta có quy tắc phân loại hàm mật độ $h(x)$, giả sử không có thông tin tiên nghiệm, ta lấy $\mathbb{P}(\mathcal{F}) = \mathbb{P}(\mathcal{G}) = 1/2$, hàm mật độ h được phân loại vào lớp $\mathcal{F}$ nếu $f(h | \mathcal{F}) > f(h | \mathcal{G})$ và ngược lại. Với nhiều lớp, ta tổng quát

$$\mathbb{P}(c_k | h) = \frac{\mathbb{P}(c_k)f(h | c_k)}{\sum_i \mathbb{P}(c_i)f(h | c_i)},$$

và phân loại h vào lớp c_k nào có xác suất hậu nghiệm lớn nhất.

Ví dụ 1.7 (Phân loại hàm mật độ bằng phương pháp Bayes). Trở lại giả thuyết của Ví dụ 1.6, ta cần phân loại hàm mật độ Gauss mới $h(x) = \mathcal{N}(3, 0; 0, 9)$ vào một trong hai lớp.

Bài giải. Khi không có thông tin tiên nghiệm, tức là $\mathbb{P}(\mathcal{F}) = \mathbb{P}(\mathcal{G}) = 0.5$. Tiếp theo, ta tính likelihood của h cho từng lớp $\mathcal{F}$ và $\mathcal{G}$. Vì tích hai hàm đều là hàm mật độ Gauss, nên ta có thể tính toán bằng công thức cụ thể từ Bổ đề 1.2, hay

$$\int_{\Omega} \mathcal{N}(\mu_h, \sigma_h^2)(x) \cdot \mathcal{N}(\mu_i, \sigma_i^2)(x) dx = \frac{1}{\sqrt{2\pi(\sigma_h^2 + \sigma_i^2)}} \exp\left(-\frac{(\mu_h - \mu_i)^2}{2(\sigma_h^2 + \sigma_i^2)}\right).$$

Xét lớp $\mathcal{F}$, ta có

$$\begin{aligned} f(h | \mathcal{F}) &= \frac{1}{\#\mathcal{F}} \sum_{i=1}^{\#\mathcal{F}} \int_{\Omega} f_i(x)h(x) dx = \frac{1}{5} \sum_{i=1}^5 \frac{1}{\sqrt{2\pi(0,9 + 0,4)}} \exp\left(-\frac{(3,0 - \mu_{\mathcal{F}_i})^2}{2(0,9 + 0,4)}\right) \\ &= \frac{1}{5} \cdot 0,350 \cdot \left(e^{-\frac{4,0}{2,6}} + e^{-\frac{2,25}{2,6}} + e^{-\frac{1,0}{2,6}} + e^{-\frac{0,25}{2,6}} + e^{-\frac{9,0}{2,6}}\right) = 0,158 \end{aligned}$$

Tương tự, xét lớp $\mathcal{G}$, ta cũng có

$$\begin{aligned} f(h|\mathcal{G}) &= \frac{1}{\#\mathcal{G}} \sum_{i=1}^{\#\mathcal{H}} \int_{\Omega} f_i(x) h(x) dx = \frac{1}{5} \sum_{i=1}^5 \frac{1}{\sqrt{2\pi(0,9+0,9)}} \exp\left(-\frac{(3,0-\mu_{\mathcal{G}_i})^2}{2(0,9+0,9)}\right) \\ &= \frac{1}{5} \cdot 0,297 \cdot \left(e^{-\frac{2,25}{3,6}} + e^{-\frac{20,25}{3,6}} + e^{-\frac{30,25}{3,6}} + e^{-\frac{25,0}{3,6}} + e^{-\frac{30,25}{3,6}}\right) = 0,032. \end{aligned}$$

Từ đây, ta có thể tính xác suất hậu nghiệm Bayes bởi

$$\mathbb{P}(\mathcal{F}|h) = \frac{\mathbb{P}(\mathcal{F})f(h|\mathcal{F})}{\mathbb{P}(\mathcal{F})f(h|\mathcal{F}) + \mathbb{P}(\mathcal{G})f(h|\mathcal{G})} = \frac{0,5 \times 0,158}{0,5 \times 0,158 + 0,5 \times 0,032} = 0,831,$$

và $\mathbb{P}(\mathcal{G}|h) = 1 - 0,831 = 0,169$. Vì $\mathbb{P}(\mathcal{F}|h) > \mathbb{P}(\mathcal{G}|h)$ nên hàm mật độ $h(x)$ được phân loại vào lớp $\mathcal{F}$ với xác suất hậu nghiệm 83,1%.

1.9 Tổng kết Chương 1

CHƯƠNG 2

NHẬN DẠNG THÔNG KÊ CHO HÀM MẬT ĐỘ XÁC SUẤT VỚI DỮ LIỆU MẤT CÂN BẰNG

2.1 Giới thiệu

2.1.1 Giới thiệu bài toán phân tích chùm cho dữ liệu mất cân bằng

Phân tích chùm cho dữ liệu mất cân bằng là chủ đề phát triển để giải quyết nhu cầu thực tế. Bài toán khoanh vùng hình ảnh hòn đảo giữa đại dương được ghi nhận là có sự mất cân bằng, hay phân đoạn chuỗi tín hiệu hiểm như động đất cũng có tính chất mất cân bằng hơn tín hiệu nền yên tĩnh. Dữ liệu lúc này có sự chênh lệch lớn giữa các loại trong tự nhiên và tồn tại hai tình trạng: Kích thước chùm và số lượng phần tử trong chùm mất cân bằng.

Kích thước chùm mất cân bằng xảy ra khi

Trong lĩnh vực phân tích chùm, để giải quyết vấn đề mất cân bằng tự nhiên, đa số phương pháp tập trung cải thiện thuật toán, trong khi các phương pháp tăng cường mẫu ít được áp dụng do khó xác định chùm tiềm ẩn. Ở dữ liệu rời rạc, thuật toán phân tích chùm mất cân bằng đã được giải quyết rất tốt.

Tuy nhiên, các thuật toán này thường giả định các chùm có cùng kích thước [53]. Khi có sự khác biệt lớn về số lượng phần tử hoặc kích thước chùm không đồng đều, các thuật toán phân chùm phân vùng có xu hướng tạo ra độ lệch trọng tâm đáng kể đối với các chùm có kích thước nhỏ [54].

2.1.2 Giới thiệu bài toán phân loại cho dữ liệu mất cân bằng

2.2 Các vấn đề liên quan

2.2.1 Tham số đánh giá thuật toán phân tích chùm

Đánh giá phân tích chùm cho biết độ hiệu quả thực thi của thuật toán bao gồm độ chính xác và độ phù hợp với thực tế. Các chỉ số đánh giá hiệu suất chùm (CVI) được sử dụng để đánh giá mối quan hệ giữa các thuộc tính của chùm đã hình thành bao gồm tính kết nối, tính gắn kết, tính đối xứng và tính tách biệt [55]. Mục đích của việc đánh giá là mang lại góc nhìn

cụ thể về kết quả của từng thuật toán và giữa các thuật toán với nhau.

Đánh giá kết quả phân tích chùm diễn ra trong hai trường hợp: đánh giá bên trong và bên ngoài. Tiêu chí đánh giá ngoài cung cấp độ chính xác giữa nhãn thực tế và nhãn kết quả của phân tích chùm trong các ví dụ mô phỏng. Nhưng trong thực tế, ta không có thông tin chính xác của nhãn nên phải đánh giá nội bộ. Đánh giá nội bộ cung cấp độ phù hợp của các chùm trong dữ liệu chưa được gán nhãn.

a. Đánh giá bên trong

Chỉ số Silhouette Chỉ số Silhouette đo mức độ phù hợp của một hàm mật độ f_j với chùm mà nó được gán nhãn, so với chùm gần nhất khác,

$$s(f_j) = \frac{b(f_j) - a(f_j)}{\max\{a(f_j), b(f_j)\}},$$

trong đó, $a(f_j) = \frac{1}{|c_k|-1} \sum_{\substack{f \in c_k \\ f \neq f_j}} D(f_j, f)$ là khoảng cách trung bình giữa f_j và tất cả các hàm mật độ khác trong chùm c_k chứa nó, và $b(f_j) = \min_{l \neq k} \frac{1}{|c_l|} \sum_{f \in c_l} D(f_j, f)$ là khoảng cách trung bình giữa f_j và các hàm mật độ trong chùm gần nhất c_l với $l \neq k$.

Chỉ số Dunn Chỉ số Dunn đánh giá mức độ tách biệt giữa các chùm, được định nghĩa bởi

$$D = \frac{\min_{k \neq l} \Delta_{\min}(c_k, c_l)}{\max_m \Delta(c_m)},$$

trong đó, $\Delta_{\min}(c_k, c_l) = \min_{\substack{f \in c_k \\ g \in c_l}} D(f, g)$ là liên kết nhỏ nhất giữa hai chùm c_k và c_l , và $\Delta(c_m) = \max_{f, g \in c_m} D(f, g)$ là đường kính lớn nhất của chùm c_m .

Chỉ số Davies–Bouldin Chỉ số Davies–Bouldin đo mức độ tương đồng giữa các chùm, được định nghĩa bởi

$$DI = \frac{1}{k} \sum_{k=1}^K \max_{l \neq k} \left\{ \frac{S_k + S_l}{D(\theta_k, \theta_l)} \right\},$$

trong đó, $S_k = \frac{1}{|c_k|} \sum_{f \in c_k} D(f, \theta_k)$ là độ phân tán trung bình của chùm c_k , θ_k là trọng tâm của chùm c_k , $D(\theta_k, \theta_l)$ là khoảng cách giữa hai trọng tâm θ_k và θ_l và k là số chùm.

b. Đánh giá bên ngoài

Đánh giá bên ngoài được sử dụng khi có nhãn thực tế $\mathcal{P} = \{\mathcal{F}_1, \dots, \mathcal{F}_R\}$ của tập hàm mật độ $\mathcal{F} = \{f_1, \dots, f_n\}$ và kết quả phân cụm $\mathcal{G} = \{\mathcal{G}_1, \dots, \mathcal{G}_K\}$. Xét các cặp (f_i, f_j) , ta định

nghĩa:

$$\begin{aligned} a &= \#\{(f_i, f_j) \mid f_i, f_j \in \mathcal{F}_r \cap \mathcal{G}_k\}, \\ b &= \#\{(f_i, f_j) \mid f_i, f_j \in \mathcal{F}_r, f_i \in \mathcal{G}_k, f_j \in \mathcal{G}_l, k \neq l\}, \\ c &= \#\{(f_i, f_j) \mid f_i, f_j \in \mathcal{G}_k, f_i \in \mathcal{F}_r, f_j \in \mathcal{F}_s, r \neq s\}, \\ d &= \#\{(f_i, f_j) \mid f_i \in \mathcal{F}_r \cap \mathcal{G}_k, f_j \in \mathcal{F}_s \cap \mathcal{G}_l, r \neq s, k \neq l\}. \end{aligned}$$

Rand Index Rand Index đo mức độ tương đồng giữa $\mathcal{P}$ và $\mathcal{G}$. Ta có $RI = 1$ nếu phân cụm trùng hoàn toàn với nhãn thực tế, được định nghĩa là

$$RI = \frac{a + d}{a + b + c + d},$$

Adjusted Rand Index ARI hiệu chỉnh RI để loại bỏ trùng khớp ngẫu nhiên.

$$ARI = \frac{RI - \mathbb{E}(RI)}{\max(RI) - \mathbb{E}(RI)},$$

Normalized Mutual Information NMI đo mức độ phụ thuộc giữa hai phân hoạch $\mathcal{P}$ và $\mathcal{Q}$,

$$NMI = \frac{2I(\mathcal{P}, \mathcal{Q})}{H(\mathcal{P}) + H(\mathcal{Q})},$$

trong đó, với $p_i = \frac{\#\mathcal{F}_i}{n}$, $p_j = \frac{\#\mathcal{G}_j}{n}$, $p_{ij} = \frac{\#(\mathcal{F}_i \cap \mathcal{G}_j)}{n}$, ta có,

$$I(\mathcal{P}, \mathcal{Q}) = \sum_{i,j} p_{ij} \log \frac{p_{ij}}{p_i p_j},$$

$$H(\mathcal{P}) = - \sum_i p_i \log p_i, H(\mathcal{Q}) = - \sum_j p_j \log p_j,$$

2.2.2 Tham số đánh giá thuật toán phân loại

Đối với thuật toán phân loại, ta đánh giá kết quả độ chính xác việc thực thi đến một đối tượng chưa được huấn luyện qua (hay tập kiểm tra). Các dự đoán từ mô hình so với thực tế sẽ được tổng hợp qua ma trận nhầm lẫn.

2.2.3 Tham số đánh giá thuật toán phân loại

Đối với thuật toán phân loại, ta đánh giá kết quả dự đoán thông qua độ chính xác của mô hình trên tập dữ liệu chưa được huấn luyện. Kết quả phân loại thường được tóm tắt trong ma trận nhầm lẫn, thể hiện số lượng dự đoán đúng và sai của mô hình. Giả sử ta có một bài toán phân loại nhị phân với hai lớp $\{\text{Positive}, \text{Negative}\}$. Ma trận nhầm lẫn có dạng

	Dự đoán Positive	Dự đoán Negative
Thực tế Positive	$\#TP$	$\#FN$
Thực tế Negative	$\#FP$	$\#TN$

Từ ma trận nhầm lẫn, ta định nghĩa các chỉ số phổ biến như sau

Bảng 2.1. Mô tả các chỉ số đánh giá phân loại

Chỉ số	Công thức	Ý nghĩa	Phạm vi
Accuracy	$\frac{\#TP + \#TN}{\#TP + \#TN + \#FP + \#FN}$	Tỷ lệ dự đoán đúng trên tổng số mẫu	[0, 1]
Precision	$\frac{\#TP}{\#TP + \#FP}$	Tỷ lệ mẫu được dự đoán Positive là đúng	[0, 1]
TPR (Recall)	$\frac{\#TP}{\#TP + \#FN}$	Tỷ lệ nhận diện đúng Positive	[0, 1]
F1-score	$\frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$	Trung bình điều hoà giữa Precision và Recall	[0, 1]
FPR	$\frac{\#FP}{\#FP + \#TN}$	Tỷ lệ dự đoán sai Negative thành Positive	[0, 1]
AUC	$\int_0^1 \text{TPR}(\text{FPR}) d\text{FPR}$	Khả năng phân biệt của mô hình	[0, 1]

2.3 Phân tích chùm cho hàm mật độ xác suất với dữ liệu mất cân bằng

2.3.1 Thuật toán

2.3.2 Sự hội tụ của thuật toán

2.3.3 Ví dụ minh họa

2.4 Phân loại cho hàm mật độ xác suất với dữ liệu mất cân bằng

2.4.1 Thuật toán

2.4.2 Sự hội tụ của thuật toán

2.4.3 Ví dụ minh họa

2.5 Tổng kết chương 2

CHƯƠNG 3

ỨNG DỤNG CHO DỮ LIỆU HÌNH ẢNH

3.1 Trích xuất đặc trưng của hình ảnh thành hàm mật độ xác suất

3.1.1 Vấn đề trích xuất đặc trưng của hình ảnh

3.1.2 Ước lượng hàm mật độ xác suất đại diện cho hình ảnh

Ước lượng hàm mật độ là bài toán phái sinh khi dữ liệu cần được chuyển thành dữ liệu hàm mật độ.

3.2 Ứng dụng của bài toán phân tích chùm

3.2.1 Dữ liệu

3.2.2 Phương pháp thực hiện

3.2.3 Kết quả thực hiện

3.3 Ứng dụng của bài toán phân loại

3.3.1 Dữ liệu

3.3.2 Phương pháp thực hiện

3.3.3 Kết quả thực hiện

3.4 Tổng kết chương 3

PHẦN KẾT LUẬN

- Tổng kết các vấn đề đã thực hiện trong đề cương;
- Đánh giá những khó khăn, hạn chế của các mô hình về mặt lý thuyết và ứng dụng;
- Đưa ra những định hướng có thể phát triển trong tương lai

1 Kết luận

Trí tuệ nhân tạo là trọng tâm, là mũi đột phá chính của phát triển khoa học công nghệ, đổi mới sáng tạo và chuyển đổi số.

2 Định hướng nghiên cứu

TÀI LIỆU THAM KHẢO

- [1] A. Belhadi, V. Mani, S. S. Kamble, S. A. R. Khan, and S. Verma, “Artificial intelligence-driven innovation for enhancing supply chain resilience and performance under the effect of supply chain dynamism: an empirical investigation,” *Annals of Operations Research*, vol. 333, no. 2, pp. 627–652, 2024.
- [2] A. I. Act, “Artificial intelligence act,” *Euroopan unioni. Luettavissa: <https://artificialintelligen>*, 2023.
- [3] P. K. Dey, S. Chowdhury, A. Abadie, E. Vann Yaroson, and S. Sarkar, “Artificial intelligence-driven supply chain resilience in vietnamese manufacturing small-and medium-sized enterprises,” *International Journal of Production Research*, vol. 62, no. 15, pp. 5417–5456, 2024.
- [4] C. M. Bishop and H. Bishop, *Deep Learning: Foundations and Concepts*. Springer, 2024.
- [5] S. Theodoridis and K. Koutroumbas, *Pattern recognition*. Elsevier, 2006.
- [6] J. C. Bezdek, R. Ehrlich, and W. Full, “Fcm: The fuzzy c -means clustering algorithm,” *Computers & geosciences*, vol. 10, no. 2-3, pp. 191–203, 1984.
- [7] J. Macqueen, “Some methods for classification and analysis of multivariate observations,” in *Proceedings of 5-th Berkeley Symposium on Mathematical Statistics and Probability/University of California Press*, 1967.
- [8] A. R. Webb, *Statistical pattern recognition*. John Wiley & Sons, 2003.
- [9] D. Zha, Z. P. Bhat, K.-H. Lai, F. Yang, Z. Jiang, S. Zhong, and X. Hu, “Data-centric artificial intelligence: A survey,” *arXiv preprint arXiv:2303.10158*, 2023.
- [10] C. Cortes, “Support-vector networks,” *Machine Learning*, 1995.
- [11] T. Nguyen-Trang, Y. Nguyen-Hoang, and T. Vo-Van, “A new semi-supervised clustering algorithm for probability density functions and applications,” *Neural Computing and Applications*, vol. 36, no. 11, pp. 5965–5980, 2024.
- [12] X. Hu, H. Chen, J. Zhang, H. Chen, S. Liu, X. Li, Y. Wang, and X. Xue, “Gat-cobo: Cost-sensitive graph neural network for telecom fraud detection,” *IEEE Transactions on Big Data*, 2024.
- [13] G. H. Nguyen, A. Bouzerdoum, and S. L. Phung, “Learning pattern classification tasks with imbalanced data sets,” *Pattern recognition*, vol. 10, no. 2009, pp. 1322–1328, 2009.

- [14] Y. Tang, Y.-Q. Zhang, N. V. Chawla, and S. Krasser, "Svms modeling for highly imbalanced classification," *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)*, vol. 39, no. 1, pp. 281–288, 2008.
- [15] T. Vo Van and T. Pham-Gia, "Clustering probability distributions," *Journal of Applied Statistics*, vol. 37, no. 11, pp. 1891–1910, 2010.
- [16] F. Gullo, G. Ponti, A. Tagarelli, and S. Greco, "A hierarchical algorithm for clustering uncertain data via an information-theoretic approach," in *2008 Eighth IEEE International Conference on Data Mining*, pp. 821–826, IEEE, 2008.
- [17] T. Nguyen-Trang, T. Nguyen-Thoi, and T. Vo-Van, "Globally automatic fuzzy clustering for probability density functions and its application for image data," *Applied Intelligence*, vol. 53, no. 15, pp. 18381–18397, 2023.
- [18] T. Vo-Van and D. PhamToan, "A supervised learning algorithm based on the quasi-bayesian method for the probability density functions and application for medical data," *Knowledge-Based Systems*, p. 112003, 2024.
- [19] M. Minami and C. E. Lennert-Cody, "Regression tree and clustering for distributions, and homogeneous structure of population characteristics," *Journal of Agricultural, Biological and Environmental Statistics*, pp. 1–20, 2024.
- [20] A. Azzalini, "A class of distributions which includes the normal ones," *Scandinavian journal of statistics*, pp. 171–178, 1985.
- [21] T. Nguyentrang and T. Vovan, "Fuzzy clustering of probability density functions," *Journal of Applied Statistics*, vol. 44, no. 4, pp. 583–601, 2017.
- [22] T. Vovan, "Cluster width of probability density functions," *Intelligent Data Analysis*, vol. 23, no. 2, pp. 385–405, 2019.
- [23] T. Nguyen-Trang, T. Nguyen-Thoi, K.-N. Nguyen-Thi, and T. Vo-Van, "Balance-driven automatic clustering for probability density functions using metaheuristic optimization," *International Journal of Machine Learning and Cybernetics*, vol. 14, no. 4, pp. 1063–1078, 2023.
- [24] S. M. Ali and S. D. Silvey, "A general class of coefficients of divergence of one distribution from another," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 28, no. 1, pp. 131–142, 1966.
- [25] T. Kailath, "The divergence and bhattacharyya distance measures in signal selection," *IEEE transactions on communication technology*, vol. 15, no. 1, pp. 52–60, 1967.
- [26] C. Villani *et al.*, *Optimal transport: old and new*, vol. 338. Springer, 2008.
- [27] K. Florek, J. Łukaszewicz, J. Perkal, H. Steinhaus, and S. Zubrzycki, "Sur la liaison et la division des points d'un ensemble fini," in *Colloquium mathematicum*, vol. 2, pp. 282–285, 1951.

- [28] T. Sorensen, "A method of establishing groups of equal amplitude in plant sociology based on similarity of species content and its application to analyses of the vegetation on danish commons," *Biologiske skrifter*, vol. 5, pp. 1–34, 1948.
- [29] J. H. Ward Jr, "Hierarchical grouping to optimize an objective function," *Journal of the American statistical association*, vol. 58, no. 301, pp. 236–244, 1963.
- [30] C. X. Gao, D. Dwyer, Y. Zhu, C. L. Smith, L. Du, K. M. Filia, J. Bayer, J. M. Menssink, T. Wang, C. Bergmeir, *et al.*, "An overview of clustering methods with guidelines for application in mental health research," *Psychiatry Research*, vol. 327, p. 115265, 2023.
- [31] K. Matusita, "On the notion of affinity of several distributions and some of its applications," *Annals of the institute of Statistical Mathematics*, vol. 19, pp. 181–192, 1967.
- [32] G. T. Toussaint, "Some inequalities between distance measures for feature evaluation," *IEEE Transactions on Computers*, vol. 21, no. 04, pp. 409–410, 1972.
- [33] T. VoVan and T. NguyenTrang, "Similar coefficient for cluster of probability density functions," *Communications in Statistics-Theory and Methods*, vol. 47, no. 8, pp. 1792–1811, 2018.
- [34] A. K. Jain, "Data clustering: 50 years beyond k -means," *Pattern recognition letters*, vol. 31, no. 8, pp. 651–666, 2010.
- [35] A. Saxena, M. Prasad, A. Gupta, N. Bharill, O. P. Patel, A. Tiwari, M. J. Er, W. Ding, and C.-T. Lin, "A review of clustering techniques and developments," *Neurocomputing*, vol. 267, pp. 664–681, 2017.
- [36] T. Dinh, H. Wong, P. Fournier-Viger, D. Lisik, M.-Q. Ha, H.-C. Dam, and V.-N. Huynh, "Categorical data clustering: 25 years beyond k -modes," *Expert Systems with Applications*, vol. 272, p. 126608, 2025.
- [37] J. C. Bezdek, *Pattern recognition with fuzzy objective function algorithms*. Springer Science & Business Media, 2013.
- [38] D. S. Watson, "On the philosophy of unsupervised learning," *Philosophy & Technology*, vol. 36, no. 2, p. 28, 2023.
- [39] S. C. Johnson, "Hierarchical clustering schemes," *Psychometrika*, vol. 32, no. 3, pp. 241–254, 1967.
- [40] J. C. Dunn, "A fuzzy relative of the isodata process and its use in detecting compact well-separated clusters," 1973.
- [41] J. C. Bezdek, "A convergence theorem for the fuzzy isodata clustering algorithms," *IEEE transactions on pattern analysis and machine intelligence*, no. 1, pp. 1–8, 1980.
- [42] R. J. Hathaway and J. C. Bezdek, "Recent convergence results for the fuzzy c-means clustering algorithms," *Journal of Classification*, vol. 5, no. 2, pp. 237–247, 1988.
- [43] W. I. Zangwill, "Nonlinear programming: a unified approach," (*No Title*), 1969.

- [44] L. Groll and J. Jakel, “A new convergence proof of fuzzy c -means,” *IEEE Transactions on Fuzzy Systems*, vol. 13, no. 5, pp. 717–720, 2005.
- [45] C. Goutte, P. Toft, E. Rostrup, F. Å. Nielsen, and L. K. Hansen, “On clustering fmri time series,” *NeuroImage*, vol. 9, no. 3, pp. 298–310, 1999.
- [46] S. Leonelli, *Data-centric biology: A philosophical study*. University of Chicago Press, 2019.
- [47] W. J. T. Mollema, “Responding to the watson-sterkenburg debate on clustering algorithms and natural kinds,” 2024.
- [48] S. Fillmore-Patrick, “The logit model measurement problem,” *Philosophy of Science*, vol. 92, no. 2, p. 285–303, 2025.
- [49] R. A. Fisher, “The use of multiple measurements in taxonomic problems,” *Annals of eugenics*, vol. 7, no. 2, pp. 179–188, 1936.
- [50] F. Rosenblatt, “Principles of neurodynamics: Perceptrons and the theory of brain mechanisms,” 1961.
- [51] H. Huynh-Van, T. Le-Hoang, and T. Vo-Van, “Classifying for images based on the extracted probability density function and the quasi bayesian method,” *Computational Statistics*, vol. 39, no. 5, pp. 2677–2701, 2024.
- [52] B. Akturk, U. Beyaztas, H. L. Shang, and A. Mandal, “Robust functional logistic regression,” *Advances in Data Analysis and Classification*, pp. 1–25, 2024.
- [53] S. Askari, “Fuzzy c -means clustering algorithm for data with unequal cluster sizes and contaminated with noise and outliers: Review and development,” *Expert Systems with Applications*, vol. 165, p. 113856, 2021.
- [54] H. Yu, H. Li, X. Xu, Q. Gao, and R. Lan, “Suppressed possibilistic fuzzy c -means clustering based on shadow sets for noisy data with imbalanced sizes,” *Applied Soft Computing*, vol. 167, p. 112263, 2024.
- [55] A. M. Ikotun, F. Habyarimana, and A. E. Ezugwu, “Cluster validity indices for automatic clustering: A comprehensive review,” *Heliyon*, 2025.

PHỤ LỤC A MÃ NGUỒN

Về tài nguyên tính toán, chúng tôi chạy trên hệ điều hành Ubuntu 24.04.2 LTS, nhân Linux 6.11.0-19-generic, 11th Gen Intel® Core™ i5-11400H×12, bộ nhớ 16.0 GiB.

Việc thực thi mã nguồn được sử dụng trong môi trường ảo của Python. Các mã Python được sử dụng trong luận văn này được lưu trữ tại <https://github.com/hungtrannam/probclust>. Xin tham khảo tệp README.md trong kho GitHub để biết thêm thông tin chi tiết về cách sử dụng, ví dụ và mở rộng hệ thống. Các thư viện trên được lưu trong tệp requirements.txt và có thể được cài đặt tự động. Đây là danh sách các thư viện Python cần thiết để thực thi toàn bộ mã nguồn trong luận văn.

```
numpy==2.2.6 scipy==1.16.0 pandas==2.3.1 optuna==4.4.0 shap==0.48.0
scikit-learn==1.7.1 statsmodels==0.14.5 matplotlib==3.10.3 seaborn==0.13.2
torch==2.7.1 torchvision==0.22.1 triton==3.3.1 torchmetrics==1.7.4
ipykernel==6.29.5 jupyter_client==8.6.3 jupyter_core==5.8.1 tqdm==4.67.1
einops==0.8.1 numba==0.61.2 joblib==1.5.1 opencv-python
```

PHỤ LỤC B KẾT QUẢ

Bài giải Ví dụ 1.3. Vì các phương sai của hàm mật độ Gauss đều bằng 1. Nên ta có thể tính $\mathcal{L}_2$ bằng công thức tổng quát $\mathcal{L}_2(u, v) = \left(2 - 2 \exp\left(-\frac{(\mu_u - \mu_v)^2}{4\sigma^2}\right)\right)^{1/2}$. Sau khi tính toán, ta nhận được ma trận khoảng cách từng đôi một.

	$\{f_1$	$f_2\}$	$\{g_1$	g_2	$g_3\}$	$\{h_1$	$h_2\}$
f_1							
f_2	0,26						
g_1	0,74	0,71					
g_2	0,75	0,75	0,49				
g_3	0,75	0,74	0,29	0,26			
h_1	0,75	0,75	0,75	0,74	0,75		
h_2	0,75	0,75	0,74	0,67	0,72	0,38	

Từ đây, ta có thể dễ dàng tính được các liên kết $\Delta(\mathcal{F}, \mathcal{G})$ thông qua ma trận này. Ta có,

$$\begin{aligned}\Delta_{\min}(\mathcal{F}, \mathcal{G}) &= \min\{\mathcal{L}_2(f_1, g_1), \mathcal{L}_2(f_1, g_2), \mathcal{L}_2(f_1, g_3), \mathcal{L}_2(f_2, g_1), \mathcal{L}_2(f_2, g_2), \mathcal{L}_2(f_2, g_3)\} \\ &= \min\{0,74; 0,75; 0,75; 0,71; 0,75; 0,74\} = 0,71,\end{aligned}$$

$$\begin{aligned}\Delta_{\max}(\mathcal{F}, \mathcal{G}) &= \max\{\mathcal{L}_2(f_1, g_1), \mathcal{L}_2(f_1, g_2), \mathcal{L}_2(f_1, g_3), \mathcal{L}_2(f_2, g_1), \mathcal{L}_2(f_2, g_2), \mathcal{L}_2(f_2, g_3)\} \\ &= \max\{0,74; 0,75; 0,75; 0,71; 0,75; 0,74\} = 0,75,\end{aligned}$$

$$\Delta_{\text{avg}}(\mathcal{F}, \mathcal{G}) = \frac{1}{6} \sum_{\substack{f \in \mathcal{F} \\ g \in \mathcal{G}}} \mathcal{L}_2(f, g) = 0,17(0,74 + 0,75 + 0,75 + 0,71 + 0,75 + 0,74) = 0,74,$$

$$\Delta_{\text{centroid}}(\mathcal{F}, \mathcal{G}) = \mathcal{L}_2(\theta_{\mathcal{F}}, \theta_{\mathcal{G}}) = \left(2 - 2 \exp\left(-\frac{(0,65 - 4,77)^2}{4}\right)\right)^{1/2} = 1,41,$$

$$\text{với } \theta_{\mathcal{F}} = (0,3 + 1,0)/2 = 0,65, \theta_{\mathcal{G}} = (4,0 + 5,5 + 4,8)/3 = 4,77,$$

$$\Delta_{\text{Ward}}(\mathcal{F}, \mathcal{G}) = \frac{\#\mathcal{F} \cdot \#\mathcal{G}}{\#\mathcal{F} + \#\mathcal{G}} \cdot \mathcal{L}_2^2(\theta_{\mathcal{F}}, \theta_{\mathcal{G}}) = \frac{2 \cdot 3}{2 + 3} \cdot (1,41)^2 = 2,39,$$

Tương tự, ta cũng có kết quả cho $\Delta(\mathcal{F} \cup \mathcal{G}, \mathcal{H})$ là

$$\Delta_{\min}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) = 0,67, \Delta_{\max}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) = 0,75, \Delta_{\text{avg}}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) = 0,74, \\ \Delta_{\text{centroid}}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) = 1,41, \Delta_{\text{Ward}}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) = 2,86.$$

Bài giải Ví dụ 1.4. Đầu tiên, ta xem thứ tự của μ_i chính là thứ tự của dữ liệu hàm mật độ f_i , tính toán các khoảng cách từng đôi hàm mật độ bất kỳ bằng khoảng cách $\mathcal{L}_2(f_i, f_j)$ với $i, j = 1, \dots, 7$, ta nhận được ma trận khoảng cách

	f_1	f_2	f_3	f_4	f_5	f_6	f_7
$D^{(t=0)} =$	f_1						
	f_2	0,74					
	f_3	0,75	0,75				
	f_4	0,26	0,71	0,75			
	f_5	0,75	0,49	0,74	0,75		
	f_6	0,75	0,74	0,38	0,75	0,67	
	f_7	0,75	0,29	0,75	0,74	0,26	0,72

Ta thấy khoảng cách $D(f_1, f_4) = D(f_5, f_7) = 0,26$ là khoảng cách nhỏ nhất nên ta chọn một trong hai. Trường hợp này, ta chọn hàm mật độ f_1 và f_4 xếp vào một chùm $\{f_1, f_4\}$. Tiến hành tính toán liên kết đủ giữa chùm $\{f_1, f_4\}$ với các hàm mật độ khác. Ta có

$$\begin{aligned} \Delta(\{f_1, f_4\}, f_2) &= \max\{D(f_1, f_2), D(f_4, f_2)\} = \max\{0,74; 0,71\} = 0,74, \\ \Delta(\{f_1, f_4\}, f_3) &= \max\{D(f_1, f_3), D(f_4, f_3)\} = \max\{0,75; 0,75\} = 0,75, \\ \Delta(\{f_1, f_4\}, f_5) &= \max\{D(f_1, f_5), D(f_4, f_5)\} = \max\{0,75; 0,75\} = 0,75, \\ \Delta(\{f_1, f_4\}, f_6) &= \max\{D(f_1, f_6), D(f_4, f_6)\} = \max\{0,75; 0,75\} = 0,75, \\ \Delta(\{f_1, f_4\}, f_7) &= \max\{D(f_1, f_7), D(f_4, f_7)\} = \max\{0,75; 0,74\} = 0,75. \end{aligned}$$

Ta xóa dòng/cột f_1 và f_4 và thay bằng một dòng/cột mới là $\{f_1, f_4\}$, ta được ma trận khoảng cách mới

	$\{f_1, f_4\}$	f_2	f_3	f_5	f_6	f_7
$D^{(t=1)} =$	$\{f_1, f_4\}$					
	f_2	0,74				
	f_3	0,75	0,75			
	f_5	0,75	0,49	0,74		
	f_6	0,75	0,74	0,38	0,67	
	f_7	0,75	0,29	0,75	0,26	0,72

Tiếp theo, ta thấy $D(f_5, f_7) = 0,26$ là cách nhỏ nhất nên ta xếp hai hàm mật độ này thành một chùm mới $\{f_5, f_7\}$. Tiến hành tính toán liên kết đủ giữa chùm $\{f_5, f_7\}$ với các hàm mật độ khác. Ta có

$$\Delta(\{f_5, f_7\}, \{f_1, f_4\}) = \max\{D(f_5, f_1), D(f_5, f_4), D(f_7, f_1), D(f_7, f_4)\} = 0,75,$$

$$\Delta(\{f_5, f_7\}, f_2) = \max\{D(f_5, f_2), D(f_7, f_2)\} = 0,49,$$

$$\Delta(\{f_5, f_7\}, f_3) = \max\{D(f_5, f_3), D(f_7, f_3)\} = 0,75,$$

$$\Delta(\{f_5, f_7\}, f_6) = \max\{D(f_5, f_6), D(f_7, f_6)\} = 0,72.$$

Ta xóa dòng/cột f_5 và f_7 và thay bằng một dòng/cột mới là $\{f_5, f_7\}$, ta được ma trận khoảng cách mới

		$\{f_1, f_4\}$	f_2	f_3	$\{f_5, f_7\}$	f_6
$D^{(t=2)} =$	$\{f_1, f_4\}$					
	f_2	0,75				
	f_3	0,75	0,75			
	$\{f_5, f_7\}$	0,75	0,49	0,75		
	f_6	0,75	0,74	0,38	0,72	

Tiếp theo, ta thấy $D(f_3, f_6) = 0,38$ là cách nhỏ nhất nên ta xếp hai hàm mật độ này thành một chùm mới $\{f_3, f_6\}$. Tiến hành tính toán liên kết đủ giữa chùm $\{f_3, f_6\}$ với các hàm mật độ khác. Ta có

$$\Delta(\{f_3, f_6\}, \{f_1, f_4\}) = \max\{D(f_3, f_1), D(f_3, f_4), D(f_6, f_1), D(f_6, f_4)\} = 0,75,$$

$$\Delta(\{f_3, f_6\}, \{f_5, f_7\}) = \max\{D(f_3, f_5), D(f_3, f_7), D(f_6, f_5), D(f_6, f_7)\} = 0,75,$$

$$\Delta(\{f_3, f_6\}, f_2) = \max\{D(f_3, f_2), D(f_6, f_2)\} = 0,75,$$

Ta xóa dòng/cột f_3 và f_6 và thay bằng một dòng/cột mới là $\{f_3, f_6\}$, ta được ma trận khoảng cách mới

		$\{f_1, f_4\}$	f_2	$\{f_5, f_7\}$	$\{f_3, f_6\}$
$D^{(t=3)} =$	$\{f_1, f_4\}$				
	f_2	0,75			
	$\{f_5, f_7\}$	0,75	0,49		
	$\{f_3, f_6\}$	0,75	0,75	0,75	

Tiếp theo, ta thấy $D(\{f_5, f_7\}, f_2) = 0,49$ là cách nhỏ nhất nên ta xếp hàm mật độ f_2 này vào chòm $\{f_5, f_7\}$. Tiến hành tính toán liên kết đủ giữa chòm $\{f_2, f_5, f_7\}$ với các hàm mật độ khác. Ta có

$$\Delta(\{f_2, f_5, f_7\}, \{f_1, f_4\}) = \max\{D(f_2, \{f_1, f_4\}), D(f_5, \{f_1, f_4\}), D(f_7, \{f_1, f_4\})\} = 0,75,$$

$$\Delta(\{f_2, f_5, f_7\}, \{f_3, f_6\}) = \max\{D(f_2, \{f_3, f_6\}), D(f_5, \{f_3, f_6\}), D(f_7, \{f_3, f_6\})\} = 0,75.$$

Ta xóa dòng/cột f_2 và $\{f_5, f_7\}$ và thay bằng một dòng/cột mới là $\{f_2, f_5, f_7\}$, ta được ma trận khoảng cách mới

	$\{f_1, f_4\}$	$\{f_2, f_5, f_7\}$	$\{f_3, f_6\}$
$D^{(t=4)} =$			
$\{f_1, f_4\}$			
$\{f_2, f_5, f_7\}$	0,75		
$\{f_3, f_6\}$	0,75	0,75	

Cuối cùng, ta chọn xếp chòm $\{f_2, f_5, f_7\}$ vào chòm $\{f_3, f_6\}$ dựa vào khoảng cách chính xác nhỏ nhất (4 chữ số thập phân). Vậy ta có chòm $\{f_2, f_5, f_3, f_6\}$. Ta xếp chòm còn lại vào chòm mới này, thuật toán kết thúc.

```
In [4]: import sys
import os

project_root = os.path.abspath("..")
if project_root not in sys.path:
    sys.path.insert(0, project_root)
```

```
In [5]: import numpy as np
from data.data_loader import generateGauss
from utils.integral import grid
from Models.clustering import HCF
```

```
In [ ]: bandwidth = 0.01
grid_x    = grid(bandwidth, start=-5, end=15)
mu        = np.array([0.3, 4.0, 9.1, 1.0, 5.5, 8.0, 4.8])
sig       = np.array([1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0])
F_data    = generateGauss(mu, sig, grid_x)
```

```
In [7]: cluster=HCF.Model(
    grid_x=grid_x,
    max_depth=7,
    distance_metric='L1',
    linkage='complete',
    bandwidth=bandwidth
)
cluster.fit(F_data)
cluster.print_tree()
```

```
├─ root (7 samples): [0, 1, 2, 3, 4, 5, 6]
│   ├── root0 (2 samples): [0, 3]
│   │   ├── root00 (1 samples): [0]
│   │   └── root01 (1 samples): [3]
│   ├── root1 (5 samples): [1, 4, 6, 2, 5]
│   │   ├── root10 (3 samples): [1, 4, 6]
│   │   │   ├── root100 (1 samples): [1]
│   │   │   ├── root101 (2 samples): [4, 6]
│   │   │   │   ├── root1010 (1 samples): [4]
│   │   │   │   └── root1011 (1 samples): [6]
│   │   └── root11 (2 samples): [2, 5]
│   │       ├── root110 (1 samples): [2]
│   │       └── root111 (1 samples): [5]
```

Bài giải Ví dụ 1.5. Với các thông số ban đầu $c = 3$, $\varepsilon = 10^{-3}$, ta tiến hành thuật toán phân tích chùm mờ. Giả sử hàm mật độ xác suất trọng tâm $\theta_i(x)$ ở ba chùm lần lượt là $\theta_1(x) \sim \mathcal{N}(0; 1)$, $\theta_2(x) \sim \mathcal{N}(2; 1)$ và $\theta_3(x) \sim \mathcal{N}(5; 1)$ và phân vùng ở mỗi hàm f_j vào ba trọng tâm này là đều nhau, tức là $U^{(0)} = 1/3 \times \text{ones}(3; 7)$.

Tại vòng lặp đầu tiên $t = 1$, ta tính khoảng cách $\mathcal{L}_2$ giữa $\theta_i(x)$ đến bảy $f_j(x)$ ta được ma trận D_{ij}

$$D_{ij} = \begin{bmatrix} 0,11 & 0,74 & 0,75 & 0,35 & 0,75 & 0,75 & 0,75 \\ 0,54 & 0,60 & 0,75 & 0,35 & 0,73 & 0,75 & 0,68 \\ 0,75 & 0,35 & 0,75 & 0,74 & 0,19 & 0,71 & 0,08 \end{bmatrix}$$

Ta tiến hành cập nhật các giá trị phân vùng U bằng công thức (1.4) và (1.5) ta được

$$U^{(1)} = \begin{bmatrix} 0.94 & 0.14 & 0.33 & 0.45 & 0.06 & 0.32 & 0.01 \\ 0.04 & 0.22 & 0.33 & 0.45 & 0.06 & 0.32 & 0.01 \\ 0.02 & 0.64 & 0.33 & 0.10 & 0.88 & 0.36 & 0.98 \end{bmatrix}$$

CHỈ MỤC

- X -means, 27
 k -means⁺⁺, 27
bộ mã hóa (encoding), 21
hàm cơ sở (basis functions), 29
hàm hạt nhân Bhattacharyya
(Bhattacharyya kernel), 17
hàm hạt nhân chuẩn (Gaussian kernel), 17
hàm hệ số $\beta(x)$ (β -functional coefficient),
29
hàm mất mát (loss function), 28
hàm phân vị (quantile function), 4
hằng số chặn (intercept), 29
ma trận nhầm lẫn (confusion matrix), 34
máy véc-tơ hỗ trợ (support vector
machine), 28
môi trường ảo (virtual environment), 42
nhận dạng không được giám sát
(unsupervised recognition), 1
nhận dạng được giám sát (supervised
recognition), 1
Phân tích cụm tự cập nhật (Self-Update
Process), 24
phương pháp hình thang (trapezoidal
method), 20
phương pháp tăng cường mẫu (resampling
methods), 32
quá khớp (overfitting), 27
siêu tham số (hyper-parametre), 27
thuật toán độ dốc (gradient decent
method), 29
thông minh nhân tạo (AI), 1
vận chuyển tối ưu (optimal transport), 14
ánh xạ nhiều-đến-một (many-to-one map),
21
điểm ngoại lệ (outliers), 27
độ dốc (gradient method), 25