

BỘ GIÁO DỤC VÀ ĐÀO TẠO
ĐẠI HỌC CẦN THƠ

TRẦN NAM HÙNG

NHẬN DẠNG THỐNG KÊ
CHO HÀM MẬT ĐỘ XÁC SUẤT MẤT CÂN BẰNG
VÀ ỨNG DỤNG CHO DỮ LIỆU ẢNH

LUẬN VĂN TỐT NGHIỆP THẠC SĨ

NGÀNH: LÝ THUYẾT XÁC SUẤT VÀ THỐNG KÊ TOÁN HỌC
MÃ SỐ: 8 46 01 06

NĂM 2025

BỘ GIÁO DỤC VÀ ĐÀO TẠO
ĐẠI HỌC CẦN THƠ

TRẦN NAM HÙNG
MÃ SỐ HỌC VIÊN: M1823002

NHẬN DẠNG THỐNG KÊ
CHO HÀM MẬT ĐỘ XÁC SUẤT MẤT CÂN BẰNG
VÀ ỨNG DỤNG CHO DỮ LIỆU ẢNH

LUẬN VĂN TỐT NGHIỆP THẠC SĨ
NGÀNH LÝ THUYẾT XÁC SUẤT VÀ THỐNG KÊ TOÁN HỌC

MÃ SỐ: 8 46 01 06

CÁN BỘ HƯỚNG DẪN
PGS. TS. VÕ VĂN TÀI

NĂM 2025

CHẤP THUẬN CỦA HỘI ĐỒNG

Luận văn này với tựa đề là “**Nhận dạng thống kê cho hàm mật độ xác suất mất cân bằng và ứng dụng cho dữ liệu ảnh**”, do học viên Trần Nam Hưng thực hiện theo sự hướng dẫn của PGs. TS. Võ Văn Tài. Luận văn đã báo cáo và được Hội đồng chấm luận văn thông qua ngày , tháng , năm . Luận văn đã được chỉnh sửa theo góp ý và được Hội đồng chấm luận văn xem lại.

Thư ký
(Ký tên)*

Ủy viên
(Ký tên)

Phản biện 1
(Ký tên)*

Phản biện 2
(Ký tên)

Người hướng dẫn
(Ký tên)*

Chủ tịch hội đồng
(Ký tên)

*: Ghi đầy đủ học hàm, học vị và họ tên

LỜI CẢM TẠ

Luận văn tốt nghiệp này được tài trợ bởi Chương trình học bổng đào tạo thạc sĩ, tiến sĩ trong nước của Quỹ Đổi mới sáng tạo Vingroup (VINIF), mã số VINIF.2024.ThS.56.

Cần Thơ, ngày tháng năm

Tác giả

(Ký, họ và tên)

TÓM TẮT NỘI DUNG

Nghiên cứu này giải quyết vấn đề Nhận dạng thống kê cho hàm mật độ xác suất mất cân bằng và ứng dụng cho dữ liệu ảnh, một lĩnh vực then chốt để phát triển các hệ thống trí thông minh nhân tạo (AI) dự đoán. Nhận dạng thống kê, bao gồm phân loại (có giám sát) và phân tích chùm (không giám sát), thường phải đối mặt với dữ liệu mất cân bằng. Tức là, một số nhóm có số lượng phần tử quá nhỏ so với các nhóm còn lại, làm cho các thuật toán truyền thống dễ bị thiên lệch về lớp đa số, từ đó giảm hiệu quả nhận dạng lớp thiểu số quan trọng. Mặc dù vấn đề này đã được quan tâm đối với dữ liệu rời rạc, nhận dạng thống kê cho dữ liệu hàm mật độ xác suất mất cân bằng hầu như chưa được xem xét. Mục đích chính của luận văn là xây dựng thuật toán phân loại và phân tích chùm với dữ liệu mất cân bằng, và áp dụng chúng cho dữ liệu hình ảnh khi các đặc trưng của ảnh được trích xuất và đại diện bởi hàm mật độ. Nghiên cứu thực hiện các thực nghiệm khoa học trong môi trường mô phỏng để đánh giá mô hình qua các tiêu chí cụ thể và xử lý so sánh kết quả bằng các phân tích thống kê.

ABSTRACT

This thesis addresses the problem of Statistical Recognition for Imbalanced Probability Density Functions and its Application to Image Data, a key area for developing predictive artificial intelligence (AI) systems. The research is thorough, covering all aspects of statistical identification, including supervised classification and unsupervised cluster analysis, as well as their application to face imbalance. This thoroughness instills confidence in the reader about the validity and reliability of the research data. That is, some clusters have too few elements compared to the remaining clusters, making traditional algorithms prone to bias towards the majority class and thereby reducing the effectiveness of identifying the important minority class. Although this problem has been addressed for discrete data, statistical identification for imbalanced probability density function data has been largely overlooked. The primary objective of this paper is to develop classification and clustering analysis algorithms for imbalanced data and apply them to image data, where image features are extracted and represented by density functions. The study conducts scientific experiments in a simulation environment to evaluate the model using specific criteria and processes, and compares the results through statistical analysis.

Keywords: *Statistical Recognition; Probability Density Functions; Supervised Classification; Unsupervised clustering; Images data*

LỜI CAM ĐOAN

Tôi tên là Trần Nam Hưng, là học viên cao học ngành Lý thuyết Xác suất và Thống kê Toán học khóa 2023–2025. Tôi xin cam đoan luận văn này là công trình nghiên cứu khoa học thực sự của bản thân tôi được sự hướng dẫn của PGS. TS. Võ Văn Tài.

Các thông tin được sử dụng tham khảo trong đề tài luận văn được thu thập từ các nguồn đáng tin cậy, đã được kiểm chứng, được công bố rộng rãi và được tôi trích dẫn nguồn gốc rõ ràng ở phần Danh mục Tài liệu tham khảo. Các kết quả nghiên cứu được trình bày trong luận văn/đề án này là do chính tôi thực hiện một cách nghiêm túc, trung thực và không trùng lặp với các đề tài khác cùng cấp đã được công bố trước đây. Tác giả đồng ý về việc Nhà trường có quyền công bố và phổ biến để phục vụ nhu cầu đào tạo, nghiên cứu khoa học (NCKH) và phục vụ cộng đồng.

Tôi xin lấy danh dự và uy tín của bản thân để đảm bảo cho lời cam đoan này.

Cần Thơ, ngày tháng năm

Người hướng dẫn

(Ký tên)

Tác giả thực hiện

(Ký tên)

LÝ LỊCH CÁ NHÂN

1 Lý lịch sơ lược

Họ và tên	Trần Nam Hưng	Giới tính	Nam
Ngày sinh	03/4/2001	Dân tộc	Kinh
Nơi sinh	phường Cái Khế, TP. Cần Thơ	Điện thoại	(+84) 765 143 365
Trình độ	Cử nhân Toán Ứng Dụng	Năm tốt nghiệp	2023
Email	hungm1823002@gstudent.ctu.edu.vn		
Địa chỉ	Số 86/11B, đường Cách Mạng Tháng Tám, phường Bình Thủy, TP. Cần Thơ		

2 Quá trình Đào tạo

Trình độ	Thời gian	Địa chỉ
THPT	2016–2019	Trường THPT Thực hành Sư phạm – Đại học Cần Thơ. Hệ đào tạo: Chính quy.
Đại học	2019–2023	Khoa Khoa học Tự nhiên – Đại học Cần Thơ. Ngành học: Toán Ứng Dụng; Hệ đào tạo: Chính quy. Trình độ ngoại ngữ: B2
Thạc sĩ	2023–2025	Khoa Khoa học Tự nhiên – Đại học Cần Thơ. Ngành học: Lý thuyết Xác suất và Thống kê Toán học; Hệ đào tạo: Chính quy. Trình độ ngoại ngữ: B2

3 Danh mục các công trình đã công bố

Bài báo khoa học hỗ trợ nội dung luận văn Thạc sỹ của tác giả

- **T. N. Hưng**, C. N. Thới, và V. V. Tài, “*Cải tiến thuật toán tự cập nhật chùm cho các hàm mật độ xác suất*”, CTU J. Sci., vol 61, số p.h 4, tháng 8 2025,
- T. M. Lượng, N. K. Ngân, **T. N. Hưng**, N. H. Chi, N. N. Huỳnh, và V. V. Tài, “*Thuật toán xây dựng chùm ảnh dựa trên các pixel màu được trích xuất*”, CTU J. Sci., vol 60, số p.h CĐ Khoa học tự nhiên, tr 98-107, tháng 8 2024.

Bài báo khoa học hỗ trợ liên quan của tác giả

- **Tran-Nam, H.**, Nguyen-Trang, T. & Che-Ngoc, H. *A new possibilistic-based clustering method for probability density functions and its application to detecting abnormal elements*. Sci Rep 14, 17871 (2024). <https://doi.org/10.1038/s41598-024-68323-9>

Cần Thơ, ngày tháng năm

Tác giả

(Ký, họ và tên)

MỤC LỤC

CHẤP THUẬN CỦA HỘI ĐỒNG	i
LỜI CẢM TẠ	ii
TÓM TẮT NỘI DUNG	iii
ABSTRACT	iv
LỜI CAM ĐOAN	v
LÝ LỊCH CÁ NHÂN	vi
DANH SÁCH BẢNG	xi
DANH SÁCH HÌNH VẼ	xii
DANH SÁCH KÝ HIỆU TOÁN HỌC	xiii
DANH SÁCH TỪ VIẾT TẮT	xiv
PHẦN MỞ ĐẦU	1
1 Lý do chọn đề tài	1
2 Mục đích nghiên cứu	2
3 Đối tượng và phạm vi nghiên cứu	2
4 Phương pháp nghiên cứu	2
5 Cấu trúc luận văn	2
PHẦN NỘI DUNG	3
1 KIẾN THỨC CHUẨN BỊ	4
1.1 Hàm mật độ xác suất	4
1.2 Một số hàm mật độ thông dụng	6
1.3 Một số hàm mật độ bổ sung	8
1.4 Ước lượng hàm mật độ xác suất	9
1.5 Độ đo đánh giá sự tương tự của các hàm mật độ xác suất	10
1.5.1 Sự tương tự của hai hàm mật độ xác suất	11

1.5.2	Sự tương tự của nhiều hơn hai hàm mật độ xác suất	15
1.6	Phương pháp số xấp xỉ tích phân	16
1.7	Phân tích chùm cho hàm mật độ xác suất	17
1.7.1	Phân tích chùm không mờ	17
1.7.2	Phân tích chùm mờ (FCF)	20
1.8	Phân loại cho hàm mật độ xác suất	22
1.8.1	Hồi quy logistics	22
1.8.2	Máy véc-tơ hỗ trợ	24
1.8.3	Phương pháp naive Bayes	25
	Tổng kết chương 1	26

2 NHẬN DẠNG THỐNG KÊ CHO HÀM MẬT ĐỘ XÁC SUẤT VỚI DỮ LIỆU MẤT CÂN BẰNG

27

2.1	Giới thiệu	27
2.1.1	Phương pháp phân tích chùm hàm mật độ xác suất	27
2.2	Giới thiệu bài toán phân tích chùm cho dữ liệu mất cân bằng	29
2.2.1	Thuật toán	31
2.2.2	Sự hội tụ của thuật toán	31
2.2.3	Tham số đánh giá chất lượng	37
2.2.4	Ví dụ minh họa	39
2.2.5	Phương pháp phân loại hàm mật độ xác suất	43
2.3	Giới thiệu bài toán phân loại cho dữ liệu mất cân bằng	44
2.3.1	Thuật toán	44
2.3.2	Tham số đánh giá chất lượng	45
2.3.3	Ví dụ minh họa	46
	Tổng kết chương 2	47

3 ỨNG DỤNG CHO DỮ LIỆU HÌNH ẢNH

48

3.1	Trích xuất đặc trưng của hình ảnh thành hàm mật độ xác suất	48
3.1.1	Vấn đề trích xuất đặc trưng của hình ảnh	48
3.1.2	Ước lượng hàm mật độ xác suất đại diện cho hình ảnh	48
3.2	Ứng dụng của bài toán phân tích chùm	50
3.2.1	Dữ liệu	50
3.2.2	Phương pháp thực hiện	51
3.2.3	Kết quả thực hiện	52
3.3	Ứng dụng của bài toán phân loại	55
3.3.1	Dữ liệu	55
3.3.2	Phương pháp thực hiện	55
3.3.3	Kết quả thực hiện	55
	Tổng kết chương 3	55

PHẦN KẾT LUẬN

56

TÀI LIỆU THAM KHẢO	56
PHỤ LỤC	63
CHỈ MỤC	76

DANH SÁCH BẢNG

1.1	Một số hàm hạt nhân phổ biến dùng trong ước lượng mật độ hạt nhân	10
1.2	Bảng tổng kết các loại khoảng cách và các chỉ số khác giữa hai hàm mật độ xác suất . .	11
1.3	Các kết quả khoảng cách giữa hai hàm mật độ đều	14
1.4	Bảng tổng kết các loại liên kết Δ giữa hai chùm hàm mật độ xác suất	15
1.5	Tổng kết các tương tự giữa các chùm hàm mật độ xác suất	16
1.6	So sánh độ phức tạp của ba thuật toán phân chùm	22
2.1	Tổng quan giai đoạn 5 năm (2019–2024) nghiên cứu phân tích chùm cho hàm mật độ xác suất	28
2.2	Tổng quan giai đoạn 5 năm (2019–2024) nghiên cứu phân tích chùm cho hàm mật độ xác suất (Các tác giả nước ngoài)	29
2.3	Các công thức trọng tâm tương ứng với các loại khoảng cách	35
2.4	Các chỉ số đánh giá độ tương đồng giữa hai phân hoạch	39
2.5	So sánh các loại khoảng cách với các mức IR đối với Ví dụ 2.1	41
2.6	Tổng quan phương pháp phân loại cho hàm mật độ xác suất	44
2.7	Mô tả các chỉ số đánh giá phân loại	46
3.1	Cấu hình thuật toán phân chùm cho phân tích so sánh	52
3.2	So sánh các thuật toán đề xuất và các thuật toán cơ sở đối với Ví dụ 3.2	53
3.3	Một số hàm cơ sở $\psi_m(x)$ phổ biến trong hồi quy logistic cho dữ liệu hàm mật độ	63
3.4	Kết quả so sánh các khoảng cách theo chỉ số <i>ARI</i> đối với Ví dụ 2.1	73
3.5	Kết quả so sánh các khoảng cách theo chỉ số đối với <i>NMI</i> Ví dụ 2.1	73
3.6	Kết quả so sánh các khoảng cách theo chỉ số <i>Silhouette</i> đối với Ví dụ 2.1	74
3.7	Kết quả so sánh các khoảng cách theo chỉ số Thời gian chạy đối với Ví dụ 2.1	74

DANH SÁCH HÌNH VẼ

1.1	Minh họa hai hàm mật độ xác suất đại diện một chùm hàm mật độ $\mathcal{F}$	9
1.2	So sánh các hàm hạt nhân và hệ số trơn trong ước lượng mật độ xác suất	10
1.3	Dãy khoảng cách $D(f_1; f_2)$ giữa hai hàm mật độ Gauss $\mathcal{N}(0; 1)$ và $\mathcal{N}(\mu; 1)$	12
1.4	Các trường hợp trong khoảng cách giữa hai hàm mật độ đều $f_1(x)$ và $f_2(x)$	13
1.5	Kết quả phân chùm KCF đối với Ví dụ 1.4	19
1.6	Kết quả phân cấp thứ bậc tích tụ HCF đối với Ví dụ 1.5	20
1.7	Biểu đồ phân vùng mờ theo khoảng cách D_{1j} với các hệ số m khác nhau.	21
1.8	Hàm $\hat{\beta}(x)$ được ước lượng qua 10 hàm cơ sở Gauss.	23
2.1	Quan hệ giữa tỷ lệ mất cân bằng và quy mô cụm chiếm ưu thế	30
2.2	Ảnh hưởng của dữ liệu hàm mật độ Gauss mất cân bằng lên FCF ($m = 2; c = 3; \mathbf{D} = \mathcal{L}_2$)	32
2.3	Minh họa các công thức trọng tâm theo khoảng cách	35
2.4	Ảnh hưởng của tham số mờ m trong EM-IFCM qua IR	37
2.5	Một số chỉ số đánh giá và số chùm tối ưu	39
2.6	Dữ liệu tại Ví dụ 2.1	40
2.7	Đánh giá thống kê các chỉ số cho Ví dụ 2.1	42
2.8	Kết quả tham số m qua các chỉ số đánh giá đối với Ví dụ 2.1	42
2.9	Đánh giá thống kê các chỉ số so sánh thuật toán cho Ví dụ 2.1	43
3.1	Minh họa quá trình chuyển đổi dữ liệu ảnh thành hàm mật độ dựa trên màu sắc.	49
3.2	Minh họa quá trình chuyển đổi dữ liệu ảnh thành hàm mật độ dựa trên khối màu.	50
3.3	Các hình ảnh được cắt từ tập dữ liệu Brodatz.	51
3.4	Hình ảnh thực tế và các hàm mật độ xác suất trích xuất từ khối màu	51
3.5	Ma trận phân vùng của các phương pháp tại $IR = 80$	52
3.6	Phương pháp IFCE được đề xuất áp dụng cho ảnh Landsat	54
3.7	Khởi tạo ngẫu nhiên của FCF	71
3.8	Vòng lặp $t = 1$ của FCF	72
3.9	Vòng lặp $t = 9$ của FCF	72
3.10	Thay đổi của trọng tâm chùm FCF qua các vòng lặp	73

DANH SÁCH KÝ HIỆU TOÁN HỌC¹

Ký hiệu	Mô tả
$X; Y; Z; S$	Biến ngẫu nhiên
Y	Tập nhãn của dữ liệu (đối với bài toán phân loại)
$D; U; U^T$	Ma trận, ma trận chuyển vị
$\mathcal{F}; \mathcal{G}; \mathcal{H}; \mathcal{P}; \mathcal{Q}$	Tập hợp
$\#\mathcal{F}$	Lực lượng của tập hợp $\mathcal{F}$
$\mathbb{R}; \mathbb{R}_{>0}; \mathbb{N}; \mathbb{N}_{>0}$	Số thực, số thực dương, số tự nhiên, số tự nhiên dương
$\mathbb{E}(\cdot)$	Kỳ vọng của biến ngẫu nhiên
$\text{Var}(\cdot)$	Phương sai của biến ngẫu nhiên
$\text{Trace}(\cdot)$	Vết của ma trận
$ \cdot $	Định thức của ma trận
$f \oplus g$	Toán tử tích chập giữa hai hàm mật độ f và g
$\mathbf{1}_{\{\cdot\}}$	Hàm logic (bằng 1 nếu thỏa điều kiện $\{\cdot\}$, ngược lại là 0)
$\text{sign}(\cdot)$	Hàm xét dấu (bằng +1 nếu thỏa điều kiện $(\cdot)$, ngược lại là -1)
$\ell(\cdot)$	Hàm mất mát
$\mathcal{L}(\cdot)$	Hàm L'Arange
$\langle \cdot; \cdot \rangle$	Tích trong của hai ma trận

¹Các ký hiệu đã được thống nhất, các ký hiệu khác sẽ được làm rõ trong luận văn

DANH SÁCH TỪ VIẾT TẮT

Từ viết tắt	Nghĩa Tiếng Việt	Nghĩa Tiếng Anh
AI	Trí thông minh nhân tạo	Artificial Intelligence
CVI	Chỉ số đánh giá phân tích cụm	Clustering Validation Indices
KCF	Thuật toán k -means cho hàm mật độ xác suất	k -means for probability density Function
FCF	Thuật toán phân cụm mờ cho hàm mật độ xác suất	Fuzzy c -means for probability density Function
HCF	Thuật toán phân cấp thứ bậc cho hàm mật độ xác suất	Hierarchical Clustering for probability density Function
IFCF	Thuật toán phân cụm mờ cải tiến cho hàm mật độ xác suất	Improved Fuzzy c -means for probability density Function
SUP	Thuật toán phân cụm tự cập nhật	Self-Updating Processing
XAI	Thông minh nhân tạo giải thích được	eXplainable Artificial Intelligence

PHẦN MỞ ĐẦU

1 Lý do chọn đề tài

Nghiên cứu – phát triển các nguyên tắc và ứng dụng hệ thống thông minh nhân tạo (AI) là yếu tố then chốt nhằm thúc đẩy tăng trưởng kinh tế bền vững ở các quốc gia [1, 2]. Với khả năng ứng dụng đa ngành – đa chiều, AI không chỉ cải thiện năng suất lao động mà còn mở ra nhiều cơ hội việc làm, góp phần xây dựng nền kinh tế số [3], nâng cao tiện ích, thu nhập và chất lượng cuộc sống [4]. Trong sự phát triển của AI, nhận dạng thống kê được xem là một trong những kiến thức nền tảng nhằm phát triển các AI dự đoán hiện nay.

Nhận dạng thống kê gồm có hai bài toán chính: nhận dạng được giám sát và không được giám sát [5, 6]. Nhận dạng không được giám sát là việc chia dữ liệu thành các cụm sao cho các phần tử trong cùng một cụm có sự tương tự nhiều hơn so với các phần tử bên ngoài cụm đó [7, 8]. Do đó, nó còn được gọi là bài toán phân tích cụm. Phân tích cụm là cơ sở của việc lưu trữ, trích xuất và xử lý dữ liệu lớn nên được rất nhiều nhà thống kê và công nghệ thông tin quan tâm. Nhận dạng được giám sát là việc xếp một phần tử vào một nhóm trong các nhóm đã biết một cách thích hợp [5, 9]. Do đó, nó còn được gọi là bài toán phân loại. Phân loại đã và đang được áp dụng trong nhiều lĩnh vực khác nhau. Chẳng hạn, trong y tế hoạt động chẩn đoán bệnh của các bác sĩ xem một người có bệnh hay không có bệnh B, loại nào trong bệnh B thực chất là thực hiện bài toán phân loại. Trong lĩnh vực xã hội và an ninh, việc nhận dạng khuôn mặt, chữ ký, dấu vân tay, ... cũng chính là thực hiện bài toán phân loại.

Dữ liệu cho nhận dạng thống kê có thể là dữ liệu rời rạc, dữ liệu khoảng và hàm mật độ xác suất. Nhận dạng thống kê cho dữ liệu rời rạc đã được xem xét đầu tiên đã và đang được nghiên cứu rất nhiều [7, 10, 11]. Trong thực tế, chúng ta cũng lưu trữ nhiều dữ liệu khoảng như nhiệt độ, lượng mưa, giá chứng khoán nên nhận dạng cho kiểu dữ liệu này đã được đề xuất và phát triển. Khi dữ liệu lớn và phức tạp như hình ảnh, đối tượng hình ảnh có thể được xem là một hàm mật độ xác suất trong một số phương pháp biểu diễn [12], do đó nhận dạng thống kê cho hàm mật độ xác suất được đề xuất.

Xét về số lượng phần tử trong các nhóm, dữ liệu có thể được gọi là mất cân bằng và không mất cân bằng. Khi số lượng phần tử của các nhóm không có sự chênh lệch nhiều thì nó được gọi là không mất cân bằng. Trong nhận dạng dữ liệu của thực tế, nhiều trường hợp chúng ta gặp phải dữ liệu mất cân bằng. Đó là kiểu dữ liệu mà một nhóm hoặc một số ít nhóm có số lượng phần tử quá nhỏ so với các nhóm còn lại [13]. Khi một mô hình nhận dạng phải đối mặt với chênh lệch lớn về số lượng mẫu, nó dễ dàng bị thiên lệch về lớp đa số, dẫn đến hiệu quả thấp trong việc nhận dạng các mẫu của lớp thiểu số [14]. Chẳng hạn, trong tầm soát ung thư, ca bị bệnh có thể ít hơn 1000 lần so với trường hợp không

bị bệnh [15]. Khi đó các thuật toán nhận dạng truyền thống sẽ không phát huy hiệu quả vì nó có xu hướng thiên vị lớp đa số mà bỏ qua lớp thiểu số. Trong trường hợp này, độ chính xác của các lớp thiểu số là quan trọng hơn [13], bởi vì việc tầm soát sai người mắc ung thư là khỏe mạnh gây ra tổn thất tính mạng lớn hơn nhiều so với sai lầm ngược lại.

Nhận dạng thông kê cho dữ liệu mất cân bằng với các phần tử rời rạc đã được quan tâm trong những năm gần đây. Tuy nhiên với dữ liệu hàm mật độ xác suất hầu như chưa được xem xét. Từ sự phân tích trên, đề tài “**Nhận dạng thông kê cho hàm mật độ xác suất mất cân bằng và ứng dụng cho dữ liệu hình ảnh**” được chọn làm luận văn tốt nghiệp.

2 Mục đích nghiên cứu

- Xây dựng thuật toán phân loại và phân tích chùm cho hàm mật độ xác suất với dữ liệu mất cân bằng;
- Áp dụng hai thuật toán trên cho dữ liệu hình ảnh khi các đặc trưng của nó được trích xuất và đại diện bởi hàm mật độ xác suất để nhận dạng.

3 Đối tượng và phạm vi nghiên cứu

3.1 Đối tượng nghiên cứu

- Thuật toán phân loại và phân tích chùm với dữ liệu mất cân bằng;
- Dữ liệu hình ảnh được trích xuất thành các đối tượng đại diện.

3.2 Phạm vi nghiên cứu

- Các thuật toán phân tích chùm và phân loại cho hàm mật độ xác suất;
- Dữ liệu hình ảnh được trích xuất thành hàm mật độ xác suất đại diện;
- Vấn đề tính toán của các phương pháp phân loại, phân tích chùm.

4 Phương pháp nghiên cứu

- *Nghiên cứu lý thuyết*: Phân tích – tổng kết, phân loại – hệ thống hóa kiến thức về lĩnh vực nhận dạng thông kê; So sánh đánh giá ưu điểm và nhược điểm của các thuật toán.
- *Thực nghiệm khoa học*: Thực hiện các ví dụ số minh họa lý thuyết trong môi trường mô phỏng nhằm đánh giá các mô hình nhận dạng qua nhiều tiêu chí cụ thể, từ đó xử lý so sánh kết quả bằng các phân tích thống kê.

5 Cấu trúc luận văn

Luận văn bao gồm phần mở đầu, phần nội dung và phần kết luận, trong đó phần nội dung gồm ba chương:

Chương 1. Kiến thức chuẩn bị

Chương 2. Nhận dạng thống kê cho hàm mật độ xác suất với dữ liệu mất cân bằng

Chương 3. Ứng dụng cho dữ liệu hình ảnh

CHƯƠNG 1

KIẾN THỨC CHUẨN BỊ

1.1 Hàm mật độ xác suất

Hàm mật độ xác suất là khách thể nghiên cứu của một số nhà thống kê hiện đại [16–18]. Nó là một phần của dữ liệu đặc trưng bao gồm hữu hạn các xác suất, khoảng và hàm mật độ [17]. Ở đây, luận văn chỉ hệ thống hóa những kiến thức có liên quan.

Định nghĩa 1.1 (Biến ngẫu nhiên). Một biến ngẫu nhiên X trong không gian xác suất $(\Omega; \mathcal{E}; \mathbb{P})$ là một hàm Borel đo được từ Ω đến $\mathbb{R}$, tức là $X : (\Omega; \mathcal{E}) \rightarrow (\mathbb{R}; \mathcal{B}(\mathbb{R}))$.

Tương tự, ta mở rộng biến ngẫu nhiên d -chiều cho véc-tơ $\mathbf{X} = (X_1; X_2; \dots; X_d)$ trong $\mathbb{R}^d$, với mỗi thành phần $X_i; (i = 1; 2; \dots; d)$ là biến ngẫu nhiên trên $(\Omega, \mathcal{E}, \mathbb{P})$, nhận giá trị trong $\mathbb{R}$.

Định nghĩa 1.2 (Biến ngẫu nhiên d -chiều). Biến ngẫu nhiên d -chiều là một hàm Borel đo được từ không gian xác suất đến không gian Euclid $\mathbb{R}^d$, tức là $\mathbf{X} : (\Omega; \mathcal{E}) \rightarrow (\mathbb{R}^d; \mathcal{B}(\mathbb{R}^d))$.

Định nghĩa 1.3 (Hàm phân phối). Hàm phân phối của biến ngẫu nhiên X là hàm $P := P_X : \mathbb{R} \rightarrow [0; 1]$ được định nghĩa bởi $P(x) = P\{\omega : X(\omega) \leq x\}; \forall x \in \mathbb{R}$.

Tính chất 1.1. Phân phối P thỏa các tính chất sau.

1. P không giảm,
2. $\lim_{x \rightarrow \infty} P(x) = 1$ và $\lim_{x \rightarrow -\infty} P(x) = 0$,
3. P liên tục phải, tức là $\lim_{x \downarrow y} P(y) = P(x)$,
4. Nếu $P(x_-) = \lim_{y \uparrow x} P(y)$ thì $P(x_-) = \mathbb{P}(X < x)$,
5. $\mathbb{P}(X = x) = P(x) - P(x_-)$.

Định nghĩa 1.4 (Hàm phân vị). Cho phân phối P trên $\mathbb{R}$, hàm phân vị $F^{-1} : [0; 1] \rightarrow \mathbb{R}$ được định nghĩa bởi $F^{-1}(s) = \inf\{x \in \mathbb{R} : P(x) \geq s\}; s \in [0; 1]$.

Tính chất 1.2. Hàm phân vị F^{-1} thỏa các tính chất sau.

1. F^{-1} không giảm: nếu $s_1 \leq s_2$ thì $F^{-1}(s_1) \leq F^{-1}(s_2)$,
2. Nếu P liên tục, $P(F^{-1}(s)) = s$ và $F^{-1}(P(x)) = x$,
3. Kỳ vọng và phương sai được biểu diễn qua F^{-1} dưới công thức $\mathbb{E}(X) = \int_0^1 F^{-1}(s) ds$ và $\text{Var}(X) = \mathbb{E}(X^2) - \mathbb{E}^2(X)$,
4. Nếu P đối xứng quanh μ , ta có quan hệ đối xứng $F^{-1}(1 - s) = 2\mu - F^{-1}(s)$.

Định nghĩa 1.5 (Hàm mật độ xác suất). Họ các hàm phân phối $P : \mathbb{R}^d \rightarrow [0; \infty]$ là liên tục tuyệt đối trong $(\Omega; \mathcal{B})$ -đo được với μ hoặc là độ đo Lebesgue hoặc độ đo đếm. Khi này, hàm mật độ trong không gian thực được định nghĩa là

$$\forall x; f(x) = \frac{dP}{d\mu}(x) = \begin{cases} f(s), & \text{nếu } \mu \text{ là độ đo Lebesgue,} \\ \mathbb{P}(X = x) = p(x), & \text{nếu } \mu \text{ là độ đo đếm.} \end{cases}$$

Tính chất 1.3. Hàm mật độ thỏa mãn các tính chất sau.

1. Hàm mật độ xác suất liên tục $f(x)$ là hàm không âm, $f(x) \geq 0; \forall x \in \Omega$,
2. Tích phân $f(x)$ trên toàn miền Ω bằng 1,
3. Xác suất trên tập con Borel $A \subseteq \Omega$ được tính bằng tích phân $\mathbb{P}(X \in A) = \int_A f(x) dx$,
4. Công thức xác suất trong tập Borel thực

$$\mathbb{P}(a < x < b) = \mathbb{P}(a < x \leq b) = \mathbb{P}(a \leq x < b) = \mathbb{P}(a \leq x \leq b) = \int_a^b f(x) dx.$$

Nhận xét. Các hàm phân phối P , và phân vị F^{-1} đều không bảo toàn trong không gian véc-tơ Hilbert. Các giá trị của mật độ xác suất liên tục thì có thể tùy ý, nhưng phải thỏa mãn Tính chất 1.3. Một xác suất tại điểm $x = x_0$ không được khảo sát trong hàm mật độ liên tục tuyệt đối mà ở một tập Borel thực như Tính chất 1.3.(3). Tức là xác suất tại điểm bất kì luôn bằng 0 đối với biến ngẫu nhiên X liên tục.

Ta có thể tổng quát hóa tập các hàm mật độ thành không gian con lồi của $\mathcal{L}^1(\Omega)$ và đóng trong tô-pô chuẩn $\mathcal{F}(\Omega) = \{f : \Omega \rightarrow \mathbb{R}^+ | \int_{\Omega} f(x) d\mu(x) = 1\}$.

Định nghĩa 1.6. Hai tham số kỳ vọng và phương sai của biến ngẫu nhiên X được định nghĩa bởi $\mathbb{E}(X) = \int_{\Omega} x f(x) dx < \infty$; và $\text{Var}(X) = \int_{\Omega} (x - \mathbb{E}(X))^2 f(x) dx$.

Định nghĩa 1.7. Với các đối tượng hàm mật độ, toán tử tổng và tích có hướng được thay thế bởi phép nhân điểm và lũy thừa. Tức là, $(f \oplus g)(x) = f(x)g(x)$ và $(\alpha \odot f)(x) = f^\alpha(x)$, với $\alpha \in \mathbb{R}$.

Định nghĩa 1.8 (Dữ liệu hàm mật độ 1-chiều). Dữ liệu hàm mật độ là một bộ đối tượng không chắc chắn o có dạng $(o_1; o_2; \dots; o_n)$ [19]. Mỗi đối tượng o_j chứa một cặp $(I_j; f_j)$ với mỗi $1 \leq j \leq n$, trong đó $I_j = [l_j; u_j]$ là khoảng xác định của o_j và $f : \mathbb{R} \rightarrow \mathbb{R}^+$ là hàm mật độ xác suất xếp các giá trị xác suất vào mỗi $x \in I_j$ sao cho

$$\int_{x \in I_j} f_j(x) dx = 1, \text{ và } \int_{x \in \mathbb{R} \setminus I_j} f_j(x) dx = 0.$$

Định nghĩa 1.9 (Dữ liệu hàm mật độ d -chiều). Dữ liệu hàm mật độ d -chiều là một bộ đối tượng không chắc chắn o có dạng $(o_1; o_2; \dots; o_n)$ [19]. Mỗi đối tượng o_j chứa một cặp $(R_j; f_j)$ với mỗi $1 \leq j \leq n$, trong đó $R_j = [l_1; u_1] \times \dots \times [l_d; u_d] \subseteq \mathbb{R}^d$ là vùng xác định d -chiều của o_j và $f : \mathbb{R}^d \rightarrow \mathbb{R}^+$ là hàm mật độ xác suất xếp các giá trị xác suất vào mỗi $x \in R_j$ sao cho

$$\int_{x \in R_j} f_j(x) dx = 1, \text{ và } \int_{x \in \mathbb{R}^d \setminus R_j} f_j(x) dx = 0.$$

Để minh họa và mô phỏng, luận văn này làm việc trên dữ liệu các hàm mật độ định nghĩa trên toàn không gian mẫu $I = \mathbb{R}$ hoặc $R = \mathbb{R}^d$, và ký hiệu xuyên suốt là $\mathcal{F} = \{f_1(x); \dots; f_n(x)\}$. Để đơn giản hóa, luận văn này giả định các đối tượng hàm mật độ là độc lập.

1.2 Một số hàm mật độ thông dụng

Hàm mật độ xác suất cụ thể được nghiên cứu bởi các nhà khoa học thực nghiệm và thỏa mãn các Tính chất 1.3.

Định nghĩa 1.10 (Hàm mật độ Gauss). Biến ngẫu nhiên liên tục X tuân theo mật độ Gauss (chuẩn) với hai tham số μ và σ^2 (trong đó $\mu \in \mathbb{R}$ và $\sigma^2 \in \mathbb{R}_{>0}$) nếu nó có hàm mật độ xác suất là

$$\mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), x \in \mathbb{R}.$$

Định lý 1.1 (Kỳ vọng và phương sai). Kỳ vọng và phương sai của biến ngẫu nhiên X có hàm mật độ xác suất Gauss là $\mathbb{E}(X) = \mu$, $\text{Var}(X) = \sigma^2$.

Hàm mật độ Gauss có dáng điệu hình cong đối xứng và miền xác định khắp không gian. Đặc trưng kỳ vọng μ chính là giá trị cực đại và xác định vị trí của hàm mật độ, đặc trưng phương sai Σ thể hiện độ phân tán hay độ cao của hàm, phương sai càng nhỏ thì hàm mật độ càng cao và hẹp. Thông thường, dữ liệu rời rạc thường được biến đổi thành dữ liệu hàm mật độ qua biểu diễn của hàm mật độ Gauss (khi ước lượng tham số) hoặc nhân-Gauss (khi ước lượng phi tham số). Hơn hết, định lý giới hạn trung tâm chứng minh tổng các biến ngẫu nhiên độc lập có phân phối xấp xỉ Gauss.

Bổ đề 1.1 (Tổng hai hàm mật độ Gauss). Cho hai biến ngẫu nhiên độc lập $X_1 \sim \mathcal{N}(\mu_1, \sigma_1^2)$ và $X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$. Khi đó tổng $S = X_1 \pm X_2$ cũng là biến ngẫu nhiên có hàm mật độ Gauss, tức là $S \sim \mathcal{N}(\mu_1 \pm \mu_2, \sigma_1^2 + \sigma_2^2)$.

Bổ đề 1.2 (Tích phân của hai hàm mật độ Gauss). Cho hai hàm mật độ Gauss $\mathcal{N}(\mu_1; \sigma_1^2)$ và $\mathcal{N}(\mu_2; \sigma_2^2)$ với kỳ vọng $\mu_1, \mu_2 \in \mathbb{R}$, và phương sai $\sigma_1^2, \sigma_2^2 > 0$. Khi đó, tích phân giữa hai hàm mật độ được xác định bởi

$$\int_{\Omega} \mathcal{N}(\mu_1; \sigma_1^2) \cdot \mathcal{N}(\mu_2; \sigma_2^2) dx = \frac{1}{\sqrt{2\pi(\sigma_1^2 + \sigma_2^2)}} \exp\left(-\frac{(\mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right).$$

Chứng minh. Xét tích phân

$$\begin{aligned} I &= \int_{-\infty}^{\infty} \mathcal{N}(x; \mu_1; \sigma_1^2) \cdot \mathcal{N}(x; \mu_2; \sigma_2^2) dx = \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{(x-\mu_1)^2}{2\sigma_1^2} - \frac{(x-\mu_2)^2}{2\sigma_2^2}\right) dx \\ &= \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{1}{2} \underbrace{\left(\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}\right)}_{:=1/\sigma^2} x^2 + \underbrace{\left(\frac{\mu_1}{\sigma_1^2} + \frac{\mu_2}{\sigma_2^2}\right)}_{:=\mu} x - \frac{\mu_1^2}{2\sigma_1^2} - \frac{\mu_2^2}{2\sigma_2^2}\right) dx \\ &= \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{1}{2}\sigma^2(x-\mu)^2 - \frac{(\mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right) dx \\ &= \frac{1}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{(\mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right) \underbrace{\int_{-\infty}^{\infty} \exp\left(-\frac{1}{2\sigma^2}(x-\mu)^2\right) dx}_{=\sqrt{2\pi\sigma^2}} \\ &= \frac{\sqrt{2\pi\sigma^2}}{2\pi\sigma_1\sigma_2} \exp\left(-\frac{(\mu_1 - \mu_2)^2}{2(\sigma_1^2 + \sigma_2^2)}\right). \end{aligned}$$

Từ đây, ta suy ra được điều phải chứng minh. ■

Định nghĩa 1.11 (Hàm mật độ Gauss d -chiều). Biến ngẫu nhiên liên tục d -chiều $\mathbf{X}$ tuân theo mật độ Gauss (chuẩn) với hai tham số $\boldsymbol{\mu}$ và $\boldsymbol{\Sigma}$ (trong đó $\boldsymbol{\mu} \in \mathbb{R}^d$ và $\boldsymbol{\Sigma}$ thuộc đa tập của ma trận đối xứng xác định dương) nếu nó có hàm mật độ xác suất là

$$\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}; \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{d/2} |\boldsymbol{\Sigma}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right), \mathbf{x} \in \mathbb{R}^d,$$

trong đó, $|\boldsymbol{\Sigma}|$ là định thức của ma trận hiệp phương sai.

Định lý 1.2 (Kỳ vọng và hiệp phương sai). Kỳ vọng và phương sai của biến ngẫu nhiên $\mathbf{X}$ có hàm mật độ xác suất Gauss là $\mathbb{E}(\mathbf{X}) = \boldsymbol{\mu}$, $\text{Cov}(\mathbf{X}) = \boldsymbol{\Sigma}$.

Bổ đề 1.3 (Tổng hai hàm mật độ Gauss d -chiều). Cho hai biến ngẫu nhiên độc lập $X_1 \sim \mathcal{N}(\boldsymbol{\mu}_1; \boldsymbol{\Sigma}_1)$ và $X_2 \sim \mathcal{N}(\boldsymbol{\mu}_2; \boldsymbol{\Sigma}_2)$. Khi đó tổng $S = X_1 + X_2$ cũng là biến ngẫu nhiên có hàm mật độ Gauss, tức là $S \sim \mathcal{N}(\boldsymbol{\mu}_1 + \boldsymbol{\mu}_2; \boldsymbol{\Sigma}_1 + \boldsymbol{\Sigma}_2)$.

Bổ đề 1.4 (Tích phân của hai hàm mật độ Gauss d -chiều). Cho hai hàm mật độ Gauss d -chiều $\mathcal{N}(\boldsymbol{\mu}_1; \boldsymbol{\Sigma}_1)$ và $\mathcal{N}(\boldsymbol{\mu}_2; \boldsymbol{\Sigma}_2)$ với véc-tơ kỳ vọng $\boldsymbol{\mu}_1, \boldsymbol{\mu}_2 \in \mathbb{R}^d$, và ma trận hiệp phương sai $\boldsymbol{\Sigma}_1, \boldsymbol{\Sigma}_2$ xác định dương. Khi đó, tích phân giữa hai hàm mật độ được xác định bởi

$$\begin{aligned} \int_{\Omega} \mathcal{N}(\boldsymbol{\mu}_1; \boldsymbol{\Sigma}_1) \cdot \mathcal{N}(\boldsymbol{\mu}_2; \boldsymbol{\Sigma}_2) d\mathbf{x} &= \frac{1}{(2\pi)^{d/2} |\boldsymbol{\Sigma}_1 + \boldsymbol{\Sigma}_2|^{1/2}} \\ &\times \exp\left(-\frac{1}{2}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^\top (\boldsymbol{\Sigma}_1 + \boldsymbol{\Sigma}_2)^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)\right). \end{aligned}$$

Nhận xét. Hàm mật độ $h(x)$ của tổng $S = X + Y$ hai biến ngẫu nhiên độc lập là kết quả của tích chập giữa các hàm mật độ tương ứng, tức là $h(x) = f_X(x) \oplus g_Y(x)$.

Ngoài ra, các phát triển bất đối xứng của Gauss điển hình là hàm Gauss-lệch [20]. với hàm mật độ của nó được định nghĩa như sau.

Định nghĩa 1.12 (Hàm mật độ Gauss-lệch). Biến ngẫu nhiên liên tục X tuân theo mật độ Gauss-lệch (chuẩn-lệch) [20] với ba tham số μ , σ^2 và α (trong đó $\mu, \alpha \in \mathbb{R}$ và $\sigma^2 \in \mathbb{R}_{>0}$) nếu nó có hàm mật độ xác suất là

$$\mathcal{S}\mathcal{N}(x; \mu, \sigma^2, \alpha) = \frac{2}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \int_{-\infty}^{\alpha(x-\mu)/\sigma} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{t^2}{2}\right) dt, x \in \mathbb{R}.$$

Hàm mật độ Gauss-lệch nhận thêm một tham số thể hiện mức độ lệch α . Khi giá trị α càng lớn, độ lệch so với kỳ vọng μ càng lớn. Khi $\alpha = 0$, phân phối này trở về Gauss như Định nghĩa 1.10.

Định lý 1.3 (Kỳ vọng và phương sai). Kỳ vọng và phương sai của biến ngẫu nhiên X có hàm mật độ xác suất Gauss-lệch là $\mathbb{E}(X) = \mu + \sigma\delta\sqrt{\frac{2}{\pi}}$; $\text{Var}(X) = \sigma^2\left(1 - \frac{2\delta^2}{\pi}\right)$, với $\delta = \frac{\alpha}{\sqrt{1+\alpha^2}}$ nằm trong $(-1; 1)$.

Định nghĩa 1.13 (Hàm mật độ đều). Biến ngẫu nhiên liên tục X tuân theo phân phối đều trên đoạn $[l; u]$ (với $l < u$ và $l, u \in \mathbb{R}$) nếu nó có hàm mật độ xác suất là

$$\mathcal{U}(x; l; u) = \begin{cases} \frac{1}{u-l}, & x \in [l; u], \\ 0, & x \notin [l; u]. \end{cases}$$

Định lý 1.4 (Kỳ vọng và phương sai). Kỳ vọng và phương sai của biến ngẫu nhiên X có hàm mật độ xác suất đều là $\mathbb{E}(X) = \frac{l+u}{2}$; $\text{Var}(X) = \frac{(u-l)^2}{12}$.

Định nghĩa 1.14 (Hàm mật độ đều d -chiều). Biến ngẫu nhiên liên tục d -chiều $\mathbf{X}$ tuân theo phân phối đều trên hình hộp $[l_1; u_1] \times \cdots \times [l_d; u_d]$ (với $l_i < u_i$, $l_i, u_i \in \mathbb{R}$) nếu nó có hàm mật độ xác suất là

$$\mathcal{U}(\mathbf{x}; \mathbf{l}; \mathbf{u}) = \begin{cases} \prod_{i=1}^d \frac{1}{u_i - l_i}, & \mathbf{x} \in [l_1; u_1] \times \cdots \times [l_d; u_d], \\ 0, & \text{ngược lại.} \end{cases}$$

Định lý 1.5 (Kỳ vọng và hiệp phương sai). Kỳ vọng và phương sai của biến ngẫu nhiên $\mathbf{X}$ có hàm mật độ xác suất đều là $\mathbb{E}(\mathbf{X}) = \frac{\mathbf{l} + \mathbf{u}}{2}$; $\text{Cov}(\mathbf{X}) = \text{diag}\left(\frac{(u_1 - l_1)^2}{12}, \dots, \frac{(u_d - l_d)^2}{12}\right)$.

1.3 Một số hàm mật độ bổ sung

Gần đây, các thuật toán phân tích chùm dựa vào trọng tâm đề xuất bổ sung hàm mật độ xác suất trọng tâm (hay hàm mật độ đại diện của chùm) [21, 22]. Nó có chức năng như trung bình có trọng số của tổng các hàm mật độ trong chùm.

Định nghĩa 1.15 (Hàm mật độ đại diện chùm). Cho tập $\mathcal{F}$ gồm n -hàm mật độ xác suất với $n \geq 2$. Ta phân bổ $\mathcal{F}$ vào c -chùm ($1 < c \leq n$), khi này hàm mật độ đại diện của các chùm c_i là

$$\theta_i(x) = \frac{\sum_{j=1}^n \mu_{ij} \times f_j(x)}{\sum_{j=1}^n \mu_{ij}}, \quad (1.1)$$

trong đó, μ_{ij} là trọng số phân bổ hàm mật độ $f_j(x)$ bất kỳ vào chùm c_i [23].

Dựa vào định nghĩa trên, ta dễ dàng nhận được θ_i cũng là một hàm mật độ thỏa Tính chất 1.3.

Chứng minh. Các giá trị trọng số $0 \leq \mu_{ij} \leq 1$ nên các θ_i liên tục không âm, và

$$\int_{\Omega} \theta_i(x) dx = \int_{\Omega} \frac{\sum_{j=1}^n \mu_{ij} \times f_j(x)}{\sum_{j=1}^n \mu_{ij}} dx = \frac{\sum_{j=1}^n \mu_{ij} \times \int_{\Omega} f_j(x) dx}{\sum_{j=1}^n \mu_{ij}} = 1.$$

Định lý 1.6. Kỳ vọng của biến ngẫu nhiên X có hàm mật độ xác suất đại diện $\theta_i(x)$ là

$$\mathbb{E}_{\theta_i}(X) = \frac{\sum_{j=1}^n \mu_{ij} \mathbb{E}_{f_j}(X)}{\sum_{j=1}^n \mu_{ij}}.$$

Chứng minh. Ta có

$$\mathbb{E}_{\theta_i}(X) = \int_{\Omega} x \theta_i(x) dx = \int_{\Omega} x \frac{\sum_{j=1}^n \mu_{ij} f_j(x)}{\sum_{j=1}^n \mu_{ij}} dx = \frac{1}{\sum_{j=1}^n \mu_{ij}} \sum_{j=1}^n \mu_{ij} \underbrace{\int_{\Omega} x f_j(x) dx}_{=\mathbb{E}_{f_j}(X)}.$$

Từ đây, ta suy ra điều phải chứng minh. ■

Ta cũng mở rộng được cho hàm mật độ đại diện chùm đến không gian d -chiều tương tự cho véc-tơ ngẫu nhiên $\mathbf{X}$ và nó cũng thỏa mãn các tính chất của một hàm mật độ xác suất. Mới đây, Thao Nguyen-Trang *et al.* [24, 25] đề xuất hàm mật độ đại diện Gauss như là một phiên bản Gauss hóa của hàm Fréchet [26].


Định nghĩa 1.16 (Hàm mật độ đại diện Gauss). Hàm mật độ đại diện Gauss có dạng phân phối chuẩn sao cho tổng khoảng cách giữa chúng đến các hàm mật độ khác là nhỏ nhất [26], tức là

$$\theta_i(x) = \arg \min_{\mathcal{N}(\mu; \sigma)} \sum_{j=1}^n \mu_{ij} D(\mathcal{N}(\mu; \sigma); f_j(x)).$$

trong đó, $D(\mathcal{N}(\mu; \sigma); f_j(x))$ là khoảng cách giữa hai hàm mật độ Gauss trong tổng thể.

Nhận xét. Hàm mật độ đại diện Gauss là hàm trung bình Fréchet nên có nghiệm duy nhất [26]. Khác với (1.1), hàm mật độ này chỉ cần tìm một hàm Gauss duy nhất mà không cần tổ hợp các f_j giúp tăng khả năng khái quát hóa. Ta cũng có phương sai Fréchet $\text{Var}_j(X) = \mathbb{E}(D^2(\mathcal{N}(\mu; \sigma); f_j(x)))$.

Hình 1.1 minh họa cụ thể hai cách biểu diễn hàm mật độ đại diện trong cùng một chùm hàm Gauss. Để thấy sự khác biệt, hàm mật độ đại diện tập trung vào phân bố trung bình của nó tại các chùm, còn hàm mật độ đại diện Gauss lựa chọn vị trí dựa vào khoảng cách các hàm mật độ với nhau.



Chú thích: Hàm mật độ đại diện thể hiện bằng đường thẳng in đậm cho ba hàm Gauss minh họa bằng nét đứt (a) dựa vào trọng số phân bố đều giữa ba hàm $\mu_{ij} = 1/3$, và (b) dựa vào vị trí tối ưu. Ta có thể nói hàm mật độ đại diện này là kỳ vọng của các tổng thể khác nhau. Nguồn: Minh họa của tác giả.

Hình 1.1. Minh họa hai hàm mật độ xác suất đại diện một chùm hàm mật độ $\mathcal{F}$.

1.4 Ước lượng hàm mật độ xác suất

Trong thực tế, ta cần phải ước lượng hàm mật độ xác suất dựa vào dữ liệu rời rạc, luận văn này sử dụng phương pháp ước lượng hàm hạt nhân để chuyển từ bài toán rời rạc sang hàm mật độ xác suất.


Định nghĩa 1.17 (Ước lượng hàm mật độ bằng phương pháp hàm hạt nhân). Giả sử ta có một tập dữ liệu rời rạc gồm n quan sát $\mathbf{x}_j$ với $j = 1, \dots, n$ trong không gian $\mathbb{R}^d$. Mỗi điểm $\mathbf{x}_j = (x_{1j}, x_{2j}, \dots, x_{dj})^\top$. Hàm mật độ xác suất tại điểm $\mathbf{x} = (x_1, x_2, \dots, x_d)^\top$ được ước lượng bằng phương pháp hạt nhân bởi

$$\hat{f}(\mathbf{x}) = \frac{1}{n \prod_{i=1}^d bw_i} \sum_{j=1}^n \prod_{i=1}^d \kappa_i \left(\frac{x_i - x_{ij}}{bw_i} \right),$$

trong đó κ_i là hàm hạt nhân theo chiều i có tính chất $\kappa(\cdot) \geq 0$ và $\int \kappa(z) dz = 1$, tham số $bw_i > 0$ là tham số trơn ứng với chiều đó.

Nhận xét. Khi tham số trơn bw nhỏ, hàm mật độ ước lượng sẽ kém trơn và có thể dao động mạnh; ngược lại, nếu bw lớn thì hàm trở nên trơn hơn nhưng có thể làm mất chi tiết quan trọng của phân phối gốc. Trong trường hợp đơn giản, có thể chọn cùng một hàm hạt nhân và cùng một tham số trơn cho tất cả các chiều, tức là $\kappa_i \equiv \kappa$ và $bw_i = bw$ với mọi $i = 1, \dots, d$.

Một số hàm hạt nhân phổ biến được liệt kê trong Bảng 1.1. Luận văn này khảo sát hàm mật độ ước lượng từ hàm hạt nhân Gauss và Epanechnikov với tham số trơn cố định và được tính bởi công thức của Silverman, $bw = 1.06 \times \text{Var}(x_j) \times n^{-1/5}$.



Hình 1.2. So sánh các hàm hạt nhân và hệ số trơn trong ước lượng mật độ xác suất

Chú thích: Vùng xám là phân phối thực tế $X \sim 0,3\mathcal{N}(0;1) + 0,7\mathcal{N}(5;1)$, (a) các hàm hạt nhân ảnh hưởng đến khả năng khớp với hàm mật độ thực tế, trong khi (b) tham số trơn ảnh hưởng đến mức độ khớp. Nguồn: Minh họa của tác giả.

Bảng 1.1. Một số hàm hạt nhân phổ biến dùng trong ước lượng mật độ hạt nhân

Tên hàm	$\kappa(z)$	Miền xác định	Khả vi
Hình chữ nhật	$(1/2)\mathbf{1}_{\{ z \leq 1\}}$	$[-1; 1]$	
Tam giác	$(1 - z)\mathbf{1}_{\{ z \leq 1\}}$	$[-1; 1]$	$\mathcal{C}^0$
Epanechnikov	$(3/4)(1 - z^2)\mathbf{1}_{\{ z \leq 1\}}$	$[-1; 1]$	$\mathcal{C}^0$
Gauss	$\frac{1}{\sqrt{2\pi}} \exp(-z^2/2)$	$(-\infty, \infty)$	$\mathcal{C}^\infty$
Logistic	$\frac{\exp(-z)}{1 + \exp(-z)^2}$	$(-\infty, \infty)$	$\mathcal{C}^\infty$

1.5 Độ đo đánh giá sự tương tự của các hàm mật độ xác suất

Khoảng cách là độ đo xa-gần các vật thể. Ở đây, khái niệm *khoảng cách* bao hàm cả *độ đo phân biệt*.

1.5.1 Sự tương tự của hai hàm mật độ xác suất

Định nghĩa 1.18 (Khoảng cách $\mathcal{L}_p$). Cho hai hàm mật độ xác suất f_1, f_2 trên $\mathbb{R}^d$. Khoảng cách $\mathcal{L}_p$ được định nghĩa là

$$\mathcal{L}_p(f, g) = \left(\int_{\mathbb{R}^d} |f_1(x) - f_2(x)|^p dx \right)^{1/p}, 1 \leq p < \infty.$$

Theo Định nghĩa 1.18, khoảng cách giữa hai hàm mật độ thỏa mãn các tiên đề của mê-tríc. Thực tế, ta thường sử dụng $p = 1$ hoặc $p = 2$ cho các tính toán. Trong lý thuyết thống kê và thông tin, một mê-tríc được gọi là *khoảng cách* và nửa mê-tríc gọi là *phân kỳ*. Ta cũng có mối quan hệ giữa hai hàm mật độ đối mới trọng tâm bất kỳ trong mê-tríc.

Bổ đề 1.5 (Bất đẳng thức tam giác). Với mọi $f_j, f_k \in \mathcal{C}_i$ và trọng tâm chùm θ_i có khoảng cách là mê-tríc, ta có bất đẳng thức tam giác $D(f_j, f_k) \leq D(f_j, \theta_i) + D(f_k, \theta_i)$.

Tại Vo-Van (2019) [22] dựa trên khoảng cách $\mathcal{L}_p$ để giới thiệu độ rộng chùm.

$$CWD(f_1; f_2) = \int_{\Omega} \max\{f_1(x); f_2(x)\} dx - 1$$

Định nghĩa 1.19 (f -phân kỳ). Hàm $D : P_1 \times P_2 \rightarrow \mathbb{R}$ được gọi là f -phân kỳ của hai hàm mật độ $f_1 \in P_1$ và $f_2 \in P_2$ khi nó thỏa hệ số phân kỳ giữa hai xác suất [27]

$$D(P_1, P_2) = h \left(\mathbb{E}_1 \left(g \left(\frac{f_2}{f_1} \right) \right) \right),$$

trong đó g là một hàm liên tục lồi trên $\mathbb{R}_{>0}$, h là hàm tăng trên $\mathbb{R}$, và $\mathbb{E}_1$ là kỳ vọng của P_1 .

Bảng 1.2 làm rõ các công thức khoảng cách và độ đo tương tự giữa hai hàm mật độ xác suất theo tiếp cận xác suất.


Bảng 1.2. Bảng tổng kết các loại khoảng cách và các chỉ số khác giữa hai hàm mật độ xác suất

Khoảng cách	$D(f_1(x), f_2(x))$	$g(u)$	$h(u)$	Miền giá trị
$\mathcal{L}_1$	$\int_{\Omega} f_1(x) - f_2(x) dx$	$ 1 - u $	u	$[0; 2]$
Chernoff	$-\log \left(\int_{\Omega} f_1(x)^s f_2(x)^{1-s} dx \right)$	$-u^{1-s}$	$-\log(-u)$	$[0; +\infty)$
Matusita	$\left(\int_{\Omega} f_1^{1/r}(x) - f_2^{1/r}(x) ^r dx \right)^{1/r}$	$ 1 - u^{1/r} ^r$	$u^{1/r}$	$[0; \sqrt{2}]$
bình phương Hellinger	$\int_{\Omega} \left(\sqrt{f_1(x)} - \sqrt{f_2(x)} \right)^2 dx$	$(\sqrt{u} - 1)^2$	u	$[0; 2]$
thông tin Kullback	$\int_{\Omega} f_1(x) \log \frac{f_1(x)}{f_2(x)} dx$	$-\log(u)$	u	$[0; +\infty)$
Jensen-Shannon	$\frac{1}{2} (D_{KL}(f_1; f_2) + D_{KL}(f_2; f_1))$	$-(u+1) \log(\frac{u+1}{2}) + u \log(u)$	$\frac{1}{2}u$	$[0; +\infty)$
Bayes Error	$1 - \int_{\Omega} \min\{\pi f_1(x); \pi(1 - f_2(x))\} dx$	$-\min\{u; 1 - u\}$	$u + 1$	$[0; 1]$

Trong khoảng cách Chernoff, $0 \leq r \leq 1$, và Nguồn: Tác giả tổng hợp

Nhận xét. Nhìn vào Bảng 1.2, có thể thấy khoảng cách Chernoff là một tổng quát hóa của khoảng cách Bhattacharyya khi chọn $s = 1/2$. Tương tự khoảng cách Matusita là tổng quát hóa của bình phương Hellinger khi $r = 2$. Trong $\mathcal{L}_p$, chỉ có $\mathcal{L}_1$ là một f -phân kỳ và là Matusita với $r = 1$. Đáng chú ý, Matusita thỏa mãn tính chất mê-tríc.

Ở Hình 1.3, luận văn này ghi nhận giá trị khoảng cách $f_1 \sim \mathcal{N}(0; 1)$ và $f_2 \sim \mathcal{N}(\mu; 1)$ với μ trượt từ -10 đến 20 .



(a) Các khoảng cách có miền xác định bị chặn trên, (b) ngược lại. Nguồn: Minh họa của tác giả

Hình 1.3. Dãy khoảng cách $D(f_1; f_2)$ giữa hai hàm mật độ Gauss $\mathcal{N}(0; 1)$ và $\mathcal{N}(\mu; 1)$

Nhận xét. Ta thấy khi hai hàm mật độ f_2 cách nhau quá xa hàm f_1 , tức là $|\mu_2| \gg 0$, tất cả loại khoảng cách hàm mật độ đều bão hòa và không đo được sự khác biệt. Lúc này hai hàm mật độ về mặt không gian rất xa nhau, nhưng khoảng cách không thể đo xa hơn nữa vì nó đã đạt đến ngưỡng lớn nhất. Đây là hạn chế không giữ được vị trí hình học đối với các khoảng cách hàm mật độ.

Luận văn này giới thiệu khoảng cách Wasserstein (hay Kantorovich–Rubinstein), là một mê-tríc hỗ trợ tốt cho tính toán khoảng cách các hàm mật độ không chồng lấp [28] thỏa Định nghĩa 1.18 và bất đẳng thức tam giác. Khoảng cách này được phát triển trong bài toán vận chuyển tối ưu, nhưng chưa được nghiên cứu trong lĩnh vực nhận dạng hàm mật độ.

Định nghĩa 1.20 (Khoảng cách p -Wasserstein). Khoảng cách p -Wasserstein ($p \geq 1$) giữa hai độ đo xác suất μ và ν trong không gian $\mathbb{R}^d$ được định nghĩa là

$$W_p(\mu, \nu) = \inf_{\substack{X \sim \mu \\ Y \sim \nu}} (\mathbb{E} \|X - Y\|^p)^{1/p} = \left(\inf_{\gamma \in \Gamma(\mu, \nu)} \int_{M \times M} d(x, y)^p d\gamma(x, y) \right)^{1/p},$$

Khoảng cách p -Wasserstein đo mức chênh lệch tối ưu giữa hai phân phối xác suất, xét trên tất cả các phép ghép cặp khả dĩ. Tức là nó tính đến công sức để di chuyển và tái sắp xếp khối lượng từ hàm này sang hàm kia. Ở đây, luận văn này sử dụng $p = 2$ để tính toán đo độ khác biệt giữa hai mật độ xác suất liên tục. Trong thực tế, ta tính toán cụ thể khoảng cách này bằng cách biểu diễn nó qua hàm phân vị. Ta có Định lý 1.7.

Định lý 1.7. Khoảng cách p -Wasserstein giữa hai độ đo xác suất μ và ν có thể được biểu diễn dưới dạng phân vị trong trường hợp 1-chiều bởi định nghĩa

$$W_p^p(\mu, \nu) = \int_0^1 |F_\mu^{-1}(s) - F_\nu^{-1}(s)|^p ds,$$

trong đó F_μ^{-1} và F_ν^{-1} lần lượt là hàm phân vị của μ và ν (Xem Định nghĩa 1.4).

Định lý 1.8 (Khoảng cách 2-Wasserstein giữa hai hàm mật độ Gauss 1 chiều). Giả sử hai hàm mật độ $f_1(x) \sim \mathcal{N}(\mu_1, \sigma_1^2)$ và $f_2(x) \sim \mathcal{N}(\mu_2, \sigma_2^2)$ là hai phân bố Gauss một chiều. Khi đó, khoảng cách 2-Wasserstein giữa chúng là $D_W^2(f_1, f_2) = (\mu_1 - \mu_2)^2 + (\sigma_1 - \sigma_2)^2$.

Chứng minh. Dựa vào Định lý 1.7, ta xét hàm phân vị Gauss $F_i^{-1}(u) = \mu_i + \sigma_i \Phi^{-1}(u)$, với $\Phi^{-1}(u)$ là phân vị chuẩn $\mathcal{N}(0, 1)$. Khi đó,

$$\begin{aligned} D_W^2(f_1, f_2) &= \int_0^1 (\mu_1 + \sigma_1 \Phi^{-1}(u) - \mu_2 - \sigma_2 \Phi^{-1}(u))^2 du \\ &= \int_0^1 ((\mu_1 - \mu_2) + (\sigma_1 - \sigma_2) \Phi^{-1}(u))^2 du \\ &= \int_0^1 [(\mu_1 - \mu_2)^2 + 2(\mu_1 - \mu_2)(\sigma_1 - \sigma_2) \Phi^{-1}(u) + (\sigma_1 - \sigma_2)^2 (\Phi^{-1}(u))^2] du \\ &= (\mu_1 - \mu_2)^2 \underbrace{\int_0^1 du}_{=1} + 2(\mu_1 - \mu_2)(\sigma_1 - \sigma_2) \underbrace{\int_0^1 \Phi^{-1}(u) du}_{=0} + (\sigma_1 - \sigma_2)^2 \underbrace{\int_0^1 (\Phi^{-1}(u))^2 du}_{=1}. \end{aligned}$$

Từ đây ta suy ra được điều phải chứng minh. ■


Tương tự ta cũng suy ra được Định lý khoảng cách sau.

Định lý 1.9 (Khoảng cách 2-Wasserstein giữa hai hàm mật độ Gauss d -chiều). Giả sử hai hàm mật độ $f_1(x) \sim \mathcal{N}(\mu_1, \Sigma_1)$ và $f_2(x) \sim \mathcal{N}(\mu_2, \Sigma_2)$ là hai phân bố Gauss trong $\mathbb{R}^d$. Khi đó, khoảng cách 2-Wasserstein giữa chúng là

$$D_W^2(f_1, f_2) = \|\mu_1 - \mu_2\|_2^2 + \text{Tr} \left(\Sigma_1 + \Sigma_2 - 2(\Sigma_2^{1/2} \Sigma_1 \Sigma_2^{1/2})^{1/2} \right).$$

Định lý 1.10 (Khoảng cách 2-Wasserstein giữa hai phân phối đều 1-chiều). Giả sử hai hàm mật độ $f_1(x) \sim \mathcal{U}[a_1, b_1]$ và $f_2(x) \sim \mathcal{U}[a_2, b_2]$ là hai phân phối đều một chiều. Khi đó, khoảng cách 2-Wasserstein giữa chúng là $D_W^2(f_1, f_2) = (\mu_1 - \mu_2)^2 + \frac{1}{12}(l_1 - l_2)^2$, trong đó $\mu_i = \frac{a_i + b_i}{2}$ là trung điểm và $l_i = b_i - a_i$ là độ dài của khoảng $[a_i, b_i]$.

Ví dụ 1.1 (So sánh các loại khoảng cách hàm mật độ). Xét hai hàm mật độ xác suất đều $f_1(x)$ và $f_2(x)$. Hình 1.4 mô tả bốn tình huống khoảng cách giữa hai hàm mật độ này.



Chú thích: Bốn trường hợp mật độ đều với (a) hai hàm rời nhau, cùng chiều rộng; (b) hai hàm rời nhau, khác chiều rộng; (c) hai hàm rời nhau, cách xa nhau; và (d) hai hàm chồng lấp. Ở đây, ô vuông trắng $\square$ biểu thị hàm mật độ $f_1(x)$ và ô vuông xám $\blacksquare$ biểu thị hàm mật độ $f_2(x)$. Nguồn: Minh họa của tác giả.

Hình 1.4. Các trường hợp trong khoảng cách giữa hai hàm mật độ đều $f_1(x)$ và $f_2(x)$.

Ta có Bảng 1.3 tổng hợp kết quả các phép đo này trong bốn tình huống.

Bảng 1.3. Các kết quả khoảng cách giữa hai hàm mật độ đều

Nhóm	$D(f_1; f_2)$	Trường hợp			
		(a)	(b)	(c)	(d)
$\mathcal{L}_p$	$\mathcal{L}_1$	2,00	2,00	2,00	1,00
	$\mathcal{L}_2$	1,41	1,22	1,41	0,71
	D_O (Overlap)	1,00	1,00	1,00	0,50
	CWD	1,00	1,00	1,00	0,50
f -phân kỳ	D_B (Bhattacharyya)	∞	∞	∞	0,69
	D_H (Hellinger)	1,00	1,00	1,00	0,71
	D_M (Matusita)	1,41	1,41	1,41	1,00
	D_{KL} (Kullback–Leibler)	27,63	27,28	27,63	13,47
	D_{JS} (Jensen–Shannon)	27,63	26,94	27,63	13,47
Optimal	D_W (2-Wasserstein)	3,00	3,5	6,00	1,00

Trước hết, các khoảng cách $\mathcal{L}_1$ và $\mathcal{L}_2$ trong các trường hợp (a), (b), và (c), mặc dù $f_1(x)$ và $f_2(x)$ nằm xa dần, nhưng các giá trị $\mathcal{L}_1$ và $\mathcal{L}_2$ hầu như không đổi (đều bằng 2 hoặc $\sqrt{2}$). Khoảng cách này nhận biết được khác biệt hình dáng và phân bố, nhưng không nhận biết tốt yếu tố vị trí trong không gian. Hệ số Bhattacharyya và khoảng cách Hellinger chỉ có ý nghĩa trong trường hợp (d), khi có phần chồng lấp giữa $f_1(x)$ và $f_2(x)$. Điều này cho thấy chúng nhạy với mức độ chồng lấp, nhưng không phân biệt được hai hàm độc lập nhau.

Ngược lại, khoảng cách Wasserstein nhạy cảm với vị trí hình học, hình dáng và phân bố. Khi so (a) và (c), ta thấy khoảng cách này tăng rất lớn cho thấy hiệu quả so sánh vị trí. Xét (a) và (b), khi thay đổi hình dáng hàm mật độ, khoảng cách này cũng có sự khác biệt. Đáng chú ý, khoảng cách $\mathcal{L}_2$ và D_W là trái ngược nhau. Khi thay đổi hình dáng đồ thị, khoảng cách $\mathcal{L}_2$ giảm nhưng D_W lại tăng lên. Cuối cùng, trường hợp (d) cho thấy khoảng cách cũng có ý nghĩa khi chồng lấp.

Định nghĩa 1.21 (Affinity). Hàm $\rho : f \rightarrow [0; 1]$ được gọi là affinity của hai hàm mật độ $f_1(x)$ và $f_2(x)$ nếu nó thỏa mãn ba điều kiện

1. $0 \leq \rho(f_1; f_2) \leq 1$,
2. $\rho(f_1; f_2) = 1$ nếu và chỉ nếu $f_1 \equiv f_2$, và
3. mỗi dãy hàm $\{f_n\}$ thì $\rho(f_n; f_0) \rightarrow 1$

Nhận xét. Affinity đo lường sự giống nhau giữa hai hàm mật độ theo vị trí. Vì vậy, ta có tương quan giữa Affinity và Khoảng cách giữa hai hàm mật độ xác suất $f_1(x)$ và $f_2(x)$ là $D(f_1; f_2) = 1 - \rho(f_1; f_2)$.

Ví dụ 1.2. Affinity cơ bản cho tương tự hai hàm mật độ $f_1(x)$ và $f_2(x)$ là Affinity Bhattacharyya với $\rho_B(f_1, f_2) = \int_{\Omega} \sqrt{f_1(x)f_2(x)} dx$.

Định nghĩa 1.22 (Hàm hạt nhân của khoảng cách). Hàm $K : \mathcal{F} \times \mathcal{F} \rightarrow [0; 1]$ với tập $\mathcal{F}$ được gọi là hạt nhân (hạch) giữa hai hàm mật độ $f_1(x), f_2(x)$ nếu nó thỏa mãn

1. $0 \leq K(f_1, f_2) \leq 1$,
2. $K(f_1, f_2) = K(f_2, f_1); \forall f_1, f_2 \in \mathcal{F}$,
3. với mọi tập hữu hạn $\{f_1; \dots; f_n\} \subset \mathcal{F}$ và các hệ số $\alpha_1; \dots; \alpha_n \in \mathbb{R}$, hàm hạt nhân là xác định dương, tức là $\sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j K(f_i, f_j) \geq 0$.

Ví dụ 1.3. Ba hạt nhân cơ bản cho khoảng cách hai hàm mật độ $f_1(x)$ và $f_2(x)$ là

1. Hạt nhân chuẩn, $K_G(f_1, f_2) = \exp(-\frac{\mathcal{L}_p^2(f_1, f_2)}{\beta \sigma^2}); \beta \in \mathbb{R}_{>0}$,
2. Hạt nhân tuyến tính, $K_L(f_1, f_2) = \int_{\Omega} f_1(x) f_2(x) dx$,
3. Hạt nhân Bhattacharyya, $K_B(f_1, f_2) = \int_{\Omega} \sqrt{f_1(x) f_2(x)} dx$,
4. Hạt nhân χ^2 , $K_{\chi^2}(f_1, f_2) = \int_{\Omega} \frac{2f_1(x)f_2(x)}{f_1(x)+f_2(x)} dx$.

Hàm hạt nhân $K(\cdot; \cdot)$ càng gần 1 thì hai hàm mật độ càng giống nhau và ngược lại. Ở đây, việc chuyển đổi từ hàm hạt nhân đến khoảng cách được cho bởi $D = 1 - K_G$ khi các hạt nhân chuẩn hóa $[0; 1]$, hoặc $D = 2(1 - K_H)$ khi là hạt nhân Bhattacharyya.

Định nghĩa 1.23 (Ma trận khoảng cách từng đôi). Cho tập n hàm mật độ $\{f_1, f_2, \dots, f_n\}$, ma trận khoảng cách $D \in \mathbb{R}^{n \times n}$ là một ma trận đối xứng và có $\text{Trace}(D) = 0$, được định nghĩa bởi $D_{ij} = D(f_i, f_j)$, với mọi $i, j = 1, \dots, n$.

1.5.2 Sự tương tự của nhiều hơn hai hàm mật độ xác suất

a. Liên kết chùm hàm mật độ

Giả sử hai chùm hàm mật độ không rỗng $\mathcal{F}$ và $\mathcal{G}$ chứa hữu hạn phần tử và $D(f; g)$ là khoảng cách giữa hai hàm mật độ, $f \in \mathcal{F}$ và $g \in \mathcal{G}$. Khoảng cách giữa hai chùm hàm mật độ gọi là *liên kết*, là một ánh xạ $\delta : \mathcal{P}(X) \times \mathcal{P}(X) \times \mathcal{M}(X) \rightarrow \mathbb{R}_+$, trong đó, $\mathcal{P}(X)$ là tập lũy thừa của X .

Bảng 1.4. Bảng tổng kết các loại liên kết Δ giữa hai chùm hàm mật độ xác suất

Liên kết	Ký hiệu	Δ
Liên kết đơn ¹ (SLINK)[29]	$\Delta_{\min}$	$\min_{f \in \mathcal{F}, g \in \mathcal{G}} D(f; g)$
Liên kết đủ ² (CLINK)[30]	$\Delta_{\max}$	$\max_{f \in \mathcal{F}, g \in \mathcal{G}} D(f; g)$
Liên kết tâm (UPGMC)	Δ_{centroid}	$D(\theta_{\mathcal{F}}; \theta_{\mathcal{G}})$
Liên kết trung bình (UPGMA)	Δ_{avg}	$\frac{1}{\#\mathcal{F}\#\mathcal{G}} \sum_{f \in \mathcal{F}, g \in \mathcal{G}} D(f; g)$
Liên kết Ward [31]	Δ_{Ward}	$\frac{\#\mathcal{F}\#\mathcal{G}}{\#\mathcal{F} + \#\mathcal{G}} D^2(\theta_{\mathcal{F}}, \theta_{\mathcal{G}})$

Chú thích: ¹: tổng khoảng cách nhỏ nhất; ²: tổng khoảng cách lớn nhất. Nguồn: Tác giả tổng hợp

Khi hai ta cần tính khoảng cách từ hợp hai chùm hàm $\mathcal{F} \cup \mathcal{G}$ đến một chùm hàm $\mathcal{H}$, ta cũng có

thể sử dụng các loại liên kết trên. Trong thực tế, các liên kết Δ được biến đổi thành

$$\begin{aligned}\Delta_{\min}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) &= \min \{D_{f \in \mathcal{F}, h \in \mathcal{H}}(f, h), D_{f \in \mathcal{G}, h \in \mathcal{H}}(g, h)\}, \\ \Delta_{\max}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) &= \max \{D_{f \in \mathcal{F}, h \in \mathcal{H}}(f, h), D_{f \in \mathcal{G}, h \in \mathcal{H}}(g, h)\}, \\ \Delta_{\text{avg}}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) &= \frac{1}{\#(\mathcal{F} \cup \mathcal{G}) \cdot \#\mathcal{H}} \sum_{\substack{f \in \mathcal{F} \cup \mathcal{G} \\ h \in \mathcal{H}}} D(f, h), \\ \Delta_{\text{centroid}}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) &= D(\theta_{\mathcal{F} \cup \mathcal{G}}, \theta_{\mathcal{H}}), \\ \Delta_{\text{Ward}}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) &= \frac{\#(\mathcal{F} \cup \mathcal{G}) \cdot \#\mathcal{H}}{(\#\mathcal{F} \cup \#\mathcal{G}) \cup \#\mathcal{H}} D^2(\theta_{\mathcal{F} \cup \mathcal{G}}, \theta_{\mathcal{H}}).\end{aligned}$$

Ví dụ 3.3 cung cấp hướng dẫn tính toán các liên kết Δ được trình bày ở Phụ lục B, tr. 66.

b. Tương tự chùm hàm mật độ

Giả sử tập hợp $\mathcal{F}$ có nhiều hơn hai phần tử ($n > 2$)

Bảng 1.5. Tổng kết các tương tự giữa các chùm hàm mật độ xác suất

Tương tự	$\Delta(\mathcal{F})$
Affinity của Matusita [32]	$\int_{\Omega} \left(\prod_{j=1}^n f_j(x) \right)^{1/n} dx$
Affinity của Toussaint [33]	$\int_{\Omega} \left(\prod_{j=1}^n f_j(x) \right)^{\alpha_j} dx$
Độ rộng chùm [16]	$\int_{\Omega} f_{\max}(x) dx - 1$
Hệ số tương tự chùm [34]	$\frac{k}{k-1} \left(1 - \frac{1}{k} \int_{\Omega} f_{\max}(x) dx \right)$

Nguồn: Tác giả tổng hợp

Nhận xét. Trong Bảng 1.5 Affinity Toussaint suy biến thành Affinity Matusita khi $\alpha_1 = \alpha_2 = \dots = \alpha_n = \frac{1}{n}$. Khi Affinity của Matusita có $n = 2$ thì nó trở thành hệ số Bhattacharyya. Cuối cùng, hệ số tương tự chùm chuẩn hóa tuyến tính độ rộng chùm.

1.6 Phương pháp số xấp xỉ tích phân

Các tích phân trong lĩnh vực hàm mật độ cần xấp xỉ bằng phương pháp số. Luận văn này, chọn sử dụng phương pháp hình thang nhằm cải thiện độ chính xác so với tổng Riemann nhưng cũng không tốn quá nhiều tài nguyên như Monte Carlo hay Simpsons. Một tích phân trên miền $\Omega \subset \mathbb{R}^d$ được xấp xỉ bằng công thức tổng quát $\int_{\Omega} f(x) dx = \lim_{h \rightarrow 0} \sum_i h^d w_i f(x_i)$. Khi này, giả sử hàm $f : [a; b] \rightarrow \mathbb{R}$, chia đoạn $[a; b]$ thành n , phương pháp hình thang một chiều xấp xỉ tích phân

$$\int_a^b f(x) dx \approx \frac{h}{2} \left(f(x_0) + 2 \sum_{i=1}^{n-1} f(x_i) + f(x_n) \right),$$

trong đó $x_i = a + ih, i = 0, \dots, n$.

1.7 Phân tích chùm cho hàm mật độ xác suất

1.7.1 Phân tích chùm không mờ

Phân tích chùm không mờ (hay phân chùm cứng) yêu cầu một phần tử chỉ thuộc duy nhất một chùm cố định. Tiểu mục này trình bày hai khía cạnh chính của phân tích chùm bao gồm phân tích chùm phân vùng (dựa trên trọng tâm) và phân cấp thứ bậc.

a. Phân tích chùm k -means (KCF)

Phân tích chùm phân vùng giả sử $\mathcal{S}$ là tập các véc-tơ d -chiều x_j , trong đó $j = 1; 2; \dots; n$. Mỗi đối tượng o_j liên hệ với hàm mật độ xác suất $f_j(x)$. Tập $\mathcal{F}$ gồm họ n -hàm mật độ trên Ω . Bài toán phân tích chùm phân bổ j -hàm mật độ vào c -chùm nguyên, với $i = 1; 2; \dots; c$ thỏa mãn ba ràng buộc

1. Hợp tất cả các chùm $\bigcup_i c_i$ bằng $\mathcal{F}$,
2. Giao của mỗi chùm là rỗng, $c_i \cap c_j = \emptyset$, với mỗi $i \neq j$,
3. Lực lượng của mỗi chùm là khác rỗng, $|c_i| \neq \emptyset$.

Phép gán này được mô tả bằng một ánh xạ nhiều-đến-một, hay còn gọi là bộ mã hóa $c_i = c(f_j)$, trong đó đối tượng f_j gán vào chùm c_i là duy nhất. Cụ thể, ràng buộc 1 đảm bảo tất cả các đối tượng phải được phân tách thành các chùm, trong đó, mỗi chùm phải chứa ít nhất một phần tử (ràng buộc 3) và không có đối tượng nào được xếp vào cùng một chùm (ràng buộc 2).

Phân tích chùm KCF là bài toán tối thiểu đơn mục tiêu cho tổng các bình phương khoảng cách trong chùm các hàm mật độ [8, 12, 16], tức là

$$\text{Minimise : } J(U; \Theta | \mathcal{F}; c) = \sum_{i=1}^c \sum_{f_j(x) \in c_i} \mu_{ij} D^2(\theta_i; f_j), \quad (\text{KCF})$$

trong đó, hàm $\theta_i(x)$ là hàm mật độ trọng tâm của chùm thứ c_i . Ký hiệu $D^2(\theta_i; f_j)$ là khoảng cách giữa hàm mật độ trọng tâm $\theta(x)$ đến các đối tượng $f_j(x)$ còn lại trong dữ liệu. Ta cũng có μ_{ij} là biến tiềm ẩn thể hiện mức độ thành viên của hàm mật độ $f_j(x)$ thỏa $\mu_{ij} = \mathbf{1}_{\{j \in c_i\}}$. Tức là $\mu_{ij} = 1$ nếu hàm j thuộc chùm c_k và $\mu_{ij} = 0$ nếu ngược lại.

Chứng minh. Điều kiện $\sum_i \mu_{ij} = 1$ đảm bảo rằng mỗi hàm f_j được gán vào đúng một chùm duy nhất. Tập tất cả các ma trận U là hữu hạn, và việc cố định U biến hàm mục tiêu KCF trở thành hàm tuyến tính theo U . Đặc biệt, với θ_i cố định, giá trị J được tối thiểu khi gán f_j vào chùm c_i sao cho $D^2(f_j, \theta_i)$ nhỏ nhất, tức là $\mu_{ij} = \mathbf{1}_{\{i = \arg \min_{\ell} D^2(f_j, \theta_{\ell})\}}$. ■

Bổ đề 1.6 (Thành lập hàm mật độ đại diện). Giả sử $\mathcal{F}$ -hàm mật độ được phân thành c -chùm qua các mức độ thành viên μ_{ij} , với bình phương khoảng cách $D^2(\theta_i, f_j)$. Khi đó, hàm mật độ đại diện $\theta_i^*(x)$ tối ưu trên mỗi chùm c_i được cho bởi công thức

$$\theta_i^*(x) = \frac{\sum_{f_j \in c_i} \mu_{ij} f_j(x)}{\sum_{f_j \in c_i} \mu_{ij}}.$$

Chứng minh. Từ hàm mục tiêu KCF, ta tính các đạo hàm riêng theo c_i . Đối thứ tự tổng và tích phân ta được

$$J(\mathcal{F}, c) = \int_{\Omega} \sum_{i=1}^c \sum_{j=1}^n \mu_{ij} (\theta_i(x) - f_j(x))^2 dx.$$

Lấy đạo hàm của J theo $\theta_i(x)$ ta có $\frac{\partial}{\partial \theta_i(x)} J = 2 \sum_{j=1}^n \mu_{ij} (\theta_i(x) - f_j(x))$. Cho đạo hàm bằng 0 ta suy ra được điều phải chứng minh. Tóm lại, mật độ đại diện tối ưu để cực tiểu hàm mục tiêu là hàm mật độ trọng tâm (1.1) các hàm mật độ trong các chùm. ■

Nhận xét. Vì mỗi hàm mật độ trọng tâm (1.1) được đại diện trừu tượng bằng trung bình có trọng số của từng chùm, nên kết quả trọng tâm này có thể không đồng nhất với bất kỳ đối tượng nào trong mẫu. Thay vào đó, mật độ trọng tâm này nằm bất kỳ trong không gian, đóng vai trò như một đối tượng tham chiếu để các hàm mật độ khác so sánh [35].

Một hàm mật độ mới h được gán vào chùm c_k nếu $k = \arg \min_i D^2(h, \theta_i)$. Hơn nữa, vì ma trận phân vùng $\mu_{ij} = 1_{\{j \in c_i\}}$ nên ta có thể rút gọn hàm mật độ đại diện (1.1) thành trung bình Fréchet với $\mathcal{L}_2$


$$\theta_i(x) = \frac{1}{\#c_i} \sum_{f_j(x) \in c_i} f_j(x). \quad (1.2)$$

Bổ đề 1.7 (Sự hội tụ của thuật toán KCF). Sau mỗi bước lặp của thuật toán KCF, hàm mục tiêu $J^{(t)}$ luôn giảm tại hữu hạn bước lặp t .

Chứng minh. Gọi $\mathcal{Z}^{(t)} = \{c_1^{(t)}, \dots, c_k^{(t)}\}$ là phân hoạch tại bước t , với hàm trọng tâm $\theta_i^{(t)}(x)$ và hàm mục tiêu $J^{(t)}$. Khi trọng tâm $\theta_i^{(t)}$ cố định, mỗi hàm f được gán vào chùm gần nhất. Khi đó, $\sum_{i=1}^k \sum_{f \in c_i^{(t+1)}} D^2(f, \theta_i^{(t)}) \leq J^{(t)}$, (1). Còn khi chùm $c_i^{(t+1)}$ cố định, hàm trọng tâm $\theta_i^{(t+1)}$ được cập nhật sao cho $\sum_{f \in c_i^{(t+1)}} D^2(f, \theta_i^{(t+1)}) \leq \sum_{f \in c_i^{(t+1)}} D^2(f, \theta_i^{(t)})$, (2). Cộng (1) và (2) ta được giá trị $J^{(t+1)} = \sum_{i=1}^k \sum_{f \in c_i^{(t+1)}} D^2(f, \theta_i^{(t+1)}) \leq J^{(t)}$. Hơn nữa, ta có chặn dưới $J^{(t)} - J^{(t+1)} \geq \sum_{i=1}^k |c_i^{(t+1)}| \cdot D^2(\theta_i^{(t)}, \theta_i^{(t+1)})$. Suy ra, thuật toán hội tụ đơn điệu và dừng sau hữu hạn bước do số phân hoạch hữu hạn. ■

Ví dụ 1.4 (Phân tích chùm cứng hàm Gauss 1-chiều). Cho bảy hàm mật độ chuẩn một chiều $\mathcal{F}$ cho bởi Vo-Van, Tai and Pham-Gia, T., [16] có phương sai đồng nhất $\sigma_i^2 = 1; i = 1; \dots; 7$ và các trung bình lần lượt là $\mu_i = \{0, 3; 4, 0; 9, 1; 1, 0; 5, 5; 8, 0; 4, 8\}$. Phân tích chùm KCF với $c = 3$ và khoảng cách xét là $\mathcal{L}_2$.

Ta có kết quả sau khi thực hiện các vòng lặp được giải chi tiết ở Phụ lục (tr. 66). Hình 1.5(a) cho thấy kết quả trọng tâm của ba chùm đối với khoảng cách $\mathcal{L}_2$. Các khoảng cách khác cũng được khảo sát, tuy nhiên kết quả đều giống nhau cho trọng tâm.



Hình 1.5. Kết quả phân cụm KCF đối với Ví dụ 1.4

(a) Trọng tâm, và (b) ma trận phân vùng cứng của KCF. Nguồn: Minh họa của tác giả.

b. Phân tích cụm thứ bậc (HCF)


Phân cấp thứ bậc giả định tập $\mathcal{F}^{(t=0)} = \{\{f_1\}; \{f_2\}; \dots; \{f_n\}\}$ trong [36] không yêu cầu tiên nghiệm số cụm c , mà xây dựng một cây phân cấp bằng cách hợp nhất lần lượt các cụm gần nhất theo một liên kết cho trước. Tại mỗi bước $t = 1; 2; \dots; n-1$, ta chọn hai cụm $c_i; c_j \in \mathcal{F}^{(t-1)}$ sao cho vị trí $(c_i; c_j) = \arg \min_{c_u; c_v \in \mathcal{F}^{(t-1)}} \Delta(c_u; c_v)$, trong đó, $\Delta(c_u; c_v)$ là liên kết giữa hai cụm hàm mật độ. Thuật toán 2 (Phụ lục C, tr. 63) mô tả rõ quy trình thực hiện của phương pháp phân cấp này.

Định lý 1.11 (Hội tụ của thuật toán HCF). *Giải thuật HCF luôn hội tụ sau $n-1$ bước hợp nhất và tạo thành một cây nhị phân có n nút lá và $n-1$ nút trong.*

Chứng minh. Mỗi lần hợp nhất, một cặp c_i, c_j được thay thế bằng cụm $c_i \cup c_j$, và giữ nguyên các cụm còn lại. Ta có $\forall c \in C_t, \exists c' \in C_{t+1}$ sao cho $c \subseteq c'$, tức là C_{t+1} phân rã nhỏ hơn C_t . ■

Ví dụ 1.5 (Phân cấp thứ bậc hàm Gauss 1-chiều). Ta sử dụng lại dãy hàm mật độ trong Ví dụ 1.4. Phân cấp thứ bậc với khoảng cách $D(f_1; f_2) = \mathcal{L}_2$ và liên kết $\Delta_{\max}(\mathcal{F}_1; \mathcal{F}_2)$ là liên kết đủ.

Ta có kết quả phân cấp thứ bậc tích tụ bởi Hình 1.6 và bài giải chi tiết được phân tích trong Phụ lục B (tr. 66). Quá trình phân cấp được thực hiện với hai phương pháp liên kết đủ liên kết Ward. Nhìn Hình 1.6, ta thấy phương pháp liên kết đủ có xu hướng tạo ra các cụm nhỏ, chặt chẽ, và nhạy cảm với nhiễu ở biên. Ngược lại, liên kết Ward cho kết quả các cụm có tính đồng nhất cao hơn về phân bố, làm cây phân cấp cân đối.



Hình 1.6. Kết quả phân cấp thứ bậc tích tụ HCF đối với Ví dụ 1.5

Chú thích: Cây phân cấp ở phía trên thể hiện cách sắp xếp và nhóm các hàm mật độ dựa trên liên kết, phần dưới thể hiện ma trận khoảng cách tương ứng với từng hàm mật độ đó. Nguồn: Minh họa của tác giả

1.7.2 Phân tích chùm mờ (FCF)

Phân tích chùm mờ được xây dựng lần đầu tiên cho hàm mật độ bởi Thao Nguyen-Trang and Tai Vo-Van [21] với sự phát triển từ phần tử rời rạc do [37]. Khác biệt giữa nó với phân chùm cứng là sự chấp nhận thuộc nhiều chùm của một phần tử với một *mức độ phân vùng* mềm hơn. Điều này hữu ích khi ranh giới giữa các hàm là không chắc chắn.

Giả sử $\mathcal{F}$ chưa được gán nhãn, mục tiêu của bài toán là tối thiểu hóa tổng trọng số các giá trị hàm thành viên với siêu tham số m và khoảng cách.

$$\text{Minimise : } J(U; \Theta | \mathcal{F}; c; m) = \sum_{i=1}^c \sum_{j=1}^n \mu_{ij}^m D^2(\theta_i; f_j), \quad (\text{FCF})$$

$$\text{s.t : } \sum_{i=1}^c \mu_{ij} = 1, \quad \forall j \in 1, \dots, n, \quad (\text{C1})$$

$$\mu_{ij} \in [0; 1], \quad \forall i \in 1, \dots, c, \forall j \in 1, \dots, n, \quad (\text{C2})$$

$$\sum_{j=1}^n \mu_{ij} > 0, \quad \forall i \in 1, \dots, c. \quad (\text{C3})$$

Thuật toán phân tích chùm mờ cho phần tử rời rạc đã được chứng minh là tối ưu toàn cục bởi [38–40] qua định lý Zangwill [41]. Đặc biệt, [42] mới đây chứng minh sự hội tụ toàn cục qua thuật toán độ dốc. Do đó, luận văn này chỉ giới thiệu Định lý 1.12 trình bày sự thành lập của ma trận phân vùng và hàm mật độ đại diện từ hàm mục tiêu J cho dữ liệu hàm mật độ xác suất.

Định lý 1.12. Cho $\mathcal{F}$ chứa $n > c$ hàm mật độ xác suất và $m > 1$. Xét $D_{ij} = D(\theta_i; f_j)$ với $1 \leq j \leq n; 1 \leq i \leq c$. Với mỗi j , xác định các tập $I_j = \{i | D_{ij} = 0, 1 \leq i \leq c\}$ và tập $I_j^c = \{1; \dots; c\} \setminus I_j$. Khi đó

J có thể đạt cực tiểu toàn cục khi và chỉ khi


$$\theta_i^*(x) = \frac{\sum_{j=1}^n (\mu_{ij}^*)^m f_j(x)}{\sum_{j=1}^n (\mu_{ij}^*)^m}; \text{ và} \quad (1.3)$$

$$\mu_{ij}^* = \frac{(D_{ij}^*)^{-1/(m-1)}}{\sum_{l=1}^n (D_{lj}^*)^{-1/(m-1)}}; \text{ nếu } I_j \neq \emptyset; \text{ và}, \quad (1.4)$$

$$\mu_{ij}^* = 0; \forall i \in I_j^c \text{ và } \sum_{i \in I_j^c} \mu_{ij}^* = 1; \text{ nếu } I_j \neq \emptyset, \quad (1.5)$$

Nhận xét. Ở đây, tham số m thể hiện mức độ mờ của ma trận phân vùng μ_{ij} . Khi $m \rightarrow 1$, ma trận phân vùng kết quả sẽ tiến về ma trận phân vùng không mờ ($\mu_{ij} = 1_{\{j \in c_i\}}$). Khi $m \rightarrow \infty$, các giá trị μ_{ij} sẽ trở nên bằng nhau ($= 1/c$) làm mất khả năng gán các hàm mật độ xác suất vào các chùm.

Để minh họa ảnh hưởng của tham số m , ta giả định hai chùm với $D_{2j} = 2 - D_{1j}$, và xét giá trị μ_{1j} theo khoảng cách này chạy từ 0 đến 2. Hình 1.7 trực quan hóa cách m điều chỉnh mức độ. Khi $m \rightarrow 1$, đường phân vùng trở nên gãy; khi m tăng, đường cong trở nên phẳng và đều ở $y = 1/2$. Nhiều nghiên cứu tổng quát hóa tham số m đã được đặt ra sau khi thuật toán này công bố. Tuy nhiên, cho đến nay các nhà phân tích vẫn chọn tiêu biểu $m = 2$ vì tính dễ giải thích [7, 39].



Hình 1.7. Biểu đồ phân vùng mờ theo khoảng cách D_{1j} với các hệ số m khác nhau.

Chú thích: Giá trị μ_{1j} tại trục tung biểu diễn mức độ phân vùng tại chùm 1 theo khoảng cách $D_{1j} = \mathcal{L}_1(f_1; f_j)$ với các giá trị $m = 1,1; 1,5; 2,0; 3,0; 5,0; 10,0$. Nguồn: Minh họa của tác giả.

Thuật toán phân chùm mờ FCF được thực hiện qua hai bước cập nhật trọng tâm và cập nhật ma trận phân vùng [7, 21] (Thuật toán 4). Kết thúc thuật toán ta nhận được ma trận phân vùng U_f và các trọng tâm chùm Θ . Trong đó, tiêu chuẩn dừng cho FCF là chênh lệch tuyệt đối tối đa giữa các phần tử của ma trận phân vùng $\mu^{(t)}$ và $\mu^{(t-1)}$ liên tiếp phải thấp hơn ngưỡng dương ε cho trước. Cuối cùng, ta có thể giải mờ theo quy tắc $c_i = \arg \max_i \mu_{ij}$. Tức là một hàm mật độ $f_j(x)$ được xếp vào chùm c_i khi và chỉ khi nó có mức độ phân vùng tại chùm đó là cao nhất.

Ví dụ 1.6 (Phân chùm mờ hàm Gauss 1-chiều). Ta sử dụng lại dãy hàm mật độ trong Ví dụ 1.4. Phân tích $\mathcal{F}$ thành ba chùm, biết $m = 2$, tiêu chuẩn dừng $\varepsilon = 10^{-3}$, và khoảng cách là $\mathcal{L}_2$. Ta có kết quả sau khi thực hiện các vòng lặp được giải chi tiết ở Phụ lục (tr. 66).

Nhận xét. Dựa vào mức độ phân vùng μ_{ij} , ta nhận thấy được mức độ tin cậy một hàm mật độ $f_j(x)$ xếp vào chùm c_i . Nếu phân vùng μ_{ij} tại chùm c_i này lớn, ta có thể chắc chắn vào kết quả phân bổ,

ngược lại, nếu giá trị này không cao, ta biết được hàm mật độ này có khả năng thuộc vào một chùm khác hoặc một chùm mới thay vì thuộc vào chùm c_i .

So sánh về mặt phức tạp thời gian và phức tạp dung lượng, Bảng 1.6 cho thấy phương pháp k -mean đơn giản hơn và ít tốn tài nguyên tính toán hơn so với Fuzzy c -mean và thuật toán thứ bậc.

Bảng 1.6. So sánh độ phức tạp của ba thuật toán phân chùm

Thuật toán	Phức tạp thời gian	Phức tạp không gian
Phân chùm KCF	$\mathcal{O}(ncdi)$	$\mathcal{O}(n + cd)$
Phân cấp HCF	$\mathcal{O}(n^2 \log n)$	$\mathcal{O}(n^2)$
Phân chùm FCF	$\mathcal{O}(ncdi)$	$\mathcal{O}(nc)$

Chú thích: n là # đối tượng trong dữ liệu, c là # chùm, d là # chiều dữ liệu, i là # vòng lặp.

1.8 Phân loại cho hàm mật độ xác suất

Ở dữ liệu rời rạc, bốn thuật toán phân loại kinh điển dựa vào thống kê là Naive Bayes, Cây quyết định, hồi quy Logistics, phân biệt Fisher [43] và Perceptron [44] đã được áp dụng phát triển cho đến hiện nay. Trong khi đó, các phát triển phân loại hàm mật độ chỉ dựa trên phương pháp Bayes. Luận văn này tập trung nghiên cứu phương pháp hồi quy logistics, máy véc-tơ hỗ trợ, và đặc biệt là phương pháp Bayes cho dữ liệu hàm mật độ [45, 46].

1.8.1 Hồi quy logistics

Phương pháp này được tổng quát hóa cho dữ liệu hàm bởi các nghiên cứu của Akturk et al. [47]. Luận văn này cụ thể hóa cho hàm mật độ xác suất. Mô hình hồi quy logistic cho dữ liệu hàm mật độ có dạng

$$\pi_j = \mathbb{P}(Y_j = 1 | f(x) = f_j(x)) = \frac{\exp\{\beta_0 + \int_{\Omega} f(x)\beta(x) dx\}}{1 + \exp\{\beta_0 + \int_{\Omega} f(x)\beta(x) dx\}}, \quad (1.6)$$

trong đó $\beta_0 \in \mathbb{R}$ là hằng số chặn, và $\beta(x) \in \mathcal{L}_2[\Omega]$ là hàm hệ số cần ước lượng. Để giải phương trình (1.6), biến đổi logit được sử dụng

$$\ell_j = \log\left(\frac{\pi_j}{1 - \pi_j}\right) = \beta_0 + \int_{\Omega} f(x)\beta(x) dx.$$

Mục tiêu tiếp theo là ước lượng β_0 và hàm $\beta(x)$. Do $\beta(x)$ là vô hạn chiều, ta chiếu hàm này vào một tập hàm cơ sở chọn trước để ước lượng, cụ thể là hàm Gauss, wavelet, chuỗi Fourier, đa thức Bernstein và Legendre, hoặc B-spline (Xem thêm Bảng 3.3 tại Phụ lục C, tr. 63). Khi đó,

$$\ell_j = \beta_0 + \sum_{m=1}^M \theta_m \underbrace{\int_{\Omega} \psi_m(x) f_i(x) dx}_{=: \Phi = \phi_{j,m}},$$

trong đó $\phi_{j,m}$ là mô-men của hàm mật độ $f_j(x)$ trên hàm cơ sở $\psi_m(x)$.

Bài toán ước lượng $\beta(x)$ chuyển thành cực đại hóa log-likelihood của hồi quy logistics

$$\ell(\beta_0; \beta(x)) = \max_{\substack{\beta_0 \in \mathbb{R}, \\ \beta(x) \in \mathbb{R}^M}} \left\{ \underbrace{\sum_{j=1}^n [y_j \log \pi_j + (1 - y_j) \log(1 - \pi_j)]}_{\text{Logistics}} - \underbrace{\lambda_1 \sum_{m=1}^M |\beta_m(x)|}_{\text{Lasso}} - \underbrace{\frac{\lambda_2}{2} \sum_{m=1}^M \beta_m(x)^2}_{\text{Ridge}} \right\},$$


trong đó, $\pi_j = \mathbb{P}(Y_j = 1 | f(x))$ và ℓ là hàm mất mát.

Định lý 1.13. Hàm mất mát ℓ là một hàm lồi theo cả β_0 và $\beta(x)$. Nếu $\lambda_2 > 0$ thì hàm này lồi nghiêm ngặt. Vì vậy, nghiệm tối ưu toàn cục luôn tồn tại duy nhất.

Từ Định lý 1.13, ta tính được Gradient theo hệ số $\beta(x)$ với $\hat{y}_j = \pi_j$ là xác suất dự đoán, có dạng $\nabla_{\beta} \ell = \Phi^T(y - \hat{y}) - \lambda_1 \text{sign}(\beta(x)) - \lambda_2 \beta$, mà qua đó ta có nhiều phương pháp tối ưu như tối ưu độ dốc như ADAM, hay các quasi-Newton khác như L-BFG-S.

Ví dụ 1.7 (Phân loại hàm mật độ bằng hồi quy logistic). Xét hai lớp hàm mật độ Gauss $\mathcal{F}$ và $\mathcal{G}$ với các trung tâm lần lượt là $\mu_{\mathcal{F}} = \{1, 0; 1, 5; 2, 0; 2, 5; 6, 0\}$, và $\mu_{\mathcal{G}} = \{4, 5; 7, 5; 8, 5; 8, 0; 9, 0\}$, trong đó phương sai lần lượt là $\sigma_{\mathcal{F}}^2 = 0,4$ và $\sigma_{\mathcal{G}}^2 = 0,9$. Bài toán đặt ra là phân loại một hàm mật độ Gauss mới $h(x) = \mathcal{N}(3, 0; 0, 9)$ vào một trong hai lớp $\mathcal{F}$ hoặc $\mathcal{G}$.

Sử dụng $M = 10$ hàm cơ sở Gauss, ta ước lượng được hàm hệ số $\hat{\beta}(x)$, phản ánh đóng góp của từng miền x đối với phân loại. Hàm $\hat{\beta}(x)$ được tái tạo và minh họa ở Hình 1.8.



Hình 1.8. Hàm $\hat{\beta}(x)$ được ước lượng qua 10 hàm cơ sở Gauss.

Tiếp theo, để phân loại h , ta cũng chiếu lên không gian cơ sở. Hàm h được chiếu lên 10 hàm cơ

sử Gauss để tạo thành véc-tơ đặc trưng được đưa vào mô hình logistic đã huấn luyện. Cuối cùng, mô hình logistic dự đoán xác suất h thuộc lớp $\mathcal{F}$ là 43,26%. Do đó, ta phân loại $h(x)$ vào lớp $\mathcal{F}$.

Nhận xét. Hàm hệ số $\widehat{\beta}(x)$ đóng vai trò như một công cụ giải thích quan trọng, cho phép đánh giá mức độ đóng góp của từng miền $x \in \Omega$ đối với quá trình phân loại nhị phân. Đáng chú ý, $\widehat{\beta}(x)$ cung cấp một dạng giải thích bằng tính năng, giúp ta hiểu thêm nguồn gốc của từng đóng góp riêng lẻ đến xác suất phân loại.

Hình 1.8 cho thấy $\widehat{\beta}(x)$ dao động quanh trục 0 với cả miền dương và âm, phản ánh rằng các vùng khác nhau của x có ảnh hưởng trái ngược đến xác suất dự đoán. Những vùng mà $\widehat{\beta}(x) > 0$ sẽ tăng xác suất dự đoán lớp 1, và ngược lại. Cụ thể, các hệ số ψ_5 và ψ_8 có giá trị dương thể hiện tác động tăng xác suất dự đoán, trong khi ψ_3 và ψ_6 mang giá trị âm, góp phần làm giảm xác suất của lớp $\mathcal{F}$. Việc áp dụng các kỹ thuật chuẩn hoá Ridge làm giảm hệ số một cách đồng đều, còn Lasso tạo ra sự chọn lọc hàm cơ sở ψ_m quan trọng.

1.8.2 Máy véc-tơ hỗ trợ

Cho tập huấn luyện $\mathcal{D} = \{(f_j, y_j)\}_{j=1}^n; f_j \in \mathcal{F}, y_j \in \{-1, 1\}$. Bài toán máy véc-tơ hỗ trợ lề mềm được xây dựng từ nguyên lý cực tiểu hoá độ lớn véc-tơ trọng số $\mathbf{w}$ và cho phép sai số điều chỉnh được bởi các biến ξ_j , tức là

$$\begin{aligned} \text{Maximise : } & \frac{1}{2} \|\mathbf{w}\|_{\mathcal{H}}^2 + C \sum_{j=1}^n \xi_j, \\ \text{S.t. : } & y_j (\langle \mathbf{w}, \Phi(f_j) \rangle + b) \geq 1 - \xi_j, \\ & \xi_j \geq 0, \quad j = 1, \dots, n. \end{aligned}$$

Hàm L'Agrange tương ứng được cho bởi

$$\mathcal{L}(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha}, \boldsymbol{\mu}) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{j=1}^n \xi_j - \sum_{j=1}^n \alpha_j [y_j (\langle \mathbf{w}, \Phi(f_j) \rangle + b) - (1 - \xi_j)] - \sum_{j=1}^n \mu_j \xi_j.$$

Lấy đạo hàm theo $\mathbf{w}$ và đặt $\nabla_{\mathbf{w}} \mathcal{L} = 0$, ta có $\mathbf{w} = \sum_{j=1}^n \alpha_j y_j \Phi(f_j)$. Thay vào hàm L'Agrange, ta được bài toán đối ngẫu của SVM được định nghĩa bởi

$$\text{Maximise : } \sum_{j=1}^n \alpha_j - \frac{1}{2} \sum_{j=1}^n \sum_{k=1}^n \alpha_j \alpha_k y_j y_k \underbrace{\langle \Phi(f_j), \Phi(f_k) \rangle}_{K(f_j, f_k)}, \quad (\text{SVM})$$

$$\text{S.t. : } 0 \leq \alpha_j \leq C, \quad \sum_{j=1}^n \alpha_j y_j = 0. \quad (1.7)$$

Định lý 1.14. SVM là bài toán tối ưu lồi nghiêm ngặt trên đa diện lồi compact, do đó tồn tại duy nhất nghiệm véc-tơ $\boldsymbol{\alpha}^* \in \mathbb{R}^n$.

Chứng minh. Ma trận Gram $\mathbf{G}_{jk} = y_j y_k K(f_j, f_k)$ là xác định dương do K là kernel thỏa mãn điều kiện Mercer. Hàm mục tiêu là hiệu của một hàm tuyến tính và một dạng toàn phương xác định dương nên lồi nghiêm ngặt. Nhờ đó, tồn tại nghiệm cực đại duy nhất theo định lý Weierstrass.

Khi đó, hàm phân lớp tương ứng đối với hàm mật độ mới h là

$$\hat{y}(h) = \text{sign}(g(h)) = \text{sign}\left(\sum_{j=1}^n \alpha_j^* y_j K(f_j, h) + b^*\right).$$

1.8.3 Phương pháp naive Bayes

a Thuật toán phân lớp

Phương pháp naive Bayes đã được nhiều nhà thống kê quan tâm cho dữ liệu hàm mật độ xác suất bởi [48]. Cho tập huấn luyện $\mathcal{D} = \{(f_j; y_j)_{j=1}^n; f_j \in \mathcal{F}, y_j \in \{0; 1\}\}$. Xác suất hậu nghiệm Bayes để xếp $h(x)$ vào lớp $Y = k$ được viết dưới dạng

$$\mathbb{P}(Y = k | h) = \frac{\mathbb{P}(Y = k) f(h | Y = k)}{\sum_{j \in \{0, 1\}} \mathbb{P}(Y = j) f(h | Y = j)}. \quad (1.8)$$

Khi này, ta ước lượng mật độ có điều kiện $f(h | Y = k)$ bằng kỳ vọng của hàm hạt nhân giữa đối tượng mới h và các hàm mật độ huấn luyện f_i trong lớp $Y = k$. Tức là,

$$f(h | Y = k) = \frac{1}{n_k b w_k} \sum_{i=1}^{N_k} \mathbb{E}_{X \sim h, Y \sim f_i} \left(\kappa \left(\frac{X - Y}{b w_k} \right) \right), \quad (1.9)$$

trong đó n_k là số mẫu huấn luyện thuộc lớp $Y = k$, f_i là các hàm mật độ huấn luyện trong lớp đó, và $b w_k$ là tham số trơn. Dưới dạng tích phân, công thức (1.9) tương đương với

$$f(h | Y = k) = \frac{1}{n_k} \sum_{i=1}^{n_k} \iint \frac{1}{b w_k} \kappa \left(\frac{x - y}{b w_k} \right) h(x) f_i(y) dx dy.$$

Giả sử không có thông tin tiên nghiệm, ta lấy tiên nghiệm đều $\mathbb{P}(Y = 1) = \mathbb{P}(Y = 0) = 1/2$. Khi này ta có quy tắc phân loại hàm mật độ $h(x)$ phân loại vào lớp $Y = 1$ nếu $f(h | Y = 1) > f(h | Y = 0)$ và ngược lại. Tương tự, đối với phân loại nhiều hơn hai lớp, hàm mật độ h sẽ được phân loại vào lớp k nào có hậu nghiệm lớn nhất, tức là

$$\hat{y} = \arg \max_{k \in \{1, \dots, K\}} \mathbb{P}(Y = k | h).$$

Bổ đề 1.8 (Hàm mật độ Gauss có điều kiện). Xét công thức ước lượng mật độ có điều kiện $f(h | Y = k)$. Nếu chọn hạt nhân Gauss $\kappa(u) = \mathcal{N}(u; 0, 1)$, thì ta có

$$f(h | Y = k) = \frac{1}{n_k} \sum_{i=1}^{n_k} \mathcal{N}(\mu_h - \mu_i; 0, \sigma_h^2 + \sigma_i^2 + b w_k^2),$$

trong đó $\mathcal{N}(\cdot; 0, \tau^2)$ là mật độ Gauss với trung bình 0 và phương sai τ^2 .

Chứng minh. Ta có $\kappa\left(\frac{x-y}{b w_k}\right) = \mathcal{N}(x-y; 0, b w_k^2)$. Ngoài ra, viết lại tích phân đôi theo biến $z = x - y$, ta có

$$\iint \mathcal{N}(z; 0, b w_k^2) h(y+z) f_i(y) dz dy.$$

Đặt $X \sim \mathcal{N}(\mu_h, \sigma_h^2)$ và $Y \sim \mathcal{N}(\mu_i, \sigma_i^2)$ độc lập. Khi đó biến ngẫu nhiên $Z = X - Y$ cũng tuân theo phân phối chuẩn (Bổ đề 1.1), tức là $Z \sim \mathcal{N}(\mu_h - \mu_i, \sigma_h^2 + \sigma_i^2)$. Do đó, giá trị $f(h|Y = k)$ có thể viết thành kỳ vọng

$$f(h|Y = k) = \int \mathcal{N}(z; 0, bw_k^2) \mathcal{N}(z; \mu_h - \mu_i, \sigma_h^2 + \sigma_i^2) dz.$$

Áp dụng Bổ đề 1.2 về tích phân của tích hai mật độ chuẩn với $a = bw_k^2$, $b = \sigma_h^2 + \sigma_i^2$, $m = \mu_h - \mu_i$ ta thu được điều phải chứng minh. ■

Ví dụ 1.8 (Phân loại hàm mật độ bằng phương pháp naive Bayes). Trở lại giả thuyết của Ví dụ 1.7, ta cần phân loại hàm mật độ Gauss mới $h(x) = \mathcal{N}(3, 0; 0, 9)$ vào một trong hai lớp.

Bài giải. Giả sử không có thông tin tiên nghiệm, $\mathbb{P}(Y=1) = \mathbb{P}(Y=0) = 0,5$. Theo Bổ đề 1.8 ta có

$$f(h|Y = k) = \frac{1}{n_k} \sum_{i=1}^{n_k} \frac{1}{\sqrt{2\pi(\sigma_h^2 + \sigma_i^2 + bw_k^2)}} \exp\left(-\frac{(\mu_h - \mu_i)^2}{2(\sigma_h^2 + \sigma_i^2 + bw_k^2)}\right).$$

Dùng quy tắc Silverman cho từng lớp, ta có

$$h_{\mathcal{F}} = 1,06 \sqrt{0,4} (n_{\mathcal{F}})^{-1/5} = 0,486, \text{ và } h_{\mathcal{G}} = 1,06 \sqrt{0,9} (n_{\mathcal{G}})^{-1/5} = 0,729,$$

Khi này, ta tính được $f(h|\mathcal{F})$ qua các kỳ vọng $\mu_{\mathcal{F}}$, ta có kết quả $f(h|\mathcal{F}) = 0,158$. Tương tự, ta cũng tính được $f(h|\mathcal{G})$ qua với các kỳ vọng $\mu_{\mathcal{G}}$, kết quả là $f(h|\mathcal{G}) = 0,033$.

Cuối cùng, xác suất hậu nghiệm của hai lớp được tính bởi công thức

$$\mathbb{P}(\mathcal{F}|h) = \frac{0,5 f(h|\mathcal{F})}{0,5 f(h|\mathcal{F}) + 0,5 f(h|\mathcal{G})} = \frac{0,5 \cdot 0,158}{0,5 \cdot 0,158 + 0,5 \cdot 0,033} = 0,826,$$

và $\mathbb{P}(\mathcal{G}|h) = 1 - 0,826 = 0,174$. Vì $\mathbb{P}(\mathcal{F}|h) > \mathbb{P}(\mathcal{G}|h)$ nên $h(x)$ được phân loại vào lớp $\mathcal{F}$ với xác suất hậu nghiệm xấp xỉ 82,6%.

b Xác định tiên nghiệm

Trong phân lớp Bayes, xác suất tiên nghiệm $\mathbb{P}(Y = k)$ thường được ước lượng dựa vào kiến thức chuyên gia hoặc thông tin trong lịch sử nghiên cứu tương tự. Trong trường hợp không có thông tin tiên nghiệm nào, ta có thể giả định mọi lớp đều có xác suất bằng nhau, tức là $\mathbb{P}(Y = k) = 1/k$. Trong nhiều tình huống, xác suất tiên nghiệm còn có thể ước lượng từ tần suất xuất hiện của các lớp trong tập dữ liệu huấn luyện. Khi đó, $\mathbb{P}(Y = k) = n_k/n$ trong đó n_k là số lượng mẫu thuộc lớp k và n là tổng số mẫu. Tuy nhiên, phương pháp này có thể gặp vấn đề khi dữ liệu ít hoặc có xác suất bằng 0 cho một số lớp, phương pháp Laplace được sử dụng để điều chỉnh, $\mathbb{P}(Y = k) = (n_k + \alpha)/(n + \alpha k)$, với $\alpha > 0$.

Tổng kết Chương 1

Chương 1 trình bày cơ sở lý thuyết của hàm mật độ xác suất, các phép đo khoảng cách và phương pháp phân tích chùm/phân loại. Những kiến thức này đóng vai trò nền tảng cho các chương tiếp theo.

CHƯƠNG 2

NHẬN DẠNG THÔNG KÊ CHO HÀM MẬT ĐỘ XÁC SUẤT VỚI DỮ LIỆU MẤT CÂN BẰNG

2.1 Giới thiệu

Hàm mật độ xác suất được xem là dạng dữ liệu đặc trưng với cấu trúc phức tạp hơn. Nó cho phép khám phá quy luật phân bố tại nhiều tổng thể khác nhau hoặc được xem như đối tượng không chắc chắn khi quyết định chưa chính xác hoặc có lỗi.

Trong dữ liệu 1-chiều, nghiên cứu về Cá hồi vây vàng (*Yellowfin tuna*) của Minami [49] thể hiện phân bố chiều dài cá theo từng ô tọa độ tại Thái Bình Dương. Bên cạnh đó, các phân phối liên quan đến phân phối tỷ giá theo ngày, khí hậu ở các trạm theo năm, hay mật độ tuổi giữa hai giới ở các tỉnh, chỉ số sức khỏe theo độ tuổi [17, 18] cũng là ví dụ tiêu biểu cho dạng 1-chiều. Đặc biệt, dữ liệu hàm mật độ còn có thể được xây dựng từ hình ảnh thông qua việc trích xuất màu sắc [12, 46]. Trong khi đó, dữ liệu 2-chiều thường xuất hiện trong các nghiên cứu về mối tương quan, ví dụ phân tích điểm số sinh viên giữa các khoa/viện tại Đại học Cần Thơ [22]. Hoặc là sự mở rộng ảnh hưởng từ các véc-tơ rời rạc đa chiều [45, 50].

Tuy nhiên, quá trình thu thập dữ liệu này thường mất nhiều thời gian, và khó khăn trong lưu trữ và không gian vô hạn chiều. Cho nên, nhiều phương pháp tiếp cận mới từ nhận dạng thông kê đã giải quyết nhu cầu phân tích dạng dữ liệu này. Chúng bao gồm phân tích chùm và phân loại hàm mật độ xác suất. Để xuyên suốt trong quá trình thực hiện các thuật toán đề xuất, phần này sử dụng ánh xạ đo được $\mathcal{F} : (\Omega, \mathcal{S}, P) \rightarrow (\mathcal{D}, \mathcal{B}_D)$ với $(\Omega, \mathcal{S}, P)$ là không gian xác suất và sigma-đại số Borel $\mathcal{B}_D$ trên $(\mathcal{D}, d)$. Một tập đối tượng hàm mật độ quan sát là $f_j \sim \mathcal{F}$ với $j = 1, \dots, n$ (Định nghĩa 1.8 và 1.9).

2.1.1 Phương pháp phân tích chùm hàm mật độ xác suất

Phân tích chùm là một nhánh chính của nhận dạng không được giám sát [51–53]. Nó có nhiệm vụ khám phá dựa vào sự tương tự giữa các mẫu trong dữ liệu đầu vào [5, 9]. Ví dụ như khi ta cần khoanh vùng khối u trong hình ảnh MRI, hay trong các báo cáo định tính cần nhóm/tổng hợp ý kiến hay quan điểm theo các chủ đề khác nhau. Đầu ra của phân tích chùm là các nhãn cho dữ liệu ban đầu.

Đã có nhiều công trình nghiên cứu liên quan đến bài toán phân tích chùm này lần đầu tiên được giới thiệu bởi Tai Vo-Van [22] từ năm 2010. Cùng với sự phát triển của phần tử rời rạc, bài toán này dần trở nên hiện đại và có nhiều ứng dụng thực tế. Bảng 2.1 mô tả quá trình phát triển phương pháp

phân tích chùm hàm mật độ giai đoạn 5 năm từ 2019 đến 2024.

Bảng 2.1. Tổng quan giai đoạn 5 năm (2019–2024) nghiên cứu phân tích chùm cho hàm mật độ xác suất

Năm	Tác giả	Mô tả phương pháp	Khoảng cách	Phân chùm tự động
2019	Tai Vo-Van [22]	Phân chùm FCF, $m = 2$, tìm số chùm bằng SUP	Độ rộng chùm	×
2019	Dinh Pham-Toan <i>et al.</i> [55]	Phân chùm k -medoids, tối thiểu SSE bằng nhị phân aeDE, số chùm cho trước	$\mathcal{L}_2$	×
2020	Dinh Pham-Toan & Tai Vo-Van [54]	Phân chùm FCF, tối thiểu VCC bằng nhị phân GA, $m = 2$, tìm số chùm bằng SUP	$\mathcal{L}_1$	×
2023	Thao Nguyen-Trang, Tai Vo-Van & Ha Che-Ngoc [56]	Phân chùm tự cập nhật cải tiến, tự động dựa trên SUP	Hạt nhân Gauss $\mathcal{L}_1$	×
2023	Thao Nguyen-Trang <i>et al.</i> [25]	Phân chùm cứng, tối thiểu CSB bằng DE, hàm đại diện Gauss	$\mathcal{L}_2$	✓
2023	Thao Nguyen-Trang, Trung Nguyen-Thoi, & Tai Vo-Van [24]	Phân chùm FCF, tối thiểu FSF bằng DE, hàm đại diện Gauss, $m = 1$	$\mathcal{L}_1$	✓
2024	Hung Tran-Nam, Thao Nguyen-Trang & Ha Che-Ngoc [57]	Phân chùm khả dĩ, tối thiểu SSE, chọn ngưỡng bắt thường bằng α -cut, $m = 2$, số chùm cho trước	$\mathcal{L}_2$	×
2024	Thao Nguyen-Trang, Yen Nguyen-Hoang & Tai Vo-Van [12]	Phân chùm KCF, tối thiểu SSE, bán giám sát bằng % nhân cho trước, số chùm cho trước	$\mathcal{L}_1$	×

Chú thích: Đối với hàm mục tiêu, SSE: sai số của bình phương tối thiểu; VCC: tiêu chuẩn tỷ lệ phương sai (chỉ số Calinski–Harabasz); CSB: hợp của độ đo tương đồng và cân bằng; FSF: tỷ lệ giữa SSE và sự phân biệt giữa các chùm. Đối với phương pháp tối ưu, DE: tiến hóa vi phân; aeDE: tiến hóa vi phân ưu tú thích nghi; GA: giải thuật di truyền. Ở cột cuối, dấu ✓ có nghĩa là tự động toàn bộ thuật toán.

Nhìn chung, các nghiên cứu từ tác giả trong nước cho thấy sự phát triển cả về bề sâu và bề rộng. Các hàm mục tiêu SSE và VCC dần được mở rộng và phức tạp hơn, như CSB và FSF cho phép đánh giá chất lượng của kết quả phân tích chùm một cách đa chiều và sâu sắc hơn. Nghiên cứu của Thao Nguyen-Trang đã sử dụng FSF [24], hoặc CSB [25] làm mục tiêu phân chùm, cho thấy nghiên cứu đã đào sâu vào nội hàm thuật toán. Hơn nữa, năm 2019 cho thấy sự mở rộng từ mô hình cứng sang các phương pháp khác như mờ, khả dĩ và bán giám sát. Các nghiên cứu giai đoạn 2019 tập trung vào các mô hình phân chùm cứng, như k -medoids, KCF. Từ năm 2019 trở đi, các nghiên cứu đã bắt đầu chuyển sang sử dụng các mô hình phân chùm mờ, như trong Tai Vo-Van [22, 54], đã sử dụng FCF với $m = 2$. Cuối năm 2024, nhóm tác giả Thao Nguyen-Trang [12] đã giới thiệu một mô hình phân chùm bán giám sát, sử dụng một phần dữ liệu có nhãn để cải thiện kết quả phân chùm.

Ở quốc tế, hai công trình tiêu biểu thể hiện hai hướng tiếp cận khác nhau. Chen & Hung (2020) [58] nhấn mạnh vào tiêu chuẩn thông tin để tự động phát hiện cấu trúc chùm và xác định số chùm tối ưu, trong khi Tavakkol & Son (2021) [50] tập trung vào không gian hạt nhân để xử lý các chùm có hình dạng bất quy tắc. Điểm chung là cả hai đều mở rộng nền tảng của phân chùm truyền thống. Về ứng dụng, giải thuật entropy-jackknife là phân chùm cứng cho dữ liệu hình ảnh, trong khi Tavakkol & Son thích hợp cho dữ liệu hàm mật độ đa chiều.

Bảng 2.2. Tổng quan giai đoạn 5 năm (2019–2024) nghiên cứu phân tích chùm cho hàm mật độ xác suất (Các tác giả nước ngoài)

Năm	Tác giả	Mô tả phương pháp	Khoảng cách	Phân chùm tự động
2020	Jen-Hao Chen & Wen-Liang Hung [58]	Phân chùm cứng bằng jackknife Shannon entropy, điều chỉnh ngưỡng bằng tối đại VCC	hạt nhân Gauss $\mathcal{L}_1$	✓
2021	Tavakkol, Behnam & Son, Youngdoo [50]	Phân chùm mờ hạt nhân k -medoids cho dữ liệu hàm mật độ 2-chiều, $m = 2$, số chùm cho trước	hạt nhân Gauss $\mathcal{L}_1$	×
2024	Okano Ryo & Imaizumi Masaaki [59]	Phân chùm cứng cho dữ liệu hàm mật độ	W_2	×

Chú thích: Ở cột cuối, dấu ✓ có nghĩa là tự động toàn bộ thuật toán.

Tuy vậy, vấn đề mất cân bằng chùm vẫn chưa có một hướng tiếp cận chuyên biệt. Tỷ lệ mất cân bằng (IR) được định nghĩa là tỷ số giữa số phần tử lớn nhất và số phần tử nhỏ nhất giữa các chùm hay lớp, $IR = \frac{\max_i \#c_i}{\min_j \#c_j}$, trong đó $\#c_i$ là số lượng phần tử trong chùm/lớp i . Khi $IR = 1$, các chùm/lớp có quy mô cân bằng hoàn toàn. Giá trị IR càng lớn thì mức độ mất cân bằng càng cao, nghĩa là sự chênh lệch kích thước giữa chùm/lớp lớn nhất và nhỏ nhất càng rõ rệt. Trong kinh tế, các giá trị IR từ trên 10 là đã có tác động tiêu cực đến các thuật toán cả thống kê và học máy/học sâu. Để giải quyết bài toán này, đa số nghiên cứu phân tích chùm tập trung vào việc cải thiện hàm mục tiêu hay cơ chế tối ưu hóa, nhưng đều giả định các chùm/lớp có quy mô tương đối đồng đều như phân tích chùm KCF hay FCF. Khi tỷ lệ mất cân bằng tăng cao, kết quả phân tích thường bị lệch, chùm nhỏ dễ bị hút vào chùm lớn, hoặc phân loại phần tử mới không đúng và lớp thiếu số. Do đó, việc phát triển các thuật toán phân tích chùm và phân loại có khả năng chống chịu với mất cân bằng là một khoảng trống nghiên cứu quan trọng.


2.2 Giới thiệu bài toán phân tích chùm cho dữ liệu mất cân bằng

Phân tích chùm cho dữ liệu mất cân bằng là chủ đề phát triển để giải quyết nhu cầu thực tế. Bài toán khoanh vùng hình ảnh hòn đảo giữa đại dương được ghi nhận là có sự mất cân bằng, hay phân đoạn chuỗi tín hiệu hiếm như động đất cũng có tính chất mất cân bằng hơn tín hiệu nền yên tĩnh. Dữ liệu lúc này có sự chênh lệch lớn giữa các loại trong tự nhiên và tồn tại hai tình trạng: Kích thước chùm và số lượng phần tử trong chùm mất cân bằng. Kích thước chùm mất cân bằng xảy ra khi các chùm có độ phân tán khác biệt đáng kể về đường kính hoặc mật độ. Trong khi đó, mất cân bằng số lượng khi tổng mẫu chùm chênh lệch lớn.

Trong lĩnh vực phân tích chùm, để giải quyết vấn đề mất cân bằng tự nhiên, đa số phương pháp tập trung cải thiện thuật toán, trong khi các phương pháp tăng cường mẫu ít được áp dụng do khó xác định chùm tiềm ẩn. Ở dữ liệu rời rạc, thuật toán phân tích chùm mất cân bằng đã được giải quyết rất tốt qua các thuật toán csiFCM (2002) [60], siiFCM (2014) [61], iFCM (2016) [62], EM-IFCM (2024) [63], và EKM (2024) [64]. Các thuật toán này giải quyết chủ yếu hai vấn đề bao gồm mở rộng kích thước chùm và dịch chuyển trọng tâm. Hơn nữa, khi có sự khác biệt lớn về số lượng phần tử hoặc kích thước chùm không đồng đều, các thuật toán phân chùm phân vùng có xu hướng nuốt các chùm nhỏ và

chia cho lớp lớn hơn như Yue Pu, Wenbin Yao, & Xiaoyong Li (2024) đề cập [63]. Hiệu ứng này được gọi là "hiệu ứng xi phong" có xu hướng kéo (hút) các phần tử biên của lớp nhỏ về lớp lớn, và trọng tâm của lớp nhỏ cũng dịch chuyển về phía lớp lớn. Hai hiệu ứng trên cũng là điểm yếu lớn của phân tích chùm truyền thống. Hình 2.2 thể hiện sự thay đổi của IR và nhiều của dữ liệu hàm mật độ mất cân bằng lên kết quả trọng tâm thuật toán FCF. Các dòng (1–4) thể hiện sự tăng dần của IR đối với FCF và kết quả phân vùng có xu hướng đồng nhất số lượng hàm mật độ trong mỗi chùm ở hiệu ứng đồng nhất. Trong khi các cột thể hiện dữ liệu nhiều thể hiện hiệu ứng xi-phong cao.

Giả sử hai chùm có số lượng phần tử $\#c_1$ lớn và $\#c_2$ có số lượng nhỏ sao cho $\#c_1 = IR \cdot \#c_2$ với $IR \in \mathbb{N}_{>0}$. Khi IR tăng lên, hàm tỷ số giữa $\#c_1$ và tổng số phần tử trong dữ liệu được biểu diễn bởi $k(x) = 1 - 1/(x+1)$. Trong Hình 2.1, hàm $k(x)$ là một đường cong tăng đơn điệu và đạo hàm của nó giảm khi IR tăng. Nghĩa là chỉ số hoá theo kích thước chùm thông qua trọng số lớp trở nên bão hoà. Do đó, cần thiết xây dựng bổ sung phương pháp trung hòa các phần tử trong lớp lớn hơn trong hàm mục tiêu.



Hình 2.1. Quan hệ giữa tỷ lệ mất cân bằng và quy mô cụm chiếm ưu thế

Tuy nhiên, thuật toán KCF, và FCF giả định các chùm có cùng kích thước [65] dẫn đến các quyết định phân chùm sai lầm. Xiong (2006) [66], giải thích rằng thuật toán k -means ưu tiên chia dữ liệu thành các lớp có kích thước tương đối đồng đều khi phân chùm dữ liệu mất cân bằng. Hiện tượng này được gọi là "hiệu ứng đồng nhất" do hàm mục tiêu. Tương tự với KCF, hàm mục tiêu của thuật toán FCF cũng được xây dựng theo cùng một nguyên tắc, nên cũng có hiệu ứng trên. Cụ thể, khi hai hàm mật độ trọng tâm θ_1 và θ_2 tính bằng (1.3) với các mức độ phân vùng đơn giản hoá thành $\mu_{ij} = u$ nếu $f_j \in c_i$ và $1 - u$ cho các trường hợp còn lại. Ta có

$$\theta_1(x) = \frac{u^m \sum_{f_j \in c_1} f_j(x) + (1-u)^m \sum_{f_j(x) \in c_2} f_j(x)}{\#c_1 u^m + \#c_2 (1-u)^m},$$

$$\theta_2(x) = \frac{(1-u)^m \sum_{f_j(x) \in c_1} f_j(x) + u^m \sum_{f_j \in c_2} f_j}{\#c_1 (1-u)^m + \#c_2 u^m}.$$

Khi chùm đa số c_1 tăng số lượng, giới hạn của khoảng cách $\mathcal{L}_2$ giữa hai trọng tâm này là

$\lim_{\#c_1 \rightarrow \infty} \mathcal{L}_2^2(\theta_1, \theta_2) = 0$. Cụ thể, giả sử $\hat{\theta}_i(x) = (1/\#c_i) \sum_{f_j \in c_i} f_j(x)$ là các trọng tâm thực tế tính theo (1.2), ta có

$$\begin{aligned} \lim_{\#c_1 \rightarrow \infty} \mathcal{L}_2^2(\theta_1, \theta_2) &= \lim_{\#c_1 \rightarrow \infty} \int \left(\frac{u^{\#c_1} \hat{\theta}_1(x) + (1-u)^{\#c_2} \hat{\theta}_2(x)}{\#c_1 u^{\#c_1} + \#c_2 (1-u)^{\#c_2}} - \frac{(1-u)^{\#c_1} \hat{\theta}_1(x) + u^{\#c_2} \hat{\theta}_2(x)}{\#c_1 (1-u)^{\#c_1} + \#c_2 u^{\#c_2}} \right)^2 dx \\ &\stackrel{\delta = \frac{\#c_1}{\#c_2}}{=} \lim_{\#c_1 \rightarrow \infty} \left(\frac{\delta(u^{2m} - (1-u)^{2m})}{(\delta u^m + (1-u)^m)(\delta(1-u)^m + u^m)} \right)^2 \int (\hat{\theta}_1(x) - \hat{\theta}_2(x))^2 dx \end{aligned}$$

Ta biết trong tỷ lệ trên, δ có bậc của tử nhỏ hơn bậc của mẫu, nên dẫn đến giới hạn khoảng cách giữa hai trọng tâm khi số lượng phần tử chòm lớn tăng lên là $\lim_{\#c_1 \rightarrow \infty} \mathcal{L}_2^2(\theta_1, \theta_2) = 0$. Điều này chứng minh rằng FCF (và KCF) đều có xu hướng làm cho các trọng tâm chòm cuối cùng dịch chuyển gần nhau hơn so với các trọng tâm thực tế. Kết quả là, các chỉ số đánh giá phân chòm truyền thống sẽ ưu tiên gộp chòm thiếu số và chòm lân cận thành một chòm duy nhất. Trong luận văn này, hiệu ứng đồng nhất lần đầu tiên được đề cập và giải quyết cho đối tượng hàm mật độ xác suất mà bỏ qua hiệu ứng xi-phông bởi do sự ưu tiên của nó.

2.2.1 Thuật toán

Cho tập các hàm mật độ xác suất $\mathcal{F}$, trong đó mỗi f_j là một hàm mật độ xác suất ($j = 1; \dots; n$). Cho trước c là số chòm ($i = 1; \dots; c$). Gọi $U = [\mu_{ij}] \in \mathbb{R}^{n \times c}$ là ma trận phân vùng, và $\Theta = \{\theta_1, \dots, \theta_c\}$ là các trọng tâm chòm. Giả sử tham số mờ $m > 1$. Hàm mục tiêu của IF CF là tổng của hai phần bao gồm trọng số $1/\omega_i$ giảm “hiệu ứng đồng nhất”.

$$\text{Minimise : } J(U; \Theta | \mathcal{F}; c; m; \delta') = \sum_{j=1}^n \sum_{i=1}^c \frac{1}{\omega_i} \mu_{ij}^m D^2(f_j; \theta_i), \quad (\text{IFCF})$$

$$\text{s.t : } \sum_{i=1}^c \mu_{ij} = 1, \quad \forall j \in 1, \dots, n, \quad (\text{C1})$$


trong đó $\omega_i^{(t)} = \frac{1}{n} \sum_{j=1}^n \mu_{ij}^{(t-1)}$ là tỷ lệ kích thước mờ của chòm thứ i , với $1; \dots; c$, thỏa mãn $\sum_{i=1}^c \omega_i = 1$ với $\mu_{ij}^{(t-1)}$ là ma trận phân vùng tại vòng lặp thứ $(t-1)$. Khi $\omega_i = 1$ thì thuật toán trở thành FCF.

Nhận xét. Khi mất cân bằng tăng, đóng góp của chòm lớn hơn vào hàm mục tiêu sẽ lấn át chòm nhỏ hơn. Do đó, thành phần IF CF chia cho $\frac{1}{\omega_i}$, với $\omega_i \in (0; 1)$ sẽ giảm một tỷ lệ kích thước chòm cho cả hai bên. Khi đó, chòm lớn phải chịu tổn thất lớn hơn để giảm đóng góp hàm mục tiêu mà không làm sai lệch trọng tâm và tính ổn định.

2.2.2 Sự hội tụ của thuật toán

Trong phần này, một dãy $(\mu^{(t)}; \Theta^{(t)})$ khởi tạo được thành lập. Mục tiêu là chứng minh dãy này có hội tụ hay không [39, 63]. Cho $F : \mathbb{R}^{cd} \rightarrow U_f; F(\Theta) = \mu$; và $G : U_f \rightarrow \mathbb{R}^{cd}; G(\mu) = \Theta$, trong đó, $\Theta = (\theta_1; \theta_2; \dots; \theta_c)$ và các hàm mật độ trọng tâm θ_i tính bởi công thức (1.3). Ta định nghĩa toán tử $T_{IFCF} : \mathbb{R}^{cd} \times U_f \rightarrow \mathbb{R}^{cd} \times U_f; T_{IFCF} = T_2 \circ T_1$, trong đó ánh xạ $T_1 : \mathbb{R}^{cd} \times U_f \rightarrow \mathbb{R}^{cd}; T_1(\mu; \Theta) = G(\mu)$, và $T_2 : \mathbb{R}^{cd} \rightarrow \mathbb{R}^{cd} \times U_f; T_2(\Theta) = (F(\Theta), \Theta)$. Khi này, ta có $T_{IFCF} = (T_2 \circ T_1)(F \circ G(\mu); G(\mu))$. Tức là

$$T_{IFCF} : \mathbb{R}^{cd} \times U_f \rightarrow \mathbb{R}^{cd} \times U_f; T_{IFCF} = T_2 \circ T_1, \quad (2.1)$$



Hình 2.2. Ảnh hưởng của dữ liệu hàm mật độ Gauss mất cân bằng lên FCF ($m = 2; c = 3; D = \mathcal{L}_2$)

Bổ đề 2.1 (Cập nhật ma trận phân vùng U). Với Θ cố định, bài toán tối ưu hoá J_{IFCF} theo $U = [\mu_{ij}]$ có nghiệm cực tiểu duy nhất $U^* = F(\Theta)$ dưới các ràng buộc phân hoạch mờ (C1). Cụ thể,

$$\mu_{ij} = \frac{\left[\frac{\omega_i}{D^2(\theta_i, f_j)} \right]^{\frac{1}{m-1}}}{\sum_{s=1}^c \left[\frac{\omega_s}{D^2(\theta_s, f_j)} \right]^{\frac{1}{m-1}}}; 1 \leq i \leq c, 1 \leq j \leq n, \quad (2.2)$$

trong đó $\omega_i = \frac{1}{n} \sum_{j=1}^n \mu_{ij}^{(t-1)}$ là trọng số kích thước chùm với $\omega_i > 0, i = 1, \dots, c$ và $\sum_i \omega_i = 1$. Ngoài ra, nếu tồn tại i_0 sao cho $D^2(\theta_{i_0}, f_j) = 0$ thì nghiệm tối ưu cho cột j là $\mu_{i_0j} = 1$ và $\mu_{sj} = 0$ với mọi $s \neq i_0$; nếu có nhiều chỉ số đạt 0 thì mọi phân phối trên tập đó đều tối ưu.

Chứng minh. Do ràng buộc phân hoạch mờ là độc lập theo từng mẫu j , và mục tiêu (IFCF) là tổng theo j , bài toán tối ưu hoá theo U tách thành n bài toán độc lập. Cố định một $j \in \{1, \dots, n\}$, đặt hằng số $\delta_{ij} := D^2(\theta_i, f_j)/\omega_i$. Khi này, mục tiêu của bài toán con theo cột j là

$$\min_{\mu_{ij} \in \mathbb{R}_{>0}^c} \phi_j(\mu_{\cdot j}) : \sum_{i=1}^c \delta_{ij} \mu_{ij}^m \quad \text{s.t.} \quad \sum_{i=1}^c \mu_{ij} = 1, \mu_{ij} \geq 0. \quad (2.3)$$

Với $m > 1$, ta nhận được hàm $t \mapsto t^m$ lồi nghiêm ngặt trên $\mathbb{R}_{>0}$. Khi đó, hàm mục tiêu ϕ_j là tổng các hàm lồi nghiêm ngặt theo từng biến. Miền khả thi là một đơn hình đóng và bị chặn, do đó nghiệm tối ưu tồn tại duy nhất. Hơn nữa, ma trận Hessian là xác định dương, với các phần tử trong ma trận

$$\frac{\partial^2 \phi_j}{\partial \mu_{ij}^2} = m(m-1)(\delta_{ij})\mu_{ij}^{m-2} > 0, \frac{\partial^2 \phi_j}{\partial \mu_{ij} \partial \mu_{sj}} = 0 \ (s \neq i),$$

Lập Lagrangian với nhân tử $\lambda_j \in \mathbb{R}$ cho ràng buộc tổng bằng 1 và $\alpha_{ij} \geq 0$ cho các ràng buộc không âm, ta có

$$\mathcal{L}(\mu_{\cdot j}, \lambda_j, \alpha_{\cdot j}) = J_{IFCF} - \lambda_j \left(\sum_{i=1}^c \mu_{ij} - 1 \right) - \sum_{i=1}^c \alpha_{ij} \mu_{ij}. \quad (2.4)$$

Điều kiện dừng bậc nhất là đạo hàm riêng của (2.4) theo μ_{ij} bằng 0.

$$\frac{\partial}{\partial \mu_{ij}} \mathcal{L} = m \delta_{ij} \mu_{ij}^{m-1} - \lambda_j - \alpha_{ij} = 0, \quad (2.5)$$

cùng với các điều kiện $\sum_{i=1}^c \mu_{ij} = 1, \mu_{ij} \geq 0, \alpha_{ij} \geq 0$, và $\alpha_{ij} \mu_{ij} = 0, \forall i$. Giả sử $\delta_{ij} > 0$ với mọi i , nếu $\mu_{ij} > 0$ thì $\alpha_{ij} = 0$. Khi đó (2.5) cho kết quả

$$\mu_{ij} = \left(\frac{\lambda_j}{m} \right)^{\frac{1}{m-1}} (\delta_{ij})^{-\frac{1}{m-1}}. \quad (2.6)$$

Áp dụng ràng buộc chuẩn hoá $\sum_{i=1}^c \mu_{ij} = 1$ vào (2.6), ta có

$$1 = \sum_{i=1}^c \left(\frac{\lambda_j}{m} \right)^{\frac{1}{m-1}} (\delta_{ij})^{-\frac{1}{m-1}} = \left(\frac{\lambda_j}{m} \right)^{\frac{1}{m-1}} \sum_{i=1}^c (\delta_{ij})^{-\frac{1}{m-1}},$$

suy ra

$$\left(\frac{\lambda_j}{m}\right)^{\frac{1}{m-1}} = \frac{1}{\sum_{s=1}^c (\delta_{sj})^{-\frac{1}{m-1}}}.$$

Thế ngược lại vào (2.6), ta thu được (2.2).

Ngược lại, tồn tại i_0 sao cho $D^2(\theta_{i_0}, f_j) = 0$ thì $\delta_{i_0j} = 0$. Tuy nhiên, với mọi $s \neq i_0$, $\delta_{sj} > 0$, nên để tối thiểu hoá tổng $\sum_s c_{sj} \mu_{sj}^m$ dưới ràng buộc tổng bằng 1, nghiệm tối ưu là $\mu_{i_0j} = 1$ và $\mu_{sj} = 0$ với $s \neq i_0$. Từ đây, ta được điều phải chứng minh. ■

Bổ đề 2.2 (Cập nhật trọng tâm Θ với $\mathcal{L}_2^2$). Với U cố định, bài toán tối thiểu hoá J_{IFCF} theo $\Theta = \{\theta_i\}_{i=1}^c$ là phân tích được theo từng θ_i và lồi nghiêm ngặt. Tồn tại duy nhất nghiệm cực tiểu $\Theta^* = G(U)$ khi khoảng cách $D^2 = \mathcal{L}_2^2$,

$$\theta_i = \frac{\sum_{j=1}^n (\mu_{ij})^m f_j}{\sum_{j=1}^n (\mu_{ij})^m}; 1 \leq i \leq c, \quad (2.7)$$

Chứng minh. Giữ U cố định, lấy đạo hàm $\psi_i = \sum_{j=1}^c \psi_i(\theta_i)$, với các $\psi_i(\theta_i) = \sum_{j=1}^n \frac{1}{\omega_i} (\mu_{ij})^m D^2(\theta_i, f_j)$. theo θ_i đối với hàm mục tiêu (IFCF) ta có

$$\nabla_{\theta_i} \psi_i(\theta_i) = \frac{1}{\omega_i} \sum_{j=1}^n (\mu_{ij})^m (\mu_{ij})^m \nabla_{\theta_i} \mathcal{L}_2^2(\theta_i, f_j) \quad (2.8)$$

Cho $\nabla_{\theta_i} \psi_i(\theta_i) = 0$, ta được công thức cập nhật (2.7) đối với riêng trường hợp $\mathcal{L}_2^2(\theta_i, f_j)$. Hơn nữa, với khoảng cách $\mathcal{L}_2$, ma trận Hess theo θ_i là $\nabla_{\theta_i}^2 \psi_i(\theta_i) = \frac{2}{\omega_i} \left(\sum_{j=1}^n (\mu_{ij})^m \right) \mathbf{I}_d$, xác định dương vì $\sum_j (\mu_{ij})^m > 0$ và $\omega_i > 0$. Do đó ψ_i lồi nghiêm ngặt và nghiệm bậc nhất (2.8) là duy nhất, suy ra nghiệm toàn cục duy nhất $\Theta^* = G(U)$. Tuy nhiên, $\nabla_{\theta_i}^2 \psi_i(\theta_i)$ chỉ lồi nghiêm ngặt trong một số khoảng cách như $\mathcal{L}_2, D_H^2, D_{KL}$ hoặc W_2 , trong khi với các khoảng cách khác bao gồm $\mathcal{L}_2, D_B$ hoặc D_M có thể không duy nhất nghiệm toàn cục. ■

Bổ đề 2.3 (Cập nhật trọng tâm Θ với D_H^2). Với U cố định, bài toán tối thiểu hoá J_{IFCF} theo $\Theta = \{\theta_i\}_{i=1}^c$ có thể tách được theo từng θ_i và là lồi nghiêm ngặt trong biến $\sqrt{\theta_i}$. Tồn tại duy nhất nghiệm cực tiểu $\Theta^* = G(U)$ khi khoảng cách $D^2 = D_H^2$, trong đó

$$\theta_i(x) = \frac{\left(\sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(x)} \right)^2}{\int_{\Omega} \left(\sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(y)} \right)^2 dy}, \quad 1 \leq i \leq c. \quad (2.9)$$

Chứng minh. Giữ U cố định, xét $\psi_i(\theta_i) = \sum_{j=1}^n \frac{1}{\omega_i} (\mu_{ij})^m D_H^2(\theta_i, f_j)$. Ta có khoảng các bình phương Hellinger là $D_H^2(\theta_i, f_j) = 1 - \int \sqrt{\theta_i(x) f_j(x)} dx$. Do đó

$$\psi_i(\theta_i) = \frac{1}{\omega_i} \sum_{j=1}^n (\mu_{ij})^m \left(1 - \int_{\Omega} \sqrt{\theta_i(x) f_j(x)} dx \right).$$

Vì $\theta(x) \leq 0$, ψ_i trở thành một hàm lồi theo $\theta_i^{1/2}(x)$. Vì vậy,

$$\frac{\partial \psi_i}{\partial \theta_i^{1/2}(x)} = -\frac{1}{\omega_i} \sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(x)} + \frac{1}{\omega_i} \left(\sum_{j=1}^n (\mu_{ij})^m \right) \theta_i^{1/2}(x).$$

Cho $\frac{\partial \psi_i}{\partial \theta_i^{1/2}(x)} = 0$, ta có công thức (2.9). Ta cũng có ma trận Hess lúc này là xác định dương, nghiệm (2.9) là nghiệm toàn cục duy nhất. ■

Ta cũng chứng minh được công thức đóng tại Bổ đề 2.3 cũng là một hàm mật độ xác suất.


Chứng minh. Từ kết quả công thức (2.9), ta có

$$\int_{\Omega} \theta_i(x) dx = \int_{\Omega} \frac{\left(\sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(x)} \right)^2}{\int_{\Omega} \left(\sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(y)} \right)^2 dy} dx = \frac{\int_{\Omega} \left(\sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(x)} \right)^2 dx}{\int_{\Omega} \left(\sum_{j=1}^n (\mu_{ij})^m \sqrt{f_j(y)} \right)^2 dy} = 1. \quad \blacksquare$$

Bảng 2.3 trình bày các công thức cập nhật trọng tâm θ của chùm theo những khoảng cách khác nhau.

Bảng 2.3. Các công thức trọng tâm tương ứng với các loại khoảng cách

Công thức khoảng cách	Trọng tâm θ
$\mathcal{L}^2(f, \theta) = \int (f(x) - \theta(x))^2 dx$	$\theta(x) = \frac{\sum_j u_{ij}^m f_j(x)}{\sum_j u_{ij}^m}$
$D_H^2(f, \theta) = \frac{1}{2} \int (\sqrt{f(x)} - \sqrt{\theta(x)})^2 dx$	$\theta(x) = \left(\frac{\sum_j u_{ij}^m \sqrt{f_j(x)}}{\sum_j u_{ij}^m} \right)^2$
$W_2^2(f, \theta) = \int_0^1 (F^{-1}(p) - G^{-1}(p))^2 dp$	$\theta(x) = \frac{d}{dx} Q_{\theta}^{-1}, Q_{\theta}(p) = \frac{\sum_j u_{ij}^m Q_{f_j}(p)}{\sum_j u_{ij}^m}$



Hình 2.3. Minh họa các công thức trọng tâm theo khoảng cách

Chú thích từng loại khoảng cách (a) $\mathcal{L}_2$, (b) Hellinger và (c) Wasserstein-2.

Tuy nhiên, hai bổ đề 2.1 và 2.2 chỉ là điều kiện cần để $(\mu^*; \Theta^*)$ là một cực tiểu toàn cục của hàm mục tiêu J_{IFCF} . Từ đây, câu hỏi tiếp theo là liệu dãy $\{T_{IFCF}^{(t)}(\mu^{(0)})\}$ có hội tụ về μ^* hay không. Điều kiện đủ cho định lý Zangwill là tính compact của một tập con $U_f \times \mathbb{R}^{cd}$ chứa tất cả các dãy sinh bởi T_{IFCF} .

Ba định lý này là một phần của chứng minh (IFCF) bằng định lý Zangwill, chứng minh trực tiếp cho kết quả của Định lý 2.4.

Định lý 2.1 (Ràng buộc com-pắc). Cho $[\text{conv}(\mathcal{F})]^c$ là tích Descartes bậc c của bao lồi $\mathcal{F}$, và $(\mu^{(0)}; \Theta^{(0)})$ là điểm bắt đầu của phép lặp với J_{IFCF} , với $\mu^{(0)} \in U_f$ và $\Theta^{(0)} = G(\mu^{(0)})$. Khi đó $T_{IFCF}^{(0)}(\mu^{(0)}; \Theta^{(0)}) \in U_f \times [\text{conv}(\mathcal{F})]^c$, và $U_f \times [\text{conv}(\mathcal{F})]^c$ là tập com-pắc trong $U_f \times \mathbb{R}^{cd}$.

Chứng minh. Giả sử $\mu^{(0)} \in U_f$, khi đó $\Theta^{(0)} = G(\mu^{(0)})$ được tính theo (2.7). Khi đó $\theta_i^{(0)} = \frac{\sum_{j=1}^n (\mu_{ij}^{(0)})^m f_j}{\sum_{j=1}^n (\mu_{ij}^{(0)})^m}$.

Đặt $\rho_{ij} = \frac{(\mu_{ij}^{(0)})^m}{\sum_{l=1}^n (\mu_{il}^{(0)})^m}$, $1 \leq j \leq n$. Theo các ràng buộc (C1), ta có $0 < \rho_{ij} < 1$, $\forall i, j$. Vậy $\forall i$, ta viết lại $\theta_i^{(0)} = \sum_{j=1}^n \rho_{ij} f_j$, với $\sum_{j=1}^n \rho_{ij} = 1$.

Tóm lại $\forall i$, $\theta_i^{(0)} \in \text{conv}(\mathcal{F})$, và do đó $\Theta^{(0)} \in [\text{conv}(\mathcal{F})]^c$. Tiếp tục đệ quy $\mu^{(1)} = F(\mu^{(0)}) \in U_f$, và $\Theta^{(1)} = G(\mu^{(1)}) \in [\text{conv}(\mathcal{F})]^c$ theo lập luận tương tự. Do đó, mọi dãy lặp của J_{IFCF} đều thuộc về $U_f \times [\text{conv}(\mathcal{F})]^c$ với mọi $t \geq 1$. Mặc dù có thể khởi tạo $\Theta^{(0)} \in \mathbb{R}^{cd} \setminus [\text{conv}(\mathcal{F})]^c$, nhưng khi đó $\mu^{(0)} = F(\Theta^{(0)}) \in U_f$, và từ $t \geq 1$ thì $\Theta^{(t)} = G(\mu^{(t)}) \in [\text{conv}(\mathcal{F})]^c$. Rõ ràng, $U_f \times [\text{conv}(\mathcal{F})]^c$ là một tập com-pắc trong $\mathcal{F}$ và dãy lặp hội tụ hữu hạn. ■

Định lý 2.2. Xét $S_{IFCF} = \{(\mu^*, \Theta^*) : J_{IFCF}(\mu^*, \Theta^*) < J_{IFCF}(\mu, \Theta); \forall (\mu, \Theta) \in B^0((\mu^*, \Theta^*), r)\}$ là tập nghiệm. Khi đó, J_{IFCF} là hàm giảm của $\{T_{IFCF}; S_{IFCF}\}$.

Chứng minh. Đầu tiên, vì các ánh xạ $\{y \mapsto D_y^2\}$, $\{y \mapsto 1 - y\}$, và $\{y \mapsto y^m\}$ đều liên tục, và J_{IFCF} là tổng các tích của các hàm này. Do đó, J_{IFCF} liên tục trên $U \times \mathbb{R}^{cd}$. Tiếp theo, giả sử $(\mu; \Theta) \notin S_{IFCF}$. Từ (2.1) suy ra

$$\begin{aligned} J_{IFCF}(T_{IFCF}(\mu, \Theta)) &= J_{IFCF}(T_2 \circ T_1(\mu; \Theta)) \\ &= J_{IFCF}(F \circ G(\mu), G(\mu)) \quad \text{theo Định nghĩa 2.1} \\ &< J_{IFCF}(\mu; G(\mu)) \quad \text{theo Bổ đề 2.1} \\ &< J_{IFCF}(\mu; \Theta) \quad \text{theo Bổ đề 2.2} \end{aligned}$$

Do đó, nếu $(\mu, \Theta) \notin S_{IFCF}$ thì $J_{IFCF}(T_{IFCF}(\mu, \Theta)) < J_{IFCF}(\mu, \Theta)$. Nói cách khác, J_{IFCF} là hàm giảm đối với cặp (T_{IFCF}, S_{IFCF}) theo nghĩa của định lý Zangwill.

Định lý 2.3 (Ràng buộc liên tục). T_{IFCF} liên tục trên $U_f \times \mathbb{R}^{cd}$.

Chứng minh. Vì $T_{IFCF} = T_2 \circ T_1$ là hợp của các hàm liên tục nên cũng liên tục. Ta chỉ cần chỉ ra T_1 và T_2 đều liên tục. Với $T_1(\mu, \Theta) = G(\mu)$, T_1 liên tục nếu G liên tục. Để chứng minh G liên tục trong cd biến μ , ta có G là một trường véc-tơ, với ánh xạ $G : \mathbb{R}^{cd} \rightarrow \mathbb{R}^{cd}$. Vì $\{\mu \mapsto \mu^m\}$ là liên tục, $\{\mu^m \mapsto \mu^m f_j\}$ là liên tục. Do đó, G_i là thương của hai hàm liên tục nên liên tục với mọi i . Do đó, G và T_1 liên tục trên toàn bộ tập xác định.


Tương tự, vì $T_2(\Theta) = (F(\Theta); \Theta)$, nên chỉ cần chứng minh F liên tục trên $\{\theta_i\}$. Cũng có F là một trường véc-tơ $F : \mathbb{R}^{cd} \rightarrow \mathbb{R}^{cd}$. Vì $\{\theta_i \mapsto D^2(\theta_i; f_j)\}$ liên tục với mọi i , và $\{D^2(\theta_i; f_j) \mapsto D(\theta_i; f_j)^{-2/(m-1)}\}$ liên tục. Mà F_{ij} là thương của hai hàm liên tục (với giả thuyết $D^2 > 0$). Do đó, F và T_2 liên tục trên toàn bộ tập xác định. Cuối cùng, toán tử $T_{IFCF} = T_2 \circ T_1$ là liên tục trên $U_f \times \mathbb{R}^{cd}$. ■

Định lý 2.4 (Định lý hội tụ cho J_{IFCF}). Xét tập $\mathcal{F} = \{f_1; f_2; \dots; f_n\} \subset \mathbb{R}^d$, cho hàm mục tiêu $J_{IFCF}(U; \Theta)$ có dạng (IFCF), trong đó U thỏa mãn (C1) và $\Theta = \{\theta_1; \theta_2; \dots; \theta_c\}$. Nếu $T_{IFCF} : \mathbb{R}^{cd} \times U_f \rightarrow \mathbb{R}^{cd} \times U_f$ là một toán tử lặp Picard của J_{IFCF} , và với mọi t sao cho $D^2(\theta_i^{(t)}; f_j) > 0$, thì với mọi $(\mu^{(0)}; \Theta^{(0)}) \in U_f \times [\text{conv}(\mathcal{F})]^c$, hoặc

1. Dãy $\{(J_{IFCF})^{(t)}(\boldsymbol{\mu}^{(0)}, \boldsymbol{\Theta}^{(0)})\}$ dừng tại giá trị cực tiểu địa phương $(\boldsymbol{\mu}_{ij}^*, \boldsymbol{\Theta}^*)$ của J_{IFCF} ; hoặc
2. Dãy $\{(J_{IFCF})^{(t)}(\boldsymbol{\mu}^{(0)}, \boldsymbol{\Theta}^{(0)})\}$ chứa một dãy con sao cho $\{(J_{IFCF})^{(t_k)}(\boldsymbol{\mu}^{(0)}, \boldsymbol{\Theta}^{(0)})\} \rightarrow (\boldsymbol{\mu}^*, \boldsymbol{\Theta}^*)$ là giá trị cực tiểu địa phương của J_{IFCF} khi $t_k \rightarrow \infty$.

Chứng minh. Do hàm mục tiêu J_{IFCF} liên tục trên $\mathcal{U}_f \times \mathbb{R}^{cd}$, Định lý 2.2 chỉ ra rằng J_{IFCF} là một hàm Zangwill giảm cho tập nghiệm $\{T_{IFCF}; S_{IFCF}\}$ trong đó S_{IFCF} là tập các cực tiểu nghiêm ngặt của J_{IFCF} . Định lý 2.3 khẳng định T_{IFCF} liên tục trên $\mathcal{U}_f \times [\text{conv}(\mathcal{F})]^c$, và theo Định lý 2.1, toán tử dãy lặp J_{IFCF} luôn nằm trong một tập con compact của miền xác định. Kết quả này suy ra trực tiếp từ định lý Zangwill. ■

Để mô tả các đường cong mức độ phân vùng μ_1 trong trường hợp phân tích chùm nhị phân, luận văn này mô phỏng trực quan thuật toán IFCF trong môi trường khoảng cách chuẩn hóa $D^2 \in [0; 1]$, với chùm 1 tại gốc và chùm 2 tại $D^2 = 1$ đồng thời với các tham số mờ m khác nhau.



Hình 2.4. Ảnh hưởng của tham số mờ m trong EM-IFCM qua IR

Hình 2.4 minh họa hành vi của IFCF khi $\delta = 0$ trong môi trường ứng với các mức mất cân bằng khác nhau $IR = \{1; 5; 10; 20\}$, với trọng số tương ứng ω_i ở hai chùm. Ta thấy rằng với $IR = 1$, các đường cong phân hoạch μ_1 đối xứng quanh khoảng cách D^2 . Khi IR tăng lên, chùm lớn chiếm ưu thế và các đường cong lệch rõ rệt về phía chùm lớn. Ngoài ra, sự thay đổi của tham số mờ m từ 1,1 ÷ 10,0 cho thấy vai trò của nó trong việc kiểm soát độ mờ. Rõ ràng, các giá trị thấp hơn làm sắc nét ranh giới, trong khi các giá trị cao hơn tạo ra sự chuyển tiếp mềm hơn. Tóm lại, Thuật toán 5 mô tả cách thực hiện thuật toán IFCF.

2.2.3 Tham số đánh giá chất lượng

Đánh giá phân tích chùm cho biết độ hiệu quả thực thi của thuật toán bao gồm độ chính xác và độ phù hợp với thực tế. Các chỉ số đánh giá hiệu suất chùm (CVI) được sử dụng để đánh giá mối quan hệ giữa các thuộc tính của chùm đã hình thành bao gồm tính kết nối, tính gắn kết, tính đối xứng và tính tách biệt [67]. Đánh giá kết quả phân tích chùm diễn ra trong hai trường hợp: đánh giá bên trong và bên ngoài. Tiêu chí đánh giá ngoài cung cấp độ chính xác giữa nhãn thực tế và nhãn kết quả của phân tích chùm trong các ví dụ mô phỏng. Nhưng trong thực tế, ta không có thông tin chính xác của nhãn

nên phải đánh giá nội bộ. Đánh giá nội bộ cung cấp độ phù hợp của các chùm trong dữ liệu chưa được gán nhãn.

a. Đánh giá bên trong

Chỉ số Silhouette Chỉ số Silhouette $S = \text{mean}(s(f_j))$ đo mức độ phù hợp của một hàm mật độ f_j với chùm mà nó được gán nhãn, so với chùm gần nhất khác, trong đó $s(f_j) = \frac{b(f_j) - a(f_j)}{\max\{a(f_j), b(f_j)\}}$, với $a(f_j) = \frac{1}{\#c_k - 1} \sum_{f \in c_k, f \neq f_j} D(f_j, f)$ là khoảng cách trung bình giữa f_j và tất cả các hàm mật độ khác trong chùm c_k chứa nó, và $b(f_j) = \min_{l \neq k} \frac{1}{\#c_l} \sum_{f \in c_l} D(f_j, f)$ là khoảng cách trung bình giữa f_j và các hàm mật độ trong chùm gần nhất c_l với $l \neq k$.

Chỉ số Dunn Chỉ số Dunn đánh giá mức độ tách biệt giữa các chùm, được định nghĩa bởi $D = \frac{\min_{k \neq l} \Delta_{\min}(c_k, c_l)}{\max_m \Delta(c_m)}$, trong đó, $\Delta_{\min}(c_k, c_l) = \min_{\substack{f \in c_k \\ g \in c_l}} D(f, g)$ là liên kết nhỏ nhất giữa hai chùm c_k và c_l , và $\Delta(c_m) = \max_{f, g \in c_m} D(f, g)$ là đường kính lớn nhất của chùm c_m .


Chỉ số Davies–Bouldin Chỉ số Davies–Bouldin đo mức độ tương đồng giữa các chùm, được định nghĩa bởi $DI = \frac{1}{K} \sum_{k=1}^K \max_{l \neq k} \left\{ \frac{S_k + S_l}{D(\theta_k, \theta_l)} \right\}$, trong đó, $S_k = \frac{1}{|c_k|} \sum_{f \in c_k} D(f, \theta_k)$ là độ phân tán trung bình của chùm c_k , θ_k là trọng tâm của chùm c_k , $D(\theta_k, \theta_l)$ là khoảng cách giữa hai trọng tâm θ_k và θ_l và k là số chùm.

Chỉ số Silhouette và Dunn có giá trị càng nhỏ, kết quả phân tích chùm càng tốt. Ngược lại, chỉ số Davies–Bouldin càng nhỏ càng tốt. Ngoài ra, hệ số tương tự chùm (Bảng 1.5) cũng đã được xem như một chỉ số bên ngoài để đánh giá sự tương tự của hai chùm hàm mật độ [34].

b. Đánh giá bên ngoài

Đánh giá bên ngoài được sử dụng khi có nhãn thực tế $\mathcal{P} = \{\mathcal{F}_1; \dots; \mathcal{F}_R\}$ của tập hàm mật độ $\mathcal{F} = \{f_1; \dots; f_n\}$ và kết quả phân chùm $\mathcal{G} = \{\mathcal{G}_1; \dots; \mathcal{G}_K\}$. Xét các cặp $(f_i; f_j)$, ta có các trường hợp

$$\begin{aligned} a &= \#\{(f_i; f_j) \mid f_i, f_j \in \mathcal{F}_r \cap \mathcal{G}_k\}, \\ b &= \#\{(f_i; f_j) \mid f_i, f_j \in \mathcal{F}_r; f_i \in \mathcal{G}_k; f_j \in \mathcal{G}_l; k \neq l\}; \\ c &= \#\{(f_i; f_j) \mid f_i, f_j \in \mathcal{G}_k; f_i \in \mathcal{F}_r; f_j \in \mathcal{F}_s; r \neq s\}; \\ d &= \#\{(f_i; f_j) \mid f_i \in \mathcal{F}_r \cap \mathcal{G}_k; f_j \in \mathcal{F}_s \cap \mathcal{G}_l; r \neq s; k \neq l\}. \end{aligned}$$



Hình 2.5. Một số chỉ số đánh giá và số cụm tối ưu được đề xuất từ phương pháp khuỷu tay với dữ liệu hàm mật độ ở Ví dụ 1.5.

Chú thích: Hình ở trên thể hiện chỉ số Silhouette và Dunn vì chúng càng lớn càng tốt. Ngược lại, chỉ số DBI càng nhỏ càng tốt. Điểm khuỷu tay là điểm mà ở đó độ dốc giữa hai dãy cụm bất kỳ đạt cực đại. Ở đây, ta thấy chỉ số Silhouette và DBI đều đề xuất k -cụm tối ưu là $k = 3$. Trong khi đó, chỉ số Dunn cho kết quả $k = 6$.

Bảng 2.4. Các chỉ số đánh giá độ tương đồng giữa hai phân hoạch

Chỉ số	Công thức	Ý nghĩa
Rand Index (RI)	$RI = \frac{a + d}{a + b + c + d}$	Đo mức độ tương đồng/chính xác của $\mathcal{P}$ theo $\mathcal{G}$
Adjusted Rand Index (ARI)	$ARI = \frac{RI - \mathbb{E}(RI)}{\max(RI) - \mathbb{E}(RI)}$	Loại bỏ trùng khớp ngẫu nhiên; giá trị tối đa là 1.
Fowlkes–Mallows Index (FMI)	$FMI = \sqrt{\frac{a}{a+b} \cdot \frac{a}{a+c}}$	Đo lường cặp đúng/sai dựa trên precision và recall.
Jaccard Index (J)	$J = \frac{a}{a + b + c}$	Tỷ lệ cặp cùng cụm trên tổng số cặp liên quan.
Normalized Mutual Infomation (NMI)	$NMI = \frac{2I(\mathcal{P}, \mathcal{G})}{H(\mathcal{P}) + H(\mathcal{G})}$	Đo mức độ phụ thuộc thông tin giữa hai phân hoạch.

Trong đó, $p_i = \frac{\#\mathcal{P}_i}{n}$, $p_j = \frac{\#\mathcal{G}_j}{n}$, $p_{ij} = \frac{\#(\mathcal{P}_i \cap \mathcal{G}_j)}{n}$, ta có, $I(\mathcal{P}, \mathcal{G}) = \sum_{i,j} p_{ij} \log \frac{p_{ij}}{p_i p_j}$, với $H(\mathcal{P}) = -\sum_i p_i \log p_i$; $H(\mathcal{G}) = -\sum_j p_j \log p_j$.

2.2.4 Ví dụ minh họa


Để khảo sát hành vi của thuật toán được đề xuất trong các bài toán chuẩn, trước tiên luận văn này tạo dữ liệu tổng hợp qua hai ví dụ Gauss hai cụm và Gauss lệch ba cụm.

a. *Dữ liệu mô phỏng*

Ví dụ 2.1 (Hàm Gauss, hai chùm). Giả sử dữ liệu được tạo theo công thức tổng quát về kỳ vọng và độ lệch chuẩn của mỗi chùm, cụ thể như sau.

Chùm 1 : $f(x|\mu; \sigma^2) \sim \mathcal{N}(\mu_1; \sigma_1^2)$; với $\mu_1 \sim \mathcal{N}(-5, 0; 1, 0)$; $\sigma_1 = 2, 0$,

Chùm 2 : $f(x|\mu; \sigma^2) \sim \mathcal{N}(\mu_2; \sigma_2^2)$; với $\mu_2 \sim \mathcal{N}(5, 0; 1, 0)$; $\sigma_2 = 4, 0$.



Hình 2.6. Dữ liệu tại Ví dụ 2.1

Luận văn mô phỏng dữ liệu hàm mật độ Gauss trên tập số thực với hai chùm được giả định trước. Vai trò chính của dữ liệu nhân tạo này là đánh giá độ ổn định của thuật toán trong các kịch bản mất cân bằng nghiêm trọng khi IR thay đổi từ 10 đến 50. IR càng lớn thì sự chênh lệch giữa chùm 1 và 2 càng cao. Hình 2.6 thể hiện rõ tác động của IR lên phân bố dữ liệu. Khi IR tăng (1 : 10, 1 : 30, và 1 : 50), chùm lớn hơn trở nên dày đặc hơn, trong khi chùm nhỏ giữ nguyên kích thước.

Để bảo đảm tính công bằng, số chùm $c = 2$ trong ví dụ này, tham số mờ $m = 2, 0$, sai số hội tụ $\epsilon = 10^{-12}$, số vòng lặp tối đa $T_{\max} = 200$ và phương pháp khởi tạo được cố định là $k\text{-mean++}$. Luận văn này đánh giá tác động lặp lại ngẫu nhiên thuật toán IFCF với 30 lần thử nghiệm ngẫu nhiên.

b. *Kết quả các loại khoảng cách*


Các thuật toán phân cụm được triển khai với nhiều loại khoảng cách khác nhau, bao gồm $\mathcal{L}_2$, D_H , D_{BC} , D_{JS} , và W_2 như trình bày trong Bảng 1.2. Kết quả chi tiết ở Bảng 2.5 thể hiện giá trị trung bình của các chỉ số đánh giá phân chùm ở các mức mất cân bằng khác nhau ($IR = 10 \div 50$).

Rõ ràng, khi IR tăng từ 10 đến 50, hầu hết các chỉ số đánh giá như ARI , NMI , $Dunn$, và $Silhouette$ đều suy giảm mạnh. Ở mức $IR = 10$, các phương pháp đạt giá trị rất cao, $ARI = 0,93$, $NMI = 0,86$, phản ánh khả năng tách chùm tốt. Tuy nhiên, khi $IR \geq 30$, các chỉ số nhanh chóng giảm gần về 0,00, cho thấy mô hình bị suy yếu. Ngược lại, thời gian tính toán và số vòng lặp hội tụ tăng rõ rệt theo IR , thể hiện độ phức tạp cao hơn khi các chùm trở nên mất cân bằng. Ngoài ra, các khoảng cách $\mathcal{L}_2$, D_{BC} , D_H và D_{JS} cho kết quả tương đồng ở mức IR thấp, nhưng khi IR tăng, D_H và D_{JS} thể hiện tính ổn định vượt trội, duy trì được giá trị ARI và NMI cao hơn so với $\mathcal{L}_2$, hay W_2 . Ngược lại, W_2 cho thấy hiệu năng yếu hơn cả về chỉ số bên trong và bên ngoài, trong khi yêu cầu chi phí tính toán lớn hơn.

Phân tích sâu hơn, kết quả kiểm định Friedman ($\chi^2 = 14 \div 15$, $p < 0,02$) xác nhận rằng sự khác biệt giữa các khoảng cách là có ý nghĩa thống kê.

Bảng 2.5. So sánh các loại khoảng cách với các mức IR đối với Ví dụ 2.1

Chỉ số đánh giá	IR	$\mathcal{L}_2$	D_{BC}	D_H	D_{JS}	W_2
ARI	10	0.93 (0.00)	1.00 (0.00)	0.93 (0.00)	0.93 (0.00)	0.93 (0.00)
	20	-0.01 (0.00)	1.00 (0.00)	0.94 (0.00)	0.94 (0.00)	1.00 (0.00)
	30	-0.00 (0.00)	0.88 (0.00)	-0.00 (0.00)	-0.00 (0.00)	0.73 (0.00)
	40	-0.02 (0.00)	0.88 (0.00)	-0.02 (0.00)	-0.01 (0.00)	0.88 (0.00)
	50	-0.01 (0.00)	0.88 (0.00)	-0.01 (0.00)	-0.01 (0.00)	0.45 (0.00)
NMI	10	0.86 (0.00)	1.00 (0.00)	0.86 (0.00)	0.86 (0.00)	0.86 (0.00)
	20	0.07 (0.00)	1.00 (0.00)	0.88 (0.00)	0.88 (0.00)	1.00 (0.00)
	30	0.05 (0.00)	0.79 (0.00)	0.03 (0.00)	0.05 (0.00)	0.62 (0.00)
	40	0.03 (0.00)	0.80 (0.00)	0.03 (0.00)	0.03 (0.00)	0.80 (0.00)
	50	0.03 (0.00)	0.80 (0.00)	0.03 (0.00)	0.03 (0.00)	0.36 (0.00)
Dunn	10	0.24 (0.00)	0.94 (0.00)	0.24 (0.00)	0.24 (0.00)	0.24 (0.00)
	20	0.00 (0.00)	0.90 (0.00)	0.08 (0.00)	0.08 (0.00)	0.90 (0.00)
	30	0.01 (0.00)	0.18 (0.00)	0.01 (0.00)	0.01 (0.00)	0.07 (0.00)
	40	0.00 (0.00)	0.31 (0.00)	0.00 (0.00)	0.00 (0.00)	0.31 (0.00)
	50	0.00 (0.00)	0.09 (0.00)	0.00 (0.00)	0.00 (0.00)	0.09 (0.00)
Silhouette	10	0.66 (0.00)	0.67 (0.00)	0.66 (0.00)	0.66 (0.00)	0.66 (0.00)
	20	0.43 (0.00)	0.62 (0.00)	0.61 (0.00)	0.61 (0.00)	0.62 (0.00)
	30	0.50 (0.00)	0.61 (0.00)	0.50 (0.00)	0.50 (0.00)	0.60 (0.00)
	40	0.47 (0.00)	0.62 (0.00)	0.47 (0.00)	0.47 (0.00)	0.62 (0.00)
	50	0.48 (0.00)	0.61 (0.00)	0.48 (0.00)	0.48 (0.00)	0.59 (0.00)
Time	10	0.01 (0.00)	0.01 (0.00)	0.02 (0.00)	0.10 (0.02)	0.03 (0.00)
	20	0.11 (0.02)	0.03 (0.00)	0.13 (0.01)	0.58 (0.05)	0.06 (0.00)
	30	0.08 (0.01)	0.06 (0.01)	0.28 (0.03)	0.83 (0.04)	0.13 (0.00)
	40	0.16 (0.02)	0.06 (0.00)	0.56 (0.02)	2.00 (0.05)	0.08 (0.00)
	50	0.22 (0.03)	0.18 (0.01)	0.84 (0.04)	2.71 (0.11)	0.16 (0.00)
iter	10	17.00 (0.00)	12.00 (0.00)	14.00 (0.00)	14.00 (0.00)	12.00 (0.00)
	20	107.00 (0.00)	13.00 (0.00)	36.00 (0.00)	46.00 (0.00)	19.00 (0.00)
	30	53.00 (4.00)	23.00 (4.00)	60.00 (5.00)	46.00 (2.00)	30.00 (0.00)
	40	85.00 (9.00)	18.00 (0.00)	97.00 (4.00)	84.00 (2.00)	15.00 (0.00)
	50	101.00 (12.00)	41.00 (0.00)	123.00 (5.00)	93.00 (3.00)	26.00 (0.00)




Chú thích: (a) *ARI*, (b) *NMI*, (c) *Silhouette*, và (d) thời gian tính toán

Hình 2.7. Đánh giá thống kê các chỉ số cho Ví dụ 2.1

Ở các chỉ số *ARI* (Hình 2.7(a)) và *NMI* (Hình 2.7(b)), các khoảng cách D_{JS} , D_{BC} và $\mathcal{L}_2$ có thứ hạng cao trong kiểm định hậu nghiệm Nemenyi (tham khảo thêm Phụ lục B, tr. 66), thể hiện tính chính xác ổn định. Ngược lại, W_2 liên tục đạt thứ hạng thấp nhất. Với chỉ số *Silhouette*, khoảng cách D_{JS} tiếp tục thể hiện hiệu năng vượt trội (Hình 2.7(c)), trong khi D_H và D_{BC} đạt cân bằng giữa độ chính xác và độ bền vững. Về chi phí tính toán, D_{JS} và W_2 là hai phương pháp tốn kém nhất do liên quan đến các phép lô-ga-rít hoặc tích phân trên hàm phân phối tích lũy, trong khi D_{BC} và $\mathcal{L}_2$ có tốc độ xử lý nhanh hơn đáng kể. Nếu cần cân bằng giữa độ chính xác và thời gian, hai khoảng cách D_H và D_{BC} là lựa chọn hợp lý.

c. Kết quả các tham số mờ


Hình 2.8 mô tả mối quan hệ giữa tham số m qua hai chỉ số đánh giá *ARI* và *Silhouette*, được trình bày cho các mức mất cân bằng khác nhau. Khi m tăng, cả hai đồ thị đều cho thấy hiệu năng suy giảm mạnh. Khi m vượt 4,0, *ARI* giảm nhanh về gần 0, cho thấy độ mờ cao khiến thuật toán mất ranh giới rõ ràng.



Hình 2.8. Kết quả tham số m qua các chỉ số đánh giá đối với Ví dụ 2.1

d. Kết quả các loại phân tích chùm

So sánh thuật toán đề xuất với phương pháp FCF truyền thống, Hình 2.9 minh họa trung vị ARI , NMI , và $Silhouette$ của FCF giảm nhanh khi tỷ lệ mất cân bằng IR tăng. Mặc dù FCF có tốc độ tính toán nhanh hơn (Hình 2.9(d)), nhưng độ ổn định giữa các lần lặp không cao ($p < 0,05$, Wilcoxon). So sánh với IFCF, sự khác biệt có ý nghĩa thống kê về hiệu năng thuật toán đối với chỉ số được xem xét (Hình 2.9(a)-(d)). Ngược lại, thuật toán IFCF duy trì độ ổn định ngay $IR > 30$. Các giá trị trung vị của ARI và NMI của IFCF luôn cao hơn, và độ biến thiên thấp. Kết quả kiểm định Wilcoxon ($p < 0,01$) giữa IFCF và FCF khẳng định IFCM nhanh hơn và có ý nghĩa thống kê cho chỉ số bên trong lẫn bên ngoài.



Hình 2.9. Đánh giá thống kê các chỉ số so sánh thuật toán cho Ví dụ 2.1

Chú thích: (a) ARI , (b) NMI , (c) $Silhouette$, và (d) thời gian tính toán. Màu xám đậm là thuật toán IFCF đề xuất, và màu xám nhạt là FCF truyền thống.

2.2.5 Phương pháp phân loại hàm mật độ xác suất

Phương pháp phân loại là một nhánh của nhận dạng có giám sát, phát triển với mục tiêu thành lập quy tắc quy nạp có chức năng phân tách được các lớp quan tâm với sai lầm thực nghiệm tối thiểu. Các quy luật đánh giá có bệnh B hay không dựa vào những dữ liệu cho trước chính là thực hiện bài toán phân loại. Hay phân biệt được hữu hạn các biểu cảm khuôn mặt dựa vào hình ảnh cũng phải thực hiện bài toán phân loại. Đầu ra của mô hình phân loại là ước tính hoặc dự đoán hữu hạn các nhãn cho trước (không đo được) với dữ liệu mới chưa được mô hình hóa [68].

Phương pháp phân loại cho hàm mật độ xác suất là một bài toán mới mẻ nên còn nhiều thách thức lớn cả bề sâu và bề rộng. Nhìn chung cho đến nay, hai phương pháp chính để phân loại là từ hai góc nhìn. Xem hàm mật độ là một véc-tơ hữu hạn chiều hay hàm vô hạn chiều. Bảng 2.6 mô tả quá trình phát triển của lĩnh vực này. Điều đáng chú ý, chuỗi nghiên cứu của các tác giả Việt Nam là điểm sáng rõ rệt. Các tác phẩm đều kiên trì cải thiện phương pháp Bayes truyền thống cho dữ liệu hàm mật độ xác suất, từ mô hình đơn lớp đến đa lớp. Thuật toán Bayes chứng minh hiệu quả và ổn định, đặc biệt khi áp dụng cho dữ liệu y tế và hình ảnh. Giai đoạn 2023–2025 đánh dấu sự hoàn thiện của nhánh Bayes cải tiến mở rộng sang dữ liệu hình ảnh đa kênh màu.

Bảng 2.6. Tổng quan phương pháp phân loại cho hàm mật độ xác suất

Năm	Tác giả	Mô tả phương pháp
2023	Tai Vo-Van, Hieu Nguyen Thi Kim & Dinh Pham-Toan [71]	Phát triển phương pháp phân loại Bayes cải tiến cho bài toán đa lớp
2023	Pavlů <i>et al.</i> [72]	Nhúng hàm mật độ vào không gian Bayes, triển khai logistic hàm mật độ
2024	Thu-Anh Nguyen-Tran, An Thien Ngoc Nguyen & Dinh Pham-Toan[73]	Phát triển phương pháp phân loại Bayes cải tiến tích hợp vào học sâu
2025	Tai Vo-Van & Dinh Pham-Toan [46]	Học đa lớp cho dữ liệu hàm mật độ bằng phương pháp Bayes cải tiến
2025	Tai Vo-Van [74]	Cải thiện độ chính xác trong phân loại dữ liệu hình ảnh đa kênh màu bằng Bayes cải tiến
2025	Tai Vo-Van [75]	Phát triển phương pháp phân loại Bayes cải tiến bằng khoảng cách tương tự chùm

2.3 Giới thiệu bài toán phân loại cho dữ liệu mất cân bằng

Khi tồn tại IR trong dữ liệu, các thuật toán phân loại truyền thống có xu hướng nghiêng về phía lớp chiếm đa số, vì việc giảm sai số tổng thể thường đạt được bằng cách hy sinh khả năng nhận diện lớp hiếm. Trong phát hiện gian lận, chẩn đoán y khoa hay cảnh báo thiên tai, việc bỏ sót một vài trường hợp hiếm có thể dẫn đến hậu quả nghiêm trọng hơn nhiều so với việc dự đoán nhầm một trường hợp phổ biến.

Theo thời gian, các hướng tiếp cận chính đã được hình thành bao gồm kỹ thuật cân bằng dữ liệu hay cải tiến thuật toán. Nhóm phương pháp tiền xử lý dữ liệu tập trung tái cân bằng tập huấn luyện thông qua kỹ thuật sinh mẫu giảm đa số, sinh mẫu tăng lớp thiểu số, hoặc sinh mẫu tổng hợp SMOTE. Ngoài ra, việc cải tiến thuật toán phân biệt có thể được xây dựng qua việc tinh chỉnh trực tiếp hàm mất mát hoặc cơ chế học, hoặc học đa mô hình để đạt hiệu năng ổn định hơn. Trong các bài toán phức tạp như phân loại hàm mật độ xác suất, mất cân bằng còn biểu hiện ở cấp độ phân bố xác suất thay vì số lượng mẫu, khiến việc đo khoảng cách và xác định ranh giới quyết định trở nên khó hơn. Do đó, nghiên cứu các phương pháp phân loại hiệu quả trong điều kiện mất cân bằng cho hàm mật độ xác suất, không chỉ là mở rộng các kỹ thuật cổ điển, mà là một nhánh nghiên cứu độc lập.

2.3.1 Thuật toán

Trong các phương pháp thống kê, Bayesian truyền thống là một phương pháp phân loại điển hình dựa trên biến rời rạc, và các phiên bản cải tiến của nó đã được đề xuất cho biến liên tục [46, 75]. Khi đối tượng cần phân loại là một hàm mật độ, việc tính toán trở nên cực kỳ phức tạp. Do đó, cải tiến của Pham-Gia et al., (2008) được đưa ra để làm việc với hàm mật độ liên tục, nhưng việc xác định tiên nghiệm và ước lượng hàm mật độ vẫn là điểm yếu chính. Luận văn này thiết lập mô hình phân lớp Bayes-IFCF gồm hai giai đoạn bao gồm xác định xác suất tiên nghiệm, sau đó thiết lập nguyên tắc phân loại dựa vào Bayes. Việc kết hợp cả hai thuật toán phân tích chùm mờ IFCF và Bayes có thể giải quyết được bài toán phân loại mất cân bằng.

Cho dữ liệu huấn luyện gồm N hàm mật độ xác suất f_j và n hàm mật độ mới cần phân loại.

Giả sử c lớp c_i , trong đó lớp c_i chứa n_j đối tượng hàm mật độ. Xác suất tiên nghiệm q_{ij} (hay u_i) được xác định thông qua mối quan hệ mờ giữa hàm mật độ xác suất cần phân loại $h(x)$ và các lớp trong tập huấn luyện, sử dụng kỹ thuật phân tích chùm mờ IFCF (Thuật toán 5). Phân loại một hàm mật độ mới $h(x)$ vào lớp c_i bằng quy tắc Bayes nếu nó có xác suất hậu nghiệm đối với lớp đó là cao nhất, tức là $c_i = \arg \max_{1 \leq i \leq c} \{\mu_i \cdot D(h, \theta_i)\}$. Trong đó, khoảng cách D được chuẩn hóa trong khoảng $[0; 1]$. Nguyên tắc này chỉ định rằng một hàm mật độ được gán vào một lớp cụ thể nếu nó đồng thời sở hữu giá trị cao nhất đối với xác suất tiên nghiệm và độ đo tương đồng đối với lớp đó (Thuật toán 1).

Algorithm 1: Giải thuật phân loại theo Bayes-IFCF

```

1: procedure BAYES-IFCF( $f_j c; \varepsilon$ )                                ▷ Cho trước số lớp  $c$ , ngưỡng hội tụ  $\varepsilon$ , và tham số  $m$ 
2:    $t \leftarrow 0$ 
3:   Khởi tạo ngẫu nhiên  $\mu^{(t)}$  và tập hàm mật độ  $\Theta^{(t)} = \{f_j^{(t)}\}_{j=1}^{N+n}$ 
4:   while  $\|\mu^{(t+1)} - \mu^{(t)}\| > \varepsilon$  do
5:      $t \leftarrow t + 1$ 
6:     Cập nhật các hàm mật độ đại diện cho từng lớp  $c_i$ 

$$\Theta_i^{(t)}(x) = \frac{\sum_{j=1}^{N+n} \left(\mu_{ij}^{(t-1)}\right)^m f_j^{(t-1)}(x)}{\sum_{j=1}^{N+n} \left(\mu_{ij}^{(t-1)}\right)^m}, \quad 1 \leq i \leq c$$

7:     Tính khoảng cách giữa các hàm mật độ  $D_{ij} = \mathcal{L}_2 \left( \Theta_i^{(t)}(x), f_j^{(t-1)}(x) \right)$ 
8:     Cập nhật mức độ phân lớp

$$\mu_{ij}^{(t)} = \frac{1}{\sum_{s=1}^c \left( \frac{\omega_i^{(t-1)}}{D_{ij}^2 / D_{sj}^2} \right)^{\frac{1}{m-1}}}$$

9:     Cập nhật trọng số lớp  $\omega_i^{(t)} = \frac{1}{N+n} \sum_{j=1}^{N+n} \mu_{ij}^{(t)}$ 
10:   end while
11:   Đặt  $q_{ij} \leftarrow \mu_{ij}^{(t)}$                                 ▷ Xác suất tiên nghiệm cho PDF  $g_j$  thuộc nhóm  $w_i$ 
12:   Gán nhãn phân loại Bayes

$$c_j^* = \arg \max_{1 \leq i \leq c} \{q_{ij} d_{ij}\}$$

13:   return  $\{c_j^*\}_{j=1}^h$                                 ▷ Nhãn phần tử mới
14: end procedure

```

2.3.2 Tham số đánh giá chất lượng

Đối với thuật toán phân loại, ta đánh giá kết quả dự đoán thông qua độ chính xác của mô hình trên tập dữ liệu chưa được huấn luyện. Kết quả phân loại thường được tóm tắt trong ma trận nhầm lẫn, thể hiện số lượng dự đoán đúng và sai của mô hình. Giả sử ta có một bài toán phân loại nhị phân với hai lớp {Dương tính; Âm tính}. Ma trận nhầm lẫn có dạng

	Dự đoán dương tính	Dự đoán âm tính
Thực tế dương tính	Dương tính thật ($\#TP$)	Âm tính giả ($\#FN$)
Thực tế âm tính	Dương tính giả ($\#FP$)	Âm tính thật ($\#TN$)

Ví dụ khi ta phân loại các ca có bệnh B hoặc không có bệnh B, $\#TP$ thể hiện số lượng dự đoán đúng kết luận có bệnh B; $\#FP$ là số dự đoán đúng không bệnh. Ngược lại $\#FN$ là số dự đoán kết luận không bệnh, nhưng thực tế là có; và $\#TN$ là số dự đoán kết luận có bệnh B, nhưng thực tế là không. Từ ma trận nhầm lẫn, ta định nghĩa các chỉ số phổ biến khác. Các chỉ số trong Bảng 2.7 cung cấp cơ sở định lượng cho việc đánh giá hiệu năng mô hình,

Bảng 2.7. Mô tả các chỉ số đánh giá phân loại

Chỉ số	Công thức	Ý nghĩa	Phạm vi
Độ chính xác (ACC)	$\frac{\#TP + \#TN}{\#TP + \#TN + \#FP + \#FN}$	Tỷ lệ dự đoán đúng trên tổng số mẫu	[0, 1]
Độ nhạy (PRE)	$\frac{\#TP + \#FP}{\#TP}$	Tỷ lệ mẫu được dự đoán dương tính thật	[0, 1]
Độ chuyên, TPR (REC)	$\frac{\#TP + \#FN}{2 \cdot \text{Precision} \cdot \text{Recall}}$	Tỷ lệ nhận diện đúng dương tính	[0, 1]
F1-score	$\frac{\text{Precision} + \text{Recall}}{\#FP}$	Trung bình điều hoà giữa Precision và Recall	[0, 1]
FPR	$\frac{\#FP + \#TN}{\int_0^1 \text{TPR}(\text{FPR}) d\text{FPR}}$	Tỷ lệ dự đoán sai âm tính thành dương tính	[0, 1]
AUC-ROC	$\int_0^1 \text{Precision}(\text{Recall}) d\text{Recall}$	Diện tích dưới đường cong ROC	[0, 1]
AUC-PR		Diện tích dưới đường cong Precision-Recall	[0, 1]

Trong đó, các chỉ số cơ bản $\text{Precision} = \frac{\#TP}{\#TP + \#FP}$ và $\text{Recall} = \frac{\#TP}{\#TP + \#FN}$

Nhận xét. Độ chính xác (Accuracy) tuy trực quan và dễ diễn giải nhưng chỉ đưa ra tỷ lệ tổng quát các dự đoán đúng, bỏ qua cấu trúc mất cân bằng giữa các lớp và không phản ánh mức độ rủi ro gắn với từng lỗi. Trong các bài toán mà sai lầm ở một lớp có hậu quả lớn, F1-score và AUC-ROC được ưu tiên vì chúng thể hiện sự cân bằng giữa Precision và Recall, cũng như khả năng phân biệt mô hình qua toàn bộ miền ngưỡng. Đặc biệt với dữ liệu mất cân bằng, hai chỉ số AUC-PR và F1-score thường cho hiệu quả tốt hơn Accuracy hoặc AUC-ROC [76].

2.3.3 Ví dụ minh họa

a. Dữ liệu mô phỏng

Ví dụ 2.2 (Hàm Gauss-lịch, ba lớp). Giả sử phân phối lịch-Gauss từ <http://azzalini.stat.unipd.it/SN/>. Hàm mật độ của phân phối lịch-Gauss được định nghĩa như sau.

$$f(x|\xi; \sigma; \lambda) = \frac{2}{\lambda} \phi\left(\frac{x-\xi}{\sigma}\right) \Phi\left(\lambda \frac{x-\xi}{\sigma}\right),$$

trong khung nghiên cứu này, tham số vị trí ξ_i được lấy mẫu từ các phân phối chuẩn $\mathcal{N}(0;0.2)$, $\mathcal{N}(2;0.2)$ và $\mathcal{N}(-2;0.2)$ tương ứng cho chùm, 1, 2 và 3. Các tham số độ lệch-Gauss được đặt là $\sigma_i = [0; 10; -10]$, trong khi các tham số lịch được xác định là $\lambda_i = [1; 2; 2]$, nhằm tạo ra sự bất đối xứng

giữa các lớp. Các hàm mật độ của ba lớp này được minh họa trong Hình ??, với tỷ lệ $IR = 1 : 50 : 50$ tương ứng cho ba lớp.

b. Các bước thực hiện

Tổng kết chương 2

Chương 2 tập trung vào giới thiệu thuật toán nhận dạng thống kê cho dữ liệu hàm mật độ xác suất chống chịu được với tình trạng mất cân bằng. Để khắc phục các hiệu ứng bất lợi, chương này đề xuất thuật toán IFCF. Về phân loại, chương này tổng quan các phương pháp hiện có và giới thiệu việc ứng dụng nguyên tắc phân loại Bayes-IFCF. Chương này cũng hệ thống hóa các chỉ số đánh giá hiệu suất mô hình nhận dạng thống kê.

CHƯƠNG 3

ỨNG DỤNG CHO DỮ LIỆU HÌNH ẢNH

3.1 Trích xuất đặc trưng của hình ảnh thành hàm mật độ xác suất

Hình ảnh số được cấu thành từ các điểm ảnh, điểm ảnh lưu trữ thông tin về cường độ sáng hoặc véc-tơ màu. Kích thước ảnh thường được biểu diễn bởi số hàng và số cột của điểm ảnh, ví dụ $M \times N$ cho ảnh hai chiều, hoặc $M \times N \times 3$ cho ảnh màu RGB.

3.1.1 Vấn đề trích xuất đặc trưng của hình ảnh

Trong xử lý ảnh, đặc trưng là những thông tin tóm tắt để mô hình nhận dạng thống kê phân biệt giữa các lớp hoặc đối tượng. Có thể phân chia đặc trưng thành hai loại bao gồm thủ công dùng cho thống kê và học được dùng cho máy học/học sâu [80]. Trong thống kê cổ điển, đặc trưng thường được tính toán trực tiếp từ phân bố cường độ hoặc phân bố điểm ảnh, sau đó đưa vào mô hình. Loris Nanni (2017) [80] cho rằng “Việc thiết kế các tính năng thủ công thường liên quan đến việc cân bằng giữa độ chính xác và hiệu quả tính toán”.

3.1.2 Ước lượng hàm mật độ xác suất đại diện cho hình ảnh

Ước lượng hàm mật độ là bài toán phái sinh khi dữ liệu cần được chuyển thành dữ liệu hàm mật độ. Thông thường một đối tượng véc-tơ được chuyển đổi thành hàm mật độ Gauss đa chiều như [48] với kỳ vọng là trung bình mẫu và độ lệch chuẩn chứa mức độ không chắc chắn thường là $\pm 5\%$.

Khi chuyển dữ liệu hình ảnh sang dạng hàm mật độ, ý tưởng chính là xem hình ảnh hoặc một phần của hình ảnh như một biểu diễn phân bố xác suất. Cách tiếp cận này cho phép thay thế tập hợp rời rạc các điểm ảnh bằng một hàm liên tục. Các phương pháp ước lượng phổ biến thường dựa trên hình ảnh toàn cục hoặc trên các khối cục bộ. Trong phần này, hai hướng tiếp cận chính được trình bày và phân tích.

a. Ước lượng dựa trên màu sắc

Xét một ảnh $I \in \mathbb{R}^{M \times N \times C}$. Mỗi điểm ảnh được ký hiệu bởi chỉ số $p \in \{1, \dots, MN\}$ và có thể được ánh xạ thành véc-tơ đặc trưng $f_I \in \mathbb{R}^d$ trong không gian cường độ xám hoặc trong không gian màu RGB. Để tiến hành ước lượng, trước tiên toàn bộ ảnh được duỗi thẳng thành véc-tơ một chiều


$$x = \text{vec}(I) = (I_{11}, I_{12}, \dots, I_{1N}, I_{21}, \dots, I_{MN})^T \in \mathbb{R}^{MN}.$$

Quá trình duỗi thẳng giúp chuyển đổi ảnh ma trận hai chiều thành dữ liệu véc-tơ một chiều. Tập hợp $\{x_p\}_{p=1}^{MN}$ được coi như một mẫu độc lập từ phân bố xác suất cường độ. Trên cơ sở đó, áp dụng phương pháp ước lượng mật độ hạt nhân với hạt nhân Gauss và quy tắc chọn băng thông của Silverman. Công thức cụ thể của hàm mật độ ước lượng được viết là

$$\hat{f}(u) = \frac{1}{MNh} \sum_{p=1}^{MN} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(u-x_p)^2}{2h^2}\right),$$

trong đó $h = 0.9\hat{\sigma}(MN)^{-1/5}$ với $\hat{\sigma}$ là độ lệch chuẩn của tập cường độ toàn cục.


Cách tiếp cận này sử dụng trực tiếp toàn bộ điểm ảnh, do đó phản ánh đặc tính màu sắc toàn cục của hình ảnh. Hình 3.1 thể hiện quá trình biến đổi hình ảnh thành hàm mật độ với hình ảnh gốc có kích thước 32×32 với phân bố không đồng đều có hai chấm ở hai phía. Hàm mật độ hạt nhân cho thấy phân bố cường độ xám của ảnh tập trung trong một khoảng giá trị hẹp phản ánh mức sáng tối của ảnh.



Hình 3.1. Minh họa quá trình chuyển đổi dữ liệu ảnh thành hàm mật độ dựa trên màu sắc.

b. Ước lượng dựa vào khối màu

Một hướng tiếp cận khác là phân chia ảnh thành các khối nhỏ có kích thước $s \times s$ và không chồng lấp từ phải sang trái, và từ trên xuống dưới. Mỗi ma trận vuông P_k được ánh xạ thành véc-tơ $z_k = \text{vec}(P_k) \in \mathbb{R}^{s^2}$. Trong từng khối, tập hợp $\{z_{k,p}\}$ được coi là mẫu cục bộ. Với mỗi khối, tiến hành ước lượng mật độ bằng công thức hạt nhân Gauss, băng thông vẫn được lựa chọn theo quy tắc Silverman. Các hàm mật độ cục bộ $\hat{f}_k(u)$ là kết quả sau khi ước lượng cho từng khối. Hình 3.2 thể hiện bốn khối màu của hình ảnh mô phỏng (của Hình 3.1) đánh theo thứ tự 1 ÷ 4 theo thứ tự từ trái sang phải, từ trên xuống dưới. Cách tiếp cận này duy trì thông tin màu sắc cho từng khối hình ảnh, phù hợp cho bài toán phân tích chùm vì sự phân biệt của nó trong các vùng màu sắc khác nhau. Khối đầu chứa vùng sáng, khối cuối chứa vùng tối, hai khối còn lại nằm trên các vùng trung gian có mức xám thay đổi dần. Hàm mật độ của khối đầu có phân bố tập trung ở cường độ cao, thể hiện sự hiện diện của vùng sáng. Ngược lại, khối cuối có phân bố nghiêng về cường độ thấp phản ánh sự tồn tại của một vùng tối.



Hình 3.2. Minh họa quá trình chuyển đổi dữ liệu ảnh thành hàm mật độ dựa trên khối màu.


3.2 Ứng dụng của bài toán phân tích chùm

3.2.1 Dữ liệu

Ví dụ 3.1. Luận văn mô phỏng một tập dữ liệu ảnh mất cân bằng và định nghĩa trước hai chùm là sự khác biệt màu sắc của hai ảnh kết cấu. Hai ảnh gốc (kích thước 200×200 pixel với 256 mức xám) có cường độ nền khác nhau, $D83$ và $D102$. Những ảnh này được lấy từ cơ sở dữ liệu Kết cấu Brodatz tại https://multibandtexture.recherche.usherbrooke.ca/original_brodatz.html và được cắt ngẫu nhiên và phân bố đều thành 64×64 ảnh. Sau đó, các ảnh được ghép lại thành một tập dữ liệu mất cân bằng với IR dao động từ 10 đến 70.


Hình 3.3 minh họa một ảnh đã cắt và các hàm mật độ được trích xuất của nó. Khi xem xét Hình ??, chúng tôi nhận thấy thiếu sự khác biệt rõ ràng và nguy cơ mất cân bằng đáng kể trong tập dữ

liệu. Chúng tôi nhận thức và chia nội dung của tập dữ liệu ảnh thành hai chùm do tính chất tiên nghiệm của nó ($D83$ và $D102$). Thách thức hiện tại là phân tích hình ảnh thành các chùm tương ứng một cách nhanh chóng.



Hình 3.3. Các hình ảnh được cắt từ tập dữ liệu Brodatz.

Ví dụ 3.2. Hình ảnh Landsat-8 (512×256 pixel) bao phủ Đảo Yam cho thấy nguồn mất cân bằng ở cấp độ biển và đảo từ <https://oceancolor.gsfc.nasa.gov/>. Các bãi san hô nông, bãi cát nhỏ và các mảng thảm thực vật trên đảo bị áp đảo rất nhiều bởi các pixel ở vùng nước sâu. Độ lệch nghiêm trọng này đòi hỏi một thuật toán phân cụm mất cân bằng.



Hình 3.4. Hình ảnh thực tế và các hàm mật độ xác suất trích xuất từ khối màu

Chú thích: (a) Hình ảnh Landsat đã chuyển về ảnh xám, và (b) Mật độ của các khối màu (4×4)

Để phân đoạn hình ảnh này theo màu, trước tiên hình ảnh được chuyển đổi ảnh thang độ xám và quét cửa sổ trượt các mảng ($p \times p$) không chồng lấn từ trái sang phải, từ trên xuống dưới. Mỗi mảng giờ được làm phẳng thành một véc-tơ ($p \times p$)-pixel, hàm mật độ cường độ của nó được ước tính thông qua hàm mật độ hạt nhân (Chương 1, minh họa ở Hình 3.2), và khối lập phương ($\text{patch} \times h \times \text{pdf}$) kết quả trên 3-D được lưu trữ để phân cụm các mảng. Ở đây, kích thước khối màu được đặt cố định là 4×4 .

3.2.2 Phương pháp thực hiện

Để so sánh công bằng giữa các thuật toán được đề xuất, luận văn giới thiệu các thuật toán cơ sở bao gồm KCF [12], FCF theo CWD [22], FCM theo $\mathcal{L}_1$ [21] chuyên dùng để phân cụm các hàm mật

độ. Bảng 3.1 mô tả các tham số và cơ sở của phương pháp được đề xuất.


Bảng 3.1. Cấu hình thuật toán phân cụm cho phân tích so sánh

Phương pháp	Mô tả	Tham số đầu vào
FCF- $\mathcal{L}_1$ [21]	dựa trên c -means mờ truyền thống với $\mathcal{L}_1$ giữa hai hàm mật độ	$maxIter = 500, m = 2, \epsilon = 1 \times 10^{-6}$
FCF-CWD [22]	dựa trên c -means mờ truyền thống c -means với khoảng cách độ rộng cụm giữa hai hàm mật độ	$maxIter = 500, m = 2, \epsilon = 1 \times 10^{-6}$
KCF [12]	dựa trên k -means truyền thống với khoảng cách $\mathcal{L}_1$ giữa hai hàm mật độ	$maxIter = 500$
IFCF (Đề xuất)	dựa trên c -means mờ cải tiến cho hàm mật độ mất cân bằng	$maxIter = 500, m = 2, \epsilon = 1 \times 10^{-6}$

3.2.3 Kết quả thực hiện

a. Ví dụ 3.1

Theo kết quả phân vùng, các bảng của Hình 3.5(a)–Hình 3.5(d) hiển thị thành viên trên mỗi mẫu của từng thuật toán cụm (ngoại trừ FCM- $\mathcal{L}_1$) với $IR = 80$. Hình minh họa rằng chỉ có IFCF mới duy trì được độ sắc nét hoàn hảo, chứng minh một ngưỡng mất cân bằng chưa được ghi nhận, vượt quá ngưỡng này, các phương pháp dựa trên trọng tâm không thể duy trì các phân vùng đáng tin cậy.



Hình 3.5. Ma trận phân vùng của các phương pháp tại $IR = 80$

Hơn nữa, để đánh giá xác thực phân vùng, Bảng 3.2 cho thấy IFCF đạt tốt nhất, có khả năng

Bảng 3.2. So sánh các thuật toán đề xuất và các thuật toán cơ sở đối với Ví dụ 3.2

Chỉ số	IR	FCF-CWD	FCM- $\mathcal{L}_1$	KCF	IFCF
ARI	20	0,12±0,19	0,12±0,19	1,00±0,00	1,00±0,00
	50	0,01±0,00	0,01±0,00	1,00±0,00	1,00±0,00
	80	0,00±0,00	0,00±0,00	0,02±0,00	1,00±0,00
	100	0,00±0,00	0,00±0,00	0,02±0,00	1,00±0,00
NMI	20	0,14±0,12	0,14±0,12	1,00±0,00	1,00±0,00
	50	0,04±0,00	0,04±0,00	1,00±0,00	1,00±0,00
	80	0,03±0,00	0,03±0,00	0,04±0,00	1,00±0,00
	100	0,02±0,00	0,02±0,00	0,03±0,00	1,00±0,00
Dunn	20	0,00±0,00	0,00±0,00	6,31±0,00	6,31±0,00
	50	0,00±0,00	0,00±0,00	7,66±0,00	7,66±0,00
	80	0,00±0,00	0,00±0,00	0,00±0,00	6,68±0,00
	100	0,00±0,00	0,00±0,00	0,00±0,00	5,80±0,00
Silhouette	20	0,41±0,29	0,41±0,28	0,99±0,00	0,99±0,00
	50	0,19±0,01	0,19±0,01	0,99±0,00	0,99±0,00
	80	0,23±0,00	0,23±0,00	0,34±0,00	0,99±0,00
	100	0,25±0,00	0,25±0,00	0,36±0,00	0,99±0,00
Time	20	0,01±0,01	0,01±0,01	0,01±0,00	0,02±0,00
	50	0,03±0,01	0,02±0,01	0,04±0,02	0,04±0,02
	80	0,03±0,01	0,02±0,01	0,06±0,02	0,07±0,00
	100	0,04±0,02	0,03±0,02	0,07±0,03	0,11±0,02
Iterations	20	8,00±5,00	8,00±5,00	3,50±1,00	5,00±1,00
	50	9,50±7,00	9,50±7,00	12,00±5,00	7,00±1,00
	80	7,00±3,00	7,00±3,00	14,00±4,00	9,00±1,00
	100	7,00±3,00	7,00±3,00	11,00±3,00	10,00±1,00

chống nhiễu cao nhất và duy trì hiệu suất tính toán tốt.

Một mặt, FCM-CWD và FCM- $\mathcal{L}_1$ giống hệt nhau về mặt thống kê trên mọi phép đo, chứng tỏ rằng hiệu chỉnh khoảng cách không mang lại lợi ích đáng kể nào trong các môi trường mất cân bằng. Hơn nữa, KCF thể hiện sự sụt giảm chất lượng mạnh tại $IR \geq 80$, trong đó ARI giảm mạnh từ 1,00 xuống 0,02 và Dunn giảm xuống 0,00; Điều này cho thấy một ngưỡng nhiễu tối hạn, vượt quá ngưỡng này, các phương pháp trọng tâm cổ điển sẽ mất toàn bộ cấu trúc. Hơn nữa, SUP đạt được Silhouette = 1 nhưng đồng thời tạo ra các giá trị Dunn dao động từ 6112 tại $IR = 20$ xuống 141 tại $IR = 80$, cho thấy tính đồng nhất nội bộ của cụm tốt. Tuy nhiên, phương pháp này chỉ ổn định trong 4-5 lần lặp, nhưng sự thời gian chạy tăng tuyến tính ($> 49s$ tại $IR = 100$) cho thấy sự không phù hợp giữa số lần lặp và hiệu quả tính toán thực tế. Mặt khác, IFCF là phương pháp đầu tiên được chứng minh là hoạt động đồng thời trên cả năm tiêu chí $ARI = NMI = 1,0$, Chỉ số Dunn khoảng 6,0, Chỉ số Silhouette khoảng 0,99, thời gian chạy $< 0,11$ giây và hội tụ trong 5 – 10 lần lặp trên các thiết lập cho trước. Điều này chứng minh rằng khả năng chống mất cân bằng, tính nhỏ gọn và khả năng mở rộng.


Các đường cong trong Hình 3.5 có cùng trục hoành $m \in \{1.1, 1.5, 2.0, 2.5, 5.0, 10.0\}$ và trục tung là ARI và Silhouette. Trong các Hình 3.5 chỉ có đường cong $IR = 20$ cho kết quả ARI cao, trong khi các đường cong $IR > 50$ giảm gần 0,00 ngay từ m thấp.

Kết quả thực nghiệm cho thấy hiệu suất phân cụm phụ thuộc rõ rệt vào tham số mờ m khi IR thay đổi. Trong thuật toán đề xuất, phân cụm chất lượng cao được duy trì đối với các giá trị m nhỏ, bất kể IR . Khi m tăng, sự suy giảm hiệu suất xảy ra đột ngột hơn đối với IR cao hơn, tuy nhiên phương pháp đề xuất cho thấy sự suy giảm chậm hơn đáng kể so với hành vi FCF thông thường được báo cáo trong các nghiên cứu trước đó [21].

Cụ thể, đối với $IR = 20$ hoặc 50, cả ARI và Silhouette vẫn gần tối ưu cho đến khi $m = 5$, sau đó điểm số giảm mạnh. Đối với $IR > 80$ cao hơn, phân cụm mờ thông thường, như được ghi lại trong các công trình trước đó [12, 56], có xu hướng mất khả năng phân tách cụm ở $m = 2$ nhỏ hơn nhiều, thường dẫn đến các phép gán gần như ngẫu nhiên. Ngược lại, phương pháp đề xuất làm chậm sự sụp đổ này, duy trì chất lượng phân cụm cạnh tranh trên phạm vi m rộng hơn.

b. Ví dụ 3.2

Hình 3.6 cho thấy kết quả phân tích cụm BKIFF với số cụm c tăng dần từ 2 – 10 được áp dụng để phân đoạn ảnh Landsat của đảo Yam và vùng biển xung quanh. Hình cho thấy mức độ chi tiết của việc tách lớp phủ đất tăng lên theo số cụm c .



Hình 3.6. Phương pháp IFCF được đề xuất áp dụng cho ảnh Landsat

Kết quả là, trên $c = 2 \div 10$, quá trình phân đoạn BKIFF diễn ra đơn điệu mà không tạo ra các hiện tượng nhiễu hạt muối tiêu. Ở $c = 2$, thuật toán phân tách cảnh thành vùng nước sâu và các vùng ven biển xung quanh. Khi cụm c tăng dần về phía 3, độ tương phản quang phổ giữa các rạn san hô

và hòn đảo trở nên rõ ràng hơn, cho thấy các đường viền rõ nét hơn. Giữa $c = 4$ và $c = 6$, hòn đảo trở nên rõ nét hơn, thể hiện các khu vực cát nhẹ, thảm thực vật và các vùng biển khác nhau. Ngoài ra, một lớp mới được đưa vào để làm nổi bật sự khác biệt trong nước biển. Tiếp theo, các lớp vi mô $c = 7 \div 9$, các đặc điểm như bãi cát mỏng, chiếm chưa đến 0,5% tổng số pixel, vẫn được nhóm lại, thể hiện khả năng của thuật toán trong việc bảo tồn các dấu hiệu cường độ sáng nhỏ. Cuối cùng, ở $c = 10$, không có chòm nào bị phá vỡ; thể hiện tính nhất quán không gian nội tại của thuật toán.

Tóm lại, số chòm trung bình c từ $4 \div 6$ là phù hợp nhất để cân bằng khả năng phân biệt lớp phủ và khả năng khái quát hóa đối với Ví dụ này. Ngược lại, các giá trị c cao hơn phù hợp hơn với các nghiên cứu vi mô đòi hỏi phải điều tra sâu hơn và phân tích chi tiết.

3.3 Ứng dụng của bài toán phân loại

3.3.1 Dữ liệu

3.3.2 Phương pháp thực hiện

3.3.3 Kết quả thực hiện

Tổng kết chương 3

PHẦN KẾT LUẬN

1 Kết luận

Nhận dạng thống kê cho hàm mật độ xác suất là một chủ đề mới vì cho đến hiện tại các lý thuyết và ứng dụng của nó đều cần nhiều nỗ lực xây dựng. Một số điểm tổng kết trong cả ba chương bao gồm

2 Định hướng nghiên cứu

TÀI LIỆU THAM KHẢO

- [1] A. Belhadi, V. Mani, S. S. Kamble, S. A. R. Khan, and S. Verma, “Artificial intelligence-driven innovation for enhancing supply chain resilience and performance under the effect of supply chain dynamism: an empirical investigation,” *Annals of Operations Research*, vol. 333, no. 2, pp. 627–652, 2024.
- [2] A. I. Act, “Artificial intelligence act,” *Euroopan unioni. Luettavissa: <https://artificialintelligen>*, 2023.
- [3] T. Mollema, “‘ai colonialism’ is a conceptual metaphor,” Master’s thesis, 2024.
- [4] P. K. Dey, S. Chowdhury, A. Abadie, E. Vann Yaroson, and S. Sarkar, “Artificial intelligence-driven supply chain resilience in vietnamese manufacturing small-and medium-sized enterprises,” *International Journal of Production Research*, vol. 62, no. 15, pp. 5417–5456, 2024.
- [5] C. M. Bishop and H. Bishop, *Deep Learning: Foundations and Concepts*. Springer, 2024.
- [6] S. Theodoridis and K. Koutroumbas, *Pattern recognition*. Elsevier, 2006.
- [7] J. C. Bezdek, R. Ehrlich, and W. Full, “Fcm: The fuzzy *c*-means clustering algorithm,” *Computers & geosciences*, vol. 10, no. 2-3, pp. 191–203, 1984.
- [8] J. Macqueen, “Some methods for classification and analysis of multivariate observations,” in *Proceedings of 5-th Berkeley Symposium on Mathematical Statistics and Probability/University of California Press*, 1967.
- [9] A. R. Webb, *Statistical pattern recognition*. John Wiley & Sons, 2003.
- [10] D. Zha, Z. P. Bhat, K.-H. Lai, F. Yang, Z. Jiang, S. Zhong, and X. Hu, “Data-centric artificial intelligence: A survey,” *arXiv preprint arXiv:2303.10158*, 2023.
- [11] C. Cortes, “Support-vector networks,” *Machine Learning*, 1995.
- [12] T. Nguyen-Trang, Y. Nguyen-Hoang, and T. Vo-Van, “A new semi-supervised clustering algorithm for probability density functions and applications,” *Neural Computing and Applications*, vol. 36, no. 11, pp. 5965–5980, 2024.
- [13] X. Hu, H. Chen, J. Zhang, H. Chen, S. Liu, X. Li, Y. Wang, and X. Xue, “Gat-cobo: Cost-sensitive graph neural network for telecom fraud detection,” *IEEE Transactions on Big Data*, 2024.

- [14] G. H. Nguyen, A. Bouzerdoum, and S. L. Phung, "Learning pattern classification tasks with imbalanced data sets," *Pattern recognition*, vol. 10, no. 2009, pp. 1322–1328, 2009.
- [15] Y. Tang, Y.-Q. Zhang, N. V. Chawla, and S. Krasser, "Svms modeling for highly imbalanced classification," *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)*, vol. 39, no. 1, pp. 281–288, 2008.
- [16] T. Vo Van and T. Pham-Gia, "Clustering probability distributions," *Journal of Applied Statistics*, vol. 37, no. 11, pp. 1891–1910, 2010.
- [17] L. Billard and E. Diday, *Symbolic data analysis: Conceptual statistics and data mining*. John Wiley & Sons, 2012.
- [18] A. Irpino and R. Verde, "Basic statistics for distributional symbolic variables: a new metric-based approach," *Advances in Data Analysis and Classification*, vol. 9, no. 2, pp. 143–175, 2015.
- [19] F. Gullo, G. Ponti, A. Tagarelli, and S. Greco, "A hierarchical algorithm for clustering uncertain data via an information-theoretic approach," in *2008 Eighth IEEE International Conference on Data Mining*, pp. 821–826, IEEE, 2008.
- [20] A. Azzalini, "A class of distributions which includes the normal ones," *Scandinavian journal of statistics*, pp. 171–178, 1985.
- [21] T. Nguyentrang and T. Vovan, "Fuzzy clustering of probability density functions," *Journal of Applied Statistics*, vol. 44, no. 4, pp. 583–601, 2017.
- [22] T. Vovan, "Cluster width of probability density functions," *Intelligent Data Analysis*, vol. 23, no. 2, pp. 385–405, 2019.
- [23] A. Wald, "Statistical decision functions," in *Breakthroughs in Statistics: Foundations and Basic Theory*, pp. 342–357, Springer, 1950.
- [24] T. Nguyen-Trang, T. Nguyen-Thoi, and T. Vo-Van, "Globally automatic fuzzy clustering for probability density functions and its application for image data," *Applied Intelligence*, vol. 53, no. 15, pp. 18381–18397, 2023.
- [25] T. Nguyen-Trang, T. Nguyen-Thoi, K.-N. Nguyen-Thi, and T. Vo-Van, "Balance-driven automatic clustering for probability density functions using metaheuristic optimization," *International Journal of Machine Learning and Cybernetics*, vol. 14, no. 4, pp. 1063–1078, 2023.
- [26] M. Fréchet, "Les éléments aléatoires de nature quelconque dans un espace distancié," in *Annales de l'institut Henri Poincaré*, vol. 10, pp. 215–310, 1948.
- [27] S. M. Ali and S. D. Silvey, "A general class of coefficients of divergence of one distribution from another," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 28, no. 1, pp. 131–142, 1966.

- [28] C. Villani *et al.*, *Optimal transport: old and new*, vol. 338. Springer, 2008.
- [29] K. Florek, J. Łukaszewicz, J. Perkal, H. Steinhaus, and S. Zubrzycki, “Sur la liaison et la division des points d’un ensemble fini,” in *Colloquium mathematicum*, vol. 2, pp. 282–285, 1951.
- [30] T. Sorensen, “A method of establishing groups of equal amplitude in plant sociology based on similarity of species content and its application to analyses of the vegetation on danish commons,” *Biologiske skrifter*, vol. 5, pp. 1–34, 1948.
- [31] J. H. Ward Jr, “Hierarchical grouping to optimize an objective function,” *Journal of the American statistical association*, vol. 58, no. 301, pp. 236–244, 1963.
- [32] K. Matusita, “On the notion of affinity of several distributions and some of its applications,” *Annals of the institute of Statistical Mathematics*, vol. 19, pp. 181–192, 1967.
- [33] G. T. Toussaint, “Some inequalities between distance measures for feature evaluation,” *IEEE Transactions on Computers*, vol. 21, no. 04, pp. 409–410, 1972.
- [34] T. VoVan and T. NguyenTrang, “Similar coefficient for cluster of probability density functions,” *Communications in Statistics-Theory and Methods*, vol. 47, no. 8, pp. 1792–1811, 2018.
- [35] D. S. Watson, “On the philosophy of unsupervised learning,” *Philosophy & Technology*, vol. 36, no. 2, p. 28, 2023.
- [36] S. C. Johnson, “Hierarchical clustering schemes,” *Psychometrika*, vol. 32, no. 3, pp. 241–254, 1967.
- [37] J. C. Dunn, “A fuzzy relative of the isodata process and its use in detecting compact well-separated clusters,” 1973.
- [38] J. C. Bezdek, *Pattern recognition with fuzzy objective function algorithms*. Springer Science & Business Media, 2013.
- [39] J. C. Bezdek, “A convergence theorem for the fuzzy isodata clustering algorithms,” *IEEE transactions on pattern analysis and machine intelligence*, no. 1, pp. 1–8, 1980.
- [40] R. J. Hathaway and J. C. Bezdek, “Recent convergence results for the fuzzy c-means clustering algorithms,” *Journal of Classification*, vol. 5, no. 2, pp. 237–247, 1988.
- [41] W. I. Zangwill, “Nonlinear programming: a unified approach,” (*No Title*), 1969.
- [42] L. Groll and J. Jakel, “A new convergence proof of fuzzy c-means,” *IEEE Transactions on Fuzzy Systems*, vol. 13, no. 5, pp. 717–720, 2005.
- [43] R. A. Fisher, “The use of multiple measurements in taxonomic problems,” *Annals of eugenics*, vol. 7, no. 2, pp. 179–188, 1936.

- [44] F. Rosenblatt, "Principles of neurodynamics: Perceptrons and the theory of brain mechanisms," 1961.
- [45] H. Huynh-Van, T. Le-Hoang, and T. Vo-Van, "Classifying for images based on the extracted probability density function and the quasi bayesian method," *Computational Statistics*, vol. 39, no. 5, pp. 2677–2701, 2024.
- [46] T. Vo-Van and D. PhamToan, "A supervised learning algorithm based on the quasi-bayesian method for the probability density functions and application for medical data," *Knowledge-Based Systems*, vol. 299, p. 112003, 2024.
- [47] B. Akturk, U. Beyaztas, H. L. Shang, and A. Mandal, "Robust functional logistic regression," *Advances in Data Analysis and Classification*, pp. 1–25, 2024.
- [48] J. Ren, S. D. Lee, X. Chen, B. Kao, R. Cheng, and D. Cheung, "Naive bayes classification of uncertain data," in *2009 Ninth IEEE international conference on data mining*, pp. 944–949, IEEE, 2009.
- [49] M. Minami and C. E. Lennert-Cody, "Regression tree and clustering for distributions, and homogeneous structure of population characteristics," *Journal of Agricultural, Biological and Environmental Statistics*, pp. 1–20, 2024.
- [50] B. Tavakkol and Y. Son, "Fuzzy kernel k-medoids clustering algorithm for uncertain data objects," *Pattern Analysis and Applications*, vol. 24, no. 3, pp. 1287–1302, 2021.
- [51] A. K. Jain, "Data clustering: 50 years beyond k -means," *Pattern recognition letters*, vol. 31, no. 8, pp. 651–666, 2010.
- [52] A. Saxena, M. Prasad, A. Gupta, N. Bharill, O. P. Patel, A. Tiwari, M. J. Er, W. Ding, and C.-T. Lin, "A review of clustering techniques and developments," *Neurocomputing*, vol. 267, pp. 664–681, 2017.
- [53] T. Dinh, H. Wong, P. Fournier-Viger, D. Lisik, M.-Q. Ha, H.-C. Dam, and V.-N. Huynh, "Categorical data clustering: 25 years beyond k -modes," *Expert Systems with Applications*, vol. 272, p. 126608, 2025.
- [54] D. Phamtoan and T. Vovan, "Automatic fuzzy clustering for probability density functions using the genetic algorithm," *Neural Computing and Applications*, vol. 34, no. 17, pp. 14609–14625, 2022.
- [55] D. Pham-Toan, T. Vo-Van, A. Pham-Chau, T. Nguyen-Trang, and D. Ho-Kieu, "A new binary adaptive elitist differential evolution based automatic k -medoids clustering for probability density functions," *Mathematical Problems in Engineering*, vol. 2019, no. 1, p. 6380568, 2019.
- [56] T. Nguyen-Trang, T. Vo-Van, and H. Che-Ngoc, "An efficient automatic clustering algorithm for probability density functions and its applications in surface material classification," *Statistica Neerlandica*, vol. 78, no. 1, pp. 244–260, 2024.
- [57] H. Tran-Nam, T. Nguyen-Trang, and H. Che-Ngoc, "A new possibilistic-based clustering method for probability density functions and its application to detecting abnormal elements," *Scientific Reports*, vol. 14, no. 1, p. 17871, 2024.

- [58] J.-H. Chen and W.-L. Hung, “A jackknife entropy-based clustering algorithm for probability density functions,” *Journal of Statistical Computation and Simulation*, vol. 91, no. 5, pp. 861–875, 2021.
- [59] R. Okano and M. Imaizumi, “Wasserstein k -centres clustering for distributional data,” *arXiv preprint arXiv:2407.08228*, 2024.
- [60] J. Noordam, W. Van Den Broek, and L. Buydens, “Multivariate image segmentation with cluster size insensitive fuzzy c-means,” *Chemometrics and intelligent laboratory systems*, vol. 64, no. 1, pp. 65–78, 2002.
- [61] P.-L. Lin, P.-W. Huang, C.-H. Kuo, and Y. Lai, “A size-insensitive integrity-based fuzzy c-means method for data clustering,” *Pattern Recognition*, vol. 47, no. 5, pp. 2042–2056, 2014.
- [62] Y. Liu, T. Hou, B. Kang, and F. Liu, “Unsupervised binning of metagenomic assembled contigs using improved fuzzy c-means method,” *IEEE/ACM transactions on computational biology and bioinformatics*, vol. 14, no. 6, pp. 1459–1467, 2016.
- [63] H. Yu, H. Li, X. Xu, Q. Gao, and R. Lan, “Suppressed possibilistic fuzzy c-means clustering based on shadow sets for noisy data with imbalanced sizes,” *Applied Soft Computing*, vol. 167, p. 112263, 2024.
- [64] Y. He, “Imbalanced data clustering using equilibrium k-means,” *arXiv preprint arXiv:2402.14490*, 2024.
- [65] S. Askari, “Fuzzy c-means clustering algorithm for data with unequal cluster sizes and contaminated with noise and outliers: Review and development,” *Expert Systems with Applications*, vol. 165, p. 113856, 2021.
- [66] H. Xiong, J. Wu, and J. Chen, “K-means clustering versus validation measures: a data distribution perspective,” in *Proceedings of the 12th ACM SIGKDD international conference on Knowledge discovery and data mining*, pp. 779–784, 2006.
- [67] A. M. Ikotun, F. Habyarimana, and A. E. Ezugwu, “Cluster validity indices for automatic clustering: A comprehensive review,” *Heliyon*, 2025.
- [68] S. Fillmore-Patrick, “The logit model measurement problem,” *Philosophy of Science*, vol. 92, no. 2, p. 285–303, 2025.
- [69] J. Bi and T. Zhang, “Support vector classification with input data uncertainty,” *Advances in neural information processing systems*, vol. 17, 2004.
- [70] S. Tsang, B. Kao, K. Y. Yip, W.-S. Ho, and S. D. Lee, “Decision trees for uncertain data,” *IEEE transactions on knowledge and data engineering*, vol. 23, no. 1, pp. 64–78, 2009.
- [71] T. Vovan, H. Nguyenthikim, and D. Phamtoan, “Multi-class classification using a new bayesian method,” *Model Assisted Statistics and Applications*, vol. 18, no. 3, pp. 257–266, 2023.

- [72] I. Pavlů, A. Menafoglio, E. Bongiorno, and K. Hron, “Classification of probability density functions in the framework of bayes spaces: methods and applications,” *SORT: statistics and operations research transactions*, vol. 47, no. 2, pp. 295–322, 2023.
- [73] T. A. N. Tran, A. T. N. Nguyen, and D. PhamToan, “A novel supervised learning model for mri image using fuzzy clustering and naïve bayes algorithms,” *Model Assisted Statistics and Applications*, p. 15741699251334321, 2025.
- [74] T. Vovan, “Classifying for images based on the extracted color scales and representative probability density functions,” *Expert Systems with Applications*, p. 128456, 2025.
- [75] T. Vo-Van, “Developing an image classification algorithm based on the novel measure combined with quasi-bayesian method for representing probability density function,” *Annals of Operations Research*, pp. 1–26, 2025.
- [76] M. Ghanem, A. K. Ghaith, V. G. El-Hajj, A. Bhandarkar, A. De Giorgio, A. Elmi-Terander, and M. Bydon, “Limitations in evaluating machine learning models for imbalanced binary outcome classification in spine surgery: a systematic review,” *Brain Sciences*, vol. 13, no. 12, p. 1723, 2023.
- [77] I. van der Linde, “Why the confusion matrix fails as a model of knowledge,” *AI & SOCIETY*, pp. 1–2, 2025.
- [78] A. Erasmus, T. D. Brunet, and E. Fisher, “What is interpretability?,” *Philosophy & Technology*, vol. 34, no. 4, pp. 833–862, 2021.
- [79] L.-V. Herm, K. Heinrich, J. Wanner, and C. Janiesch, “Stop ordering machine learning algorithms by their explainability! a user-centered investigation of performance and explainability,” *International Journal of Information Management*, vol. 69, p. 102538, 2023.
- [80] L. Nanni, S. Ghidoni, and S. Brahnam, “Handcrafted vs. non-handcrafted features for computer vision classification,” *Pattern recognition*, vol. 71, pp. 158–172, 2017.
- [81] E. Schubert, “Stop using the elbow criterion for k-means and how to choose the number of clusters instead,” *ACM SIGKDD Explorations Newsletter*, vol. 25, no. 1, pp. 36–42, 2023.
- [82] C. Goutte, P. Toft, E. Rostrup, F. Å. Nielsen, and L. K. Hansen, “On clustering fmri time series,” *NeuroImage*, vol. 9, no. 3, pp. 298–310, 1999.
- [83] S. Leonelli, *Data-centric biology: A philosophical study*. University of Chicago Press, 2019.
- [84] D. S. Watson, “Reply to tom sterkenburg’s commentary,” *Philosophy & Technology*, vol. 36, no. 4, p. 69, 2023.
- [85] W. J. T. Mollema, “Responding to the watson-sterkenburg debate on clustering algorithms and natural kinds,” 2024.

PHỤ LỤC A LÝ THUYẾT BỔ SUNG VÀ MÃ NGUỒN

Phần này cung cấp lý thuyết và các thuật toán của luận văn.

Bảng 3.3. Một số hàm cơ sở $\psi_m(x)$ phổ biến trong hồi quy logistic cho dữ liệu hàm mật độ

Hàm cơ sở	Công thức $\psi_m(x)$	Miền xác định
Gaussian (RBF)	$\psi_m(x) = \exp\left(-\frac{(x-\mu_m)^2}{2\sigma_m^2}\right)$	$x \in \mathbb{R}$
Hàm sóng con (Wavelet)	$\psi_m(x) = 2^{j_m/2} \psi(2^{j_m}x - k_m)$	$x \in \mathbb{R}$
Chuỗi Fourier	$\psi_m^{(\cos)}(x) = \cos\left(\frac{2\pi mx}{T}\right), \quad \psi_m^{(\sin)}(x) = \sin\left(\frac{2\pi mx}{T}\right)$	$x \in [0, T]$
Đa thức Bernstein	$\psi_m(x) = \binom{n}{m} x^m (1-x)^{n-m}$	$x \in [0, 1]$
Đa thức Legendre	$\psi_m(x) = \frac{1}{2^m m!} \frac{d^m}{dx^m} [(x^2 - 1)^m]$	$x \in [-1, 1]$
B-spline	$\psi_m(x) = \frac{x-t_m}{t_{m+k}-t_m} \psi_{m,k-1}(x) + \frac{t_{m+k+1}-x}{t_{m+k+1}-t_{m+1}} \psi_{m+1,k-1}(x),$ với $\psi_{m,0}(x) = \mathbf{1}_{[t_m, t_{m+1})}(x)$	$x \in \mathbb{R}$

Algorithm 2: Giải thuật phân cụm thứ bậc tích tụ (HCF)

```

1: procedure HCF( $\mathcal{F}; \Delta$ ) ▷ Cho trước liên kết
2:    $t \leftarrow 0$ 
3:   Khởi tạo:  $\mathcal{F}^{(t=0)} = \{\{f_1\}; \{f_2\}; \dots; \{f_n\}\}$ 
4:   while  $n - t > 1$  do
5:     Chọn hai  $c_i; c_j \in \mathcal{F}^{(t=0)}$  sao cho thỏa tại vị trí  $(c_i; c_j) = \arg \min_{c_u; c_v \in \mathcal{F}^{(t=0)}} \Delta(c_u; c_v)$ .
6:     Gộp  $c \leftarrow c_i \cup c_j$ 
7:     Cập nhật  $\mathcal{F}^{t+1} \leftarrow (\mathcal{F}^{(t)} \setminus \{c_i; c_j\}) \cup \{c\}$ 
8:      $t \leftarrow t + 1$ 
9:   end while
10:  return Cây phân cấp
11: end procedure

```

Algorithm 3: Giải thuật phân tích chòm (KCF)

```
1: procedure KCF( $c; \varepsilon$ ) ▷ Cho trước số chòm  $c$ 
2:    $t \leftarrow 0$ 
3:   Khởi tạo  $\mu^{(t)}$  và  $\Theta^{(t)}$  ngẫu nhiên
4:   while  $\|J^{(t+1)} - J^{(t)}\| < \varepsilon$  do
5:      $t \leftarrow t + 1$ 
6:     Cập nhật  $\mu^{(t+1)}$  bằng Công thức  $\mu_{ij} = \mathbf{1}_{\{j \in c_i\}}$ 
7:     Cập nhật  $\Theta^{(t+1)}$  bằng Công thức (1.2)
8:   end while
9:   return  $\mu$  và  $\Theta$ . ▷ Ma trận phân vùng và hàm mật độ đại diện
10: end procedure
```

Algorithm 4: Giải thuật phân tích chòm mờ (FCF)

```
1: procedure FCF( $c; \varepsilon$ ) ▷ Cho trước số chòm  $c$ 
2:    $t \leftarrow 0$ 
3:   Khởi tạo  $\mu^{(t)}$  và  $\Theta^{(t)}$  ngẫu nhiên
4:   while  $\|\mu^{(t+1)} - \mu^{(t)}\| < \varepsilon$  do
5:      $t \leftarrow t + 1$ 
6:     Cập nhật  $\Theta^{(t+1)}$  bằng Công thức (1.3)
7:     Cập nhật  $\mu^{(t+1)}$  bằng Công thức (1.4) và (1.5)
8:   end while
9:   return  $\mu$  và  $\Theta$ . ▷ Ma trận phân vùng và hàm mật độ đại diện
10: end procedure
```

Algorithm 5: Giải thuật phân tích chòm mờ cải tiến (IFCF)

```
1: procedure IFCF( $c; \varepsilon$ ) ▷ Cho trước số chòm  $c$ 
2:    $t \leftarrow 0$ 
3:   Khởi tạo  $\mu^{(t)}$  và  $\Theta^{(t)}$  ngẫu nhiên và  $\omega_i^{(t)} = \mathbf{0}$ 
4:   while  $\|\mu^{(t+1)} - \mu^{(t)}\| < \varepsilon$  do
5:      $t \leftarrow t + 1$ 
6:     Cập nhật  $\Theta^{(t+1)}$  bằng Công thức (2.7)
7:     Cập nhật  $\mu^{(t+1)}$  bằng Công thức (2.2) và (C1)
8:     Tính  $\omega_i^{(t+1)} \leftarrow \frac{1}{n} \sum_{j=1}^n \mu_{ij}^{(t+1)}$ ,  $1 \leq i \leq c$ 
9:   end while
10:  return  $\mu$ ,  $\Theta$ , và  $\omega$ . ▷ Ma trận phân vùng, hàm mật độ đại diện, trọng số chòm
11: end procedure
```

Về tài nguyên tính toán, luận văn này chạy trên hệ điều hành Ubuntu 24.04.2 LTS, nhân Linux 6.11.0-19-generic, 11th Gen Intel® Core™ i5-11400H×12, bộ nhớ 16.0 GiB.

Việc thực thi mã nguồn được sử dụng trong môi trường ảo của Anaconda tên là ‘proclustEnv’. Các mã Python được sử dụng trong luận văn này được lưu trữ tại <https://github.com/hungtrannam/probclust>. Các thư viện trên được lưu trong tệp `requirements.yml` và có thể được cài đặt tự động bằng lệnh

```
conda install environment.yml
```

Đây là danh sách các thư viện Python cần thiết để thực thi toàn bộ mã nguồn trong luận văn.

PHỤ LỤC B KẾT QUẢ

Ví dụ 3.3 (Liên kết các chùm hàm mật độ). Giả sử ta có ba chùm hàm mật độ xác suất Gauss $\mathcal{F}; \mathcal{G}$ và $\mathcal{H}$. Tính các liên kết $\Delta(\mathcal{F}; \mathcal{G})$ và $\Delta(\mathcal{F} \cup \mathcal{G}; \mathcal{H})$ biết khoảng cách giữa hai hàm mật độ là $\mathcal{L}_2$ và các chùm

$$\begin{aligned}\mathcal{F} &= \{f_1 = \mathcal{N}(0, 3; 1), f_2 = \mathcal{N}(1; 1)\}, \\ \mathcal{G} &= \{g_1 = \mathcal{N}(4, 0; 1), g_2 = \mathcal{N}(5, 5; 1), g_3 = \mathcal{N}(4, 8; 1)\}, \\ \mathcal{H} &= \{h_1 = \mathcal{N}(9, 1; 1), h_2 = \mathcal{N}(8, 0; 1)\}.\end{aligned}$$

Bài giải 3.3. Vì các phương sai của hàm mật độ Gauss đều bằng 1. Nên ta có thể tính $\mathcal{L}_2$ bằng công thức tổng quát $\mathcal{L}_2(u; v) = \left(2 - 2 \exp\left(-\frac{(\mu_u - \mu_v)^2}{4\sigma^2}\right)\right)^{1/2}$. Sau khi tính toán, ta nhận được ma trận khoảng cách từng đôi một.

	$\{f_1$	$f_2\}$	$\{g_1$	g_2	$g_3\}$	$\{h_1$	$h_2\}$
f_1							
f_2	0,26						
g_1	0,74	0,71					
g_2	0,75	0,75	0,49				
g_3	0,75	0,74	0,29	0,26			
h_1	0,75	0,75	0,75	0,74	0,75		
h_2	0,75	0,75	0,74	0,67	0,72	0,38	

Từ đây, ta có thể dễ dàng tính được các liên kết $\Delta(\mathcal{F}, \mathcal{G})$ thông qua ma trận này. Ta có,

$$\begin{aligned}\Delta_{\min}(\mathcal{F}, \mathcal{G}) &= \min \{ \mathcal{L}_2(f_1, g_1), \mathcal{L}_2(f_1, g_2), \mathcal{L}_2(f_1, g_3), \mathcal{L}_2(f_2, g_1), \mathcal{L}_2(f_2, g_2), \mathcal{L}_2(f_2, g_3) \} \\ &= \min \{ 0,74; 0,75; 0,75; 0,71; 0,75; 0,74 \} = 0,71, \\ \Delta_{\max}(\mathcal{F}, \mathcal{G}) &= \max \{ \mathcal{L}_2(f_1, g_1), \mathcal{L}_2(f_1, g_2), \mathcal{L}_2(f_1, g_3), \mathcal{L}_2(f_2, g_1), \mathcal{L}_2(f_2, g_2), \mathcal{L}_2(f_2, g_3) \} \\ &= \max \{ 0,74; 0,75; 0,75; 0,71; 0,75; 0,74 \} = 0,75, \\ \Delta_{\text{avg}}(\mathcal{F}, \mathcal{G}) &= \frac{1}{6} \sum_{\substack{f \in \mathcal{F} \\ g \in \mathcal{G}}} \mathcal{L}_2(f, g) = 0,17(0,74 + 0,75 + 0,75 + 0,71 + 0,75 + 0,74) = 0,74, \\ \Delta_{\text{centroid}}(\mathcal{F}, \mathcal{G}) &= \mathcal{L}_2(\theta_{\mathcal{F}}; \theta_{\mathcal{G}}) = \left(2 - 2 \exp \left(- \frac{(0,65 - 4,77)^2}{4} \right) \right)^{1/2} = 1,41, \\ &\text{với } \theta_{\mathcal{F}} = (0,3 + 1,0)/2 = 0,65; \theta_{\mathcal{G}} = (4,0 + 5,5 + 4,8)/3 = 4,77, \\ \Delta_{\text{Ward}}(\mathcal{F}, \mathcal{G}) &= \frac{\#\mathcal{F} \cdot \#\mathcal{G}}{\#\mathcal{F} + \#\mathcal{G}} \cdot \mathcal{L}_2^2(\theta_{\mathcal{F}}, \theta_{\mathcal{G}}) = \frac{2 \cdot 3}{2 + 3} \cdot (1,41)^2 = 2,39,\end{aligned}$$

Tương tự, ta cũng có kết quả cho $\Delta(\mathcal{F} \cup \mathcal{G}; \mathcal{H})$ là

$$\begin{aligned}\Delta_{\min}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) &= 0,67; \Delta_{\max}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) = 0,75; \Delta_{\text{avg}}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) = 0,74, \\ \Delta_{\text{centroid}}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) &= 1,41; \Delta_{\text{Ward}}(\mathcal{F} \cup \mathcal{G}, \mathcal{H}) = 2,86.\end{aligned}$$

Bài giải Ví dụ 1.5. Đầu tiên, ta xem thứ tự của μ_i chính là thứ tự của dữ liệu hàm mật độ f_i , tính toán các khoảng cách từng đôi hàm mật độ bất kỳ bằng khoảng cách $\mathcal{L}_2(f_i; f_j)$ với $i, j = 1; \dots; 7$, ta nhận được ma trận khoảng cách

	f_1	f_2	f_3	f_4	f_5	f_6	f_7
f_1							
f_2	0,74						
f_3	0,75	0,75					
f_4	0,26	0,71	0,75				
f_5	0,75	0,49	0,74	0,75			
f_6	0,75	0,74	0,38	0,75	0,67		
f_7	0,75	0,29	0,75	0,74	0,26	0,72	

Ta thấy khoảng cách $D(f_1; f_4) = D(f_5; f_7) = 0,26$ là khoảng cách nhỏ nhất nên ta chọn một trong hai. Trường hợp này, ta chọn hàm mật độ f_1 và f_4 xếp vào một cụm $\{f_1; f_4\}$. Tiến hành tính

toán liên kết đủ giữa chòm $\{f_1; f_4\}$ với các hàm mật độ khác. Ta có

$$\begin{aligned}\Delta(\{f_1; f_4\}; f_2) &= \max\{D(f_1; f_2); D(f_4; f_2)\} = \max\{0,74; 0,71\} = 0,74, \\ \Delta(\{f_1; f_4\}; f_3) &= \max\{D(f_1; f_3); D(f_4; f_3)\} = \max\{0,75; 0,75\} = 0,75, \\ \Delta(\{f_1; f_4\}; f_5) &= \max\{D(f_1; f_5); D(f_4; f_5)\} = \max\{0,75; 0,75\} = 0,75, \\ \Delta(\{f_1; f_4\}; f_6) &= \max\{D(f_1; f_6); D(f_4; f_6)\} = \max\{0,75; 0,75\} = 0,75, \\ \Delta(\{f_1; f_4\}; f_7) &= \max\{D(f_1; f_7); D(f_4; f_7)\} = \max\{0,75; 0,74\} = 0,75.\end{aligned}$$

Ta xóa dòng/cột f_1 và f_4 và thay bằng một dòng/cột mới là $\{f_1; f_4\}$, ta được ma trận khoảng cách mới

	$\{f_1; f_4\}$	f_2	f_3	f_5	f_6	f_7
$D^{(t=1)} =$	$\{f_1; f_4\}$					
	f_2	0,74				
	f_3	0,75	0,75			
	f_5	0,75	0,49	0,74		
	f_6	0,75	0,74	0,38	0,67	
	f_7	0,75	0,29	0,75	0,26	0,72

Tiếp theo, ta thấy $D(f_5; f_7) = 0,26$ là cách nhỏ nhất nên ta xếp hai hàm mật độ này thành một chòm mới $\{f_5; f_7\}$. Tiến hành tính toán liên kết đủ giữa chòm $\{f_5; f_7\}$ với các hàm mật độ khác. Ta có

$$\begin{aligned}\Delta(\{f_5; f_7\}; \{f_1; f_4\}) &= \max\{D(f_5; f_1); D(f_5; f_4); D(f_7; f_1); D(f_7; f_4)\} = 0,75, \\ \Delta(\{f_5; f_7\}; f_2) &= \max\{D(f_5; f_2); D(f_7; f_2)\} = 0,49, \\ \Delta(\{f_5; f_7\}; f_3) &= \max\{D(f_5; f_3); D(f_7; f_3)\} = 0,75, \\ \Delta(\{f_5; f_7\}; f_6) &= \max\{D(f_5; f_6); D(f_7; f_6)\} = 0,72.\end{aligned}$$

Ta xóa dòng/cột f_5 và f_7 và thay bằng một dòng/cột mới là $\{f_5; f_7\}$, ta được ma trận khoảng cách mới

	$\{f_1; f_4\}$	f_2	f_3	$\{f_5; f_7\}$	f_6
$D^{(t=2)} =$	$\{f_1; f_4\}$				
	f_2	0,75			
	f_3	0,75	0,75		
	$\{f_5; f_7\}$	0,75	0,49	0,75	
	f_6	0,75	0,74	0,38	0,72

Tiếp theo, ta thấy $D(f_3; f_6) = 0,38$ là cách nhỏ nhất nên ta xếp hai hàm mật độ này thành một

chùm mới $\{f_3; f_6\}$. Tiến hành tính toán liên kết đủ giữa chùm $\{f_3; f_6\}$ với các hàm mật độ khác. Ta có

$$\Delta(\{f_3; f_6\}; \{f_1; f_4\}) = \max\{D(f_3; f_1); D(f_3; f_4); D(f_6; f_1); D(f_6; f_4)\} = 0,75,$$

$$\Delta(\{f_3; f_6\}; \{f_5; f_7\}) = \max\{D(f_3; f_5); D(f_3; f_7); D(f_6; f_5); D(f_6; f_7)\} = 0,75,$$

$$\Delta(\{f_3; f_6\}; f_2) = \max\{D(f_5; f_3); D(f_7; f_3)\} = 0,75,$$

Ta xóa dòng/cột f_3 và f_6 và thay bằng một dòng/cột mới là $\{f_3; f_6\}$, ta được ma trận khoảng cách mới

	$\{f_1, f_4\}$	f_2	$\{f_5, f_7\}$	$\{f_3, f_6\}$
$D^{(t=3)} =$				
$\{f_1, f_4\}$				
f_2	0,75			
$\{f_5, f_7\}$	0,75	0,49		
$\{f_3, f_6\}$	0,75	0,75	0,75	

Tiếp theo, ta thấy $D(\{f_5; f_7\}; f_2) = 0,49$ là cách nhỏ nhất nên ta xếp hàm mật độ f_2 này vào chùm $\{f_5; f_7\}$. Tiến hành tính toán liên kết đủ giữa chùm $\{f_2; f_5; f_7\}$ với các hàm mật độ khác. Ta có

$$\Delta(\{f_2, f_5, f_7\}, \{f_1, f_4\}) = \max\{D(f_2; \{f_1; f_4\}); D(f_5; \{f_1; f_4\}); D(f_7; \{f_1; f_4\})\} = 0,75,$$

$$\Delta(\{f_2, f_5, f_7\}, \{f_3, f_6\}) = \max\{D(f_2; \{f_3; f_6\}); D(f_5; \{f_3; f_6\}); D(f_7; \{f_3; f_6\})\} = 0,75.$$

Ta xóa dòng/cột f_2 và $\{f_5; f_7\}$ và thay bằng một dòng/cột mới là $\{f_2; f_5; f_7\}$, ta được ma trận khoảng cách mới

	$\{f_1, f_4\}$	$\{f_2, f_5, f_7\}$	$\{f_3, f_6\}$
$D^{(t=4)} =$			
$\{f_1, f_4\}$			
$\{f_2, f_5, f_7\}$	0,75		
$\{f_3, f_6\}$	0,75	0,75	

Cuối cùng, ta chọn xếp chùm $\{f_2, f_5, f_7\}$ vào chùm $\{f_3, f_6\}$ dựa vào khoảng cách chính xác nhỏ nhất (4 chữ số thập phân). Vậy ta có chùm $\{f_2; f_5; f_7; f_3; f_6\}$. Ta xếp chùm còn lại vào chùm mới này, thuật toán kết thúc.

```
In [4]: import sys
import os

project_root = os.path.abspath("..")
if project_root not in sys.path:
    sys.path.insert(0, project_root)
```


```
In [5]: import numpy as np
from data.data_loader import generateGauss
from utils.integral import grid
from Models.clustering import HCF
```

```
In [ ]: bandwidth = 0.01
grid_x    = grid(bandwidth, start=-5, end=15)
mu        = np.array([0.3, 4.0, 9.1, 1.0, 5.5, 8.0, 4.8])
sig       = np.array([1.0, 1.0, 1.0, 1.0, 1.0, 1.0, 1.0])
F_data    = generateGauss(mu, sig, grid_x)
```

```
In [7]: cluster=HCF.Model(
    grid_x=grid_x,
    max_depth=7,
    distance_metric='L1',
    linkage='complete',
    bandwidth=bandwidth
)
cluster.fit(F_data)
cluster.print_tree()
```

```
├─ root (7 samples): [0, 1, 2, 3, 4, 5, 6]
│   ├── root0 (2 samples): [0, 3]
│   │   ├── root00 (1 samples): [0]
│   │   └── root01 (1 samples): [3]
│   ├── root1 (5 samples): [1, 4, 6, 2, 5]
│   │   ├── root10 (3 samples): [1, 4, 6]
│   │   │   ├── root100 (1 samples): [1]
│   │   │   ├── root101 (2 samples): [4, 6]
│   │   │   │   ├── root1010 (1 samples): [4]
│   │   │   │   └── root1011 (1 samples): [6]
│   │   └── root11 (2 samples): [2, 5]
│   │       ├── root110 (1 samples): [2]
│   │       └── root111 (1 samples): [5]
```

Bài giải Ví dụ 1.6. Cho $c = 3$, $\varepsilon = 10^{-3}$, Các trọng tâm khởi tạo ngẫu nhiên bởi $\theta_1(x) \sim \mathcal{N}(0; 1)$, $\theta_2(x) \sim \mathcal{N}(2; 1)$, $\theta_3(x) \sim \mathcal{N}(5; 1)$. Ta cũng khởi tạo các phần tử trong ma trận U tuân theo phân phối Dirichlet. Ma trận khoảng cách D trong đó hàng i là θ_i , cột j là f_j , các khoảng cách được tính bởi $\mathcal{L}_2$ dựa vào trọng tâm và phân vùng như sau




Hình 3.7. Khởi tạo ngẫu nhiên của FCF

Khoảng cách $D^{(t=0)}$ với $\mathcal{L}_2 = \|\mathcal{N}(\mu; 1) - \mathcal{N}(\nu; 1)\|_2 = \left[\frac{1}{\sqrt{\pi}} \left(1 - e^{-(\mu-\nu)^2/4} \right) \right]^{1/2}$, ta có

$$\begin{aligned} D_{11} &= \left[\frac{1}{\sqrt{\pi}} \left(1 - e^{-(0,3)^2/4} \right) \right]^{1/2} = 0,11, \\ D_{21} &= \left[\frac{1}{\sqrt{\pi}} \left(1 - e^{-(1,7)^2/4} \right) \right]^{1/2} = 0,54, \\ D_{31} &= \left[\frac{1}{\sqrt{\pi}} \left(1 - e^{-(4,7)^2/4} \right) \right]^{1/2} = 0,75. \end{aligned}$$

Tóm lại, ta thu được ma trận khoảng cách D tại Hình 3.7(b). Hơn nữa, Ma trận phân vùng $U^{(1)}$ với $m = 2$ cũng được tính toán như sau. Vì không có $D_{ij} = 0$ nên dùng công thức cập nhật từ (1.4), ta có $u_{ij}^{(1)} = \left(\sum_{k=1}^3 \left(\frac{D_{ij}}{D_{kj}} \right)^2 \right)^{-1}$; $\forall j$. Suy ra ta thu được ma trận phân vùng U (tại Hình 3.7(a)) từ cách tính cho cột $j = 1$ như sau

$$\begin{aligned} u_{11} &= \left[1 + \left(\frac{0,112}{0,54} \right)^2 + \left(\frac{0,11}{0,75} \right)^2 \right]^{-1} = 0,94, \\ u_{21} &= \left[\left(\frac{0,54}{0,11} \right)^2 + 1 + \left(\frac{0,54}{0,75} \right)^2 \right]^{-1} = 0,04, \\ u_{31} &= \left[\left(\frac{0,75}{0,11} \right)^2 + \left(\frac{0,75}{0,54} \right)^2 + 1 \right]^{-1} = 0,02. \end{aligned}$$




Hình 3.8. Vòng lặp $t = 1$ của FCF

Gom toàn bộ cột, ta nhận được ma trận phân vùng sau vòng lặp đầu tiên là U . Với chuẩn $\mathcal{L}_2$ trên hàm, theo (1.5). Để tính toán tiêu chuẩn dừng, ta tính theo công thức


$$\left\| \mu^{(t+1)} - \mu^{(t)} \right\| = 0,96.$$

Vì chuẩn này chưa nhỏ hơn tiêu chuẩn dừng, ta tiếp tục lặp lại quá trình trên. Sau $t = 9$ vòng lặp, thuật toán FCF dừng với chuẩn là $6,12 \times 10^{-4}$.



Hình 3.9. Vòng lặp $t = 9$ của FCF

Ta có quá trình biến đổi ở mỗi vòng lặp đối với các trọng tâm ở Hình 3.10. Khác với các điểm rời rạc, trọng tâm FCM chỉ tịnh tiến trong không gian tọa độ, các trọng tâm hàm mật độ xác suất trong FCF vừa biến dạng hình dạng vừa dịch chuyển vị trí.



Hình 3.10. Thay đổi của trọng tâm chùm FCF qua các vòng lặp

Bảng 3.4. Kết quả so sánh các khoảng cách theo chỉ số ARI đối với Ví dụ 2.1

Khoảng cách	meanrank	median	mad	ci_lower	ci_upper	effect_size	magnitude	effect_size_above	magnitude above
D_H	4.0	-0.001551	0.017663	-0.019214	0.93993	0.000000	negligible	0.000000	negligible
$\mathcal{L}_2$	3.9	-0.010574	0.009523	-0.020588	0.932119	0.428897	small	0.428897	small
D_{JS}	3.8	-0.001818	0.011585	-0.013402	0.93993	0.012035	negligible	-0.556951	medium
W_2	2.1	0.881896	0.118104	0.450172	1.000000	-7.056713	large	-7.103256	large
D_{BC}	1.2	0.883307	0.003776	0.879531	1.000000	-46.730339	large	-0.011391	negligible

Bảng 3.5. Kết quả so sánh các khoảng cách theo chỉ số đối với NMI Ví dụ 2.1

Khoảng cách	meanrank	median	mad	ci_lower	ci_upper	effect_size	magnitude	effect_size_above	magnitude above
D_H	4.2	0.028672	0.002723	0.025949	0.876524	0.000000	negligible	0.000000	negligible
$\mathcal{L}_2$	3.9	0.051818	0.024099	0.027092	0.862962	-0.910378	large	-0.910378	large
D_{JS}	3.6	0.051341	0.025252	0.026089	0.876524	-0.851356	large	0.013043	negligible
W_2	2.1	0.796297	0.176127	0.363509	1.000000	-4.156832	large	-3.993718	large
D_{BC}	1.2	0.800313	0.009732	0.790582	1.000000	-72.836544	large	-0.021719	negligible

Bảng 3.6. Kết quả so sánh các khoảng cách theo chỉ số *Silhouette* đối với Ví dụ 2.1

Khoảng cách	meanrank	mean	std	ci_lower	ci_upper	effect_size	magnitude	effect_size_above	magnitude above
D_H	4.2	0.495819	0.029603	0.466216	0.659092	0.000000	negligible	0.000000	negligible
D_{JS}	4.0	0.495607	0.029312	0.466295	0.659092	0.004854	negligible	0.004854	negligible
$\mathcal{L}_2$	3.5	0.481554	0.014613	0.432698	0.659092	0.412173	small	0.409274	small
W_2	2.1	0.620630	0.022065	0.592853	0.659092	-3.224505	large	-5.012632	large
D_{BC}	1.2	0.620630	0.006647	0.611582	0.672148	-3.923972	large	0.000000	negligible

Bảng 3.7. Kết quả so sánh các khoảng cách theo chỉ số Thời gian chạy đối với Ví dụ 2.1

Khoảng cách	meanrank	mean	std	ci_lower	ci_upper	effect_size	magnitude	effect_size_above	magnitude above
D_{BC}	4.6	0.067778	0.064004	-0.064007	0.199564	0.000000	negligible	0.000000	negligible
$\mathcal{L}_2$	3.6	0.115243	0.080680	-0.050879	0.281365	-0.651793	medium	-0.651793	medium
W_2	3.6	0.090621	0.051703	-0.015836	0.197077	-0.392616	small	0.363381	small
D_H	2.2	0.367436	0.334679	-0.321673	1.056545	-1.243690	large	-1.155995	large
D_{JS}	1.0	1.241478	1.076920	-0.975915	3.458871	-1.538590	large	-1.096083	large

PHỤ LỤC C BÀN LUẬN

1. Về phương pháp trích xuất hình ảnh

Qua các ứng dụng ta có thể thấy, việc phân đoạn hay phân loại dữ liệu hình ảnh có thể dựa trên màu sắc đặc trưng của các đối tượng. Sử dụng hàm mật độ xác suất để biểu diễn hình ảnh mang lại nhiều lợi thế đáng chú ý tính rõ ràng và trực quan qua phân tích chùm. Hơn nữa, nó có tính ổn định khi hình ảnh bị xoay. Phương pháp ước lượng hàm mật độ dựa trên màu sắc phản ánh rõ đặc tính sáng/tối toàn cục của hình ảnh. Phương pháp dựa trên khối màu duy trì thông tin màu sắc cục bộ cho từng vùng ảnh. Cuối cùng, cách tiếp cận vị trí có thể duy trì thông tin hình học của cấu trúc hình ảnh. Tuy nhiên, việc trích xuất này cần một số tiên giả định về việc màu sắc phải cố định và hạn chế sai lệch. Vì sử dụng các thang màu RGB hoặc xám làm cho bài toán phân loại phải là phân loại màu sắc mà không phải hình dạng hay kết cấu. Ví dụ, việc trích xuất các loại củ quả như ớt chuông, củ cải, táo, các loại này có nhiều màu sắc (như táo đỏ, táo xanh) nên không thể dùng trích xuất loại này. Hơn nữa, các sai lệch về độ sáng của hình ảnh cũng ảnh hưởng đến kết quả trích xuất.

2. Về thuật toán phân tích chùm các hàm mật độ xác suất

Phân tích chùm phân vùng dựa vào trọng tâm rất đơn giản.

Tuy nhiên, nó cũng có một số khuyết điểm bao gồm tính không xác định của các siêu tham số, chất lượng dữ liệu đầu vào và khả năng giải thích của mô hình. Đầu tiên, họ thuật toán này không cung cấp c chùm tối ưu. Đôi khi, ta không có tri thức về số lượng c , dẫn đến khó khăn khi phân chùm các mẫu có số chiều lớn [81], và nguy cơ quá khớp. Theo Goutte *et al.*, “*khi số lượng chùm không phản ánh trong dữ liệu, kết quả cuối cùng cơ bản là vô nghĩa*” [82]. Ngoài ra, do giả định tối ưu lỗi, thuật toán dựa trên trọng tâm thường hoạt động hiệu quả nhất với hình dạng gần cầu, và có thể gặp thách thức khi áp dụng cho dữ liệu chứa nhiễu, ngoại lệ, có chồng lấp giữa các chùm hoặc có sự chênh lệch lớn về kích thước và mật độ. Cuối cùng, hàm mật độ trọng tâm chùm ban đầu cũng ảnh hưởng đến kết quả tối ưu dù đã có nhiều khuyến nghị như k -means++.

Ngược lại, phân tích chùm thứ bậc không đòi hỏi tiên nghiệm về số chùm, nhưng chi phí tính toán cao, đặc biệt với dữ liệu lớn khi cần tính toán bộ ma trận khoảng cách

Tóm lại, các thuật toán phân tích chùm mang lại tiềm năng lớn trong việc khám phá các cấu trúc ẩn và những mối quan hệ có ý nghĩa giữa các mẫu dữ liệu, từ đó hỗ trợ các phân tích chuyên sâu và mở ra nhiều ứng dụng tiềm năng [12, 21]. Mặc dù kết quả của các thuật toán phân tích chùm có thể

chịu ảnh hưởng bởi dữ liệu đầu vào, thể loại tự nhiên và lựa chọn thuật toán, chúng vẫn đóng vai trò là công cụ mạnh mẽ giúp người dùng nhận diện và diễn giải các mẫu tốt hơn. Qua đó, *các loại tự nhiên có là những gì thuật toán phân cụm phân nào hướng đến trong điều kiện lý tưởng không* là một chủ đề nghiên cứu đầy hứa hẹn, tiếp tục được quan tâm và mở rộng trong cộng đồng khoa học thống kê [35, 83–85].

3. Về thuật toán phân tích cụm các hàm mật độ xác suất

Trong quá trình lập, giả sử hai trọng tâm Θ được xác định, khi đó với bất kỳ hàm mật độ j thuộc cụm c_1 , các mức độ phân vùng được cập nhật theo Công thức 2.2, và điều kiện $\sum_{j=1}^c u_{ij} = 1$, có thể được viết lại thành

$$\frac{1}{1 + \left(\frac{\omega_2}{\omega_1}\right)^{\frac{1}{m-1}} \left(\frac{\mathcal{L}_2^2(\theta_1; f_j)}{\mathcal{L}_2^2(\theta_2; f_j)}\right)^{\frac{1}{m-1}}} + \frac{1}{\left(\frac{\omega_1}{\omega_2}\right)^{\frac{1}{m-1}} \left(\frac{\mathcal{L}_2^2(\theta_2; f_j)}{\mathcal{L}_2^2(\theta_1; f_j)}\right)^{\frac{1}{m-1}} + 1} = 1.$$

Khi $\omega_1 \rightarrow \infty$, ta có $\lim_{\omega_1 \rightarrow \infty} \mu_{i1} = 1$, $\lim_{\omega_1 \rightarrow \infty} \mu_{i2} = 0$. Điều này cho thấy khi tỷ lệ IR tăng, $\mu_{i1} \rightarrow 1$ và $\mu_{i2} \rightarrow 0$, hiện tượng phân cực xảy ra trong các mức độ phân vùng. Do đó, với cụm lớn c_1 , giả sử tồn tại một sai số nhỏ $\varepsilon > 0$ sao cho $\omega_1 = \omega_{1,\text{true}} + \varepsilon$, trong đó $\omega_{1,\text{true}}$ là tỷ lệ thực của kích thước hàm mật độ thực tế c_1 so với toàn bộ tập dữ liệu.

4. Về thuật toán phân loại các hàm mật độ xác suất

5. Về các chỉ số đánh giá nhận dạng hàm mật độ xác suất

Lưu ý, các chỉ số này định lượng hình thức, nhưng không phải chất lượng và tính tin cậy. Ma trận nhầm lẫn cung cấp thông tin về số lượng dự đoán đúng/sai tại một ngưỡng, nhưng không đánh giá tính hợp lý của bằng chứng nó nhận biết. Ian van der Linde (2025) nhấn mạnh *một mô hình có thể dự đoán đúng và có bằng chứng nhưng dựa trên đặc trưng hoặc bằng chứng không liên quan sẽ dẫn đến kết quả dù đúng nhưng không thể coi là quy luật tổng quát* [77].

Do vậy, để đánh giá mô hình một cách đầy đủ và tin cậy, cần kết hợp nhiều thước đo. Quan trọng hơn, việc tối ưu hiệu năng đi kèm với chú trọng giải thích lý do dự đoán [78, 79], thông qua giải thích-AI (XAI), tương tác người dùng và tiêu chuẩn đánh giá phù hợp, sẽ nâng cao độ tin cậy và giá trị ứng dụng thực tiễn của mô hình.

CHỈ MỤC

- k*-mean++, 40
- k*-means++, 75
- Affinity Bhattacharyya, 14
- bộ mã hóa (encoding), 17
- dữ liệu đặc trưng (symbolic data), 4, 27
- giải thích-AI (eXplainable AI), 76
- hàm cơ sở (basis functions), 22
- hàm hệ số $\beta(x)$ (β -functional coefficient), 22
- hàm mất mát (loss function), 23
- hàm phân vị (quantile function), 4
- Hạt nhân χ^2 (Chi-squared kernel), 15
- Hạt nhân Bhattacharyya, 15
- hạt nhân chuẩn (Gaussian kernel), 15
- hạt nhân tuyến tính (Linear kernel), 15
- hằng số chặn (intercept), 22
- ma trận nhầm lẫn (confusion matrix), 45
- máy véc-tơ hỗ trợ (support vector machine), 22
- môi trường ảo (virtual environment), 65
- nhận dạng không được giám sát (unsupervised recognition), 1
- nhận dạng được giám sát (supervised recognition), 1
- phép nhân điểm (point-wise product), 5
- phương pháp hình thang (trapezoidal method), 16
- phương pháp tăng cường mẫu (resampling methods), 29
- quá khớp (overfitting), 75
- siêu tham số (hyper-parametre), 75
- thông minh nhân tạo (AI), 1
- tỷ lệ mất cân bằng (Imbalance Ratio), 29
- vận chuyển tối ưu (optimal transport), 12
- ánh xạ nhiều-đến-một (many-to-one map), 17
- điểm ngoại lệ (outliers), 75
- độ dốc (gradient method), 20