

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC CẦN THƠ

TRẦN NAM HÙNG

NHẬN DẠNG THỐNG KÊ
CHO HÀM MẬT ĐỘ XÁC SUẤT MẤT CÂN BẰNG
VÀ ỨNG DỤNG CHO DỮ LIỆU ẢNH

LUẬN VĂN TỐT NGHIỆP THẠC SĨ

NGÀNH: LÝ THUYẾT XÁC SUẤT VÀ THỐNG KÊ TOÁN HỌC
MÃ SỐ: 8 46 01 06

NĂM 2025

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC CẦN THƠ

TRẦN NAM HÙNG
MÃ SỐ HỌC VIÊN: M1823002

NHẬN DẠNG THỐNG KÊ
CHO HÀM MẬT ĐỘ XÁC SUẤT MẤT CÂN BẰNG
VÀ ỨNG DỤNG CHO DỮ LIỆU ẢNH

LUẬN VĂN TỐT NGHIỆP THẠC SĨ
NGÀNH LÝ THUYẾT XÁC SUẤT VÀ THỐNG KÊ TOÁN HỌC
MÃ SỐ: 8 46 01 06

CÁN BỘ HƯỚNG DẪN
PGS. TS. VÕ VĂN TÀI

NĂM 2025

CHẤP THUẬN CỦA HỘI ĐỒNG

Luận văn này với tựa đề là “**Nhận dạng thống kê cho hàm mật độ xác suất mất cân bằng và ứng dụng cho dữ liệu ảnh**”, do học viên Trần Nam Hưng thực hiện theo sự hướng dẫn của PGs. TS. Võ Văn Tài. Luận văn đã báo cáo và được Hội đồng chấm luận văn thông qua ngày , tháng , năm . Luận văn đã được chỉnh sửa theo góp ý và được Hội đồng chấm luận văn xem lại.

Thư ký
(Ký tên)*

Ủy viên
(Ký tên)

Phản biện 1
(Ký tên)*

Phản biện 2
(Ký tên)

Người hướng dẫn
(Ký tên)*

Chủ tịch hội đồng
(Ký tên)

*: Ghi đầy đủ học hàm, học vị và họ tên

LỜI CẢM ƠN

Luận văn tốt nghiệp này được tài trợ bởi Chương trình học bổng đào tạo thạc sĩ, tiến sĩ trong nước của Quỹ Đổi mới sáng tạo Vingroup (VINIF), mã số VINIF.2024.ThS.56.

Cần Thơ, ngày tháng năm

Tác giả

(Ký, họ và tên)

LỜI CAM ĐOAN

Tôi tên là Trần Nam Hưng, là học viên cao học ngành Lý thuyết Xác suất và Thống kê Toán học khóa 2023–2025. Tôi xin cam đoan luận văn này là công trình nghiên cứu khoa học thực sự của bản thân tôi được sự hướng dẫn của PGS. TS. Võ Văn Tài.

Các thông tin được sử dụng tham khảo trong đề tài luận văn được thu thập từ các nguồn đáng tin cậy, đã được kiểm chứng, được công bố rộng rãi và được tôi trích dẫn nguồn gốc rõ ràng ở phần Danh mục Tài liệu tham khảo. Các kết quả nghiên cứu được trình bày trong luận văn/đề án này là do chính tôi thực hiện một cách nghiêm túc, trung thực và không trùng lặp với các đề tài khác cùng cấp đã được công bố trước đây. Tác giả đồng ý về việc Nhà trường có quyền công bố và phổ biến để phục vụ nhu cầu đào tạo, nghiên cứu khoa học (NCKH) và phục vụ cộng đồng.

Tôi xin lấy danh dự và uy tín của bản thân để đảm bảo cho lời cam đoan này.

Cần Thơ, ngày tháng năm

Người hướng dẫn

(Ký tên)

Tác giả thực hiện

(Ký tên)

MỤC LỤC

PHẦN MỞ ĐẦU	1
1 Lý do chọn đề tài	1
2 Mục đích nghiên cứu	2
3 Đối tượng và phạm vi nghiên cứu	2
4 Phương pháp nghiên cứu	3
5 Cấu trúc luận văn	3
PHẦN NỘI DUNG	3
1 KIẾN THỨC CHUẨN BỊ	4
1.1 Hàm mật độ xác suất	4
1.2 Một số hàm mật độ thông dụng	6
1.3 Độ đo đánh giá sự tương tự của các hàm mật độ xác suất	8
1.3.1 Sự tương tự của hai hàm mật độ xác suất	8
1.3.2 Sự tương tự của nhiều hơn hai hàm mật độ xác suất	10
1.4 Xấp xỉ tích phân	11
1.5 Một số định lý hội tụ	11
1.5.1 Nhân tử L'Arange	11
1.5.2 Điều kiện Karush–Kuhn–Tucker	11
1.5.3 Định lý hội tụ toàn cục Zangwill	11
1.6 Phân tích chùm cho hàm mật độ xác suất	12
1.6.1 Phân tích chùm không mờ	12
1.6.2 Phân tích chùm mờ	14
1.7 Phân loại cho hàm mật độ xác suất	16
1.7.1 Vấn đề tìm xác suất tiên nghiệm	17
1.7.2 Thuật toán phân loại	17
1.8 Tổng kết Chương 1	17
2 NHẬN DẠNG THÔNG KÊ CHO HÀM MẬT ĐỘ XÁC SUẤT VỚI DỮ LIỆU MẤT CÂN BẰNG	18

2.1	Giới thiệu	18
2.1.1	Giới thiệu bài toán phân tích chùm cho dữ liệu mất cân bằng	18
2.1.2	Giới thiệu bài toán phân loại cho dữ liệu mất cân bằng	18
2.2	Các vấn đề liên quan	18
2.2.1	Một số khái niệm liên quan	18
2.2.2	Tham số đánh giá thuật toán phân tích chùm	18
2.2.3	Tham số đánh giá thuật toán phân loại	19
2.3	Phân tích chùm cho hàm mật độ xác suất với dữ liệu mất cân bằng	19
2.3.1	Thuật toán	19
2.3.2	Sự hội tụ của thuật toán	19
2.3.3	Ví dụ minh họa	19
2.3.4	Đánh giá thuật toán	19
2.4	Phân loại cho hàm mật độ xác suất với dữ liệu mất cân bằng	19
2.4.1	Thuật toán	19
2.4.2	Sự hội tụ của thuật toán	19
2.4.3	Ví dụ minh họa	19
2.4.4	Đánh giá thuật toán	19
2.4.5	Tổng kết chương 2	19
3	ỨNG DỤNG CHO DỮ LIỆU ẢNH	20
3.1	Trích xuất đặc trưng của ảnh thành hàm mật độ xác suất	20
3.1.1	Vấn đề trích xuất đặc trưng của ảnh	20
3.1.2	Ước lượng hàm mật độ xác suất đại diện cho ảnh	20
3.2	Ứng dụng của bài toán phân tích chùm	20
3.2.1	Dữ liệu	20
3.2.2	Phương pháp thực hiện	20
3.2.3	Kết quả thực hiện	20
3.3	Ứng dụng của bài toán phân loại	20
3.3.1	Dữ liệu	20
3.3.2	Phương pháp thực hiện	20
3.3.3	Kết quả thực hiện	20
3.3.4	Tổng kết chương 3	20
	PHẦN KẾT LUẬN	21
	TÀI LIỆU THAM KHẢO	21
	CHỈ MỤC	25

DANH SÁCH HÌNH VẼ

1.1	Hàm mật độ xác suất Gauss trong các không gian 1-chiều và 2-chiều	6
1.2	Minh họa các khoảng cách phổ biến giữa hai hàm mật độ Gauss	9
1.3	Dãy khoảng cách giữa hai hàm mật độ Gauss $\mathcal{N}(0, 1)$ và $\mathcal{N}(\mu, 1)$	10

DANH SÁCH BẢNG

1.1	Bảng tổng kết các loại khoảng cách giữa hai hàm mật độ xác suất	8
1.2	Bảng tổng kết các loại liên kết giữa hai chùm hàm mật độ xác suất	10
1.3	Tổng kết các tương tự giữa các chùm hàm mật độ xác suất	11
1.4	So sánh độ phức tạp của ba loại phân tích chùm	16

DANH SÁCH GIẢI THUẬT

1	Giải thuật phân tích chùm k -means (KCF)	14
2	Giải thuật phân tích chùm mờ (FCF)	15

PHẦN MỞ ĐẦU

1 Lý do chọn đề tài

Nghiên cứu – phát triển các nguyên tắc và ứng dụng hệ thống thông minh nhân tạo (AI) là yếu tố then chốt nhằm thúc đẩy tăng trưởng kinh tế bền vững ở các quốc gia [1, 2]. Với khả năng ứng dụng đa ngành – đa chiều, AI không chỉ cải thiện năng suất lao động mà còn mở ra nhiều cơ hội việc làm, góp phần xây dựng nền kinh tế số, nâng cao tiện ích, thu nhập và chất lượng cuộc sống [3]. Trong sự phát triển của AI, nhận dạng thống kê được xem là một trong những kiến thức nền tảng.

Nhận dạng thống kê gồm có hai bài toán chính: nhận dạng được giám sát và không được giám sát [4, 5]. Nhận dạng không được giám sát là việc chia dữ liệu thành các cụm sao cho các phần tử trong cùng một cụm có sự tương tự nhiều hơn so với các phần tử bên ngoài cụm đó [6, 7]. Do đó nhận dạng không được giám sát còn được gọi là bài toán phân tích cụm. Phân tích cụm là cơ sở của việc lưu trữ, trích xuất và xử lý dữ liệu lớn nên được rất nhiều nhà thống kê và công nghệ thông tin quan tâm. Nhận dạng được giám sát là việc xếp một phần tử vào một nhóm trong các nhóm đã biết một cách thích hợp [4, 8]. Do đó, nhận dạng được giám sát còn được gọi là bài toán phân loại. Phân loại đã và đang được áp dụng trong nhiều lĩnh vực khác nhau. Chẳng hạn, trong y tế hoạt động chẩn đoán bệnh của các bác sĩ xem một người có bệnh hay không có bệnh B, loại nào trong bệnh B thực chất là thực hiện bài toán phân loại. Trong lĩnh vực xã hội và an ninh, việc nhận dạng khuôn mặt, chữ ký, dấu vân tay, ... cũng chính là thực hiện bài toán phân loại.

Dữ liệu cho nhận dạng thống kê có thể là dữ liệu rời rạc, dữ liệu khoảng và hàm mật độ xác suất. Nhận dạng thống kê cho dữ liệu rời rạc đã được xem xét đầu tiên đã và đang được nghiên cứu rất nhiều [6, 9, 10]. Trong thực tế, chúng ta cũng lưu trữ nhiều dữ liệu khoảng như nhiệt độ, lượng mưa, giá chứng khoán nên nhận dạng cho kiểu dữ liệu này đã được đề xuất và phát triển. Khi dữ liệu lớn và phức tạp như hình ảnh, mỗi đối tượng cần được xem như một phân phối [11], do đó nhận dạng thống kê cho hàm mật độ xác suất được đề xuất.

Xét về số lượng phần tử trong các nhóm, dữ liệu có thể được gọi là mất cân bằng và không mất cân bằng. Khi số lượng phần tử của các nhóm không có sự chênh lệch nhiều thì nó được gọi là không mất cân bằng. Trong nhận dạng dữ liệu của thực tế, nhiều trường hợp chúng ta gặp phải dữ liệu mất cân bằng. Đó là kiểu dữ liệu mà một nhóm hoặc một số ít nhóm có số lượng phần tử quá nhỏ so với các nhóm còn lại [12]. Khi một mô hình nhận dạng phải đối mặt với chênh lệch lớn về số lượng mẫu, nó dễ dàng bị thiên lệch về lớp đa số, dẫn đến hiệu quả thấp trong việc nhận dạng các mẫu của lớp thiểu số [13]. Chẳng hạn, trong tầm soát ung thư, ca bị bệnh có thể ít hơn 1000 lần so với trường hợp không bị bệnh [14]. Khi đó các thuật toán nhận dạng truyền thống sẽ không phát huy hiệu quả vì nó có xu hướng thiên vị lớp đa số mà bỏ qua lớp thiểu số. Trong trường hợp này, độ chính xác của các lớp thiểu số là quan trọng hơn [12] bởi vì việc tầm soát sai người mắc ung thư là khỏe mạnh gây ra tổn thất tính mạng lớn hơn nhiều so với sai lầm ngược lại.

Theo sự hiểu biết của chúng tôi, nhận dạng thống kê cho dữ liệu mất cân bằng với các phần tử rời rạc đã được quan tâm trong những năm gần đây. Tuy nhiên với dữ liệu hàm mật độ xác suất hầu như chưa được xem xét. Từ sự phân tích trên, đề tài **“Nhận dạng thống kê cho hàm mật độ xác suất mất cân bằng và ứng dụng cho dữ liệu ảnh”** được chọn làm luận văn tốt nghiệp.

2 Mục đích nghiên cứu

- Xây dựng thuật toán phân loại và phân tích chùm cho hàm mật độ xác suất với dữ liệu mất cân bằng;
- Áp dụng hai thuật toán trên cho dữ liệu ảnh khi các đặc trưng của nó được trích xuất và đại diện bởi hàm mật độ xác suất để nhận dạng.

3 Đối tượng và phạm vi nghiên cứu

3.1 Đối tượng nghiên cứu

- Thuật toán phân loại và phân tích chùm với dữ liệu mất cân bằng;
- Dữ liệu ảnh được trích xuất thành các đối tượng đại diện.

3.2 Phạm vi nghiên cứu

- Các thuật toán phân tích chùm và phân loại cho hàm mật độ xác suất;
- Dữ liệu ảnh được trích xuất thành hàm mật độ xác suất đại diện;
- Vấn đề tính toán của các phương pháp phân loại, phân tích chùm.

4 Phương pháp nghiên cứu

- *Nghiên cứu lý thuyết*: Phân tích – tổng kết, phân loại – hệ thống hóa kiến thức về lĩnh vực nhận dạng thống kê; So sánh đánh giá ưu điểm và nhược điểm của các thuật toán.
- *Thực nghiệm khoa học*: Thực hiện các ví dụ số minh họa lý thuyết trong môi trường mô phỏng nhằm đánh giá các mô hình nhận dạng qua nhiều tiêu chí cụ thể, từ đó xử lý so sánh kết quả bằng các phân tích thống kê.

5 Cấu trúc luận văn

Luận văn bao gồm phần mở đầu, phần nội dung và phần kết luận, trong đó phần nội dung gồm ba chương:

Chương 1. Kiến thức chuẩn bị

Chương 2. Nhận dạng thống kê cho hàm mật độ xác suất với dữ liệu mất cân bằng

Chương 3. Ứng dụng cho dữ liệu ảnh

CHƯƠNG 1

KIẾN THỨC CHUẨN BỊ

1.1 Hàm mật độ xác suất

Hàm mật độ xác suất được xem như là đối tượng nghiên cứu của các nhà thống kê từ những năm 2010. Trong phần này, một vài các lý thuyết cơ sở được tổng hợp nhằm chuẩn bị cho nội dung tiếp theo.

Định nghĩa 1.1 (Biến ngẫu nhiên). Một biến ngẫu nhiên X trong không gian xác suất $(\Omega, \mathcal{E}, \mathbb{P})$ là một hàm Borel đo được từ Ω đến $\mathbb{R}$, tức là $X : (\Omega, \mathcal{E}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$.

Tương tự, ta mở rộng biến ngẫu nhiên d -chiều cho véc-tơ $\mathbf{X} = (X_1, X_2, \dots, X_d)$ trong $\mathbb{R}^d$, với mỗi thành phần $X_i, (i = 1, 2, \dots, d)$ là biến ngẫu nhiên trên $(\Omega, \mathcal{E}, \mathbb{R})$.

Định nghĩa 1.2 (Biến ngẫu nhiên d -chiều). Biến ngẫu nhiên d -chiều là một hàm Borel đo được từ không gian xác suất đến không gian Euclid $\mathbb{R}^d$, tức là $\mathbf{X} : (\Omega, \mathcal{E}) \rightarrow (\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$.

Định nghĩa 1.3 (Hàm phân phối). Hàm phân phối của biến ngẫu nhiên X là hàm $P = P_X : \mathbb{R} \rightarrow [0, 1]$ cho bởi

$$P(x) = \mathbb{P}\{\omega : X(\omega) \leq x\}, \forall x \in \mathbb{R}.$$

Tính chất 1.1. *Phân phối P thỏa mãn:*

1. P không giảm;
2. $\lim_{x \rightarrow \infty} P(x) = 1$ và $\lim_{x \rightarrow -\infty} P(x) = 0$
3. P liên tục phải, tức là $\lim_{x \downarrow y} P(x) = P(y)$
4. Nếu $P(x-) = \lim_{y \uparrow x} P(y)$ thì $P(x-) = \mathbb{P}(X < x)$
5. $\mathbb{P}(X = x) = P(x) - P(x-)$

Không mất tính tổng quát, ta giả sử các hàm mật độ được định nghĩa trên tập số thực. Họ các hàm phân phối $P : \mathbb{R} \rightarrow [0, 1]$ là liên tục tuyệt đối trong $(\Omega, \mathcal{B})$ -đo được với μ hoặc là độ đo Lebesgue hoặc độ đo đếm. Khi này, hàm mật độ trong không gian thực được định nghĩa

là

$$\forall x, f(x) = \frac{dP}{d\mu}(x) = \begin{cases} f(s), & \text{nếu } \mu \text{ là độ đo Lebesgue,} \\ \mathbb{P}(X = x) = p(x), & \text{nếu } \mu \text{ là độ đo đếm.} \end{cases}$$

Trong luận văn này, chúng tôi tập trung khảo sát tính chất của hàm mật độ (μ là độ đo Lebesgue) liên tục tuyệt đối của biến ngẫu nhiên X .

Tính chất 1.2.

1. Hàm mật độ xác suất liên tục $f(x)$ là hàm không âm, $f(x) \geq 0, \forall x \in \Omega$,
2. Tích phân $f(x)$ trên toàn miền Ω bằng 1,
3. Công thức xác suất trong tập Borel thực

$$\mathbb{P}(a < x < b) = \mathbb{P}(a < x \leq b) = \mathbb{P}(a \leq x < b) = \mathbb{P}(a \leq x \leq b) = \int_b^a f(x) dx.$$

Nhận xét. Các giá trị của mật độ xác suất thì có thể tùy ý, nhưng phải thỏa mãn Tính chất 1.2. Tương tự, xác suất tại điểm $x = x_0$ bất kỳ không được khảo sát trong hàm mật độ liên tục tuyệt đối mà một tập Borel thực như Tính chất 1.2.(3), nghĩa là xác suất tại điểm bất kỳ luôn bằng 0 đối với biến ngẫu nhiên X liên tục. $\square$

Định nghĩa 1.4 (Dữ liệu hàm mật độ 1-chiều). Dữ liệu hàm mật độ là một bộ đối tượng không chắc chắn o có dạng $(o_1, o_2, \dots, o_n)$ [15]. Mỗi đối tượng o_j chứa một cặp (I_j, f_j) với mỗi $1 \leq j \leq n$, trong đó $I_j = [l_j, u_j]$ là khoảng xác định của o_j và $f : \mathbb{R} \rightarrow \mathbb{R}^+$ là hàm mật độ xác suất xếp các giá trị xác suất vào mỗi $x \in I_j$ sao cho

$$\int_{x \in I_j} f_j(x) dx = 1 \text{ và } \int_{x \in \mathbb{R} \setminus I_j} f_j(x) dx = 0.$$

Định nghĩa 1.5 (Dữ liệu hàm mật độ d -chiều). Dữ liệu hàm mật độ d -chiều là một bộ đối tượng không chắc chắn o có dạng $(o_1, o_2, \dots, o_n)$ [15]. Mỗi đối tượng o_j chứa một cặp (R_j, f_j) với mỗi $1 \leq j \leq n$, trong đó $R_j = [l_1, u_1] \times \dots \times [l_d, u_d] \subseteq \mathbb{R}^d$ là vùng xác định d -chiều của o_j và $f : \mathbb{R}^d \rightarrow \mathbb{R}^{d+}$ là hàm mật độ xác suất xếp các giá trị xác suất vào mỗi $x \in R_j$ sao cho

$$\int_{x \in R_j} f_j(x) dx = 1 \text{ và } \int_{x \in \mathbb{R}^d \setminus R_j} f_j(x) dx = 0.$$

Nhận xét. Dữ liệu hàm mật độ xác suất có cấu trúc phức tạp và tốn nhiều thời gian thu thập. Hầu hết các dữ liệu hàm mật độ ta có thể bắt gặp đều là dữ liệu mô phỏng chùm hàm mật độ như [16, 17]. Trong thực tế, dữ liệu hàm mật độ 1-chiều cụ thể khám phá cơ cấu phân bố loài, là dữ liệu Cá hồi vây vàng (*Yellowfin tuna*) của [18] biểu diễn phân bố chiều dài của cá qua các ô tọa độ vùng biển Thái Bình Dương từ 2003 đến 2007. Ngoài ra, dữ liệu hàm mật độ 2-chiều chỉ xuất hiện khi ứng dụng trong phân tích chùm tương quan điểm số của sinh viên

các khoa/viện thuộc trường Đại học Cần Thơ. Đặc biệt, dữ liệu hàm mật độ còn được thành lập dựa trên dữ liệu hình ảnh trích xuất màu sắc nhưng vẫn rất hạn chế trong ứng dụng.

Để minh họa, luận văn này tập trung chủ yếu vào dữ liệu các hàm mật độ mô phỏng định nghĩa trên toàn không gian mẫu $I = \mathbb{R}$ hoặc $\mathbf{R} = \mathbb{R}^d$, và ký hiệu xuyên suốt là $\mathcal{F} = \{f_1(x), \dots, f_n(x)\}$. Về mặt nguyên tắc, dữ liệu hàm mật độ này có thể là rời rạc hoặc liên tục. Để đơn giản hóa, chúng tôi giả định các đối tượng là độc lập và cùng phân phối, và các dữ liệu hàm mật độ f_i là liên tục.

1.2 Một số hàm mật độ thông dụng

Trong thực tế, ta làm việc trên hàm mật độ xác suất cụ thể được nghiên cứu bởi các nhà khoa học thực nghiệm thỏa mãn các Tính chất 1.2. Hàm mật độ Gauss, rất quan trọng trong thống kê, được trình bày qua định nghĩa sau.


Định nghĩa 1.6 (Hàm mật độ Gauss). Biến ngẫu nhiên liên tục X tuân theo mật độ Gauss (chuẩn) với hai tham số μ và σ^2 (trong đó $\mu \in \mathbb{R}$ và $\sigma^2 \in \mathbb{R}_{>0}$) nếu nó có hàm mật độ xác suất là

$$\mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), x \in \mathbb{R}.$$


Định nghĩa 1.7 (Hàm mật độ Gauss d -chiều). Biến ngẫu nhiên liên tục d -chiều X tuân theo mật độ Gauss (chuẩn) với hai tham số μ và Σ (trong đó $\mu \in \mathbb{R}^d$ và Σ thuộc đa tạp của ma trận đối xứng xác định dương) nếu nó có hàm mật độ xác suất là

$$\mathcal{N}(\mathbf{x}; \mu, \Sigma) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x}-\mu)^\top \Sigma^{-1}(\mathbf{x}-\mu)\right), \mathbf{x} \in \mathbb{R}^d.$$

Định lý 1.1 (Kỳ vọng và phương sai). Kỳ vọng và phương sai của hàm mật độ xác suất Gauss là



(a) Hàm mật độ Gauss một chiều



(b) Hàm mật độ Gauss hai chiều

Hình 1.1. Hàm mật độ xác suất Gauss trong các không gian 1-chiều và 2-chiều

Hình 1.1 cho thấy hàm Gauss có dáng điệu hình cong đối xứng có miền xác định khắp miền không gian. Đặc trưng kỳ vọng μ chính là giá trị cực đại và thể hiện vị trí của hàm mật độ trong không gian, đặc trưng phương sai Σ thể hiện độ phân tán hay độ cao của hàm, phương sai càng nhỏ thì hàm mật độ càng cao và hẹp. Thông thường, dữ liệu rời rạc thường được biến đổi thành dữ liệu hàm mật độ qua biểu diễn của hàm mật độ Gauss (khi ước lượng tham số) hoặc nhân-Gauss (khi ước lượng phi tham số).

Ngoài ra, các phát triển bất đối xứng của Gauss điển hình là hàm Gauss-lệch [19]. với hàm mật độ của nó được định nghĩa như sau.

Định nghĩa 1.8 (Hàm mật độ Gauss-lệch). Biến ngẫu nhiên liên tục X tuân theo mật độ Gauss-lệch (chuẩn-lệch) [19] với ba tham số μ , σ^2 và α (trong đó $\mu, \alpha \in \mathbb{R}$ và $\sigma^2 \in \mathbb{R}_{>0}$) nếu nó có hàm mật độ xác suất là

$$\mathcal{S}\mathcal{N}(x; \mu, \sigma^2, \alpha) = \frac{2}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \int_{-\infty}^{\alpha(x-\mu)/\sigma} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{t^2}{2}\right) dt, x \in \mathbb{R}.$$

Định lý 1.2 (Kỳ vọng và phương sai).

Ngoài ra, các thuật toán phân tích chùm dựa vào trọng tâm đề xuất thêm hàm mật độ xác suất trọng tâm (hay hàm mật độ đại diện của chùm) [20, 21] có chức năng như trung bình có trọng số của tổng các hàm mật độ trong chùm.

Định nghĩa 1.9 (Hàm mật độ đại diện chùm). Cho tập $\mathcal{F}$ gồm n -hàm mật độ xác suất, trong đó, $\mathcal{F} = \{f_1(x), f_2(x), \dots, f_n(x)\}$ với $n \geq 2$. Ta phân bổ $\mathcal{F}$ vào c -chùm ($1 < c \leq n$), khi này hàm mật độ đại diện của các chùm c_i là

$$\theta_i = \frac{\sum_{j=1}^n \mu_{ij} \times f_j}{\sum_{j=1}^n \mu_{ij}}, \quad (1.1)$$

trong đó, μ_{ij} là trọng số phân bổ hàm mật độ f_j bất kỳ vào chùm c_i .

Nhận xét. Dựa vào định nghĩa trên, ta dễ dàng nhận được θ_i cũng là một hàm mật độ thỏa Tính chất 1.2. Thật vậy, các giá trị trọng số $0 \leq \mu_{ij} \leq 1$ nên các θ_i liên tục không âm, và

$$\int_{\Omega} \theta_i(x) dx = \int_{\Omega} \frac{\sum_{j=1}^n \mu_{ij} \times f_j}{\sum_{j=1}^n \mu_{ij}} dx = \frac{\sum_{j=1}^n \mu_{ij} \times \int_{\Omega} f_j(x) dx}{\sum_{j=1}^n \mu_{ij}} = 1.$$

Ta cũng mở rộng được cho hàm mật độ đại diện chùm đến không gian d -chiều tương tự cho véc-tơ ngẫu nhiên $\mathbf{X}$. Ngoài ra, [16, 22] đề xuất hàm mật độ đại diện Gauss như là một phiên bản đơn giản hóa hàm mật độ kết hợp (1.1). Hàm mật độ đại diện Gauss có dạng phân phối chuẩn $\mathcal{N}(\mu, \Sigma)$ sao cho tổng khoảng cách giữa chúng đến các hàm mật độ khác là nhỏ nhất, tức là

$$\theta_{G_i} = \arg \min_{f(\mu, \Sigma)} \sum_{j=1}^n \mu_{ij} D(f(\mu, \Sigma), f_j).$$

Hình ?? minh họa cụ thể hai cách biểu diễn hàm mật độ đại diện trong cùng một chùm hàm mật độ $\mathcal{F}$ bằng đường thẳng in đậm. Để thấy sự khác biệt, hàm mật độ đại diện tập trung vào vị trí của nó trong không gian, còn hàm mật độ đại diện Gauss chuyển dịch chùm hàm mật độ thành một đại diện Gauss đơn giản hơn.

1.3 Độ đo đánh giá sự tương tự của các hàm mật độ xác suất

Khoảng cách là độ đo xa-gần các vật thể. Ở đây, khái niệm *khoảng cách* bao hàm cả *độ đo phân biệt*. Phần này giới thiệu một số loại khoảng cách đối với hai đối tượng hàm mật độ bao gồm: khoảng cách hai hàm mật độ, một hàm mật độ với một chùm hàm và giữa hai chùm hàm mật độ bất kỳ.

1.3.1 Sự tương tự của hai hàm mật độ xác suất

Cho f, g là hai hàm mật độ Radon-Nikodym tương ứng với độ đo trong không gian đo được $(\Omega, \mathcal{B})$ với $\mathcal{X} \subseteq \mathbb{R}^d$.

Định nghĩa 1.10 (Khoảng cách hàm mật độ). Hàm $D : \mathcal{F} \rightarrow \mathbb{R}$ được gọi là khoảng cách của hai hàm mật độ f và g nếu nó thỏa mãn ba điều kiện [23]

1. $D(f, g) \geq 0$,
2. $D(f, g) = 0$ khi và chỉ khi $f \equiv g$, và

Theo Định nghĩa 1.10, khoảng cách giữa hai hàm mật độ thỏa mãn các tiên đề của mê-tríc. Trong lý thuyết thống kê và thông tin, một mê-tríc được gọi là *khoảng cách* và nửa mê-tríc gọi là *phân kỳ*. Các khoảng cách của hai hàm mật độ xác suất được thành lập theo hai các tiếp cận: véc-tơ và xác suất. Cách tiếp cận véc-tơ xem xét các mức giá trị là điểm trong không gian Euclide, nên chúng cũng có thể tính toán dựa vào các khoảng cách hình học thông thường.

Bảng 1.1 làm rõ các công thức khoảng cách và độ đo tương tự giữa hai hàm mật độ xác suất.

Bảng 1.1. Bảng tổng kết các loại khoảng cách giữa hai hàm mật độ xác suất


Khoảng cách	D	Miền giá trị	Đối xứng	Tam giác	Không âm
Chernoff	$-\log \left(\int_{\Omega} f(x)^s g(x)^{1-s} dx \right)$	$[0, \infty]$	✓		✓
$\mathcal{L}_p$	$\left(\int_{\Omega} f(x) - g(x) ^p dx \right)^{1/p}$	$[0, 2]$	✓	✓	✓
Hellinger [24]	$\left(1 - \sqrt{\int_{\Omega} f(x)g(x) dx} \right)$	$[0, 1]$	✓	✓	✓

Nhận xét. Nhìn Bảng 1.1, khoảng cách Chernoff là tổng quát hóa của khoảng cách Bhattacharyya với $s = 1/2$. Thông thường, ta sử dụng khoảng cách $\mathcal{L}_1$ và $\mathcal{L}_2$ cho các ứng dụng. Cả hai loại khoảng cách $\mathcal{L}_p$ và Hillinger đều là mê-tríc trong không gian các hàm mật độ $\mathcal{F}$.

Định nghĩa 1.11 (Affinity). Hàm $\rho : f \rightarrow [0, 1]$ được gọi là affinity của hai hàm mật độ f_1 và f_2 nếu nó thỏa mãn ba điều kiện

1. $0 \leq \rho(f_1, f_2) \leq 1$,
2. $\rho(f_1, f_2) = 1$ nếu và chỉ nếu $f_1 \equiv f_2$, và
3. mỗi dãy hàm $\{f_n\}$ thì $\rho(f_n, f_0) \rightarrow 1$

Nhận xét. Ta có tương quan giữa Affinity và Khoảng cách giữa hai hàm mật độ xác suất f_1 và f_2 là $D(f_1, f_2) = 1 - \rho(f_1, f_2)$.



Hình 1.2. Minh họa khoảng cách $\mathcal{L}_2$ và một vài Affinity phổ biến giữa hai hàm mật độ Gauss $\mathcal{N}(1, 1)$ và $\mathcal{N}(4, 1)$


Ví dụ (Khoảng cách $\mathcal{L}_2$ cho hàm mật độ Gauss).

Ví dụ (Khoảng cách Bhattacharyya cho hàm mật độ Gauss). Khoảng cách Bhattacharyya giữa hai hàm mật độ Gauss d -chiều f_1 và f_2 là

$$D_{BC}(f_1, f_2) = \frac{1}{8} \mu^\top \Gamma^{-1} \mu + \frac{1}{2} \log(|\Sigma_1|^{-1/2} |\Sigma_2|^{-1/2} |\Gamma|)$$

Ví dụ (Khoảng cách Hellinger cho hàm mật độ Gauss).

$$D_H(f_1, f_2) = \left(2 - 2|\Gamma|^{-1/2} |\Sigma_1|^{1/4} |\Sigma_2|^{1/4} \right)^{1/2}$$



Hình 1.3. Dãy khoảng cách giữa hai hàm mật độ Gauss $\mathcal{N}(0, 1)$ và $\mathcal{N}(\mu, 1)$

Ở Hình 1.3, chúng tôi ghi nhận giá trị khoảng cách khi duyệt qua từ $f_1 \sim \mathcal{N}(0, 1)$ và $f_2 \sim \mathcal{N}(\mu, 1)$ với μ chạy từ -10 đến 20 . Ta nhận ra khoảng cách $\mathcal{L}_1$ là hàm không trơn tại $\mu = 0$

1.3.2 Sự tương tự của nhiều hơn hai hàm mật độ xác suất

a. Liên kết chùm hàm mật độ

Giả sử hai chùm hàm mật độ không rỗng $\mathcal{F}$ và $\mathcal{G}$ chứa hữu hạn phần tử và $D(f, g)$ là khoảng cách giữa hai hàm mật độ cho trước. Khoảng cách giữa hai chùm hàm mật độ gọi là *liên kết*.

Bảng 1.2. Bảng tổng kết các loại liên kết giữa hai chùm hàm mật độ xác suất

Liên kết	δ
Liên kết đủ ¹ [25]	$\delta = \max_{f \in \mathcal{F}, g \in \mathcal{G}} D(f, g)$
Liên kết đơn ² [26]	$\delta = \min_{f \in \mathcal{F}, g \in \mathcal{G}} D(f, g)$
Liên kết tâm	$\delta = D(\theta_{\mathcal{F}}, \theta_{\mathcal{G}})$
Liên kết Ward [27]	$\sum_{h \in \mathcal{F} \cup \mathcal{G}} D^2(f, \theta_{\mathcal{F} \cup \mathcal{G}}) - (\sum_{f \in \mathcal{F}} D^2(f, \theta_{\mathcal{F}}) + \sum_{g \in \mathcal{G}} D^2(g, \theta_{\mathcal{G}}))$
Liên kết	

2

b. Tương tự chùm hàm mật độ

Giả sử tập hợp $\mathcal{F}$ có nhiều hơn hai phần tử ($n > 2$)

Bảng 1.3. Tổng kết các tương tự giữa các chùm hàm mật độ xác suất

Tương tự	$\Delta(\mathcal{F})$
Affinity của Matusita [28]	$\int_{\Omega} \left(\prod_{j=1}^n f_j(x) \right)^{1/n} dx$
Affinity của Toussaint [29]	$\int_{\Omega} \left(\prod_{j=1}^n f_j(x) \right)^{\alpha_j} dx$
Độ rộng chùm [30]	$\int_{\Omega} f_{\max}(x) dx - 1$
Hệ số tương tự chùm [31]	$\frac{k}{k-1} \left(1 - \frac{1}{k} \int_{\Omega} f_{\max}(x) dx \right)$

Nhận xét. Trong Bảng 1.3 trường hợp Affinity của Toussaint có các hệ số $\alpha_1 = \alpha_2 = \dots = \alpha_n = \frac{1}{n}$, nó trở thành Affinity của Matusita. Khi Affinity của Matusita có $n = 2$ thì nó trở thành hệ số Bhattacharrya []. Ngoài ra hệ số tương tự chùm tổng quát hóa độ rộng chùm với $k = 2$.

1.4 Xấp xỉ tích phân

Trong khoa học máy tính, các khoảng cách hàm mật độ phải được tính xấp xỉ vì có chứa tích phân xác định.

1.5 Một số định lý hội tụ

1.6 Phân tích chùm cho hàm mật độ xác suất

Phân tích chùm là một nhánh của nhận dạng không được giám sát. Nó có nhiệm vụ khám phá sự tương tự giữa các mẫu trong dữ liệu đầu vào [4, 8]. Ví dụ như khi ta cần phân đoạn một đối tượng trong nội dung hình ảnh, hay trong các báo cáo định tính cần nhóm/tổng hợp ý kiến, quan điểm theo các chủ đề khác nhau, bản chất ta phải giải quyết bằng phân tích chùm. Các thuật toán này thích hợp để khám phá các cấu trúc và mối quan hệ có ý nghĩa giữa các mẫu trong dữ liệu, tạo điều kiện thuận lợi cho nhiều ứng dụng và phân tích sâu hơn. Ta cũng có phân tích chùm các hàm mật độ xác suất là bài toán phân tích chùm cho đối tượng các hàm mật độ xác suất [11, 20].

Giả sử $\mathcal{S}$ là tập các véc-tơ d -chiều $\mathbf{x}_j$, trong đó $j = 1, 2, \dots, n$. Mỗi đối tượng o_j liên hệ với hàm mật độ xác suất $f_j(\mathbf{x})$. Tập $\mathcal{F}$ gồm họ n -hàm mật độ trên Ω . Bài toán phân tích chùm phân bổ j -hàm mật độ vào c -chùm nguyên, với $i = 1, 2, \dots, c$ thỏa mãn ba ràng buộc

1. Hợp tất cả các chùm $\bigcup_i c_i$ bằng $\mathcal{F}$,
2. Giao của mỗi chùm là rỗng, $c_i \cap c_j = \emptyset$, với mỗi $i \neq j$,
3. Lực lượng của mỗi chùm là khác rỗng, $|c_i| \neq \emptyset$.

Phép gán này được mô tả bằng một ánh xạ many-to-one, hay còn gọi là *bộ mã hóa* (encoding) $i = c(j)$, trong đó đối tượng thứ j được gán vào cụm thứ i . Ràng buộc 1 đảm bảo tất cả các mẫu phải được phân tách thành các chùm, trong đó, mỗi chùm phải chứa ít nhất một phần tử (Ràng buộc 3) và không có mẫu nào được xếp vào cùng một chùm (Ràng buộc 2).

Thuật toán phân chùm dựa vào trọng tâm đề xuất hàm mục tiêu khác nhau, nhưng tư tưởng chung là sự phân bổ tối thiểu khoảng cách phần tử trong chùm trong khi vẫn giữ tối đa khoảng cách phần tử giữa các chùm. Tác vụ này được chia thành hai loại theo lý thuyết mờ [32] là phân chùm không mờ (như k -mean [11]) và phân chùm mờ (như Fuzzy c -means [20, 21]).

1.6.1 Phân tích chùm không mờ

Phân tích chùm không mờ (hay phân chùm cứng) yêu cầu một phần tử chỉ thuộc duy nhất một chùm cố định. Tiểu mục này trình bày k -means và phân tích chùm tự cập nhật là các thuật toán đã được sử dụng tích cực cho dữ liệu hàm mật độ xác suất.

a. Phân tích chùm k -means

Thuật toán k -means nguyên bản được đề cập bởi J. Macqueen [7] cho dữ liệu rời rạc nhưng mãi đến [11, 30], nó được mở rộng cho hàm mật độ với đáng vấp của bán giám sát hiện đại. Xét k -means là bài toán tối thiểu đơn mục tiêu là tổng các bình phương trong chùm nhằm

tìm kiếm các θ_i , ta có

$$\text{Minimize : } J(\mathbf{U}, \Theta | \mathcal{F}, c) = \sum_{i=1}^c \sum_{f_j \in c_i} \mu_{ij} d^2(\theta_i, f_j), \quad (k\text{-means})$$

trong đó, μ_{ij} là biến tiềm ẩn thể hiện mức độ thành viên của hàm mật độ j thỏa $\mu_{ij} = 1$ nếu hàm j thuộc cụm c_k và $\mu_{ij} = 0$ nếu ngược lại. $d^2(\theta_i, f_j)$ là khoảng cách giữa hàm mật độ trọng tâm đến các đối tượng f_j còn lại trong dữ liệu.

Bổ đề 1.1 (Thành lập hàm mật độ đại diện).

$$\theta_i = \frac{\sum_{f_j \in c_i} \mu_{ij} f_j}{\sum_{f_j \in c_i} \mu_{ij}} \quad (1.2)$$

Chứng minh. Từ hàm mục tiêu k -means, ta tính các đạo hàm riêng theo c_i .

$$\begin{aligned} \frac{\partial}{\partial \theta_i} J(\mathcal{F}, c) &= \frac{\partial}{\partial \theta_i} \sum_{i=1}^c \sum_{f_j \in c_i} \mu_{ij} d^2(\theta_i, f_j) = \sum_{i=1}^c \sum_{f_j \in c_i} \mu_{ij} \frac{\partial}{\partial \theta_i(x)} \int_{\Omega} (\theta_i(x) - f_j(x))^2 dx \\ &= \sum_{f_j \in c_i} \mu_{ij} \int_{\Omega} 2(\theta_i(x) - f_j(x)) dx. \end{aligned}$$

Để hàm J đạt cực trị, ta cho đạo hàm vừa tính bằng 0. Tức là,

$$\sum_{f_j \in c_i} \mu_{ij} \int_{\Omega} 2(\theta_i(x) - f_j(x)) dx = 0 \Leftrightarrow \theta_i \sum_{f_j \in c_i} \mu_{ij} = \sum_{f_j \in c_i} \mu_{ij} f_j \Leftrightarrow \theta_i = \frac{\sum_{f_j \in c_i} \mu_{ij} f_j}{\sum_{f_j \in c_i} \mu_{ij}}$$

Tóm lại, mật độ đại diện tối ưu để cực tiểu hàm mục tiêu là hàm mật độ trọng tâm (1.1) các hàm mật độ trong các cụm. $\square$

Nhận xét. Vì mỗi hàm mật độ trọng tâm (1.1) được đại diện bằng trung bình có trọng số của từng cụm, nên có thể kết quả trọng tâm này không đồng nhất với bất kỳ đối tượng nào trong mẫu. Thay vào đó, mật độ trọng tâm này mô tả một giả định nằm bất kỳ làm nguyên mẫu để các hàm mật độ các so sánh [33]. Hơn nữa, vì ma trận phân vùng (??) của k -means là phân vùng cứng nên ta có thể rút gọn hàm mật độ đại diện (1.2) thành

$$\theta_i = \frac{1}{|c_i|} \sum_{f_j \in c_i} f_j \quad (1.3)$$

Algorithm 1: Giải thuật phân tích cụm k -means (KCF)

```
1: procedure KCF( $c, \varepsilon$ ) ▷ Cho trước số cụm  $c$ 
2:    $t \leftarrow 0$ 
3:   Khởi tạo  $\mu^{(t)}$  và  $\Theta^{(t)}$  ngẫu nhiên
4:   while  $\|J^{(t+1)} - J^{(t)}\| < \varepsilon$  do
5:      $t \leftarrow t + 1$ 
6:     Cập nhật  $\mu^{(t+1)}$  bằng Công thức (??)
7:     Cập nhật  $\Theta^{(t+1)}$  bằng Công thức (1.3)
8:   end while
9:   return  $\mu$  và  $\Theta$ . ▷ Ma trận phân vùng và hàm mật độ đại diện
10: end procedure
```

Bổ đề 1.2 (Sự hội tụ). Sau mỗi bước lặp của thuật toán k -means, hàm mục tiêu k -means luôn giảm.

Chứng minh. Giả sử tập $\mathcal{Z}^{(t)} = \{\mathcal{F}_1^{(t)}, \dots, \mathcal{F}_k^{(t)}\}$ là phân hoạch của tập $\mathcal{F}$ tại bước lặp t bất kỳ và hàm mục tiêu $J^{(t)}$. Khi đó, $J^{(t+1)}$ có phân hoạch $\mathcal{Z}^{(t+1)}$ tại bước lặp tiếp theo. Ta cần chứng minh $J^{(t)} - J^{(t+1)} \geq \sum_{i=1}^c |\mathcal{F}_i^{(t+1)}| d(\theta_{\mathcal{F}_i^{(t)}} - \theta_{\mathcal{F}_i^{(t+1)}})$. □

b. Phân tích cụm thứ bậc

1.6.2 Phân tích cụm mờ

Phân tích cụm mờ được xây dựng lần đầu tiên cho hàm mật độ bởi [20] với sự phát triển từ phần tử rời rạc do [34]. Khác biệt giữa nó với phân cụm cứng là sự chấp nhận thuộc nhiều cụm của một phần tử với một *mức độ phân vùng* mềm hơn. Điều này hữu ích khi ranh giới giữa các hàm là không chắc chắn.

Giả sử $\mathcal{F}$ chưa được gán nhãn, mục tiêu của bài toán là tối thiểu hóa tổng trọng số các giá trị hàm thành viên với siêu tham số m và khoảng cách.

$$\begin{aligned} \text{Minimize : } J(\mathbf{U}, \Theta | \mathcal{F}, c, m) &= \sum_{i=1}^c \sum_{j=1}^n \mu_{ij}^m d^2(\theta_i, f_j), & (\text{FCF}) \\ \text{s.t : } & (??), (??), (??). \end{aligned}$$

Thuật toán phân tích cụm mờ cho phần tử rời rạc đã được chứng minh là tối ưu toàn cục bởi [32, 35, 36] qua định lý Zangwill [37]. Đặc biệt, [38] mới đây chứng minh sự hội tụ toàn cục qua thuật toán gradient. Do đó, luận văn này chỉ giới thiệu Định lý 1.4 trình bày sự thành lập của ma trận phân vùng và hàm mật độ đại diện từ hàm mục tiêu J cho dữ liệu hàm mật độ xác suất.

Định lý 1.3. Cho $\mathcal{F}$ chứa $n > c$ hàm mật độ xác suất và $m > 1$. Xét $D_{ij} = \mathcal{L}_1^2(\theta_i, f_j)$ với $1 \leq j \leq n, 1 \leq i \leq c$. Với mỗi j , xác định các tập $I_j = \{i \mid D_{ij} = 0, 1 \leq i \leq c\}$ và tập $I_j^c = \{1, \dots, c\} \setminus I_j$. Khi đó J có thể đạt cực tiểu toàn cục khi và chỉ khi

$$\theta_i^* = \frac{\sum_{j=1}^n (\mu_{ij}^*)^m f_j}{\sum_{j=1}^n (\mu_{ij}^*)^m}, \text{ và} \quad (1.4)$$

$$\mu_{ij}^* = \frac{(D_{ij}^*)^{-1/(m-1)}}{\sum_{l=1}^n (D_{lj}^*)^{-1/(m-1)}}, \text{ nếu } I_j \neq \emptyset, \text{ và}, \quad (1.5)$$

$$\mu_{ij}^* = 0, \forall i \in I_j^c \text{ và } \sum_{i \in I_j^c} \mu_{ij}^* = 1, \text{ nếu } I_j \neq \emptyset, \quad (1.6)$$

trong đó, $D_{ij}^* = \mathcal{L}_2(f_j, \theta_i^*), 1 \leq j \leq n, 1 \leq i \leq c$.

Thuật toán phân cụm mờ FCF được thực hiện qua các bước như sau [6, 20].

Algorithm 2: Giải thuật phân tích cụm mờ (FCF)

```

1: procedure FCF( $c, \varepsilon$ ) ▷ Cho trước số cụm  $c$ 
2:    $t \leftarrow 0$ 
3:   Khởi tạo  $\mu^{(t)}$  và  $\Theta^{(t)}$  ngẫu nhiên
4:   while  $\|\mu^{(t+1)} - \mu^{(t)}\| < \varepsilon$  do
5:      $t \leftarrow t + 1$ 
6:     Cập nhật  $\mu^{(t+1)}$  bằng Công thức (1.5) và (1.6)
7:     Cập nhật  $\Theta^{(t+1)}$  bằng Công thức (1.4).
8:   end while
9:   return  $\mu$  và  $\Theta$ . ▷ Ma trận phân vùng và hàm mật độ đại diện
10: end procedure

```

Kết thúc thuật toán ta nhận được ma trận phân vùng U_f và các trọng tâm cụm Θ . Một phần tử f_j được xếp vào cụm c_i khi và chỉ khi nó có mức độ phân vùng là cao nhất.

Ví dụ (Phân cụm mờ hàm Gauss 1-chiều). Cho bảy hàm mật độ chuẩn một chiều $\mathcal{F}$ cho bởi [30] có phương sai đồng nhất $\sigma_i^2 = 1, i = 1, \dots, 7$ và các trung bình lần lượt là

$$\mu_i = \{0, 3; 4, 0; 9, 1; 1, 0; 5, 5; 8, 0; 4, 8\}.$$

Hãy phân tích $\mathcal{F}$ thành ba cụm, biết $m = 2$ và khoảng cách là $\mathcal{L}_1$.

Bài giải. Với các thông số ban đầu $c = 3, \varepsilon = 10^{-3}$ và khoảng cách $\mathcal{L}_1$, ta tiến hành

thuật toán phân tích cụm mờ. Giả sử ma trận phân vùng U_f được tạo ngẫu nhiên

$$\mu^{(0)} = \begin{pmatrix} 0.37 & 0.56 & 0.20 & 0.33 & 0.18 & 0.41 & 0.12 \\ 0.63 & 0.27 & 0.37 & 0.26 & 0.79 & 0.25 & 0.17 \\ 0.00 & 0.17 & 0.43 & 0.42 & 0.02 & 0.34 & 0.70 \end{pmatrix}$$

So sánh về mặt phức tạp thời gian và phức tạp dung lượng, k -mean đơn giản hơn và ít tốn tài nguyên tính toán hơn so với Fuzzy c -mean và thuật toán thứ bậc.

Bảng 1.4. So sánh độ phức tạp của ba loại phân tích cụm

Thuật toán	Phức tạp thời gian	Phức tạp không gian
k -mean	$\mathcal{O}(ncdi)$	$\mathcal{O}(n)$
k -medoids	$\mathcal{O}(ncdi)$	$\mathcal{O}(n)$
Fuzzy c -mean	$\mathcal{O}(nc^2di)$	$\mathcal{O}(n)$

Nhận xét. Phân tích cụm phân vùng dựa vào trọng tâm nói chung là đơn giản. Tuy nhiên, nó cũng có một số điểm chưa tối ưu bao gồm tính tối ưu của siêu tham số, chất lượng dữ liệu, độ mờ đục của mô hình và cơ hội sử dụng (sai). Đầu tiên, họ thuật toán này không cung cấp c cụm tối ưu. Đôi khi, ta không có tri thức về số lượng c , dẫn đến khó khăn khi phân cụm các mẫu có số chiều lớn dẫn đến *quá khớp*. Theo Goutte *et al.* “*khi số lượng cụm không phản ánh trong dữ liệu, kết quả cuối cùng cơ bản là vô nghĩa*” [39]. Ngoài ra, thuật toán k -means dựa trên tối ưu lồi nên không thích hợp để khám phá loại dữ liệu có hình dáng khác nhau. Cuối cùng, sự tiềm ẩn của dữ liệu có các bất thường như nhiễu, các ngoại lệ, dữ liệu có chồng chéo hay mất cân bằng đều tác động tiêu cực đến thuật toán. Bất kỳ tuyên bố về tính khách quan đều phụ thuộc vào các đầu vào do người dùng cung cấp và được trung gian bởi các đầu ra do người dùng diễn giải [33, 40].

1.7 Phân loại cho hàm mật độ xác suất

Phương pháp phân loại là một nhánh của nhận dạng có giám sát, phát triển với mục tiêu thành lập mô hình (hay quy tắc) có chức năng phân tách được các lớp quan tâm với sai lầm tối thiểu. Các quy luật đánh giá có bệnh B hay không dựa vào những dữ liệu cho trước chính là thực hiện bài toán phân loại. Hay phân biệt được hữu hạn các biểu cảm khuôn mặt dựa vào hình ảnh cũng phải thực hiện bài toán phân loại. Đầu ra của mô hình phân loại là ước tính hoặc dự đoán hữu hạn các nhãn cho trước, không bao gồm phép đo [41].

Bốn thuật toán phân loại dựa vào thống kê là Naive Bayes, Cây quyết định, hồi quy Logistics, phân biệt Fisher [42] và Perceptron [43]. Những phương pháp này là kinh điển và

đã được áp dụng phát triển cho đến hiện nay. Nó cũng chính là cơ sở để xây dựng và áp dụng cho hàm mật độ xác suất với sự cải tiến, đặc biệt là phương pháp Bayes [17, 44].

Phương pháp phân loại cho hàm mật độ xác suất là một bài toán mới mẻ nên còn nhiều thách thức lớn cả bề sâu và bề rộng.

1.7.1 Vấn đề tìm xác suất tiên nghiệm

biến

1.7.2 Thuật toán phân loại

1.8 Tổng kết Chương 1

CHƯƠNG 2

NHẬN DẠNG THÔNG KÊ CHO HÀM MẬT ĐỘ XÁC SUẤT VỚI DỮ LIỆU MẤT CÂN BẰNG

2.1 Giới thiệu

2.1.1 Giới thiệu bài toán phân tích chùm cho dữ liệu mất cân bằng

Phân tích chùm cho dữ liệu mất cân bằng là chủ đề phát triển để giải quyết nhu cầu thực tế. Bài toán gán nhãn một hình ảnh hai ngôi sao được ghi nhận là có sự mất cân bằng, hay phân đoạn chuỗi tín hiệu có nhiễu cũng có tính chất mất cân bằng. Việc giải quyết bằng phân tích chùm là bước tiền xử lý quan trọng cho các khám phá tiếp theo. Tựu trung lại, dữ liệu mất cân bằng tồn tại hai tình trạng: Kích thước chùm và số lượng phần tử trong chùm mất cân bằng. Kích thước chùm mất cân bằng xảy ra khi

Các bài toán này đòi hỏi nhiều kỹ thuật phân tích chùm rất cao. Ở dữ liệu rời rạc, thuật toán phân tích chùm mất cân bằng đã được giải quyết rất tốt.

Tuy nhiên, các thuật toán này thường giả định các chùm có cùng kích thước [45]. Khi có sự khác biệt lớn về số lượng phần tử hoặc kích thước chùm không đồng đều, các thuật toán phân chùm phân vùng có xu hướng tạo ra độ lệch trọng tâm đáng kể đối với các chùm có kích thước nhỏ [46].

2.1.2 Giới thiệu bài toán phân loại cho dữ liệu mất cân bằng

2.2 Các vấn đề liên quan

2.2.1 Một số khái niệm liên quan

2.2.2 Tham số đánh giá thuật toán phân tích chùm

Đánh giá phân tích chùm cho biết độ hiệu quả thực thi của thuật toán bao gồm độ chính xác và độ phù hợp với thực tế. Mục đích của việc đánh giá là mang lại góc nhìn cụ thể về kết quả của từng thuật toán và giữa các thuật toán với nhau. Đánh giá kết quả phân tích chùm diễn ra trong hai trường hợp: đánh giá bên trong và bên ngoài. Tiêu chí đánh giá ngoài cung cấp độ chính xác giữa nhãn thực tế và nhãn kết quả của phân tích chùm trong các ví dụ mô phỏng.

Nhưng trong thực tế, ta không có thông tin chính xác của nhãn nên phải đánh giá nội bộ. Đánh giá nội bộ cung cấp độ phù hợp của các chùm trong dữ liệu chưa được gán nhãn.

a. Đánh giá bên trong

a. Đánh giá bên ngoài

2.2.3 Tham số đánh giá thuật toán phân loại

Đối với thuật toán phân loại, ta đánh giá kết quả độ chính xác việc thực thi đến một đối tượng chưa được huấn luyện qua (hay tập kiểm tra). Các dự đoán từ mô hình so với thực tế sẽ được tổng hợp qua ma trận nhầm lẫn.

2.3 Phân tích chùm cho hàm mật độ xác suất với dữ liệu mất cân bằng

2.3.1 Thuật toán

2.3.2 Sự hội tụ của thuật toán

2.3.3 Ví dụ minh họa

2.3.4 Đánh giá thuật toán

2.4 Phân loại cho hàm mật độ xác suất với dữ liệu mất cân bằng

2.4.1 Thuật toán

2.4.2 Sự hội tụ của thuật toán

2.4.3 Ví dụ minh họa

2.4.4 Đánh giá thuật toán

2.4.5 Tổng kết chương 2

CHƯƠNG 3

ỨNG DỤNG CHO DỮ LIỆU ẢNH

3.1 Trích xuất đặc trưng của ảnh thành hàm mật độ xác suất

3.1.1 Vấn đề trích xuất đặc trưng của ảnh

3.1.2 Ước lượng hàm mật độ xác suất đại diện cho ảnh

Ước lượng hàm mật độ là bài toán phái sinh khi dữ liệu cần được chuyển thành dữ liệu hàm mật độ.

3.2 Ứng dụng của bài toán phân tích chùm

3.2.1 Dữ liệu

3.2.2 Phương pháp thực hiện

3.2.3 Kết quả thực hiện

3.3 Ứng dụng của bài toán phân loại

3.3.1 Dữ liệu

3.3.2 Phương pháp thực hiện

3.3.3 Kết quả thực hiện

3.3.4 Tổng kết chương 3

PHẦN KẾT LUẬN

1 Kết luận

Trí tuệ nhân tạo là trọng tâm, là mũi đột phá chính của phát triển khoa học công nghệ, đổi mới sáng tạo và chuyển đổi số.

2 Định hướng nghiên cứu

TÀI LIỆU THAM KHẢO

- [1] A. Belhadi, V. Mani, S. S. Kamble, S. A. R. Khan, and S. Verma, “Artificial intelligence-driven innovation for enhancing supply chain resilience and performance under the effect of supply chain dynamism: an empirical investigation,” *Annals of Operations Research*, vol. 333, no. 2, pp. 627–652, 2024.
- [2] A. I. Act, “Artificial intelligence act,” *Euroopan unioni. Luettavissa: <https://artificialintelligen>*, 2023.
- [3] P. K. Dey, S. Chowdhury, A. Abadie, E. Vann Yaroson, and S. Sarkar, “Artificial intelligence-driven supply chain resilience in vietnamese manufacturing small-and medium-sized enterprises,” *International Journal of Production Research*, vol. 62, no. 15, pp. 5417–5456, 2024.
- [4] C. M. Bishop and H. Bishop, *Deep Learning: Foundations and Concepts*. Springer, 2024.
- [5] S. Theodoridis and K. Koutroumbas, *Pattern recognition*. Elsevier, 2006.
- [6] J. C. Bezdek, R. Ehrlich, and W. Full, “Fcm: The fuzzy c -means clustering algorithm,” *Computers & geosciences*, vol. 10, no. 2-3, pp. 191–203, 1984.
- [7] J. Macqueen, “Some methods for classification and analysis of multivariate observations,” in *Proceedings of 5-th Berkeley Symposium on Mathematical Statistics and Probability/University of California Press*, 1967.
- [8] A. R. Webb, *Statistical pattern recognition*. John Wiley & Sons, 2003.
- [9] D. Zha, Z. P. Bhat, K.-H. Lai, F. Yang, Z. Jiang, S. Zhong, and X. Hu, “Data-centric artificial intelligence: A survey,” *arXiv preprint arXiv:2303.10158*, 2023.
- [10] C. Cortes, “Support-vector networks,” *Machine Learning*, 1995.
- [11] T. Nguyen-Trang, Y. Nguyen-Hoang, and T. Vo-Van, “A new semi-supervised clustering algorithm for probability density functions and applications,” *Neural Computing and Applications*, vol. 36, no. 11, pp. 5965–5980, 2024.
- [12] X. Hu, H. Chen, J. Zhang, H. Chen, S. Liu, X. Li, Y. Wang, and X. Xue, “Gat-cobo: Cost-sensitive graph neural network for telecom fraud detection,” *IEEE Transactions on Big Data*, 2024.
- [13] G. H. Nguyen, A. Bouzerdoum, and S. L. Phung, “Learning pattern classification tasks with imbalanced data sets,” *Pattern recognition*, vol. 10, no. 2009, pp. 1322–1328, 2009.

- [14] Y. Tang, Y.-Q. Zhang, N. V. Chawla, and S. Krasser, "Svms modeling for highly imbalanced classification," *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)*, vol. 39, no. 1, pp. 281–288, 2008.
- [15] F. Gullo, G. Ponti, A. Tagarelli, and S. Greco, "A hierarchical algorithm for clustering uncertain data via an information-theoretic approach," in *2008 Eighth IEEE International Conference on Data Mining*, pp. 821–826, IEEE, 2008.
- [16] T. Nguyen-Trang, T. Nguyen-Thoi, and T. Vo-Van, "Globally automatic fuzzy clustering for probability density functions and its application for image data," *Applied Intelligence*, vol. 53, no. 15, pp. 18381–18397, 2023.
- [17] T. Vo-Van and D. PhamToan, "A supervised learning algorithm based on the quasi-bayesian method for the probability density functions and application for medical data," *Knowledge-Based Systems*, p. 112003, 2024.
- [18] M. Minami and C. E. Lennert-Cody, "Regression tree and clustering for distributions, and homogeneous structure of population characteristics," *Journal of Agricultural, Biological and Environmental Statistics*, pp. 1–20, 2024.
- [19] A. Azzalini, "A class of distributions which includes the normal ones," *Scandinavian journal of statistics*, pp. 171–178, 1985.
- [20] T. Nguyentrang and T. Vovan, "Fuzzy clustering of probability density functions," *Journal of Applied Statistics*, vol. 44, no. 4, pp. 583–601, 2017.
- [21] T. Vovan, "Cluster width of probability density functions," *Intelligent Data Analysis*, vol. 23, no. 2, pp. 385–405, 2019.
- [22] T. Nguyen-Trang, T. Nguyen-Thoi, K.-N. Nguyen-Thi, and T. Vo-Van, "Balance-driven automatic clustering for probability density functions using metaheuristic optimization," *International Journal of Machine Learning and Cybernetics*, vol. 14, no. 4, pp. 1063–1078, 2023.
- [23] S. M. Ali and S. D. Silvey, "A general class of coefficients of divergence of one distribution from another," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 28, no. 1, pp. 131–142, 1966.
- [24] T. Kailath, "The divergence and bhattacharyya distance measures in signal selection," *IEEE transactions on communication technology*, vol. 15, no. 1, pp. 52–60, 1967.
- [25] T. Sorensen, "A method of establishing groups of equal amplitude in plant sociology based on similarity of species content and its application to analyses of the vegetation on danish commons," *Biologiske skrifter*, vol. 5, pp. 1–34, 1948.
- [26] K. Florek, J. Łukaszewicz, J. Perkal, H. Steinhaus, and S. Zubrzycki, "Sur la liaison et la division des points d'un ensemble fini," in *Colloquium mathematicum*, vol. 2, pp. 282–285, 1951.

- [27] J. H. Ward Jr, "Hierarchical grouping to optimize an objective function," *Journal of the American statistical association*, vol. 58, no. 301, pp. 236–244, 1963.
- [28] K. Matusita, "On the notion of affinity of several distributions and some of its applications," *Annals of the institute of Statistical Mathematics*, vol. 19, pp. 181–192, 1967.
- [29] G. T. Toussaint, "Some inequalities between distance measures for feature evaluation," *IEEE Transactions on Computers*, vol. 21, no. 04, pp. 409–410, 1972.
- [30] T. Vo Van and T. Pham-Gia, "Clustering probability distributions," *Journal of Applied Statistics*, vol. 37, no. 11, pp. 1891–1910, 2010.
- [31] T. VoVan and T. NguyenTrang, "Similar coefficient for cluster of probability density functions," *Communications in Statistics-Theory and Methods*, vol. 47, no. 8, pp. 1792–1811, 2018.
- [32] J. C. Bezdek, *Pattern recognition with fuzzy objective function algorithms*. Springer Science & Business Media, 2013.
- [33] D. S. Watson, "On the philosophy of unsupervised learning," *Philosophy & Technology*, vol. 36, no. 2, p. 28, 2023.
- [34] J. C. Dunn, "A fuzzy relative of the isodata process and its use in detecting compact well-separated clusters," 1973.
- [35] J. C. Bezdek, "A convergence theorem for the fuzzy isodata clustering algorithms," *IEEE transactions on pattern analysis and machine intelligence*, no. 1, pp. 1–8, 1980.
- [36] R. J. Hathaway and J. C. Bezdek, "Recent convergence results for the fuzzy c-means clustering algorithms," *Journal of Classification*, vol. 5, no. 2, pp. 237–247, 1988.
- [37] W. I. Zangwill, "Nonlinear programming: a unified approach," (*No Title*), 1969.
- [38] L. Groll and J. Jakel, "A new convergence proof of fuzzy c-means," *IEEE Transactions on Fuzzy Systems*, vol. 13, no. 5, pp. 717–720, 2005.
- [39] C. Goutte, P. Toft, E. Rostrup, F. Å. Nielsen, and L. K. Hansen, "On clustering fmri time series," *NeuroImage*, vol. 9, no. 3, pp. 298–310, 1999.
- [40] S. Leonelli, *Data-centric biology: A philosophical study*. University of Chicago Press, 2019.
- [41] S. Fillmore-Patrick, "The logit model measurement problem," *Philosophy of Science*, vol. 92, no. 2, p. 285–303, 2025.
- [42] R. A. Fisher, "The use of multiple measurements in taxonomic problems," *Annals of eugenics*, vol. 7, no. 2, pp. 179–188, 1936.
- [43] F. Rosenblatt, "Principles of neurodynamics: Perceptrons and the theory of brain mechanisms," 1961.

- [44] H. Huynh-Van, T. Le-Hoang, and T. Vo-Van, “Classifying for images based on the extracted probability density function and the quasi bayesian method,” *Computational Statistics*, vol. 39, no. 5, pp. 2677–2701, 2024.
- [45] S. Askari, “Fuzzy c-means clustering algorithm for data with unequal cluster sizes and contaminated with noise and outliers: Review and development,” *Expert Systems with Applications*, vol. 165, p. 113856, 2021.
- [46] H. Yu, H. Li, X. Xu, Q. Gao, and R. Lan, “Suppressed possibilistic fuzzy c-means clustering based on shadow sets for noisy data with imbalanced sizes,” *Applied Soft Computing*, vol. 167, p. 112263, 2024.

CHỈ MỤC

quá khớp (overfitting), 16